MÉTODOS NUMÉRICOS

130146-A

Facultad de Economía

Universidad del Pacífico

Actualizado al 8 de noviembre de 2026

Oswaldo Velásquez C.

Índice general

Capítulo 1. Análisis de errores 5
1. Representación de números 5
2. Errores de redondeo y aritmética de punto flotante 6
3. Propagación de errores 8
4. Ejercicios 16

Capítulo 2. Introducción a los métodos iterativos 19
1. Convergencia de sucesiones escalares 19
2. Convergencia de sucesiones de vectores 19
3. Velocidades de convergencia 20
4. Carácter local de la velocidad 21
5. Criterios de parada 22

Capítulo 3. Sistemas de ecuaciones lineales 23
1. Fundamentos 23
2. Eliminación de Gauss 28
3. La factorización LU 31
4. Errores y condición de una matriz 34
5. Factorización LU para sistemas especiales 38
6. La Factorización QR 40
7. Ejemplos 46
8. Ejercicios 51
9. El teorema del punto fijo de Banach 54
10. Soluciones de sistemas de ecuaciones lineales por métodos iterativos 55

Capítulo 4. Sistemas de ecuaciones no lineales 65
1. Métodos unidimensionales 65
2. Teoremas de convergencia 69
3. Métodos de Minimización 74

Capítulo 5. Aproximación lineal 81
1. Introducción 81
2. Ecuaciones normales 81
3. Tratamiento numérico 83
4. Ejercicios 83

Capítulo 6. Interpolación 85
1. Interpolación polinomial 85
2. Splines cúbicos 95
3. Interpolación trigonométrica 98
4. Ejercicios 103

Capítulo 7. Integración Numérica 107
1. Fórmulas de Newton-Cotes 107
2. Fórmula de Cuadratura de Gauss 112

Capítulo 8. Ecuaciones Diferenciales Ordinarias 115
1. Problemas de valor inicial 115

Capítulo 9. Optimización numérica 121
1. Programación lineal 121
2. Optimización sin restricciones 133

Bibliografía 137

Capítulo 1

Análisis de errores

Acceder a la precisión de los resultados de los cálculos es una meta importante en el análisis numérico. Podemos distinguir varias clases de error que pueden limitar esta precisión:

- *Errores en los datos de entrada*, provocados por limitaciones y/o imperfecciones de los instrumentos físicos;
- *Errores de redondeo*, por el cálculo de números que están representados con un número finito de dígitos;
- *Errores de aproximación*, cuando aproximamos la solución de un problema P resolviendo un problema P'. Un ejemplo de esto es la aproximación de una suma infinita por otra finita;

$$e \approx 1 + \frac{1}{1!} + \frac{1}{2!} + \cdots + \frac{1}{N!}$$

El error resultante de aproximación es llamado comúnmente *error de truncamiento*. Lo que hacemos es discretizar un problema: por ejemplo cocientes diferenciales son aproximados por cocientes de diferencias, integrales definidas por sumas finitas, etc. En dichos casos, el error de aproximación es llamado *error de discretización*.
En este capítulo se analizarán los dos primeros tipos de errores.

1. Representación de números

Se presentan dos tipos de máquinas según la manera en la que representan los números:

1. *Computadoras analógicas*, se caracterizan por resolver un problema matemático simulándolo por un problema físico, resolviéndolo por medición y retornando un resultado. Los números son representados por cantidades físicas, como por ejemplo, la longitud de una barra o la intensidad de un voltaje. Es claro que la precisión de los dispositivos analógicos se encuentra directamente limitada por las mediciones físicas que emplean.
2. *Computadoras digitales*, entre las cuales se encuentran las computadoras personales (PC); expresan los dígitos de la representación de un número por una secuencia discreta de cantidades físicas. Un ejemplo de esto es la representación del número binario 11010110 con una secuencia de ocho diodos: el 1 se representa con el diodo encendido, y el 0 con el diodo apagado. La representación de dígitos en computadoras digitales no requiere tanta precisión como la representación de números en las computadoras analógicas. Nosotros estudiaremos este tipo de computadoras.

Un número entero N se puede representar como

$$N = \pm(\alpha_n p^n + \alpha_{n-1} p^{n-1} + \cdots + \alpha_0)$$

donde $p \in \mathbb{N}, p > 1$ es la *base* del sistema de numeración y $\alpha_i \in \{0, 1, \ldots, (p-1)\}$, $i = 0, 1, \ldots, n$

EJEMPLO 1.1. El número 18 (base 10) admite la descomposición en base 2:

$$18 = 1 \cdot 2^4 + 0 \cdot 2^3 + 0 \cdot 2^2 + 1 \cdot 2^1 + 0 \cdot 2^0 = 10010_{(2)}$$

Un número arbitrario se puede representar, en particular, en base 2, como:

$$x = \pm(\alpha_n 2^n + \alpha_{n-1} 2^{n-1} + \cdots + \alpha_o 2^0 + \alpha_{-1} 2^{-1} + \alpha_{-2} 2^{-2} + \cdots)$$

donde $\alpha_i \in \{0, 1\}$. Para cualquier otra base se puede realizar esto de manera análoga.

En las computadoras digitales se ha de representar los números con un número finito de lugares, la *longitud de palabra*. La *representación de punto fijo* especifica un número fijo n_1 de lugares antes de y un número fijo n_2 de lugares después del punto decimal (binario), tales que $n = n_1 + n_2 =$ longitud de palabra (usualmente $n_1 = 0$ o $n_1 = n$). De este modo, un número x se representa en la máquina como (en base 2)

$$x = \pm(\alpha_{n_1-1} 2^{n_1-1} + \alpha_{n_1-2} 2^{n_1-2} + \cdots + \alpha_0 2^0 + \alpha_{-1} 2^{-1} + \alpha_{-2} 2^{-2} + \cdots + \alpha_{-n_2} 2^{-n_2})$$

EJEMPLO 1.2. Para $n = 10$, $n_1 = 4$, $n_2 = 6$

$$145{,}6132 \rightarrow \boxed{0145}\boxed{613200}$$

En esta representación, la posición del punto decimal (binario) es fija.

Más importante es la *representación de punto flotante*. Aquí el punto decimal (binario) no se encuentra fijo. Esto es hecho con un *exponente*. Cada número puede ser representado en la forma

$$x = a \cdot 10^b (x = a \cdot 2^b) \text{ con } |a| < 1, b \text{ entero}$$

EJEMPLO 1.3. $30{,}421 = 0{,}30241 \cdot 10^2$.

El exponente b indica la posición del punto decimal con respecto a la *mantisa* a. Rutishauser propuso la notación : $0{,}30241_{10}2$
En cada computadora existen, por supuesto, números finitos t y e, $n = t + e$, de lugares disponibles para la representación de mantisa y exponente, respectivamente.

EJEMPLO 1.4. Para $t = 4$, $e = 2$, el número 5420 en el sistema decimal se expresa:

$$0\boxed{5420}_{10}\boxed{04}$$

o bien

$$\boxed{5420}\boxed{04}$$

Una representación de punto flotante es *normalizada* si el primer dígito de la mantisa es distinto de 0. Entonces $|a| \geq 10^{-1}$ ($|a| \geq 2^{-1}$). Los *dígitos significativos (bits)* de un número son los dígitos de la mantisa sin contar ceros al principio.

En lo que sigue, consideraremos solamente representaciones de punto flotante y su aritmética de punto flotante correspondiente. Los números t y e, junto con la base B, determinan el conjunto $A \subset \mathbb{R}$ de los números reales que pueden ser representados exactamente con una computadora dada. Los elementos de A son llamados *números de máquina*.

2. Errores de redondeo y aritmética de punto flotante

El conjunto A de números de máquina es finito. Luego surgen las preguntas: ¿ Cómo representar un número $x \notin A$? Además, dados dos números de máquina, es posible que su suma o su producto no sean números de máquina.
Es natural postular que la aproximación de cualquier número $x \notin A$ por un número de máquina $\mathrm{rd}(x)$ deba cumplir la condición

$$\big|x - \mathrm{rd}(x)\big| \leq |x - g|, \quad \text{para todo } g \in A.$$

EJEMPLO 1.5. Para $t = 4$

$$\begin{aligned} \mathrm{rd}(0{,}14285_{10}0) &= 0{,}1429_{10}0 \\ \mathrm{rd}(3{,}14159_{10}0) &= 0{,}3142_{10}1 \end{aligned}$$

En general se procede como sigue: $x \notin A$ se normaliza primero a $x = a \cdot 10^b$, donde $|a| \geq 10^{-1}$. Supongamos que la representación decimal de $|a|$ es dada por

$$|a| = 0.\alpha_1\alpha_2 \ldots \alpha_i\alpha_{i+1} \ldots, \quad 0 \leq \alpha_i \leq 9, \quad \alpha_1 \neq 0.$$

Entonces se forma

$$a' := \begin{cases} 0.\alpha_1\alpha_2 \ldots \alpha_t & \text{si } 0 \leq \alpha_{t+1} \leq 4, \\ 0.\alpha_1\alpha_2 \ldots \alpha_t + 10^{-t} & \text{si } \alpha_{t+1} \geq 5 \end{cases}$$

Finalmente se coloca

$$\mathrm{rd}'(x) := \mathrm{sign}(x) \cdot a' \cdot 10^b.$$

NOTA. Cuando se aproxima un número real x mediante otro número x^* el *error* que resulta es $(x - x^*)$. El *error absoluto* es $|x - x^*|$ y el *error relativo* es $\left|\dfrac{x - x^*}{x}\right| \approx \left|\dfrac{x - x^*}{x^*}\right|$ si $x \neq 0$.

El error relativo de aproximar x por $\mathrm{rd}'(x)$ es (recordar que $|a| \geq 10^{-1}$)

$$\left|\frac{\mathrm{rd}'(x) - x}{x}\right| \leq \frac{5 \cdot 10^{-(t+1)}}{|a|} \leq 5 \cdot 10^{-t}.$$

Con la abreviación $\mathrm{eps} = 5 \cdot 10^{-t}$ podemos escribir

$$\mathrm{rd}'(x) = x(1 + \varepsilon), \text{ con } |\varepsilon| \leq \mathrm{eps}\,.$$

La cantidad $\mathrm{eps} = 5 \cdot 10^{-t}$ es llamada *precisión de la máquina* . En el sistema binario, podemos definir todo lo anterior análogamente.

Siempre que $\mathrm{rd}'(x) \in A$, se podrá definir correctamente $\mathrm{rd}'(x) := \mathrm{rd}(x)$. Sin embargo, esto no siempre ocurre como se muestra en el siguiente ejemplo.

EJEMPLO 1.6. Para $t = 4$, $e = 2$ tenemos

$$\begin{aligned} \mathrm{rd}'(0{,}31974_{10}110) &= 0{,}3197_{10}110 \notin A \\ \mathrm{rd}'(0{,}99997_{10}99) &= 0{,}1000_{10}100 \notin A \\ \mathrm{rd}'(0{,}012345_{10} - 99) &= 0{,}1235_{10} - 100 \notin A \\ \mathrm{rd}'(0{,}54321_{10} - 110) &= 0{,}5432_{10} - 110 \notin A \end{aligned}$$

En el primer y segundo caso el exponente es muy grande para el espacio: entonces tenemos un *overflow* de exponente (sobreflujo). El tercer y cuarto casos son instancias de un *underflow*, esto es, el exponente del número representado es muy negativo. En estos casos podemos prevenir el underflow definiendo

$$\mathrm{rd}(0{,}012345_{10} - 99) = 0{,}0123_{10} - 99 \in A.$$

$$\mathrm{rd}(0{,}54321_{10} - 110) = 0 \in A.$$

Como el overflow y el underflow son poco frecuentes y requieren un tratamiento especial, para simplificar la teoría asumiremos en adelante que $e = \infty$. De este modo tendremos $\mathrm{rd} := \mathrm{rd}'$, y aseguraremos que

$$\begin{aligned} &\mathrm{rd} : \mathbb{R} \to A \\ &\mathrm{rd}(x) = x(1 + \varepsilon) \quad \text{con } |\varepsilon| \leq \mathrm{eps}, \quad \forall x \in \mathbb{R}. \end{aligned}$$

Como los resultados de las operaciones aritméticas no son necesariamente números de máquina, requeriremos definir *operaciones de punto flotante*, $+^*, -^*, \cdot^*, /^*$,

las cuales son definidas como:

$$\left.\begin{array}{l} x +^* y := \mathrm{rd}(x+y), \\ x -^* y := \mathrm{rd}(x-y), \\ x \cdot^* y := \mathrm{rd}(x\cdot y), \\ x/^* y := \mathrm{rd}(x/y), \end{array}\right. \quad \text{para } x, y \in A,$$

lo cual implica

$$\left.\begin{array}{r} x +^* y := (x+y)(1+\varepsilon_1) \\ x -^* y := (x-y)(1+\varepsilon_2) \\ x \cdot^* y := (x\cdot y)(1+\varepsilon_3) \\ x/^* y := (x/y)(1+\varepsilon_4) \end{array}\right\} \quad |\varepsilon_i| \leq \mathrm{eps}\,.$$

De lo anterior se observará que las operaciones de punto flotante no satisfacen las leyes conocidas para las operaciones aritméticas usuales. Por ejemplo,

$$x +^* y = x, \text{ si } |y| < \frac{\mathrm{eps}}{B}|x|, \quad x, y \in A$$

La precisión de máquina eps puede también definirse entonces como

$$\mathrm{eps} = \mathrm{mín}\{g \in A / 1 +^* g > 1 \wedge g > 0\}.$$

Además, las operaciones de punto flotante no son asociativas o distributivas.

Ejemplo 1.7 ($t = 8$). Con

$$\begin{array}{rl} a := & 0{,}23371258_{10} - 4, \\ b := & 0{,}33678429_{10}2, \\ c := & -0{,}33677811_{10}2. \end{array}$$

$$\begin{array}{rl} a +^* (b +^* c) & = 0{,}23371258_{10} - 4 +^* 0{,}61800000_{10} - 3, \\ & = 0{,}64137126_{10} - 3, \\ (a +^* b) +^* c & = 0{,}33678452_{10}2 -^* 0{,}33677811_{10}2, \\ & = 0{,}64100000_{10} - 3. \end{array}$$

El resultado exacto es

$$a + b + c = 0{,}641371258_{10} - 3.$$

3. Propagación de errores

Para expresar el resultado de operaciones de punto flotante, una notación ha sido ampliamente aceptada, y la usaremos frecuentemente: dada una expresión E a calcular, $\mathrm{fl}(E)$ denota el valor de la expresión obtenida por aritmética de punto flotante.

Ejemplo 1.8.

$$\begin{array}{l} \mathrm{fl}(x\cdot y) := x \cdot^* y \\ \mathrm{fl}\big(a + (b+c)\big) := a +^* (b +^* c) \\ \mathrm{fl}\big((a+b)+c\big) := (a +^* b) +^* c \\ \mathrm{fl}\big(\cos(x)\big) := \cos^*(x) \\ \mathrm{fl}\big(\sqrt{x}\big) := \sqrt{x}^* \end{array}$$

Las operaciones $+, -, \cdot, /, \cos, \sqrt{}$, junto con algunas otras (que posean substitutos $*$) serán llamadas *operaciones elementales*. Como se vio, dos diferentes pero matemáticamente equivalentes maneras de evaluar la misma expresión $a + b + c$ pueden llevar a diferentes resultados, cuando usamos aritmética de punto flotante. Para propósitos numéricos es necesario distinguir entre distintos esquemas de evaluación incluso si ellos son matemáticamente equivalentes. Llamaremos *algoritmo* a una secuencia finita de operaciones elementales (dadas como instrucciones de computadora) que prescriben como calcular la solución de un problema a partir de una entrada de datos dada.

Formalizemos un poco la noción de algoritmo. Supongamos que el problema consiste en calcular los números reales $y_1, \ldots, y_m$ a partir de las entradas $x_1, \ldots, x_n$. Si introducimos los vectores

$$x = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}, \quad y = \begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix},$$

entonces resolver el problema significa determinar el valor $y = \varphi(x)$ donde

$$\varphi : D \to \mathbb{R}^m, \quad D \subset \mathbb{R}^n,$$
$$y_i = \varphi_i(x_1, \ldots, x_n), \quad i = 1, \ldots, m.$$

En cada paso del cálculo hay un *conjunto de operandos* de números. Una sola operación calcula un nuevo número a partir de uno o más operandos del conjunto de operandos. El nuevo número es un resultado intermedio o el final.

Una operación corresponde a una transformación del conjunto de operandos. Escribiendo éstos consecutivamente como vectores,

$$x^{(i)} = \begin{bmatrix} x_1^{(i)} \\ \vdots \\ x_{n_i}^{(i)} \end{bmatrix} \in \mathbb{R}^{n_i},$$

podemos asociar a cada operación elemental un *mapeo elemental*

$$\varphi^{(i)} : D_i \to \mathbb{R}^{n_{i+1}}, \quad D_i \subset \mathbb{R}_{n_i},$$

tal que

$$\varphi^{(i)}\big(x^{(i)}\big) = x^{(i+1)}.$$

Dado un algoritmo, entonces su secuencia de operaciones elementales da lugar a la descomposición de φ en una secuencia de mapeos elementales

$$\varphi^{(i)} : D_i \to D_{i+1}, \quad i = 0, 1, \ldots, r, \quad D_j \subset \mathbb{R}^{n_j},$$
$$\varphi = \varphi^{(r)} \circ \varphi^{(r-1)} \circ \cdots \circ \varphi^{(0)}, \quad D_0 = D, \quad D_{r+1} \subset \mathbb{R}^{n_{r+1}} = \mathbb{R}^m,$$

que caracteriza al algoritmo.

Ejemplo 1.9. Para $\varphi(a, b, c) = a + b + c$, consideremos los dos algoritmos $\eta := a + b$, $y := c + \eta$ y $\eta := b + c$, $y := a + \eta$. Las descomposiciones son:

$$\varphi^{(0)}(a, b, c) := \begin{bmatrix} a + b \\ c \end{bmatrix} \in \mathbb{R}^2, \qquad \varphi^{(1)}(u, v) := u + v \in \mathbb{R}$$

y

$$\varphi^{(0)}(a, b, c) := \begin{bmatrix} a \\ b + c \end{bmatrix} \in \mathbb{R}^2, \qquad \varphi^{(1)}(u, v) := u + v \in \mathbb{R}.$$

Ejemplo 1.10. Para $\varphi(a, b) := a^2 - b^2$ se tienen los algoritmos

- Algoritmo 1:
$$\eta_1 := a \cdot a,$$
$$\eta_2 := b \cdot b,$$
$$y := \eta_1 - \eta_2,$$
- Algoritmo 2:
$$\eta_1 := a + b,$$
$$\eta_2 := a - b,$$
$$y := \eta_1 \cdot \eta_2.$$

Sus descomposiciones correspondientes son

- Algoritmo 1:

$$\varphi^{(0)}(a,b) := \begin{bmatrix} a^2 \\ b \end{bmatrix}, \varphi^{(1)}(u,v) := \begin{bmatrix} u \\ v^2 \end{bmatrix}, \varphi^{(2)}(u,v) := u - v.$$

- Algoritmo 2:

$$\varphi^{(0)}(a,b) := \begin{bmatrix} a \\ b \\ a+b \end{bmatrix}, \quad \varphi^{(1)}(a,b,u) := \begin{bmatrix} u \\ a-b \end{bmatrix}, \varphi^{(1)}(a,b,u) := u \cdot v.$$

Nótese que las descomposiciones de los algoritmos pueden ser simplificadas:

$$\text{Algoritmo 1:} \qquad \varphi'^{(0)}(a,b) := \begin{bmatrix} a^2 \\ b^2 \end{bmatrix}, \qquad \varphi'^{(1)}(u,v) := u - v.$$

$$\text{Algoritmo 2:} \qquad \varphi'^{(0)}(a,b) := \begin{bmatrix} a+b \\ a-b \end{bmatrix}, \qquad \varphi'^{(1)}(u,v) := u \cdot v.$$

Estrictamente hablando, los mapeos $\varphi'^{(0)}$ no son elementales. Sin embargo lo más importante al hacer las descomposiciones es que las componentes de los mapeos intermedios sean elementales, para poder hacer así el análisis de error que se estudiará a continuación.

EJEMPLO 1.11. $y := a + b + c$,

$$\begin{aligned} \tilde{y} &:= \mathrm{rd}((a+b)+c) \\ &= \mathrm{rd}(a+b) +^* c \\ &= (a+b)(1+\varepsilon_1) +^* c \\ &= [(a+b)(1+\varepsilon_1)+c](1+\varepsilon_2) \\ &= (a+b+c)\left[1 + \frac{a+b}{a+b+c}\varepsilon_1(1+\varepsilon_2) + \varepsilon_2\right]. \end{aligned}$$

Despreciamos el término $\varepsilon_1\varepsilon_2$ por ser de grado superior; luego el error relativo (al haber calculado primero $(a+b)$) es

$$\varepsilon_y := \frac{\tilde{y}-y}{y} = \frac{\tilde{y}}{y} - 1 \approx \frac{a+b}{a+b+c}\varepsilon_1 + \varepsilon_2,$$

el cual es pequeño si $(a+b)$ es pequeño.

Si se hubiese calculado primero $(b+c)$ tendriamos

$$\varepsilon_y \approx \frac{b+c}{a+b+c}\varepsilon_1' + \varepsilon_2',$$

que es pequeño si $(b+c)$ es pequeño.

Vamos a hacer ahora un *análisis diferencial de error* de un algoritmo para calcular $y := \varphi(x)$ si esta función está dada por la descomposición:

$$\varphi = \varphi^{(r)} o\, \varphi^{(r-1)} o \ldots o\, \varphi^{(0)}.$$

Para este fin necesitamos investigar como los errores de entrada, así como los errores por redondeo acumulados durante el curso del algoritmo afectan el resultado final. Iniciamos esta investigación considerando solamente los errores de entrada Δx. Supongamos que la función

$$\varphi : D \to \mathbb{R}^m, \qquad \varphi = \begin{bmatrix} \varphi_1(x_1,\ldots,x_n) \\ \vdots \\ \varphi_m(x_1,\ldots,x_n) \end{bmatrix},$$

está definida en un conjunto abierto D de $\mathbb{R}^n$, y que sus funciones componentes φ_i, $i = 1, 2, \ldots, n$, poseen derivadas continuas en D. Sea $\tilde{x}$ un valor aproximado de x. Entonces denotamos por

$$\Delta x_i := \tilde{x}_i - x_i, \qquad \Delta x := \tilde{x} - x,$$

al *error absoluto* $\tilde{x}_i$ y $\tilde{x}$, respectivamente. El *error relativo* de $\tilde{x}_i$ es definido como la cantidad

$$\varepsilon_{\tilde{x}_i} := \frac{\tilde{x}_i - x_i}{x_i} \quad \text{si } x_i \neq 0.$$

Reemplazando x por $\tilde{x}$ obtenemos el resultado $\tilde{\mathrm{y}} := \varphi(\tilde{x})$ en vez de $y = \varphi(x)$. Expandiendo en series de Taylor y despreciando los términos de mayor orden, tenemos

$$\begin{aligned} \Delta y_i &:= \tilde{y}_i - y_i = \varphi_i(\tilde{x}) - \varphi_i(x) \approx \sum_{j=1}^{n} (\tilde{x}_j - x_j) \frac{\partial \varphi_i(x)}{\partial x_j} \\ &= \sum_{j=1}^{n} \frac{\partial \varphi_i(x)}{\partial x_j} \Delta x_j, \quad i = 1, \ldots, m, \end{aligned}$$

de donde

$$\Delta y = \begin{bmatrix} \Delta y_1 \\ \vdots \\ \Delta y_m \end{bmatrix} \approx \begin{bmatrix} \dfrac{\partial \varphi_1(x)}{\partial x_1} & \cdots & \dfrac{\partial \varphi_1(x)}{\partial x_n} \\ \vdots & & \vdots \\ \dfrac{\partial \varphi_m(x)}{\partial x_1} & \cdots & \dfrac{\partial \varphi_m(x)}{\partial x_n} \end{bmatrix} \begin{bmatrix} \Delta x_1 \\ \vdots \\ \Delta x_n \end{bmatrix} = D\varphi(x) \cdot \Delta x,$$

con la matriz jacobiana $D\varphi(x)$.

La cantidad $\dfrac{\partial \varphi_i(x)}{\partial x_j}$ representa la sensitividad con que y_i reacciona a las perturbaciones Δx_j de x_j.
Si $y_i \neq 0$ para $i = 1, \ldots, m$ y $x_j \neq 0$ para $j = 1, \ldots, n$ entonces se tiene:

$$\begin{aligned} \varepsilon_{y_i} = \frac{\tilde{y}_i - y_i}{y_i} &\approx \sum_{j=1}^{n} \frac{\partial \varphi_i(x)}{\partial x_j} \frac{\tilde{x}_j - x_j}{y_i} \\ &= \sum_{j=1}^{n} \left(\frac{x_j}{y_i} \frac{\partial \varphi_i(x)}{\partial x_j} \right) \frac{\tilde{x}_j - x_j}{x_j} \\ &= \sum_{j=1}^{n} \left(\frac{x_j}{y_i} \frac{\partial \varphi_i(x)}{\partial x_j} \right) \varepsilon_{x_j}. \end{aligned}$$

Los factores de amplificación $(x_j/\varphi_i)\partial\varphi_i/\partial x_j$ para el error relativo son llamados *números de condicionamiento*. Si alguno de estos números es en valor absoluto muy grande, se dice que el problema es *mal condicionado*. En otro caso, se dice que está *bien condicionado*. Como se puede observar, la condición del problema está descrita por mn números. Por estas razones, hay una manera más práctica de definir la condición del problema. En álgebra lineal, usando una norma conveniente $\|\cdot\|$, el número de condición c deberá satisfacer

$$\frac{\|\varphi(\tilde{x}) - \varphi(x)\|}{\|\varphi(x)\|} \leq c \frac{\|\tilde{x} - x\|}{\|x\|}.$$

Ejemplo 1.12. Para $\varphi(a, b, c) := a + b + c$ se tiene

$$\begin{aligned} \varepsilon_y &\approx \frac{a}{y} \frac{\partial \varphi(a,b,c)}{\partial a} \varepsilon_a + \frac{b}{y} \frac{\partial \varphi(a,b,c)}{\partial b} \varepsilon_b + \frac{c}{y} \frac{\partial \varphi(a,b,c)}{\partial c} \varepsilon_c \\ &= \frac{a}{a+b+c} \varepsilon_a + \frac{b}{a+b+c} \varepsilon_b + \frac{c}{a+b+c} \varepsilon_c. \end{aligned}$$

El problema estará bien condicionado cuando los sumandos a, b, c sean pequeños comparados con $a + b + c$ (por ejemplo, cuando todos tengan el mismo signo).

EJEMPLO 1.13. Para $y = \varphi(a, b) := -a + \sqrt{a^2 + b}$,

$$\begin{aligned}\varepsilon_y \quad &\approx \frac{a}{y}\left(-1 + \frac{a}{\sqrt{a^2+b}}\right)\varepsilon_a + \frac{b}{y}\frac{1}{2\sqrt{a^2+b}}\varepsilon_b \\ &\frac{-a}{\sqrt{a^2+b}}\varepsilon_a + \frac{a+\sqrt{a^2+b}}{2\sqrt{a^2+b}}\varepsilon_b.\end{aligned}$$

Desde que

$$\left|\frac{a}{\sqrt{a^2+b}}\right| \le 1, \quad \left|\frac{a+\sqrt{a^2+b}}{2\sqrt{a^2+b}}\right| \le 1 \qquad \text{para } b > 0;$$

tendremos que φ es bien condicionado si $b > 0$, y mal condicionado si $b \approx -a^2$.

Cuando se substraen dos números $x, y \in A$ del mismo signo, uno debe tener cuidado con la cancelación (esto es, cuando los números tienen valores absolutos casi iguales). Por ejemplo, para calcular

$$y = \sqrt{x^2 + 1} - 1$$

cuando el valor de x es cercano a cero, se sugiere calcular equivalentemente

$$y = (\sqrt{x^2+1} - 1) \cdot \frac{\sqrt{x^2+1}+1}{\sqrt{x^2+1}+1} = \frac{x^2}{\sqrt{x^2+1}+1}.$$

Para evitar desbordamientos (overflow, underflow)

$$z := \frac{x^2 + y^2}{\sqrt{x^4 + y^4}}$$

en caso $|x| < |y|$, hacemos $t := \dfrac{x}{y}(|t| < 1)$. Entonces calculamos

$$z = \frac{t^2 + 1}{\sqrt{t^4 + 1}}.h$$

Para las operaciones aritméticas $(x \neq 0, y \neq 0)$

$$\begin{aligned}&\varphi(x, y) := x \cdot y && \varepsilon_{xy} \approx \varepsilon_x + \varepsilon_y \\ &\varphi(x, y) := x/y && \varepsilon_{x/y} \approx \varepsilon_x - \varepsilon_y \\ &\varphi(x, y) := x \pm y && \varepsilon_{x\pm y} \approx \frac{x}{x \pm y}\varepsilon_x + \frac{y}{x \pm y}\varepsilon_y \text{ si } x \pm y \neq 0 \\ &\varphi(x) := \sqrt{x} && \varepsilon_{\sqrt{x}} \approx \tfrac{1}{2}\varepsilon_x\end{aligned}$$

Se sigue que la multiplicación, división, y raíz cuadrada no son peligrosas. Si los operandos son del mismo signo, la adición no es peligrosa: En efecto, tendremos que

$$|\varepsilon_{x+y}| \le \text{máx}\{|\varepsilon_x|, |\varepsilon_y|\}$$

Si los operandos tienen signos distintos, entonces almenos uno de los factores $\left|\dfrac{x}{x+y}\right|$ o $\left|\dfrac{y}{x+y}\right|$ es mayor que uno; entonces los errores serán amplificados, y drásticamente amplificados si $x \approx -y$.

Un algoritmo para calcular la función $\varphi : D \to \mathbb{R}^m, D \subset \mathbb{R}^n$, para un dado $x = (x_1, \ldots, x_n)^T \in D$ corresponde a la descomposición de φ en mapeos elementales $\varphi^{(i)}, i = 0, 1, \ldots, r$. Luego $y = \varphi(x)$ se obtiene por una cadena de resultados intermedios

$$x^{(0)} := x \to \varphi^{(0)}(x^{(0)}) = x^{(1)} \to \cdots \to \varphi^{(r)}(x^{(r)}) = x^{(r+1)} = y.$$

Suponemos de nuevo que cada $\varphi^{(i)}$ es continuamente diferenciable en D_i, y denotemos por $\psi^{(i)}$ el *mapeo remanente*

$$\psi^{(i)} = \varphi^{(r)} \circ \varphi^{(r-1)} \circ \cdots \circ \varphi^{(i)} : D_i \to \mathbb{R}^m, \quad i = 0, 1, 2, \ldots, r.$$

Entonces $\psi^{(0)} \equiv \varphi$. De la regla de la cadena, tenemos

$$D\varphi(x) = D\varphi^{(r)}(x^{(r)}) \cdot D\varphi^{(r-1)}(x^{(r-1)}) \cdot \cdots \cdot D\varphi^{(0)}(x),$$

$$D\psi(x^{(i)}) = D\varphi^{(r)}(x^{(r)}) \cdot D\varphi^{(r-1)}(x^{(r-1)}) \cdot \cdots \cdot D\varphi^{(i)}(x^{(i)}), \quad i = 0, 1, \ldots, r.$$

En el cálculo con punto flotante bajo la influencia de los errores de entrada y los errores por redondeo en lugar de los resultados intermedios $x^{(i)}$ se obtienen valores aproximados $\tilde{x}^{(i)}$ con $\tilde{x}^{(i+1)} = \mathrm{fl}(\varphi^{(i)}(\tilde{x}^{(i)}))$.
De esto se obtiene, para los errores absolutos $\Delta x^{(i)} = \tilde{x}^{(i)} - x^{(i)}$,

$$\Delta x^{(i+1)} = [\mathrm{fl}(\varphi^{(i)}(\tilde{x}^{(i)})) - \varphi^{(i)}(\tilde{x}^{(i)})] + [\varphi^{(i)}(\tilde{x}^{(i)}) - \varphi^{(i)}(x^{(i)})].$$

Usando series de Taylor, y despreciando términos de orden superior:

$$\varphi^{(i)}(\tilde{x}^{(i)}) - \varphi^{(i)}(x^{(i)}) \approx D\varphi^{(i)}(x^{(i)})\Delta x^{(i)}.$$

Como $\varphi^{(i)}$ es elemental, o bien involucra sólo operaciones elementales independientes, tenemos que

$$\mathrm{fl}(\varphi^{(i)}(u)) = \mathrm{rd}(\varphi^{(i)}(u)).$$

Nótese ahora que $\varphi^{(i)} : D_i \to D_{i+1} \subset \mathbb{R}^{n_{i+1}}$ es un vector de funciones componentes $\varphi_j^{(i)} : D_i \to \mathbb{R}$,

$$\varphi^{(i)}(u) = \begin{bmatrix} \varphi_1^{(i)}(u) \\ \vdots \\ \varphi_{n_{i+1}}^{(i)}(u) \end{bmatrix}.$$

Así, podemos trabajar con las componentes. De este modo:

$$\mathrm{fl}(\varphi_j^{(i)}(u)) = \mathrm{rd}(\varphi_j^{(i)}(u)) = (1 + \varepsilon_j)\varphi_j^{(i)}(u),$$

$$|\varepsilon_j| \leq \mathrm{eps}, \qquad j = 1, 2, \ldots, n_{i+1}$$

Entonces podemos simplemente escribir

$$\mathrm{fl}(\varphi^{(i)}(u)) = (I + E_{i+1}) \cdot \varphi^{(i)}(u).$$

Con la matriz identidad I y la matriz diagonal de error

$$E_{i+1} = \begin{bmatrix} \varepsilon_1 & 0 & \cdots & 0 \\ 0 & \varepsilon_2 & & 0 \\ \vdots & & \ddots & \vdots \\ 0 & 0 & \cdots & \varepsilon_{n_{i+1}} \end{bmatrix}, \qquad |\varepsilon_j| \leq \mathrm{eps}\,.$$

Esto nos da

$$\mathrm{fl}(\varphi^{(i)}(\tilde{x}^{(i)})) - \varphi^{(i)}(\tilde{x}^{(i)}) = E_{i+1} \cdot \varphi^{(i)}(\tilde{x}^{(i)}),$$

pero $E_{i+1} \cdot \varphi^{(i)}(\tilde{x}^{(i)}) \approx E_{i+1} \cdot \varphi^{(i)}(x^{(i)})$ (despreciando términos de orden superior). Por consiguiente

$$\mathrm{fl}(\varphi^{(i)}(\tilde{x}^{(i)})) - \varphi^{(i)}(\tilde{x}^{(i)}) \approx E_{i+1} \cdot \varphi^{(i)}(x^{(i)}) = E_{i+1} \cdot x^{(i+1)} =: \alpha_{i+1}.$$

Por lo anterior, $\Delta x^{(i+1)}$ puede ser expresado con una aproximación de primer orden como

$$\begin{aligned} \Delta x^{(i+1)} &\approx \alpha_{i+1} + D\varphi^{(i)}(x^{(i)}) \cdot \Delta x^{(i)} \\ &= E_{i+1} \cdot x^{(i+1)} + D\varphi^{(i)}(x^{(i)}) \cdot \Delta x^{(i)}, \text{ para } i \geq 0, \quad \Delta x^{(0)} := \Delta x. \end{aligned}$$

Luego

$$\begin{aligned} \Delta x^{(1)} &\approx D\varphi^{(0)}(x)\cdot\Delta x+\alpha_1\\ \Delta x^{(2)} &\approx D\varphi^{(1)}(x^{(1)})\cdot[D\varphi^{(0)}(x)\Delta x+\alpha_1]+\alpha_2\\ &\vdots\\ \Delta y=\Delta x^{(r+1)} &\approx D\varphi^{(r)}\cdots D\varphi^{(0)}\cdot\Delta x+D\varphi^{(r)}\cdots D\varphi^{(1)}\cdot\alpha_1+\cdots+\alpha_{r+1}. \end{aligned}$$

Finalmente, llegamos a la fórmula que describe el efecto de los errores de entrada Δx y los errores de redondeo α_i en el resultado $y = x^{(r+1)} = \varphi(x)$:

$$\begin{aligned} \Delta y &\approx D\varphi(x)\,\Delta x+\sum_{i=1}^{r} D\psi^{(i)}(x^{(i)})\,\alpha_i+\alpha_{r+1}\\ &= D\varphi(x)\,\Delta x+\sum_{i=1}^{r} D\psi^{(i)}(x^{(i)})\,E_i x^{(i)}+E_{r+1}y. \end{aligned} \tag{1}$$

3.1. Grafos computacionales. Un *grafo computacional* representa de manera dirigida las operaciones de un algoritmo. Sus nodos son los datos de entrada y las cantidades intermedias. Se dibuja una flecha cuando un nodo depende directamente de otro. En los algoritmos considerados aquí el grafo no contiene ciclos: las operaciones se ejecutan siguiendo el orden indicado por las flechas.

Esta forma de presentar un algoritmo es habitual en la diferenciación automática y en el aprendizaje automático. Es moderna en su uso y en su presentación visual, pero la idea matemática no es nueva: corresponde a los programas de asignaciones sucesivas y a la composición de funciones elementales. En particular, no reemplaza el punto de vista de Stoer–Bulirsch, sino que lo hace visible.

Si un nivel del grafo calcula

$$x^{(i+1)} = \varphi^{(i)}(x^{(i)}),$$

entonces la propagación hacia adelante de un error pequeño satisface

$$\Delta x^{(i+1)} \approx D\varphi^{(i)}(x^{(i)})\,\Delta x^{(i)}+\alpha_{i+1}, \tag{2}$$

donde α_{i+1} es el error de redondeo introducido al evaluar ese nivel. Por tanto, recorrer el grafo desde las entradas hasta la salida y aplicar la regla de la cadena produce exactamente la fórmula (1).

Como ejemplo, consideremos el algoritmo factorizado para calcular

$$y = a^3 - b^3 = (a-b)(a^2+ab+b^2).$$

Una posible descomposición en funciones elementales es

$$d = a-b,\quad u = a^2,\quad v = ab,\quad w = b^2,\quad s = u+v,\quad t = s+w,\quad y = dt.$$

Su grafo computacional es el de la figura 1.

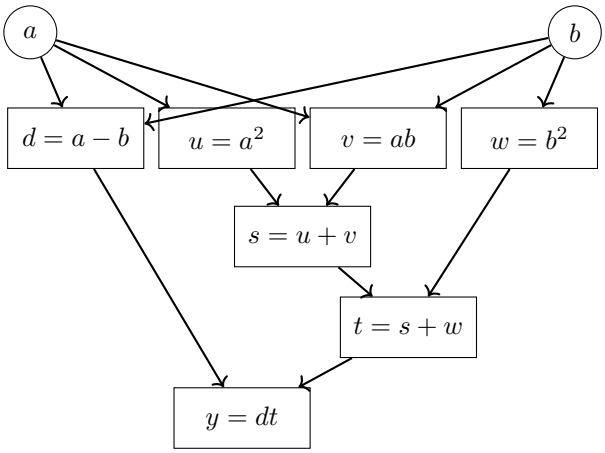


FIGURA 1. Grafo computacional del algoritmo factorizado para $a^3 - b^3$.

Cada flecha tiene asociada una derivada local. La sensibilidad de la salida respecto de un nodo se obtiene sumando, sobre todos los caminos dirigidos que llegan a la salida, los productos de las derivadas locales. Por ejemplo, un error α_d introducido al calcular d aporta aproximadamente $t\alpha_d$ al error de salida, mientras que un error α_t aporta $d\alpha_t$. Asimismo, los errores introducidos al calcular u, v o w se transmiten con factor d.

Los errores de entrada se colocan en los nodos a y b. Al recorrer todos los caminos desde esos nodos se recupera

$$\Delta y_{\text{entrada}} \approx \frac{\partial y}{\partial a}\Delta a + \frac{\partial y}{\partial b}\Delta b = 3a^2\Delta a - 3b^2\Delta b.$$

Los errores de redondeo, en cambio, se introducen en los nodos donde se realizan operaciones. Cada uno es transportado por la función remanente desde ese nodo hasta la salida; esto es precisamente lo que representan los términos $D\psi^{(i)}\alpha_i$ de (1).

El grafo permite distinguir con claridad dos hechos. La función $\varphi(a,b) = a^3 - b^3$ determina la sensibilidad frente a los errores de entrada, independientemente de la expresión elegida. En cambio, cada fórmula algebraicamente equivalente genera un grafo diferente y, por tanto, introduce y propaga errores de redondeo distintos. El grafo ayuda a organizar el cálculo; no modifica por sí mismo el condicionamiento del problema.

EJEMPLO 1.14. Para los dos algoritmos que calculan $y = \varphi(a,b) = a^2 - b^2$ dados tenemos:
Algoritmo 1:

$$x = x^{(0)} = \begin{bmatrix} a \\ b \end{bmatrix}, \quad x^{(1)} = \begin{bmatrix} a^2 \\ b \end{bmatrix}, \quad x^{(2)} = \begin{bmatrix} a^2 \\ b^2 \end{bmatrix}, \quad x^{(3)} = y = a^2 - b^2,$$

$$\psi^{(1)}(u,v) = u - v^2, \qquad \psi^{(2)}(u,v) = u - v,$$

$$D\varphi(x) = (2a, -2b)$$

$$D\psi^{(1)}(x^{(1)}) = (1, -2b), \qquad D\psi^{(2)}(x^{(2)}) = (1, -1),$$

$$\alpha_1 = \begin{bmatrix} \varepsilon_1 a^2 \\ 0 \end{bmatrix}, \quad E_1 = \begin{bmatrix} \varepsilon_1 & 0 \\ 0 & 0 \end{bmatrix},$$

pues

$$\text{fl}(\varphi^{(0)}(x^{(0)})) - \varphi^{(0)}(x^{(0)}) = \begin{bmatrix} a \cdot^* a \\ b \end{bmatrix} - \begin{bmatrix} a^2 \\ b \end{bmatrix}.$$

También

$$\alpha_2 = \begin{bmatrix} 0 \\ \varepsilon_2 b^2 \end{bmatrix}, \quad E_2 = \begin{bmatrix} 0 & 0 \\ \varepsilon_1 & 0 \end{bmatrix}.$$

$\alpha_3 = \varepsilon_3(a^2 - b^2)$, $\quad |\varepsilon_i| \leq \text{eps}$ para $i = 1, 2, 3$.

Con $\Delta x = \begin{bmatrix} \Delta a \\ \Delta b \end{bmatrix}$,

$$\Delta y \approx 2a\Delta a - 2b\Delta b + a^2\varepsilon_1 - b^2\varepsilon_2 + (a^2 - b^2)\varepsilon_3.$$

Análogamente para el algoritmo 2:

$$x = x^{(0)} = \begin{bmatrix} a \\ b \end{bmatrix}, \quad x^{(1)} = \begin{bmatrix} a+b \\ a-b \end{bmatrix}, \quad x^{(2)} = y = a^2 - b^2,$$

$$\psi^{(1)}(u, v) = u \cdot v,$$

$$D\varphi(x) = (2a, -2b), \quad D\psi^{(1)}(x^{(1)}) = (a - b, a + b),$$

$$\alpha_1 = \begin{bmatrix} \varepsilon_1(a+b) \\ \varepsilon_2(a-b) \end{bmatrix}, \quad \alpha_2 = \varepsilon_3(a^2 - b^2), \quad E_1 = \begin{bmatrix} \varepsilon_1 & 0 \\ 0 & \varepsilon_2 \end{bmatrix}, \quad |\varepsilon_i| \leq \text{eps}\,.$$

Por tanto

$$\Delta y \approx 2a\Delta a - 2b\Delta b + (a^2 - b^2)(\varepsilon_1 + \varepsilon_2 + \varepsilon_3).$$

Un algoritmo es llamado *numéricamente más estable* que otro para calcular $\varphi(x)$ si, para un conjunto dado de datos x, el efecto total de redondeo del primero es menor que el del otro.

Ejemplo 1.15. En el ejemplo anterior, el efecto total por redondeo usando el Algoritmo 1 es

$$\left|a^2\varepsilon_1 - b^2\varepsilon_2 + (a^2 - b^2)\varepsilon_3\right| \leq \left(a^2 + b^2 + |a^2 - b^2|\right) \text{eps},$$

y usando el Algoritmo 2

$$|(a^2 - b^2)(\varepsilon_1 + \varepsilon_2 + \varepsilon_3)| \leq 3|a^2 - b^2|\,\text{eps}\,.$$

Esto muestra que el algoritmo 2 es numéricamente más estable que el algoritmo 1 siempre que $\frac{1}{3} < |a/b|^2 < 3$; en otro caso el algoritmo 1 es más estable.

4. Ejercicios

1. Calcule el efecto total de errores de entrada y redondeo (mediante análisis diferencial) de dos algoritmos para evaluaciones distintas de
$$y = (a + b)^2 = a^2 + 2ab + b^2.$$
2. Calcule el efecto total de errores de entrada y redondeo de los dos siguientes algoritmos para la evaluación de
$$y = ax^2 + bx + c$$
   a) Algoritmo 1: $u \leftarrow x^2$, $v \leftarrow a \cdot u$, $w \leftarrow b \cdot x$, $z \leftarrow v + w$, $y \leftarrow z + c$;
   b) Algoritmo 2: $u \leftarrow a \cdot x$, $v \leftarrow u + b$, $w \leftarrow v \cdot x$, $y \leftarrow w + c$.
   Compare la estabilidad numérica de los algoritmos.
3. Para la función lineal $f(x) = a + bx$, donde $a \neq 0$, $b \neq 0$, calcule la primera derivada $f'(0) = b$ por la fórmula
$$D_h f(0) = \frac{f(h) - f(-h)}{2h},$$
   en aritmética de punto flotante binaria. Supongamos que a y b son números de máquina binarios, y h es una potencia de 2. La multiplicación por h y el cociente por $2h$ pueden ser entonces calculados de manera exacta. De una

cota para el error relativo de $D_h f(0)$. ¿Cuál es el comportamiento de este error cuando $h \to 0$?

4. La raíz cuadrada $\pm(u+iv)$ de un número complejo $x+iy$ con $y \neq 0$ puede ser calculada por medio de las fórmulas

$$u = \pm\sqrt{\frac{x+\sqrt{x^2+y^2}}{2}}, \quad v = \frac{y}{2u}.$$

Compare los casos $x \geq 0$ y $x < 0$ con respecto a su estabilidad numérica.

5. Calcule el número de condición en el cálculo de

$$f(x) = \arcsin(x),$$

y encuentre el peor caso posible de expansión del error relativo (de entrada) de x.

6. Demuestre que en aritmética de punto flotante de t lugares decimales

$$\mathrm{rd}(x) = \frac{x}{1+\varepsilon}$$

con $|\varepsilon| \leq 5 \cdot 10^{-t}$.

7. Demuestre que, fijados un número real x y un número entero $k \geq 1$, existe δ, $|\delta| \leq \mathrm{eps}$ tal que

$$\mathrm{fl}(x^k) = x^k(1+\delta)^{k-1}.$$

8. Calcule el efecto total de errores de entrada y redondeo en la evaluación de

$$y = x^3 + 2x^2\cos(a) + b$$

en aritmética de punto flotante binaria, mediante los dos siguientes algoritmos:

a) $u \leftarrow \cos(a)$, $v \leftarrow x^2$, $w \leftarrow vx$, $t \leftarrow vu$, $t' \leftarrow 2t$, $s \leftarrow w + t'$, $y \leftarrow s + b$.

b) $u \leftarrow \cos(a)$, $u' \leftarrow 2u$, $w \leftarrow x + u'$, $v \leftarrow x^2$, $t \leftarrow wv$, $y \leftarrow t + b$.

Compare los errores de redondeo correspondientes según los valores de x, a y b ingresados.

9. Demuestre lo siguiente: sean $x_1, \ldots, x_n$ números de máquina positivos, $n \geq 2$. Entonces, el error de redondeo relativo al calcular $\displaystyle\sum_{k=1}^{n} x_i$ de la manera usual está acotado por

$$(1+\mathrm{eps})^{n-1} - 1.$$

Capítulo 2

Introducción a los métodos iterativos

Un *método iterativo* parte de uno o varios valores iniciales y genera una sucesión

$$r_0, r_1, r_2, \ldots$$

de aproximaciones a la solución r^* de un problema. Para analizarlo distinguiremos tres preguntas: si las aproximaciones convergen, con qué rapidez disminuye el error y cuándo conviene detener el cálculo. La estabilidad numérica completa este análisis y se estudia junto con los errores de redondeo.

En este capítulo no introduciremos una teoría general del orden de convergencia. Trabajaremos directamente con los tres comportamientos que se usan con mayor frecuencia en el curso: convergencia lineal, superlineal y cuadrática.

1. Convergencia de sucesiones escalares

Definición. *Sea $\{r_k\}_{k\geq 0}$ una sucesión de números reales. Decimos que r_k converge a r^*, y escribimos*

$$\lim_{k\to\infty} r_k = r^*,$$

si, para cada $\varepsilon > 0$, existe un entero k_0 tal que

$$|r_k - r^*| < \varepsilon \qquad \text{para todo } k \geq k_0.$$

La definición significa que, aunque los primeros términos puedan estar lejos de r^* u oscilar, desde cierto momento todos permanecen tan cerca de r^* como se haya solicitado.

Proposición 2.1. *Sean $r_k \to r^*$ y $s_k \to s^*$. Para cualquier constante real c se cumple*

$$r_k + s_k \to r^* + s^*, \qquad cr_k \to cr^*.$$

Proposición 2.2. *Si $r_k \to r^*$ y a es un entero fijo para el cual r_{k+a} está definido, entonces*

$$r_{k+a} \to r^*.$$

Por tanto, modificar, eliminar o añadir una cantidad finita de términos no cambia el límite de una sucesión.

Las propiedades de convergencia describen la *cola* de la sucesión. En un algoritmo bien definido suele ocurrir una de las siguientes situaciones: ninguna iteración coincide exactamente con r^*, o bien, si $r_k = r^*$, entonces $r_j = r^*$ para todo $j \geq k$. En el segundo caso, la sucesión permanece constante y el algoritmo ha terminado matemáticamente.

2. Convergencia de sucesiones de vectores

En problemas con varias variables escribimos las iteraciones mediante superíndices,

$$x^{(k)} = (x_1^{(k)}, \ldots, x_n^{(k)}) \in \mathbb{R}^n,$$

para reservar los subíndices para las componentes del vector.

DEFINICIÓN. *Una sucesión* $\{x^{(k)}\}_{k\geq 0} \subset \mathbb{R}^n$ *converge a* x^* *si, para cada* $\varepsilon > 0$, *existe* k_0 *tal que*

$$\|x^{(k)} - x^*\| < \varepsilon \qquad \text{para todo } k \geq k_0.$$

En dimensión finita puede emplearse cualquiera de las normas usuales. La norma elegida determina cómo se mide la distancia, pero no cambia el hecho de que una sucesión converja o no.

EJEMPLO 2.1. La sucesión

$$x^{(k)} = \left(\frac{1}{k+1}, \frac{(-1)^k}{k+1}\right)$$

converge a $(0,0)$. La segunda componente oscila, pero la distancia al origen tiende a cero.

Para escalares y vectores definiremos el error verdadero mediante

$$e_k = \|x^{(k)} - x^*\|,$$

donde, en el caso escalar, la norma se reduce al valor absoluto. Así, $x^{(k)} \to x^*$ equivale a $e_k \to 0$.

En ocasiones conviene usar una función escalar de error o defecto $E : \mathbb{R}^n \to \mathbb{R}$. Algunos ejemplos son

$$E(x) = \|x - x^*\|, \qquad E(x) = \|x - x^*\|^2, \qquad E(x) = \|F(x)\|,$$

cuando se desea resolver $F(x) = 0$. En optimización también puede emplearse una brecha de la función objetivo. La medida escogida debe mantenerse fija al comparar dos métodos, pues los cocientes observados pueden depender de ella.

3. Velocidades de convergencia

En las definiciones siguientes suponemos que $e_k > 0$ desde cierta iteración. Si un algoritmo alcanza exactamente la solución, se reporta convergencia exacta y no se intentan evaluar cocientes de la forma $0/0$.

3.1. Convergencia lineal.

DEFINICIÓN. *La convergencia es lineal si existen una constante* $q \in (0,1)$ *y un entero* k_0 *tales que*

$$e_{k+1} \leq q e_k \qquad \text{para todo } k \geq k_0.$$

Cada iteración elimina al menos una fracción fija del error. Iterando la desigualdad se obtiene $e_k \leq c q^k$ para una constante $c > 0$; por ello esta convergencia también se denomina *geométrica*. Entre dos factores $0 < q_1 < q_2 < 1$, el menor describe una reducción más rápida.

EJEMPLO 2.2. Sea $0 < a < 1$ y $r_k = a^k$. Como $r_k \to 0$ y

$$\frac{|r_{k+1}|}{|r_k|} = a,$$

la sucesión converge linealmente con factor $q = a$.

Converger no implica necesariamente converger linealmente.

EJEMPLO 2.3. Para $r_k = 1/(k+1)$ se tiene $r_k \to 0$, pero

$$\frac{|r_{k+1}|}{|r_k|} = \frac{k+1}{k+2} \longrightarrow 1.$$

Por tanto, la sucesión converge, pero no linealmente.

3.2. Convergencia superlineal.

DEFINICIÓN. *La convergencia es superlineal si*

$$\frac{e_{k+1}}{e_k} \longrightarrow 0.$$

El factor de reducción no permanece constante: termina acercándose a cero, de modo que cada iteración resulta más eficaz que la anterior.

EJEMPLO 2.4. Considere

$$r_k = \left(\frac{1}{k+1}\right)^{k+1}.$$

Entonces

$$\frac{r_{k+1}}{r_k} = \frac{1}{k+2}\left(\frac{k+1}{k+2}\right)^{k+1} \leq \frac{1}{k+2} \longrightarrow 0.$$

La convergencia es superlineal. Sin embargo,

$$\frac{r_{k+1}}{r_k^2} = \frac{(k+1)^{2k+2}}{(k+2)^{k+2}} \longrightarrow \infty,$$

por lo que este ejemplo no converge cuadráticamente.

3.3. Convergencia cuadrática.

DEFINICIÓN. *La convergencia es cuadrática si existen una constante $C > 0$ y un entero k_0 tales que*

$$e_{k+1} \leq Ce_k^2 \qquad \textit{para todo } k \geq k_0.$$

Cuando e_k ya es pequeño, su cuadrado es mucho menor. En condiciones favorables, el número de cifras correctas puede aproximadamente duplicarse en cada iteración.

EJEMPLO 2.5. Sea $0 < a < 1$ y $r_k = a^{2^k}$. Entonces

$$e_{k+1} = a^{2^{k+1}} = \left(a^{2^k}\right)^2 = e_k^2.$$

La convergencia es cuadrática con $C = 1$.

PROPOSICIÓN 2.3. *Toda sucesión que converge cuadráticamente converge también de manera superlineal.*

DEMOSTRACIÓN. Si $e_{k+1} \leq Ce_k^2$, entonces

$$\frac{e_{k+1}}{e_k} \leq Ce_k.$$

Como $e_k \to 0$, el lado derecho tiende a cero. □

4. Carácter local de la velocidad

Las relaciones de la sección 3 suelen cumplirse cuando la iteración ya está suficientemente cerca de la solución. Un método puede ser muy rápido localmente y, sin embargo, fallar desde un mal punto inicial. Por ello deben separarse dos preguntas: si el método llega a la región correcta y con qué rapidez avanza una vez que está allí.

Ejemplo 2.6 (Método de Herón). Para aproximar $\sqrt{2}$ se puede usar

$$x^{(k+1)} = \frac{1}{2}\left(x^{(k)} + \frac{2}{x^{(k)}}\right).$$

El error satisface la identidad

$$x^{(k+1)} - \sqrt{2} = \frac{(x^{(k)} - \sqrt{2})^2}{2x^{(k)}}.$$

Cerca de $\sqrt{2}$, el denominador permanece aproximadamente constante y

$$e_{k+1} \approx \frac{1}{2\sqrt{2}} e_k^2.$$

Esto explica el comportamiento cuadrático observado.

5. Criterios de parada

El criterio ideal sería detenerse cuando

$$\|x^{(k)} - x^*\| \leq \varepsilon,$$

pero normalmente x^* es desconocido. Por ello se utilizan cantidades observables.

5.1. Tamaño del paso. Un criterio frecuente es

$$\|x^{(k+1)} - x^{(k)}\| \leq \tau_a + \tau_r \,\text{máx}\{1, \|x^{(k+1)}\|\},$$

donde τ_a y τ_r son tolerancias absoluta y relativa. Un paso pequeño no demuestra por sí solo que la sucesión converge. Por ejemplo, las sumas parciales

$$r_k = 1 + \frac{1}{2} + \frac{1}{3} + \cdots + \frac{1}{k}$$

no convergen, aunque $|r_{k+1} - r_k| = 1/(k+1) \to 0$.

5.2. Residuo del problema. Si se resuelve $F(x) = 0$, puede observarse $\|F(x^{(k)})\|$. Para un cero de una función escalar se usa $|f(r_k)|$; para un punto fijo $r^* = g(r^*)$ se usa $|r_k - g(r_k)|$. En el cálculo de $\sqrt{a}$, por ejemplo, puede emplearse el residuo $|r_k^2 - a|$.

El significado de un residuo absoluto depende de la escala de los datos y del condicionamiento del problema. Por ello conviene combinar un residuo escalado con tolerancias absoluta y relativa.

5.3. Terminación auditable. Una implementación confiable debe devolver la aproximación, el número de iteraciones y el motivo de terminación. Además de comprobar el paso y el residuo, debe imponer un número máximo de iteraciones y distinguir entre convergencia, estancamiento y fracaso. Cerca de la precisión de la máquina, los cocientes de errores pueden dejar de ser informativos por efecto del redondeo.

Capítulo 3

Sistemas de ecuaciones lineales

1. Fundamentos

Antes de iniciar el estudio de los sistemas de ecuaciones lineales debemos complementar los fundamentos de la teoría, para esto veremos propiedades de las normas en $\mathbb{K}^n$ (considerando $\mathbb{K} = \mathbb{R}$ ó $\mathbb{C}$).

Definición. *Sea $\mathbb{K} = \mathbb{R}$ ó $\mathbb{C}$. A una función $\|\cdot\| : \mathbb{K}^n \to \mathbb{R}$ se le llama norma de vectores si se cumple:*

1) $\|x\| \geq 0$ *para todo* $x \in \mathbb{K}^n$, y $\|x\| = 0$ *si y sólo si* $x = 0$;
2) $\|\alpha x\| = |\alpha|\|x\|$, *para todos* $\alpha \in \mathbb{K}$ y $x \in \mathbb{K}^n$;
3) $\|x + y\| \leq \|x\| + \|y\|$, *para todo* $x, y \in \mathbb{K}^n$ *(desigualdad triangular).*

Teorema 3.1. *Sea $\|\cdot\|$ una norma en $\mathbb{R}^n$. Entonces se cumple:*

1) *Con respecto a la continuidad de una norma*
   a) $|\|x\| - \|y\|| \leq \|x - y\|$, *para todo* $x, y \in \mathbb{R}^n$;
   b) *existe* $C > 0$ *constante tal que* $|\|x\| - \|y\|| \leq C\|x - y\|_\infty$, *para todo* $x, y \in \mathbb{R}^n$.
2) *Para cada par de normas $\|\cdot\|_A$ y $\|\cdot\|_B$ en $\mathbb{K}^n$ existen constantes C y D tales que*

$$C\|x\|_A \leq \|x\|_B \leq D\|x\|_A, \text{ para todo } x \in \mathbb{K}^n. \tag{3}$$

Definición. *Si $\|\cdot\|_A$ y $\|\cdot\|_B$ satisfacen (3) son llamadas equivalentes.*

Demostración (del teorema).

1) En efecto
   a) Se sigue de la desigualdad triangular;
   b) de a), tenemos que:

$$|\|x\| - \|y\|| \leq \|x - y\| = \left\|\sum_{j=1}^{n}(x_j - y_i)e_j\right\| \leq \sum_{j=1}^{n}|x_j - y_i|\|e_j\|$$
$$\leq \sum_{j=1}^{n}\|x - y\|_\infty\|e_j\| \leq \|x - y\|_\infty \sum_{j=1}^{n}\|e_j\| = C\|x - y\|_\infty,$$

   con $C = \sum_{j=1}^{n}\|e_j\|$.
2) Sea $S := \{y \in \mathbb{K}^n : \|x\|_\infty = 1\}$. Como S es compacto y $\|\cdot\|_B$ es continua, entonces $\|\cdot\|_B$ toma sus extremos en S:

$$C := \min_{x \in S}\|x\|_B, \quad D := \max_{x \in S}\|x\|_B$$

Resulta que $C > 0$ ya que $0 \notin S$. Para cualquier $x \in \mathbb{K}^n \setminus \{0\}$ se cumple que $\dfrac{x}{\|x\|_\infty} \in S$ y se obtiene

$$C \leq \left\| \frac{x}{\|x\|_\infty} \right\|_B \leq D$$

de donde

$$C\|x\|_\infty \leq \|x\|_B \leq D\|x\|_\infty$$

□

Ejemplo 3.1. Tres normas vectoriales en $\mathbb{K}^n$ son

$$\|x\|_1 = \sum_{i=1}^{n} |x_i|.$$
$$\|x\|_2 = \left(\sum_{i=1}^{n} x_i^2 \right)^{1/2}.$$
$$\|x\|_\infty = \max_{i=1,\ldots,n} |x_i|$$

la segunda de éstas conocida como *norma euclidiana*; y la *norma de Hölder*:

$$\|x\|_p = \left(\sum_{i=1}^{n} |x_i|^p \right)^{1/p}, \quad p \in \mathbb{R}, \quad p \geq 1.$$

La bola unitaria de radio 1 con la norma $\|\cdot\|$ en $\mathbb{R}^n$ es el conjunto $B = \{x \in \mathbb{R}^n / \|x\| \leq 1\}$ y su frontera el conjunto $\{x \in \mathbb{R}^n / \|x\| = 1\}$.

Definición. *Sea $\|\cdot\|$ una norma en $\mathbb{K}^n$. La norma matricial subordinada o norma asociada a esta norma (o norma inducida) se define como*

$$\|A\| := \sup \left\{ \frac{\|Ax\|}{\|x\|} / x \in \mathbb{K}^n \setminus \{0\} \right\} = \sup_{x \neq 0} \frac{\|Ax\|}{\|x\|}.$$

Teorema 3.2. *Si $\|\cdot\|$ es una norma en $\mathbb{K}^n$, entonces se cumple:*

a) $\|A\| = \sup_{\|x\|=1} \|Ax\|$

b) $\|A\| = \sup_{x \neq 0} \dfrac{\|Ax\|}{\|x\|}$, *para toda $A \in \mathbb{K}^{n \times n}$, define una norma sobre el espacio vectorial de las matrices en $\mathbb{K}^{n \times n}$*

c) $\|Ax\| \leq \|A\|\|x\|$, *para todo $x \in \mathbb{K}^n$, $A \in \mathbb{K}^{n \times n}$*

d) $\|AB\| \leq \|A\|\|B\|$, *para todo $A, B \in \mathbb{K}^{n \times n}$.*

Demostración.

a) $\|A\| = \sup_{x \neq 0} \dfrac{\|Ax\|}{\|x\|} = \sup_{\frac{x}{\|x\|} \neq 0} \left\| A \left(\dfrac{x}{\|x\|} \right) \right\|$

b) Primero veamos que si $A = (a_1, a_2, \ldots, a_n) \neq 0$, entonces al menos una columna $a_i \neq 0$. Luego $Ae_i = a_i \neq 0$ y

$$0 < \frac{\|a_i\|}{\|e_i\|} = \frac{\|Ae_i\|}{\|e_i\|} \leq \sup_{x \neq 0} \frac{\|Ax\|}{\|x\|} = \|A\|$$

Así $\|A\| > 0$, para todo $A \neq 0$, de donde

$|A\| \geq 0,$ para todo $A \in \mathbb{K}^{n \times n},$ y $\|A\| = 0$ sí y solamente si $A = 0$

Las otras propiedades se cumplen trivialmente (Ejercicio).

c) Se tiene

$$\frac{\|Ax\|}{\|x\|} = \sup_{x\neq 0} \frac{\|Ax\|}{\|x\|} = \|A\|, \text{ para todo } x \neq 0.$$

Luego,

$$\|Ax\| \leq \|A\|\|x\|, \text{ para todo } x \neq 0.$$

Además para $x = 0$ se cumple trivialmente, de donde se tiene c).

d) Del item anterior se tiene que $\|ABx\| \leq \|A\|\|Bx\|$. Entonces

$$\|AB\| = \sup_{\|x\|=1} \|ABx\| \leq \sup_{\|x\|=1} \|A\|\|Bx\| = \|A\| \sup_{\|x\|=1} \|Bx\| = \|A\|\|B\|.$$

□

Ejemplo 3.2. Normas matriciales:

a) $\|A\|_\infty = \sup_{\|x\|_\infty=1} \|Ax\|_\infty$

b) $\|A\|_1 = \sup_{\|x\|_1=1} \|Ax\|_1$

Teorema 3.3. *Para toda matriz $A = (a_{ij}) \in \mathbb{K}^{n\times n}$, se cumple que:*

a) $\|A\|_\infty = \sup_{\|x\|_\infty=1} \|Ax\|_\infty = \max_{i=1,\ldots,n} \sum_{j=1}^{n} |a_{ij}|$

b) $\|A\|_1 = \sup_{\|x\|_1=1} \|Ax\|_1 = \max_{j=1,\ldots,n} \sum_{i=1}^{n} |a_{ij}|$

Demostración.

a) Primero notemos que

$$\begin{aligned}\|A\|_\infty &= \sup_{\|x\|_\infty=1} \|Ax\|_\infty = \sup_{\|x\|_\infty=1} \left(\max_{i=1,\ldots,n} |(Ax)_i|\right) \\ &= \sup_{\|x\|_\infty=1} \left(\max_{i=1,\ldots,n} \left|\sum_{k=1}^{n} a_{ik}x_k\right|\right)\end{aligned}$$

Sea $x \in \mathbb{K}^n$ con $\|x\|_\infty = \max_{k=1,\ldots,n} |x_k| = 1$. Entonces, para $i = 1, \ldots, n$ se tiene:

$$\begin{aligned}\left|\sum_{k=1}^{n} a_{ik}x_k\right| &\leq \sum_{k=1}^{n} |a_{ik}||x_k| \leq \sum_{k=1}^{n} |a_{ik}|\|x\|_\infty \\ &= \sum_{k=1}^{n} |a_{ik}| \leq \max_{i=1,\ldots,n} \sum_{k=1}^{n} |a_{ik}|,\end{aligned}$$

luego

$$\sup_{\|x\|_\infty=1} \left(\max_{i=1,\ldots,n} \left|\sum_{k=1}^{n} a_{ik}x_k\right|\right) \leq \max_{i=1,\ldots,n} \sum_{k=1}^{n} |a_{ik}| = \sum_{k=1}^{n} |a_{i_0k}|,$$

para algún i_0 tal que $1 \leq i_0 \leq n$, esto es,

$$\|A\|_\infty \leq \sum_{k=1}^{n} |a_{i_0k}|.$$

Ahora bien, sea $x' \in \mathbb{K}^n$ definido como

$$x'_k = \begin{cases} 1, & a_{i_0 k} = 0 \\ \dfrac{\overline{a_{i_0 k}}}{|a_{i_0 k}|}, & a_{i_0 k} \neq 0 \end{cases}$$

Entonces $\|x'\|_\infty = 1$ y además

$$\|A\|_\infty \geq \|Ax'\|_\infty = \max_{i=1,\ldots,n} |(Ax)_i| \geq |(Ax)_{i_0}| = \sum_{k=1}^{n} |a_{i_0 k}|.$$

Por lo tanto

$$|A\|_\infty = \sum_{k=1}^{n} |a_{i_0 k}| = \max_{i=1,\ldots,n} \sum_{k=1}^{n} |a_{ik}|.$$

b) ¡Ejercicio!

□

NOTA. Si $\|\cdot\|$ es una norma subordinada, entonces $\|I\| = 1$.

Otro ejemplo de norma matricial es la norma de Fröbenius:

$$\|A\|_F = \left(\sum_{i,j=1}^{n} |a_{ij}|^2 \right)^{1/2}$$

En este caso se cumplen:

a) $\|I\|_F = \sqrt{n}$
b) Para todo $x \in \mathbb{K}^n$

$$\begin{aligned} \|Ax\|_2^2 &= \sum_{i=1}^{n} \left| \sum_{j=1}^{n} a_{ij} x_j \right|^2 \leq \sum_{i=1}^{n} \left(\sum_{j=1}^{n} |a_{ij}|^2 \sum_{j=1}^{n} |x_j|^2 \right) \\ &= \left(\sum_{i=1}^{n} \sum_{j=1}^{n} |a_{ij}|^2 \right) \left(\sum_{j=1}^{n} |x_j|^2 \right) = \|A\|_F^2 \sum_{j=1}^{n} |x_j|^2 \end{aligned}$$

esto implica que $\|Ax\|_2 \leq \|A\|_F \|x\|_2$, de donde

$$\|A\|_2 \leq \|A\|_F$$

La norma de Fröbenius no es subordinada de alguna otra (¿porqué?).

LEMA 3.4. *Sean $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_n$ los valores propios de la matriz hermitiana $A \in \mathbb{K}^{n\times n}$. Entonces se cumple*

$$\lambda_n \|x\|_2^2 \leq x^* A x \leq \lambda_1 \|x\|_2^2, \text{ para todo } x \in \mathbb{K}^{n\times n}.$$

DEMOSTRACIÓN. Como A es hermitiana, existe una matriz $U \in \mathbb{K}^{n\times n}$ unitaria ($U^*U = I$) tal que

$$U^* A U = \operatorname{diag}(\lambda_1, \ldots, \lambda_n).$$

Para cualquier $x \in \mathbb{K}^n$ se cumple:

$$\begin{aligned} x^* A x &= x^* \operatorname{diag}(\lambda_1, \ldots, \lambda_n) U^* x \\ &= (U^* x)^* \operatorname{diag}(\lambda_1, \ldots, \lambda_n)(U^* x) \\ &= \sum_{j=1}^{n} \lambda_i |(U^* x)_j|^2 \leq \lambda_1 \sum_{j=1}^{n} |(U^* x)_j|^2 = \lambda_1 \|U^* x\|_2^2 \\ &= \lambda_1 (U^* x)^* (U^* x) = \lambda_1 x^* U U^* x = \lambda_1 x^* I x \\ &= \lambda_1 \|x\|_2^2 \end{aligned}$$

Esto implica que $x^* A x \leq \lambda_1 \|x\|_2^2$. De manera similar se obtiene $\lambda_n \|x\|_2^2 \leq x^* A x$. □

DEFINICIÓN. *Sea $A \in \mathbb{K}^{n\times n}$, al conjunto ξ de valores propios de A se le llama espectro de A y al número*

$$\rho(A) = \max_{\lambda_i \in \xi} |\lambda_i|$$

se le llama radio espectral de la matriz A.

LEMA 3.5. *Se cumple $\|A\|_2 = \rho(A^*A)^{1/2}$, para todo $A \in \mathbb{K}^{n\times n}$.*

DEMOSTRACIÓN. Se tiene que A^*A es hermitiana y semidefinida positiva (pues $x^*(A^*A)x = (Ax)^*(Ax) = \|Ax\|_2^2 \geq 0, \quad \forall x \in \mathbb{K}^n$). Entonces A^*A tiene valores propios no negativos:

$$\rho(A^*A) = \lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_n \geq 0.$$

Por el lema anterior:

$$\|Ax\|_2^2 = x^*A^*Ax \leq \lambda_1\|x\|_2^2 = \rho(A^*A)\|x\|_2^2,$$

de donde

$$\frac{\|Ax\|_2^2}{\|x\|_2^2} \leq \rho(A^*A)$$

para $x \neq 0$; luego

$$\|A\|_2 \leq \sqrt{\rho(A^*A)}.$$

Sea $\hat{x} \in \mathbb{K}^n$ un vector propio correspondiente a $\rho(A^*A)$ de A^*A con $\|\hat{x}\|_2 = 1$. Luego se tiene:

$$\begin{aligned} \|A\|_2^2 &= \sup_{\|x\|=1} \|Ax\|_2^2 \geq \|A\hat{x}\|_2^2 = \hat{x}^*A^*Ax \leq \rho(A^*A)\|\hat{x}\|_2^2 \\ \|A\|_2 &\geq \sqrt{\rho(A^*A)}. \end{aligned}$$

De lo anterior $\|A\|_2 = \sqrt{\rho(A^*A)}$. □

TEOREMA 3.6. *Se cumplen:*

1) *Sea $\|\cdot\|$ una norma en $\mathbb{K}^n$. Entonces $\rho(A) \leq \|A\|$, para toda matriz $A \in \mathbb{K}^{n\times n}$.*
2) *Si $A \in \mathbb{K}^{n\times n}$ es hermitiana se cumple $\rho(A) = \|A\|_2$.*
3) *Para toda matriz $A \in \mathbb{K}^{n\times n}$ y $\varepsilon > 0$, existe una norma en $\mathbb{K}^{n\times n}$ con $\|A\| < \rho(A) + \varepsilon$, esto es*

$$\rho(A) = \inf_{\|\cdot\|} \|A\|,$$

donde el ínfimo se toma sobre todas las normas subordinadas de $\mathbb{K}^{n\times n}$.

DEMOSTRACIÓN. 1) Sea λ un valor propio de A cualquiera. Tomemos un vector propio correspondiente x con $\|x\| = 1$. Entonces

$$|\lambda| = |\lambda|\|x\| = \|\lambda x\| = \|Ax\| \leq \|A\|\|x\| = \|A\|.$$

En particular, tomemos λ tal que $|\lambda| = \rho(A)$, de donde $\rho(A) \leq \|A\|$.

2) En efecto, si $A = A^*$ entonces

$$\|A\|_2 = \sqrt{\rho(A^*A)} = \sqrt{\rho(A\,A)} = \sqrt{\rho(A^2)} = \sqrt{\rho(A)^2} = \rho(A).$$

3) Tomemos $\varepsilon > 0$. Como A es cuadrada, entonces existe una matriz inversible U tal que $S := U^{-1}AU = (s_{ij})$ es triangular superior. Definamos $E = \operatorname{diag}(\varepsilon, \varepsilon^2, \ldots, \varepsilon^n)$. Consideremos la matriz $E^{-1}SE = (s_{ij}\varepsilon^{j-i})$. Esta matriz es triangular superior, al igual que S. Para los elementos posiblemente no nulos fuera de la diagonal ($i < j$), tenemos:

$$|s_{ij}\varepsilon^{j-i}| < |s_{ij}|\varepsilon$$

esto es, los elementos de la diagonal son arbitrariamente pequeños (basta escoger un ε adecuado). La matriz $P := (UE)^{-1}$ es tal que $PAP^{-1} =$

$(s_{ij}\varepsilon^{j-i})$.
Debido a esto, podemos escribir $PAP^{-1} = D+T$, con D diagonal y $\|T\|_\infty < \varepsilon$.
Ahora bien, es obvio que si $\|\cdot\|$ es una norma en $\mathbb{K}^n$ y P una matriz inversible , la aplicación definida por $\|x\|' := \|Px\|$, $\forall x \in \mathbb{K}^n$ también lo es. Su norma subordinada es (véase que $y := Px$):

$$\|A\|' = \sup_{x\neq 0} \frac{\|Ax\|'}{\|x\|'} = \sup_{x\neq 0} \frac{\|PAx\|}{\|Px\|} = \sup_{y\neq 0} \frac{\|PAP^{-1}y\|}{\|y\|} = \|PAP^{-1}\|$$

De lo anterior, tenemos:

$$\|PAP^{-1}\|_\infty \leq \|D\|_\infty + \|T\|_\infty < \rho(A) + \varepsilon$$

y sabiendo que $\|A\| := \|PAP^{-1}\|_\infty$ es una norma subordinada, tenemos

$$\|A\| < \rho(A) + \varepsilon$$

□

2. Eliminación de Gauss

Dado el sistema lineal

$$\begin{aligned} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n &= b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n &= b_2 \\ &\vdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n &= b_n \end{aligned}$$

En su forma matricial:

$$Ax = b$$

donde

$$A = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{bmatrix} \in \mathbb{K}^{n\times n}, \quad b = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix} \in \mathbb{K}^n, \quad x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \in \mathbb{K}^n.$$

Empezamos con el sistema lineal de forma triangular superior

$$\begin{aligned} a_{11}x_1 + \quad a_{12}x_2 + \cdots + \quad & a_{1,n-1}x_{n-1} + \quad a_{1n}x_n \quad = b_1 \\ a_{22}x_2 + \cdots + \quad & a_{2,n-1}x_{n-1} + \quad a_{2n}x_n \quad = b_2 \\ & \vdots \\ & a_{n-1,n-1}x_{n-1} + \quad a_{n-1,n}x_n \quad = b_{n-1} \\ & \qquad\qquad\qquad\quad a_{nn}x_n \quad = b_n \end{aligned}$$

Supongamos que los elementos de la diagonal de A son distintos de cero: $a_{ii} \neq 0$, $i = 1, 2, \dots, n$. Luego:

$$\begin{aligned} x_n &= b_n/a_{nn}, \\ x_{n-1} &= [b_{n-1} - a_{n-1,n}x_n]/a_{n-1,n-1}, \\ x_j &= [b_j - \sum_{k=j+1}^{n} a_{jk}x_k]/a_{jj} \end{aligned}$$

Teorema 3.7. *Dado un sistema de ecuaciones lineales $Ax = b$. Las siguientes operaciones:*

i) *la multiplicación de una ecuación por un factor diferente de cero;*
ii) *la adición de un múltiplo de una ecuación a otra;*
iii) *el cambio de ecuaciones;*

Algoritmo 1 Resolución de sistema triangular superior $Ax = b$

Entrada: $A = (a_{ij}) \in \mathbb{K}^{n\times n}$, $b = (b_1, \ldots, b_n)^t \in \mathbb{K}^n$
1: **Condiciones:**
2: $a_{ii} \neq 0$, para $i = 1, \ldots, n$
3: $a_{ij} = 0$ para $j = 1, \ldots, i-1$, $i = 2, \ldots, n$ (matriz triangular superior)
Salida: $x = (x_1, \ldots, x_n)^t$ tal que $Ax = b$
4: $x_n := \dfrac{b_n}{a_{nn}}$
5: **Para** $j = n-1, n-2, \ldots, 1$ **hacer**
6: $x_j := \dfrac{1}{a_{jj}} \left(b_j - \displaystyle\sum_{k=j+1}^{n} a_{jk} x_k \right)$
7: **Fin Para**
8: **Devolver** $(x_1, x_2, \ldots, x_n)^t$

no cambian la solución del sistema, es decir el sistema lineal obtenido por estas operaciones, $\tilde{A}x = \tilde{b}$ tiene la misma solución del sistema $Ax = b$.

Luego, la transformación a un sistema triangular funciona del siguiente modo:

1. Se busca el coeficiente de la primera columna de $(A|b)$ que posea el valor absoluto más grande.

$$|a_{r1}| = \text{máx}\{|a_{11}|, |a_{21}|, \ldots, |a_{n1}|\}$$

2. Cambiar la primera ecuación con la r-ésima, se obtiene $(\overline{A}|\overline{b})$ con $\overline{A} = (\overline{a}_{jk})$ y $\overline{b} = (\overline{b_1}, \ldots, \overline{b_n})$, donde

$$\begin{cases} \overline{a}_{1k} := a_{rk} \\ \overline{a}_{rk} := a_{1k}, \quad k = 1, \ldots, n \\ \overline{a}_{jk} := a_{jk}, \quad j = 2, \ldots, n, j \neq r \end{cases}$$

$$\begin{cases} \overline{b}_1 := b_r \\ \overline{b}_r := b_1 \\ \overline{b}_j := b_j, \quad j = 2, \ldots, n, j \neq r \end{cases}$$

3. "Eliminar"los elementos $\overline{a}_{21}, \overline{a}_{31}, \ldots, \overline{a}_{n1}$, obteniéndose :

$$(A|b) \sim \left[\begin{array}{cccc|c} \overline{a}_{11} & \overline{a}_{12} & \ldots & \overline{a}_{1n} & \overline{b}_1 \\ 0 & \overline{a}_{22}^{(1)} & \ldots & \overline{a}_{2n}^{(1)} & \overline{b}_2^{(1)} \\ \vdots & \vdots & \ddots & & \vdots \\ 0 & \overline{a}_{n2}^{(1)} & \ldots & \overline{a}_{nn}^{(1)} & \overline{b}_n^{(1)} \end{array}\right]$$

con

$$a_{jk}^{(1)} := \overline{a}_{jk} - \frac{\overline{a}_{j1}}{\overline{a}_{11}} \overline{a}_{1k}, \quad j, k = 2, \ldots, n$$
$$b_j^{(1)} := \overline{b}_j - \frac{\overline{a}_{j1}}{\overline{a}_{11}} b_1, \quad j = 2, \ldots, n$$

Aplicando nuevamente 1, 2 y 3 a la submatriz

$$\left[\begin{array}{ccc|c} a_{22}^{(1)} & \ldots & a_{2n} & b_2^{(1)} \\ \vdots & \ddots & & \vdots \\ a_{n2}^{(1)} & \ldots & a_{nn} & b_n^{(1)} \end{array}\right]$$

se obtiene:

$$(A|b) \sim \left[\begin{array}{ccccccc|c} \overline{a}_{11} & \overline{a}_{12} & \overline{a}_{13} & \overline{a}_{14} & \dots & \overline{a}_{1n} & \overline{b}_1 \\ 0 & \overline{a}_{22}^{(1)} & \overline{a}_{23}^{(1)} & \overline{a}_{24}^{(1)} & \dots & \overline{a}_{2n}^{(1)} & \overline{b}_2^{(1)} \\ 0 & 0 & \overline{a}_{33}^{(2)} & \overline{a}_{34}^{(2)} & \dots & \overline{a}_{3n}^{(2)} & \overline{b}_3^{(2)} \\ \vdots & \vdots & & & \ddots & & \vdots \\ 0 & 0 & 0 & 0 & \dots & \overline{a}_{nn}^{(n-1)} & \overline{b}_n^{(n-1)} \end{array}\right]$$

2.1. Algoritmo de Gauss Jordan. Dados los sistemas

$$Ax = b^{(1)}, Ax = b^{(2)}, \dots, Ax = b^{(m)}$$

sea

$$W := (A|b^{(1)}|b^{(2)}|\dots|b^{(m)})$$

queremos

$$W \sim (\tilde{A}|\tilde{b}^{(1)}|\tilde{b}^{(2)}|\dots|\tilde{b}^{(m)})$$

con $\tilde{A}$ triangular superior,

$$W = \left[\begin{array}{ccc|ccc} w_{11} & \dots & w_{1n} & w_{1,n+1} & \dots & w_{1,n+m} \\ \vdots & & & \vdots & & \\ w_{n1} & \dots & w_{nn} & w_{n,n+1} & \dots & w_{n,n+m} \end{array}\right]$$

Utilizamos el vector $p := (p_1, \dots, p_n)$ (llamado *vector de permutaciones*) para registrar los cambios de filas. Al inicio se empieza con $p := (1, 2, \dots, n)$. Luego, en vez de hacer los cambios de filas, hacemos los cambios en las componentes de p. Así, en el primer paso, al cambiar la r-ésima fila por la primera resulta $p := (r, 2, \dots, r-1, 1, r+1, \dots, n)$.
De este modo tenemos en Algoritmo de Gauss-Jordan:

Entrada: $W \in \mathbb{K}^{n\times(n+m)}$, $W := (w_{jk}) = (A\|b^{(1)}\|b^{(2)}\|\dots\|b^{(m)})$
Poner $p := (p_1, \dots, p_n)$ con $p_i = i, \quad i = 1, 2, \dots, n$
Para k:=1,…,n-1
Encontrar $j \geq k$ con $\|w_{p_j,k}\| = \text{máx}\{\|w_{p_k,k}\|, \dots, \|w_{p_n,k}\|\}$
Cambiar p_j y p_k en p
Para $i := k+1, \dots, n$
Poner $m := w_{p_i,k}/w_{p_k,k}$
Poner $w_{p_i,k} := w_{p_i,k}/w_{p_k,k}$
Para $j := k+1, \dots, n, n+1, \dots, n+m$
$w_{p_i,j} := w_{p_i,j} - m \cdot w_{p_k,j}$
Salida: $W = (\tilde{A}\|\tilde{b}^{(1)}\|\tilde{b}^{(2)}\|\dots\|\tilde{b}^{(m)})$ con $\tilde{A}$ triangular superior permutada.

NOTAS.

1. En general, si se tuvieran m sistemas lineales

$$Ax = b^{(q)}, \quad q = 1, 2, \dots, m,$$

luego de aplicar el algoritmo anterior se tendrá que resolver $\tilde{A}x = \tilde{b}^{(q)}$, donde

$$(\tilde{A}|\tilde{b}^{(q)}) = \left[\begin{array}{cccc|c} w_{p_1,1} & w_{p_1,2} & \dots & w_{p_1,n} & w_{p_1,n+q} \\ & w_{p_2,2} & \dots & w_{p_2,n} & w_{p_2,n+q} \\ & & \ddots & \vdots & \vdots \\ 0 & & & w_{p_n,n} & w_{p_n,n+q} \end{array}\right]$$

Se puede usar el algoritmo para resolver sistemas de la forma triangular superior.

2. Propuesta: Verificar
Si se quiere resolver $Ax = \mathfrak{b}$, donde $\mathfrak{b} = (b_1, b_2, \ldots, b_n)^t$ usando $\tilde{A}$ del algoritmo anterior, se puede usar el sgte algoritmo:

Para $j := 1, \ldots, n-1$		
	Para $k := j+1, \ldots, n$	
		$b_{p_k} := b_{p_k} - w_{p_k,j} \cdot b_{p_j}$.

Luego, se resuelve el sistema triangular superior $\tilde{A}x = \mathfrak{b}$, donde

$$(\tilde{A}|\mathfrak{b}) = \left[\begin{array}{cccc|c} w_{p_1,1} & w_{p_1,2} & \ldots & w_{p_1,n} & b_{p_1} \\ & w_{p_2,2} & \ldots & w_{p_2,n} & b_{p_2} \\ & & \ddots & \vdots & \vdots \\ 0 & & & w_{p_n,n} & b_{p_n} \end{array}\right]$$

3. La factorización LU

Dada una matriz $A \in \mathbb{K}^{n\times n}$, se buscan

$$L = \begin{bmatrix} l_{11} & 0 & \ldots & 0 \\ l_{21} & l_{22} & \ldots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ l_{n1} & l_{n2} & \ldots & l_{nn} \end{bmatrix} \quad \text{y} \quad U = \begin{bmatrix} u_{11} & u_{12} & \ldots & u_{1n} \\ 0 & u_{22} & \ldots & u_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & \ldots & 0 & u_{nn} \end{bmatrix}$$

tales que

$$A = LU.$$

Si se tiene $A = LU$, para resolver el sistema lineal $Ax = b$ se procede como sigue:

$$b = LUx = Ly$$

Resolver $Ly = b$ obteniendo y, luego resolver $Ux = y$ obteniendo x.
Si exigimos $\det(A) \neq 0 \Longrightarrow \det(L) \neq 0, \det(U) \neq 0$ lo cual implica

$$l_{ii} \neq 0, u_{ii} \neq 0, \quad i = 1, 2, \ldots, n$$

Damos el algoritmo para resolver un sistema $LU : LUx = b$

Teorema 3.8. *El método de Gauss implica la factorización LU, si no se aplica cambio de filas.*

Demostración. Después del primer paso se obtiene sin cambio de filas

$$A^{(1)} = \begin{bmatrix} a_{11} & a_{12} & \ldots & a_{1n} \\ 0 & a_{22}^{(1)} & \ldots & a_{2n}^{(1)} \\ \vdots & \vdots & \ddots & \\ 0 & a_{n2}^{(1)} & \ldots & a_{nn}^{(1)} \end{bmatrix}$$

$A^{(1)} = L^{(1)}A$ donde

$$L^{(1)} = \begin{bmatrix} 1 & 0 & 0 & \ldots & 0 \\ -a_{21}/a_{11} & 1 & 0 & \ldots & 0 \\ -a_{31}/a_{11} & 0 & 1 & \ldots & 0 \\ \vdots & \vdots & & \ddots & 0 \\ -a_{n1}/a_{11} & 0 & 0 & \ldots & 1 \end{bmatrix}$$

Algoritmo 2 Resolución de sistema $Ax = b$ usando factorización $A = LU$

Entrada: $L = (l_{ij})$ matriz triangular inferior, $U = (u_{ij})$ matriz triangular superior tal que $A = LU$, $b = (b_1, \ldots, b_n)^t$

Salida: $x = (x_1, \ldots, x_n)^t$ tal que $Ax = b$

1: Calcular $y_1 := \dfrac{b_1}{l_{11}}$
2: **Para** $j = 2, 3, \ldots, n$ **hacer**
3: $\quad y_j := \dfrac{1}{l_{jj}} \left(b_j - \displaystyle\sum_{i=1}^{j-1} l_{ji} y_i \right)$
4: **Fin Para**
5: Calcular $x_n := \dfrac{y_n}{u_{nn}}$
6: **Para** $j = n-1, n-2, \ldots, 1$ **hacer**
7: $\quad x_j := \dfrac{1}{u_{jj}} \left(y_j - \displaystyle\sum_{i=j+1}^{n} u_{ji} x_i \right)$
8: **Fin Para**
9: **Devolver** $x = (x_1, \ldots, x_n)^t$

después del segundo paso sin cambios de filas

$$A^{(2)} = \begin{bmatrix} a_{11} & a_{12} & a_{13} & a_{14} & \ldots & a_{1n} \\ 0 & a_{22}^{(1)} & a_{23}^{(1)} & a_{24}^{(1)} & \ldots & a_{2n}^{(1)} \\ 0 & 0 & a_{33}^{(2)} & a_{34}^{(2)} & \ldots & a_{3n}^{(2)} \\ \vdots & \vdots & & & & \vdots \\ 0 & 0 & a_{n3}^{(2)} & a_{n4}^{(2)} & \ldots & a_{nn}^{(2)} \end{bmatrix} = L^{(2)} A^{(1)} = L^{(2)} L^{(1)} A$$

Al final resulta:

$$A^{(n-1)} = L^{(n-1)} A^{(n-2)} = L^{(n-1)} \ldots L^{(1)} A$$

con

$$A^{(n-1)} = \begin{bmatrix} a_{11} & a_{12} & a_{13} & \ldots & a_{1n} \\ 0 & a_{22}^{(1)} & a_{23}^{(1)} & \ldots & a_{2n}^{(1)} \\ 0 & 0 & a_{33}^{(2)} & \ldots & a_{3n}^{(2)} \\ \vdots & \vdots & & \ddots & \vdots \\ 0 & 0 & 0 & \ldots & a_{nn}^{(n-1)} \end{bmatrix}$$

y

$$L^{(k)} = \begin{bmatrix} 1 & 0 & & 0 & & \ldots & & 0 \\ 0 & 1 & & \vdots & & & & \vdots \\ & \ddots & & & & & & \\ & & & 1 & & & & 0 \\ \vdots & & & -a_{k+1,k}^{(k-1)} / a_{kk}^{(k-1)} & & 1 & \ldots & 0 \\ & & & \vdots & & \vdots & \ddots & 0 \\ 0 & \ldots & & -a_{n,k}^{(k-1)} / a_{kk}^{(k-1)} & & 0 & \ldots & 1 \end{bmatrix}$$

definimos $U = A^{(n-1)}$, esta matriz es triangular superior.

$$L = \begin{bmatrix} 1 & 0 & \dots & 0 \\ a_{21}/a_{11} & 1 & & 0 \\ a_{31}/a_{11} & a_{32}^{(1)}/a_{22}^{(1)} & 1 & \vdots \\ \vdots & & \vdots & \ddots \quad 0 \\ a_{n1}/a_{11} & a_{n2}^{(1)}/a_{22}^{(1)} & & \dots \quad 1 \end{bmatrix}$$

que es una matriz triangular inferior. Luego:

$$A = LU$$

como se quería. □

Nota. La eliminación de Gauss sin cambios de fila no siempre es posible. Por ejemplo:

$$A = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}, \text{ se tiene } \det(A) \neq 0$$

supongamos

$$A = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} = \begin{bmatrix} l_{11} & 0 \\ l_{21} & l_{22} \end{bmatrix} \begin{bmatrix} u_{11} & u_{12} \\ 0 & u_{22} \end{bmatrix}$$

entonces

$$\begin{array}{ll} l_{11}u_{11} = 0 & (1) \\ l_{11}u_{12} = 1 & (2) \\ l_{21}u_{11} = 1 & (3) \\ l_{21}u_{12} + l_{22}u_{22} = 0 & (4) \end{array}$$

de (3) $u_{11} \neq 0$ y de (1) $l_{21} = 0$ lo cual no cumple (2). Por lo tanto $A = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$ no tiene una factorización LU .

Sin embargo:

Teorema 3.9. *Para una matriz regular A existe siempre, antes de la k-ésima eliminación en el algoritmo de Gauss, una permutación de filas, tal que el k-ésimo elemento diagonal es distinto de cero.*

Demostración. Si $a_{11} = 0$, entonces por lo menos existe un $a_{i1} \neq 0$ en la primera columna e i-ésima fila (de otro modo A no sería regular). Esto produce un elemento $\overline{a}_{11} \neq 0$ y se obtiene:

$$\det(A) = \begin{vmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{vmatrix} = (-1)^{v_1} \begin{vmatrix} \overline{a}_{11} & \overline{a}_{12} & \dots & \overline{a}_{1n} \\ 0 & \overline{a}_{22}^{(1)} & \dots & \overline{a}_{2n}^{(1)} \\ \vdots & \vdots & \ddots & \\ 0 & \overline{a}_{n2}^{(1)} & \dots & \overline{a}_{nn}^{(1)} \end{vmatrix}$$

donde

$$v_1 = \begin{cases} 1, & \text{si hubo cambio de fila} \\ 0, & \text{en otro caso} \end{cases}$$

de este modo:

$$\det(A) = (-1)^{v_1+v_2+\dots+v_{n-1}} \overline{a}_{11}\overline{a}_{22}^{(1)} \dots \overline{a}_{n-1,n-1}^{(n-2)} \overline{a}_{nn}^{(n-1)}.$$

□

Teorema 3.10. *Para cada matriz A regular, existe una matriz de permutación P, tal que el producto PA se puede factorizar como $PA = LU$.*

DEMOSTRACIÓN. Las matrices de permutación P contienen en cada fila y en cada columna un elemento igual a 1 y el resto igual a 0.
Todos los cambios de fila que sean necesarios para aplicar el método de Gauss se pueden almacenar en una matriz de permutación P (esto se hace cambiando las filas de la matriz identidad I según indica el vector de permutaciones p del método) de modo que al aplicar el método de Gauss a la matriz PA ya no sea necesario el cambio de filas. Luego, por el teorema 3.8, se obtiene que la matriz PA tiene una factorización LU. □

TEOREMA 3.11. *Si los menores principales de una matriz A son no singulares, entonces A admite la factorización LU sin cambios de filas.*

DEMOSTRACIÓN. Los menores principales de la matriz A son las submatrices

$$A_k = \begin{bmatrix} a_{11} & \dots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{k1} & \dots & a_{kk} \end{bmatrix}$$

Ahora bien, $\det(A_1) = det(a_{11}) = a_{11} \neq 0$.

$$\det(A_2) = \begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{vmatrix} = \begin{vmatrix} a_{11} & a_{12} \\ 0 & a_{22}^{(1)} \end{vmatrix} \neq 0 \Longrightarrow a_{11}a_{22}^{(1)} \neq 0 \Longrightarrow a_{22}^{(1)} \neq 0$$

y así

$$\det(A_k) = \begin{vmatrix} a_{11} & \dots & a_{1k} \\ \vdots & & \vdots \\ a_{k1} & \dots & a_{kk} \end{vmatrix} = a_{11}a_{22}^{(1)}a_{33}^{(2)} \dots a_{kk}^{(k-1)} \neq 0, \quad k = 1, 2, \dots, n$$

lo cual implica que $a_{kk}^{(k-1)} \neq 0, \quad k = 1, 2, \dots, n$.
Como no hay cambio de filas, por el teorema 3.8, A tiene una factorización LU. □

LEMA 3.12. *Sea $A = A^t \in \mathbb{K}^{n\times n}$ definida positiva. Entonces se puede aplicar la eliminación de Gauss sin cambio de filas y A tiene una factorización LU con L matriz triangular inferior con elementos en la diagonal iguales a 1 y U matriz triangular superior.*

DEMOSTRACIÓN. Los menores principales $A_k, \quad k = 1, 2, \dots n$ de A son matrices definidas positivas, pues como

$$x^t Ax > 0, \quad \text{para todo } x \neq 0, \quad x = (x_1, x_2, \dots, x_n) \in \mathbb{K}^n.$$

Dado un vector arbitrario $y = (y_1, y_2, \dots, y_k) \neq 0 \in \mathbb{K}^k$, tomando
$x = (y_1, \dots, y_k, 0, \dots, 0) \in \mathbb{K}^n$ tenemos:

$$y^t A_k y = x^t Ax > 0$$

De donde $\det(A_k) \neq 0, \quad k = 1, 2, \dots, n$. Por el teorema anterior, A tiene una factorización LU y por la prueba del teorema 3.8, L tiene elementos en la diagonal iguales a 1. □

4. Errores y condición de una matriz

4.1. Influencia de errores por redondeos.

EJEMPLO 3.3. Consideremos el sistema lineal:

$$\begin{array}{rcccc} 0{,}005 & x & + & y & = & 0{,}5 \\ & x & + & y & = & 1 \end{array}$$

entonces

$$x = \frac{5000}{9950} \approx 0{,}503$$
$$y = \frac{4950}{9950} \approx 0{,}497$$

En cálculos con punto flotante con 2 decimales (mantisa con $t = 2$):

a) Tomando a $a_{11} = 0{,}005$ como elemento pivote

$$\begin{aligned} 0{,}005\, x + \ y &= 0{,}5 \\ -199\, y &= -99 \end{aligned}$$

$$y = \frac{-99}{-199} \approx 0{,}50 \text{ de donde } x \approx 0$$

b) Tomando $a_{21} = 1$ como elemento pivote:

$$\begin{aligned} x \ + \ y &= 1 \\ 0{,}995\, y &= 0{,}495 \end{aligned}$$

$$y = \frac{0{,}495}{0{,}995} \approx 0{,}497 \approx 0{,}50 \text{ de donde } x \approx 0{,}50,$$

más exacto que antes.

c) Multiplicando por (400) la primera fila del sistema lineal inicial tenemos

$$\begin{aligned} 2\, x + 400\, y &= 200 \\ x \ + \ y &= 1 \end{aligned}$$

Eligiendo $a_{11} = 2$ como elemento de pivoteo se obtiene el mismo resultado inexacto como en (a).

Observación. La búsqueda del elemento de pivoteo muchas veces no tiene mucho sentido, si los coeficientes tienen un tamaño diferente.

4.2. Condición de una matriz.

Sea A una matriz invertible, y supongamos que en $Ax = b$, se cambia b por $\tilde{b}$. Veamos cómo influye esto en la solución del sistema x, que cambia a $\tilde{x}$. Tenemos $\|Ax\| = \|b\|$ y

$$Ax = b, \qquad A\tilde{x} = \tilde{b}.$$

Entonces:

$$\begin{aligned} \|x - \tilde{x}\| &= \|A^{-1}b - A^{-1}\tilde{b}\| \leq \|A^{-1}\|\|b - \tilde{b}\| = \|A^{-1}\|\frac{\|Ax\|}{\|b\|}\|b - \tilde{b}\| \\ &\leq \|A^{-1}\|\|A\|\|x\|\frac{\|b - \tilde{b}\|}{\|b\|} \end{aligned}$$

de donde

$$\frac{\|x - \tilde{x}\|}{\|x\|} \leq \|A^{-1}\|\|A\|\frac{\|b - \tilde{b}\|}{\|b\|}$$

o bien

$$\frac{\|\Delta x\|}{\|x\|} \leq (\|A^{-1}\|\|A\|)\frac{\|\Delta b\|}{\|b\|}$$

donde $\Delta x := x - \tilde{x}$, $\Delta b := b - \tilde{b}$, $b, x \neq 0$.

Definición. *El valor $\|A^{-1}\|\|A\|$ es denominado el número de condición de la matriz A y se denota por* $\mathrm{cond}(A)$*, esto es*

$$\mathrm{cond}(A) := \|A^{-1}\|\|A\|$$

o

$$\mathrm{cond}_{\|\cdot\|}(A) := \|A^{-1}\|\|A\|.$$

La condición de una matriz depende de la norma.

NOTA. Se cumple, para una norma subordinada, que

$$\mathrm{cond}_{\|\cdot\|}(A) = \|A^{-1}\|\|A\| \geq \|A^{-1}A\| = \|I\| = 1$$

EJEMPLO 3.4. Sean

$$A := \begin{bmatrix} 1 & 0{,}99 \\ 0{,}99 & 0{,}98 \end{bmatrix}, \quad b := \begin{bmatrix} 1{,}99 \\ 1{,}97 \end{bmatrix}, \quad \tilde{b} := \begin{bmatrix} 1{,}989903 \\ 1{,}970106 \end{bmatrix}$$

La solución exacta de $Ax = b$ es $x = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$

La solución de $A\tilde{x} = \tilde{b}$ es $\tilde{x} = \begin{bmatrix} 3 \\ -1{,}0203 \end{bmatrix}$

Aquí el cambio $b - \tilde{b} = \begin{bmatrix} -0{,}000097 \\ 0{,}000106 \end{bmatrix}$ que es pequeño influye en el cambio relativamente grande $x - \tilde{x} = \begin{bmatrix} 2{,}0000 \\ -2{,}0203 \end{bmatrix}$

$$\frac{\|x - \tilde{x}\|_\infty}{\|x\|_\infty} = \frac{2{,}0203}{1} = 2{,}0203$$
$$\frac{\|b - \tilde{b}\|_\infty}{\|b\|_\infty} = \frac{0{,}000106}{1{,}99} = 0{,}000053266$$

Como

$$\frac{\|\Delta x\|_\infty}{\|x\|_\infty} \leq \mathrm{cond}_\infty(A) \frac{\|\Delta b\|_\infty}{\|b\|_\infty}$$

Luego el error se propaga un factor

$$\frac{2{,}0203}{0{,}000053266} \approx 37928$$

Como

$$A^{-1} = \begin{bmatrix} -9800 & 9900 \\ 9900 & -10000 \end{bmatrix}$$

luego

$$\mathrm{cond}_\infty(A) = \|A^{-1}\|_\infty \|A\|_\infty = 19900 \cdot 1{,}99 = 39601$$

Entonces se dice que el problema es *mal condicionado*, cuando $\mathrm{cond}(A)$ es muy grande.

NOTA. En general el cálculo de $\|A^{-1}\|$ es un problema.

TEOREMA 3.13. *En el caso de la norma $\|\cdot\|_2$ se obtiene*

$$\mathrm{cond}_2(A) = \rho(A)\rho(A^{-1}) = \frac{|\lambda_{\text{máx}}|}{|\lambda_{\text{mín}}|},$$

donde $\lambda_{\text{máx}}$ es el valor propio de A con el valor absoluto más grande y $\lambda_{\text{mín}}$ es el valor propio con el valor absoluto más pequeño.

LEMA 3.14 (De perturbación). *Sea $A \in \mathbb{K}^{n\times n}$ regular. Si $S \in \mathbb{K}^{n\times n}$ es una perturbación de A con $\|A^{-1}\|\|S\| < 1$, entonces $A + S$ es regular y*

$$\left\|(A+S)^{-1}\right\| \leq \frac{\|A^{-1}\|}{1 - \|A^{-1}\|\|S\|}.$$

DEMOSTRACIÓN. Se cumple:

$$\left\|(I + A^{-1}S)y\right\| \geq \|y\| - \|A^{-1}Sy\| \geq \left(1 - \|A^{-1}S\|\right)\|y\|, \qquad \text{para todo } y \in \mathbb{K}^n. \tag{4}$$

Entonces, la ecuación $(I + A^{-1}S)y = 0$ implica $y = 0$ como solución única, esto es, $I + A^{-1}S$ es no singular. Luego $I + A^{-1}S$ y $A(I + A^{-1}S) = A + S$ son matrices regulares.

Para $y = (I + A^{-1}S)^{-1}x$, $x \in \mathbb{K}^n$, de (4) se obtiene:

$$\begin{aligned}\left\|(I + A^{-1}S)^{-1}x\right\| &\leq \frac{\left\|(I + A^{-1}S)(I + A^{-1}S)^{-1}x\right\|}{1 - \|A^{-1}\|\|S\|} \\ &= \frac{\|x\|}{1 - \|A^{-1}\|\|S\|},\end{aligned}$$

de donde

$$\left\|(I + A^{-1}S)^{-1}\right\| \leq \frac{1}{1 - \|A^{-1}\|\|S\|}$$

De esto se obtiene:

$$\begin{aligned}\left\|(A + S)^{-1}\right\| =& \left\|(I + A^{-1}S)^{-1}A^{-1}\right\| \\ &\leq \left\|(I + A^{-1}S)^{-1}\right\|\|A^{-1}\| \leq \frac{\|A\|^{-1}}{1 - \|A^{-1}\|\|S\|}.\end{aligned}$$

□

TEOREMA 3.15. *Sea $A \in \mathbb{K}^{n\times n}$ una matriz regular, $\Delta A \in \mathbb{K}^{n\times n}$ una matriz con $\|A^{-1}\|\|\Delta A\| < 1$, $b \in \mathbb{K}^n \setminus \{0\}$, $\Delta b \in \mathbb{K}^n$ y x, Δx definidos por $Ax = b$ y $(A + \Delta A)(x + \Delta x) = b + \Delta b$. Entonces se cumple*

$$\frac{\|\Delta x\|}{\|x\|} \leq \frac{\mathrm{cond}_{\|\cdot\|}(A)}{1 - \mathrm{cond}_{\|\cdot\|}(A)\dfrac{\|\Delta A\|}{\|A\|}}\left[\frac{\|\Delta A\|}{\|A\|} + \frac{\|\Delta b\|}{\|b\|}\right].$$

DEMOSTRACIÓN. Como $\|A^{-1}\|\|\Delta A\| < 1$ y siendo A regular, por el lema 3.14 para $S := \Delta A$ se obtiene que $A + \Delta A$ es regular y

$$\left\|(A + \Delta A)^{-1}\right\| \leq \frac{\|A^{-1}\|}{1 - \|A^{-1}\|\|\Delta A\|} \tag{5}$$

de $Ax = b$ y $(A + \Delta A)(x + \Delta x) = b + \Delta b$ se obtiene:

$$Ax + \Delta Ax + A\Delta x + \Delta A\Delta x = b + \Delta b$$

Luego,

$$\Delta x = (A + \Delta A)^{-1}(\Delta b - \Delta Ax). \tag{6}$$

De (5) y (6):

$$\begin{aligned}\|\Delta x\| &\leq \left\|(A + \Delta A)^{-1}\right\|\|\Delta b - \Delta Ax\| \\ &\leq \frac{\|A^{-1}\|}{1 - \|A^{-1}\|\|\Delta A\|}\left[\frac{\|\Delta b\|}{\|b\|}\|b\| + \frac{\|\Delta A\|\|x\|\|A\|}{\|A\|}\right] \\ &\leq \frac{\|A^{-1}\|}{1 - \|A^{-1}\|\|\Delta A\|}\left[\frac{\|\Delta b\|}{\|b\|}\|A\|\|x\| + \frac{\|\Delta A\|}{\|A\|}\|A\|\|x\|\right] \\ &= \frac{\|A^{-1}\|\|A\|}{1 - \left(\|A^{-1}\|\|A\|\right)\left(\dfrac{\|\Delta A\|}{\|A\|}\right)}\left[\frac{\|\Delta A\|}{\|A\|} + \frac{\|\Delta b\|}{\|b\|}\right]\|x\|,\end{aligned}$$

de donde

$$\frac{\|\Delta x\|}{\|x\|} \leq \frac{\mathrm{cond}_{\|\cdot\|}(A)}{1 - \mathrm{cond}_{\|\cdot\|}(A)\dfrac{\|\Delta A\|}{\|A\|}}\left[\frac{\|\Delta A\|}{\|A\|} + \frac{\|\Delta b\|}{\|b\|}\right].$$

□

5. Factorización LU para sistemas especiales

Sea $A = (a_{ij})_{n\times n} = LU$, donde

$$L = \begin{bmatrix} l_{11} & 0 & \dots & 0 \\ l_{21} & l_{22} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ l_{n1} & l_{n2} & \dots & l_{nn} \end{bmatrix} \qquad U = \begin{bmatrix} u_{11} & u_{12} & \dots & u_{1n} \\ 0 & u_{22} & \dots & u_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & \dots & 0 & u_{nn} \end{bmatrix}$$

se cumple que $a_{ij} = \sum_{k=1}^{n} l_{ik}u_{kj}, \quad i,j = 1,2,\dots,n.$

Para $k > i$, $l_{ik} = 0$; entonces basta calcular solamente para $1 \le i \le k$. Por otro lado, para $k > j$: $u_{kj} = 0$; basta entonces calcular solamente para $1 \le j \le k$. Luego:

$$a_{ij} = \sum_{k=1}^{\text{mín}\{i,j\}} l_{ik}u_{kj}, \quad i,j = 1,2,\dots,n$$

Específicamente, para

$$\begin{aligned} i = j: &\quad l_{jj}u_{jj} = a_{jj} - \sum_{k=1}^{j-1} l_{jk}u_{kj}, \quad j = 1,2,\dots,n \\ j > i: &\quad u_{ij} = \frac{1}{l_{ii}}(a_{ij} - \sum_{k=1}^{i-1} l_{ik}u_{kj}) \\ i > j: &\quad l_{ij} = \frac{1}{u_{jj}}(a_{ij} - \sum_{k=1}^{j-1} l_{ik}u_{kj}). \end{aligned}$$

5.1. Algoritmo de Cholesky.

TEOREMA 3.16. *Sea $A = A^t \in \mathbb{R}^{n\times n}$ definida positiva. Entonces existe una única matriz triangular inferior $L \in \mathbb{R}^{n\times n}$ con elementos diagonales positivos tal que $A = LL^t$.*

DEMOSTRACIÓN. Por el lema 3.12 existe una factorización LU para una matriz simétrica y definida positiva, esto es, existe $\hat{L} \in \mathbb{R}^{n\times n}$ triangular inferior con unos en la diagonal y $\hat{U} \in \mathbb{R}^{n\times n}$ matriz triangular superior regular tal que $A = \hat{L}\hat{U}$. Definamos $D := \hat{U}(\hat{L}^t)^{-1}$. De $A = \hat{L}\hat{U}$ y $A = A^t$ tenemos

$$\hat{L}\hat{U} = A = A^t = \hat{U}^t\hat{L}^t$$

de donde

$$D := \hat{U}(\hat{L}^t)^{-1} = \hat{L}^{-1}\hat{U}^t$$

Ahora bien, del álgebra lineal se sabe que el producto de matrices triangulares superiores [inferiores] es triangular superior [inferior], que la inversa de una matriz triangular superior [inferior] es triangular superior [inferior] y que la transpuesta de una matriz triangular superior [inferior] es triangular inferior [superior]. Sabiendo esto, la igualdad $D = \hat{U}(\hat{L}^t)^{-1}$ implica que la matriz D es triangular superior, y la igualdad $D = \hat{L}^{-1}\hat{U}^t$ implica que D es triangular inferior. Luego D es una matriz diagonal :

$$D = \text{diag}(d_{11}, d_{22}, \dots, d_{nn})$$

Además:

$$A = \hat{L}\hat{U} = \hat{L}D\hat{L}^t.$$

Siendo A definida positiva, D también lo es, pues dado $x \neq 0 \in \mathbb{R}^n$:

$$x^t D x = x^t \hat{L}^{-1} A (\hat{L}^t)^{-1} x = x^t \hat{L}^{-1} A (\hat{L}^{-1})^t x = \big((\hat{L}^{-1})^t x\big)^t A \big((\hat{L}^{-1})^t x\big) > 0$$

luego $d_{ii} = e_i^t D e_i > 0$, $i = 1, 2, \ldots, n$. Así, D tiene diagonal positiva. Definiendo $D^{1/2} = \operatorname{diag}\big(\sqrt{d_{11}}, \sqrt{d_{22}}, \ldots, \sqrt{d_{nn}}\big)$, tenemos:

$$A = \hat{L} D \hat{L}^t = \hat{L} D^{1/2} D^{1/2} \hat{L}^t = (\hat{L} D^{1/2})(\hat{L} D^{1/2})^t = L L^t$$

Con $L := \hat{L} D^{1/2}$, matriz triangular inferior con elementos diagonales positivos, como se buscaba.

La prueba de la unicidad se deja como ejercicio. □

DEFINICIÓN. *La factorización de una matriz $A = A^t \in \mathbb{R}^{n \times n}$ definida positiva, tal que $A = LL^t$ donde L es una matriz triangular inferior con elementos diagonales positivos, es denominada factorización de Cholesky de A.*

De las fórmulas vistas anteriormente con

$$\begin{aligned} u_{jj} &= l_{jj}, \quad j = 1, 2, \ldots, n \\ l_{ij} &= u_{ji}, \quad i, j = 1, 2, \ldots, n \end{aligned}$$

se obtiene

$$\begin{aligned} l_{jj}^2 &= a_{jj} - \sum_{k=1}^{j-1} l_{jk}^2, \quad j = 1, 2, \ldots, n \\ l_{ij} &= \frac{1}{l_{jj}} (a_{ij} - \sum_{k=1}^{j-1} l_{ik} l_{jk}), \quad j < i. \end{aligned}$$

Así tenemos el algoritmo de Cholesky:

Algoritmo 3 Descomposición de Cholesky de una matriz definida positiva A

Entrada: $A = A^t = (a_{ij}) \in \mathbb{R}^{n \times n}$, definida positiva
Salida: Parte triangular inferior de L tal que $A = LL^t$

1: Calcular $l_{11} := \sqrt{a_{11}}$
2: **Para** $i = 2, \ldots, n$ **hacer**
3: Calcular $l_{i1} := \dfrac{a_{i1}}{l_{11}}$
4: **Fin Para**
5: **Para** $j = 2, \ldots, n$ **hacer**
6: Calcular $l_{jj} := \left(a_{jj} - \sum_{k=1}^{j-1} l_{jk}^2 \right)^{1/2}$
7: **Para** $i = j + 1, \ldots, n$ **hacer**
8: Calcular $l_{ij} := \dfrac{1}{l_{jj}} \left(a_{ij} - \sum_{k=1}^{j-1} l_{ik} l_{jk} \right)$
9: **Fin Para**
10: **Fin Para**
11: **Devolver** Parte triangular inferior de L

Se cumple:

$$\begin{aligned} \operatorname{cond}_2(A) &= \|A\|_2 \|A^{-1}\|_2 = \rho(A)\rho(A^{-1}) = \rho(LL^t)\rho((L^{-1})^t L^{-1}) \\ \operatorname{cond}_2(L) &= \|L\|_2 \|L^{-1}\|_2 = \rho(L)\rho(L^{-1}) \end{aligned}$$

La cantidad de operaciones necesarias para este algoritmo, es solamente la mitad de las del algoritmo de Gauss para n bastante grande.

5.2. Algoritmo compuesto para sistemas tridiagonales. Consideremos el sistema:

$$\begin{array}{ccccccccccccc}
a_1x_1 & + & c_1x_2 & & & & & & & & & = & f_1 \\
b_2x_1 & + & a_2x_2 & + & c_2x_3 & & & & & & & = & f_2 \\
 & & b_3x_2 & + & a_3x_3 & + & c_3x_4 & & & & & = & f_3 \\
 & & & & b_4x_2 & & \dots & & & & & & \\
 & & & & \ddots & & & & & & & & \vdots \\
 & & & & & & b_{n-1}x_{n-2} & + & a_{n-1}x_{n-1} & + & c_{n-1}x_n & = & f_{n-1} \\
 & & & & & & & & b_nx_{n-1} & + & a_nx_n & = & f_n
\end{array}$$

Sea

$$A = \begin{bmatrix} a_1 & c_1 & 0 & \dots & 0 \\ b_2 & a_2 & c_2 & & 0 \\ 0 & b_3 & a_3 & & 0 \\ \vdots & & \ddots & & c_{n-1} \\ 0 & \dots & 0 & b_n & a_n \end{bmatrix}$$

El sistema anterior (con la matriz $A = (a_{ij})$ asociada) es *tridiagonal* cuando $a_{ij} = 0$, para $|i - j| > 1$.

Si $A = LU$ con

$$L = \begin{bmatrix} \alpha_1 & 0 & \dots & & 0 \\ b_2 & \alpha_2 & \dots & & 0 \\ 0 & b_3 & & & \\ \vdots & 0 & \ddots & & \vdots \\ 0 & \dots & 0 & b_n & \alpha_n \end{bmatrix} \qquad U = \begin{bmatrix} 1 & u_1 & 0 & \dots & 0 \\ 0 & 1 & & \dots & 0 \\ & & \ddots & & \vdots \\ \vdots & & & 1 & u_{n-1} \\ 0 & & \dots & 0 & 1 \end{bmatrix}$$

Entonces

$$\begin{array}{ll}
a_1 = \alpha_1 & c_1 = \alpha_1 u_1 \\
b_2 = \alpha_2 & a_2 = b_2u_1 + \alpha_2 \qquad c_1 = \alpha_1 u_1 \\
 & a_3 = b_3u_2 + \alpha_3 \qquad c_2 = \alpha_2 u_2 \\
 & \vdots \qquad\qquad \vdots \\
 & a_n = b_nu_{n-1} + \alpha_n \quad c_{n-1} = \alpha_{n-1}u_{n-1}
\end{array}$$

Se obtiene:

$$\begin{array}{l}
\alpha_1 = a_1, \quad u_1 := c_1/\alpha_1 \\
\alpha_j = a_j - b_ju_{j-1}, \quad j = 2, \dots, n \\
u_j = c_j/\alpha_j, \quad j = 2, \dots, n-1
\end{array}$$

Se requieren $\alpha_j \neq 0, \quad j = 1, 2, \dots, n.$

Así tenemos el algoritmo compuesto para sistemas tridiagonales:

6. La Factorización QR

DEFINICIÓN. *Sea $A \in \mathbb{R}^{m\times n}$, $m \geq n$. Si existe una matriz ortogonal $Q \in \mathbb{R}^{m\times m}$ ($Q^tQ = I$) y una matriz $R = \begin{bmatrix} R_1 \\ 0 \end{bmatrix} \in \mathbb{R}^{m\times n}$ con R_1 matriz matriz triangular superior tal que $A = QR$, entonces QR es denominada factorización QR de A.*

La razón de desear obtener una factorización tal es simple: dado el sistema $Ax = b$ con $A = QR$ y $Q^tQ = I$ entonces

$$QRx = b \text{ implica } Q^tQRx = Q^tb, \text{ y luego } Rx = Q^tb,$$

un sistema triangular superior.

Algoritmo 4 Resolución de sistemas tridiagonales $Ax = f$

Entrada: $A = (b_j, a_j, c_j)$ matriz tridiagonal, $f = (f_1, \ldots, f_n)^t$ vector lado derecho
Salida: Solución $(x_1, \ldots, x_n)^t$ tal que $Ax = f$

$\alpha_1 := a_1, \quad u_1 := \frac{c_1}{\alpha_1}$
Para $j = 2, \ldots, n-1$ **hacer**
    $\alpha_j := a_j - b_j u_{j-1}$
    $u_j := \frac{c_j}{\alpha_j}$
Fin Para
$\alpha_n := a_n - b_n u_{n-1}$
$y_1 := \frac{f_1}{\alpha_1}$
Para $j = 2, \ldots, n$ **hacer**
    $y_j := \frac{f_j - b_j y_{j-1}}{\alpha_j}$
Fin Para
$x_n := y_n$
Para $j = n-1, \ldots, 1$ **hacer**
    $x_j := y_j - u_j x_{j+1}$
Fin Para
Devolver Solución $(x_1, \ldots, x_n)^t$

TEOREMA 3.17. *Sea $A \in \mathbb{R}^{m\times n}$, con $rang(A) = n$, $m \geq n$. Entonces A tiene una factorización QR con $R = \begin{bmatrix} R_1 \\ 0 \end{bmatrix}$ y R_1 tiene elementos diagonales distintos de cero.*

DEMOSTRACIÓN. Aplicando el proceso de ortogonalización de Gram-Schmidt a las columnas $a_1, a_2, \ldots, a_n$ de A se obtiene un sistema ortonormal $\{q_1, q_2, \ldots, q_n\} \subset \mathbb{R}^n$ con $\text{lin}\{a_1, \ldots, a_k\} = \text{lin}\{q_1, \ldots, q_k\}$ para $1 \leq k \leq n$. En especial se cumple:

$$a_k = \sum_{j=1}^{k} r_{jk} q_j, \quad k = 1, \ldots, n$$

con $r_{kk} \neq 0$. Completando $\{q_1, \ldots, q_n\}$ a una base ortonormal de $\mathbb{R}^m$, digamos $\{q_1, \ldots, q_n, q_{n+1}, \ldots, q_m\}$, se tiene que $Q := [q_1, \ldots, q_m] \in \mathbb{R}^{m\times n}$ es ortogonal, y definiendo

$$(R_1)_{jk} := \begin{cases} r_{jk}, & \text{para } j \leq k \\ 0, & \text{para } j > k \end{cases}$$

se cumple

$$A = [a_1, \ldots, a_n] = QR, \quad R := \begin{bmatrix} R_1 \\ 0 \end{bmatrix}.$$

□

TEOREMA 3.18. *Para cualquier matriz $A \in \mathbb{R}^{m\times n}$, $m \geq n$ existe una factorización QR.*

6.1. Factorización QR de Householder.

Idea: En el primer paso se determina una matriz ortogonal $P_1 \in \mathbb{R}^{m\times m}$ tal que

$$P_1 A = \left[\begin{array}{c|ccc} * & & & \\ \hline 0 & * & \ldots & * \\ \vdots & \vdots & & \vdots \\ 0 & * & \ldots & * \end{array}\right]$$

Supongamos que ya han sido determinadas matrices ortogonales $P_1, P_2, \ldots, P_k$ tal que $P_k \ldots P_1 A$ tiene la siguiente forma:

$$P_k \ldots P_1 A = \left[\begin{array}{cccc|ccc} * & * & \ldots & * & * & \ldots & * \\ & * & \ldots & * & * & \ldots & * \\ & & \ddots & \vdots & \vdots & & \\ 0 & & \ldots & * & * & \ldots & * \\ \hline 0 & & \ldots & 0 & * & \ldots & * \\ \vdots & & & \vdots & \vdots & & \vdots \\ 0 & & \ldots & 0 & * & \ldots & * \end{array}\right] = \left[\begin{array}{c|c} R^k & A_{12}^k \\ \hline 0 & A_{22}^k \end{array}\right]$$

donde $R^k \in \mathbb{R}^{k\times k}$ es una matriz triangular superior. Sea $k \leq n+1$, de otro modo $P_k \ldots P_1 A$ tendría la forma deseada. Luego, se determina una matriz ortogonal $P_{k+1} \in \mathbb{R}^{(m-k)\times(m-k)}$ tal que la primera columna de $P_{k+1}A_{22}^k$ sea un múltiplo del primer vector canónico de $\mathbb{R}^{m-k}$ ($P_{k+1}A_{22}^k = \alpha(1, 0, \ldots, 0)^t$). Se define

$$P_{k+1} := \left[\begin{array}{c|c} I^k & 0 \\ \hline 0 & P_{k+1} \end{array}\right]$$

se cumple que $P_{k+1} \in \mathbb{R}^{m\times m}$ es ortogonal (¡verificar!). También se cumple:

$$P_{k+1}P_k \ldots P_1 A = \left[\begin{array}{c|c} R^k & A_{12}^k \\ \hline 0 & P_{k+1}A_{22}^k \end{array}\right] = \left[\begin{array}{c|c} R^{k+1} & A_{12}^{k+1} \\ \hline 0 & A_{22}^{k+1} \end{array}\right],$$

donde $\mathbb{R}^{k+1}$ es una matriz triangular superior.
Se debe notar que las primeras k filas no cambian por la multiplicación de $P_k \ldots P_1 A$ con P_{k+1} por su izquierda.

Definición. *Sea $u \in \mathbb{R}^n \setminus \{0\}$. Una matriz $P \in \mathbb{R}^{n\times n}$ de la forma*

$$P = I - \frac{2uu^t}{u^t u}$$

es denominada matriz de Householder.

Observación. Se cumple que la matriz de Householder es simétrica y ortogonal. En efecto, la simetría se sigue de

$$P^t = \left(I - \frac{2uu^t}{u^t u}\right)^t = I^t - \frac{2(u^t)^t u^t}{u^t u} = I - \frac{2uu^t}{u^t u} = P,$$

mientras que la ortogonalidad se sigue del hecho que

$$PP^t = \left(I - \frac{2uu^t}{u^t u}\right)\left(I - \frac{2uu^t}{u^t u}\right) = I - \frac{4uu^t}{u^t u} + \frac{4(uu^t)(uu^t)}{(u^t u)^2} = I - \frac{4uu^t}{u^t u} + \frac{4u(u^t u)u^t}{(u^t u)^2} = I.$$

Ahora bien, consideremos

$$\operatorname{sign}(x) = \begin{cases} 1, & x \geq 0 \\ -1, & x < 0 \end{cases}$$

Lema 3.19. *Sea $x \in \mathbb{R}^n \setminus \{0\}$. Definiendo $u := x + \operatorname{sign}(x_1)\|x\|_2 e_1$, se obtiene por*

$$P = I - \frac{2uu^t}{u^t u} = I - \beta uu^t \quad \text{con} \quad \beta = \frac{2}{u^t u} = \frac{1}{\|x\|_2\big(\|x\|_2 + |x_1|\big)},$$

una matriz de Householder con

$$Px = -\operatorname{sign}(x_1)\|x\|_2 e_1 = (*, 0, \ldots, 0)^t.$$

DEMOSTRACIÓN.

$$\begin{aligned} u^t u &= \big(x^t + \operatorname{sign}(x_1)\|x\|_2 e_1^t\big)\big(x + \operatorname{sign}(x_1)\|x\|_2 e_1\big) \\ &= \|x\|_2^2 + \operatorname{sign}(x_1)\|x\|_2 x_1 + x_1 \operatorname{sign}(x_1)\|x\|_2 + \operatorname{sign}(x_1)^2\|x\|_2^2 \\ &= 2\|x\|_2^2 + 2|x_1|\|x\|_2 = 2\|x\|_2\big(\|x\|_2 + |x_1|\big) \end{aligned}$$

lo cual implica que $\beta = \dfrac{2}{u^t u} = \dfrac{1}{\|x\|_2(\|x\|_2 + |x_1|)}$

$$\begin{aligned} Px &= P\big(u - \operatorname{sign}(x_1)\|x\|_2 e_1\big) = Pu - \operatorname{sign}(x_1)\|x\|_2 Pe_1 \\ &= \Big(I - \frac{2uu^t}{u^t u}\Big)u - \operatorname{sign}(x_1)\|x\|_2(I - \beta uu^t)e_1 \\ &= u - \frac{2uu^t u}{u^t u} - \operatorname{sign}(x_1)\|x\|_2 e_1 + \operatorname{sign}(x_1)\|x\|_2 \beta uu^t e_1 \\ &= -u - \operatorname{sign}(x_1)\|x\|_2 e_1 + \beta u_1 \operatorname{sign}(x_1)\|x\|_2 u \\ &= -u - \operatorname{sign}(x_1)\|x\|_2 e_1 + u\frac{(x_1 + \operatorname{sign}(x_1)\|x\|_2)}{\|x\|_2\big(\|x\|_2 + |x_1|\big)} \operatorname{sign}(x_1)\|x\|_2 \\ &= -\operatorname{sign}(x_1)\|x\|_2 e_1. \end{aligned}$$

□

Se obtiene el siguiente algoritmo:

Entrada: matriz $A = (a_{ij}) \in \mathbb{R}^{m\times n}$, $m \geq n$	
Para $k = 1, \ldots,$ mín$\{n, m-1\}$	
	Calcular una matriz $(m-k+1)\times(m-k+1)$ de Householder con $P_k(a_{kk}, \ldots, a_{mk})^t = (r_k, 0, \ldots, 0)^t$
	Hacer $P_k := diag(I_{k-1}, P_k)$
	Calcular $A := P_k A$
Salida: matriz transformada A a una matriz R triangular superior	

De esta manera, la matriz A se transforma en mín$\{n, m-1\}$ pasos en una matriz triangular.
Definiendo $Q := P_1, \ldots, P_n$ se ha encontrado la factorización QR.
Evitando un overflow y un underflow: Es conveniente primero calcular $y := x/\|x\|_\infty$ y después $u := y + \operatorname{sign}(y_1)\|y\|_2 e_1$. La matriz de Householder correspondiente será

$$P := I - \beta uu^t \quad \text{con} \quad \beta := \frac{1}{\|y\|_2\big(\|y\|_2 + |y_1|\big)}.$$

Al solucionar un sistema de ecuaciones lineales (mediante el siguiente algoritmo) no se requiere almacenar $Q := P_1 \ldots P_n$. Sin embargo se pueden almacenar los datos importantes para P_k, $u_k = (u_{kk}, \ldots, u_{mk})^t$ y β_k de la siguiente manera:

$$A := \begin{bmatrix} u_{11} & a_{12} & \ldots & a_{1n} \\ u_{21} & u_{22} & \ldots & a_{2n} \\ \vdots & & \ddots & \vdots \\ u_{n1} & u_{n2} & \ldots & u_{nn} \\ \vdots & & & \vdots \\ u_{m1} & u_{m2} & \ldots & u_{mn} \end{bmatrix}, \quad r = \begin{bmatrix} a_{11} \\ \vdots \\ a_{nn} \end{bmatrix}, \quad \beta = \begin{bmatrix} \beta_1 \\ \vdots \\ \beta_n \end{bmatrix}$$

La implementación del algoritmo para el k-ésimo paso para el cálculo de $\tilde{P}_k = I_{m-k+1} - \beta_k u_k u_k^t$, donde

$$u_k := (u_{kk}, \ldots, u_{mk})^t, \qquad \beta_k := \frac{2}{u_k^t u_k}$$

tal que

$$\tilde{P}_k a_k = (r_k, 0, \ldots, 0)^t \text{ con } a_k = (a_{kk}, \ldots, a_{mk})^t$$

es la siguiente:

Algoritmo 5 Algoritmo de transformación de Householder

Entrada: Matriz $A \in \mathbb{R}^{m\times n}$
Salida: Matriz R triangular superior y las matrices de reflexión de Householder

Calcular $\|a_k\|_\infty = \max_{i=k,\dots,n} |a_{ik}|$
$\alpha := 0$
Para $i = k, \dots, n$ **hacer**
    $u_{ik} := \frac{a_{ik}}{\|a_k\|_\infty}$
    $\alpha := \alpha + u_{ik}^2$
Fin Para
$\alpha := \sqrt{\alpha}$
$\beta := \frac{1}{\alpha(\alpha+|u_{kk}|)}$
$u_{kk} := u_{kk} + \operatorname{sign}(a_{kk})\alpha$
Actualizar $A := P_k A$ (se eliminan las entradas por debajo de la diagonal en la columna k)
$a_{kk} := -\operatorname{sign}(a_{kk})\|a_k\|_\infty \alpha$
Para $i = k+1, \dots, m$ **hacer**
    $a_{ik} := 0$
Fin Para
Para $j = k+1, \dots, n$ **hacer**
    $s := \beta \sum_{i=k}^{m} u_{ik} a_{ij}$
    Para $i = k, \dots, m$ **hacer**
        $a_{ij} := a_{ij} - s \cdot u_{ik}$
    Fin Para
Fin Para

6.2. Factorización QR de Givens. Sea $A = (a_{ij}) \in \mathbb{R}^{m\times n}$, $m \geq n$. Para obtener la factorización QR de A mediante el método de Givens, se multiplica por la izquierda a A sucesivamente por *rotaciones de Givens*, que son matrices $m \times m$ de la forma

$$
G_{ik} := \begin{bmatrix}
1 & & 0 & & & & & & \\
& \ddots & & \vdots & & 0 & \vdots & & 0 \\
0 & & 1 & & & & & & \\
& \cdots & & C & & \cdots & S & & \cdots \\
& & & & 1 & & & & \\
& 0 & & \vdots & & \ddots & \vdots & & 0 \\
& & & & & & 1 & & \\
& \cdots & & -S & & \cdots & C & & \cdots \\
& & & & & & & 1 & \\
& 0 & & \vdots & & 0 & \vdots & & \ddots \\
& & & & & & & & & 1
\end{bmatrix}
\begin{matrix} \\ \\ \\ \leftarrow i \\ \\ \\ \\ \leftarrow k \\ \\ \\ \\ \end{matrix}
$$

$$
\begin{matrix} \\ \\ \\ \uparrow \\ i \end{matrix}
\qquad
\begin{matrix} \\ \\ \\ \uparrow \\ k \end{matrix}
$$

con $C^2 + S^2 = 1$, $C \neq 0$, $1 \leq i \leq k \leq m$. Una rotación de Givens se distingue de la matriz identidad solamente por los elementos de las posiciones (i,i), (i,k), (k,i) y (k,k).

Las rotaciones de Givens gozan de las siguientes propiedades:

a) Los G_{ik} son ortogonales:

$$\begin{bmatrix} C & S \\ -S & C \end{bmatrix}^t \begin{bmatrix} C & S \\ -S & C \end{bmatrix} = \begin{bmatrix} C & -S \\ S & C \end{bmatrix} \begin{bmatrix} C & S \\ -S & C \end{bmatrix}$$
$$= \begin{bmatrix} C^2+S^2 & 0 \\ 0 & C^2+S^2 \end{bmatrix}$$
$$= \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

b) Multiplicación por un vector:
Sea $x \in \mathbb{R}^m$, $y := G_{ik}x$, entonces

$$y = \begin{bmatrix} x_1 \\ \vdots \\ x_{i-1} \\ Cx_i + Sx_k \\ x_{i+1} \\ \vdots \\ x_{k-1} \\ -Sx_i + Cx_k \\ \vdots \\ x_m \end{bmatrix} \begin{matrix} \\ \\ \\ \leftarrow i \\ \\ \\ \\ \leftarrow k \\ \\ \\ \end{matrix} = \begin{cases} Cx_i + Sx_k, & \text{para } j = i \\ -Sx_i + Cx_k, & \text{para } j = k \\ x_j, & \text{para } j \neq i, k \end{cases}$$

NOTA. $C = \cos(\theta)$, $S = \operatorname{sen}(\theta)$, θ: ángulo de rotación;

$$\begin{bmatrix} \cos(\theta) & \operatorname{sen}(\theta) \\ -\operatorname{sen}(\theta) & \cos(\theta) \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} x\cos(\theta) + y\operatorname{sen}(\theta) \\ -x\operatorname{sen}(\theta) + y\cos(\theta) \end{bmatrix}$$

Multiplicando una matriz $A \in \mathbb{R}^{m\times n}$ por la izquierda con una rotación de Givens G_{ik}, se obtiene solamente un cambio de la i-ésima y k-ésima filas. Las nuevas filas son una combinación lineal de las antiguas y están dadas por

$$\begin{aligned} (G_{ik}A)_{ij} &= \quad C\, a_{ij} + S\, a_{kj} \\ (G_{ik}A)_{kj} &= -S\, a_{ij} + C\, a_{kj}, \qquad j = 1, 2, \ldots, n \end{aligned}$$

En particular, si $a_{ij} = a_{kj} = 0$ entonces $(G_{ik}A)_{ij} = 0 = (G_{ik}A)_{kj}$.

Mediante la factorización QR de Givens, para cualquier $x \in \mathbb{R}^n$, $1 \leq i < k \leq m$ se puede encontrar una rotación de Givens tal que $(G_{ik}x)_k = 0$. Entonces se puede poner la k-ésima componente de $y := G_{ik}x$ a cero dejando todas las demás con la i-ésima componente sin cambio. Para esto, se define, para $(\alpha, \beta) \in \mathbb{R}^2$, $\gamma \in \mathbb{R}$ y $C^2 + S^2 = 1$ tales que

$$\begin{matrix} i \to \\ k \to \end{matrix} \begin{bmatrix} C & S \\ -S & C \end{bmatrix} \begin{bmatrix} \alpha \\ \beta \end{bmatrix} = \begin{bmatrix} \gamma \\ 0 \end{bmatrix}$$

Por consiguiente, mediante las rotaciones de Givens se pueden cambiar a cero los elementos que se encuentran debajo de la diagonal. Se debe tener en cuenta que los elementos que ya son iguales a cero se quedan así.

EJEMPLO 3.5. En el siguiente ejemplo tipo de una matriz 4×3, avanzando por columnas, escribiremos, en cada operación

$\circ$: elemento no cambiado por la transformación.
$*$: elemento cambiado por la transformación.

Algoritmo 6 Cálculo de rotación y escala

Entrada: $\alpha, \beta \in \mathbb{R}$
if $\beta = 0$ **then**
  $C \leftarrow 1$
  $S \leftarrow 0$
  $\gamma \leftarrow \alpha$
else
  if $|\beta| \geq |\alpha|$ **then**
    $t \leftarrow \alpha/\beta$
    $S \leftarrow 1/\sqrt{1+t^2}$
    $C \leftarrow St$
    $\gamma \leftarrow \beta\sqrt{1+t^2}$
  else
    $t \leftarrow \beta/\alpha$
    $C \leftarrow 1/\sqrt{1+t^2}$
    $S \leftarrow Ct$
    $\gamma \leftarrow \alpha\sqrt{1+t^2}$
  Fin if
Fin if
Salida: $\mathrm{rot}(\alpha, \beta) := (C, S, \gamma)$
Propiedad: $C^2 + S^2 = 1$ y

$$\begin{bmatrix} C & S \\ -S & C \end{bmatrix} \begin{bmatrix} \alpha \\ \beta \end{bmatrix} = \begin{bmatrix} \gamma \\ 0 \end{bmatrix}$$

$$A := \begin{bmatrix} \circ & \circ & \circ \\ \circ & \circ & \circ \\ \circ & \circ & \circ \\ \circ & \circ & \circ \end{bmatrix} \underset{(1,2)}{\overset{G_{12}}{\rightarrow}} \begin{bmatrix} * & * & * \\ 0 & * & * \\ \circ & \circ & \circ \\ \circ & \circ & \circ \end{bmatrix} \underset{(1,3)}{\overset{G_{13}}{\rightarrow}} \begin{bmatrix} * & * & * \\ 0 & \circ & \circ \\ 0 & * & * \\ \circ & \circ & \circ \end{bmatrix}$$

$$\underset{(1,4)}{\overset{G_{14}}{\rightarrow}} \begin{bmatrix} * & * & * \\ 0 & \circ & \circ \\ 0 & \circ & \circ \\ 0 & * & * \end{bmatrix} \underset{(2,3)}{\overset{G_{23}}{\rightarrow}} \begin{bmatrix} \circ & \circ & \circ \\ 0 & * & * \\ 0 & 0 & * \\ 0 & \circ & \circ \end{bmatrix} \underset{(2,4)}{\overset{G_{24}}{\rightarrow}} \begin{bmatrix} 0 & \circ & \circ \\ 0 & * & * \\ 0 & 0 & \circ \\ 0 & 0 & * \end{bmatrix} \underset{(3,4)}{\overset{G_{34}}{\rightarrow}} \begin{bmatrix} \circ & \circ & \circ \\ 0 & \circ & \circ \\ 0 & 0 & * \\ 0 & 0 & 0 \end{bmatrix}$$

Esto es, dada $A \in \mathbb{R}^{m \times n}$, aplicar sucesivamente $(1,2), (1,3), \ldots, (1,m), (2,3), \ldots, (2,m)$, $\ldots$, $\min(\{n, m-1\}, m)$.

Se obtiene el siguiente algoritmo:

Nota. Para el método de Givens se requieren más multiplicaciones/divisiones que para el método de Householder. Sin embargo, para matrices de una estructura especial, como por ejemplo matrices con muchos elementos nulos, el método de Givens es mejor. Además existe un método rápido de Givens.

7. Ejemplos

7.1. Cálculo de la factorización $A = QR$ por el algoritmo de Householder. Consideramos la matriz

$$A = \begin{bmatrix} 63{,}0000 & 41{,}0000 & -88{,}0000 \\ 42{,}0000 & 60{,}0000 & 51{,}0000 \\ 0{,}0000 & -28{,}0000 & 56{,}0000 \\ 126{,}0000 & 82{,}0000 & -71{,}0000 \end{bmatrix} \tag{7}$$

Algoritmo 7 Algoritmo de Givens para la descomposición QR

Entrada: Matriz $A \in \mathbb{R}^{m\times n}$, con $m \geq n$
Salida: Matriz R triangular superior y matriz ortogonal Q

Para $i = 1, 2, \ldots, \text{mín}(n, m-1)$ **hacer**
  Para $k = i+1, \ldots, m$ **hacer**
    $(C, S, a_{ii}) := \text{rot}(a_{ii}, a_{ki})$
    $a_{ki} := 0$
    Para $j = i+1, \ldots, n$ **hacer**

$$\begin{bmatrix} a_{ij} \\ a_{kj} \end{bmatrix} := \begin{bmatrix} C & S \\ -S & C \end{bmatrix} \begin{bmatrix} a_{ij} \\ a_{kj} \end{bmatrix}$$

    Fin Para
  Fin Para
Fin Para
Devolver $Q^tA = R$, donde Q es ortogonal y R tiene la forma:

$$R = \begin{bmatrix} R_1 \\ 0 \end{bmatrix} \begin{matrix} \leftarrow n \\ \leftarrow m-n \end{matrix}$$

donde R_1 es triangular superior.

Para la reducción de la matriz A a una forma triangular, realizamos 3 pasos sucesivos para reducir sus columnas.

En el primer paso, reducimos la columna $x_1 = (63{,}0000, 42{,}0000, 0{,}0000, 126{,}0000)^t$, definiendo

$$u_1 = x_1 + \text{sign}(x_{1(1)})\|x_1\|_2 e_1 = (210{,}0000, 42{,}0000, 0{,}0000, 126{,}0000)^t$$

y luego la matriz de Householder

$$\tilde{P}_1 = I - \frac{2u_1u_1^t}{u_1^tu_1} = \begin{bmatrix} -0{,}4286 & -0{,}2857 & 0{,}0000 & -0{,}8571 \\ -0{,}2857 & 0{,}9429 & 0{,}0000 & -0{,}1714 \\ 0{,}0000 & 0{,}0000 & 1{,}0000 & 0{,}0000 \\ -0{,}8571 & -0{,}1714 & 0{,}0000 & 0{,}4857 \end{bmatrix}$$

$$P_1 = \begin{bmatrix} -0{,}4286 & -0{,}2857 & 0{,}0000 & -0{,}8571 \\ -0{,}2857 & 0{,}9429 & 0{,}0000 & -0{,}1714 \\ 0{,}0000 & 0{,}0000 & 1{,}0000 & 0{,}0000 \\ -0{,}8571 & -0{,}1714 & 0{,}0000 & 0{,}4857 \end{bmatrix}$$

$$P_1A = \begin{bmatrix} -147{,}0000 & -105{,}0000 & 84{,}0000 \\ 0{,}0000 & 30{,}8000 & 85{,}4000 \\ 0{,}0000 & -28{,}0000 & 56{,}0000 \\ 0{,}0000 & -5{,}6000 & 32{,}2000 \end{bmatrix}$$

Para reducir la segunda columna, tomamos $x_2 = (30{,}8000, -28{,}0000, -5{,}6000)^t$ y luego

$$u_2 = x_2 + \text{sign}(x_{2(1)})\|x_2\|_2 e_1 = (72{,}8000, -28{,}0000, -5{,}6000)^t,$$

para luego calcular

$$\tilde{P}_2 = I - \frac{2u_2u_2^t}{u_2^tu_2} = \begin{bmatrix} -0{,}7333 & 0{,}6667 & 0{,}1333 \\ 0{,}6667 & 0{,}7436 & -0{,}0513 \\ 0{,}1333 & -0{,}0513 & 0{,}9897 \end{bmatrix}$$

$$P_2 = \begin{bmatrix} 1{,}0000 & 0{,}0000 & 0{,}0000 & 0{,}0000 \\ 0{,}0000 & -0{,}7333 & 0{,}6667 & 0{,}1333 \\ 0{,}0000 & 0{,}6667 & 0{,}7436 & -0{,}0513 \\ 0{,}0000 & 0{,}1333 & -0{,}0513 & 0{,}9897 \end{bmatrix}$$

Ahora

$$P_2P_1A = \begin{bmatrix} -147{,}0000 & -105{,}0000 & 84{,}0000 \\ 0{,}0000 & -42{,}0000 & -21{,}0000 \\ -0{,}0000 & 0{,}0000 & 96{,}9231 \\ 0{,}0000 & 0{,}0000 & 40{,}3846 \end{bmatrix}.$$

Finalmente, reducimos la tercera columna tomando $x_3 = (96{,}9231, 40{,}3846)^t$,

$$u_3 = x_3 + \text{sign}(x_{3(1)})\|x_3\|_2 e_1 = (201{,}9231, 40{,}3846)^t$$

y calculando

$$\tilde{P}_3 = I - \frac{2u_3u_3^t}{u_3^tu_3} = \begin{bmatrix} -0{,}9231 & -0{,}3846 \\ -0{,}3846 & 0{,}9231 \end{bmatrix}$$

$$P_3 = \begin{bmatrix} 1{,}0000 & 0{,}0000 & 0{,}0000 & 0{,}0000 \\ 0{,}0000 & 1{,}0000 & 0{,}0000 & 0{,}0000 \\ 0{,}0000 & 0{,}0000 & -0{,}9231 & -0{,}3846 \\ 0{,}0000 & 0{,}0000 & -0{,}3846 & 0{,}9231 \end{bmatrix}$$

Luego, las matrices triangular superior R y ortogonal Q tales que $A = QR$ son

$$R = P_3P_2P_1A = \begin{bmatrix} -147{,}0000 & -105{,}0000 & 84{,}0000 \\ 0{,}0000 & -42{,}0000 & -21{,}0000 \\ -0{,}0000 & -0{,}0000 & -105{,}0000 \\ 0{,}0000 & -0{,}0000 & -0{,}0000 \end{bmatrix}$$

$$Q = P_1P_2P_3 = \begin{bmatrix} -0{,}4286 & 0{,}0952 & 0{,}4762 & -0{,}7619 \\ -0{,}2857 & -0{,}7143 & -0{,}5714 & -0{,}2857 \\ 0{,}0000 & 0{,}6667 & -0{,}6667 & -0{,}3333 \\ -0{,}8571 & 0{,}1905 & -0{,}0476 & 0{,}4762 \end{bmatrix}$$

7.2. Cálculo de la factorización $A = QR$ por rotaciones de Givens. Consideramos la misma matriz A del ejemplo anterior, definida por (7). Siguiendo los pasos del ejemplo (3.5):

Definimos

$$(C, S, a_{11}) = \text{rot}(a_{11}, a_{21}) = \text{rot}(63{,}0000, 42{,}0000) = (0{,}8321, 0{,}5547, 75{,}717),$$

y

$$G_{12} = \begin{bmatrix} 0{,}8321 & 0{,}5547 & 0{,}0000 & 0{,}0000 \\ -0{,}5547 & 0{,}8321 & 0{,}0000 & 0{,}0000 \\ 0{,}0000 & 0{,}0000 & 1{,}0000 & 0{,}0000 \\ 0{,}0000 & 0{,}0000 & 0{,}0000 & 1{,}0000 \end{bmatrix}$$

$$G_{12}A = \begin{bmatrix} 75{,}7166 & 67{,}3961 & -44{,}9307 \\ 0{,}0000 & 27{,}1803 & 91{,}2482 \\ 0{,}0000 & -28{,}0000 & 56{,}0000 \\ 126{,}0000 & 82{,}0000 & -71{,}0000 \end{bmatrix}$$

Ahora

$$(C, S, a_{11}) = \text{rot}(a_{11}, a_{31}) = \text{rot}(75{,}7166, 0{,}0000) = (1{,}0000, 0{,}0000, 75{,}717)$$

y

$$G_{13} = \begin{bmatrix} 1{,}0000 & 0{,}0000 & 0{,}0000 & 0{,}0000 \\ 0{,}0000 & 1{,}0000 & 0{,}0000 & 0{,}0000 \\ 0{,}0000 & 0{,}0000 & 1{,}0000 & 0{,}0000 \\ 0{,}0000 & 0{,}0000 & 0{,}0000 & 1{,}0000 \end{bmatrix}$$

$$G_{13}G_{12}A = \begin{bmatrix} 75{,}7166 & 67{,}3961 & -44{,}9307 \\ 0{,}0000 & 27{,}1803 & 91{,}2482 \\ 0{,}0000 & -28{,}0000 & 56{,}0000 \\ 126{,}0000 & 82{,}0000 & -71{,}0000 \end{bmatrix}$$

Para

$$(C, S, a_{11}) = \text{rot}(a_{11}, a_{41}) = \text{rot}(75{,}7166, 126{,}0000) = (0{,}5151, 0{,}8571, 147{,}000),$$

$$G_{14} = \begin{bmatrix} 0{,}5151 & 0{,}0000 & 0{,}0000 & 0{,}8571 \\ 0{,}0000 & 1{,}0000 & 0{,}0000 & 0{,}0000 \\ 0{,}0000 & 0{,}0000 & 1{,}0000 & 0{,}0000 \\ -0{,}8571 & 0{,}0000 & 0{,}0000 & 0{,}5151 \end{bmatrix}$$

$$G_{14}G_{13}G_{12}A = \begin{bmatrix} 147{,}0000 & 105{,}0000 & -84{,}0000 \\ 0{,}0000 & 27{,}1803 & 91{,}2482 \\ 0{,}0000 & -28{,}0000 & 56{,}0000 \\ 0{,}0000 & -15{,}5316 & 1{,}9415 \end{bmatrix}$$

Para

$$(C, S, a_{11}) = \text{rot}(a_{22}, a_{32}) = \text{rot}(27{,}1803, -28{,}0000) = (-0{,}6965, 0{,}7175, -39{,}023),$$

$$G_{23} = \begin{bmatrix} 1{,}0000 & 0{,}0000 & 0{,}0000 & 0{,}0000 \\ 0{,}0000 & -0{,}6965 & 0{,}7175 & 0{,}0000 \\ 0{,}0000 & -0{,}7175 & -0{,}6965 & 0{,}0000 \\ 0{,}0000 & 0{,}0000 & 0{,}0000 & 1{,}0000 \end{bmatrix}$$

$$G_{23}G_{14}G_{13}G_{12}A = \begin{bmatrix} 147{,}0000 & 105{,}0000 & -84{,}0000 \\ 0{,}0000 & -39{,}0227 & -23{,}3750 \\ 0{,}0000 & 0{,}0000 & -104{,}4789 \\ 0{,}0000 & -15{,}5316 & 1{,}9415 \end{bmatrix}$$

Para

$$(C, S, a_{22}) = \text{rot}(a_{22}, a_{42}) = \text{rot}(-39{,}0227, -15{,}5316) = (0{,}9291, 0{,}3698, -42{,}000),$$

$$G_{24} = \begin{bmatrix} 1{,}0000 & 0{,}0000 & 0{,}0000 & 0{,}0000 \\ 0{,}0000 & 0{,}9291 & 0{,}0000 & 0{,}3698 \\ 0{,}0000 & 0{,}0000 & 1{,}0000 & 0{,}0000 \\ 0{,}0000 & -0{,}3698 & 0{,}0000 & 0{,}9291 \end{bmatrix}$$

$$G_{24}G_{23}G_{14}G_{13}G_{12}A = \begin{bmatrix} 147{,}0000 & 105{,}0000 & -84{,}0000 \\ 0{,}0000 & -42{,}0000 & -21{,}0000 \\ 0{,}0000 & 0{,}0000 & -104{,}4789 \\ 0{,}0000 & 0{,}0000 & 10{,}4479 \end{bmatrix}$$

Y para

$$(C, S, a_{11}) = \text{rot}(a_{33}, a_{43}) = \text{rot}(-104{,}4789, 10{,}4479) = (0{,}9950, -0{,}0995, -105{,}000),$$

$$G_{34} = \begin{bmatrix} 1{,}0000 & 0{,}0000 & 0{,}0000 & 0{,}0000 \\ 0{,}0000 & 1{,}0000 & 0{,}0000 & 0{,}0000 \\ 0{,}0000 & 0{,}0000 & 0{,}9950 & -0{,}0995 \\ 0{,}0000 & 0{,}0000 & 0{,}0995 & 0{,}9950 \end{bmatrix}$$

Finalmente

$$R = G_{34}G_{24}G_{23}G_{14}G_{13}G_{12}A = \begin{bmatrix} 147{,}0000 & 105{,}0000 & -84{,}0000 \\ 0{,}0000 & -42{,}0000 & -21{,}0000 \\ 0{,}0000 & 0{,}0000 & -105{,}0000 \\ 0{,}0000 & 0{,}0000 & 0{,}0000 \end{bmatrix}$$

y

$$Q = \begin{bmatrix} 0{,}4286 & 0{,}0952 & 0{,}4762 & -0{,}7619 \\ 0{,}2857 & -0{,}7143 & -0{,}5714 & -0{,}2857 \\ 0{,}0000 & 0{,}6667 & -0{,}6667 & -0{,}3333 \\ 0{,}8571 & 0{,}1905 & -0{,}0476 & 0{,}4762 \end{bmatrix}.$$

7.3. Cálculo de $A = LL^t$ por el algoritmo de Cholesky. Consideremos

$$A = \begin{bmatrix} 136{,}0000 & 90{,}8600 & 0{,}0000 & 0{,}0000 \\ 90{,}8600 & 98{,}8100 & -67{,}5900 & 0{,}0000 \\ 0{,}0000 & -67{,}5900 & 132{,}0100 & 42{,}2600 \\ 0{,}0000 & 0{,}0000 & 42{,}2600 & 177{,}1700 \end{bmatrix}$$

La factorización de Cholesky $A = LL^t$ con $L = (l_{ij}) \in \mathbb{R}^{4\times 4}$ se realiza de manera directa por las fórmulas obtenidas, teniendo en cuenta simplemente el orden de cálculo:

$$\begin{aligned} l_{11} &= (136{,}0000 - 0{,}0000)^{1/2} = 11{,}6619 \\ l_{21} &= (90{,}8600 - 0{,}0000)/11{,}6619 = 7{,}7912 \\ l_{31} &= (0{,}0000 - 0{,}0000)/11{,}6619 = 0{,}0000 \\ l_{41} &= (0{,}0000 - 0{,}0000)/11{,}6619 = 0{,}0000 \\ l_{22} &= (98{,}8100 - 60{,}7025)^{1/2} = 6{,}1731 \\ l_{32} &= (-67{,}5900 - 0{,}0000)/6{,}1731 = -10{,}9491 \\ l_{42} &= (0{,}0000 - 0{,}0000)/6{,}1731 = 0{,}0000 \\ l_{33} &= (132{,}0100 - 119{,}8821)^{1/2} = 3{,}4825 \\ l_{43} &= (42{,}2600 - 0{,}0000)/3{,}4825 = 12{,}1349 \\ l_{44} &= (177{,}1700 - 147{,}2563)^{1/2} = 5{,}4693 \end{aligned}$$

El resto de los elementos de L (por encima de la diagonal) es cero:

$$l_{12} = l_{13} = l_{14} = l_{23} = l_{24} = l_{34} = 0.$$

Luego

$$L = \begin{bmatrix} 11{,}6619 & 0{,}0000 & 0{,}0000 & 0{,}0000 \\ 7{,}7912 & 6{,}1731 & 0{,}0000 & 0{,}0000 \\ 0{,}0000 & -10{,}9491 & 3{,}4825 & 0{,}0000 \\ 0{,}0000 & 0{,}0000 & 12{,}1349 & 5{,}4693 \end{bmatrix}.$$

7.4. Factorización $PA = LU$ con pivoteo de filas escaladas. Sea

$$A = \begin{bmatrix} 30{,}0000 & 9{,}0000 & 77{,}0000 \\ 20{,}0000 & 6{,}0000 & 80{,}0000 \\ 27{,}0000 & 11{,}0000 & 98{,}0000 \end{bmatrix}$$

Realizaremos la factorización LU de A con pivoteo de filas escaladas: en lugar de elegir el pivote según el criterio (p. 29)

$$|a_{r1}| = \text{máx}\{|a_{11}|, |a_{21}|, \ldots, |a_{n1}|\},$$

elegimos el índice r tal que

$$\frac{|a_{r1}|}{s_r} = \text{máx}\Big\{\frac{|a_{11}|}{s_1}, \frac{|a_{21}|}{s_2}, \ldots, \frac{|a_{n1}|}{s_n}\Big\},$$

donde $s_i = |a_{i1}| + |a_{i2}| + \cdots + |a_{in}|$ para $i = 1, 2, \ldots, n$. Puesto que estos útimos números corresponden a las normas de las filas (mediante la norma $\|\cdot\|_1$), la elección del pivote se realiza, de manera equivalente, en una matriz cuyas filas han sido *escaladas* normalizándolas.

Los pasos del algoritmo sólo implican el intercambio de la segunda y tercera filas en una de las etapas, obteniendo el vector de permutaciones $p = (1, 3, 2)$, y las matrices

$$L = \begin{bmatrix} 1{,}0000 & 0{,}0000 & 0{,}0000 \\ 0{,}9000 & 1{,}0000 & 0{,}0000 \\ 0{,}6667 & -0{,}0000 & 1{,}0000 \end{bmatrix}$$

$$U = \begin{bmatrix} 30{,}0000 & 9{,}0000 & 77{,}0000 \\ 0{,}0000 & 2{,}9000 & 28{,}7000 \\ 0{,}0000 & 0{,}0000 & 28{,}6667 \end{bmatrix}$$

$$P = \begin{bmatrix} 1{,}0000 & 0{,}0000 & 0{,}0000 \\ 0{,}0000 & 0{,}0000 & 1{,}0000 \\ 0{,}0000 & 1{,}0000 & 0{,}0000 \end{bmatrix}$$

Finalmente

$$LU = PA = \begin{bmatrix} 30{,}0000 & 9{,}0000 & 77{,}0000 \\ 27{,}0000 & 11{,}0000 & 98{,}0000 \\ 20{,}0000 & 6{,}0000 & 80{,}0000 \end{bmatrix}.$$

8. Ejercicios

1. El siguiente ejercicio tiene como objetivo demostrar la desigualdad de Minkowsky

$$\|x + y\|_p \leq \|x\|_p + \|y\|_p,$$

donde $x = (x_1, \ldots, x_n), y = (y_1, \ldots, y_n) \in \mathbb{K}$, $p \geq 1$.

a) Sea $0 < \lambda < 1$. Definiendo

$$g(t) = \lambda t + (1 - \lambda) - t^\lambda,$$

demuestre que $g(t)$ posee un mínimo en $t = 1$. Concluya que $f(t) \geq 0$ para $t \geq 0$.

b) Usando el ítem anterior, demuestre que para $0 < \lambda < 1$ y $a, b > 0$, se tiene

$$a^\lambda b^{1-\lambda} \leq \lambda a + (1 - \lambda)b.$$

c) Sea $q \geq 1$ tal que

$$\frac{1}{p} + \frac{1}{q} = 1.$$

Para cada $1 \leq i \leq n$, defina

$$a = \frac{|x_i|^p}{\|x\|_p^p}, \quad b = \frac{|y_i|^q}{\|y\|_q^q}.$$

Usando la desigualdad anterior con $\lambda = 1/p$

$$\frac{|x_i|}{\|x\|_p} \cdot \frac{|y_i|}{\|y\|_q} \leq \frac{1}{p}\frac{|x_i|^p}{\|x\|_p^p} + \frac{1}{q}\frac{|y_i|^q}{\|x\|_q^q}.$$

y sumando, obtenga la desigualdad de Hölder:

$$\sum_{i=1}^{n} |x_i y_i| \leq \|x\|_p \|y\|_q.$$

d) A partir del hecho que

$$\|x+y\|_p^p \leq \sum_{i=1}^{n} |x_i||x_i+y_i|^{p-1} + \sum_{i=1}^{n} |y_i||x_i+y_i|^{p-1}$$

y con la desigualdad de Hölder, pruebe que

$$\|x+y\|_p^p \leq \|x\|_p \left(\sum_{i=1}^{n} |x_i+y_i|^{(p-1)q} \right)^{1/q} + \|y\|_p \left(\sum_{i=1}^{n} |x_i+y_i|^{(p-1)q} \right)^{1/q}.$$

e) Finalmente, pruebe la desigualdad de Minkowsky.

2. Demuestre que
$$\|A\|_2 \leq \|A\|_F \leq \sqrt{n}\|A\|$$
para toda matriz $A \in \mathbb{C}^{n\times n}$.
3. Caracterice las matrices $A \in \mathbb{R}^{n\times n}$ para las cuales $\|A^2\|_\infty = \|A\|_\infty^2$.
4. ¿Satisfacen las normas subordinadas matriciales la igualdad $\|AB\| = \|BA\|$? Justifique.
5. La norma ℓ_∞ ponderada es una norma en $\mathbb{R}^n$ dada por
$$\|x\| = \max_{1\leq i\leq n} w_i|x_i|,$$
donde $w_1, w_2, \ldots, w_n$ son números positivos prefijados, que reciben el nombre de *pesos*. Demuestre que esta función satisface la definición de norma. ¿Cuál es la norma matricial subordinada?
6. ¿Es necesariamente cierto, para cualquier norma matricial subordinada, que la norma de una matriz de permutación sea uno? Justifique su respuesta.
7. Demuestre que el número de condición $\text{cond}(A)$ se puede expresar mediante la fórmula
$$\text{cond}(A) = \sup_{\|x\|=\|y\|} \frac{\|Ax\|}{\|Ay\|}.$$
8. Dada la matriz
$$A = \begin{bmatrix} 3 & 4 & 5 \\ 5 & 2 & 6 \\ 1 & -54 & 3 \end{bmatrix},$$
calcular
   a) sus normas $\|A\|_1$, $\|A\|_2$,$\|A\|_\infty$, $\|A\|_F$;
   b) sus números de condición $\text{cond}_1(A)$, $\text{cond}_2(A)$, $\text{cond}_\infty(A)$, $\text{cond}_F(A)$;
   c) su factorización LU (con o sin cambios de filas).

   Sug.: `help norm`, `help cond`, `help lu`
9. Programe la resolución de un sistema triangular superior (inferior) no singular. *Sug.:* `help for`, `help sum`
10. Los elementos más grandes en magnitud en una matriz definida positiva aparecen sobre la diagonal y son positivos.
11. Una matriz $A = [a_{ij}]_{1\leq i,j\leq n} \in \mathbb{R}^{n\times n}$ es definida positiva, si y sólo si, los determinantes de las submatrices principales, llamados *menores principales*

$$\begin{vmatrix} a_{11} & a_{12} & \ldots & a_{1n} \\ a_{21} & a_{22} & & a_{2n} \\ \vdots & & \ddots & \vdots \\ a_{n1} & a_{n2} & & a_{nn} \end{vmatrix}$$

son números reales positivos.
Sug.: En la definición de definida positiva, considere $x = (x_1, \ldots, x_k, 0, \ldots, 0)^t$.

12. Si A es invertible y tiene una descomposición LU, entonces todos los menores principales de A son no singulares.
13. Sea $A \in \mathbb{R}^{n\times n}$ definida positiva. Supongamos que se puede realizar eliminación de Gauss sobre A sin cambios de filas. Luego de k pasos de eliminación, A será reducida a la forma

$$A^{(k)} = \begin{bmatrix} A_{11}^{(k)} & A_{12}^{(k)} \\ 0 & A_{22}^{(k)} \end{bmatrix},$$

donde $A_{22}^{(k)} \in \mathbb{R}^{(n-k)\times(n-k)}$. Pruebe por inducción que
   a) $A_{22}^{(k)}$ es definida positiva;
   b) $a_{ii}^{(k)} \leq a_{ii}^{(k-1)}$ para $k \leq i \leq n$, $k = 1, 2, \ldots, n-1$.
14. Una matriz $A = (a_{ij})$ en la que $a_{ij} = 0$ cuando $j > i$ o $j < i - 1$ se llama matriz de Stieltjes. Diseñe un algoritmo eficiente para invertir dicha matriz.
15. Si A es invertible y tiene una descomposición LU, entonces todos los menores principales de A son no principales.
16. Sabemos que si $Ax = b$ y $A\tilde{x} = \tilde{b}$ con $b \neq 0$, entonces

$$\frac{\|x - \tilde{x}\|}{\|x\|} \leq \text{cond}(A)\frac{\|b - \tilde{b}\|}{\|b\|}.$$

Demuestre que para toda matriz no singular A esta desigualdad se vuelve igualdad para algunos vectores b y $\tilde{b} \neq b$.
17. Demuestre que el número de condición $\text{cond}(A)$ puede expresarse mediante la fórmula

$$\text{cond}(A) = \sup_{\|x\|=\|y\|} \frac{\|Ax\|}{\|Ay\|}.$$

18. Demuestre que si existe un polinomio sin término constante $p(x)$, y que satisface

$$\big\|I - p(A)\big\| < 1$$

entonces A es invertible.
19. La eliminación gaussiana con pivoteo total trata tanto las filas como las columnas en un rden distinto del orden natural. Así, en el primer paso, el elemento pivote a_{ij} se elige de tal modo que $|a_{ij}|$ es el valor máximo de toda la matriz. Esto determina que la fila i sea la fila pivote y la columna j sea la columna pivote. Los ceros se producen en la columna j sustrayendo múltiplos de la fila i de las otras filas. Escriba el algoritmo que realiza este proceso. Serán necesarios dos vectores de permutación.
20. Resuelva el siguiente sistema por medio de la eliminación gaussiana con pivoteo total:

$$\begin{aligned} -9x_1 + x_2 + 17x_3 &= 5 \\ 3x_1 + 2x_2 - x_3 &= 9 \\ 6x_1 + 8x_2 + x_3 &= -3. \end{aligned}$$

21. Sabemos que si $Ax = b$ y $A\tilde{x} = \tilde{b}$ con $b \neq 0$, entonces

$$\frac{\|x - \tilde{x}\|}{\|x\|} \leq \text{cond}(A)\frac{\|b - \tilde{b}\|}{\|b\|}.$$

Demuestre que para toda matriz no singular A esta desigualdad se vuelve igualdad para algunos vectores b y $\tilde{b} \neq b$.

22. Si $A \in \mathbb{C}^{n\times n}$ es tal que
$$\rho(I - A^3 + 3A^2 + 5A) < 1,$$
entonces A es invertible.
23. Obtenga la factorización $A = QR$ de la matriz
$$A = \begin{bmatrix} -9 & 1 & 17 \\ 3 & 2 & -1 \\ 6 & 8 & 1 \end{bmatrix}$$
ya sea por el método de Householder o el de Givens. A continuación, resuelva $Ax = b$ donde $b = (44, 4, 25)^t$ con los resultados obtenidos.
24. Una matriz tiene *diagonal dominante* cuando
$$|a_{ii}| > \sum_{\substack{j=1 \\ j\neq i}}^{n} |a_{ij}|, \quad i = 1, \ldots, n.$$
Pruebe que todo sistema lineal con diagonal dominante puede ser resuelto con eliminación gaussiana sin pivoteo.

9. El teorema del punto fijo de Banach

DEFINICIÓN. *Sea $\|\cdot\|$ una norma en $\mathbb{R}^n$. La función $F : D \subset \mathbb{R}^n \to \mathbb{R}^n$ se dice que es continua en el sentido de Lipschitz en D, si existe una constante $L > 0$ tal que*
$$\|F(x) - F(y)\| \leq L\|x - y\|, \qquad \forall x, y \in D.$$
Si $L < 1$ se dice que F es una contracción en D con respecto a $\|\cdot\|$.

TEOREMA 3.20 (Teorema del punto fijo de Banach). *Sea $\|\cdot\|$ una norma en $\mathbb{R}^n$ y*
$F : D \subset \mathbb{R}^n \to \mathbb{R}^n$ con las siguientes propiedades:

1. *$\phi \neq D \subset \mathbb{R}^n$ es cerrado.*
2. *$F(D) \subset D$.*
3. *$\|F(x) - F(y)\| \leq L\|x - y\|, \qquad \forall x, y \in D, \qquad L \in (0, 1)$.*

Entonces:

(a) *La sucesión $\{x^{(k)}\}$ con $x^{(k+1)} := F(x^{(k)})$, $k = 0, 1, 2, \cdots$, converge para todo punto inicial $x^{(0)} \in D$ hacia $x^* \in D$ que es el único punto fijo de F en D.*

(b) $\|x^{(k)} - x^*\| \leq \dfrac{L^k}{1-L}\|x^{(1)} - x^{(0)}\|, \qquad k = 1, 2, \cdots$
(Estimación del error a priori).

(c) $\|x^{(k)} - x^*\| \leq \dfrac{L}{1-L}\|x^{(k)} - x^{(k-1)}\|, \qquad k = 1, 2, \cdots$
(Estimación del error a posteriori).

Demostración.

(a) Como $F(D) \subset D$ y $x^{(0)} \in D$ se cumple que $\{x^{(k)}\} \subset D$. Vamos a probar que $\{x^{(k)}\}$ es una sucesión de Cauchy, es decir, que para cada $\varepsilon > 0$, existe $N(\varepsilon) \in \mathbb{N}$ tal que
$$\|x^{(k)} - x^{(l)}\| < \varepsilon, \qquad \forall k, l \geq N(\varepsilon).$$
Como toda sucesión de Cauchy en $\mathbb{R}^n$ es convergente y siendo $D \subset \mathbb{R}^n$ cerrado, existe $x^* \in D$ como límite de $\{x^{(k)}\}$.

Para $p \in \mathbb{N}$, se cumple

$$\begin{aligned} \|x^{(p+1)} - x^{(p)}\| &= \|F(x^{(p)}) - F(x^{(p-1)})\| \\ &\leq L\|x^{(p)} - x^{(p-1)}\| \\ &\leq L^p\|x^{(1)} - x^{(0)}\| \end{aligned}$$

Para $l > k \geq 0$, se obtiene

$$\begin{aligned} \|x^{(l)} - x^{(k)}\| &\leq \sum_{i=1}^{l-k} \|x^{(k+i)} - x^{(k+i-1)}\| \\ &\leq \sum_{i=1}^{l-k} L^{k+i-1}\|x^{(1)} - x^{(0)}\| \\ &= L^k\left(\sum_{i=1}^{l-k} L^{i-1}\right)\|x^{(1)} - x^{(0)}\| \\ &\leq L^k\frac{1}{1-L}\|x^{(1)} - x^{(0)}\| = \frac{L^k}{1-L}\|x^{(1)} - x^{(0)}\|, \\ \|x^{(l)} - x^{(k)}\| &\leq \frac{L^k}{1-L}\|x^{(1)} - x^{(0)}\| \end{aligned}$$

pues $L < 1$. Por consiguiente, $\{x^{(k)}\}$ es una sucesión de Cauchy que converge hacia un $x^* \in D$. Siendo F continua en el sentido de Lipschitz se tiene que también es continua. Por consiguiente de $x^{(k)} \to x^*$ y $x^{(k+1)} = F(x^{(k)})$ se tiene que $x^* = F(x^*)$.

Unicidad: Supongamos que x^{**} es también un punto fijo de F, entonces:

$$\|x^* - x^{**}\| = \|F(x^*) - F(x^{**})\| \leq L\|x^* - x^{**}\|,$$

luego

$$(1-L)\|x^* - x^{**}\| \leq 0 \quad \Longrightarrow \quad x^* = x^{**} \qquad (\text{ pues } L < 1)$$

(b) A partir de la prueba de (a) se tiene

$$\|x^{(l)} - x^{(k)}\| \leq \frac{L^k}{1-L}\|x^{(1)} - x^{(0)}\|, \quad 0 \leq k \leq l$$

Para k fijo y $l \to +\infty$, se obtiene

$$\|x^{(k)} - x^*\| \leq \frac{L^k}{1-L}\|x^{(1)} - x^{(0)}\|, \quad k = 1, 2, \cdots$$

Nota: Esta inecuación permite "estimar."al inicio de una iteración el número de iteraciones necesarias para una cierta exactitud, conociendo $x^{(1)}$ y $x^{(0)}$ con $L < 1$.

(c) Sea $k \in \mathbb{N}$ fijo, $y^{(0)} := x^{(k-1)}$ y $y^{(1)} := F(y^{(0)})$. Se cumple que $y^{(1)} := F(x^{(k-1)}) = x^{(k)}$ y se obtiene

$$\begin{aligned} \|x^{(k)} - x^*\| &= \|y^{(1)} - x^*\| \leq \frac{L}{1-L}\|y^{(1)} - y^{(0)}\| \\ &= \frac{L}{1-L}\|x^{(k)} - x^{(k-1)}\|. \qquad \square \end{aligned}$$

10. Soluciones de sistemas de ecuaciones lineales por métodos iterativos

Supongamos que A es una matriz con los elementos diagonales distintos de cero, esto es, $a_{ii} \neq 0,\ i = 1, 2, \cdots, n$. El sistema lineal $Ax = b$ puede escribirse

como:

$$\begin{array}{ccccccccccc} a_{11}x_1 & + & a_{12}x_2 & + & a_{13}x_2 & + & \dots & + & a_{1n}x_n & = & b_1 \\ a_{21}x_1 & + & a_{22}x_2 & + & a_{23}x_2 & + & \dots & + & a_{2n}x_n & = & b_2 \\ & & & & & & \vdots & & & & \\ a_{n1}x_1 & + & a_{n2}x_2 & + & a_{n3}x_2 & + & \dots & + & a_{nn}x_n & = & b_n \end{array}$$

de donde:

$$\begin{array}{ccccccccccccccc} -a_{11}x_1 & = & & + & a_{12}x_2 & + & a_{13}x_3 & + & \cdots & & & + & a_{1n}x_n & - & b_1 & & \\ -a_{22}x_2 & = & a_{21}x_1 & + & & + & a_{23}x_3 & + & \cdots & & & + & a_{2n}x_n & - & b_2 & & \\ -a_{33}x_3 & = & a_{31}x_1 & + & a_{32}x_2 & + & & + & \cdots & & & + & a_{3n}x_n & - & b_3 & \dots & (*) \\ & & & + & & & & & & & \ddots & & & & & & \\ -a_{nn}x_n & = & a_{n1}x_1 & + & a_{n2}x_2 & + & \cdots & + & & + & \cdots & + & & - & b_n & & \end{array}$$

Dividiendo cada ecuación entre $-a_{ii}$, obtenemos

$$\begin{array}{c} x_1 = F_1(\overline{x}) \\ x_2 = F_2(\overline{x}) \\ \vdots \\ x_n = F_n(\overline{x}) \end{array}$$

o $\overline{x} = F(\overline{x})$, con $F : \mathbb{R}^n \to \mathbb{R}^n$, función a la cual se le puede aplicar el teorema 3.20 del punto fijo de Banach.
Definimos las matrices:

$$A_D = diag(a_{11}, a_{22}, \cdots, a_{nn}),$$

$$A_L = \begin{bmatrix} 0 & 0 & \dots & 0 \\ a_{21} & 0 & & \vdots \\ \vdots & & \ddots & \\ a_{n1} & \cdots & a_{n,n-1} & 0 \end{bmatrix} \quad \text{y} \quad A_D = \begin{bmatrix} 0 & a_{12} & \dots & a_{1n} \\ \vdots & & & \vdots \\ & 0 & \ddots & a_{n-1,n} \\ 0 & & \cdots & 0 \end{bmatrix}$$

y se cumple: $A = A_D + A_L + A_R$, de esto y de $(*)$ se obtiene:

$$-A_D x = (A_L + A_R)x - b$$

ó

$$\begin{array}{rl} x & = -A_D^{-1}(A_L + A_R)x + A_D^{-1}b \\ & = -A_D^{-1}(A - A_D)x + A_D^{-1}b \\ x & = (I - A_D^{-1}A)x + A_D^{-1}b =: F(x) \end{array}$$

De esto se obtiene el método de Jacobi (Método del paso entero):

$$\begin{array}{rl} x^{(j+1)} & = (I - A_D^{-1}A)x^{(j)} + A_D^{-1}b \\ & = A_D^{-1}b + A_D^{-1}(A_L + A_R)x^{(j)}, \qquad j = 1, 2, \cdots, n \end{array}$$

que escrito componente a componente:

$$x_i^{(j+1)} = \frac{1}{a_{ii}} \left[b_i - \sum_{\substack{k=1 \\ k \neq i}}^{n} a_{ik} x_k^{(j)} \right], \qquad i = 1, 2, \cdots, n, \quad a_{ii} \neq 0$$

Para la convergencia, según el teorema del punto fijo 3.20 de Banach se tiene que mostrar la existencia de $L \in \langle 0, 1 \rangle$ tal que

$$\|F(x) - F(y)\| \leq L\|x - y\|$$

con $F(x) = (I - A_D^{-1}A)x + A_D^{-1}b$ y como $F'(x) = I - A_D^{-1}A$, exigimos que

$$\|I - A_D^{-1}A\| < 1$$

Veamos el método de Gauss-Seidel:
Sabiendo que $(A_D + A_L + A_R)x = b$, tenemos que

$$(A_D + A_L)x = -A_R x + b$$

de donde

$$(A_D + A_L)x^{(j+1)} = -A_R x^{(j)} + b$$

lo cual puede escribirse como

$$A_D x^{(j+1)} = b - A_L x^{(j+1)} - A_R x^{(j)}$$

y en componentes:

$$a_{ii}x_i^{(j+1)} = b_i - \sum_{k=1}^{i-1} a_{ik}x_k^{(j+1)} - \sum_{k=i+1}^{n} a_{ik}x_k^{(j)}$$

despejando:

$$x_i^{(j+1)} = \frac{1}{a_{ii}}\left[b_i - \sum_{k=1}^{i-1} a_{ik}x_k^{(j+1)} - \sum_{k=i+1}^{n} a_{ik}x_k^{(j)}\right]$$

El método de Gauss-Seidel aprovecha para el cálculo de $x_i^{(j+1)}$ las componentes ya calculadas $x_1^{(j+1)}, \cdots, x_{i-1}^{(j+1)}$.

En general, la matriz A se descompone en la forma

$$A = B + (A - B), \quad B \in \mathbb{R}^{n\times n} \text{ regular}$$

Reemplazando en el sistema $Ax = b$ se obtiene

$$Bx = (B - A)x + B$$

ó

$$x = (I - B^{-1}A)x + B^{-1}b$$

Esto sugiere el método iterativo:

$$x^{(j+1)} = (I - B^{-1}A)x^{(j)} + B^{-1}b \qquad \ldots \qquad (1)$$

ó

$$Bx^{(j+1)} = (B - A)x^{(j)} + b \qquad \ldots \qquad (2)$$

Objetivo: Elegir B de manera que:

(a) Se pueda calcular fácilmente la sucesión $\{x^{(j)}\}$ y
(b) La sucesión $\{x^{(j)}\}$ converja rápidamente a la solución.
(c) La sucesión $\{x^{(j)}\}$ converja globalmente.

En la práctica no es necesario calcular B^{-1}, la ecuación (1) se usa para el análisis teórico.

TEOREMA 3.21. *Dado el sistema lineal $Ax = b$, $A \in \mathbb{C}^{n\times n}$ regular, $b \in \mathbb{C}^n$, aplicando el método iterativo*

$$Bx^{(j+1)} = (B - A)x^{(j)} + b,$$

donde $B \in \mathbb{C}^{n\times n}$ es regular, entonces se cumple:

(a) *La sucesión $\{x^{(j)}\}$ converge para cada valor inicial $x^{(0)} \in \mathbb{C}^n$ a la solución x^* de $Ax = b$, sí y sólo si $\rho(I - B^{-1}A) < 1$.*

(b) *Si* $L := \|I - B^{-1}A\| < 1$*, la sucesión* $\{x^{(j)}\}$ *converge para cada valor inicial* $x^{(0)} \in \mathbb{C}^n$ *a la solución* x^* *de* $Ax = b$.
Además se cumplen las siguientes estimaciones de error:

$$\|x^{(k)} - x^*\| \leq \frac{L^k}{1-L}\|x^{(1)} - x^{(0)}\|, \qquad k = 1, 2, \cdots$$

(Estimación del error a priori).

$$\|x^{(k)} - x^*\| \leq \frac{L}{1-L}\|x^{(k)} - x^{(k-1)}\|, \qquad k = 1, 2, \cdots$$

(Estimación del error a posteriori).

Demostración:

(a) Sea $\varepsilon^{(j)} := x^{(j)} - x^*$ el error de la i-ésima iteración. Entonces se obtiene:

$$\begin{aligned} \varepsilon^{(j+1)} &= x^{(j+1)} - x^* = B^{-1}(B - A)x^{(j)} + B^{-1}b - x^* \\ &= (I - B^{-1}A)x^{(j)} + B^{-1}Ax^* - x^* \\ &= (I - B^{-1}A)(x^{(j)} - x^*) \\ &= (I - B^{-1}A)\varepsilon^{(j)} \end{aligned}$$

($\Longrightarrow$) Sea λ el valor propio con el mayor módulo de $I - B^{-1}A$ y $\varepsilon^{(0)}$ un vector propio correspondiente. Entonces

$$(I - B^{-1}A)\varepsilon^{(0)} = \lambda\varepsilon^{(0)}$$

Elegimos el punto inicial $x^{(0)} := x^* + \varepsilon^{(0)}$ y se cumple

$$x^{(j+1)} - x^* = (I - B^{-1}A)^{j+1}\varepsilon^{(0)} = \lambda^{j+1}\varepsilon^{(0)}$$

Como $x^{(j+1)} \to x^*$, se obtiene $|\lambda| = \rho(I - B^{-1}A) < 1$, pues de otro modo se tendría que $x^{(j+1)} - x^* \not\to 0$.

($\Longleftarrow$) Eligiendo $\varepsilon > 0$ con $q := \rho(I - B^{-1}A) + \varepsilon < 1$, por el teorema 3.6 (pag. 27), existe una norma matricial $\|\cdot\|$ tal que

$$\|I - B^{-1}A\| < \rho(I - B^{-1}A) + \varepsilon = q < 1$$

Para cualquier $x^{(0)} \in \mathbb{C}^n$ se obtiene

$$\begin{aligned} \|x^{(j)} - x^*\| &= \|(I - B^{-1}A)^j(x^{(0)} - x^*)\| \\ &\leq \|I - B^{-1}A\|^j\|x^{(0)} - x^*\| \leq q^n\|x^{(0)} - x^*\| \end{aligned}$$

Como $q < 1$ se obtiene:

$$\lim_{j\to\infty} \|x^{(j)} - x^*\| = 0 \qquad \text{ó} \qquad \lim_{j\to\infty} x^{(j)} = x^*$$

(b) La función $F : \mathbb{C}^n \to \mathbb{C}^n$, $F(x) = (I - B^{-1}A)x + B^{-1}b$ cumple las condiciones del teorema del punto fijo de Banach 3.20. Las estimaciones corresponden a las estimaciones a priori y a posteriori del mismo teorema.

Nota: La velocidad de convergencia depende del radio espectral $\rho(I - B^{-1}A)$. Mientras más pequeño es el radio, más rápida es la velocidad de convergencia.

10.0.1. Relajación. Tiene como objetivo acelerar la convergencia de los métodos actuales. Introduciendo un *parámetro de relajación* del cual dependa la matriz iterativa se puede mejorar la rapidez de convergencia. Luego se tiene que determinar el parámetro de tal manera que el radio espectral resulte tan pequeño como sea posible.

Relajación del método de Jacobi.
Consideremos $w \neq 0, w \in \mathbb{R}$.

$$\begin{aligned} z_i^{(j+1)} &:= \frac{1}{a_{ii}}\left[b_i - \sum_{\substack{k=1 \\ k\neq i}}^{n} a_{ik}x_k^{(j)}\right] \\ x_i^{(j+1)} &:= (1 - w)x_i^{(j)} + wz_i^{(j+1)} \end{aligned}$$

Para $w = 1$, tenemos el método de Jacobi. La idea es minimizar

$$x^{(j+1)} - x^{(j)} = w(z^{(j+1)} - x^{(j)})$$

Matricialmente:

$$\begin{array}{rcl} z^{(j+1)} & := & -A_D^{-1}(A_L + A_R)x^{(j)} + A_D^{-1}b \\ x^{(j+1)} & := & (1-w)x^{(j)} + wz^{(j+1)} \\ & = & [(1-w)I - wA_D^{-1}(A_L + A_R)]x^{(j)} + wA_D^{-1}b \end{array}$$

Haciendo $B(w) := \dfrac{1}{w}A_D$ se obtiene

$$\begin{aligned} I - B(w)^{-1}A &= I - wA_D^{-1}(A_D + A_L + A_R) \\ &= (1-w)I - wA_D^{-1}(A_L + A_R) = J(w) \end{aligned}$$

En componentes:

$$x_i^{(j+1)} := (1-w)x_i^{(j)} + \frac{w}{a_{ii}}\left[b_i - \sum_{\substack{k=1 \\ k\neq i}}^{n} a_{ik}x_k^{(j)}\right]$$

Relajación del método de Gauss-Seidel (SOR-Successive OverRelaxation). Sea $w \neq 0$.

$$\begin{aligned} z_i^{(j+1)} &= \frac{1}{a_{ii}}\left[b_i - \sum_{k=1}^{i-1} a_{ik}x_k^{(j+1)} - \sum_{k=i+1}^{n} a_{ik}x_k^{(j)}\right] \\ x_i^{(j+1)} &:= (1-w)x_i^{(j)} + wz_i^{(j+1)} \qquad\qquad i = 1, 2, \cdots, n \end{aligned}$$

Para $w = 1$, se tiene el método de Gauss-Seidel. Matricialmente:

$$\begin{array}{rcl} A_D z^{(j+1)} & := & -A_L x^{(j+1)} - A_R x^{(j)} + b \\ x^{(j+1)} & := & (1-w)x^{(j)} + wz^{(j+1)} \end{array}$$

Luego:

$$\begin{aligned} &(A_D + wA_L)x^{(j+1)} = [(1-w)A_D - wA_R]x^{(j)} + wb \\ &x^{(j+1)} = (A_D + wA_L)^{-1}[(1-w)A_D - wA_R]x^{(j)} + w(A_D + wA_L)^{-1}b \end{aligned}$$

Definiendo

$$\begin{aligned} G(w) &:= (A_D + wA_L)^{-1}[(1-w)A_D - wA_R] \\ B(w) &:= \frac{1}{w}A_D + A_L \end{aligned}$$

se obtiene que $I - B(w)^{-1}A = G(w)$ (Ejercicio).
Por componentes:

$$x_i^{(j+1)} = \frac{w}{a_{ii}}\left[b_i - \sum_{k=1}^{i-1} a_{ik}x_k^{(j+1)} - \sum_{k=i+1}^{n} a_{ik}x_k^{(j)}\right], \qquad i = 1, 2, \cdots, n$$

Criterios para convergencia.

DEFINICIÓN. *Sea $A = (a_{ij}) \in \mathbb{C}^{n\times n}$.*

(a) *La matriz A satisface el criterio de la suma de filas, si*

$$\sum_{\substack{k=1 \\ k\neq i}}^{n} |a_{ik}| < |a_{ii}|, \qquad i = 1, 2, \cdots, n$$

(b) *La matriz A satisface el criterio débil de la suma de filas si*

$$\sum_{\substack{k=1 \\ k\neq i}}^{n} |a_{ik}| \begin{cases} \leq |a_{ii}|, & \text{para todo } i = 1, 2, \cdots, n \\ < |a_{ii}| & \text{para por lo menos un } i = i_0. \end{cases}$$

DEFINICIÓN. *Una matriz $A = (a_{ij}) \in \mathbb{C}^{n\times n}$ es denominada reducible si existen $N_1, N_2 \neq \phi$, $N_1, N_2 \subset N := \{1, 2, \cdots, n\}$ con $N_1 \cap N_2 = \phi$ y $N_1 \cup N_2 = N$ y $a_{ij} = 0$, $\forall (i, j) \in N_1 \times N_2$. Si A no es reducible se dice que es irreducible.*

Ejemplos:

(a)
$$A = \begin{bmatrix} 14 & 13 & 15 & 0 \\ 16 & 17 & 18 & 20 \\ 0 & 2 & 3 & 4 \\ 5 & 6 & 8 & 9 \end{bmatrix}$$
A es irreducible. Además, vemos que $|5|+|6|+|8| \not\leq 9$. Luego A no satisface el criterio débil ni el estricto de la suma de filas.

(b)
$$B = \begin{bmatrix} 4+3i & 1 & 1/2 \\ i & 5 & 3i \\ 4 & 5 & 100 \end{bmatrix} \qquad \begin{array}{l} |1| + |1/2| = 3/2 < |4+3i| = 5 \\ |i| + |3i| = 4 < |5| = 5 \\ |4| + |5| = 9 < |100| = 100 \end{array}$$
B satisface el criterio estricto de la suma de filas, luego también cumple el criterio débil de la suma de filas.

(c)
$$C = \begin{bmatrix} 3 & 4 & 5 & 56 \\ 0 & 9 & 10 & 0 \\ 0 & 8 & 11 & 0 \\ 6 & 7 & 12 & 13 \end{bmatrix}$$
Tenemos que $N_1 = \{2, 3\}$, $N_2 = \{1, 4\}$. Además $N_1 \cup N_2 = \{1, 2, 3, 4\}$,$N_1 \cap N_2 = \phi$ y $a_{21} = a_{31} = a_{24} = a_{34} = 0$. Por lo tanto C es reducible.

TEOREMA 3.22. *Sea $A = (a_{ij}) \in \mathbb{C}^{n\times n}$ y $J = -A_D^{-1}(A_L + A_R) = (I - A_D^{-1}A)$ la matriz iterativa de Jacobi con $A = A_D + A_L + A_R$.*

(a) *Si A cumple el criterio estricto, entonces $\|J\|_\infty < 1$ y las iteraciones de Jacobi convergen.*

(b) *Si A es irreducible y cumple el criterio débil, entonces $\rho(J) < 1$, y las iteraciones de Jacobi convergen.*

Demostración:

(a) Como A cumple el criterio estricto se tiene que $a_{ii} \neq 0$, $i = 1, 2, \cdots, n$. Entonces A_D^{-1} existe y $J = -A_D^{-1}(A_L + A_R)$ está bien definida. Luego:
$$\|J\|_\infty = \max\left(\sum_{\substack{k=1 \\ k\neq i}}^{n} \left|\frac{a_{ik}}{a_{ii}}\right|\right) = \max\left(\frac{1}{|a_{ii}|}\sum_{\substack{k=1 \\ k\neq i}}^{n} |a_{ik}|\right) < 1$$

(b) A es irreducible y cumple el criterio débil, entonces $a_{ii} \neq 0$ para $i = 1, 2, \cdots, n$. Supongamos que existe $i_0 \in N$ tal que $a_{i_0 i_0} = 0$. Sean
$$N_1 := \{i \in N \,/\, a_{ii} = 0\} \quad \text{y} \quad N_2 := \{i \in N \,/\, a_{ii} \neq 0\}$$
Luego se cumple que N_1 y N_2 son no vacíos, pues si $N_2 = \phi$ entonces el criterio débil no se cumpliría. Para $i \in N_1$ se cumple que $a_{ik} = 0, k = 1, 2, \cdots, n$ por el criterio débil. Entonces $a_{ik} = 0$ para $(i, k) \in N_1 \times N_2$, $N_1 \cap N_2 = \phi$ y $N_1 \cup N_2 = N$, lo cual contradice que A es irreducible, y por lo tanto $a_{ii} \neq 0$, $\forall i = 1, 2, \cdots, n$.
$$\rho(J) \leq \|J\|_\infty \leq \max_{1\leq i\leq n}\left(\frac{1}{|a_{ii}|}\sum_{\substack{k=1 \\ k\neq i}}^{n} |a_{ik}|\right) \geq 1$$

Supongamos que J tiene un valor propio λ con $|\lambda| = 1$. Sea x un valor propio correspondiente λ, con $\|x\|_\infty = 1$, de donde $J(x) = \lambda x$. Definimos

$$N_1 := \{i \in N : |x_i| = 1\}$$

entonces

$$|x_i| = |\lambda||x_i| = |\lambda x_i| = |(Jx)_i| = \frac{1}{|a_{ii}|}\left|\sum_{\substack{k=1\\k\neq i}}^{n} a_{ik}x_k\right| \leq \frac{1}{|a_{ii}|}\sum_{\substack{k=1\\k\neq i}}^{n}|a_{ik}| \leq 1$$

Luego, para todo $i \in N_1$, tenemos $|a_{ii}| = \sum_{k=1}^{n}|a_{ik}|$. $N_2 = N\setminus N_1 \neq \phi$, pues por el criterio débil existe al menos un $i_0 \in N$ tal que $|a_{i_0 i_0}| > \sum_{\substack{k=1\\k\neq i_0}}^{n}|a_{ik}|$.
Como A es irreducible, existe una pareja de índices $(i_0, j_0) \in N_1 \times N_2$ con $a_{i_0 j_0} \neq 0$. Entonces:

$$\begin{aligned}|\lambda| \quad &= 1 = |\lambda||x_0| = |(Jx)_{i_0}| \leq \frac{1}{|a_{i_0 i_0}|}\sum_{\substack{k=1\\k\neq i_0}}^{n}|a_{i_0 k}||x_k| \\ &< \frac{1}{|a_{i_0 i_0}|}\sum_{\substack{k=1\\k\neq i_0}}^{n}|a_{i_0 k}| \leq 1\end{aligned}$$

pues $|x_{j_0}| < 1,\ j_0 \in N_2$. Esto es una contradicción. Por tanto, no existe λ tal que $|\lambda| = 1$.

TEOREMA 3.23. *Si la matriz iterativa $J := A_D^{-1}(A_L + A_R)$ del método de Jacobi tiene solamente valores propios reales*

$$\lambda_1 \leq \lambda_2 \leq \cdots \leq \lambda_n \leq 1,$$

entonces el radio espectral de $J(w) = (1-w)I - wA_D^{-1}(A_L + A_R)$ es minimal para

$$w_{opt} := \frac{2}{2 - \lambda_1 - \lambda_n}$$

Demostración: Se cumple que la matriz $J(w)$ tiene valores propios $1-w+w\lambda_i$, con λ_i autovalor de J . Luego

$$\lambda_i' = 1 - w + w\lambda_i$$

Se tiene que probar que w_{opt} es solución del siguiente problema:

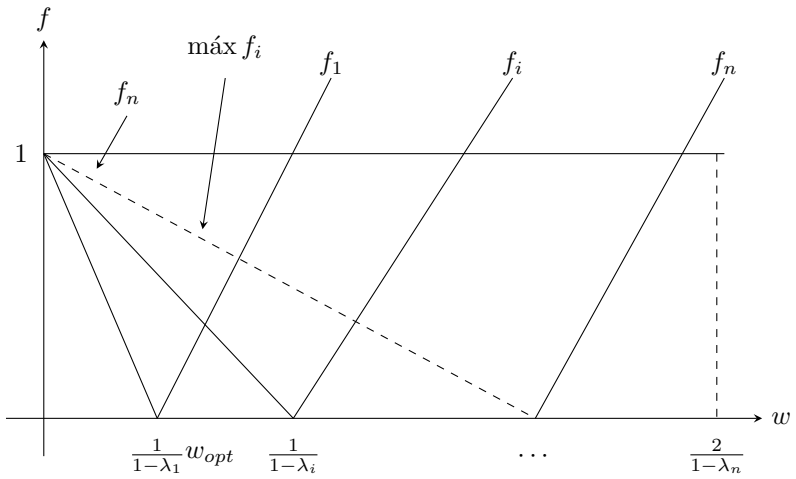
$$\text{mín}\left[\rho(J(w)) := \max_{i=1,\cdots,n}|1 - w + w\lambda_i|\right]$$

Definamos $f_i(w) := |1 - w + w\lambda_i|$, $i = 1, 2, \cdots, n$. Como $\lambda_1 \leq \lambda_2 \leq \cdots \leq \lambda_n \leq 1$, se cumple que

$$0 < \frac{1}{1-\lambda_1} \leq \frac{1}{1-\lambda_2} \leq \frac{1}{1-\lambda_3} \leq \cdots \leq \frac{1}{1-\lambda_n}$$

Tenemos que

$$\begin{aligned}&f_i(0) = 1, \quad i = 1, 2, \cdots, n \\ &f_i(\frac{1}{1-\lambda_i}) = \left|1 + (-1+\lambda_i)\frac{1}{1-\lambda_i}\right| = 0 \\ &f_i(\frac{2}{1-\lambda_i}) = \left|1 + (-1+\lambda_i)\frac{2}{1-\lambda_i}\right| = 1\end{aligned}$$



De este gráfico se aprecia que $\rho(J(w))$ toma su valor mínimo con $f_n(w_{opt}) = f_1(w_{opt})$, es decir

$$|1 - w_{opt} + w_{opt}\lambda_n| = |1 - w_{opt} + w_{opt}\lambda_1|$$

luego

$$1 - w_{opt} + w_{opt}\lambda_n = -1 + w_{opt} - w_{opt}\lambda_1$$

de donde

$$w_{opt} = \frac{2}{2 - \lambda_n - \lambda_1} \qquad \square$$

Ahora veamos la convergencia del método de Gauss-Seidel ($w = 1$) y el método SOR de manera conjunta.

TEOREMA 3.24. *Si los elementos diagonales de $A = (a_{ij}) \in \mathbb{C}^{n\times n}$ son distintos de cero, se cumple*

$$\rho(G(w)) \geq |w - 1|$$

donde:

$$G(w) := (A_D + wA_L)^{-1}[(1 - w)A_D - wA_R]$$

es la matriz iterativa del método SOR. Es decir, el método de SOR converge solamene si $w \in \langle 0, 2\rangle$.

Demostración:

$$\begin{aligned} G(w) &= (A_D + wA_L)^{-1}[(1 - w)A_D - wA_R] \\ &= (A_D + wA_L)^{-1}A_D[(1 - w)I - wA_D^{-1}A_R] \\ &= [A_D^{-1}(A_D + wA_L)]^{-1}[(1 - w)I - wA_D^{-1}A_L] \\ &= [I + wA_D^{-1}A_L]^{-1}[(1 - w)I - wA_D^{-1}A_R] \qquad \cdots \quad (*) \end{aligned}$$

Como la matriz $(I + wA_D^{-1}A_L)$ es triangular inferior con elementos en su diagonal iguales a 1, se tiene que $\det(I + wA_D^{-1}A_L) = 1$. Para el polinomio característico $P(\lambda)$ de $G(w)$ se cumple:

$$\begin{aligned} P(\lambda) &= \det(\lambda I - G(w)) \\ &= \det(I + wA_D^{-1}A_L)\det(\lambda I - G(w)) \\ &= \det(I + wA_D^{-1}A_L)(\lambda I - G(w)) \\ &= \det[(I + wA_D^{-1})\lambda I - ((1 - w)I + wA_D^{-1}A_R)] \quad [\text{por } (*)] \end{aligned}$$

Como $p(0)$ es igual al producto de los valores propios λ_i de $G(w)$, $i = 1, 2, \cdots, n$ se cumple

$$\prod_{i=1}^{n} \lambda_i = P(0) = \det[(w - 1)I + wA_D^{-1}A_R] = (w - 1)^n$$

pues A_R es diagonal superior con ceros en la diagonal, de donde $wA_D^{-1}A_R$ es diagonal superior con ceros en la diagonal. Luego:

$$|\lambda_{max}|^n \geq \prod_{i=1}^{n} |\lambda_i| = |w-1|^n$$

de donde finalmente:

$$\rho(G(w)) \geq |w-1|. \qquad \square$$

TEOREMA 3.25. *Si $A \in \mathbb{C}^{n\times n}$ cumple el criterio estricto, entonces $\|G(w)\|_\infty < 1$, $\forall w \in [0,1)$ y el método SOR converge para todos los valores iniciales.*

Demostración: Sea $x \in \mathbb{C}^n$ con $\|x\|_\infty = 1$ y $z := G(w)x$. Por $(*)$ se tiene:

$$(I + wA_D^{-1}A_L)z = [(1-w)I - wA_D^{-1}A_R]x.$$

Para las componentes se obtiene:

$$z_i = (1-w)x_i - \frac{w}{a_{ii}}\left[\sum_{k=1}^{i-1} a_{ik}z_k + \sum_{k=i+1}^{n} a_{ik}x_k\right]$$

$$|z_i| = (1-w) + \frac{w}{|a_{ii}|}\left[\sum_{k=1}^{i-1} |a_{ik}||z_k| + \sum_{k=i+1}^{n} |a_{ik}||x_k|\right], \quad i = 1,2,\cdots,n$$

En particular para $i = 1$:

$$\begin{aligned}
|z_1| &\leq (1-w) + \frac{w}{|a_{11}|}\left[\sum_{k=2}^{n} |a_{1k}|\right] \\
&\leq (1-w) + w\sum_{k=2}^{n} \frac{|a_{1k}|}{|a_{11}|} \\
&\leq (1-w) + w\left[\max_{j=1,2,\cdots,n} \sum_{\substack{k=1\\k\neq j}}^{n} \frac{|a_{jk}|}{|a_{jj}|}\right] \\
&= 1 - w + w\|J\|_\infty < 1 - w + w \\
&< 1
\end{aligned}$$

Esto es, $|z_1| < 1$. En general, $|z_i| < 1$, pues

$$\begin{aligned}
|z_2| &\leq (1-w) + \frac{w}{|a_{22}|}\left[|a_{21}||z_1| + \sum_{k=3}^{n} |a_{2k}|\right] \\
&\leq (1-w) + w\left[\max_{j=1,2,\cdots,n} \frac{1}{|a_{jj}|}\sum_{\substack{k=1\\k\neq j}}^{n} |a_{jk}|\right] \\
&< 1
\end{aligned}$$

Luego

$$\|G(w)\|_\infty = \sup_{\|x\|_\infty=1} \|G(w)x\|_\infty = \|z\|_\infty < 1 \qquad \square$$

TEOREMA 3.26. *Sea $A \in \mathbb{C}^{n\times n}$ hermitiana y definida positiva. Entonces el método SOR converge para todo $w \in \langle 0,2\rangle$, en especial el método de Gauss-Seidel en $w = 1$.*

Demostración: Vamos a probar que

$$\rho(G(w)) = \rho(I - B(w)^{-1}A) < 1, \qquad \forall w \in \langle 0,2\rangle.$$

Sea λ un valor propio de $G(w)$, $x \in \mathbb{C}^n$ un valor propio correspondiente.

$$[I - B(w)^{-1}A]x = \lambda x \qquad \Longleftrightarrow \qquad Ax = (1-\lambda)B(w)x \qquad \cdots \qquad (**)$$

Como A es definida positiva se cumple que $\det(A) \neq 0$ y por $(**)$ se concluye que $\lambda \neq 1$. De $(**)$,

$$\frac{Ax}{1-\lambda} = B(w)x \quad \Longrightarrow \quad \frac{x^*Ax}{1-\lambda} = x^*B(w)x$$
$$\frac{1}{1-\lambda} = \frac{x^*B(w)x}{x^*Ax}$$

Luego

$$2Re\left(\frac{1}{1-\lambda}\right) = 2Re\left(\frac{x^*B(w)x}{x^*Ax}\right) = \frac{x^*[B^*(w)+B(w)]x}{x^*Ax}$$

y como $B(w) = \dfrac{1}{w}A_D + A_L$, entonces

$$\begin{aligned} 2Re\left(\frac{1}{1-\lambda}\right) &= \frac{x^*[\frac{1}{w}A_D + A_L^* + \frac{1}{w}A_D + A_L]x}{x^*Ax} = \frac{x^*[\frac{1}{w}A_D + A_R + \frac{1}{w}A_D + A_L]x}{x^*Ax} \\ &= \left(\frac{2}{w}-1\right)\frac{x^*A_Dx}{x^*Ax} + \frac{x^*(A_R+A_D+A_L)x}{x^*Ax} \\ &= \left(\frac{2}{w}-1\right)\frac{x^*A_Dx}{x^*Ax} + 1 > 1 \end{aligned}$$

pues A_D también es definida positiva (y por tanto el primer término en la anterior expresión es positivo). Para $\lambda = \alpha + i\beta$ se obtiene

$$1 < 2Re\left(\frac{1}{1-\lambda}\right) = 2Re\left[\left(\frac{1}{1-\alpha-i\beta}\right)\cdot\left(\frac{1-\alpha+i\beta}{1-\alpha+i\beta}\right)\right] = \frac{2(2-\alpha)}{(1-\alpha)^2+\beta^2}$$

entonces

$$|\lambda^2| = |\alpha+i\beta|^2 = \alpha^2+\beta^2 < 1$$

pues $1-2\alpha+\alpha^2+\beta^2 < 2-2\alpha$. Por lo tanto

$$\rho(G(w)) < 1, \qquad \forall w \in \langle 0,1\rangle. \qquad \square$$

Capítulo 4

Sistemas de ecuaciones no lineales

1. Métodos unidimensionales

DEFINICIÓN (Raíz de una ecuación). *Sea $f : \mathbb{R} \to \mathbb{R}$. $\hat{x} \in \mathbb{R}$ es una raíz de f si $f(\hat{x}) = 0$.*

El problema que atacamos es el de resolver $f(x) = 0, \quad a \leq x \leq b$.
Para esto necesitamos algunos teoremas preliminares:

TEOREMA 4.1 (del valor intermedio). *Sea $f : \mathbb{R} \to \mathbb{R}$. Si $f \in C[a, b]$, $f(a) < f(b)$ y si $k \in \mathbb{R}$ es tal que $f(a) < k < f(b)$, entonces existe un punto $c \in (a, b)$ tal que $f(c) = k$.*

TEOREMA 4.2 (del cero). *Si $f \in C[a, b]$ y si $f(a)f(b) < 0$, entonces existe $c \in (a, b)$ tal que $f(c) = 0$.*

1.1. Algoritmo de la Bisección. Para revisar: otra alternativa al momento de calcular $x^{(j+1)}$ es:

$$x^{(j+1)} := a^{(j)} + \frac{(b^{(j)} - a^{(j)})}{2}$$

Queda como ejercicio comprobar que

$$|x^* - x^{(j+1)}| \leq |a^{(0)} - b^{(0)}|/2^{j+1}$$

1.2. Algoritmo Regula Falsi. Hipótesis: $f \in C^0[a, b]$, $f(a)f(b) < 0$. Es un algoritmo similar al anterior, la diferencia radica en que el cálculo de $x^{(j+1)}$ se hace con la ayuda de la recta secante a la gráfica:

La ecuación de la recta secante L_{sec}:

$$y - f(a^{(j)}) = \frac{f(b^{(j)}) - f(a^{(j)})}{b^{(j)} - a^{(j)}}(x - a^{(j)})$$

para $x = x^{(j+1)}$ se tiene que $y = 0$, luego

$$x^{(j+1)} = -f(a^{(j)})\frac{b^{(j)} - a^{(j)}}{f(b^{(j)}) - f(a^{(j)})} + a^{(j)}$$

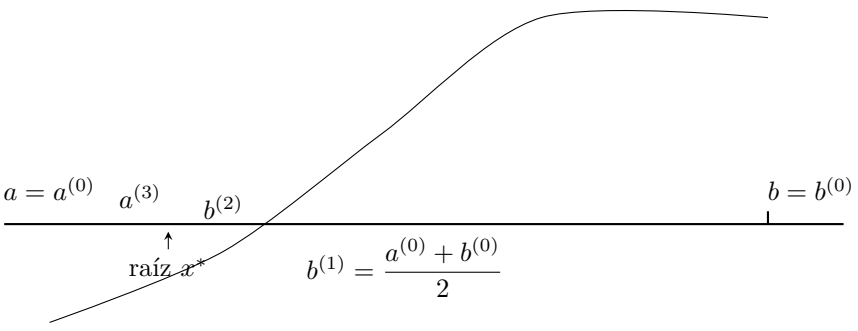


FIGURA 1. Método de la bisección

Algoritmo 8 Algoritmo de la bisección

Entrada: f continua sobre $[a^{(0)}, b^{(0)}]$, $f(a^{(0)})f(b^{(0)}) < 0$, $\varepsilon > 0$ (precisión)
1: Poner $j := 0$
2: Calcular $x^{(1)} := \frac{a^{(0)}+b^{(0)}}{2}$
3: **while** $|f(x^{(j+1)})| > \varepsilon$ **hacer**
4: **if** $f(a^{(j)})f(x^{(j+1)}) \leq 0$ **then**
5: $a^{(j+1)} := a^{(j)}$
6: $b^{(j+1)} := x^{(j)}$
7: **else**
8: $a^{(j+1)} := x^{(j)}$
9: $b^{(j+1)} := b^{(j)}$
10: **Fin if**
11: $j := j + 1$
12: Calcular $x^{(j+1)} := \frac{a^{(j)}+b^{(j)}}{2}$
13: **Fin while**
Salida: $x^{(j+1)}$ como aproximación para x^*, con $|x^* - x^{(j+1)}| \leq \frac{|a^{(0)}-b^{(0)}|}{2^{j+1}}$

de donde, simplificando:

$$x^{(j+1)} := \frac{a^{(j)}f(b^{(j)}) - b^{(j)}f(a^{(j)})}{f(b^{(j)}) - f(a^{(j)})}$$

Entonces tenemos el *Algoritmo Regula Falsi*:

Algoritmo 9 Algoritmo Regula Falsi

Entrada: f continua sobre $[a^{(0)}, b^{(0)}]$ y $f(a^{(0)})f(b^{(0)}) < 0$, $\varepsilon > 0$ (precisión)
1: Poner $j := 0$
2: Calcular $x^{(1)} := \frac{a^{(0)}f(b^{(0)})-b^{(0)}f(a^{(0)})}{f(b^{(0)})-f(a^{(0)})}$
3: **while** $|f(x^{(j+1)})| > \varepsilon$ **hacer**
4: **if** $f(a^{(j)})f(x^{(j+1)}) \leq 0$ **then**
5: $a^{(j+1)} := a^{(j)}$
6: $b^{(j+1)} := x^{(j+1)}$
7: **else**
8: $a^{(j+1)} := x^{(j+1)}$
9: $b^{(j+1)} := b^{(j)}$
10: **Fin if**
11: $j := j + 1$
12: Calcular $x^{(j+1)} := \frac{a^{(j)}f(b^{(j)})-b^{(j)}f(a^{(j)})}{f(b^{(j)})-f(a^{(j)})}$
13: **Fin while**
Salida: $x^{(j+1)}$ como aproximación de x^* con $f(x^*) = 0$

Nota: Aquí no es tan sencillo calcular la aproximación de $x^{(j+1)}$ a x^*. Si se desea una precisión adicional, se puede agregar una condición al algoritmo para la repetición del mismo (por ejemplo, poner $|f(x^{(j+1)})| > \varepsilon$ y $|x^* - x^{(j+1)}| \leq \frac{1}{2}10^{-n}$, donde n sería el número de cifras significativas deseadas).

1.3. Algoritmo Regula Falsi modificada. Este es un algoritmo de Regula Falsi Modificada, que es una mejora sobre el método de la falsa posición, para evitar el estancamiento en casos en los que una de las raíces no cambia de posición rápidamente.

Algoritmo 10 Algoritmo Regula Falsi Modificada

Entrada: f continua sobre $[a^{(0)}, b^{(0)}]$ y $f(a^{(0)})f(b^{(0)}) < 0$, $\varepsilon > 0$ (precisión)

Hacer $F := f(a^{(0)})$, $G := f(b^{(0)})$, $x^{(0)} := a^{(0)}$
Poner $j := 0$
Calcular $x^{(1)} := \frac{a^{(0)}G - b^{(0)}F}{G-F}$
while $|f(x^{(j+1)})| > \varepsilon$ **hacer**
    if $f(a^{(j)})f(x^{(j+1)}) \leq 0$ **then**
        $a^{(j+1)} := a^{(j)}$
        $b^{(j+1)} := x^{(j+1)}$
    else
        $a^{(j+1)} := x^{(j+1)}$
        $b^{(j+1)} := b^{(j)}$
    Fin if
    if $f(a^{(j)})f(x^{(j+1)}) \leq 0$ **then**
        $G := f(x^{(j+1)})$
    else
        $F := f(x^{(j+1)})$
    Fin if
    if $f(x^{(j)})f(x^{(j+1)}) > 0$ **then**
        if $f(a^{(j)})f(x^{(j+1)}) > 0$ **then**
            Hacer $F := F/2$
        else
            Hacer $G := G/2$
        Fin if
    Fin if
    $j := j + 1$
    Calcular $x^{(j+1)} := \frac{a^{(j)}G - b^{(j)}F}{G-F}$
Fin while

Salida: $x^{(j+1)}$ como aproximación de x^*

1.4. Método de las Secantes. De la figura, observamos que la pendiente de la recta secante es:

$$\frac{f(x^{(j)}) - 0}{x^{(j)} - x^{(j+1)}} = \frac{f(x^{(j)}) - f(x^{(j-1)})}{x^{(j)} - x^{(j-1)}}$$

de esto último tenemos:

$$x^{(j+1)} = x^{(j)} - f(x^{(j)}) \left(\frac{x^{(j)} - x^{(j-1)}}{f(x^{(j)}) - f(x^{(j-1)})} \right)$$

Algoritmo 11 Método de las Secantes

Entrada: $f \in C^0[x^{(0)}, x^{(1)}]$, $x^{(0)}$, $x^{(1)}$, $\varepsilon > 0$ (precisión)

Poner $j := 1$
repeat
    Calcular $x^{(j+1)} := x^{(j)} - f(x^{(j)}) \left(\frac{x^{(j)} - x^{(j-1)}}{f(x^{(j)}) - f(x^{(j-1)})} \right)$
    Incrementar $j := j + 1$
until $|f(x^{(j+1)})| \leq \varepsilon$

Salida: $x^{(j+1)}$ como aproximación para x^*

1.5. Método de Newton. La pendiente de la recta tangente L_t a la gráfica de f es:

$$m_t : f'(x^{(j)}) = \frac{0 - f(x^{(j)})}{x^{(j+1)} - x^{(j)}}$$

entonces

$$x^{(j+1)} := x^{(j)} - \frac{f(x^{(j)})}{f'(x^{(j)})}, \qquad j = 0, 1, 2, \ldots,$$

dado $x^{(0)}$: punto inicial, que debe ser bien escogido.

Algoritmo 12 Método de Newton

Entrada: f continua y derivable, $f'(x)$, $x^{(0)}$ (punto inicial bien escogido), $\varepsilon > 0$ (precisión)

1: Poner $j := 0$
2: **repeat**
3: Calcular $x^{(j+1)} := x^{(j)} - \frac{f(x^{(j)})}{f'(x^{(j)})}$
4: Incrementar $j := j + 1$
5: **until** $|f(x^{(j+1)})| \leq \varepsilon$

Salida: $x^{(j+1)}$ como aproximación para x^*

1.6. Métodos simplificado y modificado de Newton.

1.6.1. Método simplificado de Newton.

$$x^{(j+1)} := x^{(j)} - \frac{f(x^{(j)})}{f'(\hat{\mathrm{x}}^{(0)})}$$

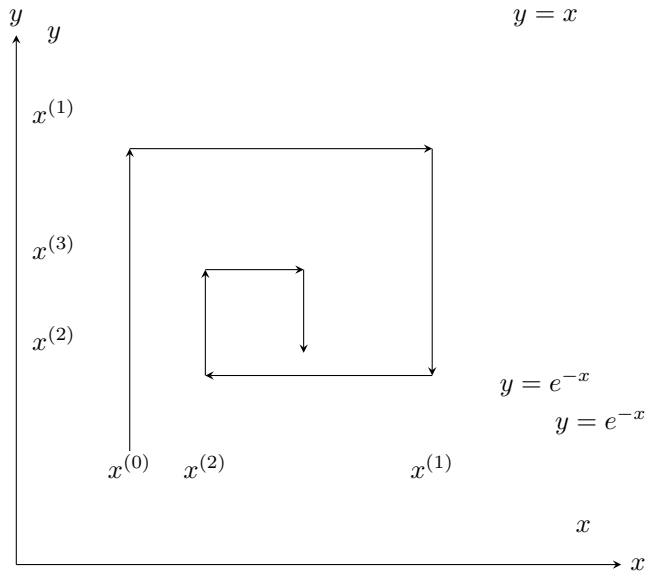
donde $f'(\hat{\mathrm{x}}^{(0)})$ se actualiza después de un número determinado de pasos. Este método es más lento.
La ventaja de este método es que no se requiere calcular la derivada de la función en todos los pasos, lo cual es numéricamente costoso.

1.6.2. Método modificado de Newton. Resulta de modificar la pendiente original. La iteración es:

$$x^{(j+1)} := x^{(j)} - m\frac{f(x^{(j)})}{f'(x^{(j)})}$$

donde m es un parámetro que puede, bien usado, evitar la divergencia del método sin él.

1.7. Método del Punto Fijo. Recordemos que nuestro problema inicial era el de resolver $f(x) = 0$.
A veces este problema se puede cambiar a un problema de punto fijo, $F(x) = x$ y se construye una sucesión $\{x^{(k)}\}$ que se inicia en $x^{(0)}$ y luego $x^{(k+1)} := F(x^{(k)})$.
Ejemplo: Resolver $f(x) = x + \ln x = 0$. Podemos resolver equivalentemente $F(x) = e^{-x} = x$.
Construímos la sucesión $x^{(k+1)} := e^{-x^{(k)}}$. Luego:



2. Teoremas de convergencia

Problema: Resolver el sistema de ecuaciones no lineales

$$\begin{array}{l} f_1(x_1, x_2, \cdots, x_n) = 0 \\ f_2(x_1, x_2, \cdots, x_n) = 0 \\ \qquad \vdots \\ f_n(x_1, x_2, \cdots, x_n) = 0 \end{array} \qquad \text{ó} \qquad f(\overline{x}) = \overline{0}.$$

Recordemos que muchas veces se cambia este problema a un problema de punto fijo de la forma $F(x) = x$ y se construye una sucesión $\{x^{(k)}\}$ que se inicia en $x^{(0)}$ y luego $x^{(k+1)} := F(x^{(k)})$.

Esto nos permitirá aplicar el teorema del punto fijo de Banach, teorema 3.20.

TEOREMA 4.3. *Sea $\|\cdot\|$ una norma en $\mathbb{R}^n$ y $F : \mathbb{R}^n \to \mathbb{R}^n$ una función tal que*

1. $\|F(x) - F(y)\| \leq L\|x - y\|, \quad \forall x, y \in B[x^{(0)}; r] = \{x \in \mathbb{R}^n / \|x - x^{(0)}\| \leq r\}$.
2. $\|F(x^{(0)}) - x^{(0)}\| \leq (1 - L)r$.

Entonces la sucesión $\{x^{(k)}\}$ dada por $x^{(k+1)} := F(x^{(k)})$, satisface:

(a) $\{x^{(k)}\} \subset B[x^{(0)}; r]$.

(b) *F tiene en $B[x^{(0)}; r]$ un punto fijo x^* único con $\lim_{k\to\infty} x^{(k)} = x^*$ y con las estimaciones a priori y a posteriori.*

Demostración: Es suficiente verificar las hipótesis del teorema del punto fijo de Banach con $D := B[x^{(0)}; r]$.
Como $D = B[x^{(0)}; r] \subset \mathbb{R}^n$ es cerrado y por la hipótesis (1); se cumplen la primera y tercera hipótesis del teorema del punto fijo de Banach. Solamente hay que probar que también se cumple la segunda hipótesis, es decir, que $F(D) \subset D$. Sea $x \in D = B[x^{(0)}; r]$, entonces se cumple

$$\begin{array}{rcl} \|F(x) - x^{(0)}\| & \leq & \|F(x) - F(x^{(0)})\| + \|F(x^{(0)}) - x^{(0)}\| \\ & \leq & L\|x - x^{(0)}\| + (1 - L)r \\ & \leq & L\, r + (1 - L)\, r = r \end{array}$$

esto es, $\|F(x) - x^{(0)}\| \leq r$, de donde $F(x) \in B[x^{(0)}; r]$. Por lo tanto $F(D) \subset D$. □

LEMA 4.4. *Sea $F \in C^1[a,b]$. Entonces F es continua sobre $[a,b]$ en el sentido de Lipschitz con $L := \max_{\xi\in[a,b]} |F'(\xi)|$.*

Demostración: Sean $x, y \in [a,b]$. Por el teorema del valor medio, existe ξ perteneciente al intervalo abierto con extremos x e y, tal que $F(x)-F(y) = F'(\xi)(x-y)$, entonces

$$|F(x) - F(y)| = |F'(\xi)||x-y| \leq \max_{\xi\in[a,b]} |F'(\xi)||x-y|, \qquad \forall x, y \in [a,b]. \square$$

LEMA 4.5. *Sea $g : [a,b] \to \mathbb{R}^n$ continua y $\|\cdot\|$ una norma en $\mathbb{R}^n$. Entonces*

$$\left\| \int_a^b g(t)dt \right\| \leq \int_a^b \|g(t)\| dt.$$

TEOREMA 4.6. *Sea $\phi \neq D \subset \mathbb{R}^n$ convexo, $U \subset \mathbb{R}^n$ abierto con $D \subset U$ y $F : U \to \mathbb{R}^n$ continuamente diferenciable. Para cualquier norma $\|\cdot\|$ de $\mathbb{R}^n$ se cumple*

$$\|F(x) - F(y)\| \leq \left(\sup_{\xi\in D} \|F'(\xi)\| \right) \|x-y\|, \qquad \forall x, y \in D.$$

Si D es compacto y las derivadas parciales son acotadas, entonces F es continua en el sentido de Lipschitz en D con constante

$$L := \sup_{\xi\in D} \|F'(\xi)\|.$$

Demostración: Se cumple que

$$\int_0^1 F'(x + t(y-x))(y-x)dt = F(y) - F(x).$$

De esto y usando el lema anterior se obtiene

$$\begin{aligned} \|F(y) - F(x)\| &= \left\| \int_0^1 F'(x + t(y-x))(y-x)dt \right\| \\ &\leq \int_0^1 \|F'(x + t(y-x))\| \, \|y-x\| dt \\ &\leq \sup_{\lambda\in[0,1]} \|F'(x + \lambda(y-x))\| \, \|y-x\|, \qquad \forall x, y \in D. \qquad \square \end{aligned}$$

Ejemplo: Consideremos el siguiente sistema no lineal:

$$\begin{aligned} x_1 &= 0{,}1x_1^2 + \sin x_2 \\ x_2 &= \cos x_1 + 0{,}1x_2^2 \end{aligned}$$

Entonces $F : \mathbb{R}^2 \to \mathbb{R}^2$ está definida por:

$$F(x) = F(x_1, x_2) = \begin{bmatrix} 0{,}1x_1^2 + \sin x_2 \\ \cos x_1 + 0{,}1x_2^2 \end{bmatrix} = \begin{bmatrix} f_1(x_1, x_2) \\ f_2(x_1, x_2) \end{bmatrix}.$$

Para $D := \{(x_1, x_2) \in \mathbb{R}^2 / \quad 0{,}75 \leq x_1 \leq 0{,}78, \quad 0{,}77 \leq x_2 \leq 0{,}80\}$ se cumple que $F(D) \subset D$. Además:

$$F'(x_1, x_2) = \begin{bmatrix} 0{,}2x_1 & \cos x_2 \\ -\sin x_1 & 0{,}2x_2 \end{bmatrix}$$

Eligiendo una norma:

$$\begin{aligned} &\sup_{\xi\in D} \|F'(\xi)\|_\infty \leq 0{,}74 \\ &\sup_{\xi\in D} \|F'(\xi)\|_1 < 0{,}878 \\ &\sup_{\xi\in D} \|F'(\xi)\|_F \leq 1{,}030, \end{aligned}$$

En este caso la velocidad de convergencia es lenta, porque la constante de Lipschitz es grande.
Analizando los valores propios de $F'(x^*)$, vemos que

$$\rho(F'(x^*)) \leq \|F'(x^*)\| \leq \sup_{\xi \in D} \|F'(\xi)\|$$

De esto se tiene que si $\rho(F'(x^*))$ no es pequeño, la velocidad de convergencia es lenta.

Convergencia local.

TEOREMA 4.7. *Sea x^* un punto fijo de $F : \mathbb{R}^n \to \mathbb{R}$ donde F es de clase C^1 en una vecindad de x^*. Si se cumple que $\rho(F'(x^*)) < 1$, entonces existe una vecindad $U(x^*)$ de x^* tal que la sucesión $\{x^{(k)}\}$ definida por $x^{(k+1)} := F(x^{(k)})$ converge a x^* para todo punto inicial $x^{(0)} \in U(x^*)$.*

Nota: Esto implica que las iteraciones del punto fijo tienen *convergencia local*.

DEFINICIÓN. *Sea $\{x^{(k)}\} \subset \mathbb{R}^n$ una sucesión que converge a $x^* \in \mathbb{R}$ con $x^{(k)} \neq x^*, \forall k \in \mathbb{N}$ y sea $\|\cdot\|$ una norma en $\mathbb{R}^n$:*

1. *Para $p \geq 1$ decimos que $\{x^{(k)}\}$ converge a x^* con por lo menos orden de convergencia p, si existe una constante $C > 0$ (para $p = 1, C \in \langle 0, 1\rangle$) y $n_0 \in \mathbb{N}$ tal que*

$$\|x^{(k+1)} - x^*\| \leq C\|x^{(k)} - x^*\|^p, \quad \forall k \geq n_0$$

2. *Si $\lim_{k\to\infty} \dfrac{\|x^{(k+1)} - x^*\|}{\|x^{(k)} - x^*\|} = 0$ se dice que $\{x^{(k)}\}$ converge a x^* de manera superlineal.*

Ejercicio: Probar que las iteraciones del método de las secantes tienen orden de convergencia igual a 1,6.

2.0.1. Método de Newton en $\mathbb{R}^n$. Para $f : \mathbb{R} \to \mathbb{R}$:

$$x^{(k+1)} := x^{(k)} - \frac{f(x^{(k)})}{f'(x^{(k)})}$$

Para $f : \mathbb{R}^n \to \mathbb{R}^n$:

$$x^{(k+1)} := x^{(k)} - \left[f'(x^{(k)})\right]^{-1} \cdot f(x^{(k)})$$

donde $f'(x^{(k)})$ es la matriz jacobiana.

Para obtener una iteración, resolvemos el sistema lineal

$$f'(x^{(k)})\,\overline{d} = f(x^{(k)}),$$

obteniendo $\overline{d}$ y luego hacemos $x^{(k+1)} := x^{(k)} - \overline{d}$.

TEOREMA 4.8. *Sea $f : \mathbb{R}^n \to \mathbb{R}^n$, y x^* un cero de f. Supongamos que se cumplen las condiciones:*

1. *f es de clase C^1 en una vecindad de x^*.*
2. *$f(x^*) \in \mathbb{R}^{n\times n}$ es regular.*

Entonces existe $\delta > 0$ tal que la sucesión $\{x^{(k)}\}$ del método de Newton está definida para todo $x^{(0)} \in B[x^*, \delta] := \{x \in \mathbb{R}^n / \|x - x^*\| \leq \delta\}$, y converge de manera superlineal a x^*.

3. *Supongamos además que se cumpla la condición de Lipschitz para f' en una vecindad bastante pequeña de x^*; es decir, si además existen $\eta > 0$ y $L > 0$ tales que*

$$\|f'(x) - f'(x^*)\| \leq L\|x - x^*\|, \quad \text{siempre que} \quad \|x - x^*\| \leq \eta$$

entonces $\{x^{(k)}\}$ converge a x^*, por lo menos cuadráticamente (orden 2).

Demostración: Se puede elegir un $\delta_1 > 0$ tan pequeño de modo que f' existe en $B[x^*, \delta_1]$ y

$$\|f'(x) - f'(x^*)\| \leq \frac{1}{2\|f'(x^*)^{-1}\|}, \qquad \forall x \in B[x^*, \delta_1] \qquad \ldots \qquad (*)$$

Para todo $x \in B[x^*, \delta_1]$, se cumple:

(a) $f'(x)$ es regular y $\|f'(x)^{-1}\| \leq 2\|f'(x^*)^{-1}\|$. De $(*)$, tenemos que

$$\|f'(x^*)^{-1}\|\|f'(x) - f'(x^*)\| \leq \frac{1}{2} < 1.$$

En el lema de perturbación 3.14 (pág. 36) con $A := f'(x^*)$ que es regular y $S := [f'(x) - f'(x^*)]$, se obtiene que $A + S = f'(x)$ es regular y

$$\|f'(x)^{-1}\| \leq \frac{\|f'(x^*)^{-1}\|}{1 - \|f'(x^*)^{-1}\|\|f'(x) - f'(x^*)\|}$$

Por tanto (Ejercicio)

$$\|f'(x)^{-1}\| \leq 2\|f'(x^*)^{-1}\|.$$

(b) Se cumple:

$$\|f'(x)^{-1} - f'(x^*)^{-1}\| \leq 2\|f'(x^*)^{-1}\|^2\|f'(x) - f'(x^*)\|$$

Esto se obtiene de lo sgte:

$$f'(x)^{-1} - f'(x^*)^{-1} = -f'(x)^{-1}[f'(x) - f'(x^*)]f'(x^*)^{-1}$$

Aplicando (a):

$$\begin{aligned} \|f'(x)^{-1} - f'(x^*)^{-1}\| &\leq \|f'(x)^{-1}\|\|f'(x) - f'(x^*)\|\|f'(x^*)^{-1}\| \\ &\leq 2\|f'(x^*)^{-1}\|^2\|f'(x) - f'(x^*)\|.\square \end{aligned}$$

Sea $F : B[x^*, \delta_1] \subset \mathbb{R}^n \to \mathbb{R}^n$ la función iterativa del método de Newton $x^{(k+1)} := F(x^{(k)})$ con $F(x) = x - f'(x)^{-1}f(x)$. Vamos a probar que la sucesión $x^{(k+1)} := F(x^{(k)})$ no sale de $B[x^*, \delta_1]$:

$$\begin{aligned} F(x) - x^* &= x - x^* - f'(x)^{-1}[f(x) - f(x^*)] \\ &= [f'(x^*)^{-1} - f'(x)^{-1}]f'(x^*)(x - x^*) - f'(x^*)^{-1}[f(x) - f(x^*) - f'(x^*)(x - x^*)] \\ &= [f'(x^*) - f'(x)^{-1}]f'(x^*)(x - x^*) - f'(x^*)^{-1}\int_0^1 [F'(x^* + t(x - x^*)) - F'(x^*)] \cdot (x - x^*)dt \end{aligned}$$

luego

$$\|F(x)-x^*\| \leq \{\|f'(x^*)-f'(x)^{-1}\|\|f'(x^*)\|+\|f'(x^*)^{-1}\|\int_0^1 \|F'(x^*+t(x-x^*))-F'(x^*)\|dt\}\|x-x^*\| \ldots (**)$$

Si hacemos $\varepsilon(x) := \|f'(x^*) - f'(x)^{-1}\|\|f'(x^*)\| + \|f'(x^*)^{-1}\|\int_0^1 \|F'(x^* + t(x - x^*)) - F'(x^*)\|dt$ en la última expresión, entonces

$$\|F(x) - x^*\| \leq \varepsilon(x)\|x - x^*\|$$

Aplicando (b):

$$\begin{aligned} \varepsilon(x) &\leq 2\|f'(x^*)^{-1}\|^2\|f'(x) - f'(x^*)\|\|f'(x^*)\| + \|f'(x)^{-1}\|\int_0^1 \|f'(x^* + t(x - x^*)) - f'(x^*)\|dt \\ &\leq 2\|f'(x^*)^{-1}\|\left\{\|f'(x^*)\|\|f'(x^*)^{-1}\|\|f'(x) - f'(x^*)\| + \int_0^1 \|f'(x^* + t(x - x^*)) - f'(x^*)\|dt\right\} \end{aligned}$$

por (a). Por la continuidad de f' en $B[x^*, \delta_1]$ y la existencia de $\delta \in [0, \delta_1]$ tal que:

$$\|F(x) - F(x^*)\| = \|F(x) - x^*\| \leq \frac{1}{2}\|x - x^*\|, \quad \forall x \in B[x^*, \delta]$$

se tiene convergencia superlineal,

$$\|x^{(k+1)} - x^*\| \leq \varepsilon(x^{(k)})\ \|x^{(k)} - x^*\| \quad \dots \quad (\alpha)$$

pues $\lim\limits_{k\to\infty} \dfrac{\|x^{(k+1)} - x^*\|}{\|x^{(k)} - x^*\|} = 0$, lo cual es cierto pues $\lim\limits_{k\to\infty} \varepsilon(x^{(k)}) = 0$.
De la condición de Lipschitz

$$\begin{aligned}\varepsilon(x^{(k)}) &\leq 2\|f'(x^*)^{-1}\| \left\{ \|f'(x)\|\|f'(x^*)^{-1}\|\|f'(x^{(k)}) - f'(x^*)\| + \textstyle\int_0^1 \|f'(x^* + t(x - x^*)) - f'(x^*)\| dt \right\} \\ &\leq 2\ L\|f'(x^*)^{-1}\| \left\{ \|f'(x^*)\|\|f'(x^*)^{-1}\| + \frac{1}{2} \right\} \|x^{(k)} - x^*\|\end{aligned}$$

por (3). Haciendo $G := 2\ L\|f'(x^*)^{-1}\| \left\{ \|f'(x^*)\|\|f'(x^*)^{-1}\| + \dfrac{1}{2} \right\}$ y reemplazando en (α), tenemos que

$$\|x^{(k+1)} - x^*\| \leq G\ \|x^{(k)} - x^*\|^2. \quad \square$$

La ventaja del método de Newton es que, en caso de convergencia, la convergencia es rápida (al menos de orden 2). Las desventajas principales son : la convergencia es lineal; además, en cada paso se tiene que solucionar un sistema lineal.
Problema: Encontrar un método para obtener convergencia global (esto es, que converja para todo $x^{(0)} \in \mathbb{R}^n$ inicial).

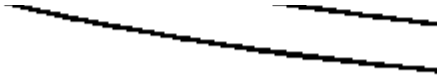


FIGURA 2. Movimiento en direcciones descendentes

3. Métodos de Minimización

Hemos visto que en el caso de que el método de Newton converja, la velocidad de convergencia es muy rápida. Sin embargo, según el teorema 4.8 no hay ninguna garantía para la convergencia. Luego se tiene que buscar otros métodos. Una idea es cambiar el problema de solucionar un sistema de ecuaciones no lineales es un problema de minimización

$$\begin{aligned} (P): &\qquad \text{Buscar } x^* \ / \ f(x^*) = 0, \quad f : \mathbb{R}^n \to \mathbb{R}^n \\ (M): &\qquad \text{Minimizar } h(x) := \|f(x)\|_2^2 = \sum_{i=1}^{n} [f_i(x)]^2 \end{aligned}$$

El siguiente lema muestra que los problemas (P) y (M) son equivalentes:

LEMA 4.9. *Si* $\det(f'(x^*)) \neq 0$, *entonces se cumple:*

$$f(x^*) = 0 \quad \Longleftrightarrow \quad 0 = h(x^*) \leq h(x), \quad \forall x \in \mathbb{R}^n \quad \Longleftrightarrow \quad \nabla h(x^*) = 0$$

Demostración:

($\Longrightarrow$) $f(x^*) = 0$ implica $f_i(x^*) = 0, \quad i = 1, 2, \ldots, n$. De esto $h(x^*) = 0 \leq h(x), \quad \forall x \in \mathbb{R}^n \quad \Longrightarrow \quad \nabla h(x^*) = 0$.

($\Longleftarrow$) Si $0 = \nabla h(x^*)$ entonces

$$0 = \nabla h(x^*) = \nabla \left(\sum_{i=1}^{n} [f_i]^2(x^*) \right) = 2 \sum_{i=1}^{n} \nabla f_i(x^*) \ f_i(x^*) = 2 \ f'(x^*)^t f(x^*)$$

lo cual implica $f'(x^*)^t f(x^*) = 0$. Como $\det(f'(x^*)^t) \neq 0$ se obtiene $f(x^*) = 0$.

También se cumple $h(x^*) = 0 \leq h(x), \quad \forall x \in \mathbb{R}^n$. □

DEFINICIÓN. *Sea* $h : \mathbb{R}^n \to \mathbb{R}$. *Se dice que* $p \in \mathbb{R}^n$ *es una dirección descendente para* h *en* $x \in \mathbb{R}^n$ *si existe* $t_0 > 0$ *tal que*

$$h(x + tp) < h(x), \quad \forall t \in \langle 0, t_0]$$

LEMA 4.10. *Sea* $h : \mathbb{R}^n \to \mathbb{R}$ *continuamente diferenciable. Entonces* $p \in \mathbb{R}^n$ *es una dirección descendente si* $\nabla h(x)^t p < 0$.

Demostración:

$$\lim_{t \to 0^+} \frac{h(x + tp) - h(x)}{t} = \nabla h(x)^t p$$

implica $h(x + tp) - h(x) < 0$ para $0 \leq t$ bastante pequeño ó $h(x + tp) < h(x)$. □

Estando en $x^{(k)}$, si encontramos una dirección descendente $p^{(k)} \in \mathbb{R}^n$ y definimos

$$x^{(k+1)} := x^{(k)} + t_k p^{(k)}$$

para t_k bastante pequeño, nos vamos acercando al mínimo de la función, lo cual implicaría que nos estamos acercando a la raíz de (P) .

Según esta idea se obtienen los siguientes métodos:

1. *Método modificado de Newton*:

$$x^{(k+1)} := x^{(k)} - t_k f'(x^{(k)})^{-1} f(x^{(k)}), \quad k = 0, 1, 2, \ldots$$

$t_k \in [0, 1]$, $t_k := 2^{-j}$ con j como el entero no negativo más pequeño tal que

$$h(x^{(k)}) - h(x^{(k)} + 2^{-j} p^{(k)}) > 0$$

y $p^{(k)} := -f'(x^{(k)})^{-1} f(x^{(k)})$ que es una dirección descendente. En efecto:

$$\begin{aligned} \nabla h(x^{(k)})^t p^{(k)} &= (2 f(x^{(k)})^t f'(x^{(k)}))(-f'(x^{(k)})^{-1} f(x^{(k)})) \\ &= -2 f(x^{(k)})^t \; I \; f(x^{(k)}) = -2\|f(x^{(k)})\|_2^2 < 0 \end{aligned}$$

Con este método se obtiene un radio de convergencia más grande que en el método de Newton. Si $x^{(k)}$ está bastante cercano a la solución, se puede mostrar que $(*)$ se cumple para $j = 0$, $t_k = 1$, lo que da una iteración del método de Newton. Luego el orden de convergencia es también 2.

2. *Método del descenso más rápido*:

$$x^{(k+1)} := x^{(k)} - t_k \nabla h(x^{(k)}).$$

Aquí $p^{(k)} = -\nabla h(x^{(k)})$ que es una dirección descendente, pues

$$\nabla h(x^{(k)})^t p(x^{(k)}) = \nabla h(x^{(k)})^t \nabla h(x^{(k)}) = -\|\nabla h(x^{(k)})\|_2^2 < 0$$

Hay varias maneras de elegir t_k:
(a)

$$x^{(k+1)} := x^{(k)} - \frac{h(x^{(k)})}{\|\nabla h(x^{(k)})\|_2^2} \nabla h(x^{(k)})$$

(b) *Búsqueda exacta*: Determinar t_k tal que

$$h(x^{(k)} - t_k p^{(k)}) = \min_{t \in [0,1]} h(x^{(k)} - t p^{(k)})$$

(c) *Prueba de Armijo*: Determinar $t_k := 2^{-j}$, donde j es el entero no negativo más pequeño, tal que para $\beta \in [0, 1/2]$ se cumpla

$$h(x^{(k)} + 2^{-j} p^{(k)}) - h(x^{(k)}) \leq \beta 2^{-j} \nabla h(x^{(k)})^t p^{(k)}$$

En los casos (b) y (c) se cumple $h(x^{(k+1)}) < h(x^{(k)})$ y se obtiene convergencia global. El orden de convergencia es solamente 1.

3.1. Métodos Quasi-Newton.

$$x^{(k+1)} := x^{(k)} - B_k^{-1} f(x^k), \quad j = 0, 1, 2, \ldots$$

donde $\{B_k\}$ es una sucesión de matrices adecuadas.
[Revise Luemberger, Programación lineal y no lineal]

3.2. Cálculo de ceros de polinomios.

TEOREMA 4.11. *Un polinomio de grado n tiene exactamente n ceros en el plano complejo, conviniendo que cada cero debe contarse un número de veces igual a su multiplicidad.*

TEOREMA 4.12. *Todos los ceros del polinomio*

$$P_n(z) = a_n z^n + a_{n-1} z^{n-1} + \cdots + a_2 z^2 + a_1 z + a_0$$

donde $a_k \in \mathbb{R}$ *o* $a_k \in \mathbb{C}, \quad k = 0, 1, \ldots, n$, *se encuentran en el disco cerrado cuyo centro está en el origen del plano complejo y cuyo radio es*

$$\rho = 1 + |a_n|^{-1} \max_{0 \le k < n} |a_k|$$

Demostración: Sea $C = \max_{0 \le k < n} |a_k|$ de modo que $\rho = 1 + |a_n|^{-1} C$ ó $C|a_n|^{-1} = \rho - 1$.
Si $|z| > \rho$, entonces

$$\begin{aligned}
|P_n(z)| &\ge |a_n z^n| - |a_{n-1} z^{n-1} + \cdots + a_2 z^2 + a_1 z + a_0| \\
&\ge |a_n z^n| - \sum_{k=0}^{n-1} |a_k| |z|^k \ge |a_n z^n| - \sum_{k=0}^{n-1} C|z|^k \\
&= |a_n z^n| - C|z|^n \sum_{k=0}^{n-1} \frac{1}{|z|^{n-k}} = |a_n z^n| - C|z|^n \sum_{k=1}^{n} \frac{1}{|z|^k} \\
&> |a_n z^n| - C|z|^n \frac{1}{|z|} \left(\frac{1}{1 - \dfrac{1}{|z|}} \right) \\
&= |a_n z^n| \left\{ 1 - C|a_n|^{-1} (|z| - 1|)^{-1} \right\} \\
|P_n(z)| &> |a_n z^n| \left\{ 1 - C|a_n|^{-1} (\rho - 1|)^{-1} \right\} = 0
\end{aligned}$$

de donde $P_n(z) \neq 0$. De esto, z no puede ser una raíz de P_n. □

Ejemplo: Hallar un disco cerrado en el origen que contenga todos los ceros del polinomio

$$P_4(z) = 7z^4 - 3z^3 - 4z^2 + 3^z + 1$$

Basta tomar

$$\begin{aligned}
\rho &= 1 + |a_4|^{-1} \max_{0 \le k < 4} |a_k| = 1 + 7^{-1} \max\{|1|, |3|, |-4|, |-3|\} \\
&= 1 + 7^{-1} 4 = \frac{11}{4}
\end{aligned}$$

Así tenemos el disco $D = \left\{ z \in \mathbb{C} \ / \ |z| < \dfrac{11}{4} \right\}$.

Sea $S_n(z) = z^n P_n(1/z)$. Entonces

$$\begin{aligned}
S_n(z) &= z^n \left[a_n \left(\frac{1}{z} \right)^n + a_{n-1} \left(\frac{1}{z} \right)^{n-1} + \cdots + \left(\frac{1}{z} \right) a_1 + a_0 \right] \\
&= a_n + a_{n-1} z + \cdots + a_1 z^{n-1} + a_0 z^n
\end{aligned}$$

Si $z_0 \neq 0$ se cumple:

$$P_n(z_0) = 0 \quad \Longleftrightarrow \quad S_n \left(\frac{1}{z_0} \right) = 0$$

Por lo tanto se obtiene el siguiente teorema:

TEOREMA 4.13. *Si todos los ceros de* S_n *están en el disco* $\{z : |z| \le \rho'\}$, *entonces todos los ceros no nulos de* P_n *se encuentran fuera del disco* $\{z : |z| < \rho'^{-1}\}$.

Ejemplo: Para el ejemplo anterior:

$$\begin{aligned} S_4(z) &= z^4 P_4(z) = z^4\left[7\left(\frac{1}{z}\right)^n - 3\left(\frac{1}{z}\right)^3 - 4\left(\frac{1}{z}\right)^2 + 3\left(\frac{1}{z}\right) + 1\right] \\ &= 7 - 3z - 4z^2 + 3z^3 + z^4 \end{aligned}$$

$$\begin{aligned} \rho' &= 1 + |A_4|^{-1} \max_{0\le k<4}\{|A_k|\} \\ &= 1 + 1^{-1}\,\text{máx}\{|7|, |-3|, |-4|, |3|\} = 1 + 7 = 8 \end{aligned}$$

Entonces los ceros de P_4 se encuentran fuera del disco de radio $\rho'^{-1} = 1/8$. Por lo tanto, los ceros de P_4 se encuentran en el anillo $\left\{z \in \mathbb{C} : \frac{1}{8} \le |z| \le \frac{11}{7}\right\}$ del plano complejo.

3.2.1. Algoritmo de Horner (Multiplicación anidada, división sintética). Dado un polinomio P_n y un número complejo z_0, el algoritmo de Horner proporciona $P_n(z_0)$ y el polinomio

$$Q_{n-1}(z) = \frac{P_n(z) - P_n(z_0)}{z - z_0} \quad \dots \quad (\alpha_1)$$

Se cumple:

$$P_n(z) = (z - z_0)Q_{n-1}(z) + P_n(z_0) \quad \dots \quad (\alpha_2)$$

Sea $Q_{n-1}(z) := b_{n-1}z^{n-1} + b_{n-2}z^{n-2} + \cdots + b_1 z + b_0$. Reemplazando en (α_2):

$$\begin{aligned} \sum_{k=0}^{n} a_k z^k &= (z - z_0)\sum_{k=0}^{n-1} b_k z^k + P_n(z_0) \\ &= \sum_{k=0}^{n-1} b_k z^{k+1} - z_0 \sum_{k=0}^{n-1} b_k z^k + P_n(z_0) \\ &= (-z_0 b_0 + P_n(z_0)) + \sum_{k=1}^{n} b_{k-1} z^k - z_0 \sum_{k=1}^{n-1} b_k z^k \\ &= (-z_0 b_0 + P_n(z_0)) + \sum_{k=1}^{n-1} (b_{k-1} - z_0 b_k) z^k + b_{n-1} z^n \end{aligned}$$

de esto obtenemos

$$\begin{aligned} &a_0 = -z_0 b_0 + P_n(z_0) \\ &a_k = b_{k-1} - z_0 b_k \qquad k = 1, 2, \dots, n-1 \\ &a_n = b_{n-1} \end{aligned}$$

de donde

$$\begin{aligned} &b_{n-1} = a_n \\ &b_{k-1} = a_k + z_0 b_k, \qquad k = n-1, n-2, \dots, 1 \\ &P_n(z_0) = a_0 + z_0 b_0 \end{aligned}$$

Entrada:	$n, a_0, a_1, \cdots, a_n, z_0$
$b_{n-1} := a_n$	
Para $k = n-1, n-2, \cdots, 0$	
	$b_{k-1} := a_k + z_0 b_k$
Salida:	$P_n(z_0) = b_{-1}, b_0, b_1, \cdots, b_{n-1}$

Ahora deseamos encontrar las raíces del polinomio. Para esto, podemos aplicar el método de Newton, pero necesitamos para ello la derivada del polinomio. Para esto tenemos el siguiente

TEOREMA 4.14. *Sea* $P(x) = a_n x^n + \cdots + a_1 x + a_0$. *Sean* (α_j, β_j) *para* $j = n, n-1, \cdots, 0$, *definidos por*

$$\begin{aligned}(\alpha_n, \beta_n) &= (a_n, 0)\\ (\alpha_j, \beta_j) &= (a_j + x\,\alpha_{j+1}, \alpha_{j+1} + x\,\beta_{j+1}), \quad j = n-1, n-2, \cdots, 0\end{aligned}$$

Entonces $\alpha_0 = P(x)$ *y* $\beta_0 = P'(x)$

TEOREMA 4.15 (Bodewig - 1946). *Sean* $x^{(k)}$ *y* $x^{(k+1)}$ *dos iteraciones sucesivas que resultan de la aplicación del método de Newton a un polinomio* P_n *de grado* n. *Entonces existe un cero de* P_n *en una vecindad de* $x^{(k)}$ *de radio* $\|x^{(k)} - x^{(k+1)}\|$ *en el plano complejo.*

3.3. Método de Bairstrow.

TEOREMA 4.16. *Si* $P_n(x) = a_n x^n + a_{n-1}x^{n-1} + \cdots + a_0$, $a_n \neq 0, a_i \in \mathbb{R}$ *y* z_0 *es un cero complejo de* P_n, *entonces* $\overline{z}_0$ *es también un cero de* P_n *y* $(x - z_0)(x - \overline{z}_0)$ *es un factor cuadrático real de* P_n.

Demostración: Como z_0 es un cero de P_n

$$P_n(z_0) = a_n z_0^n + a_{n-1} z_0^{n-1} + \cdots + a_1 z_0 + a_0 = 0$$

Tomando conjugadas a ambos miembros:

$$\overline{0} = 0 = a_n \overline{z_0}^n + a_{n-1}\overline{z_0}^{n-1} + \cdots + a_1 \overline{z_0} + a_0 = P_n(\overline{z_0})$$

entonces $\overline{z_0}$ es también un cero de P_n. Como z_0 no es un número real se tiene que z_0 y $\overline{z_0}$ son ceros distintos de P_n. Por consiguiente $P_n(x)$ contiene al factor cuadrático

$$\begin{aligned}(x - z_0)(x - \overline{z_0}) &= x^2 - (z_0 + \overline{z_0})x + z_0\,\overline{z_0}\\ &= x^2 - 2Re(z_0)x + |z_0|^2\end{aligned}$$

que es un factor cuadrático irreducible. □

TEOREMA 4.17. *Si el polinomio* $P_n(x) = a_n x^n + a_{n-1}x^{n-1} + \cdots + a_1 x + a_0$ *se divide entre el polinomio cuadrático* $x^2 - rx - q$, *entonces el cociente y el residuo están dados por*

$$\begin{aligned}Q_{n-2}(x) &= b_n x^{n-2} + b_{n-1}x^{n-3} + \cdots + b_3 x + b_2\\ R(x) &= b_1(x - r) + b_0\end{aligned}$$

con

$$P_n(x) = Q_{n-2}(x)(x^2 - rx - q) + R(x)$$

Los cuales pueden calcularse de manera recursiva utilizando

$$b_k = a_k + rb_{k+1} + qb_{k+2}, \quad k = n, n-1, \cdots, 0 \qquad \ldots \qquad (+)$$

donde $b_{n+1} = b_{n+2} = 0$.

Demostración: Tenemos (probar reemplazando Q_{n-2}):

$$P_n(x) = b_n x^n + (b_{n-1} - rb_n)x^{n-1} + \sum_{k=2}^{n-2}(b_k - rb_{k+1} - qb_{k+2})x^k + (b_1 - rb_2 - qb_3)x + (b_0 - rb_1 - qb_2) \quad \square$$

Para calcular las raíces de P_n buscamos un factor cuadrático real del tipo $x^2 - rx - q$ con $r, q \in \mathbb{R}$. En este proceso de división, se tiene

$$\begin{aligned}b_0 &= b_0(r, q)\\ b_1 &= b_1(r, q)\\ R(x) &= b_1(x - r) + b_0\end{aligned}$$

En el esquema de Bairstrow, este sistema no lineal se resuelve por el método de Newton:

$$\begin{pmatrix} r^{(k+1)} \\ q^{(k+1)} \end{pmatrix} = \begin{pmatrix} r^{(k)} \\ q^{(k)} \end{pmatrix} - \left[\begin{array}{cc} \dfrac{\partial b_0}{\partial r} & \dfrac{\partial b_0}{\partial q} \\ \dfrac{\partial b_1}{\partial r} & \dfrac{\partial b_1}{\partial q} \end{array} \right]^{-1} \Bigg|_{\substack{q=q^{(k)} \\ r=r^{(k)}}} \begin{pmatrix} b_0(r^{(k)}, q^{(k)}) \\ b_1(r^{(k)}, q^{(k)}) \end{pmatrix} \quad \cdots \quad (++)$$

Definiendo

$$c_k := \frac{\partial b_k}{\partial r}, \quad d_k := \frac{\partial b_{k-1}}{\partial q}$$

En el teorema anterior, derivando a ambos miembros de (+), se obtiene

$$\begin{aligned} &\frac{\partial b_k}{\partial r} = b_{k+1} + r\frac{\partial b_{k+1}}{\partial r} + q\frac{\partial b_{k+2}}{\partial r} \\ &c_k = b_{k+1} + r\, c_{k+1} + q\, c_{k+2} \\ &c_{n+1} = c_n = 0 \end{aligned}$$

Esto es, $P_(x) = Q_{n-2}(x)(x^2 - rx - q) + R(x)$. Del mismo modo, para q, obtenemos

$$\begin{aligned} &\frac{\partial b_k}{\partial q} = b_{k+1} + r\frac{\partial b_{k+1}}{\partial q} + q\frac{\partial b_{k+2}}{\partial q} \\ &d_k = b_{k+1} + r\, d_{k+1} + q\, d_{k+2} \\ &d_{n+1} = d_n = 0 \end{aligned}$$

Usando (++), llegamos al sistema

$$\begin{bmatrix} c_0 & c_1 \\ c_1 & c_2 \end{bmatrix} \begin{bmatrix} \Delta r^{(k)} \\ \Delta q^{(k)} \end{bmatrix} = \begin{bmatrix} b_0(r^{(k)}, q^{(k)}) \\ b_1(r^{(k)}, q^{(k)}) \end{bmatrix}$$

donde

$$\begin{bmatrix} \Delta r^{(k)} \\ \Delta q^{(k)} \end{bmatrix} = \begin{bmatrix} r^{(k+1)} - r^{(k)} \\ q^{(k+1)} - q^{(k)} \end{bmatrix}$$

Resolviendo el sistema: hacemos

$$\Delta = \begin{vmatrix} c_0 & c_1 \\ c_1 & c_2 \end{vmatrix}$$

De donde:

$$\begin{aligned} r^{(k+1)} &= r^{(k)} + \frac{1}{\Delta}(b_1 c_1 - b_0 c_2) \\ q^{(k+1)} &= q^{(k)} + \frac{1}{\Delta}(b_0 c_1 - b_1 c_0) \end{aligned}$$

Capítulo 5

Aproximación lineal

1. Introducción

En física, el siguiente problema es típico: dado un conjunto de puntos $\{(x_i, y_i)\}_{i=1}^n$, y una familia de rectas $\{y = ax + c / x \in \mathbb{R}\}$, hallar los coeficientes a, c que minimicen la sumas de los cuadrados de las distancias de los puntos a la recta (esto es lo que se llamará *recta mínimo cuadrática*) . Esto se puede expresar como:

$$\min_{(a,c)\in\mathbb{R}^2} \sum_{i=1}^{n} (y_i - ax_i - c)^2$$

el problema anterior es equivalente al siguiente problema:

$$\min_{x\in\mathbb{R}^n} \|Ax - b\|_2 = \left\| \begin{bmatrix} x_1 & 1 \\ x_2 & 1 \\ \vdots & \vdots \\ x_n & 1 \end{bmatrix} \begin{bmatrix} a \\ c \end{bmatrix} - \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} \right\|_2$$

donde

$$A := \begin{bmatrix} x_1 & 1 \\ x_2 & 1 \\ \vdots & \vdots \\ x_n & 1 \end{bmatrix}, \qquad x := \begin{bmatrix} a \\ c \end{bmatrix}, \qquad b := \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

Sea $A \in \mathbb{R}^{m\times n}$, $m \geq n$.

Formulamos entonces, de manera más general, el siguiente problema: buscar una solución $x \in \mathbb{R}^n$ tal que $Ax = b$ cuando se tienen más ecuaciones que variables. Una alternativa, es solucionar el problema equivalente

$$\min_{x\in\mathbb{R}^n} \|Ax - b\|.$$

Eligiendo la norma $\|\cdot\|_1$ o $\|\cdot\|_\infty$ se obtiene un problema de optimización lineal. En caso de que se trate de $\|\cdot\|_2$, se obtiene el problema del mínimo de los cuadrados más pequeños. Este último es conocido como el problema de aproximación lineal:

$$\min_{x\in\mathbb{R}^n} \|Ax - b\|_2. \tag{8}$$

2. Ecuaciones normales

TEOREMA 5.1. *Sea $A \in \mathbb{R}^{m\times n}$, $m \geq n$ y el problema de aproximación lineal:*

$$\min \|Ax - b\|_2, \quad x \in \mathbb{R}^n. \tag{9}$$

Entonces se cumplen:

1. *$x^* \in \mathbb{R}^n$ es solución de (9) sí, y sólo si $A^tAx^* = A^tb$, es decir, si se cumplen las ecuaciones normales.*

2. *El conjunto*
$$L = \{x \in \mathbb{R}^n : A^tAx = A^tb\}$$
de las soluciones de (9) es un subespacio no vacío, afín de $\mathbb{R}^n$*. Además se cumple* $Ax_1 = Ax_2$*, para todo* $x_1, x_2 \in L$*.*
3. *El problema (9) tiene una solución única sí y sólo si* $\operatorname{rang}(A) = n$*.*
4. *De todas las soluciones de (9) existe exactamente una solución con norma de Euclides minimal.*

Demostración.

1. Definimos $f : \mathbb{R}^n \to \mathbb{R}$ por
$$f(x) := \frac{1}{2}\|Ax - b\|_2^2 = \frac{1}{2}(Ax - b)^t(Ax - b)$$
Solucionar (9) es equivalente a solucionar mín $f(x)$. Sea $x^* \in \mathbb{R}^n$ una solución de (9). Entonces
$$\nabla f(x^*) = 0 \quad \text{implica} \quad A^tAx^* - A^tb = 0$$
esto es, $A^tAx^* = A^tb$. Luego x^* es una solución de las ecuaciones normales. Recíprocamente, sea x^* una solución de las ecuaciones normales, entonces (¡verifique!):
$$f(x) - f(x^*) = \frac{1}{2}\big[A(x - x^*)\big]^tA(x - x^*) + (A^tAx^* - A^tb)^t(x - x^*).$$
Luego
$$f(x) - f(x^*) = \frac{1}{2}\big\|A(x - x^*)\big\|_2^2 \geq 0, \tag{10}$$
lo cual implica que $f(x) \geq f(x^*)$, entonces x^* es solución de (9).
2. Primero se tiene que mostrar que $L \neq \emptyset$.
Se cumple: el sistema $Ax = b$ tiene solución sí y sólo si
$$y \in \operatorname{Nu}(A^t) \quad \text{implica} \quad b^ty = 0$$
En efecto, si $Ax = b$ tiene solución, entonces existe $x \in \mathbb{R}^n$ satisfaciendo
$$(A^ty)^tx = y^tAx = y^tb, \qquad y \in \mathbb{R}^m.$$
Por lo tanto
$$y \in \operatorname{Nu}(A^t) \text{ implica } A^ty = 0 \text{ y luego } y^tb = 0.$$
El recíproco se deja como ejercicio.
Ahora, sea $x \in \operatorname{Nu}(A^tA)^t = \operatorname{Nu}(A^tA)$, entonces
$$\|Ax\|_2^2 = x^t(A^tAx) = 0,$$
de donde $Ax = 0$ y
$$(A^tb)^tx = b^t(Ax) = 0.$$
Por la afirmación anterior, $L \neq \emptyset$.
Sean $x_1, x_2 \in L, \lambda \in \mathbb{R}$, entonces
$$\begin{aligned} A^tA(\lambda x_1 + (1 - \lambda)x_2) &= \lambda A^tAx_1 + (1 - \lambda)A^tAx_2 \\ &= \lambda A^tb + (1 - \lambda)A^tb = A^tb. \end{aligned}$$
Esto implica que $\lambda x_1 + (1 - \lambda)x_2 \in L$. Por lo tato L es afín.
Sean $x_1, x_2 \in L$, entonces $f(x_1) = f(x_2)$ y por (10)
$$0 = f(x_1) - f(x_2) = \frac{1}{2}\big\|A(x_1 - x_2)\big\|_2^2,$$
de donde $Ax_1 = Ax_2$.

3. $\mathrm{Nu}(A^tA) = \mathrm{Nu}(A)$ (¡verifíquelo!). Esto implica que $A^tA \in \mathbb{R}^{n\times n}$ es regular si $\mathrm{rang}(A) = n$. Luego (9) tendría solución única.
4. Sea $x^* \in L$, entonces $L \cap \{x \in \mathbb{R}^n / \|x\|_2 \leq \|x^*\|_2\} =: B$ es compacto (L es cerrado y el otro conjunto compacto). La función continua $\|\cdot\|_2$ posee un mínimo en $B \subset L$, luego también lo tiene en L.

   La unicidad de la solución se sigue del hecho que si $x_1, x_2 \in L$ son dos soluciones con norma minimal, entonces $\|x\|_1 = \|x\|_2$, y luego como L es afín $\frac{1}{2}(x_1 + x_2) \in L$ y

$$\left\|\frac{1}{2}(x_1 + x_2)\right\|_2 \leq \frac{1}{2}\big(\|x_1\|_2 + \|x_2\|_2\big) = \|x_1\|_2,$$

   de donde

$$\frac{1}{2}\|x_1 + x_2\| = \|x_1\|_2 = \|x_2\|_2.$$

   Luego

$$\|x_1 - x_2\|_2^2 = 2\big(\|x_1\|_2^2 + \|x_2\|_2^2\big) - \|x_1 + x_2\|_2^2 = 0,$$

   de donde $x_1 = x_2$.

□

3. Tratamiento numérico

Numéricamente, el problema de aproximación lineal (9) se trata de la manera siguiente: por el método de Householder o Givens se determina una matriz ortogonal $Q \in \mathbb{R}^{m\times n}$ tal que

$$Q^tA = R = \begin{bmatrix} R_1 \\ 0 \end{bmatrix} \begin{matrix} \leftarrow n \\ \leftarrow m-n \end{matrix} \qquad \text{y} \qquad Q^tb = \begin{bmatrix} c \\ d \end{bmatrix} \begin{matrix} \leftarrow n \\ \leftarrow m-n \end{matrix}$$

donde R_1 es una matriz triangular superior, $R_1 \in \mathbb{R}^{n\times n}$.
Si $\mathrm{rang}(A) = n$, R_1 es regular. Luego los elementos de la diagonal son distintos de cero.
Sea $x \in \mathbb{R}^n$, se cumple:

$$\begin{aligned} \|Ax - b\|_2^2 &= \|Q^t(Ax - b)\|_2^2 = \|Q^tAx - Q^tb\|_2^2 = \left\|\begin{bmatrix} R_1 \\ 0 \end{bmatrix} x - \begin{bmatrix} c \\ d \end{bmatrix}\right\|_2^2 \\ &= \|R_1x - c\|_2^2 + \|d\|_2^2 \end{aligned}$$

La solución se obtiene de $R_1x - c = 0$.

Para el caso en que la matriz A no tenga $\mathrm{rang}(A) = n$ o las columnas de A son "casi"linealmente dependientes, se deben utilizar otros métodos (problemas de buscar valores propios). El método numérico dado es más eficiente que aplicar el método de Cholesky a las ecuaciones normales ($A^tAx = A^tb$), porque A^tA tiene una pésima condición: para $A \in \mathbb{R}^{n\times n}$,

$$\begin{aligned} \mathrm{cond}_2(A) &= \|A^tA\|_2\|A^{-1}A^{-t}\|_2 = \rho(A^tA)\rho(A^{-1}A^{-t}) \\ &= \rho(A^2)\rho((A^2)^{-1}) = \mathrm{cond}_2(A^2). \end{aligned}$$

4. Ejercicios

1. Realice el ajuste de los datos de la tabla

x_i	1,1	1,9	2,7	4,3	5,1	7,8
y_i	11,2	16,8	18,7	8,1	2,7	14,3

   mediante una combinación lineal de las funciones 1, $\sin(x)$, $\cos(x)$.

2. Sea $A \in \mathbb{R}^{m\times n}$, $b \in \mathbb{R}^m$ y $\alpha > 0$. Defina $F : \mathbb{R}^n \to \mathbb{R}$ mediante
$$F(x) = \|Ax - b\|_2^2 + \alpha\|x\|_2^2.$$
Demuestre que F alcanza un mínimo cuando x es solución de la ecuación
$$(A^TA + \alpha I)x = A^Tb.$$
Demuestre que cuando x se define de esta manera,
$$F(x + h) = F(x) + (Ah)^TAh + \alpha h^Tx.$$

3. Encuentre la solución en mínimos cuadrados del sistema
$$\begin{bmatrix} x & y \end{bmatrix} \begin{bmatrix} 3 & 2 & 1 \\ 2 & 3 & 2 \end{bmatrix} = \begin{bmatrix} 3 & 0 & 1 \end{bmatrix}.$$

4. En un trabajo relacionado con el estudio de la eficiencia de la utilización de la energía por las larvas de la polilla modesta (*Pachysphinx modesta*), L. Schroeder utilizó los siguientes datos para determinar una relación entre W, el peso de las larvas vivas en gramos, y R, el consumo de oxígeno de las larvas en mililitros/hora. Por razones biológicas, se supone que entre W y R existe una relación de la forma
$$R = bW^a.$$
   a) Encuentre el polinomio lineal de mínimos cuadrados asociado a la fórmula anterior, y resuelva el problema de mínimos cuadrados hallando estimados de a y b. Calcule además el error asociado.
   b) Modifique la ecuación de la parte anterior para ajustarla al modelo
   $$R = b \cdot W^a \cdot W^{c \ln W}$$
   y calcule los nuevos parámetros.

   Los datos a utilizar se presentan en la siguiente tabla:

W	0,017	0,087	0,085	0,020	0,233	4,83	5,53
R	0,154	0,296	0,260	0,180	0,537	4,66	6,94

Capítulo 6

Interpolación

Las fórmulas de interpolación constituyen los puntos de partida de las derivaciones de muchos métodos del análisis numérico.

En general, para la solución del problema de interpolación se busca una función $g(x, \alpha_0, \ldots, \alpha_r)$ de la cual se eligen los parámetros $\alpha_0, \ldots, \alpha_r$, tal que la función asuma los valores de otra función o de una tabla, como

$$\{(x_i, y_i)\}_{i=1}^n, \qquad g(x_i, \alpha_0, \ldots, \alpha_r) = y_i, \quad i = 0, \ldots, n.$$

Como ejemplos:

1. En la interpolación polinomial:

$$g(x, \alpha_0, \ldots, \alpha_m) = \alpha_0 + \alpha_1 x + \alpha_2 x^2 + \cdots + \alpha_r x^r$$

2. Para funciones periódicas, se puede elegir:

$$g(x, \alpha_0, \ldots, \alpha_m) = \alpha_0 + \alpha_1 \operatorname{sen}(\alpha_2 x) + \alpha_3 \cos(\alpha_4 x) + \cdots + \alpha_{r-1} \cos(\alpha_r x)$$

3. Para oscilaciones amortiguadas:

$$g(x, \alpha_0, \ldots, \alpha_m) = \alpha_0 + \alpha_1 e^{\alpha_2 x} \operatorname{sen}(\alpha_3 x) + \alpha_4 e^{\alpha_5 x} \cos(\alpha_6 x) + \cdots + \alpha_{r-2} e^{\alpha_{r-1} x} \cos(\alpha_r x)$$

4. Para una función con polos:

$$g(x, \alpha_0, \ldots, \alpha_m) = \frac{\alpha_0 + \alpha_1 x + \alpha_2 x^2 + \cdots + \alpha_s x^s}{\alpha_{s+1} x^{s+1} + \cdots + \alpha_r x^r}$$

.

1. Interpolación polinomial

Supongamos que tenemos $x_0, x_1, \ldots, x_n$, $(n+1)$ puntos distintos del eje real y $f_0, f_1, \ldots, f_n$ los valores correspondientes de la ordenada. Buscamos un polinomio de grado menor o igual a n

$$P_n(x) = a_0 + a_1 x + a_2 x^2 + \cdots + a_n x^n$$

tal que $P_n(x_i) = f_i, \quad i = 0, 1, \ldots, n.$

TEOREMA 6.1. *Para $(n+1)$ puntos $(x_0, f_0), (x_1, f_1), \ldots, (x_n, f_n) \in \mathbb{R}^2$ con abscisas distintas (esto es, $x_i \neq x_j$ para $i \neq j$), existe un único polinomio P_n de grado menor o igual a n que cumple las condiciones interpolantes:*

$$P_n(x_i) = f_i, \quad i = 0, 1, \ldots, n$$

DEMOSTRACIÓN. Consideremos el sistema lineal:

$$f_i = a_0 + a_1 x_i + a_2 x_i^2 + \cdots + a_n x_i^n, \quad i = 0, 1, \ldots, n$$

en la forma $Ax = b$:

$$\begin{bmatrix} 1 & x_0 & x_0^2 & \ldots & x_0^n \\ 1 & x_1 & x_1^2 & \ldots & x_1^n \\ \vdots & & & & \vdots \\ 1 & x_n & x_n^2 & \ldots & x_n^n \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \end{bmatrix} = \begin{bmatrix} f_0 \\ f_1 \\ \vdots \\ f_n \end{bmatrix} \tag{11}$$

como $x_i \neq x_j$ para $i \neq j$ el determinante de Vandermonde

$$\det(A) = \prod_{i>j}(x_i - x_j)$$

$(i = 1, \ldots, n, j = 0, \ldots, n)$ es diferente de cero y el sistema lineal (11) tiene solución única $(a_0, a_1, \ldots, a_n)^t$ y por consiguiente $P_n(x) = a_0 + a_1 x + \cdots + a_n x^n$ es el único polinomio que cumple las condiciones interpolantes. □

1.1. Fórmula de Lagrange. Evitando el sistema lineal

$$\begin{bmatrix} 1 & x_0 & x_0^2 & \ldots & x_0^n \\ 1 & x_1 & x_1^2 & \ldots & x_1^n \\ \vdots & & & & \vdots \\ 1 & x_n & x_n^2 & \ldots & x_n^n \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \end{bmatrix} = \begin{bmatrix} f_0 \\ f_1 \\ \vdots \\ f_n, \end{bmatrix} \tag{12}$$

por ser usualmente este mal condicionado, escribimos

$$P_n(x) = f_0 L_0(x) + f_1 L_1(x) + \cdots + f_n L_n(x)$$

donde los polinomios $L_0, L_1, \ldots, L_n$ tienen grado n y

$$f_j = P_n(x_j) = f_0 L_0(x_j) + f_1 L_1(x_j) + \cdots + f_n L_n(x_j), \quad j = 0, 1, \ldots, n.$$

Esto se cumple, si se exige que

$$L_j(x_k) = \begin{cases} 0, & j \neq k \\ 1, & j = k \end{cases} = \delta_{jk}.$$

Los polinomios L_j con estas propiedades son denominados *polinomios básicos de Lagrange*. Como L_j es de grado n con $L_j(x_k) = 0, \quad k = 0, \ldots, n, \quad k \neq j$ entonces

$$L_j(x) = \alpha_j (x - x_0) \cdots (x - x_{j-1})(x - x_{j+1}) \ldots (x - x_n), \quad j = 0, \ldots, n,$$

y de $L_j(x_j) = 1$, se tiene

$$1 = \alpha_j (x_j - x_0) \cdots (x_j - x_{j-1})(x_j - x_{j+1}) \ldots (x_j - x_n).$$

Usando que $x_j \neq x_k$ para $j \neq k$ se obtiene:

$$L_j(x) = \frac{(x - x_0) \cdots (x - x_{j-1})(x - x_{j+1}) \cdots (x - x_n)}{(x_j - x_0) \cdots (x_j - x_{j-1})(x_j - x_{j+1}) \cdots (x_j - x_n)}$$

o en forma abreviada:

$$L_j(x) = \prod_{\substack{k=0 \\ k \neq j}}^{n} \frac{x - x_k}{x_j - x_k}$$

Reemplazando, obtenemos

$$P_n(x) = \sum_{j=0}^{n} f_j \prod_{\substack{k=0 \\ k \neq j}}^{n} \frac{x - x_k}{x_j - x_k}$$

de esta manera, hemos obtenido

TEOREMA 6.2. *Dados* $(x_i, f_i) \in \mathbb{R}^2, \quad i = 0, 1, \ldots, n$, $x_i \neq x_j$ *para* $i \neq j$, *entonces el único polinomio interpolante de la forma de Lagrange de grado no mayor que* n *puede expresarse como*

$$P_n(x) = \sum_{j=0}^{n} f_j L_j(x) \quad \textit{con} \quad L_j(x) = \prod_{\substack{k=0 \\ k \neq j}}^{n} \frac{x - x_k}{x_j - x_k}, \quad j = 0, 1, \ldots, n$$

Ejemplo 6.1. Para los datos:

x_j	0	0,5	1
f_j	1,1	0,9	0,6

tenemos:

$$\begin{aligned} L_0(x) &= \frac{(x-x_1)(x-x_2)}{(x_0-x_1)(x_0-x_2)} = \frac{(x-0{,}5)(x-1)}{(0-0{,}5)(0-1)} = 2x^2-3x+1 \\ L_1(x) &= \frac{(x-x_0)(x-x_2)}{(x_1-x_0)(x_1-x_2)} = \frac{(x-0)(x-1)}{(0{,}5-0)(0-1)} = 2x^2-2x \\ L_2(x) &= \frac{(x-x_0)(x-x_1)}{(x_2-x_0)(x_2-x_1)} = \frac{(x-0)(x-0{,}5)}{(1-0)(1-0{,}5)} = 2x^2-x \end{aligned}$$

Luego:

$$P_n(x) = 1{,}1(2x^2-3x+1) + 0{,}9(2x^2-2x) + 0{,}6(2x^2-x)$$

La desventaja de este método es que, si se añaden nuevos puntos interpolantes, se tiene que recalcular todos los polinomios nuevamente.

1.2. Forma de Newton. Se inicia con el polinomio de grado 0 que pasa por el punto (x_0, f_0)

$$P_0(x) = f_0, \quad x \in \mathbb{R}.$$

Añadiendo (x_1, f_1), se construye un polinomio $P_1(x)$ de grado no mayor que 1 tal que

$$\begin{cases} P_1(x_0) = f_0 \\ P_1(x_1) = f_1 \end{cases}$$

Sea $P_1(x) = P_0(x) + q_1(x)$, $\quad grado(q_1) \leq 1$. Como $P_1(x_0) = f_0$, entonces $q_1(x_0) = 0$. Luego $grado(q_1) = 1$ implica que $q_1(x) = b_1(x - x_0)$. Como $P_1(x_1) = f_1$, entonces $f_1 = P_1(x_1) = f_0 + b_1(x_1 - x_0) = f_1$. De esto último obtenemos la expresión para b_1:

$$b_1 = \frac{f_1 - f_0}{x_1 - x_0} = \frac{f_1 - P_0(x_1)}{x_1 - x_0}$$

En general, si se tiene un polinomio interpolante P_{n-1} de grado no mayor que $(n-1)$ que pasa por los puntos $(x_0, f_0), (x_1, f_1), \ldots, (x_{n-1}, f_{n-1})$, se calcula el polinomio $P_n(x)$ que pasa además por el punto (x_n, f_n) de la siguiente manera:

$$P_n(x) = P_{n-1}(x) + q_n(x), \text{ donde } grado(q_n) \leq n$$

Como $P_n(x_j) = P_{n-1}(x_j) = f_j$, $\quad j = 0, 1, \ldots, n-1$, entonces $q_n(x_j) = 0$, $\quad j = 0, 1, \ldots, n-1$. Luego

$$q_n(x) = b_n(x - x_0)(x - x_1)\cdots(x - x_{n-1})$$

El coeficiente b_n, se obtiene de $P_n(x_n) = P_{n-1}(x_n) + q_n(x_n) = f_n$, mediante

$$b_n = \frac{f_n - P_{n-1}(x_n)}{\prod_{j=0}^{n-1}(x_n - x_j)}$$

Veamos otra manera de obtener P_n a partir de P_{n-1}: de la expresión $P_n(x) = P_{n-1} + b_n \prod_{j=0}^{n-1}(x - x_j)$ notamos que el coeficiente correspondiente a x^n es b_n (pues $grado(P_{n-1}) \leq n-1$). Sea R_{n-1} el polinomio interpolante que pasa por los puntos $(x_1, f_1), (x_2, f_2), \ldots, (x_n, f_n)$. Definimos

$$P_n(x) = \frac{(x - x_n)P_{n-1}(x) - (x - x_0)R_{n-1}(x)}{x_0 - x_n}. \tag{13}$$

Este polinomio satisface las condiciones interpolantes

$$P_n(x_j) = f_j, \quad j = 0, 1, \ldots, n$$

En efecto: para $j = 0$

$$P_n(x_0) = \frac{(x_0 - x_n)f_0 - (x_0 - x_0)R_{n-1}(x_0)}{x_0 - x_n} = f_0;$$

para $j = 1, 2, \ldots, n-1$

$$P_n(x_j) = \frac{(x_j - x_n)f_j - (x_j - x_0)f_j}{x_0 - x_n} = f_j;$$

y para $j = n$

$$P_n(x_n) = \frac{(x_n - x_n)P_{n-1}(x_n) - (x_n - x_0)f_n}{x_0 - x_n} = f_n.$$

Sea b_{n-1}^R el coeficiente correspondiente a x^{n-1} en el polinomio $R_{n-1}(x)$. De (13) se obtiene:

$$b_n = \frac{b_{n-1} - b_{n-1}^R}{x_0 - x_n} \tag{14}$$

Denotemos con $f[x_j, x_{j+1}, \ldots, x_{j+k}]$ al coeficiente de x_k en el polinomio interpolante que pasa por los puntos $(x_j, f_j), (x_{j+1}, f_{j+1}), \ldots, (x_{j+k}, f_{j+k})$. Se cumple:

$$f[x_0] = f_0, \quad f[x_1] = f_1, \quad \ldots, \quad f[x_n] = f_n$$

y de (14) se obtiene:

$$b_n = f[x_0, \ldots, x_n] = \frac{f[x_1, \ldots, x_n] - f[x_0, \ldots, x_{n-1}]}{x_n - x_0}$$

En general:

$$f[x_j, \ldots, x_{j+k}] = \frac{f[x_{j+1}, \ldots, x_{j+k}] - f[x_j, \ldots, x_{j+k-1}]}{x_{j+k} - x_j}$$

El polinomio interpolante P_n puede ser escrito ahora como:

$$P_n(x) = f[x_0] + f[x_0, x_1](x - x_0) + \cdots + f[x_0, x_1, \ldots, x_n](x - x_0)\ldots(x - x_{n-1})$$

Damos ahora un esquema para calcular $f[x_0, \ldots, x_n]$, la *tabla de diferencias divididas*:

x	$f[x]$	$f[x,x]$	$f[x,x,x]$	$f[x,x,x,x]$	$\ldots$
x_0	$f_0 := f[x_0]$				
		$f[x_0,x_1] = \frac{f[x_1]-f[x_0]}{x_1-x_0}$			
x_1	$f_1 := f[x_1]$		$f[x_0,x_1,x_2] = \frac{f[x_1,x_2]-f[x_1,x_0]}{x_2-x_0}$		
		$f[x_1,x_2] = \frac{f[x_1]-f[x_0]}{x_1-x_0}$		$f[x_0,x_1,x_2,x_3]$	
x_2	$f_2 := f[x_2]$		$f[x_1,x_2,x_3] = \frac{f[x_2,x_3]-f[x_1,x_2]}{x_3-x_1}$		$\ldots$
		$f[x_2,x_3] = \frac{f[x_1]-f[x_0]}{x_1-x_0}$		$f[x_1,x_2,x_3,x_4]$	
x_3	$f_3 := f[x_3]$		$f[x_2,x_3,x_4] = \frac{f[x_3,x_4]-f[x_2,x_3]}{x_4-x_2}$	$\vdots$	
		$f[x_3,x_4] = \frac{f[x_1]-f[x_0]}{x_1-x_0}$	$\vdots$		
x_4	$f_4 := f[x_4]$	$\vdots$			
$\vdots$	$\vdots$				
x_4	$f_n := f[x_n]$				

NOTA. Ahora podemos ir agregando más y más puntos. Por ejemplo, al agregar el punto (x_{n+1}, f_{n+1}), tendremos

$$P_{n+1}(x) = P_n(x) + f[x_0, x_1, \ldots, x_{n+1}] \prod_{j=0}^{n} (x - x_j)$$

y así sucesivamente.

Tenemos ahora el *algoritmo de las diferencias divididas*:

Entrada: $x_0, x_1, \ldots, x_n, f_0, f_1, \ldots, f_n$
$f[x_0] := f_0, \quad f[x_1] := f_1, \quad \ldots, \quad f[x_n] := f_n$
Para $k = 1, 2, \ldots, n$
Para $j = 0, \ldots, (n-k)$
$f[x_j, \ldots, x_{j+k}] := \dfrac{f[x_{j+1}, \ldots, x_{j+k}] - f[x_j, \ldots, x_{j+k-1}]}{x_{j+k} - x_j}$

El cálculo se simplifica cuando se tienen puntos igualmente espaciados :

$$x_j := x_0 + jh, \quad j = 0, 1, \ldots, n, \quad h > 0$$

entonces $x_{k+l} - x_k = lh$. Definimos:

$$\Delta^0 f_k = f_k, \quad k = 0, 1, 2, \ldots$$
$$\Delta^l f_k = \Delta^{l-1} f_{k+1} - \Delta^{l-1} f_k$$

y se obtiene:

$$f[x_k, \ldots, x_{k+l}] = \frac{1}{l!} \frac{\Delta^l f_k}{h^l}$$

y el polinomio interpolante:

$$\begin{aligned} P_n(x) =& \Delta^0 f_0 + \frac{1}{1!} \frac{\Delta^1 f_0}{h^1}(x - x_0) + \frac{1}{2!} \frac{\Delta^2 f_0}{h^2}(x - x_0)(x - x_1) \\ &+ \cdots + \frac{1}{n!} \frac{\Delta^n f_0}{h^n}(x - x_0)(x - x_1) \cdots (x - x_{n-1}) \end{aligned}$$

que es parecido a la fórmula de Taylor.

NOTA. Para evaluar el polinomio en un punto, se puede utilizar el esquema de Horner:

$$P_n(x) = b_0 + (x - x_0)(b_1 + \cdots + (x - x_{n-3})(b_{n-2} + (x - x_{n-2})(b_{n-1} + (x - x_{n-1})b_n)) \cdots)$$

Por ejemplo, para $n = 3$:

$$\begin{aligned} P_3(x) &= b_0 + b_1(x - x_0) + b_2(x - x_0)(x - x_1) + b_3(x - x_0)(x - x_1)(x - x_2) \\ &= b_0 + (x - x_0)[b_1 + (x - x_1)[b_2 + (x - x_2)b_3]] \end{aligned}$$

1.3. Fórmula de Aitken-Neville. Para calcular el valor del polinomio interpolante en un punto x no es necesario el cálculo de todo el polinomio $P_n(x)$. Para este fin vamos a desarrollar el algoritmo de Aitken-Neville.
Sea $P_{j,k}$ el polinomio interpolante de grado no mayor que k que pasa por los puntos $(x_{j-k}, f_{j-k}), \ldots, (x_j, f_j) \in \{(x_j, f_j)\}_{j=0}^{n}$. Se tiene:

$$P_{j,k}(x_i) = f_i, \quad i = j - k, \ldots, j$$

Por ejemplo: $P_{5,2}$ es el polinomio interpolante de grado no mayor que 2, que pasa por los puntos $(x_3, f_3), (x_4, f_4), (x_5, f_5)$.
Con esta notación $P_{n,n}$ es el polinomio P_n que pasa por los puntos $(x_0, f_0), \ldots, (x_n, f_n)$.

TEOREMA 6.3. *Sea $P_{j,k}$ el polinomio interpolante que pasa por los puntos $(x_{j-k}, f_{j-k}), \ldots, (x_j, f_j) \in \{(x_j, f_j)\}_{j=0}^{n}$. Entonces este polinomio puede ser evaluado en un punto t recursivamente por:*

$$P_{j,0}(t) = f_j$$

para $j = 0, 1, \ldots, n$, y

$$P_{j,k}(t) = \frac{(t - x_{j-k})P_{j,k-1}(t) - (t - x_j)P_{j-1,k-1}(t)}{x_j - x_{j-k}},$$

para $k = 1, 2, \ldots, j$, $j = 1, 2, \ldots, n$.

DEMOSTRACIÓN. Por inducción sobre k:
Para $k = 1$:

$$\begin{aligned} P_{j,1}(t) &= \frac{(t - x_{j-1})f_j - (t - x_j)f_{j-1}}{x_j - x_{j-1}} \\ &= \frac{(t - x_{j-1})P_{j,0}(t) - (t - x_j)P_{j-1,0}(t)}{x_j - x_{j-1}} \end{aligned}$$

pasa por $(x_{j-1}, f_{j-1}), (x_j, f_j)$. Supongamos que la fórmula es correcta para $k = m$. Se tiene que probar que

$$P_{j,m+1}(t) = \frac{(t - x_{j-m-1})P_{j,m}(t) - (t - x_j)P_{j-1,m}(t)}{x_j - x_{j-m-1}}$$

cumple las condiciones interpolantes:

$$P_{j,m+1}(x_i) = f_i, \quad i = j - m - 1, \ldots, j$$

Se tiene:

$$\begin{aligned} &P_{j,m}(x_i) = f_i, \quad i = j - m, \ldots, j; \quad j - m \leq i \leq j - 1 \\ &P_{j-1,m}(x_i) = f_i, \quad i = j - m - 1, \ldots, j - 1 \end{aligned}$$

Luego para $i = j - m, \ldots, j - 1$:

$$P_{j,m+1}(x_i) = \frac{(x_i - x_{j-m-1})f_i - (x_i - x_j)f_i}{x_j - x_{j-m-1}} = f_i$$

También:

$$\begin{aligned} &P_{j+1,m}(x_{j-m-1}) = f_{j-m-1} \\ &P_{j-1,m}(x_j) = f_j \end{aligned}$$

□

Podemos calcular $P_{n,n}(t)$ con el esquema:

x_0	$f_0 := P_{0,0}(t)$				
		$P_{1,1}(t)$			
x_1	$f_1 := P_{1,0}(t)$		$P_{2,2}(t)$		
		$P_{2,1}(t)$			
x_2	$f_2 := P_{2,0}(t)$			$\ddots$	
$\vdots$	$\vdots$				$P_{n,n}(t)$
x_{n-1}	$f_{n-1} := P_{n-1,0}(t)$				
		$P_{n-1,1}(t)$			
x_n	$f_n := P_{n,0}(t)$				

Damos el algoritmo de Aitken-Neville:

Entrada: $x_0, \ldots, x_k, f_0, \ldots, f_k, t$		
Tomar $r_j := t - x_j, \quad j = 0, \ldots, n$		
Hacer $d_j := f_j, \quad j = 0, \ldots, n$		
Para $k = 1, \ldots, n$		
	Para $j = 0, \ldots, n-k$	
		$d_j := \dfrac{r_j d_{j+1} - r_{j+k} d_j}{x_{j+k} - x_k}$
Salida: $d_0 := P_{n,n}(t)$		

1.4. Error del polinomio interpolante. Suponemos que utilizamos un polinomio para aproximar los valores de otra función, lo suficientemente *suave*. ¿Cuál es el error de la aproximación realizada?

TEOREMA 6.4. *Sea $f \in C^{(n+1)}[a,b]$ con $\{x_i\}_{i=0}^n \subset [a,b]$ y $x_i \neq x_j$ para $i \neq j$. Sea P_n el polinomio interpolante con $P_n(x_i) = f(x_i)$, $i = 0, 1, \ldots, n$. Entonces para cada $x \in [a,b]$, existe un número $\xi \in]\min\{x, x_0, \ldots, x_n\}, \max\{x, x_0, \ldots, x_n\}[= I$ con*

$$f(x) - P_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \prod_{k=0}^{n} (x - x_k)$$

DEMOSTRACIÓN. Para $x = x_k, \quad k = 0, 1, \ldots, n$, resulta $f(x_k) = P_n(x_k)$. Definamos la función $w_n(x) := \prod_{k=0}^{n} (x - x_k)$, y tomemos además $x \in [a,b]$ tal que $x \neq x_k, \quad k = 0, 1, \ldots, n$.
Consideremos la función

$$\phi(t) := f(t) - P_n(t) - \frac{f(x) - P_n(x)}{w_n(x)} w_n(t),$$

se cumple que $\phi \in C^{(n+1)}[a,b], \quad \phi(x) = 0, \quad \phi(x_i) = 0, \quad i = 0, 1, \ldots, n$ (pues $w_n(x_i) = 0$). Entonces ϕ tiene por lo menos $(n+2)$ ceros distintos en el intervalo $[a,b]$, los cuales son $x, x_0, \ldots, x_n$. Por una extensión del teorema de Rolle se obtiene que existe $\xi \in I$ tal que $\phi^{(n+1)}(\xi) = 0$ o

$$f^{(n+1)}(\xi) - \frac{f(x) - P_n(x)}{w_n(x)} (n+1)! = 0$$

de donde

$$f(x) - P_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \prod_{k=0}^{n} (x - x_k)$$

□

1.5. Diferenciación numérica. Fórmulas de diferencias: Sean $(x_i, f_i), \quad i = 0, 1, \ldots, n$ puntos interpolantes. De la fórmula de Lagrange:

$$P_n(x) = \sum_{j=0}^{n} f_j \alpha_j \prod_{\substack{k=0 \\ k \neq j}}^{n} (x - x_k)$$

con $\alpha_j = \prod_{\substack{k=0 \\ k \neq j}}^{n} \frac{1}{x_j - x_k}$.
Se obtiene:

$$\frac{d^n P_n}{dx^n}(x) = \sum_{j=0}^{n} f_j \alpha_j n! \approx f^{(n)}(x)$$

que podría ser una posible aproximación de la n-ésima derivada $f^{(n)}$.

TEOREMA 6.5. *Sea $f \in C^{(n+1)}[a,b]$ con $a = \min\{x_0,\ldots,x_n\}$ y $b = \max\{x_0,\ldots,x_n\}$ con $x_{j+1} = x_j + h$ ($h > 0$, constante). Entonces existe $\xi \in]a,b[$ tal que*

$$f^{(n)}(\xi) = \sum_{j=0}^{n} f_j \frac{(-1)^{n-j}}{h^n} \binom{n}{j}$$

DEMOSTRACIÓN. Sea $g(x) = f(x) - P_n(x)$, P_n el polinomio interpolante para $f(x)$ en $(x_0,f_0),\ldots,(x_n,f_n)$. Entonces g tiene $n+1$ ceros $x_0, x_1, \ldots, n$. Luego, por una variante del teorema de Rolle, existe $\xi \in]a,b[$ tal que

$$g^{(n)}(\xi) = f^{(n)}(\xi) - P_n^{(n)}(\xi) = 0$$

Se cumple:

$$\begin{aligned}\alpha_j &= \prod_{\substack{k=0\\k\neq j}}^{n} \frac{1}{x_j - x_k} = \frac{1}{(-1)^{n-j}h^n[j\cdot(j-1)\cdots 1][1\cdot 2\cdots(n-j)]} \\ &= \frac{(-1)^{n-j}}{h^n\, n!}\binom{n}{j}\end{aligned}$$

entonces

$$\frac{d^n P_n}{dx^n}(x) = \frac{1}{h^n}\left[(-1)^n f_0 + (-1)^{n-1}\binom{n}{1} f_1 + (-1)^{n-2}\binom{n}{2} f_2 + \cdots - \binom{n}{n-1} f_{n-1} + f_n\right]$$

Para $n = 1, 2, 3$:

$$\begin{aligned} f'(x) &\approx \frac{f_1 - f_0}{h} \\ f''(x) &\approx \frac{f_2 - 2f_1 + f_0}{h^2} \\ f'''(x) &\approx \frac{f_3 - 3f_2 + 3f_1 - f_0}{h^3}. \end{aligned}$$

□

1.6. Método de Romberg. Este método para diferenciación numérica fue creado por el matemático alemán W. Romberg en el año 1955.
Sea $f : \mathbb{R} \to \mathbb{R}$, y definamos el cociente:

$$\varphi(h) := \delta_h f(x_0) = \frac{1}{2h}[f(x_0 + h) - f(x_0 - h)]$$

se cumple que

$$\lim_{h\to 0} \varphi(h) = \lim_{h\to 0} \delta_h f(x_0) = f'(x_0)$$

La idea principal del método de Romberg es la extrapolación de φ como función de h a través de interpolación polinomial y los puntos de partición $h_0, h_0/2, h_0/4, \ldots, h_0/2^n$, en el punto $h = 0$. Para este objetivo se utilizan las fórmulas de Aitken-Neville.

EJEMPLO 6.2. $f(x) = \tan(x), \quad x_0 = 0{,}5.$

$$\varphi(h) := \delta_h f(0{,}5) = \frac{1}{2h}[\tan(0{,}5 + h) - \tan(0{,}5 - h)]$$

Algoritmo de Romberg:

Entrada:	$n, h_0, x_0, \varphi(h) = \delta_h f(x_0)$
Para $j = 0,\ldots,n$	
	$r_j := -h_0/2^{n-j}$ $d_j := \varphi(h_0/2^{n-j})$
Para $k = 1,\ldots,n$	
	Para $j = 0,\ldots,(n-k)$
	$d_j := \dfrac{r_j d_{j+1} - r_{j+k} d_j}{r_j - r_{j+k}}$
Salida:	d_0, aproximación de $f'(x_0)$

1.7. Interpolación de Hermite. Ahora exigimos que el polinomio interpolante , además de pasar por algunos puntos, tenga que cumplir condiciones paa sus derivadas. En este caso se habla de *interpolación de Hermite*.

TEOREMA 6.6. *Dados los puntos interpolantes* $x_0, x_1, \ldots, x_n$, *consideremos* $m_0, m_1, \ldots, m_n \in \mathbb{N}$ *con* $\sum_{i=0}^{n} m_i = m+1$ *y* $f_i^{(k)} \in \mathbb{R}$ *para* $k = 0, \ldots, m_i - 1, \quad i = 0, \ldots, n$. *Entonces existe un único polinomio interpolante* P_m *de grado no mayor a* m *tal que*

$$P_m^{(k)}(x_i) = f_i^{(k)}$$

para $k = 0, 1, \ldots, m_i - 1, \quad i = 0, 1, \ldots, n$.

DEMOSTRACIÓN. Se tienen $\sum_{i=0}^{n} m_i = m+1$ condiciones interpolantes para los $(m+1)$ coeficientes del polinomio, esto es, se tienen $(m+1)$ ecuaciones lineales para las $(m+1)$ incógnitas.
Basta mostrar que el sistema homogéneo tiene solamente la solución trivial. Cuando P_m es un polinomio con $P^{(k)}(x_i) = 0$, para $k = 0, 1, \ldots, m_i - 1$, $i = 0, \ldots, n$ se tiene que P_m tiene el punto interpolante x_i como m_i-múltiple cero. Esto implica que P_m tiene por lo menos $\sum_{i=0}^{n} m_i = m+1$ ceros, de donde $P_m \equiv 0$. □

1.7.1. Interpolación de Hermite con polinomios de Lagrange. Trataremos ahora un caso especial de la interpolación de Hermite, en el caso en que las condiciones de interpolación se dan para el polinomio y sus derivadas en todos los nodos considerados.

TEOREMA 6.7. *Dados* $x_0, \ldots, x_n, f_0, \ldots, f_n, f_0', \ldots, f_n'$. *Entonces el único polinomio* P_{2n+1} *de grado no mayor que* $(2n+1)$ *con*

$$\begin{aligned} P_{2n+1}(x_i) &= f_i \\ P'_{2n+1}(x_i) &= f_i', \qquad i = 0, \ldots, n, \end{aligned}$$

tiene la forma

$$P_{2n+1}(x) = \sum_{j=0}^{n} f_j L_j^2(x)(c_j(x) + d_j) + f_j' L_j^2(x)(x - x_j),$$

con

$$c_j = -2 \sum_{\substack{k=0 \\ k \neq j}}^{n} \frac{1}{x_j - x_k}, \quad d_j = 1 - c_j x_j, \quad j = 0, \ldots, n.$$

DEMOSTRACIÓN. Sea $P_{2n+1}(x) = \sum_{j=0}^{n} f_j g_j(x) + f_j' h_j(x)$. Determinemos los polinomios g_j y h_j de grado no mayor que $(2n+1)$ de modo que

$$g_j(x_i) = \begin{cases} 1, & i = j \\ 0, & i \neq j \end{cases} \qquad h_j(x_i) = 0, \quad i, j = 0, \ldots, n$$

$$g_j'(x_i) = 0, \quad i, j = 0, \ldots, n \qquad h_j'(x_i) = \begin{cases} 1, & i = j \\ 0, & i \neq j \end{cases}$$

Definiendo

$$h_j(x) := L_j^2(x)(x - x_j), \text{ donde } L_j(x) = \prod_{\substack{k=0 \\ k \neq j}}^{n} \frac{x - x_k}{x_j - x_k},$$

se cumplen:

i) h_j tiene grado $2n+1$.
ii) $h_j(x_i) = 0, \quad i,j = 0,\ldots,n.$
iii) $h_j'(x) = 2L_j(x)L_j'(x)(x-x_j) + L_j^2(x)$, de donde
$$h_j'(x_i) = 2L_j(x_i)L_j'(x)(x_i - x_j) + L_j^2(x_i) = \begin{cases} 1, & i = j \\ 0, & i \neq j \end{cases}$$

Definiendo
$$g_j(x) := L_j^2(x)(c_j x + d_j), \quad j = 0,\ldots,n,$$
con c_j, d_j constantes, se cumple:

i) g_j tiene grado no mayor que $2n+1$.
ii) $g_j(x_i) = 0$ para $i \neq j$
iii) $g_j'(x) = 2L_j(x)L_j'(x)(c_j x + d_j) + c_j L_j^2(x)$, entonces
$g_j'(x_i) = 2L_j(x_i)L_j'(x_i)(c_j x_i + d_j) + c_j L_j^2(x_i) = 0, \quad i \neq j$

Las constantes c_j y d_j se determinan de las ecuaciones:
$$g_j(x_j) = 1 \quad \text{y} \quad g_j'(x_j) = 0.$$

Como $g_j'(x_j) = 2L_j'(x_j) + c_j = 0$ y del hecho que $L_j'(x_j) = \sum_{\substack{k=0 \\ k\neq j}}^{n} \frac{1}{x_j - x_k}$, se obtienen:

$$c_j = -2\sum_{\substack{k=0 \\ k\neq j}}^{n} \frac{1}{x_j - x_k} \quad \text{y} \quad d_j = 1 - c_j x_j, \quad j = 0,\ldots,n.$$

□

1.7.2. Interpolación de Hermite por diferencias divididas de Newton. Dos puntos interpolantes x_k y $x_{k+1} := x_k + h$ para $h \to 0$ son iguales. Por ello definimos para la primera diferencia dividida de Newton:
$$f[x_k, x_k] = \lim_{h\to 0} \frac{f[x_{k+1}] - f[x_k]}{x_{k+1} - x_k} = f'(x_k).$$

Para tres puntos equidistantes x_k, $x_{k+1} := x_k + h$, $x_{k+2} := x_k + 2h$ definimos para $h \to 0$ la segunda diferencia dividida:
$$\begin{aligned} f[x_k, x_k, x_k] &= \lim_{h\to 0} \frac{f[x_{k+1}, x_{k+2}] - f[x_k, x_{k+1}]}{x_{k+2} - x_k} \\ &= \lim_{h\to 0} \frac{\dfrac{f[x_{k+2}] - f[x_{k+1}]}{h} - \dfrac{f[x_{k+1}] - f[x_k]}{h}}{2h} = \frac{1}{2} f''(x_k). \end{aligned}$$

De manera análoga se define para $(n+1)$ puntos interpolantes:
$$f[x_k, x_k, \ldots, x_k] = \frac{1}{n!} f^{(n)}(x_k), \quad n = 1, 2, \ldots$$

Utilizando estas definiciones se puede calcular el polinomio de Hermite a través del esquema de las diferencias divididas.

Ejemplo 6.3. Dados los datos:

x_i	x_0	x_1
f_i	f_0	f_1
f_i'	f_0'	f_1'
f_i''	f_0''	f_1''

Tenemos 6 condiciones interpolantes. Se está buscando un polinomio de grado 5: $P_5(x)$.

x	$f[x]$	$f[x,x]$	$f[x,x,x]$	$f[x,x,x,x]$	$f[x,x,x,x,x]$	$f[x,x,x,x,x,x]$
x_0	$f[x_0]$					
		$f'(x_0)$				
x_0	$f[x_0]$		$\frac{1}{2}f''(x_0)$			
		$f'(x_0)$		$f[x_0,x_0,x_0,x_1]$		
x_0	$f[x_0]$		$f[x_0,x_0,x_1]$		$f[x_0,x_0,x_0,x_1,x_1]$	
		$f[x_0,x_1]$		$f[x_0,x_0,x_1,x_1]$		$f[x_0,x_0,x_0,x_1,x_1,x_1]$
x_1	$f[x_1]$		$f[x_0,x_1,x_1]$		$f[x_0,x_0,x_1,x_1,x_1]$	
		$f'(x_1)$		$f[x_0,x_1,x_1,x_1]$		
x_1	$f[x_1]$		$\frac{1}{2}f''(x_1)$			
		$f'(x_1)$				
x_1	$f[x_1]$					

Entonces

$P_5(x) = b_0+b_1(x-x_0)+b_2(x-x_0)^2+b_3(x-x_0)^3+b_4(x-x_0)^3(x-x_1)+b_5(x-x_0)^3(x-x_1)^2$

donde los b_i, $\quad i = 0,\ldots,5$ son los valores de la primera línea oblicua.

2. Splines cúbicos

Dados los puntos interpolantes $a = x_0 < x_1 < \ldots < x_m = b$ en el intervalo $[a,b]$ con los valores correspondientes $f_0, f_1, \ldots, f_m$ utilizando la interpolación por Splines cúbicos, se unen los puntos $(x_0,f_0),\ldots,(x_m,f_m)$ obteniendo una función spline cúbico S^3_Δ, tal que:

a) S^3_Δ es un polinomio de grado 3 en cada intervalo $[x_j,x_{j+1}]$, $(j = 0,1,\ldots,m-1)$.
b) $S^3_\Delta(x_j) = f_j$, $j = 0,1,\ldots,m$.
c) $S^3_\Delta \in C^2[a,b]$.

2.0.1. Construcción de S^3_Δ. La condición (a) implica que S^3_Δ se escribe como

$$S^3_\Delta(x) = P_j(x), \quad x_j \le x \le x_{j+1}, \quad j = 0,1,2,\ldots,m-1$$

donde

$$P_j(x) = a_j + b_j(x-x_j) + c_j(x-x_j)^2 + d_j(x-x_j)^3,$$

$x_j \le x \le x_{j+1}$, $j = 0,1,\ldots,m-1$; lo cual implica que requerimos $4m$ coeficientes. La condición (b) de interpolación nos da $m+1$ ecuaciones:

$$P_j(x_j) = f_j, \quad j = 0,1,\ldots,m.$$

Las condiciónes de continuidad sobre S^3_Δ, $(S^3_\Delta)'$ y $(S^3_\Delta)''$ (condición (c)) nos dan $3(m-1)$ ecuaciones:

$$\begin{aligned} P_{j-1}(x_j) &= P_j(x_j),\\ P'_{j-1}(x_j) &= P'_j(x_j),\\ P''_{j-1}(x_j) &= P''_j(x_j), \quad j = 1,\ldots,m-1. \end{aligned}$$

Tenemos entonces un total de $m+1+3(m-1) = 4m-2$ condiciones y $4m$ incógnitas. Agregamos entonces 2 condiciones más.
Se puede exigir

$$(S^3_\Delta)''(x_0) = 0 = (S^3_\Delta)''(x_m), \tag{15}$$

obteniendo en este caso el spline natural.
Para la interpolación de una función periódica se podría exigir

$$(S^3_\Delta)'(x_0) = (S^3_\Delta)'(x_m), \quad (S^3_\Delta)''(x_0) = (S^3_\Delta)''(x_m).$$

Otra posibilidad es

$$S^3_\Delta(x_0) = m_0 \ \text{ y } \ S^3_\Delta(x_m) = m_1,$$

donde los números m_0 y m_1 son dados.
De (15) se obtiene

$$P_0''(x_0) = 0, \quad P_{m-1}''(x_m) = 0. \tag{16}$$

Necesitamos las derivadas de P_k

$$\begin{aligned} P_k'(x) &= b_k + 2c_k(x - x_k) + 3d_k(x - x_k)^2 \\ P_k''(x) &= 2c_k + 6d_k(x - x_k), \qquad\qquad x_k \le x \le x_{k+1}, \quad k = 0, \ldots, m-1. \end{aligned}$$

De la continuidad de $(S_\Delta^3)''$, tenemos

$$2c_{j-1} + 6d_{j-1}(x_j - x_{j-1}) = P_{j-1}''(x_j) = P_j''(x_j) = 2c_j$$

y luego

$$2c_j = 2c_{j-1} + 6d_{j-1}(x_j - x_{j-1}).$$

Haciendo $h_j = x_{j+1} - x_j$ obtenemos

$$c_j = c_{j-1} + 3d_{j-1}h_j$$

esto es,

$$d_j = \frac{c_{j+1} - c_j}{3h_j}, \quad j = 0, 1, 2, \ldots, m-2, m-1. \tag{17}$$

De las condiciones de interpolación

$$a_j = P_j(x_j) = f_j, \quad j = 0, 1, \ldots, m. \tag{18}$$

y de la continuidad de S_Δ^3:

$$a_j = P_j(x_j) = P_{j-1}(x_j) = a_{j-1} + b_{j-1}(x_j - x_{j-1}) + c_{j-1}(x_j - x_{j-1})^2 + d_{j-1}(x_j - x_{j-1})^3,$$

esto es,

$$a_j = a_{j-1} + b_{j-1}h_{j-1} + c_{j-1}h_{j-1}^2 + d_jh_{j-1}^3, \quad j = 1, \ldots, m$$

de donde

$$b_j = \frac{a_{j+1} - a_j}{h_j} - h_j(c_j + h_jd_j), \quad j = 0, 1, \ldots, m-1.$$

Reemplazando (17) y (18) en la anterior expresión

$$b_j = \frac{f_{j+1} - f_j}{h_j} - \frac{h_j}{3}(c_{j+1} + 2c_j), \quad j = 0, \ldots, m-1. \tag{19}$$

Ahora de la continuidad de $(S_\Delta^3)'$ tenemos

$$b_j = P_j'(x_j) = P_{j-1}'(x_j) = b_{j-1} + 2c_{j-1}(x_j - x_{j-1}) + 3d_{j-1}(x_j - x_{j-1})^2, \quad j = 1, \ldots, m-1$$

o bien

$$b_j - b_{j-1} - 2c_{j-1}h_{j-1} = 3d_{j-1}h_{j-1}^2.$$

Reemplazando (17) y (19) se obtiene

$$\frac{f_{j+1} - f_j}{h_j} - \frac{h_j}{3}(c_{j+1} + 2c_j) - \frac{f_j - f_{j-1}}{h_{j-1}} + \frac{h_{j-1}}{3}(c_j + 2c_{j-1}) = h_{j-1}(c_j + c_{j-1}), \quad j = 1, \ldots, m-1.$$

De este modo

$$h_{j-1}c_{j-1} + 2(h_{j-1} + h_j)c_j + h_jc_{j+1} = g_j, \quad j = 1, \ldots, m-1$$

donde

$$g_j = 3\frac{f_{j+1} - f_j}{h_j} - 3\frac{f_j - f_{j-1}}{h_{j-1}}, \quad j = 1, \ldots, m-1. \tag{20}$$

Los g_j son conocidos. Entonces (20) es un sistema lineal de $(m-1)$ ecuaciones con $(m+1)$ incógnitas $c_0, c_1, \ldots, c_m$. Este sistema lineal sirve generalmente para splines cúbicos.

Veamos el caso de los splines naturales:

$$\begin{aligned} P_0''(x_0) &= 2c_0 = 0 \text{ de donde } c_0 = 0 \\ P_{m-1}''(x_m) &= 2c_{m-1} + 6d_{m-1}(x_m - x_{m-1}) = 0 \\ &= 2c_{m-1} + 6\frac{c_m - c_{m-1}}{3h_m}h_m \\ &= 2c_m = 0 \text{ de donde } c_m = 0 \end{aligned}$$

Dado que $c_0 = 0 = c_m$, el sistema anterior se reduce a un sistema de $(m-1)$ ecuaciones con $(m-1)$ incógnitas $c_1, \ldots, c_{m-1}$:

$$\begin{bmatrix} 2(h_0+h_1) & h_1 & & & 0 \\ h_1 & 2(h_1+h_2) & h_2 & & \\ & h_2 & & \ddots & \\ & & \ddots & & h_{m-2} \\ 0 & & & h_{m-2} & 2(h_{m-2}+h_{m-1}) \end{bmatrix} \begin{bmatrix} c_1 \\ c_2 \\ \\ \vdots \\ c_{m-1} \end{bmatrix} = \begin{bmatrix} g_1 \\ g_2 \\ \\ \vdots \\ g_{m-1} \end{bmatrix}$$

el cual tiene la forma $Ac = g$.

Ejemplo 6.4. Construímos la función interpolante spline cúbico para los datos:

j	0	1	2	3	4
x_j	-1	$-0{,}5$	0	0,5	1
f_j	0,5	0,8	1	0,8	0,5

Aquí $h_j = x_{j+1} - x_j = 0{,}5$; y el sistema de ecuaciones lineales es (asumiendo $c_0 = 0 = c_4$):

$$\begin{aligned} 2c_1 + 0{,}5c_2 &= -0{,}6 \\ 0{,}5c_1 + 2c_2 + 0{,}5c_3 &= -2{,}4 \\ 0{,}5c_2 + 2c_3 &= -0{,}6 \end{aligned}$$

el cual tiene como solución:

$$c_1 = 0, \quad c_2 = -1{,}2, \quad c_3 = 0.$$

De esta manera obtenemos los coeficientes:

$$\begin{array}{llll} b_0 = 0{,}6 & b_1 = 0{,}6 & b_2 = 0 & b_3 = -0{,}6 \\ d_0 = 0 & d_1 = -0{,}8 & d_2 = 0{,}8 & d_3 = 0 \end{array}$$

y formamos

$$S_\Delta^3(x) = \begin{cases} P_0(x), & x_0 \le x \le x_1 \\ P_1(x), & x_1 \le x \le x_2 \\ P_2(x), & x_2 \le x \le x_3 \\ P_3(x), & x_3 \le x \le x_4 \end{cases}$$

$$S_\Delta^3(x) = \begin{cases} 0{,}5 + 0{,}6(x+1), & -1 \le x \le -0{,}5 \\ 0{,}8 + 0{,}6(x+0{,}5) - 0{,}8(x+0{,}5)^3, & -0{,}5 \le x \le 0 \\ 1 - 1{,}2x^2 + 0{,}8x^3, & 0 \le x \le 0{,}5 \\ 0{,}8 - 0{,}6(x-0{,}5), & 0{,}5 \le x \le 1 \end{cases}$$

Para probar el resultado, veamos que

$$S_\Delta^3(0{,}8) = 0{,}62 \quad \text{y} \quad f(0{,}8) = 0{,}61.$$

Además se cumple

$$\max_{x\in[a,b]} \left|f(x) - S_\Delta^3(x)\right| \le Kh^4 \max_{x\in[a,b]} \left|f^{(4)}(x)\right|.$$

3. Interpolación trigonométrica

DEFINICIÓN. *Sea $n \in \mathbb{N}$, entonces el conjunto*

$$T_n := \Big\{ \sum_{j=0}^{n} c_j e^{ijx},\ c_j \in \mathbb{C},\ j = 0, 1, \ldots, n \Big\}$$

es denominado el conjunto de los polinomios trigonométricos complejos de grado menor o igual a n.

Para la interpolación: tenemos los puntos de partición $x_0, x_1, \ldots, x_{n-1} \in [0, 2\pi[$ con $x_k \neq x_j$ para $k \neq j$ y los valores correspondientes $f_0, f_1, \ldots, f_{n-1} \in \mathbb{C}$. Buscamos un polinomio $p \in T_{n-1}$ tal que $p(x_k) = f_k$, $k = 0, \ldots, n-1$.

TEOREMA 6.8. *Sean $(x_k, f_k) \in [0, 2\pi[\times \mathbb{C}$, $k = 0, \ldots, n-1$ con $x_k \neq x_j$ para $k \leq j$; entonces existe un único polinomio trigonométrico $P \in T_{n-1}$ tal que $P(x_k) = f_k$, $k = 0, \ldots, n-1$.*

DEMOSTRACIÓN. Sea

$$P(x) = \sum_{j=0}^{n-1} c_j e^{ijx}.$$

Exigiendo: $P(x_k) = f_k$, $k = 0, \ldots, n-1$ se obtiene el siguiente sistema lineal de ecuaciones:

$$\sum_{j=0}^{n-1} c_j e^{ijx_k} = f_k, \quad k = 0, \ldots, n-1.$$

Este sistema tendrá solución única si y solamente si el sistema homogéneo asociado tiene solamente la solución trivial.
Tenemos que probar que si

$$\sum_{j=0}^{n-1} c_j e^{ijx_k} = 0,\ k = 0, \ldots, n-1 \quad \text{entonces} \quad c_j = 0,\ j = 0, \ldots, n-1.$$

Definimos $z_k = e^{ix_k}$, $k = 0, 1, \ldots, n-1$. Se cumple que los z_k son puntos distintos de la circunferencia unitaria del plano complejo, y

$$\sum_{j=0}^{n-1} c_j e^{ijx_k} = \sum_{j=0}^{n-1} c_j z_k^j.$$

Definiendo $Q_{n-1}(z) := \sum_{j=0}^{n-1} c_j z^j$, tenemos que Q_{n-1} es un polinomio complejo de grado menor o igual a $(n-1)$ y

$$Q_{n-1}(z_k) = 0, \quad k = 0, 1, \ldots, n-1;$$

esto es, Q_{n-1} tiene n ceros. Esto implica que necesariamente $Q_{n-1}(z) = 0$, para todo $z \in \mathbb{C}$; de donde $c_j = 0$, $j = 0, 1, \ldots, n-1$. □

DEFINICIÓN. *Sea $n \in \mathbb{N}$. Entonces se define*

$$T_n^{\mathbb{R}} := \{ \frac{a_0}{2} + \sum_{j=1}^{n} (a_j \cos jx + b_j \operatorname{sen} jx) \,/\, a_o, a_j, b_j \in \mathbb{R},\ j = 1, \ldots, n \}$$

como el conjunto de polinomios trigonométricos reales de grado menor o igual a n.

TEOREMA 6.9. *Sean los puntos* $(x_k, g_k) \in [0, 2\pi[\times\mathbb{R}$, $k = 0, \ldots, 2n$ *con* $x_k \neq x_j$ *para* $k \leq j$. *Sea* $P(x) = \sum_{j=0}^{2n} c_j e^{ijx}$ *el polinomio trigonométrico complejo único de grado menor o igual a* $2n$ *con* $P(x_k) = e^{inx_k} g_k$, $k = 0, 1, \ldots, 2n$. *Entonces existe un polinomio trigonométrico real único* $q \in T_n^{\mathbb{R}}$ *tal que* $q(x_k) = g_k$, $k = 0, 1, \ldots, 2n$. *Este polinomio tiene la forma*

$$q(x) = \frac{1}{2}a_0 + \sum_{j=1}^{n}(a_j \cos jx + b_j \operatorname{sen} jx)$$

donde $a_0 = 2c_n$, $a_j = 2\,\Re(c_{n-j})$, $b_j = 2\Im(c_{n-j})$; $j = 1, \ldots, n$.

DEMOSTRACIÓN. Definimos $\tilde{P} \in T_{2n}$ por

$$\tilde{P}(x) = e^{2inx}\overline{P(x)} = e^{2inx}\sum_{j=0}^{2n}\overline{c_j}e^{-ijx} = \sum_{j=0}^{2n}\overline{c_j}e^{(2n-j)ix} = \sum_{j=0}^{2n}\overline{c_j}e^{jix} \tag{21}$$

Se cumple

$$\begin{aligned}\tilde{P}(x_k) &= e^{2inx_k}\overline{P(x_k)} = e^{2inx_k}\overline{P(x_k)} \\ &= e^{2inx_k}\overline{e^{inx_k}g_k} = e^{2inx_k}e^{-inx_k}g_k = e^{inx_k}g_k = P(x_k)\end{aligned}$$

$\tilde{P}$ cumple las mismas condiciones interpolantes que P. Entonces por la unicudad de P y (21) se obtiene que

$$c_j = \overline{c_{2n-j}},\ j = 0, \ldots, 2n \quad \text{implica} \quad c_{n+j} = \overline{c_{n-j}},\ j = 0, \ldots, n.$$

Luego $c_n = \overline{c_n}$, de donde c_n es real. Además

$$\begin{aligned}e^{-inx}P(x) &= e^{-inx}\sum_{j=0}^{2n}c_j e^{ijx} = \sum_{j=0}^{2n}c_j e^{(j-n)ix} = c_n + \sum_{j=1}^{n}[c_{n-j}e^{-jix} + c_{n+j}e^{ijx}] \\ &= c_n + \sum_{j=1}^{n}[c_{n-j}(\cos jx - i\operatorname{sen} jx) + c_{n+j}(\cos jx + i\operatorname{sen} jx)] \\ &= c_n + \sum_{j=1}^{n}[(c_{n-j} + \overline{c_{n-j}})\cos jx + i(-c_{n-j} + \overline{c_{n-j}})\operatorname{sen} jx] \\ &= \underbrace{c_n}_{a_0/2} + \sum_{j=1}^{n}[\underbrace{2\Re(c_{n-j})}_{a_j}\cos jx + \underbrace{2\Im(c_{n-j})}_{b_j}\operatorname{sen} jx]\end{aligned}$$

Sea $\hat{q}(x) = e^{-inx}P(x)$, entonces $\hat{q}(x_k) = e^{-inx_k}P(x_k) = e^{-inx_k}e^{inx_k}g_k = g_k$ y por tanto $q(x) = \hat{q}(x)$. □

3.1. Puntos de partición equidistantes.

LEMA 6.10. *Sea* $N \in \mathbb{N}$, $W_N = e^{2\pi i/N}$. *Entonces*

$$\frac{1}{N}\sum_{j=0}^{N-1}(W_N^{k-l})^j = \delta_{kl} = \begin{cases} 1, & k = l \\ 0, & k \neq l \end{cases}, \quad 0 \leq k, l \leq N-1.$$

DEMOSTRACIÓN. Para $l = k$, $0 \leq l, k \leq N$ se tiene $\frac{1}{N}\sum_{j=0}^{N-1}(W_N^0)^j = 1$.

Para $l \neq k$, $0 \leq l, k \leq N-1$, se tiene: $W_N^{k-l} = e^{\frac{2\pi}{N}(k-l)i} \neq 1$,

$$\begin{aligned}\frac{1}{N}\sum_{j=0}^{N-1}(W_N^{k-l})^j &= \frac{1}{N}\frac{1-W_N^{(k-l)N}}{1-W_N^{(k-l)}} = \frac{1}{N}\frac{1-e^{\frac{2\pi i}{N}(k-l)N}}{1-e^{\frac{2\pi i}{N}(k-l)}} \\ &= \frac{1}{N}\frac{1-e^{2(k-l)\pi i}}{1-W_N^{(k-l)}} = \frac{1}{N}\frac{(1-1)}{1-W_N^{(k-l)}} = 0.\end{aligned}$$

□

TEOREMA 6.11. *Para $N \in \mathbb{N}$, sea $W_N = e^{2\pi i/N}$, y sean dados los puntos de partición equidistantes $x_k = \frac{2\pi k}{N}$, $k = 0, 1, \ldots, N-1$ y sus valores correspondientes $f_k \in \mathbb{C}$, $k = 0, 1, \ldots, N-1$. Entonces el único polinomio complejo $P \in T_{n-1}$ con $P(x_k) = f_k$, $k = 0, 1, \ldots, N-1$ está dado por:*

$$P(x) = \sum_{j=0}^{N-1} c_j e^{ijx} \text{ con } c_j = \frac{1}{N}\sum_{k=0}^{N-1} W_N^{-jk} f_k, \quad j = 0, \ldots, N-1.$$

DEMOSTRACIÓN. La unicidad se tiene por el teorema 6.8. Falta mostrar que $P(x)$ satisface las condiciones interpolantes.

$$P(x_k) = \sum_{j=0}^{N-1}\left(\frac{1}{N}\sum_{l=0}^{N-1} W_N^{-jl} f_l\right) e^{ijx_k}$$

Se cumple: $e^{ijx_k} = e^{ij\frac{2\pi k}{N}} = (e^{2\pi i/N})^{jk} = W_N^{jk}$. Luego

$$P(x_k) = \sum_{l=0}^{N-1}\left(\frac{1}{N}\sum_{j=0}^{N-1} W_N^{j(k-l)}\right) f_l = \sum_{l=0}^{N-1}\delta_{kl} f_l = f_k, \quad k = 0, 1, \ldots, N-1.$$

□

TEOREMA 6.12. *Sea $N \in \mathbb{N}$,*

$$n := \begin{cases} \frac{1}{2}(N-1), & \text{si } N \text{ es impar} \\ \frac{1}{2}N, & \text{si } N \text{ es par.} \end{cases}$$

Dados los puntos de partición $x_k = \frac{2\pi k}{N}$, con sus valores correspondientes g_k, $k = 0, 1, \ldots, N-1$. Sean

$$\begin{aligned} a_j &= \frac{2}{N}\sum_{k=0}^{N-1} g_k \cos jx_k, \\ b_j &= \frac{2}{N}\sum_{k=0}^{N-1} g_k \operatorname{sen} jx_k, \quad j = 0, 1, \ldots, n. \end{aligned}$$

Definiendo el polinomio trigonométrico real q de grado menor o igual a n

$$q(x) := \begin{cases} \frac{a_0}{2} + \sum_{j=1}^{n}(a_j \cos jx + b_j \operatorname{sen} jx), & \text{para } N = 2n+1 \\ \frac{a_0}{2} + \sum_{j=1}^{n-1}(a_j \cos jx + b_j \operatorname{sen} jx) + \frac{a_n}{2}\cos nx, & \text{para } N = 2n \end{cases}$$

Se cumple $q(x_k) = g_k$, $k = 0, 1, \ldots, N-1$.

DEMOSTRACIÓN.

a) Para $N = 2n+1$. Sea $P(x) = \sum_{j=0}^{2n} c_j e^{ijx}$ el polinomio trigonométrico complejo de grado menor o igual a $2n$, que cumple las condiciones interpolantes

$$P(x_k) = e^{inx_k} g_k =: f_k, \quad k = 0, 1, \ldots, 2n.$$

Por el teorema 6.11 se tiene: $c_j = \frac{1}{N} \sum_{k=0}^{N-1} W_N^{-jk} e^{inx_k} g_k$. Se cumple

$$\begin{aligned} c_j &= \frac{1}{N} \sum_{k=0}^{N-1} W_N^{-jk} e^{in\frac{2\pi k}{N}} g_k = \frac{1}{N} \sum_{k=0}^{N-1} W_N^{(n-j)k} g_k \\ c_{n-j} &= \frac{1}{N} \sum_{k=0}^{N-1} W_N^{-(n-j)k} e^{inx_k} g_k = \frac{1}{N} \sum_{k=0}^{N-1} [e^{\frac{2\pi i}{n}}]^{-(n-j)k} e^{in\frac{2\pi k}{n}} g_k \\ &= \frac{1}{N} \sum_{k=0}^{N-1} e^{\frac{2\pi i}{n} jk} g_k = \frac{1}{N} \sum_{k=0}^{N-1} e^{ijx_k} g_k \\ &= \frac{1}{N} \sum_{k=0}^{N-1} g_k [\cos jx_k + i \operatorname{sen} jx_k] \end{aligned}$$

Se tiene que $c_{n-j} = \Re(c_{n-j}) + i\Im(c_{n-j})$. Por el teorema 6.9, $\frac{1}{2}(a_j + i\, b_j) = \frac{1}{N} \sum_{k=0}^{N-1} g_k(\cos jx_k + i \operatorname{sen} jx_k)$. Igualando las partes real e imaginaria se concluye.

b) Caso $N = 2n$. Sea $P(x) = \sum_{j=0}^{2n-1} c_j e^{ijx}$ el polinomio trigonométrico complejo de grado menor o igual a $2n-1$, tal que

$$P(x_k) = e^{inx_k} g_k =: f_k, \quad k = 0, 1, \ldots, 2n-1.$$

[Nota: No se puede aplicar el teorema 6.9 pues exige $k = 0, \ldots, 2N$]. Definimos el polinomio $\tilde{q}$ por $\tilde{q}(x) = \Re\big(e^{-inx} P(x)\big)$, este polinomio cumple $\tilde{q}(x_k) = g_k$, $k = 0, 1, \ldots, 2n-1$. Luego

$$\tilde{q}(x) = \Re\Big(\sum_{j=0}^{2n-1} c_j e^{(j-n)ix}\Big) = \Re(c_n + \sum_{j=1}^{n-1}(c_{n-j} e^{-ijx} + c_{n+j} e^{ijx}) + c_0 e^{-inx}\Big)$$

Entonces

$$\tilde{q}(x) = \frac{1}{2}\left[c_n + \overline{c_n} + \sum_{j=0}^{n-1}[(c_{n-j} + \overline{c_{n+j}})e^{-ijx} + (c_{n+j} + \overline{c_{n-j}})e^{ijx}] + c_0^{-inx} + \overline{c_0} e^{inx}\right]$$

□

3.2. Transformada Rápida de Fourier (FFT). El cálculo de los coeficientes de los polinomios trigonométricos exige $N(N-1)$ multiplicaciones complejas, lo cual indica que el algoritmo utilizado no es muy eficiente. Aplicando la transformada rápida de Fourier (FFT) (*Fast Fourier Transform*), inventada por Cooley/Tukey (1965) se puede reducir esta cantidad de multiplicaciones para el caso $N = 2^p$ (potencia de 2) a $\frac{1}{2}NP = \frac{N}{2}\log_2 N$, lo cual es una gran mejora.

La idea es la siguiente: Se puede reducir el cálculo de un vector de una transformada discreta de Fourier calculando dos DFT's (*Discrete Fourier Transform*) de longitud media. En el caso $N = 2^p$ se puede continua este proceso hasta que se manejan en

el p-ésimo paso n DFT's de longitud 1. La DFT $F_N : \mathbb{C}^N \to \mathbb{C}^N$ es representada por la matriz $\Omega_N = (\overline{W_N}^{jk})_{0\le j,k\le N-1} \in \mathbb{C}^{N\times N}$ con $\overline{W_N} = e^{-2\pi i/N}$. Entonces se cumple

$$F_n f = \Omega_N f, \quad \text{para todo } f = (f_0, f_1, \ldots, f_{N-1}) \in \mathbb{C}^N.$$

LEMA 6.13. *Para $N \in \mathbb{N}$, sea $\Omega_N \in \mathbb{C}^{N\times N}$ definido por $\Omega_N := (\overline{W_N}^{jk})$, $0 \le j,k \le N-1$ con $\overline{W_N} = e^{-2\pi i/N}$. Para N par sea $n = \frac{1}{2}N$ y $P_N \in \mathbb{R}^{N\times N}$ la matriz de permutación $P_N := (e_1, e_3, \ldots, e_{N-1}, e_2, e_4, \ldots, e_N)^t \in \mathbb{R}^{N\times N}$; donde e_j el el j-ésimo vector canónico de $\mathbb{R}^N$. Entonces se cumple*

$$P_N\Omega_N = \begin{bmatrix} \Omega_n & 0_n \\ 0_n & \Omega_n \end{bmatrix} \begin{bmatrix} I_n & I_n \\ D_n & -D_n \end{bmatrix} = \begin{bmatrix} \Omega_n & \Omega_n \\ \Omega_n D_n & -\Omega_n D_n \end{bmatrix}$$

donde $D_n := \operatorname{diag}(\overline{W_N}^0, \overline{W_N}^1, \ldots, \overline{W_N}^{N-1})$.

DEMOSTRACIÓN. Sea $f = (f_0, \ldots, f_{N-1})^t \in \mathbb{C}^N$ y $g := \Omega_N f$ la transformada discreta de Fourier. Entonces se cumple

$$P_N\Omega_N f = P_N g = (g_0, g_2, \ldots, g_{N-2}, g_1, g_3, \ldots, g_{N-1})^t.$$

Luego la aplicación de la matriz de permutación P_N respecto al vector $g = (g_0, g_1, \ldots, g_{N-1})^t$ produce la permutación de las componentes de g.
Se cumplen:

$$\begin{array}{rcl} \overline{W_N}^{2j(n+k)} & = & \overline{W_N}^{2jn+2jk} = (\overline{W_N}^N)^j \overline{W_N}^{2jk} = (\overline{W_N}^2)^{jk} = \overline{W_n}^{jk} \\ \overline{W_N}^{(2j+1)(n+k)} & = & \overline{W_N}^{2jn+n+(2j+1)k} = \overline{W_N}^{n+(2j+1)k} = -\overline{W_N}^{(2j+1)k} \\ & = & -(\overline{W_N}^2)^{jk}\overline{W_N}^k = -\overline{W_n}^{jk}\overline{W_N}^k \end{array}$$

Para $j = 0, \ldots, n-1$ se cumple

$$\begin{array}{rcl} g_{2j} & = & \displaystyle\sum_{k=0}^{N-1} \overline{W_N}^{2jk} f_k = \sum_{k=0}^{n-1} (\overline{W_N}^2)^{jk}(f_k + f_{n+k}) = \sum_{k=0}^{n-1} \overline{W_n}^{jk}(f_k + f_{n+k}) \\ g_{2j+1} & = & \displaystyle\sum_{k=0}^{N-1} \overline{W_N}^{(2j+1)k} f_k = \sum_{k=0}^{n-1} (\overline{W_N}^2)^{jk}(f_k - f_{n+k})\overline{W_N}^k \\ & = & \displaystyle\sum_{k=0}^{n-1} \overline{W_n}^{jk}(f_k - f_{n+k})\overline{W_N}^k. \end{array}$$

□

EJEMPLO 6.5. Sean $N = 2^2 = 4$, $f = (f_0, f_1, f_2, f_3)^t \in \mathbb{C}^4$, $\overline{W} = \overline{W_4} = e^{-2\pi i/4}$. Tenemos entonces

$$P_4 \begin{bmatrix} q_0 \\ q_1 \\ q_2 \\ q_3 \end{bmatrix} = \begin{bmatrix} q_0 \\ q_2 \\ q_1 \\ q_3 \end{bmatrix}.$$

Además

$$\begin{bmatrix} q_0 \\ q_2 \\ q_1 \\ q_3 \end{bmatrix} = P_4\Omega_4 \begin{bmatrix} f_0 \\ f_1 \\ f_2 \\ f_3 \end{bmatrix} = \left[\begin{array}{c|c} \Omega_2 & 0_2 \\ \hline 0_2 & \Omega_2 \end{array}\right] \left[\begin{array}{c|c} I_2 & I_2 \\ \hline D_2 & -D_2 \end{array}\right] \begin{bmatrix} f_0 \\ f_1 \\ f_2 \\ f_3 \end{bmatrix}$$

$$= \left[\begin{array}{c|c} \Omega_2 & 0_2 \\ \hline 0_2 & \Omega_2 \end{array}\right] \left[\begin{array}{cc|cc} 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \\ \hline \overline{W}^0 & 0 & -\overline{W}^0 & 0 \\ 0 & \overline{W}^1 & 0 & -\overline{W}^1 \end{array}\right] \begin{bmatrix} f_0 \\ f_1 \\ f_2 \\ f_3 \end{bmatrix}$$

$$= \left[\begin{array}{c|c} \Omega_2 & 0_2 \\ \hline 0_2 & \Omega_2 \end{array}\right] \begin{bmatrix} f_0 + f_2 \\ f_1 + f_3 \\ (f_0 - f_2)\overline{W}^0 \\ (f_1 - f_3)\overline{W}^1 \end{bmatrix}$$

Paso 1.

$$f^1 = \left[\begin{array}{cc|cc} 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \\ \hline \overline{W}^0 & 0 & -\overline{W}^0 & 0 \\ 0 & \overline{W}^1 & 0 & -\overline{W}^1 \end{array}\right] \begin{bmatrix} f_0 \\ f_1 \\ f_2 \\ f_3 \end{bmatrix} = \begin{bmatrix} f_0 + f_2 \\ f_1 + f_3 \\ (f_0 - f_2)\overline{W}^0 \\ (f_1 - f_3)\overline{W}^1 \end{bmatrix}$$

Ahora veamos que

$$P_2\Omega_2 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \Omega_2 = \Omega_2$$

de donde

$$\Omega_2 = P_2\Omega_2 = \left[\begin{array}{c|c} \Omega_1 & 0_1 \\ \hline 0_1 & \Omega_1 \end{array}\right] \left[\begin{array}{c|c} I_1 & I_1 \\ \hline D_1 & -D_1 \end{array}\right] = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ \overline{W}^0 & -\overline{W}^0 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ \overline{W}^0 & -\overline{W}^0 \end{bmatrix}$$

Paso 2.

$$\begin{bmatrix} g_0 \\ g_1 \\ g_2 \\ g_3 \end{bmatrix} = \begin{bmatrix} f_0^2 \\ f_1^2 \\ f_2^2 \\ f_3^2 \end{bmatrix} = \left[\begin{array}{cc|cc} 1 & 1 & 0 & 0 \\ \overline{W}^0 & -\overline{W}^0 & 0 & 0 \\ \hline 0 & 0 & 1 & 1 \\ 0 & 0 & \overline{W}^0 & -\overline{W}^0 \end{array}\right] \begin{bmatrix} f_0^1 \\ f_1^1 \\ f_2^1 \\ f_3^1 \end{bmatrix} = \begin{bmatrix} f_0^1 + f_1^1 \\ (f_0^1 - f_1^1)\overline{W}^0 \\ f_2^1 + f_3^1 \\ (f_2^1 - f_3^1)\overline{W}^0 \end{bmatrix}$$

Resumiendo tenemos:

Entrada		Paso 1		Paso 2	Salida
f_0	0	$f_0^1 = f_0 + f_2$	0	$f_0^2 = f_0^1 + f_1^1$	g_0
f_1	1	$f_1^1 = f_1 + f_3$	2	$f_1^2 = (f_0^1 + f_1^1)\overline{W}^0$	g_2
f_2	2	$f_2^1 = (f_0 - f_2)\overline{W}^0$	1	$f_2^2 = f_2^1 + f_3^1$	g_1
f_3	3	$f_3^1 = (f_1 - f_3)\overline{W}^0$	3	$f_3^2 = (f_2^1 + f_3^1)\overline{W}^0$	g_3

Los coeficientes de Fourier son, finalmente: $\frac{g_0}{N}, \frac{g_1}{N}, \frac{g_2}{N}, \frac{g_3}{N}$.

4. Ejercicios

1. Demuestre que si f es un polinomio de grado k, entonces para $n > k$

$$f[x_0, x_1, \ldots, x_n] = 0.$$

2. Demuestre que las diferencias divididas son mapeos lineales en relación con las funciones, esto es, para dos funciones f, g y escalares α, β

   $(\alpha f + \beta g)[x_0, x_1, \ldots, x_n] = \alpha f[x_0, x_1, \ldots, x_n] + \beta g[x_0, x_1, \ldots, x_n]$.

3. Demuestre la fórmula

$$f[x_0, x_1, \ldots, x_n] = \sum_{i=0}^{n} f(x_i) \prod_{\substack{j=0 \\ j \neq i}}^{n} (x_n - x_j)^{-1}.$$

4. Demuestre que

$$f[x_0, x_1, \ldots, x_n] = \frac{\begin{vmatrix} 1 & x_0 & x_0^2 & \ldots & x_0^{n-1} & f(x_0) \\ 1 & x_1 & x_1^2 & \ldots & x_1^{n-1} & f(x_1) \\ \vdots & \vdots & \vdots & & \vdots & \vdots \\ 1 & x_n & x_n^2 & \ldots & x_n^{n-1} & f(x_n) \end{vmatrix}}{2 \begin{vmatrix} 1 & x_0 & x_0^2 & \ldots & x_0^{n-1} & x_0^n \\ 1 & x_1 & x_1^2 & \ldots & x_1^{n-1} & x_0^n \\ \vdots & \vdots & \vdots & & \vdots & \vdots \\ 1 & x_n & x_n^2 & \ldots & x_n^{n-1} & x_0^n \end{vmatrix}}.$$

5. Demuestre la fórmula de Leibniz

$$(fg)[x_0, x_1, \ldots, x_n] = \sum_{k=0}^{n} f[x_0, x_1, \ldots, x_k] g[x_k, x_{k+1}, \ldots, x_n].$$

6. Encuentre el polinomio de interpolación de Newton para los siguientes datos:

x_i	1	3/2	0	2
y_i	3	13/4	3	5/3

7. Realice la interpolación de los datos de la tabla

x_i	1,1	1,9	2,7	4,3	5,1	7,8
y_i	11,2	16,8	18,7	8,1	2,7	14,3

   utilizando un spline cúbico natural.

8. Sea $f \in C^2[a, b]$ y tomemos $a = t_0 < t_1 < \ldots < t_n = b$. Si S es el spline cúbico natural que interpola f en los puntos t_i, $0 \leq i \leq n$, entonces

$$\int_a^b \big[S''(x)\big]^2 dx \leq \int_a^b \big[f''(x)\big]^2 dx.$$

9. Determine todos los valores de a, b, c, d y e para los cuales la siguiente función es un spline cúbico:

$$f(x) = \begin{cases} a(x-2)^2 + b(x-1)^3, & x \in]-\infty, 1] \\ c(x-2)^2, & x \in [1, 3] \\ d(x-2)^2 + e(x-3)^3, & x \in [3, +\infty[. \end{cases}$$

10. Determine todos los valores a, b, c de manera tal que la siguiente función sea un spline cúbico con nudos 0, 1, 2:

$$f(x) = \begin{cases} 3 + x - 9x^2, & x \in [0, 1] \\ a + b(x-1) + c(x-1)^2 + d(x-1)^3, & x \in [1, 2]. \end{cases}$$

    Calcule d de forma que $\displaystyle\int_0^2 \big[f''(x)\big]^2 dx$ sea mínimo. Finalmente, encuentre el valor de d que hace de f un spline cúbico natural y explique porqué este valor es distinto del que se calculó previamente.

11. Determine si la siguiente función es un spline cúbico:
$$f(x) = \begin{cases} x^3 + x, & x \leq 0 \\ x^3 - x, & x \geq 0. \end{cases}$$

12. Interpole y grafique una curva paramétrica en el plano, parametrizada por el intervalo $[0, 1]$, a partir de los siguientes datos:
$$x = \begin{bmatrix} -1 \\ 0{,}5 \\ 1 \\ 0 \\ 1 \end{bmatrix}, \quad y = \begin{bmatrix} 0 \\ 1 \\ 0 \\ -1 \\ 0 \end{bmatrix}.$$

13. Sean $L_i(x)$ los polinomios de Lagrange para abscisas de soporte distintas dos a dos $x_0, \ldots, x_n$, y sea $c_i = L_i(0)$. Muestre que

    a) $\displaystyle\sum_{i=0}^{n} c_i x_i^j = \begin{cases} 1 & \text{para } j = 0, \\ 0 & \text{para } j = 1, 2, \ldots, n, \\ (-1)^n x_0 x_1 \cdots x_n \text{ para } j = n+1, \end{cases}$

    b) $\displaystyle\sum_{i=0}^{n} L_i(x) = 1.$

14. Pruebe que el polinomio trigonométrico interpolante con abscisas de soporte x_k,
$$a \leq x_0 < x_1 \cdots < x_{2n} < a + 2\pi$$
y ordenadas de soporte $y_0, \ldots, y_{2n}$ es precisamente
$$T(x) = \sum_{j=0}^{2n} y_j t_j(x),$$
donde
$$t_j(x) = \frac{\displaystyle\prod_{\substack{k=0 \\ k \neq j}} \sin \frac{x - x_k}{2}}{\displaystyle\prod_{\substack{k=0 \\ k \neq j}} \sin \frac{x_j - x_k}{2}}.$$

15. Considere $f(x) = \ln(x+1)$ en el intervalo $I = [0, 1]$. Sea $p_n(x)$ el polinomio que interpola f en los puntos $x_0, \ldots, x_n \in I$.

    a) Calcule una cota superior para el error
    $$\|f - p_n\|_\infty = \sup_{x \in I} \big| f(x) - p_n(x) \big|$$
    que dependa solamente de n y no de la elección de los puntos de interpolación.

    b) Pruebe que $p_n \to f$ uniformemente.

    c) ¿Para qué valor de n se tiene que $\|f - p_n\|_\infty < 10^{-6}$?

Capítulo 7

Integración Numérica

Para el cálculo aproximado de integrales definidas de la forma

$$I(f) = \int_a^b f(x)dx, \quad f : \mathbb{R} \to \mathbb{R}$$

Se usan *fórmulas de cuadratura* de la forma

$$Q_n(f) = \sum_{j=0}^{n} \alpha_j f(x_j)$$

donde las constantes α_j son llamadas *pesos de integración*.

1. Fórmulas de Newton-Cotes

Consideremos una partición del intervalo $[a, b]$:

$$a = x_0 < x_1 < \cdots < x_n = b$$

Sea P_n el polinomio interpolante con $P_n(x_i) = f(x_i)$, $i = 0, \cdots, n$. Bajo estas condiciones, existe un único polinomio interpolante de grado menor o igual a n en la forma de Lagrange

$$P_n(x) = \sum_{j=0}^{n} f(x_j)L_j(x) \qquad \text{con} \qquad L_j(x) = \prod_{\substack{k=0 \\ k\neq j}}^{n} \frac{x - x_k}{x_j - x_k}$$

Utilizando este polinomio como aproximación para f resulta

$$Q_n(f) = \int_a^b P_n(x)dx = \sum_{j=0}^{n} \left[\int_a^b L_j(x)dx \right] f(x_j) = \sum_{j=0}^{n} \alpha_j f(x_j)$$

donde $\alpha_j = \displaystyle\int_a^b L_j(x)dx, \quad j = 0, \cdots, n.$

Definición. *La fórmula de cuadratura de Newton-Cotes está definida por*

$$Q_n(f) = \sum_{j=0}^{n} \alpha_j f(x_j) \qquad con \qquad \alpha_j = \int_a^b L_j(x)dx, \quad j = 0, \cdots, n$$

donde α_j son los pesos de integración y con el error de integración

$$E_n(f) = I(f) - Q_n(f) = \int_a^b f(x)dx - \sum_{j=0}^{n} \alpha_j f(x_j)$$

Para polinomios P_k de grado menor o igual a n se cumple $E_n(P_k) = 0$. Por el teorema 6.4, se cumple lo siguiente:

Teorema 7.1. *Para $a = x_0 < \cdots < x_n = b$, existe una única fórmula de cuadratura*

$$Q_n(f) = \sum_{j=0}^{n} \alpha_j f(x_j) \qquad con \qquad \alpha_j = \int_a^b L_j(x)dx, \quad j = 0, \cdots, n$$

la cual es exacta para todos los polinomios de grado menor o igual a n.

TEOREMA 7.2. *Para los puntos de partición equidistante*

$$x_j = a + jh, \quad j = 0, \cdots, n \qquad h = \frac{b-a}{n}$$

del intervalo $[a, b]$*, los pesos de integración están dados por*

$$\alpha_j^{(n)} = (-1)^{n-j} \frac{h}{j!(n-j)!} \int_0^n \prod_{\substack{k=0 \\ k \neq j}}^{n} (t-k) dt.$$

Demostración.

$$\alpha_j^{(n)} = \int_a^b L_j(x) dx = \int_a^b \prod_{\substack{k=0 \\ k \neq j}}^{n} \frac{x - x_k}{x_j - x_k} dx = \int_a^b \prod_{\substack{k=0 \\ k \neq j}}^{n} \frac{x - (a+kh)}{h(j-k)} dx$$

Con el cambio de variables $x = a + ht$, $dx = h\, dt$, se obtiene

$$\begin{aligned} \alpha_j^{(n)} &= \int_0^n \prod_{\substack{k=0 \\ k \neq j}}^{n} \frac{h(t-k)}{h(j-k)} h\, dt = \frac{h}{\prod_{\substack{k=0 \\ k \neq j}}^{n} (j-k)} \int_0^n \prod_{\substack{k=0 \\ k \neq j}}^{n} (t-k) dt \\ &= (-1)^{n-j} \frac{h}{j!(n-j)!} \int_0^n \prod_{\substack{k=0 \\ k \neq j}}^{n} (t-k) dt. \end{aligned}$$

De éstas fórmulas resultan las siguientes reglas:

Regla del Trapecio:$(n = 1)$

$$\begin{aligned} \alpha_0^{(1)} &= (b-a) \left(- \int_0^1 (t-1) dt \right) = \frac{b-a}{2} \\ \alpha_1^{(1)} &= (b-a) \int_0^1 t\, dt = \frac{b-a}{2} \\ Q_1(f) &= \frac{b-a}{2} (f(a) + f(b)) \end{aligned}$$

Regla de Simpson:$(n = 2)$

$$\begin{aligned} \alpha_0^{(2)} &= \frac{b-a}{2} \frac{1}{2} \int_0^2 (t-1)(t-2) dt = \frac{b-a}{6} \\ \alpha_1^{(2)} &= \frac{b-a}{2} \left(- \int_0^2 t(t-2) dt \right) = \frac{4(b-a)}{6} \\ \alpha_2^{(2)} &= \frac{b-a}{4} \int_0^2 t(t-1) dt = \frac{b-a}{6} \\ Q_2(f) &= \frac{b-a}{6} \left[f(a) + 4f\left(\frac{a+b}{2} \right) + f(b) \right] \end{aligned}$$

Fórmulas de Newton-Cotes $(1 \leq n \leq 6)$

n	$\alpha_j^{(n)}/(b-a)$							
1	$\frac{1}{2}$	$\frac{1}{2}$						Regla Trapezoidal
2	$\frac{1}{6}$	$\frac{4}{6}$	$\frac{1}{6}$					Regla de Simpson
3	$\frac{1}{8}$	$\frac{3}{8}$	$\frac{3}{8}$	$\frac{1}{8}$				Regla 3/8 de Newton
4	$\frac{7}{90}$	$\frac{32}{90}$	$\frac{12}{90}$	$\frac{32}{90}$	$\frac{7}{90}$			Regla de Milne
5	$\frac{19}{288}$	$\frac{75}{288}$	$\frac{50}{288}$	$\frac{50}{288}$	$\frac{75}{288}$	$\frac{19}{288}$		Anónimo
6	$\frac{41}{1400}$	$\frac{216}{1400}$	$\frac{27}{1400}$	$\frac{272}{1400}$	$\frac{27}{1400}$	$\frac{216}{1400}$	$\frac{41}{1400}$	Regla de Wedolle

Para $n = 1$**:** La regla trapezoidal es exacta para todos los polinomios de grado $n \leq 1$.
Para $n = 2$**:** La regla de Simpson es exacta para polinomios de grado $n \leq 3$, pues

$$\begin{aligned} E_2(x^3) &= I(x^3) - Q_2(x^3) \\ &= \int_a^b x^3 dx - \frac{b-a}{6}\left[a^3 + 4\left(\frac{b+a}{2}\right)^3 + b^3\right] = 0 \end{aligned}$$

pero $E_2(x^4) \neq 0$.
Para $n = 3$**:** Para la regla 3/8 de Newton resulta

$$E_3(x^3) = 0, \quad E_3(x^4) \neq 0$$

Para $n = 4$**:** Para la regla de Milne se obtiene

$$E_4(x^5) = 0, \quad E_4(x^6) \neq 0$$

En general se puede probar que $E_m(x^{m+1}) = 0$ si m es par, y que en caso de que m sea impar resulta solamente

$$E_m(x^m) = 0, \quad \text{y } E_m(x^{m+1}) \neq 0$$

Para $n = 8$ y $n \geq 10$ algunos de los pesos $\alpha_j^{(n)}$ se vuelven negativos, lo cual no tiene ningún sentido.
Utilizando la fórmula del error de un polinomio interpolante se obtiene:

$$\begin{aligned} E_n(f) &= I(f) - Q_n(P_n) = I(f) - I(P_n) = \int_a^b (f(x) - P_n(x))dx \\ &= \int_a^b \frac{f^{(n+1)}(\xi_x)}{(n+1)!} \prod_{k=0}^{n} (x - x_k)dx \end{aligned}$$

$$E_n(f) = \int_a^b \frac{f^{(n+1)}(\xi_x)}{(n+1)!}\rho_n(x)dx$$

donde

$$\rho_n(x) = \prod_{k=0}^{n}(x - x_k).$$

Usando integración por partes se obtiene:

TEOREMA 7.3. *Si $f \in C^{(n+2)}[a,b]$, con n par, entonces el error para la fórmula de cuadratura de Newton-Cotes está dado por*

$$E_n(f) = \frac{K_n}{(n+2)!} f^{(n+2)}(\xi), \qquad a < \xi < b$$

$$K_n = \int_a^b x\rho_n(x)dx, \qquad \rho_n(x) = \prod_{k=0}^{n}(x - x_k).$$

TEOREMA 7.4. *Si n impar y $f \in C^{(n+1)}[a,b]$, entonces el error de la fórmula de de Newton-Cotes está dado por*

$$E_n(f) = \frac{K_n}{(n+1)!} f^{(n+1)}(\xi), \qquad a < \xi < b$$

$$K_n = \int_a^b \rho_n(x)dx, \qquad \rho_n(x) = \prod_{k=0}^{n}(x - x_k).$$

De estos resultados, se obtienen para las siguientes reglas:
Regla Trapezoidal:$(n = 1)$

$$\alpha_0^{(1)} = \frac{b-a}{2}, \quad \alpha_1^{(1)} = \frac{b-a}{2}$$

$$Q_1(f) = \frac{b-a}{2}(f(a) + f(b))$$
$$E_1(f) = -\frac{1}{12}h^3 f''(\xi), \quad h = b - a$$

Regla de Simpson:$(n = 2)$

$$\alpha_0^{(2)} = \frac{b-a}{6} = \alpha_2^{(2)}; \quad \alpha_1^{(2)} = \frac{4(b-a)}{6}$$
$$Q_2(f) = \frac{b-a}{6}\left[f(a) + 4f\left(\frac{a+b}{2}\right) + f(b)\right]$$
$$E_2(f) = -\frac{h^5}{90}f^{(4)}(\xi) = -\frac{1}{2880}(b-a)^5 f^{(4)}(\xi), \quad a < \xi < b$$

Regla 3/8 de Newton:$(n = 3)$

$$Q_3(f) = \frac{b-a}{8}\left[f(a) + 3f\left(\frac{2a+b}{2}\right) + 3f\left(\frac{a+2b}{2}\right) + f(b)\right]$$
$$E_3(f) = -\frac{3h^5}{80}f^{(4)}(\xi) = -\frac{(b-a)^5}{6480}f^{(4)}(\xi), \quad a < \xi < b$$

Para $n \geq 4$ se obtienen fórmulas similares.

1.1. Fórmulas abiertas de Newton-Cotes. En las fórmulas abiertas de Newton-Cotes, los nodos $x_i = x_0 + ih$ se usan para cada $i = 0, \cdots, n$, donde

$$h = \frac{b-a}{b+2} \quad \text{y} \quad x_0 = a + h, \quad x_n = b - h.$$

Definiendo $x_{-1} := a$ y $x_{n+1} := b$ se obtiene la partición

$$a = x_{-1} < x_0 < \cdots < x_n < x_{n+1} = b$$

y todos los nodos empleados para la aproximación se encuentran en el intervalo abierto $\langle a, b\rangle$. Las fórmulas se convierten en

$$\int_a^b = \int_{x_{-1}}^{x_{n+1}} f(x)dx \approx \sum_{j=0}^{n} \alpha_j f(x_j)$$

donde

$$\alpha_j := \int_a^b L_j(x)dx$$

TEOREMA 7.5. *Si $\hat{K}_n(f) = \sum_{j=0}^{n} \alpha_j f(x_j)$ es la fórmula abierta de Newton-Cotes para $(n+1)$ puntos, tal que $x_{-1} = a$, $x_{n+1} = b$ y $h = (b-a)/(n+2)$, entonces:*

(i) *Si* $f \in C^{(n+2)}[a,b]$ *con* n *par, entonces existe* $\xi \in \langle a,b\rangle$ *tal que*

$$\int_a^b f(x)dx = \sum_{j=0}^{n} \alpha_j f(x_j) + \frac{h^{(n+3)} f^{(n+2)}(\xi)}{(n+2)!} \int_{-1}^{n+1} t^2(t-1)\cdots(t-n)dt$$

(ii) *Si* $f \in C^{(n+1)}[a,b]$ *con* n *impar, entonces existe* $\xi \in \langle a,b\rangle$ *tal que*

$$\int_a^b f(x)dx = \sum_{j=0}^{n} \alpha_j f(x_j) + \frac{h^{(n+2)} f^{(n+1)}(\xi)}{(n+1)!} \int_{-1}^{n+1} t(t-1)\cdots(t-n)dt$$

Las fórmulas abiertas de Newton-Cotes

Para $n = 0$**:** Regla del Punto Medio

$$\int_{x-1}^{x_1} f(x)dx = 2hf(x_0) + \frac{h^3}{3} f''(\xi), \quad \text{donde } \xi \in \langle x_{-1}, x_1\rangle$$

Para $n = 1$**:**

$$\int_{x-1}^{x_2} f(x)dx = \frac{3}{2}h[f(x_0) + f(x_1)]\frac{3}{4}h^3 f''(\xi),$$

$$\text{donde } \xi \in \langle x_{-1}, x_2\rangle$$

Para $n = 2$**:**

$$\int_{x-1}^{x_3} f(x)dx = \frac{4}{3}h[2f(x_0) - f(x_1) + 2f(x_2)]\frac{14}{45}h^5 f^{(4)}(\xi),$$

$$\text{donde } \xi \in \langle x_{-1}, x_3\rangle$$

Para $n = 3$**:**

$$\int_{x-1}^{x_4} f(x)dx = \frac{5}{24}h[11f(x_0) + f(x_1) + f(x_2) + 11f(x_3)] + \frac{95}{144}h^5 f^{(4)}(\xi),$$

$$\text{donde } \xi \in \langle x_{-1}, x_4\rangle$$

1.2. Regla Trapezoidal Compuesta. La composición de la fórmula trapezoidal se puede realizar de la siguiente manera:
Sea $x_j = a + jh$, $j = 0, 1, \cdots, n$ donde $n \in \mathbb{N}$, $h = (b-a)/n$ una partición regular de $[a,b]$ y $f \in C^2[a,b]$. Aplicando la regla trapezoidal en los subintervalos $[x_{j-1}, x_j]$, $j = 1, 2, \cdots, n$ se obtiene

$$\begin{aligned}\int_a^b f(x)dx &= \sum_{j=1}^{n} \int_{x_{j-1}}^{x_j} f(x)dx \\ &= \sum_{j=1}^{n} \left[\frac{h}{2}(f(x_{j-1}) + f(x_j)) - \frac{1}{12}h^3 f''(\xi_j)\right]\end{aligned}$$

donde $\xi_j \in \langle x_{j-1}, x_j\rangle$.

$$\int_a^b f(x)dx = h\left[\frac{f(x_0)}{2} + \sum_{j=1}^{n} f(x_j) + \frac{f(x_n)}{2}\right] - \sum_{j=1}^{n} \frac{1}{12}h^3 f''(\xi_j)$$

De esto se obtiene la fórmula trapezoidal compuesta:

$$T_n(f) := h\left[\frac{f(x_0)}{2} + \sum_{j=1}^{n} f(x_j) + \frac{f(x_n)}{2}\right]$$

$$\int_a^b f(x)dx = T_n(f) - \frac{h^2(b-a)}{12}\left(\frac{1}{n}\sum_{j=1}^{n} f''(\xi_j)\right)$$

Por el teorema del valor intermedio, el error puede ser expresado como:

$$\int_a^b f(x)dx - T_n(f) = -\frac{h^2(b-a)}{12} f''(\xi)$$

para algún $\xi \in \langle a, b\rangle$.

1.3. Regla Compuesta de Simpson. De manera similar se obtiene esta regla. Sean $n = 2m$ (par), $m \in \mathbb{N}$, $h = (b-a)/n$, $x_j = a+jh$, $j = 0, \cdots, n$, $f \in C^4[a, b]$. Aplicando la Regla compuesta de Simpson en los subintervalos $[x_{2(j-1)}, x_{2j}]$, $j = 1, \cdots, m$ se obtiene

$$\int_a^b f(x)dx = \sum_{j=1}^{m} \int_{x_{2j-2}}^{x_{2j}} f(x)dx = S_n[a, b] - \frac{h^4(b-a)}{180} \left[\frac{1}{m}\sum_{j=1}^{m} f^{(4)}(\xi_j)\right]$$

donde $\xi_j \in \langle x_{2(j-1)}, x_{2j}\rangle$ y

$$S_n[a, b] := \frac{h}{3}\left[f(x_0) + 4\sum_{j=1}^{m} f(x_{2j-1}) + 2\sum_{j=1}^{m-1} f(x_{2j}) + f(x_n)\right]$$

Por el teorema del valor intermedio el error puede ser expresado como:

$$\int_a^b f(x)dx - S_n[a, b] = -\frac{h^4(b-a)}{180} f^{(4)}(\xi),$$

para algún $\xi \in \langle a, b\rangle$.

Ejemplo. Se requiere calcular

$$\int_1^3 \frac{100}{x^2} sen\left(\frac{10}{x}\right) dx,$$

con $\varepsilon = 0{,}0000001$, utilizando para ello el algoritmo de Simpson compuesto. Para obtener el valor de n se debe realizar un análisis de error de este método, esto es, se debe encontrar un número n tal que se cumpla la siguiente desigualdad:

$$\left|\int_a^b f(x)dx - S_n[a, b]\right| = \left|-\frac{h^4(b-a)}{180} f^{(4)}(\xi)\right| \leq \max_{\xi\in[a,b]} h^4(b-a)|f^{(4)}|(\xi)| < \varepsilon$$

lo cual no es una tarea sencilla. Utilizando el algoritmo compuesto se obtiene

n	**Valor Aproximado**	**Error**
400	$-1{,}426024347713767$	$-0{,}000000408630$
1000	$-1{,}426024745884060$	$-0{,}000000010465$

2. Fórmula de Cuadratura de Gauss

Las fórmulas de cuadratura de Gauss aproximan integrales de la forma

$$I(f) = \int_a^b f(x)w(x)dx$$

donde $w : \langle a, b\rangle \to \mathbb{R}$ es una función no negativa, integrable y con un número finito de ceros en $\langle a, b\rangle$. La función w es denominada *función de peso* .

Notación. De ahora en adelante denotaremos con π_n al espacio de los polinomios con coeficientes reales de grado menor o igual a n y con π al espacio de todos los polinomios.

DEFINICIÓN. *Una fórmula de cuadratura* $G_n(f) := \sum_{j=0}^{n} A_j f(x_j)$ *con* $(n+1)$ *puntos de partición distintos para el cálculo de la integral* $I(f) = \int_a^b f(x)w(x)dx$ *es denominada del tipo Gauss, si*

$$G_n(p) = I(p), \quad \forall p \in \pi_{2n+1}.$$

TEOREMA 7.6. *La fórmula de cuadratura de Gauss*

$$G_n(f) := \sum_{j=0}^{n} A_j f(x_j)$$

con $(n+1)$ *puntos de partición distintos no es exacta para polinomios de grado mayor a* $(2n+1)$.

Demostración. Sea $q(x) = \prod_{k=0}^{n} (x - x_k)^2$, entonces

$$I(q) = \int_a^b w(x)q(x)dx > 0,$$

pues $q(x) > 0, \quad \forall x \in [a,b] \setminus \{x_k\}_{k=0}^n$. Pero $q(x_j) = 0,\ j = 0, \cdots, n$ implica que

$$G_n(q) = \sum_{j=0}^{n} \alpha_j q(x_j) = 0,$$

de donde

$$R_n(q) = I(q) - G_n(q) \neq 0$$

2.1. Construcción de la fórmula de cuadratura de Gauss. En $C[a,b]$ se define un producto escalar

$$\langle f, g\rangle = \int_a^b w(x)f(x)g(x)dx, \quad f, g \in C[a,b].$$

Se inicia con un proceso de ortonormalización de $\{1, x, x^2, \cdots, x^{n+1}\}$, obteniendo $\{P_i\}_{i=0}^{n+1}$ tales que

$$\langle P_i, P_i\rangle = 1; \qquad \langle P_i, P_j\rangle = 0,\ i \neq j$$

y donde $\{P_0, \cdots, P_k\}$ es una base de π_k.
Se cumple que los $(n+1)$ ceros de P_{n+1} son reales y distintos y están en $\langle a, b\rangle$.
Si $x_j,\ j = 0, \cdots, n$ $(x_0 < x_1 < \cdots < x_n)$ son los ceros de P_{n+1} se define G_n como fórmula de cuadratura con dichos puntos de partición:

$$G_n(f) = \sum_{j=0}^{n} \alpha_j f(x_j).$$

Se cumple entonces que $G_n(p) = I(p)$, $\forall p \in \pi_{2n+1}$.

TEOREMA 7.7. *Sea* $n \in \mathbb{N}$, $w \in C[a,b]$ *una función de peso y* $P_i \in \pi_i$, $i = 0, \cdots, n+1$ *dados por el proceso de ortonormalización de* $\{1, \cdots, x^{n+1}\}$ *con el producto escalar*

$$\langle f, g\rangle = \int_a^b w(x)f(x)g(x)dx, \quad f, g \in C[a,b].$$

Entonces se cumplen:

(a) *Los* $(n+1)$ *ceros de* P_{n+1} *son reales y distintos y se encuentran en* $\langle a, b\rangle$.

(b) *Sean* $x_0 < x_1 < \cdots < x_n$ *los ceros de* P_{n+1}. *Definiendo*

$$L_j(x) = \prod_{\substack{k=0 \\ k\neq j}}^{n} \frac{x - x_k}{x_j - x_k} \qquad y \qquad \alpha_j = \int_a^b w(x) L_j(x) dx, \quad j = 0, \cdots, n$$

Se obtiene la fórmula de cuadratura de Gauss

$$G_n(f) = \sum_{j=0}^{n} \alpha_j f(x_j).$$

Entonces G_n *es la fórmula de cuadratura de Gauss para el cálculo aproximado de*

$$I(f) = \int_a^b w(x) f(x) dx$$

Demostración.

(a) Sean $\xi_1, \xi_2, \cdots, \xi_m$ $(m \leq n+1)$ los ceros de P_{n+1} en $\langle a, b\rangle$ con multiplicidad impar. Como $\langle 1, P_{n+1}\rangle = 0$, se cumple que $m \geq 1$ y P_{n+1} cambia de signo. Sea $q_m(x) := \prod_{i=1}^{m}(x - \xi_i)$. Entonces $P_{n+1} q_m$ no cambia de signo en $\langle a, b\rangle$, lo que implica que $\langle P_{n+1}, q_m\rangle \neq 0$. Vamos a probar que $m = n + 1$: Supongamos que $m < n + 1$, entonces

$$q_m \in \pi_m \subset \pi_n = span\{P_0, \cdots, P_n\}$$

y como $\langle P_{n+1}, P_j\rangle = 0$, $j = 0, 1, \cdots, n$, se obtiene

$$\begin{aligned} \langle P_{m+1}, q_m\rangle &= \langle P_{m+1}, \sum_{l=0}^{n} \beta_l P_l\rangle \\ &= \sum_{l=0}^{n} \beta_l \langle P_{m+1}, P_l\rangle = 0 \end{aligned}$$

lo cual constituye una contradicción. Por lo tanto $m = n + 1$.

(b) Sea $p \in \pi_{2n+1}$. Dividiendo p por P_{n+1}, por el algoritmo de la división, existen $q, r \in \pi_n$ tales que

$$p = q P_{n+1} + r.$$

Como $P_{n+1}(x_j) = 0,\ j = 0, \cdots, n$, entonces

$$p(x_j) = q(x_j) P_{n+1}(x_j) + r(x_j) = r(x_j), \quad j = 0, \cdots, n$$

de donde

$$\begin{aligned} G_n(p) &= \sum_{j=0}^{n} \alpha_j p(x_j) = \sum_{j=0}^{n} \alpha_j r(x_j) \\ &= \sum_{j=0}^{n} \left(\int_a^b w(x) L_j(x) dx \right) r(x_j) \\ &= \int_a^b w(x) \sum_{j=0}^{n} L_j(x) r(x_j) dx = \int_a^b w(x) r(x) dx \\ &= \int_a^b w(x)(p(x) - q(x) P_{n+1}(x)) dx \\ &= \int_a^b w(x) p(x) - \langle q, P_{n+1}\rangle = \int_a^b w(x) p(x) \end{aligned}$$

esto es,

$$G_n(p) = I(p), \quad \forall p \in \pi_{2n+1}. \qquad \square$$

Capítulo 8

Ecuaciones Diferenciales Ordinarias

1. Problemas de valor inicial

1.0.1. El problema de Cauchy. Consideramos el problema

$$\begin{cases} \overline{y}'(t) = \overline{f}(t, \overline{y}(t)) \\ \overline{y}(t_0) = \overline{y}_0 \end{cases} \tag{22}$$

donde $\overline{f} : \Omega \to \mathbb{R}^d$ es continua, $\Omega \subset \mathbb{R} \times \mathbb{R}^d$ es abierto y convexo y $(t_0, \overline{y}_0) \in \Omega$. La dimensión del estado es d; reservaremos n para el número de pasos de la malla. La continuidad de $\overline{f}$ y la condición de Lipschitz local respecto de $\overline{y}$ aseguran existencia y unicidad local. En lo que sigue suponemos que la solución existe en todo el intervalo de integración considerado.

LEMA 8.1. *Sea $\overline{y}$ una función continua en un intervalo que contiene a t_0, con $(t, \overline{y}(t)) \in \Omega$. La función $\overline{y}$ es solución del problema de Cauchy* (22) *si y sólo si satisface*

$$\overline{y}(t) = \overline{y}_0 + \int_{t_0}^{t} \overline{f}(s, \overline{y}(s))\, ds.$$

DEMOSTRACIÓN. Si $\overline{y}$ resuelve el problema de Cauchy, basta integrar la ecuación y utilizar la condición inicial. Recíprocamente, el integrando es continuo; por el teorema fundamental del cálculo, la identidad integral implica $\overline{y}'(t) = \overline{f}(t, \overline{y}(t))$. Al evaluar en $t = t_0$ se recupera $\overline{y}(t_0) = \overline{y}_0$. □

Gracias a éste lema, podemos utilizar los resultados del capítulo anterior para resolver numéricamente ecuaciones diferenciales ordinarias.

1.1. Métodos de un paso. Consideremos el siguiente P.V.I. (Problema de Valor Inicial):

$$\begin{cases} \overline{y}'(t) = \overline{f}(t, \overline{y}(t)) \\ \overline{y}(a) = \overline{y}_0 \end{cases}, \quad a \le t \le b.$$

Aproximamos la solución en un número finito de nodos. Elegimos $n \in \mathbb{N}$, $n \ge 1$, y una partición regular de $[a, b]$, con $a < b$:

$$h = \frac{b-a}{n}, \qquad t_k = a + kh, \quad k = 0, \ldots, n.$$

Así, $t_0 = a$, $t_n = b$ y $t_{k+1} - t_k = h$.

Los métodos de un paso tienen la forma

$$\overline{y}_{k+1} := \overline{y}_k + h\overline{\phi}(t_k, \overline{y}_k; h),$$

en donde $\overline{y}_k$ es la aproximación a $\overline{y}(t_k)$ y $\overline{\phi}$ es la pendiente efectiva del paso. Se toma como valor inicial el dato $\overline{y}_0 = \overline{y}(a)$.

1.1.1. Método de Euler. Estudiamos el P.V.I.

$$\begin{cases} y'(t) = f(t, y(t)) \\ y(a) = y_0 \end{cases}, \quad a \le t \le b. \tag{23}$$

Consideramos una partición regular de $[a, b]$, de modo que

$$t_{k+1} = t_k + h, \quad k = 0, 1, \ldots, n-1$$

con $h > 0$ fijo.

Consideremos la aproximación de la integral

$$\int_{t_0}^{t_1} \varphi(s)ds \approx (t_1 - t_0)\varphi(t_0)$$

obtenida cuando aproximamos $\varphi(s)$ por la función constante $\varphi(t_0)$. De esta manera, obtenemos la aproximación

$$y_1 := y_0 + hf(t_0, y_0)$$

y, en general

$$y_{k+1} := y_k + hf(t_k, y_k); \qquad k = 0, 1, \ldots, n-1$$

el método de Euler.

El método también puede obtenerse como aproximación de la serie de Taylor, teniendo en cuenta que

$$y(t_0 + h) = y(t_0) + hy'(t_0) + \frac{h^2}{2}y''(\theta), \qquad \text{para algún } t_0 < \theta < t_1 = t_0 + h.$$

El método se presenta de forma operativa en el algoritmo 13.

Algoritmo 13 Método de Euler explícito

Entrada: Extremos $a < b$, valor inicial y_0, función f y entero $n \ge 1$
Salida: Vectores de nodos t y aproximaciones y

1: $h \leftarrow (b-a)/n$
2: $t_0 \leftarrow a$
3: **Para** $k = 0, \ldots, n-1$ **hacer**
4: $\quad y_{k+1} \leftarrow y_k + hf(t_k, y_k)$
5: $\quad t_{k+1} \leftarrow a + (k+1)h$
6: **Fin Para**
7: **Devolver** $(t_0, \ldots, t_n)$, $(y_0, \ldots, y_n)$

Consistencia y defecto local. Para estudiar si un método reproduce la ecuación diferencial al reducir el paso, se sustituye en su fórmula la solución exacta, no la trayectoria numérica. En el caso escalar, para $y_{k+1} = y_k + h\phi(t_k, y_k; h)$, definimos el *defecto local* y el *residuo local normalizado* por

$$d_{k+1}(h) = y(t_{k+1}) - y(t_k) - h\phi(t_k, y(t_k); h),$$
$$\tau_{k+1}(h) = \frac{d_{k+1}(h)}{h} = \frac{y(t_{k+1}) - y(t_k)}{h} - \phi(t_k, y(t_k); h).$$

Definición (Consistencia de un método de un paso). *El método es consistente en $[a, b]$ si, para cada solución exacta suficientemente regular en ese intervalo,*

$$\max_{0 \le k < n} |\tau_{k+1}(h)| \longrightarrow 0, \qquad h = \frac{b-a}{n}, \quad n \longrightarrow \infty.$$

Tiene orden de consistencia p si este máximo es $O(h^p)$, o, equivalentemente, $\max_k |d_{k+1}(h)| = O(h^{p+1})$.

PROPOSICIÓN 8.2 (Consistencia del método de Euler). *Si la solución exacta y pertenece a* $C^2[a,b]$ *y* $M = \max_{t\in[a,b]} |y''(t)|$*, Euler satisface*

$$\max_{0\le k<n} |\tau_{k+1}(h)| \le \frac{M}{2}h.$$

En consecuencia, es consistente de primer orden.

DEMOSTRACIÓN. Por Taylor, para algún $\xi_k \in (t_k, t_{k+1})$,

$$y(t_{k+1}) = y(t_k) + hy'(t_k) + \frac{h^2}{2}y''(\xi_k).$$

Como $y'(t_k) = f(t_k, y(t_k))$ y Euler usa $\phi(t, y; h) = f(t, y)$, al sustituir en el residuo se obtiene

$$\tau_{k+1}(h) = \frac{h}{2}y''(\xi_k), \qquad |\tau_{k+1}(h)| \le \frac{M}{2}h \longrightarrow 0.$$

La cota no depende de k, por lo que la convergencia es uniforme sobre la malla. □

Así, en Euler el residuo normalizado es $O(h)$ y el defecto sin normalizar es $O(h^2)$. La consistencia describe el error de un paso con inicio exacto; el error global $e_k = y(t_k) - y_k$ también depende de la propagación de los errores anteriores. Bajo una hipótesis de Lipschitz en y y suficiente regularidad, esa propagación permite obtener el error global $O(h)$.

1.1.2. Regla del trapecio y método de Heun. La identidad integral exacta de un paso es

$$y(t_{k+1}) = y(t_k) + \int_{t_k}^{t_{k+1}} f(s, y(s))\, ds.$$

La regla trapezoidal aproxima la integral mediante

$$\int_{t_k}^{t_{k+1}} \varphi(s)\, ds \approx \frac{h}{2}[\varphi(t_k) + \varphi(t_{k+1})].$$

Al sustituir los valores exactos por aproximaciones obtenemos el *trapecio implícito*:

$$y_{k+1} = y_k + \frac{h}{2}[f(t_k, y_k) + f(t_{k+1}, y_{k+1})]. \tag{24}$$

El valor y_{k+1} aparece en ambos lados. En general se debe resolver una ecuación en cada paso; si f es afín en y, basta despejar el valor nuevo.

Para obtener una fórmula explícita, primero calculamos un predictor de Euler y después lo sustituimos una sola vez en la pendiente del extremo derecho:

$$\begin{aligned} y_{k+1}^{\text{pred}} &= y_k + hf(t_k, y_k), \\ y_{k+1} &= y_k + \frac{h}{2}[f(t_k, y_k) + f(t_{k+1}, y_{k+1}^{\text{pred}})]. \end{aligned}$$

Es decir,

$$y_{k+1} = y_k + \frac{h}{2}[f(t_k, y_k) + f(t_k + h, y_k + hf(t_k, y_k))]. \tag{25}$$

Esta fórmula es el *método de Heun*, también llamado *trapecio explícito*. Una única corrección no equivale a resolver la ecuación (24). Bajo suficiente regularidad y Lipschitz, ambos métodos tienen orden global dos, aunque pueden producir valores distintos.

1.1.3. Métodos (Explícitos) de Runge-Kutta. Tienen la forma

$$\phi(t_k, y_k; h) = \sum_{i=1}^{m} c_i k_i(t_k, y_k; h)$$

con

$$k_1(t, y; h) = f(t, y)$$

y

$$k_i(t, y; h) = f\left(t + a_i h,\, y + h \sum_{\ell=1}^{i-1} b_{i\ell} k_\ell(t, y; h)\right), \quad i = 2, \ldots, m.$$

Los k_i representan pendientes; el factor h convierte cada combinación de pendientes en un incremento del estado.

En detalle:

$$\begin{aligned}
k_1 &:= f(t_k, y_k) \\
k_2 &:= f(t_k + a_2 h, y_k + h b_{2,1} k_1) \\
k_3 &:= f(t_k + a_3 h, y_k + h(b_{3,1} k_1 + b_{3,2} k_2)) \\
&\vdots \\
k_m &:= f(t_k + a_m h, y_k + h(b_{m,1} k_1 + b_{m,2} k_2 + \cdots + b_{m,m-1} k_{m-1})) \\
y_{k+1} &:= y_k + h(c_1 k_1 + c_2 k_2 + \cdots + c_m k_m).
\end{aligned}$$

Por lo general se exige $a_1 = 0$ y

$$a_i = \sum_{\ell=1}^{i-1} b_{i\ell}, \qquad i = 2, \ldots, m,$$

de modo que los desplazamientos temporales y de estado de las etapas sean compatibles. La exactitud para $y'(t) = 1$ requiere, además,

$$\sum_{i=1}^{m} c_i = 1,$$

pues en ese caso $k_i = 1$ y el incremento debe ser exactamente h. Con las condiciones anteriores, para orden dos se exige también $\sum_{i=1}^{m} c_i a_i = 1/2$. El número de etapas no determina por sí solo el orden del método.

m	i	c_i	a_i	b_{i1}	b_{i2}	b_{i3}	Método
1	1	1	0	0	0	0	Euler
2	1	0	0	0	0	0	Euler mejorado
	2	1	1/2	1/2	0	0	(punto medio explícito)
2	1	1/2	0	0	0	0	Heun
	2	1/2	1	1	0	0	(trapecio explícito)
4	1	1/6	0	0	0	0	Runge–Kutta
	2	1/3	1/2	1/2	0	0	clásico
	3	1/3	1/2	0	1/2	0	
	4	1/6	1	0	0	1	

De la tabla:

a) Método de Euler:

$$y_{k+1} := y_k + h f(t_k, y_k).$$

b) Método de Euler mejorado (punto medio explícito):

$$y_{k+1} := y_k + h f(t_k + \frac{1}{2}h, y_k + \frac{1}{2} h f(t_k, y_k)).$$

c) Método de Heun (trapecio explícito, (25)):

$$y_{k+1} := y_k + \frac{h}{2}[f(t_k, y_k) + f(t_k + h, y_k + hf(t_k, y_k))].$$

d) Método de Runge-Kutta clásico:

$$\begin{array}{rcl} k_1 & := & f(t_k, y_k) \\ k_2 & := & f(t_k + \frac{1}{2}h, y_k + \frac{1}{2}hk_1) \\ k_3 & := & f(t_k + \frac{1}{2}h, y_k + \frac{1}{2}hk_2) \\ k_4 & := & f(t_k + h, y_k + hk_3) \\ y_{k+1} & := & y_k + \frac{h}{6}(k_1 + 2k_2 + 2k_3 + k_4). \end{array}$$

Capítulo 9

Optimización numérica

1. Programación lineal

Una planta puede obtener un margen alto por unidad de un producto y aun así ganar más si dedica parte de su capacidad a otro. La decisión depende de cuánto consume cada producto de los insumos escasos. La programación lineal permite calcular esa mezcla y estimar cuánto valdría disponer de una unidad adicional de un insumo.

1.1. De la decisión económica al modelo. En un programa lineal, el objetivo es una función lineal de las decisiones y las restricciones son igualdades o desigualdades lineales. Los coeficientes son datos. Por ejemplo, si x_j es la cantidad de producto j, c_j es su margen unitario, a_{ij} es el consumo del insumo i por unidad de j y b_i es la disponibilidad del insumo i, un modelo de producción es

$$\max_{x \geq 0} c^{\top} x \qquad \text{sujeto a} \qquad Ax \leq b. \tag{26}$$

Cada fila de Ax mide el consumo total en las unidades del insumo correspondiente. Su diferencia respecto a b_i es la *holgura*. El modelo supone márgenes y consumos unitarios constantes y permite cantidades continuas. Si la decisión exige lotes indivisibles, se necesitan restricciones de integridad.

Ejemplo 9.1 (Plan de producción de BIM). Sean x_1 y x_2 las cantidades de dos tipos de chips, con márgenes de 12 y 9 unidades monetarias por chip. Los límites de silicio y germanio se expresan en chips de cada tipo. El plástico y el cobre se miden en unidades de sus respectivos insumos. El modelo del libro es

$$\begin{aligned} \max \quad & 12x_1 + 9x_2 & \\ \text{sujeto a} \quad & x_1 \leq 1000 & \text{(silicio)},\\ & x_2 \leq 1500 & \text{(germanio)},\\ & x_1 + x_2 \leq 1750 & \text{(plástico)},\\ & 4x_1 + 2x_2 \leq 4800 & \text{(cobre)},\\ & x_1, x_2 \geq 0. & \end{aligned} \tag{27}$$

Cuaderno 2.1 del libro: producción BIM y modelo en Pyomo.

1.2. La geometría del conjunto factible. Cada desigualdad del modelo BIM conserva un semiplano. La intersección de esos semiplanos es el polígono sombreado en la Figura 1. Es convexo porque una mezcla de dos planes factibles, con pesos no negativos que suman uno, también respeta todos los límites. Las rectas $12x_1 + 9x_2 = z$ tienen pendiente $-4/3$. A medida que z crece, se desplazan en la dirección de $(12, 9)$. La última recta que toca la región pasa por el cruce de las fronteras de plástico y cobre. Al resolver las dos ecuaciones activas se obtiene $x^{*} = (650, 1100)$ y $z^{*} = 17\,700$.

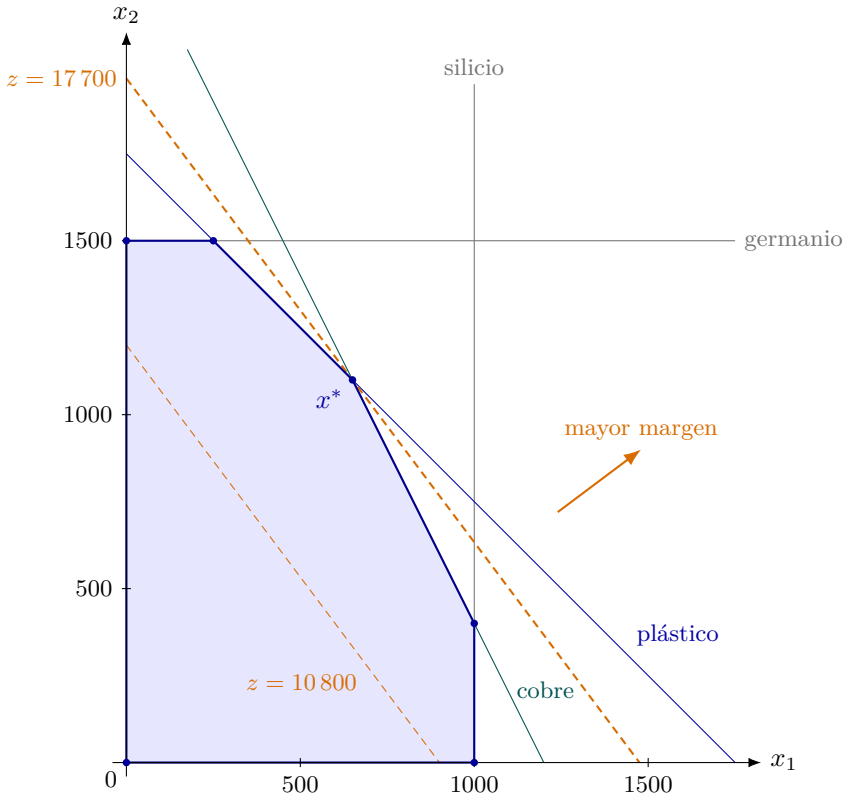


FIGURA 1. Región factible de BIM y rectas de igual margen. La recta de mayor nivel que toca el polígono pasa por x^*.

Por qué basta buscar entre los vértices. Sea P un poliedro acotado y no vacío con vértices $v_1, \dots, v_q$. Cada $x \in P$ se puede escribir como una combinación convexa de esos vértices. Si $M = \max_i c^\top v_i$, entonces

$$x = \sum_{i=1}^{q} \theta_i v_i, \quad \theta_i \geq 0, \quad \sum_{i=1}^{q} \theta_i = 1 \quad \Longrightarrow \quad c^\top x = \sum_{i=1}^{q} \theta_i c^\top v_i \leq M.$$

Un vértice de valor M alcanza la cota. Además, para alcanzar M, cada vértice que entra en la combinación con peso positivo debe tener valor M. Por eso, si hay un solo vértice con ese valor, el óptimo es único. Si hay varios, sus combinaciones convexas también son óptimas. Para un mínimo se obtiene el mismo resultado aplicando el argumento a $-c$.

Contacto en un vértice, una arista o una cara. La recta o plano de nivel de mayor valor que toca el conjunto factible se llama de *soporte*. Todo punto de contacto es óptimo. En la Figura 2, el conjunto es $x_1, x_2 \geq 0$, $x_1 + x_2 \leq 4$. Al maximizar $2x_1 + x_2$, la recta de soporte toca solo $(4, 0)$. Al maximizar $x_1 + x_2$, toca toda la arista $[(4, 0), (0, 4)]$. El punto $(2, 2)$ también alcanza el máximo de 4.

En la Figura 3, el conjunto es el tetraedro $x \geq 0$, $x_1 + x_2 + x_3 \leq 4$. Maximizar $2x_1 + x_2 + x_3$ da 8 solo en $(4, 0, 0)$. Maximizar $x_1 + x_2 + x_3$ da 4 en toda la cara triangular $x_1 + x_2 + x_3 = 4$, incluidos sus tres vértices y su centroide $(4/3, 4/3, 4/3)$.

En BIM, cambiar el objetivo por $x_1 + x_2$ hace óptimo todo el segmento entre $(250, 1500)$ y $(650, 1100)$. En ambos extremos y entre ellos se agota el plástico.

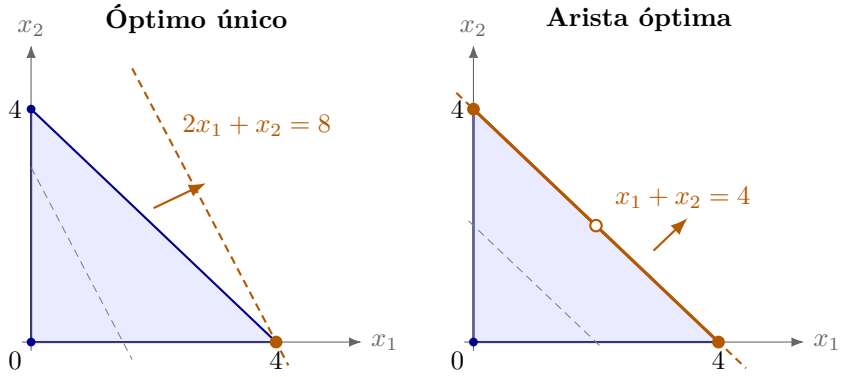


FIGURA 2. En 2D, la última recta de nivel toca un vértice o coincide con una arista. Los círculos llenos en naranja señalan los vértices óptimos y el círculo hueco señala otro óptimo sobre la arista.

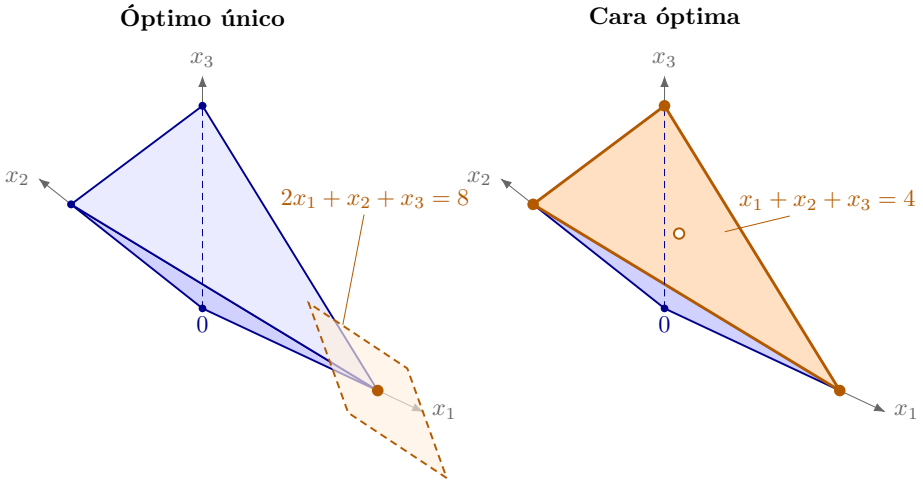


FIGURA 3. En 3D, el plano de soporte toca un vértice o coincide con una cara. El área naranja del panel derecho es toda la cara óptima.

1.3. Forma estándar, vértices y direcciones. Para estudiar el símplex usaremos la convención de minimización

$$\min_{x\in\mathbb{R}^n} c^\top x \qquad \text{sujeto a} \qquad Ax = b, \quad x \geq 0, \qquad A \in \mathbb{R}^{m\times n}. \tag{28}$$

Denotamos su conjunto factible por P. Supondremos $\operatorname{rang}(A) = m$. En (26), con datos originales A_0, c_0, se obtiene esta forma con $A = [A_0 \mid I]$, $x = (u, s)$ y $c = (-c_0, 0)$, donde u es el vector de producción y $s = b - A_0 u \geq 0$ es el vector de holguras. Una desigualdad $\geq$ puede multiplicarse por -1 antes de agregar una holgura. Una variable libre u_j se representa como $u_j^+ - u_j^-$ con $u_j^+, u_j^- \geq 0$.

De los vértices a los sistemas lineales. Se eligen m columnas linealmente independientes de A y se agrupan en la matriz básica B. Las columnas restantes forman N y sus índices componen el conjunto R. En la notación de Bazaraa, al agrupar las columnas y las componentes correspondientes se escribe

$$A = [B \mid N], \qquad Bx_B + Nx_N = b, \qquad x_N = 0 \implies x_B = B^{-1}b = \bar{b}.$$

Las variables de x_B son *básicas* y las de x_N son *no básicas*. Fijar $x_N = 0$ da la *solución básica*, que es factible (SBF) si $\bar{b} \geq 0$. Si alguna variable básica vale cero, la SBF es *degenerada* y puede admitir más de una base. Usaremos B_i para el índice original de la variable básica de la fila i, de modo que x_{B_i} es la componente i de x_B.

Proposición 9.1 (Vértices y bases). *Los puntos extremos de P son exactamente las soluciones básicas factibles de* (28).

Demostración. Si una SBF es una combinación convexa estricta de dos puntos factibles, ambos deben tener sus componentes no básicas nulas, por no negatividad. Los dos resuelven el mismo sistema con la matriz invertible B, así que coinciden con la SBF. Recíprocamente, sea x un punto extremo y $J = \{j : x_j > 0\}$. Si las columnas de A en J fueran dependientes, existiría $d \neq 0$ con $Ad = 0$ y $d_j = 0$ fuera de J. Para $\varepsilon > 0$ pequeño, $x + \varepsilon d$ y $x - \varepsilon d$ serían factibles y tendrían a x como punto medio. Por tanto, las columnas en J son independientes. Como $\operatorname{rang}(A) = m$, se completan hasta una base con columnas de A. Los índices añadidos tienen valor cero y x es la SBF de esa base. □

Existencia de una solución básica factible. Si P es no vacío, tomamos cualquier $x \in P$. Si las columnas asociadas a $x_j > 0$ son dependientes, existe $\gamma \neq 0$ con $A\gamma = 0$ y $\gamma_j = 0$ donde $x_j = 0$. Elegimos su signo para que alguna $\gamma_j > 0$ y tomamos

$$\lambda = \min_{j:\gamma_j > 0} \frac{x_j}{\gamma_j}, \qquad x' = x - \lambda\gamma.$$

Se conserva $Ax' = b$ y, por el cociente mínimo, $x' \geq 0$. Al menos una componente positiva se hace cero y las que ya valían cero siguen en cero. Al repetir disminuye el número de componentes positivas hasta que sus columnas son independientes. Se completan hasta formar una base, como en la demostración anterior.

Un paso factible y un rayo. En la forma estándar, para dar un paso suficientemente pequeño desde $x \in P$ en dirección d, se necesita $Ad = 0$ y $d_j \geq 0$ donde $x_j = 0$. Una componente con $x_j > 0$ puede disminuir hasta agotarse. Para avanzar indefinidamente se necesita $Ad = 0$ y $d \geq 0$ en *todas* las componentes. Estas últimas condiciones definen el cono de recesión de P cuando P es no vacío. Si además $c^\top d < 0$, $c^\top(x + td) \to -\infty$ cuando $t \to \infty$.

Más generalmente, si P es no vacío en forma estándar, su descomposición poliedral expresa cada punto como

$$x = \sum_{i=1}^{p} \lambda_i v_i + \sum_{\ell=1}^{q} \mu_\ell d^\ell, \qquad \lambda_i, \mu_\ell \geq 0, \quad \sum_{i=1}^{p} \lambda_i = 1,$$

donde v_i son los vértices y d^ℓ las direcciones extremas de recesión. Si algún $c^\top d^\ell < 0$, el costo no está acotado inferiormente. Si todos los $c^\top d^\ell \geq 0$, la parte de recesión aporta un costo no negativo y el menor costo entre los vértices es óptimo. Así, un PL en forma estándar con óptimo finito admite un vértice óptimo incluso si P es no acotado.

Ejemplo 9.2 (Misma región, dos resultados). Considérese $x_1, x_2 \geq 0$, $-x_1 + x_2 \leq 2$ y $-x_1 + 2x_2 \leq 6$. Los vértices son $(0,0)$, $(0,2)$ y $(2,4)$. Las direcciones extremas de recesión son $d_1 = (1,0)$ y $d_2 = (2,1)$. Con el objetivo $x_1 - 3x_2$, cada paso unitario a lo largo de d_2 reduce el costo en 1. Con el objetivo $4x_1 - x_2$, ambas direcciones aumentan el costo y el mínimo vale -2, en $(0,2)$.

1.4. Cómo decide un pivote del símplex.

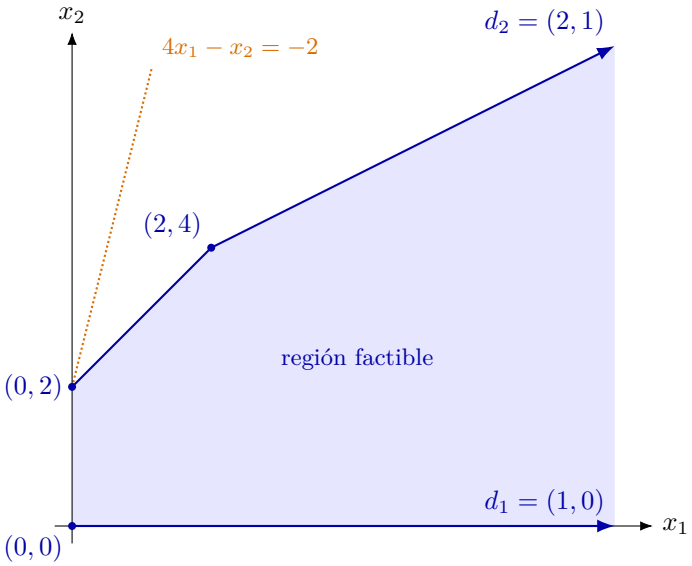


FIGURA 4. Región del ejemplo 9.2. Los dos rayos continúan fuera de la figura. La recta punteada corresponde al mínimo de $4x_1 - x_2$.

Variable entrante y costos reducidos. Desde una base factible despejamos $x_B = \bar{b} - B^{-1}Nx_N$ y lo sustituimos en $z = c_B^\top x_B + c_N^\top x_N$. Para todo punto factible se obtiene

$$z = z_0 + \sum_{j \in R} \bar{c}_j x_j, \qquad z_0 = c_B^\top \bar{b}, \tag{29}$$
$$z_j = c_B^\top B^{-1} a_j, \qquad \bar{c}_j = c_j - z_j.$$

Aquí a_j es la columna j de A. Si todos los $\bar{c}_j \geq 0$, la SBF alcanza z_0 y es óptima en toda la región. Si algún $\bar{c}_j < 0$, ese índice es candidato a entrar. En el código se resuelve $B^\top \pi = c_B$ para evaluar $z_j = a_j^\top \pi$.

Variable saliente y cociente mínimo. Elegimos la entrante x_k con $\bar{c}_k < 0$. Al aumentar solo esa variable no básica, la variable básica de la fila i queda en

$$x_{B_i} = \bar{b}_i - y_{ik} x_k, \qquad y_{ik} = (B^{-1} a_k)_i.$$

Las filas con $y_{ik} > 0$ imponen una cota superior para conservar $x_B \geq 0$. La menor cota fija el mayor paso factible.

$$\bar{x}_k = \min_{i : y_{ik} > 0} \frac{\bar{b}_i}{y_{ik}}. \tag{30}$$

Si r es una fila que alcanza el mínimo, sale x_{B_r} y la columna a_k ocupa su lugar en B. Si todos los $y_{ik} \leq 0$, la dirección d con $d_B = -B^{-1}a_k$, $d_k = 1$ y las demás componentes no básicas nulas cumple $Ad = 0$, $d \geq 0$ y $c^\top d = \bar{c}_k < 0$. Por tanto, certifica que el costo puede disminuir sin límite.

Qué conserva el pivote. Si el cociente mínimo existe, x_{B_r} se hace cero al tomar $x_k = \bar{x}_k$ y el punto sigue factible. Si B' es la nueva matriz, $B^{-1}B'$ coincide con la identidad salvo en la columna r, que es $B^{-1}a_k$. Su determinante es $y_{rk} > 0$, por lo que B' es invertible. Con las nuevas no básicas en cero se tiene otra SBF y

$$z' = z_0 + \bar{c}_k \bar{x}_k.$$

Si $\bar{x}_k > 0$, el costo baja estrictamente. Si $\bar{x}_k = 0$, cambia la base en el mismo punto y el costo queda igual.

Algoritmo 14 Símplex primal revisado en forma estándar

Entrada: A, b, c y una base factible inicial B
Salida: Una SBF óptima o un rayo de mejora

while verdadero **hacer**
  Resolver $B\bar{b} = b$ y $B^\top \pi = c_B$
  Calcular $z_j = a_j^\top \pi$ y $\bar{c}_j = c_j - z_j$ para $j \in R$
  if $\bar{c}_j \geq 0$ para todo $j \in R$ **then**
    Devolver $x_B = \bar{b},\ x_N = 0$
  Fin if
  Elegir el menor $k \in R$ con $\bar{c}_k < 0$ y resolver $By_{\cdot k} = a_k$
  if $y_{\cdot k} \leq 0$ **then**
    Devolver d con $d_B = -y_{\cdot k}$, $d_k = 1$ y $d_j = 0$ para $j \in R \setminus \{k\}$
  Fin if
  Hallar r con (30), con desempate por menor B_r
  Sustituir a_{B_r} por a_k en B y actualizar R
Fin while

Los desempates del algoritmo 14 corresponden a la regla de Bland, que evita el ciclaje en aritmética exacta. En un ciclo todos los pasos tendrían que ser cero, pues repetir una base devuelve el mismo punto y costo. Como hay a lo sumo $\binom{n}{m}$ conjuntos de columnas que pueden ser bases, con Bland el algoritmo termina con un óptimo o un rayo de mejora. Las ecuaciones de cada pivote se resuelven como sistemas lineales, sin formar la inversa de B.

Por ejemplo, en $\min\{-x_2 : x_1 + x_2 = 0,\ x \geq 0\}$ el único punto factible es el origen. Con $B = [a_1]$ se tiene $\bar{c}_2 = -1$ y $\bar{x}_2 = 0$. El pivote cambia a $B' = [a_2]$, que certifica el mismo punto con $\bar{c}_1 = 1$.

¿De dónde sale la primera base? En BIM, las holguras forman la base inicial I y el plan de producción inicial es $(0, 0)$. Si el modelo en forma estándar no proporciona una base factible inmediata, se puede usar una fase I. Tras hacer $b \geq 0$ mediante cambios de signo en filas, se resuelve $\min\{\mathbf{1}^\top a : Ax + a = b,\ x, a \geq 0\}$ desde la base de variables artificiales $a = b$. Un mínimo positivo certifica infactibilidad. Con mínimo cero, las artificiales básicas que aún queden se retiran mediante pivotes o eliminando filas redundantes, antes de restaurar el objetivo original en la fase II. Por ejemplo, $x_1 - x_2 + a_1 = 1$ admite el plan $x_1 = 1$, $x_2 = a_1 = 0$ con mínimo auxiliar cero. En cambio, $-x_1 + a_1 = 1$ exige $a_1 = 1 + x_1 \geq 1$ y certifica que $-x_1 = 1$ es incompatible con $x_1 \geq 0$.

1.4.1. Los tres pivotes de BIM. En la forma estándar, $x_3, \ldots, x_6$ son las holguras de silicio, germanio, plástico y cobre, en ese orden. El costo de minimización es $z = -12x_1 - 9x_2$, y el margen es $-z$.

Primer pivote. La base inicial es $B = I = [a_3 \mid a_4 \mid a_5 \mid a_6]$ y $c_B = 0$. Los costos reducidos son $\bar{c}_1 = -12$ y $\bar{c}_2 = -9$. Entra x_1 por la regla de Bland. Como $B^{-1}a_1 = (1, 0, 1, 4)^\top$,

$$\bar{x}_1 = \min\{1000/1,\ 1750/1,\ 4800/4\} = 1000.$$

El mínimo está en $r = 1$. Sale x_3 y la nueva base es $[a_1 \mid a_4 \mid a_5 \mid a_6]$. El plan es $(1000, 0)$ y el margen es 12 000.

Segundo pivote. Con $B = [a_1 \mid a_4 \mid a_5 \mid a_6]$ tenemos

$$\bar{b} = (1000, 1500, 750, 800)^\top, \qquad R = \{2, 3\}.$$

De $c_B^\top B^{-1} = (-12, 0, 0, 0)$ resultan $(z_2, z_3) = (0, -12)$ y $(\bar{c}_2, \bar{c}_3) = (-9, 12)$. Solo x_2 puede entrar.

$$B^{-1}a_2 = (0, 1, 1, 2)^\top, \qquad \bar{x}_2 = \min\{1500/1,\ 750/1,\ 800/2\} = 400.$$

El mínimo está en $r = 4$. Sale x_6 porque se agota el cobre. Con la nueva base $[a_1 \mid a_4 \mid a_5 \mid a_2]$, el plan es $(1000, 400)$ y el costo es $z' = -12\,000 - 9(400) = -15\,600$.

Tercer pivote. Con $B = [a_1 \mid a_4 \mid a_5 \mid a_2]$ tenemos

$$\bar{b} = (1000, 1100, 350, 400)^\top, \qquad R = \{3, 6\}.$$

De $c_B^\top B^{-1} = (6, 0, 0, -4.5)$ resultan $(z_3, z_6) = (6, -4.5)$ y $(\bar{c}_3, \bar{c}_6) = (-6, 4.5)$. Entra x_3, la holgura de silicio.

$$B^{-1}a_3 = (1, 2, 1, -2)^\top, \qquad \bar{x}_3 = \min\{1000/1,\ 1100/2,\ 350/1\} = 350.$$

El mínimo está en $r = 3$. Sale x_5 porque se agota el plástico. La fila de x_2 tiene $y_{43} = -2$. Por cada unidad adicional de x_3, x_1 cae en uno y x_2 sube en dos, manteniendo el consumo de cobre. El margen sube en $2(9) - 12 = 6$ por unidad de x_3.

Con la nueva base $[a_1 \mid a_4 \mid a_3 \mid a_2]$, el plan es $(650, 1100)$ y el costo es $z' = -15\,600 - 6(350) = -17\,700$. Las únicas no básicas son x_5 y x_6 y sus costos reducidos son 6 y 1.5. Ambos son positivos y certifican la optimalidad del plan. La Figura 5 muestra el recorrido completo.

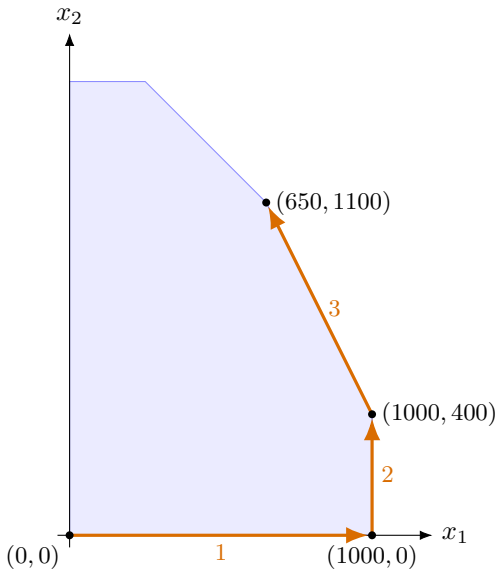


FIGURA 5. Pivotes del símplex primal en BIM. Los cuatro planes tienen márgenes de 0, 12 000, 15 600 y 17 700.

1.5. Certificados y precios sombra. Para el problema de maximización (26), un vector $\lambda \geq 0$ con $A^\top \lambda \geq c$ asigna valores unitarios a los recursos. En cada producto, el valor de los insumos que consume debe cubrir el margen del producto. Cualquier plan factible satisface

$$c^\top x \leq \lambda^\top A x \leq \lambda^\top b. \tag{31}$$

El problema dual busca la menor de estas cotas, minimizando $b^\top \lambda$ sujeto a $A^\top \lambda \geq c$ y $\lambda \geq 0$.

En BIM, $\lambda = (0, 0, 6, 1.5)$ es factible para el dual. La cota vale $6(1750) + 1.5(4800) = 17\,700$, igual al margen del plan $(650, 1100)$. La igualdad certifica la optimalidad del plan. Las holguras son $(350, 400, 0, 0)$. El plástico y el cobre tienen un precio sombra positivo, mientras que aumentar la disponibilidad de silicio o germanio tiene un valor marginal nulo en el modelo.

Si se dispone de una unidad adicional de plástico, las dos restricciones activas se cruzan en $(649, 1102)$. El nuevo plan sigue siendo factible y alcanza $17\,706$, la cota obtenida con el mismo λ y el nuevo b. La unidad adicional de plástico vale 6 unidades monetarias en este margen. Si el cambio de disponibilidad altera la base óptima, se debe recalcular su valor. Cuaderno 2.6 del libro: dual de BIM en Pyomo.

1.6. Implementación en Python. El símplex revisado del algoritmo 14 se implementa en la sección BIM del cuaderno de demostración. Cada pivote se calcula con `numpy.linalg.solve`. El código recibe una base inicial factible y usa una tolerancia absoluta adecuada para estos ejemplos. Para resolver el modelo directamente a partir de las desigualdades, se compara el resultado con HiGHS desde SciPy. Referencia de `linprog`. Abrir el cuaderno de programación lineal en Colab.

```
import numpy as np
from scipy.optimize import linprog

c = np.array([12., 9.])
A = np.array([[1., 0.], [0., 1.], [1., 1.], [4., 2.]])
b = np.array([1000., 1500., 1750., 4800.])

res = linprog(-c, A_ub=A, b_ub=b, bounds=(0, None),
              method="highs")
if not res.success:
    raise RuntimeError(res.message)

print(res.x, -res.fun)
print(b - A @ res.x)
print(-res.ineqlin.marginals)
```

Las tres salidas son el plan y su margen, $(650, 1100)$ y $17\,700$, las holguras $(350, 400, 0, 0)$ y los precios sombra $(0, 0, 6, 1.5)$. El signo menos en la última línea recupera los marginales del *máximo* de BIM a partir de los del *mínimo* que devuelve `linprog`. Para comprobar el precio del plástico, el cuaderno también resuelve el modelo con $b_3 = 1751$.

1.7. Regresión LAD y cartera MAD con Pyomo. Las formulaciones de esta sección se basan en los cuadernos de Postek, Zocca, Gromicho y Kantor (2025), *Hands-On Mathematical Optimization with Python*, Cambridge University Press. Índice de los cuadernos del libro.

Pyomo permite escribir el modelo con variables, restricciones y objetivos. HiGHS lo resuelve a través de la interfaz de Python `highspy`. Los ejemplos LAD y MAD están en el mismo cuaderno. En Colab, elige **Entorno de ejecución** → **Ejecutar todas**.

```
%pip install -q numpy scipy matplotlib pyomo highspy
```

La celda de instalación prepara el entorno del cuaderno. Los fragmentos siguientes también se pueden ejecutar en orden. El primero comprueba la disponibilidad del solver y define una función que verifica la terminación antes de cargar los valores.

```
import pyomo.environ as pyo

solver = pyo.SolverFactory("appsi_highs")
if not solver.available(exception_flag=False):
    raise RuntimeError("HiGHS requiere el paquete highspy.")

def resolver(modelo, solver):
    resultado = solver.solve(modelo, load_solutions=False)
    pyo.assert_optimal_termination(resultado)
    modelo.solutions.load_from(resultado)
```

La opción `load_solutions=False` permite inspeccionar la terminación del solver, incluso si el modelo es infactible. Una vez cargada la solución, `pyo.value` evalúa variables, expresiones y objetivos. Instalación de Pyomo y solvers en el libro.

Regresión de mínima suma de desviaciones absolutas (LAD). LAD significa *least absolute deviation*. Si y_i es el gasto observado de un hogar y z_i reúne sus regresores, se puede estimar un intercepto α y un vector β por mínima suma de errores absolutos. Con $y_i - \alpha - z_i^\top \beta = p_i - q_i$, el programa lineal es

$$\begin{aligned} \text{mín} \quad & \sum_{i=1}^{n} (p_i + q_i) \\ \text{sujeto a} \quad & \alpha + z_i^\top \beta + p_i - q_i = y_i \qquad (i = 1, \dots, n), \\ & p_i, q_i \geq 0, \qquad \alpha, \beta_j \text{ libres.} \end{aligned}$$

Si p_i y q_i fueran ambos positivos, se podría restarles la misma cantidad y reducir el objetivo manteniendo el residuo. Así, en el óptimo, $p_i + q_i = |y_i - \alpha - z_i^\top \beta|$. Con solo un intercepto, el problema estima una mediana muestral. Cuaderno 2.2 del libro: formulación y código de LAD.

Ajuste de una recta con LAD. Usamos cinco observaciones sintéticas de ingreso z y gasto y. Con un solo regresor, β es la pendiente. Se declara una igualdad por observación y se especifica el dominio de cada variable. `RangeSet` incluye ambos extremos.

```
z = (0, 1, 2, 3, 4)
y = (1, 3, 15, 7, 9)
lad = pyo.ConcreteModel("LAD")
lad.I = pyo.RangeSet(0, len(y) - 1)
lad.alpha = pyo.Var(domain=pyo.Reals)
lad.beta = pyo.Var(domain=pyo.Reals)
lad.p = pyo.Var(lad.I, domain=pyo.NonNegativeReals)
lad.q = pyo.Var(lad.I, domain=pyo.NonNegativeReals)

@lad.Constraint(lad.I)
def residuo(m, i):
    return m.alpha + z[i] * m.beta + m.p[i] - m.q[i] == y[i]

lad.error = pyo.Objective(
    expr=sum(lad.p[i] + lad.q[i] for i in lad.I),
    sense=pyo.minimize,
)
resolver(lad, solver)
print(pyo.value(lad.alpha), pyo.value(lad.beta),
      pyo.value(lad.error))
```

Interpretación. La salida es `1.0 2.0 10.0`. La recta $\hat{y} = 1 + 2z$ pasa por cuatro de las cinco observaciones. Para $z = 2$, predice 5 frente a un gasto observado de 15. Ese residuo positivo de 10 explica toda la suma de errores absolutos, medida en unidades de gasto.

Cartera de mínima desviación absoluta media (MAD). MAD significa *mean absolute deviation*. Sea r_{tj} el retorno del activo j en el período t y $\bar{r}_j$ su media muestral. Con pesos w_j y desvíos auxiliares p_t, q_t, el modelo es

$$
\begin{aligned}
\text{mín} \quad & \frac{1}{T}\sum_{t=1}^{T}(p_t + q_t) \\
\text{sujeto a} \quad & p_t - q_t = \sum_{j=1}^{J}(r_{tj} - \bar{r}_j)w_j \qquad (t = 1, \dots, T), \\
& \sum_{j=1}^{J}\bar{r}_j w_j \geq R, \qquad \sum_{j=1}^{J} w_j = 1, \\
& 0 \leq w_j \leq u_j \qquad (j = 1, \dots, J), \\
& p_t, q_t \geq 0 \qquad (t = 1, \dots, T).
\end{aligned}
$$

R fija el retorno medio mínimo y u_j limita el peso del activo j. Al elevar R, el MAD mínimo puede subir o quedar igual mientras exista una cartera factible. Cuaderno 2.3 del libro: modelo MAD y aplicación a datos históricos.

Modelo MAD de dos activos. Usamos retornos sintéticos de dos activos durante cuatro períodos. A tiene un retorno medio de 4 % por período y B, de 2 %. Se invierte todo el presupuesto, con pesos entre 0 y 80 % por activo. En el código, 3 % se escribe `0.03`. La opción `mutable=True` permite cambiar R y resolver el mismo modelo.

```
r = {"A": (0.00, 0.02, 0.06, 0.08),
     "B": (0.04, 0.03, 0.01, 0.00)}
media = {j: sum(serie) / len(serie) for j, serie in r.items()}

mad = pyo.ConcreteModel("Cartera MAD")
mad.J = pyo.Set(initialize=list(r))
mad.T = pyo.RangeSet(0, len(r["A"]) - 1)
mad.R = pyo.Param(initialize=0.03, mutable=True)
mad.w = pyo.Var(mad.J, bounds=(0, 0.8))
mad.p = pyo.Var(mad.T, domain=pyo.NonNegativeReals)
mad.q = pyo.Var(mad.T, domain=pyo.NonNegativeReals)

@mad.Constraint(mad.T)
def desvio(m, t):
    return m.p[t] - m.q[t] == sum(
        (r[j][t] - media[j]) * m.w[j] for j in m.J
    )

mad.presupuesto = pyo.Constraint(expr=sum(mad.w.values()) == 1)
mad.retorno = pyo.Expression(
    expr=sum(media[j] * mad.w[j] for j in mad.J)
)
mad.meta = pyo.Constraint(expr=mad.retorno >= mad.R)
mad.riesgo = pyo.Objective(
    expr=sum(mad.p[t] + mad.q[t] for t in mad.T) / len(mad.T),
    sense=pyo.minimize,
)
```

`Expression` da un nombre al retorno medio de la cartera. Así se puede usar en la restricción de retorno y consultarlo al reportar la solución. En el óptimo, `p[t]` y `q[t]` representan los desvíos por encima y por debajo de ese retorno medio.

Cambio de la meta de retorno. `set_value` actualiza la meta de retorno entre escenarios. Después de cada resolución, el código reporta los pesos, el retorno medio y el riesgo MAD en porcentajes.

```
for meta in (0.03, 0.035):
    mad.R.set_value(meta)
    resolver(mad, solver)
    pesos = {j: pyo.value(mad.w[j]) for j in mad.J}
    print(f"Meta: {meta:.1%}")
    print({j: f"{w:.1%}" for j, w in pesos.items()})
    print(f"Retorno: {pyo.value(mad.retorno):.3%}")
    print(f"MAD: {pyo.value(mad.riesgo):.3%}")
```

Meta R	Peso de A	Peso de B	Retorno medio	MAD
3.0 %	50 %	50 %	3.000 %	0.750 %
3.5 %	75 %	25 %	3.500 %	1.875 %

Interpretación. Con la primera meta, los retornos de la cartera en los cuatro períodos son 2 %, 2.5 %, 3.5 % y 4 %. Sus distancias absolutas respecto a la media del 3 % son 1, 0.5, 0.5 y 1 puntos porcentuales. El promedio de esas distancias es 0.750 puntos porcentuales. Al exigir 3.5 %, la cartera necesita más peso en A. En esta muestra se reduce la compensación entre las variaciones de los dos activos y el MAD sube a 1.875 puntos porcentuales. Ambas metas se cumplen con igualdad.

El límite de peso permite diagnosticar una meta infactible. Aun asignando a A su máximo de 80 %, el retorno medio solo llega a $0.8(4\,\%) + 0.2(2\,\%) = 3.6\,\%$. Una meta de 4 % haría que la verificación de terminación detuviera el código antes de leer los pesos.

Fuente de los fundamentos geométricos y algebraicos. Método del Simplex: Fundamentos y Pseudocódigo, material del curso Optimización para Machine Learning basado en Bazaraa, Jarvis y Sherali. El ejemplo de recesión adapta el ejemplo 3.1 de ese material.

2. Optimización sin restricciones

2.1. Dirección de descenso. Dada una función $f\colon \mathbb{R}^n \to \mathbb{R}$ de clase C^1, buscamos un minimizador de

$$\min_{x \in \mathbb{R}^n} f(x). \tag{32}$$

Un mínimo local satisface $\nabla f(x^*) = 0$. El método actualiza

$$x^{(k+1)} = x^{(k)} + \alpha_k d_k, \qquad \alpha_k > 0.$$

Si $\nabla f(x^{(k)})^{\mathsf{T}} d_k < 0$, la derivada direccional es negativa y los pasos positivos suficientemente cortos reducen f. En particular, con $d_k = -\nabla f(x^{(k)})$ se obtiene la dirección del descenso del gradiente. Normalizada, es la dirección unitaria de mayor disminución instantánea en norma euclidiana, por Cauchy–Schwarz.

En el laboratorio se usa $\|\nabla f(x^{(k)})\| \le \varepsilon$ como criterio de estacionariedad aproximada y se limita el número de iteraciones. Estudiaremos primero un paso constante $\alpha_k = \alpha$ y luego dos reglas que eligen el paso en cada iteración.

2.2. Descenso del gradiente con paso fijo. El análisis de esta subsección sigue a Sven-Ake Wegner, *Mathematische Einführung in Data Science*, capítulo 17. Usaremos la norma euclidiana y la iteración $x^{(k+1)} = x^{(k)} - \alpha \nabla f(x^{(k)})$.

Si f es convexa y diferenciable, el plano tangente da la cota inferior $f(y) \ge f(x) + \nabla f(x)^{\mathsf{T}}(y - x)$. En particular, $\nabla f(x) = 0$ caracteriza un mínimo global. La convexidad por sí sola no determina el paso. Para $f(x) = x^2$, la iteración multiplica

por $1-2\alpha$. Si $x^{(0)} \neq 0$, converge al mínimo cuando $0 < \alpha < 1$, oscila si $\alpha = 1$ y diverge si $\alpha > 1$.

Suavidad y descenso. Si ∇f es L-Lipschitz, integrar la derivada a lo largo del segmento de x a y y aplicar Cauchy–Schwarz da

$$f(y) \leq f(x) + \nabla f(x)^{\mathsf{T}}(y-x) + \tfrac{L}{2}\|y-x\|^2. \tag{33}$$

En efecto, con $s = y - x$, el integrando que queda después de restar el término lineal es $[\nabla f(x+ts) - \nabla f(x)]^{\mathsf{T}} s \leq Lt\|s\|^2$. Al tomar $y = x - \alpha\nabla f(x)$ resulta

$$f(y) \leq f(x) - \alpha(1 - L\alpha/2)\|\nabla f(x)\|^2.$$

Por tanto, $0 < \alpha < 2/L$ asegura descenso en cada punto no estacionario.

Convexidad y tasa sublineal. Una desigualdad útil combina la cota de primer orden con (33). Para $u, v \in \mathbb{R}^n$,

$$f(u) - f(v) - \nabla f(v)^{\mathsf{T}}(u-v) \geq \frac{\|\nabla f(u) - \nabla f(v)\|^2}{2L}. \tag{34}$$

Para verla, se aplica (33) a $h(z) = f(z) - \nabla f(v)^{\mathsf{T}} z$, desde u hasta $u - \nabla h(u)/L$. El valor de h allí es al menos $h(v)$ por convexidad y a lo sumo $h(u) - \|\nabla h(u)\|^2/(2L)$ por la cota superior.

Supongamos que existe un minimizador x^* y usemos $\alpha = 1/L$. Si $g_k = \nabla f(x^{(k)})$ y $\delta_k = f(x^{(k)}) - f(x^*)$, al aplicar (34) con $u = x^*$ y $v = x^{(k)}$ se obtiene

$$g_k^{\mathsf{T}}(x^{(k)} - x^*) \geq \delta_k + \frac{\|g_k\|^2}{2L}.$$

Al desarrollar $\|x^{(k)} - x^* - g_k/L\|^2$, esta desigualdad muestra que la distancia a x^* decrece en sentido no estricto. En particular, $\|x^{(k)} - x^*\| \leq R := \|x^{(0)} - x^*\|$. Si aún no se ha llegado al mínimo, $\delta_k \leq R\|g_k\|$ y $\delta_k - \delta_{k+1} \geq \|g_k\|^2/(2L) \geq \delta_k^2/(2LR^2)$. Para $\delta_{k+1} > 0$,

$$\frac{1}{\delta_{k+1}} - \frac{1}{\delta_k} \geq \frac{1}{2LR^2}.$$

Al sumar se obtiene $\delta_k \leq 2LR^2/k$ para $k \geq 1$. La sucesión de iterados es acotada y cada punto de acumulación minimiza f por continuidad. La distancia a ese minimizador decrece y una subsucesión la lleva a cero. Así, toda la sucesión converge a un minimizador.

Convexidad fuerte. Para $\mu > 0$, la función f es μ-fuertemente convexa si $f(x) - \mu\|x\|^2/2$ es convexa. En forma diferencial,

$$f(y) \geq f(x) + \nabla f(x)^{\mathsf{T}}(y-x) + \tfrac{\mu}{2}\|y-x\|^2.$$

Al fijar $x = 0$, la cota inferior cuadrática implica coercividad. Por continuidad existe un mínimo y la convexidad estricta asegura su unicidad. Con suavidad, ambas cotas implican $0 < \mu \leq L$.

Lema 9.2 (Desigualdad de interpolación de Wegner). *Si f es μ-fuertemente convexa y L-suave, para $s = y - x$ y $g = \nabla f(y) - \nabla f(x)$ se cumple*

$$g^{\mathsf{T}} s \geq \frac{\mu L}{\mu + L}\|s\|^2 + \frac{1}{\mu + L}\|g\|^2.$$

Demostración. Si $L > \mu$, la función convexa $h(z) = f(z) - \mu\|z\|^2/2$ tiene la cota superior (33) con constante $L - \mu$. Se aplica el argumento de (34) a h en ambos órdenes y se suman las desigualdades. Así, $(g - \mu s)^{\mathsf{T}} s \geq \|g - \mu s\|^2/(L-\mu)$. Al desarrollar el cuadrado resulta la desigualdad deseada. Si $L = \mu$, las cotas inferior y superior coinciden y h es afín. En este caso $g = \mu s$ y se cumple la igualdad. $\square$

Teorema 9.3 (Convergencia lineal con paso fijo). *Bajo las hipótesis del lema, para* $\alpha = 2/(\mu + L)$ *y* $q = (L - \mu)/(L + \mu)$ *se cumple, para* $k \geq 1$,

$$\|x^{(k)} - x^*\| \leq q^k \|x^{(0)} - x^*\|, \qquad f(x^{(k)}) - f(x^*) \leq \tfrac{L}{2} q^{2k} \|x^{(0)} - x^*\|^2.$$

Demostración. Sea $e_k = x^{(k)} - x^*$ y $g_k = \nabla f(x^{(k)})$, ya que $\nabla f(x^*) = 0$. El lema anterior da

$$\begin{aligned} \|e_{k+1}\|^2 &= \|e_k\|^2 - 2\alpha g_k^{\mathsf{T}} e_k + \alpha^2 \|g_k\|^2 \\ &\leq \left(1 - \frac{2\alpha\mu L}{\mu + L}\right) \|e_k\|^2 + \left(\alpha^2 - \frac{2\alpha}{\mu + L}\right) \|g_k\|^2. \end{aligned}$$

El paso elegido cancela el término en $\|g_k\|^2$ y deja q^2 como factor de contracción de la distancia al cuadrado. Iterar y aplicar (33) desde x^* da las dos cotas. $\square$

En términos de $\kappa = L/\mu$, se tiene $q = (\kappa - 1)/(\kappa + 1)$. Si κ es grande, la garantía de reducción por paso es pequeña.

Ejemplo 9.3 (Ajuste de demanda por mínimos cuadrados). Para los precios simulados $P = (6, 8, 10, 12, 14)$ y las cantidades observadas simuladas $Q = (63, 53, 49, 43, 32)$, se ajusta $\widehat{Q}(P) = a + b(P - 10)$ minimizando

$$f(a, b) = \frac{1}{10} \sum_{i=1}^{5} \big(a + b(P_i - 10) - Q_i\big)^2.$$

La matriz hessiana es $\operatorname{diag}(1, 8)$ porque los precios centrados tienen media cero y segundo momento igual a 8. Por tanto, $\mu = 1$, $L = 8$ y el paso de Wegner es $2/9$. La solución es $(a^*, b^*) = (48, -3.6)$. El ajuste asocia una unidad adicional de precio con 3.6 unidades menos de demanda.

En el laboratorio se compara el paso fijo con Armijo y Powell–Wolfe desde el mismo punto inicial, midiendo tanto iteraciones como evaluaciones.

2.3. Búsqueda lineal. Para elegir un paso, fijamos el iterado x y la dirección de descenso d y definimos

$$\phi(\alpha) = f(x + \alpha d), \qquad \phi'(\alpha) = \nabla f(x + \alpha d)^{\mathsf{T}} d.$$

Una búsqueda lineal inexacta prueba candidatos hasta encontrar un paso que cumpla las condiciones de aceptación.

Armijo y disminución suficiente. Fijado $0 < c_1 < 1$, la condición de Armijo exige

$$\phi(\alpha) \leq \phi(0) + c_1 \alpha \phi'(0). \tag{35}$$

Como $\phi'(0) < 0$, el lado derecho queda por debajo de $\phi(0)$. Para α pequeño,

$$\phi(\alpha) - \phi(0) - c_1 \alpha \phi'(0) = (1 - c_1)\alpha \phi'(0) + o(\alpha) < 0.$$

Esto garantiza que el retroceso con paso de prueba $\bar{\alpha} > 0$ y factor $0 < \rho < 1$ termina en aritmética exacta.

Algoritmo 15 Retroceso de Armijo

Entrada: ϕ con $\phi'(0) < 0$, $\bar{\alpha} > 0$, $0 < c_1 < 1$ y $0 < \rho < 1$

```
α ← ᾱ
while φ(α) > φ(0) + c1 α φ'(0) hacer
    α ← ρ α
Fin while
Devolver α
```

Para $d = -\nabla f(x)$ y ∇f globalmente L-Lipschitz, la cota cuadrática (33) garantiza Armijo para $0 < \alpha \le T = 2(1 - c_1)/L$. El paso aceptado cumple $\alpha \ge \min\{\bar{\alpha}, \rho T\}$. En efecto, si hubo un rechazo antes de aceptar, el candidato previo era mayor que T. Si además f está acotada inferiormente, la disminución en cada iteración es al menos $c_1 \min\{\bar{\alpha}, \rho T\}\|\nabla f(x)\|^2$. Al sumar esas disminuciones se obtiene que las normas del gradiente tienden a cero.

Powell–Wolfe y condición de curvatura. Con $0 < c_1 < c_2 < 1$, se exige Armijo y también

$$\phi'(\alpha) \ge c_2 \phi'(0). \tag{36}$$

La segunda desigualdad descarta candidatos cuya pendiente sigue demasiado cerca de la pendiente inicial. Juntas forman las condiciones de Wolfe débil.

Interpretación y cálculo del paso. Escribamos $\phi(\alpha) = f(x + \alpha d)$, con $\phi'(0) < 0$. Armijo compara ϕ con la recta de pendiente $c_1\phi'(0)$. La condición de curvatura exige que la pendiente en el candidato haya subido al menos hasta $c_2\phi'(0)$. Para el perfil $\phi(\alpha) = (\alpha - 1)^2$, con $c_1 = 0.2$ y $c_2 = 0.5$, la primera condición equivale a $0 < \alpha \le 1.6$ y la segunda a $\alpha \ge 0.5$. La intersección $[0.5, 1.6]$ es el intervalo que se grafica en la presentación.

Lema 9.4 (Existencia de un paso de Powell–Wolfe). *Si ϕ es continuamente diferenciable y acotada inferiormente en $[0, \infty)$, $\phi'(0) < 0$ y $0 < c_1 < c_2 < 1$, existe un paso positivo que satisface ambas condiciones.*

Demostración. Sea $\psi(\alpha) = \phi(\alpha) - \phi(0) - c_1\alpha\phi'(0)$. Como $\psi(0) = 0$ y $\psi'(0) = (1 - c_1)\phi'(0) < 0$, se tiene $\psi < 0$ para pasos positivos suficientemente pequeños. Además $\psi(\alpha)$ tiende a $+\infty$ por la cota inferior de ϕ. Sea b la primera raíz positiva de ψ. El teorema del valor medio da $\psi'(a) = 0$ para algún $a \in (0, b)$. Allí $\psi(a) < 0$ y $\phi'(a) = c_1\phi'(0) > c_2\phi'(0)$. □

Para hallar un paso, el laboratorio expande el candidato mientras satisface Armijo y falla curvatura. En cuanto falla Armijo, queda un intervalo con un extremo inferior de pendiente demasiado negativa y un extremo superior que falla la condición de descenso. El extremo inferior puede empezar en cero. Se prueba el punto medio y se reemplaza el extremo que corresponda hasta aceptar un candidato que cumpla ambas condiciones. Se fija un máximo de pruebas para controlar el costo numérico.

Teorema 9.5 (Descenso suficiente con Powell–Wolfe). *Si ∇f tiene constante de Lipschitz $L > 0$ en el segmento del paso, todo paso α que cumple Powell–Wolfe verifica*

$$f(x + \alpha d) \le f(x) - \frac{c_1(1 - c_2)}{L} \left(\frac{\nabla f(x)^{\mathsf{T}} d}{\|d\|} \right)^2 .$$

Demostración. Por curvatura y suavidad,

$$(1 - c_2)(-\phi'(0)) \le \phi'(\alpha) - \phi'(0) \le L\alpha\|d\|^2.$$

Se inserta la cota inferior para α en Armijo, usando $\phi'(0) < 0$. □

Bibliografía

[1] R. L. Burden and D. J. Faires. *Numerical Analysis*. Brooks Cole, December 2004.

[2] K. L. Judd. *Numerical Methods in Economics*, volume 1 of *MIT Press Books*. The MIT Press, 1 edition, December 1998.

[3] D. R. Kincaid and E. W. Cheney. *Numerical Analysis*. Brooks/Cole Publishing Company, 1991.

[4] J. Stoer and R. Bulirsch. *Introduction to numerical analysis*, volume 12 of *Texts in Applied Mathematics*. Springer-Verlag, New York, third edition, 2002. Translated from the German by R. Bartels, W. Gautschi and C. Witzgall.