MÉTODOS NUMÉRICOS

130146-A

Facultad de Economía

Universidad del Pacífico

Actualizado al 2 de noviembre de 2026

Oswaldo Velásquez C.

Índice general

Capítulo 1. Análisis de errores 5
1. Representación de números 5
2. Errores de redondeo y aritmética de punto flotante 6
3. Propagación de errores 8
4. Ejercicios 16

Capítulo 2. Introducción a los métodos iterativos 19
1. Convergencia de sucesiones escalares 19
2. Convergencia de sucesiones de vectores 19
3. Velocidades de convergencia 20
4. Carácter local de la velocidad 21
5. Criterios de parada 22

Capítulo 3. Sistemas de ecuaciones lineales 23
1. Fundamentos 23
2. Eliminación de Gauss 28
3. La factorización LU 31
4. Errores y condición de una matriz 34
5. Factorización LU para sistemas especiales 38
6. La Factorización QR 40
7. Ejemplos 46
8. Ejercicios 51
9. El teorema del punto fijo de Banach 54
10. Soluciones de sistemas de ecuaciones lineales por métodos iterativos 55

Capítulo 4. Sistemas de ecuaciones no lineales 65
1. Métodos unidimensionales 65
2. Teoremas de convergencia 69
3. Métodos de Minimización 74

Capítulo 5. Aproximación lineal 81
1. Introducción 81
2. Ecuaciones normales 81
3. Tratamiento numérico 83
4. Ejercicios 83

Capítulo 6. Interpolación 85
1. Interpolación polinomial 85
2. Splines cúbicos 95
3. Interpolación trigonométrica 98
4. Ejercicios 103

Capítulo 7. Integración Numérica 107
1. Fórmulas de Newton-Cotes 107
2. Fórmula de Cuadratura de Gauss 112

Capítulo 8. Ecuaciones Diferenciales Ordinarias 115
1. Problemas de valor inicial 115

Capítulo 9. Optimización numérica 121
1. Mínimo local. Dirección de descenso 121
2. Optimización numérica con restricciones 136
3. Métodos de penalización 136
4. Programación cuadrática 142

Bibliografía 145

Capítulo 1

Análisis de errores

Acceder a la precisión de los resultados de los cálculos es una meta importante en el análisis numérico. Podemos distinguir varias clases de error que pueden limitar esta precisión:

- *Errores en los datos de entrada*, provocados por limitaciones y/o imperfecciones de los instrumentos físicos;
- *Errores de redondeo*, por el cálculo de números que están representados con un número finito de dígitos;
- *Errores de aproximación*, cuando aproximamos la solución de un problema P resolviendo un problema P'. Un ejemplo de esto es la aproximación de una suma infinita por otra finita;

$$e \approx 1 + \frac{1}{1!} + \frac{1}{2!} + \cdots + \frac{1}{N!}$$

El error resultante de aproximación es llamado comúnmente *error de truncamiento*. Lo que hacemos es discretizar un problema: por ejemplo cocientes diferenciales son aproximados por cocientes de diferencias, integrales definidas por sumas finitas, etc. En dichos casos, el error de aproximación es llamado *error de discretización*.
En este capítulo se analizarán los dos primeros tipos de errores.

1. Representación de números

Se presentan dos tipos de máquinas según la manera en la que representan los números:

1. *Computadoras analógicas*, se caracterizan por resolver un problema matemático simulándolo por un problema físico, resolviéndolo por medición y retornando un resultado. Los números son representados por cantidades físicas, como por ejemplo, la longitud de una barra o la intensidad de un voltaje. Es claro que la precisión de los dispositivos analógicos se encuentra directamente limitada por las mediciones físicas que emplean.
2. *Computadoras digitales*, entre las cuales se encuentran las computadoras personales (PC); expresan los dígitos de la representación de un número por una secuencia discreta de cantidades físicas. Un ejemplo de esto es la representación del número binario 11010110 con una secuencia de ocho diodos: el 1 se representa con el diodo encendido, y el 0 con el diodo apagado. La representación de dígitos en computadoras digitales no requiere tanta precisión como la representación de números en las computadoras analógicas. Nosotros estudiaremos este tipo de computadoras.

Un número entero N se puede representar como

$$N = \pm(\alpha_n p^n + \alpha_{n-1} p^{n-1} + \cdots + \alpha_0)$$

donde $p \in \mathbb{N}, p > 1$ es la *base* del sistema de numeración y $\alpha_i \in \{0, 1, \ldots, (p-1)\}$, $i = 0, 1, \ldots, n$

EJEMPLO 1.1. El número 18 (base 10) admite la descomposición en base 2:

$$18 = 1 \cdot 2^4 + 0 \cdot 2^3 + 0 \cdot 2^2 + 1 \cdot 2^1 + 0 \cdot 2^0 = 10010_{(2)}$$

Un número arbitrario se puede representar, en particular, en base 2, como:

$$x = \pm(\alpha_n 2^n + \alpha_{n-1} 2^{n-1} + \cdots + \alpha_o 2^0 + \alpha_{-1} 2^{-1} + \alpha_{-2} 2^{-2} + \cdots)$$

donde $\alpha_i \in \{0, 1\}$. Para cualquier otra base se puede realizar esto de manera análoga.

En las computadoras digitales se ha de representar los números con un número finito de lugares, la *longitud de palabra*. La *representación de punto fijo* especifica un número fijo n_1 de lugares antes de y un número fijo n_2 de lugares después del punto decimal (binario), tales que $n = n_1 + n_2 =$ longitud de palabra (usualmente $n_1 = 0$ o $n_1 = n$). De este modo, un número x se representa en la máquina como (en base 2)

$$x = \pm(\alpha_{n_1-1} 2^{n_1-1} + \alpha_{n_1-2} 2^{n_1-2} + \cdots + \alpha_0 2^0 + \alpha_{-1} 2^{-1} + \alpha_{-2} 2^{-2} + \cdots + \alpha_{-n_2} 2^{-n_2})$$

EJEMPLO 1.2. Para $n = 10$, $n_1 = 4$, $n_2 = 6$

$$145{,}6132 \rightarrow \boxed{0145}\boxed{613200}$$

En esta representación, la posición del punto decimal (binario) es fija.

Más importante es la *representación de punto flotante*. Aquí el punto decimal (binario) no se encuentra fijo. Esto es hecho con un *exponente*. Cada número puede ser representado en la forma

$$x = a \cdot 10^b (x = a \cdot 2^b) \text{ con } |a| < 1, b \text{ entero}$$

EJEMPLO 1.3. $30{,}421 = 0{,}30241 \cdot 10^2$.

El exponente b indica la posición del punto decimal con respecto a la *mantisa* a. Rutishauser propuso la notación : $0{,}30241_{10}2$
En cada computadora existen, por supuesto, números finitos t y e, $n = t + e$, de lugares disponibles para la representación de mantisa y exponente, respectivamente.

EJEMPLO 1.4. Para $t = 4$, $e = 2$, el número 5420 en el sistema decimal se expresa:

$$0\boxed{5420}_{10}\boxed{04}$$

o bien

$$\boxed{5420}\boxed{04}$$

Una representación de punto flotante es *normalizada* si el primer dígito de la mantisa es distinto de 0. Entonces $|a| \geq 10^{-1}$ ($|a| \geq 2^{-1}$). Los *dígitos significativos (bits)* de un número son los dígitos de la mantisa sin contar ceros al principio.

En lo que sigue, consideraremos solamente representaciones de punto flotante y su aritmética de punto flotante correspondiente. Los números t y e, junto con la base B, determinan el conjunto $A \subset \mathbb{R}$ de los números reales que pueden ser representados exactamente con una computadora dada. Los elementos de A son llamados *números de máquina*.

2. Errores de redondeo y aritmética de punto flotante

El conjunto A de números de máquina es finito. Luego surgen las preguntas: ¿ Cómo representar un número $x \notin A$? Además, dados dos números de máquina, es posible que su suma o su producto no sean números de máquina.
Es natural postular que la aproximación de cualquier número $x \notin A$ por un número de máquina $\mathrm{rd}(x)$ deba cumplir la condición

$$\big|x - \mathrm{rd}(x)\big| \leq |x - g|, \quad \text{para todo } g \in A.$$

EJEMPLO 1.5. Para $t = 4$

$$\begin{aligned} \mathrm{rd}(0{,}14285_{10}0) &= 0{,}1429_{10}0 \\ \mathrm{rd}(3{,}14159_{10}0) &= 0{,}3142_{10}1 \end{aligned}$$

En general se procede como sigue: $x \notin A$ se normaliza primero a $x = a \cdot 10^b$, donde $|a| \geq 10^{-1}$. Supongamos que la representación decimal de $|a|$ es dada por

$$|a| = 0.\alpha_1\alpha_2 \ldots \alpha_i\alpha_{i+1} \ldots, \quad 0 \leq \alpha_i \leq 9, \quad \alpha_1 \neq 0.$$

Entonces se forma

$$a' := \begin{cases} 0.\alpha_1\alpha_2 \ldots \alpha_t & \text{si } 0 \leq \alpha_{t+1} \leq 4, \\ 0.\alpha_1\alpha_2 \ldots \alpha_t + 10^{-t} & \text{si } \alpha_{t+1} \geq 5 \end{cases}$$

Finalmente se coloca

$$\mathrm{rd}'(x) := \mathrm{sign}(x) \cdot a' \cdot 10^b.$$

NOTA. Cuando se aproxima un número real x mediante otro número x^* el *error* que resulta es $(x - x^*)$. El *error absoluto* es $|x - x^*|$ y el *error relativo* es $\left|\dfrac{x - x^*}{x}\right| \approx \left|\dfrac{x - x^*}{x^*}\right|$ si $x \neq 0$.

El error relativo de aproximar x por $\mathrm{rd}'(x)$ es (recordar que $|a| \geq 10^{-1}$)

$$\left|\frac{\mathrm{rd}'(x) - x}{x}\right| \leq \frac{5 \cdot 10^{-(t+1)}}{|a|} \leq 5 \cdot 10^{-t}.$$

Con la abreviación $\mathrm{eps} = 5 \cdot 10^{-t}$ podemos escribir

$$\mathrm{rd}'(x) = x(1 + \varepsilon), \text{ con } |\varepsilon| \leq \mathrm{eps}\,.$$

La cantidad $\mathrm{eps} = 5 \cdot 10^{-t}$ es llamada *precisión de la máquina* . En el sistema binario, podemos definir todo lo anterior análogamente.

Siempre que $\mathrm{rd}'(x) \in A$, se podrá definir correctamente $\mathrm{rd}'(x) := \mathrm{rd}(x)$. Sin embargo, esto no siempre ocurre como se muestra en el siguiente ejemplo.

EJEMPLO 1.6. Para $t = 4$, $e = 2$ tenemos

$$\begin{aligned} \mathrm{rd}'(0{,}31974_{10}110) &= 0{,}3197_{10}110 \notin A \\ \mathrm{rd}'(0{,}99997_{10}99) &= 0{,}1000_{10}100 \notin A \\ \mathrm{rd}'(0{,}012345_{10} - 99) &= 0{,}1235_{10} - 100 \notin A \\ \mathrm{rd}'(0{,}54321_{10} - 110) &= 0{,}5432_{10} - 110 \notin A \end{aligned}$$

En el primer y segundo caso el exponente es muy grande para el espacio: entonces tenemos un *overflow* de exponente (sobreflujo). El tercer y cuarto casos son instancias de un *underflow*, esto es, el exponente del número representado es muy negativo. En estos casos podemos prevenir el underflow definiendo

$$\mathrm{rd}(0{,}012345_{10} - 99) = 0{,}0123_{10} - 99 \in A.$$

$$\mathrm{rd}(0{,}54321_{10} - 110) = 0 \in A.$$

Como el overflow y el underflow son poco frecuentes y requieren un tratamiento especial, para simplificar la teoría asumiremos en adelante que $e = \infty$. De este modo tendremos $\mathrm{rd} := \mathrm{rd}'$, y aseguraremos que

$$\begin{aligned} &\mathrm{rd} : \mathbb{R} \to A \\ &\mathrm{rd}(x) = x(1 + \varepsilon) \quad \text{con } |\varepsilon| \leq \mathrm{eps}, \quad \forall x \in \mathbb{R}. \end{aligned}$$

Como los resultados de las operaciones aritméticas no son necesariamente números de máquina, requeriremos definir *operaciones de punto flotante*, $+^*, -^*, \cdot^*, /^*$,

las cuales son definidas como:

$$\left.\begin{array}{l} x +^* y := \mathrm{rd}(x+y), \\ x -^* y := \mathrm{rd}(x-y), \\ x \cdot^* y := \mathrm{rd}(x\cdot y), \\ x/^* y := \mathrm{rd}(x/y), \end{array}\right. \quad \text{para } x, y \in A,$$

lo cual implica

$$\left.\begin{array}{r} x +^* y := (x+y)(1+\varepsilon_1) \\ x -^* y := (x-y)(1+\varepsilon_2) \\ x \cdot^* y := (x\cdot y)(1+\varepsilon_3) \\ x/^* y := (x/y)(1+\varepsilon_4) \end{array}\right\} \quad |\varepsilon_i| \leq \mathrm{eps}\,.$$

De lo anterior se observará que las operaciones de punto flotante no satisfacen las leyes conocidas para las operaciones aritméticas usuales. Por ejemplo,

$$x +^* y = x, \text{ si } |y| < \frac{\mathrm{eps}}{B}|x|, \quad x, y \in A$$

La precisión de máquina eps puede también definirse entonces como

$$\mathrm{eps} = \mathrm{mín}\{g \in A / 1 +^* g > 1 \wedge g > 0\}.$$

Además, las operaciones de punto flotante no son asociativas o distributivas.

Ejemplo 1.7 ($t = 8$). Con

$$\begin{array}{rl} a := & 0{,}23371258_{10} - 4, \\ b := & 0{,}33678429_{10}2, \\ c := & -0{,}33677811_{10}2. \end{array}$$

$$\begin{array}{rl} a +^* (b +^* c) & = 0{,}23371258_{10} - 4 +^* 0{,}61800000_{10} - 3, \\ & = 0{,}64137126_{10} - 3, \\ (a +^* b) +^* c & = 0{,}33678452_{10}2 -^* 0{,}33677811_{10}2, \\ & = 0{,}64100000_{10} - 3. \end{array}$$

El resultado exacto es

$$a + b + c = 0{,}641371258_{10} - 3.$$

3. Propagación de errores

Para expresar el resultado de operaciones de punto flotante, una notación ha sido ampliamente aceptada, y la usaremos frecuentemente: dada una expresión E a calcular, $\mathrm{fl}(E)$ denota el valor de la expresión obtenida por aritmética de punto flotante.

Ejemplo 1.8.

$$\begin{array}{l} \mathrm{fl}(x\cdot y) := x \cdot^* y \\ \mathrm{fl}\big(a + (b+c)\big) := a +^* (b +^* c) \\ \mathrm{fl}\big((a+b)+c\big) := (a +^* b) +^* c \\ \mathrm{fl}\big(\cos(x)\big) := \cos^*(x) \\ \mathrm{fl}\big(\sqrt{x}\big) := \sqrt{x}^* \end{array}$$

Las operaciones $+, -, \cdot, /, \cos, \sqrt{}$, junto con algunas otras (que posean substitutos $*$) serán llamadas *operaciones elementales*. Como se vio, dos diferentes pero matemáticamente equivalentes maneras de evaluar la misma expresión $a + b + c$ pueden llevar a diferentes resultados, cuando usamos aritmética de punto flotante. Para propósitos numéricos es necesario distinguir entre distintos esquemas de evaluación incluso si ellos son matemáticamente equivalentes. Llamaremos *algoritmo* a una secuencia finita de operaciones elementales (dadas como instrucciones de computadora) que prescriben como calcular la solución de un problema a partir de una entrada de datos dada.

Formalizemos un poco la noción de algoritmo. Supongamos que el problema consiste en calcular los números reales $y_1, \ldots, y_m$ a partir de las entradas $x_1, \ldots, x_n$. Si introducimos los vectores

$$x = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}, \quad y = \begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix},$$

entonces resolver el problema significa determinar el valor $y = \varphi(x)$ donde

$$\varphi : D \to \mathbb{R}^m, \quad D \subset \mathbb{R}^n,$$
$$y_i = \varphi_i(x_1, \ldots, x_n), \quad i = 1, \ldots, m.$$

En cada paso del cálculo hay un *conjunto de operandos* de números. Una sola operación calcula un nuevo número a partir de uno o más operandos del conjunto de operandos. El nuevo número es un resultado intermedio o el final.

Una operación corresponde a una transformación del conjunto de operandos. Escribiendo éstos consecutivamente como vectores,

$$x^{(i)} = \begin{bmatrix} x_1^{(i)} \\ \vdots \\ x_{n_i}^{(i)} \end{bmatrix} \in \mathbb{R}^{n_i},$$

podemos asociar a cada operación elemental un *mapeo elemental*

$$\varphi^{(i)} : D_i \to \mathbb{R}^{n_{i+1}}, \quad D_i \subset \mathbb{R}_{n_i},$$

tal que

$$\varphi^{(i)}\big(x^{(i)}\big) = x^{(i+1)}.$$

Dado un algoritmo, entonces su secuencia de operaciones elementales da lugar a la descomposición de φ en una secuencia de mapeos elementales

$$\varphi^{(i)} : D_i \to D_{i+1}, \quad i = 0, 1, \ldots, r, \quad D_j \subset \mathbb{R}^{n_j},$$
$$\varphi = \varphi^{(r)} \circ \varphi^{(r-1)} \circ \cdots \circ \varphi^{(0)}, \quad D_0 = D, \quad D_{r+1} \subset \mathbb{R}^{n_{r+1}} = \mathbb{R}^m,$$

que caracteriza al algoritmo.

Ejemplo 1.9. Para $\varphi(a, b, c) = a + b + c$, consideremos los dos algoritmos $\eta := a + b$, $y := c + \eta$ y $\eta := b + c$, $y := a + \eta$. Las descomposiciones son:

$$\varphi^{(0)}(a, b, c) := \begin{bmatrix} a + b \\ c \end{bmatrix} \in \mathbb{R}^2, \qquad \varphi^{(1)}(u, v) := u + v \in \mathbb{R}$$

y

$$\varphi^{(0)}(a, b, c) := \begin{bmatrix} a \\ b + c \end{bmatrix} \in \mathbb{R}^2, \qquad \varphi^{(1)}(u, v) := u + v \in \mathbb{R}.$$

Ejemplo 1.10. Para $\varphi(a, b) := a^2 - b^2$ se tienen los algoritmos

- Algoritmo 1:
$$\eta_1 := a \cdot a,$$
$$\eta_2 := b \cdot b,$$
$$y := \eta_1 - \eta_2,$$
- Algoritmo 2:
$$\eta_1 := a + b,$$
$$\eta_2 := a - b,$$
$$y := \eta_1 \cdot \eta_2.$$

Sus descomposiciones correspondientes son

- Algoritmo 1:

$$\varphi^{(0)}(a,b) := \begin{bmatrix} a^2 \\ b \end{bmatrix}, \varphi^{(1)}(u,v) := \begin{bmatrix} u \\ v^2 \end{bmatrix}, \varphi^{(2)}(u,v) := u - v.$$

- Algoritmo 2:

$$\varphi^{(0)}(a,b) := \begin{bmatrix} a \\ b \\ a+b \end{bmatrix}, \quad \varphi^{(1)}(a,b,u) := \begin{bmatrix} u \\ a-b \end{bmatrix}, \varphi^{(1)}(a,b,u) := u \cdot v.$$

Nótese que las descomposiciones de los algoritmos pueden ser simplificadas:

$$\text{Algoritmo 1:} \qquad \varphi'^{(0)}(a,b) := \begin{bmatrix} a^2 \\ b^2 \end{bmatrix}, \qquad \varphi'^{(1)}(u,v) := u - v.$$

$$\text{Algoritmo 2:} \qquad \varphi'^{(0)}(a,b) := \begin{bmatrix} a+b \\ a-b \end{bmatrix}, \qquad \varphi'^{(1)}(u,v) := u \cdot v.$$

Estrictamente hablando, los mapeos $\varphi'^{(0)}$ no son elementales. Sin embargo lo más importante al hacer las descomposiciones es que las componentes de los mapeos intermedios sean elementales, para poder hacer así el análisis de error que se estudiará a continuación.

EJEMPLO 1.11. $y := a + b + c$,

$$\begin{aligned} \tilde{y} &:= \mathrm{rd}((a+b)+c) \\ &= \mathrm{rd}(a+b) +^* c \\ &= (a+b)(1+\varepsilon_1) +^* c \\ &= [(a+b)(1+\varepsilon_1)+c](1+\varepsilon_2) \\ &= (a+b+c)\left[1 + \frac{a+b}{a+b+c}\varepsilon_1(1+\varepsilon_2) + \varepsilon_2\right]. \end{aligned}$$

Despreciamos el término $\varepsilon_1\varepsilon_2$ por ser de grado superior; luego el error relativo (al haber calculado primero $(a+b)$) es

$$\varepsilon_y := \frac{\tilde{y}-y}{y} = \frac{\tilde{y}}{y} - 1 \approx \frac{a+b}{a+b+c}\varepsilon_1 + \varepsilon_2,$$

el cual es pequeño si $(a+b)$ es pequeño.

Si se hubiese calculado primero $(b+c)$ tendriamos

$$\varepsilon_y \approx \frac{b+c}{a+b+c}\varepsilon_1' + \varepsilon_2',$$

que es pequeño si $(b+c)$ es pequeño.

Vamos a hacer ahora un *análisis diferencial de error* de un algoritmo para calcular $y := \varphi(x)$ si esta función está dada por la descomposición:

$$\varphi = \varphi^{(r)} o\, \varphi^{(r-1)} o \ldots o\, \varphi^{(0)}.$$

Para este fin necesitamos investigar como los errores de entrada, así como los errores por redondeo acumulados durante el curso del algoritmo afectan el resultado final. Iniciamos esta investigación considerando solamente los errores de entrada Δx. Supongamos que la función

$$\varphi : D \to \mathbb{R}^m, \qquad \varphi = \begin{bmatrix} \varphi_1(x_1,\ldots,x_n) \\ \vdots \\ \varphi_m(x_1,\ldots,x_n) \end{bmatrix},$$

está definida en un conjunto abierto D de $\mathbb{R}^n$, y que sus funciones componentes φ_i, $i = 1, 2, \ldots, n$, poseen derivadas continuas en D. Sea $\tilde{x}$ un valor aproximado de x. Entonces denotamos por

$$\Delta x_i := \tilde{x}_i - x_i, \qquad \Delta x := \tilde{x} - x,$$

al *error absoluto* $\tilde{x}_i$ y $\tilde{x}$, respectivamente. El *error relativo* de $\tilde{x}_i$ es definido como la cantidad

$$\varepsilon_{\tilde{x}_i} := \frac{\tilde{x}_i - x_i}{x_i} \quad \text{si } x_i \neq 0.$$

Reemplazando x por $\tilde{x}$ obtenemos el resultado $\tilde{\mathrm{y}} := \varphi(\tilde{x})$ en vez de $y = \varphi(x)$. Expandiendo en series de Taylor y despreciando los términos de mayor orden, tenemos

$$\begin{aligned} \Delta y_i &:= \tilde{y}_i - y_i = \varphi_i(\tilde{x}) - \varphi_i(x) \approx \sum_{j=1}^{n} (\tilde{x}_j - x_j) \frac{\partial \varphi_i(x)}{\partial x_j} \\ &= \sum_{j=1}^{n} \frac{\partial \varphi_i(x)}{\partial x_j} \Delta x_j, \quad i = 1, \ldots, m, \end{aligned}$$

de donde

$$\Delta y = \begin{bmatrix} \Delta y_1 \\ \vdots \\ \Delta y_m \end{bmatrix} \approx \begin{bmatrix} \dfrac{\partial \varphi_1(x)}{\partial x_1} & \cdots & \dfrac{\partial \varphi_1(x)}{\partial x_n} \\ \vdots & & \vdots \\ \dfrac{\partial \varphi_m(x)}{\partial x_1} & \cdots & \dfrac{\partial \varphi_m(x)}{\partial x_n} \end{bmatrix} \begin{bmatrix} \Delta x_1 \\ \vdots \\ \Delta x_n \end{bmatrix} = D\varphi(x) \cdot \Delta x,$$

con la matriz jacobiana $D\varphi(x)$.

La cantidad $\dfrac{\partial \varphi_i(x)}{\partial x_j}$ representa la sensitividad con que y_i reacciona a las perturbaciones Δx_j de x_j.
Si $y_i \neq 0$ para $i = 1, \ldots, m$ y $x_j \neq 0$ para $j = 1, \ldots, n$ entonces se tiene:

$$\begin{aligned} \varepsilon_{y_i} = \frac{\tilde{y}_i - y_i}{y_i} &\approx \sum_{j=1}^{n} \frac{\partial \varphi_i(x)}{\partial x_j} \frac{\tilde{x}_j - x_j}{y_i} \\ &= \sum_{j=1}^{n} \left(\frac{x_j}{y_i} \frac{\partial \varphi_i(x)}{\partial x_j} \right) \frac{\tilde{x}_j - x_j}{x_j} \\ &= \sum_{j=1}^{n} \left(\frac{x_j}{y_i} \frac{\partial \varphi_i(x)}{\partial x_j} \right) \varepsilon_{x_j}. \end{aligned}$$

Los factores de amplificación $(x_j/\varphi_i)\partial\varphi_i/\partial x_j$ para el error relativo son llamados *números de condicionamiento*. Si alguno de estos números es en valor absoluto muy grande, se dice que el problema es *mal condicionado*. En otro caso, se dice que está *bien condicionado*. Como se puede observar, la condición del problema está descrita por mn números. Por estas razones, hay una manera más práctica de definir la condición del problema. En álgebra lineal, usando una norma conveniente $\|\cdot\|$, el número de condición c deberá satisfacer

$$\frac{\|\varphi(\tilde{x}) - \varphi(x)\|}{\|\varphi(x)\|} \leq c \frac{\|\tilde{x} - x\|}{\|x\|}.$$

Ejemplo 1.12. Para $\varphi(a, b, c) := a + b + c$ se tiene

$$\begin{aligned} \varepsilon_y &\approx \frac{a}{y} \frac{\partial \varphi(a,b,c)}{\partial a} \varepsilon_a + \frac{b}{y} \frac{\partial \varphi(a,b,c)}{\partial b} \varepsilon_b + \frac{c}{y} \frac{\partial \varphi(a,b,c)}{\partial c} \varepsilon_c \\ &= \frac{a}{a+b+c} \varepsilon_a + \frac{b}{a+b+c} \varepsilon_b + \frac{c}{a+b+c} \varepsilon_c. \end{aligned}$$

El problema estará bien condicionado cuando los sumandos a, b, c sean pequeños comparados con $a + b + c$ (por ejemplo, cuando todos tengan el mismo signo).

EJEMPLO 1.13. Para $y = \varphi(a, b) := -a + \sqrt{a^2 + b}$,

$$\begin{aligned}\varepsilon_y \quad &\approx \frac{a}{y}\left(-1 + \frac{a}{\sqrt{a^2+b}}\right)\varepsilon_a + \frac{b}{y}\frac{1}{2\sqrt{a^2+b}}\varepsilon_b \\ &\frac{-a}{\sqrt{a^2+b}}\varepsilon_a + \frac{a+\sqrt{a^2+b}}{2\sqrt{a^2+b}}\varepsilon_b.\end{aligned}$$

Desde que

$$\left|\frac{a}{\sqrt{a^2+b}}\right| \le 1, \quad \left|\frac{a+\sqrt{a^2+b}}{2\sqrt{a^2+b}}\right| \le 1 \qquad \text{para } b > 0;$$

tendremos que φ es bien condicionado si $b > 0$, y mal condicionado si $b \approx -a^2$.

Cuando se substraen dos números $x, y \in A$ del mismo signo, uno debe tener cuidado con la cancelación (esto es, cuando los números tienen valores absolutos casi iguales). Por ejemplo, para calcular

$$y = \sqrt{x^2 + 1} - 1$$

cuando el valor de x es cercano a cero, se sugiere calcular equivalentemente

$$y = (\sqrt{x^2+1} - 1) \cdot \frac{\sqrt{x^2+1}+1}{\sqrt{x^2+1}+1} = \frac{x^2}{\sqrt{x^2+1}+1}.$$

Para evitar desbordamientos (overflow, underflow)

$$z := \frac{x^2 + y^2}{\sqrt{x^4 + y^4}}$$

en caso $|x| < |y|$, hacemos $t := \dfrac{x}{y}(|t| < 1)$. Entonces calculamos

$$z = \frac{t^2 + 1}{\sqrt{t^4 + 1}}.h$$

Para las operaciones aritméticas $(x \neq 0, y \neq 0)$

$$\begin{aligned}&\varphi(x, y) := x \cdot y && \varepsilon_{xy} \approx \varepsilon_x + \varepsilon_y \\ &\varphi(x, y) := x/y && \varepsilon_{x/y} \approx \varepsilon_x - \varepsilon_y \\ &\varphi(x, y) := x \pm y && \varepsilon_{x\pm y} \approx \frac{x}{x \pm y}\varepsilon_x + \frac{y}{x \pm y}\varepsilon_y \text{ si } x \pm y \neq 0 \\ &\varphi(x) := \sqrt{x} && \varepsilon_{\sqrt{x}} \approx \tfrac{1}{2}\varepsilon_x\end{aligned}$$

Se sigue que la multiplicación, división, y raíz cuadrada no son peligrosas. Si los operandos son del mismo signo, la adición no es peligrosa: En efecto, tendremos que

$$|\varepsilon_{x+y}| \le \text{máx}\{|\varepsilon_x|, |\varepsilon_y|\}$$

Si los operandos tienen signos distintos, entonces almenos uno de los factores $\left|\dfrac{x}{x+y}\right|$ o $\left|\dfrac{y}{x+y}\right|$ es mayor que uno; entonces los errores serán amplificados, y drásticamente amplificados si $x \approx -y$.

Un algoritmo para calcular la función $\varphi : D \to \mathbb{R}^m, D \subset \mathbb{R}^n$, para un dado $x = (x_1, \ldots, x_n)^T \in D$ corresponde a la descomposición de φ en mapeos elementales $\varphi^{(i)}, i = 0, 1, \ldots, r$. Luego $y = \varphi(x)$ se obtiene por una cadena de resultados intermedios

$$x^{(0)} := x \to \varphi^{(0)}(x^{(0)}) = x^{(1)} \to \cdots \to \varphi^{(r)}(x^{(r)}) = x^{(r+1)} = y.$$

Suponemos de nuevo que cada $\varphi^{(i)}$ es continuamente diferenciable en D_i, y denotemos por $\psi^{(i)}$ el *mapeo remanente*

$$\psi^{(i)} = \varphi^{(r)} \circ \varphi^{(r-1)} \circ \cdots \circ \varphi^{(i)} : D_i \to \mathbb{R}^m, \quad i = 0, 1, 2, \ldots, r.$$

Entonces $\psi^{(0)} \equiv \varphi$. De la regla de la cadena, tenemos

$$D\varphi(x) = D\varphi^{(r)}(x^{(r)}) \cdot D\varphi^{(r-1)}(x^{(r-1)}) \cdot \cdots \cdot D\varphi^{(0)}(x),$$

$$D\psi(x^{(i)}) = D\varphi^{(r)}(x^{(r)}) \cdot D\varphi^{(r-1)}(x^{(r-1)}) \cdot \cdots \cdot D\varphi^{(i)}(x^{(i)}), \quad i = 0, 1, \ldots, r.$$

En el cálculo con punto flotante bajo la influencia de los errores de entrada y los errores por redondeo en lugar de los resultados intermedios $x^{(i)}$ se obtienen valores aproximados $\tilde{x}^{(i)}$ con $\tilde{x}^{(i+1)} = \mathrm{fl}(\varphi^{(i)}(\tilde{x}^{(i)}))$.
De esto se obtiene, para los errores absolutos $\Delta x^{(i)} = \tilde{x}^{(i)} - x^{(i)}$,

$$\Delta x^{(i+1)} = [\mathrm{fl}(\varphi^{(i)}(\tilde{x}^{(i)})) - \varphi^{(i)}(\tilde{x}^{(i)})] + [\varphi^{(i)}(\tilde{x}^{(i)}) - \varphi^{(i)}(x^{(i)})].$$

Usando series de Taylor, y despreciando términos de orden superior:

$$\varphi^{(i)}(\tilde{x}^{(i)}) - \varphi^{(i)}(x^{(i)}) \approx D\varphi^{(i)}(x^{(i)})\Delta x^{(i)}.$$

Como $\varphi^{(i)}$ es elemental, o bien involucra sólo operaciones elementales independientes, tenemos que

$$\mathrm{fl}(\varphi^{(i)}(u)) = \mathrm{rd}(\varphi^{(i)}(u)).$$

Nótese ahora que $\varphi^{(i)} : D_i \to D_{i+1} \subset \mathbb{R}^{n_{i+1}}$ es un vector de funciones componentes $\varphi_j^{(i)} : D_i \to \mathbb{R}$,

$$\varphi^{(i)}(u) = \begin{bmatrix} \varphi_1^{(i)}(u) \\ \vdots \\ \varphi_{n_{i+1}}^{(i)}(u) \end{bmatrix}.$$

Así, podemos trabajar con las componentes. De este modo:

$$\mathrm{fl}(\varphi_j^{(i)}(u)) = \mathrm{rd}(\varphi_j^{(i)}(u)) = (1 + \varepsilon_j)\varphi_j^{(i)}(u),$$

$$|\varepsilon_j| \leq \mathrm{eps}, \qquad j = 1, 2, \ldots, n_{i+1}$$

Entonces podemos simplemente escribir

$$\mathrm{fl}(\varphi^{(i)}(u)) = (I + E_{i+1}) \cdot \varphi^{(i)}(u).$$

Con la matriz identidad I y la matriz diagonal de error

$$E_{i+1} = \begin{bmatrix} \varepsilon_1 & 0 & \cdots & 0 \\ 0 & \varepsilon_2 & & 0 \\ \vdots & & \ddots & \vdots \\ 0 & 0 & \cdots & \varepsilon_{n_{i+1}} \end{bmatrix}, \qquad |\varepsilon_j| \leq \mathrm{eps}\,.$$

Esto nos da

$$\mathrm{fl}(\varphi^{(i)}(\tilde{x}^{(i)})) - \varphi^{(i)}(\tilde{x}^{(i)}) = E_{i+1} \cdot \varphi^{(i)}(\tilde{x}^{(i)}),$$

pero $E_{i+1} \cdot \varphi^{(i)}(\tilde{x}^{(i)}) \approx E_{i+1} \cdot \varphi^{(i)}(x^{(i)})$ (despreciando términos de orden superior). Por consiguiente

$$\mathrm{fl}(\varphi^{(i)}(\tilde{x}^{(i)})) - \varphi^{(i)}(\tilde{x}^{(i)}) \approx E_{i+1} \cdot \varphi^{(i)}(x^{(i)}) = E_{i+1} \cdot x^{(i+1)} =: \alpha_{i+1}.$$

Por lo anterior, $\Delta x^{(i+1)}$ puede ser expresado con una aproximación de primer orden como

$$\begin{aligned} \Delta x^{(i+1)} &\approx \alpha_{i+1} + D\varphi^{(i)}(x^{(i)}) \cdot \Delta x^{(i)} \\ &= E_{i+1} \cdot x^{(i+1)} + D\varphi^{(i)}(x^{(i)}) \cdot \Delta x^{(i)}, \text{ para } i \geq 0, \quad \Delta x^{(0)} := \Delta x. \end{aligned}$$

Luego

$$\begin{aligned} \Delta x^{(1)} &\approx D\varphi^{(0)}(x)\cdot\Delta x+\alpha_1\\ \Delta x^{(2)} &\approx D\varphi^{(1)}(x^{(1)})\cdot[D\varphi^{(0)}(x)\Delta x+\alpha_1]+\alpha_2\\ &\vdots\\ \Delta y=\Delta x^{(r+1)} &\approx D\varphi^{(r)}\cdots D\varphi^{(0)}\cdot\Delta x+D\varphi^{(r)}\cdots D\varphi^{(1)}\cdot\alpha_1+\cdots+\alpha_{r+1}. \end{aligned}$$

Finalmente, llegamos a la fórmula que describe el efecto de los errores de entrada Δx y los errores de redondeo α_i en el resultado $y = x^{(r+1)} = \varphi(x)$:

$$\begin{aligned} \Delta y &\approx D\varphi(x)\,\Delta x+\sum_{i=1}^{r} D\psi^{(i)}(x^{(i)})\,\alpha_i+\alpha_{r+1}\\ &= D\varphi(x)\,\Delta x+\sum_{i=1}^{r} D\psi^{(i)}(x^{(i)})\,E_i x^{(i)}+E_{r+1}y. \end{aligned} \tag{1}$$

3.1. Grafos computacionales. Un *grafo computacional* representa de manera dirigida las operaciones de un algoritmo. Sus nodos son los datos de entrada y las cantidades intermedias. Se dibuja una flecha cuando un nodo depende directamente de otro. En los algoritmos considerados aquí el grafo no contiene ciclos: las operaciones se ejecutan siguiendo el orden indicado por las flechas.

Esta forma de presentar un algoritmo es habitual en la diferenciación automática y en el aprendizaje automático. Es moderna en su uso y en su presentación visual, pero la idea matemática no es nueva: corresponde a los programas de asignaciones sucesivas y a la composición de funciones elementales. En particular, no reemplaza el punto de vista de Stoer–Bulirsch, sino que lo hace visible.

Si un nivel del grafo calcula

$$x^{(i+1)} = \varphi^{(i)}(x^{(i)}),$$

entonces la propagación hacia adelante de un error pequeño satisface

$$\Delta x^{(i+1)} \approx D\varphi^{(i)}(x^{(i)})\,\Delta x^{(i)}+\alpha_{i+1}, \tag{2}$$

donde α_{i+1} es el error de redondeo introducido al evaluar ese nivel. Por tanto, recorrer el grafo desde las entradas hasta la salida y aplicar la regla de la cadena produce exactamente la fórmula (1).

Como ejemplo, consideremos el algoritmo factorizado para calcular

$$y = a^3 - b^3 = (a-b)(a^2+ab+b^2).$$

Una posible descomposición en funciones elementales es

$$d = a-b,\quad u = a^2,\quad v = ab,\quad w = b^2,\quad s = u+v,\quad t = s+w,\quad y = dt.$$

Su grafo computacional es el de la figura 1.

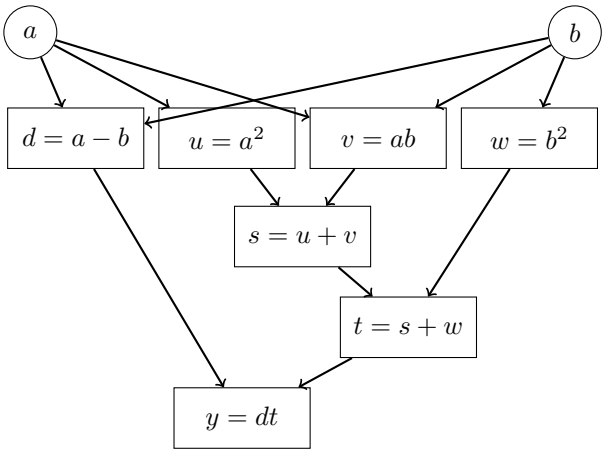


FIGURA 1. Grafo computacional del algoritmo factorizado para $a^3 - b^3$.

Cada flecha tiene asociada una derivada local. La sensibilidad de la salida respecto de un nodo se obtiene sumando, sobre todos los caminos dirigidos que llegan a la salida, los productos de las derivadas locales. Por ejemplo, un error α_d introducido al calcular d aporta aproximadamente $t\alpha_d$ al error de salida, mientras que un error α_t aporta $d\alpha_t$. Asimismo, los errores introducidos al calcular u, v o w se transmiten con factor d.

Los errores de entrada se colocan en los nodos a y b. Al recorrer todos los caminos desde esos nodos se recupera

$$\Delta y_{\text{entrada}} \approx \frac{\partial y}{\partial a}\Delta a + \frac{\partial y}{\partial b}\Delta b = 3a^2\Delta a - 3b^2\Delta b.$$

Los errores de redondeo, en cambio, se introducen en los nodos donde se realizan operaciones. Cada uno es transportado por la función remanente desde ese nodo hasta la salida; esto es precisamente lo que representan los términos $D\psi^{(i)}\alpha_i$ de (1).

El grafo permite distinguir con claridad dos hechos. La función $\varphi(a,b) = a^3 - b^3$ determina la sensibilidad frente a los errores de entrada, independientemente de la expresión elegida. En cambio, cada fórmula algebraicamente equivalente genera un grafo diferente y, por tanto, introduce y propaga errores de redondeo distintos. El grafo ayuda a organizar el cálculo; no modifica por sí mismo el condicionamiento del problema.

EJEMPLO 1.14. Para los dos algoritmos que calculan $y = \varphi(a,b) = a^2 - b^2$ dados tenemos:
Algoritmo 1:

$$x = x^{(0)} = \begin{bmatrix} a \\ b \end{bmatrix}, \quad x^{(1)} = \begin{bmatrix} a^2 \\ b \end{bmatrix}, \quad x^{(2)} = \begin{bmatrix} a^2 \\ b^2 \end{bmatrix}, \quad x^{(3)} = y = a^2 - b^2,$$

$$\psi^{(1)}(u,v) = u - v^2, \qquad \psi^{(2)}(u,v) = u - v,$$

$$D\varphi(x) = (2a, -2b)$$

$$D\psi^{(1)}(x^{(1)}) = (1, -2b), \qquad D\psi^{(2)}(x^{(2)}) = (1, -1),$$

$$\alpha_1 = \begin{bmatrix} \varepsilon_1 a^2 \\ 0 \end{bmatrix}, \quad E_1 = \begin{bmatrix} \varepsilon_1 & 0 \\ 0 & 0 \end{bmatrix},$$

pues

$$\text{fl}(\varphi^{(0)}(x^{(0)})) - \varphi^{(0)}(x^{(0)}) = \begin{bmatrix} a \cdot^* a \\ b \end{bmatrix} - \begin{bmatrix} a^2 \\ b \end{bmatrix}.$$

También

$$\alpha_2 = \begin{bmatrix} 0 \\ \varepsilon_2 b^2 \end{bmatrix}, \quad E_2 = \begin{bmatrix} 0 & 0 \\ \varepsilon_1 & 0 \end{bmatrix}.$$

$\alpha_3 = \varepsilon_3(a^2 - b^2)$, $\quad |\varepsilon_i| \leq \text{eps}$ para $i = 1, 2, 3$.

Con $\Delta x = \begin{bmatrix} \Delta a \\ \Delta b \end{bmatrix}$,

$$\Delta y \approx 2a\Delta a - 2b\Delta b + a^2\varepsilon_1 - b^2\varepsilon_2 + (a^2 - b^2)\varepsilon_3.$$

Análogamente para el algoritmo 2:

$$x = x^{(0)} = \begin{bmatrix} a \\ b \end{bmatrix}, \quad x^{(1)} = \begin{bmatrix} a+b \\ a-b \end{bmatrix}, \quad x^{(2)} = y = a^2 - b^2,$$

$$\psi^{(1)}(u, v) = u \cdot v,$$

$$D\varphi(x) = (2a, -2b), \quad D\psi^{(1)}(x^{(1)}) = (a - b, a + b),$$

$$\alpha_1 = \begin{bmatrix} \varepsilon_1(a+b) \\ \varepsilon_2(a-b) \end{bmatrix}, \quad \alpha_2 = \varepsilon_3(a^2 - b^2), \quad E_1 = \begin{bmatrix} \varepsilon_1 & 0 \\ 0 & \varepsilon_2 \end{bmatrix}, \quad |\varepsilon_i| \leq \text{eps}\,.$$

Por tanto

$$\Delta y \approx 2a\Delta a - 2b\Delta b + (a^2 - b^2)(\varepsilon_1 + \varepsilon_2 + \varepsilon_3).$$

Un algoritmo es llamado *numéricamente más estable* que otro para calcular $\varphi(x)$ si, para un conjunto dado de datos x, el efecto total de redondeo del primero es menor que el del otro.

Ejemplo 1.15. En el ejemplo anterior, el efecto total por redondeo usando el Algoritmo 1 es

$$\left|a^2\varepsilon_1 - b^2\varepsilon_2 + (a^2 - b^2)\varepsilon_3\right| \leq \left(a^2 + b^2 + |a^2 - b^2|\right) \text{eps},$$

y usando el Algoritmo 2

$$|(a^2 - b^2)(\varepsilon_1 + \varepsilon_2 + \varepsilon_3)| \leq 3|a^2 - b^2|\,\text{eps}\,.$$

Esto muestra que el algoritmo 2 es numéricamente más estable que el algoritmo 1 siempre que $\frac{1}{3} < |a/b|^2 < 3$; en otro caso el algoritmo 1 es más estable.

4. Ejercicios

1. Calcule el efecto total de errores de entrada y redondeo (mediante análisis diferencial) de dos algoritmos para evaluaciones distintas de
$$y = (a + b)^2 = a^2 + 2ab + b^2.$$
2. Calcule el efecto total de errores de entrada y redondeo de los dos siguientes algoritmos para la evaluación de
$$y = ax^2 + bx + c$$
   a) Algoritmo 1: $u \leftarrow x^2$, $v \leftarrow a \cdot u$, $w \leftarrow b \cdot x$, $z \leftarrow v + w$, $y \leftarrow z + c$;
   b) Algoritmo 2: $u \leftarrow a \cdot x$, $v \leftarrow u + b$, $w \leftarrow v \cdot x$, $y \leftarrow w + c$.
   Compare la estabilidad numérica de los algoritmos.
3. Para la función lineal $f(x) = a + bx$, donde $a \neq 0$, $b \neq 0$, calcule la primera derivada $f'(0) = b$ por la fórmula
$$D_h f(0) = \frac{f(h) - f(-h)}{2h},$$
   en aritmética de punto flotante binaria. Supongamos que a y b son números de máquina binarios, y h es una potencia de 2. La multiplicación por h y el cociente por $2h$ pueden ser entonces calculados de manera exacta. De una

cota para el error relativo de $D_h f(0)$. ¿Cuál es el comportamiento de este error cuando $h \to 0$?

4. La raíz cuadrada $\pm(u+iv)$ de un número complejo $x+iy$ con $y \neq 0$ puede ser calculada por medio de las fórmulas

$$u = \pm\sqrt{\frac{x+\sqrt{x^2+y^2}}{2}}, \quad v = \frac{y}{2u}.$$

Compare los casos $x \geq 0$ y $x < 0$ con respecto a su estabilidad numérica.

5. Calcule el número de condición en el cálculo de

$$f(x) = \arcsin(x),$$

y encuentre el peor caso posible de expansión del error relativo (de entrada) de x.

6. Demuestre que en aritmética de punto flotante de t lugares decimales

$$\mathrm{rd}(x) = \frac{x}{1+\varepsilon}$$

con $|\varepsilon| \leq 5 \cdot 10^{-t}$.

7. Demuestre que, fijados un número real x y un número entero $k \geq 1$, existe δ, $|\delta| \leq \mathrm{eps}$ tal que

$$\mathrm{fl}(x^k) = x^k(1+\delta)^{k-1}.$$

8. Calcule el efecto total de errores de entrada y redondeo en la evaluación de

$$y = x^3 + 2x^2\cos(a) + b$$

en aritmética de punto flotante binaria, mediante los dos siguientes algoritmos:

a) $u \leftarrow \cos(a)$, $v \leftarrow x^2$, $w \leftarrow vx$, $t \leftarrow vu$, $t' \leftarrow 2t$, $s \leftarrow w + t'$, $y \leftarrow s + b$.

b) $u \leftarrow \cos(a)$, $u' \leftarrow 2u$, $w \leftarrow x + u'$, $v \leftarrow x^2$, $t \leftarrow wv$, $y \leftarrow t + b$.

Compare los errores de redondeo correspondientes según los valores de x, a y b ingresados.

9. Demuestre lo siguiente: sean $x_1, \ldots, x_n$ números de máquina positivos, $n \geq 2$. Entonces, el error de redondeo relativo al calcular $\displaystyle\sum_{k=1}^{n} x_i$ de la manera usual está acotado por

$$(1+\mathrm{eps})^{n-1} - 1.$$

Capítulo 2

Introducción a los métodos iterativos

Un *método iterativo* parte de uno o varios valores iniciales y genera una sucesión

$$r_0, r_1, r_2, \ldots$$

de aproximaciones a la solución r^* de un problema. Para analizarlo distinguiremos tres preguntas: si las aproximaciones convergen, con qué rapidez disminuye el error y cuándo conviene detener el cálculo. La estabilidad numérica completa este análisis y se estudia junto con los errores de redondeo.

En este capítulo no introduciremos una teoría general del orden de convergencia. Trabajaremos directamente con los tres comportamientos que se usan con mayor frecuencia en el curso: convergencia lineal, superlineal y cuadrática.

1. Convergencia de sucesiones escalares

Definición. *Sea $\{r_k\}_{k\geq 0}$ una sucesión de números reales. Decimos que r_k converge a r^*, y escribimos*

$$\lim_{k\to\infty} r_k = r^*,$$

si, para cada $\varepsilon > 0$, existe un entero k_0 tal que

$$|r_k - r^*| < \varepsilon \qquad \text{para todo } k \geq k_0.$$

La definición significa que, aunque los primeros términos puedan estar lejos de r^* u oscilar, desde cierto momento todos permanecen tan cerca de r^* como se haya solicitado.

Proposición 2.1. *Sean $r_k \to r^*$ y $s_k \to s^*$. Para cualquier constante real c se cumple*

$$r_k + s_k \to r^* + s^*, \qquad cr_k \to cr^*.$$

Proposición 2.2. *Si $r_k \to r^*$ y a es un entero fijo para el cual r_{k+a} está definido, entonces*

$$r_{k+a} \to r^*.$$

Por tanto, modificar, eliminar o añadir una cantidad finita de términos no cambia el límite de una sucesión.

Las propiedades de convergencia describen la *cola* de la sucesión. En un algoritmo bien definido suele ocurrir una de las siguientes situaciones: ninguna iteración coincide exactamente con r^*, o bien, si $r_k = r^*$, entonces $r_j = r^*$ para todo $j \geq k$. En el segundo caso, la sucesión permanece constante y el algoritmo ha terminado matemáticamente.

2. Convergencia de sucesiones de vectores

En problemas con varias variables escribimos las iteraciones mediante superíndices,

$$x^{(k)} = (x_1^{(k)}, \ldots, x_n^{(k)}) \in \mathbb{R}^n,$$

para reservar los subíndices para las componentes del vector.

DEFINICIÓN. *Una sucesión* $\{x^{(k)}\}_{k\geq 0} \subset \mathbb{R}^n$ *converge a* x^* *si, para cada* $\varepsilon > 0$, *existe* k_0 *tal que*

$$\|x^{(k)} - x^*\| < \varepsilon \qquad \text{para todo } k \geq k_0.$$

En dimensión finita puede emplearse cualquiera de las normas usuales. La norma elegida determina cómo se mide la distancia, pero no cambia el hecho de que una sucesión converja o no.

EJEMPLO 2.1. La sucesión

$$x^{(k)} = \left(\frac{1}{k+1}, \frac{(-1)^k}{k+1}\right)$$

converge a $(0,0)$. La segunda componente oscila, pero la distancia al origen tiende a cero.

Para escalares y vectores definiremos el error verdadero mediante

$$e_k = \|x^{(k)} - x^*\|,$$

donde, en el caso escalar, la norma se reduce al valor absoluto. Así, $x^{(k)} \to x^*$ equivale a $e_k \to 0$.

En ocasiones conviene usar una función escalar de error o defecto $E : \mathbb{R}^n \to \mathbb{R}$. Algunos ejemplos son

$$E(x) = \|x - x^*\|, \qquad E(x) = \|x - x^*\|^2, \qquad E(x) = \|F(x)\|,$$

cuando se desea resolver $F(x) = 0$. En optimización también puede emplearse una brecha de la función objetivo. La medida escogida debe mantenerse fija al comparar dos métodos, pues los cocientes observados pueden depender de ella.

3. Velocidades de convergencia

En las definiciones siguientes suponemos que $e_k > 0$ desde cierta iteración. Si un algoritmo alcanza exactamente la solución, se reporta convergencia exacta y no se intentan evaluar cocientes de la forma $0/0$.

3.1. Convergencia lineal.

DEFINICIÓN. *La convergencia es lineal si existen una constante* $q \in (0,1)$ *y un entero* k_0 *tales que*

$$e_{k+1} \leq q e_k \qquad \text{para todo } k \geq k_0.$$

Cada iteración elimina al menos una fracción fija del error. Iterando la desigualdad se obtiene $e_k \leq c q^k$ para una constante $c > 0$; por ello esta convergencia también se denomina *geométrica*. Entre dos factores $0 < q_1 < q_2 < 1$, el menor describe una reducción más rápida.

EJEMPLO 2.2. Sea $0 < a < 1$ y $r_k = a^k$. Como $r_k \to 0$ y

$$\frac{|r_{k+1}|}{|r_k|} = a,$$

la sucesión converge linealmente con factor $q = a$.

Converger no implica necesariamente converger linealmente.

EJEMPLO 2.3. Para $r_k = 1/(k+1)$ se tiene $r_k \to 0$, pero

$$\frac{|r_{k+1}|}{|r_k|} = \frac{k+1}{k+2} \longrightarrow 1.$$

Por tanto, la sucesión converge, pero no linealmente.

3.2. Convergencia superlineal.

DEFINICIÓN. *La convergencia es superlineal si*

$$\frac{e_{k+1}}{e_k} \longrightarrow 0.$$

El factor de reducción no permanece constante: termina acercándose a cero, de modo que cada iteración resulta más eficaz que la anterior.

EJEMPLO 2.4. Considere

$$r_k = \left(\frac{1}{k+1}\right)^{k+1}.$$

Entonces

$$\frac{r_{k+1}}{r_k} = \frac{1}{k+2}\left(\frac{k+1}{k+2}\right)^{k+1} \leq \frac{1}{k+2} \longrightarrow 0.$$

La convergencia es superlineal. Sin embargo,

$$\frac{r_{k+1}}{r_k^2} = \frac{(k+1)^{2k+2}}{(k+2)^{k+2}} \longrightarrow \infty,$$

por lo que este ejemplo no converge cuadráticamente.

3.3. Convergencia cuadrática.

DEFINICIÓN. *La convergencia es cuadrática si existen una constante $C > 0$ y un entero k_0 tales que*

$$e_{k+1} \leq Ce_k^2 \qquad \textit{para todo } k \geq k_0.$$

Cuando e_k ya es pequeño, su cuadrado es mucho menor. En condiciones favorables, el número de cifras correctas puede aproximadamente duplicarse en cada iteración.

EJEMPLO 2.5. Sea $0 < a < 1$ y $r_k = a^{2^k}$. Entonces

$$e_{k+1} = a^{2^{k+1}} = \left(a^{2^k}\right)^2 = e_k^2.$$

La convergencia es cuadrática con $C = 1$.

PROPOSICIÓN 2.3. *Toda sucesión que converge cuadráticamente converge también de manera superlineal.*

DEMOSTRACIÓN. Si $e_{k+1} \leq Ce_k^2$, entonces

$$\frac{e_{k+1}}{e_k} \leq Ce_k.$$

Como $e_k \to 0$, el lado derecho tiende a cero. □

4. Carácter local de la velocidad

Las relaciones de la sección 3 suelen cumplirse cuando la iteración ya está suficientemente cerca de la solución. Un método puede ser muy rápido localmente y, sin embargo, fallar desde un mal punto inicial. Por ello deben separarse dos preguntas: si el método llega a la región correcta y con qué rapidez avanza una vez que está allí.

Ejemplo 2.6 (Método de Herón). Para aproximar $\sqrt{2}$ se puede usar

$$x^{(k+1)} = \frac{1}{2}\left(x^{(k)} + \frac{2}{x^{(k)}}\right).$$

El error satisface la identidad

$$x^{(k+1)} - \sqrt{2} = \frac{(x^{(k)} - \sqrt{2})^2}{2x^{(k)}}.$$

Cerca de $\sqrt{2}$, el denominador permanece aproximadamente constante y

$$e_{k+1} \approx \frac{1}{2\sqrt{2}} e_k^2.$$

Esto explica el comportamiento cuadrático observado.

5. Criterios de parada

El criterio ideal sería detenerse cuando

$$\|x^{(k)} - x^*\| \leq \varepsilon,$$

pero normalmente x^* es desconocido. Por ello se utilizan cantidades observables.

5.1. Tamaño del paso. Un criterio frecuente es

$$\|x^{(k+1)} - x^{(k)}\| \leq \tau_a + \tau_r \,\text{máx}\{1, \|x^{(k+1)}\|\},$$

donde τ_a y τ_r son tolerancias absoluta y relativa. Un paso pequeño no demuestra por sí solo que la sucesión converge. Por ejemplo, las sumas parciales

$$r_k = 1 + \frac{1}{2} + \frac{1}{3} + \cdots + \frac{1}{k}$$

no convergen, aunque $|r_{k+1} - r_k| = 1/(k+1) \to 0$.

5.2. Residuo del problema. Si se resuelve $F(x) = 0$, puede observarse $\|F(x^{(k)})\|$. Para un cero de una función escalar se usa $|f(r_k)|$; para un punto fijo $r^* = g(r^*)$ se usa $|r_k - g(r_k)|$. En el cálculo de $\sqrt{a}$, por ejemplo, puede emplearse el residuo $|r_k^2 - a|$.

El significado de un residuo absoluto depende de la escala de los datos y del condicionamiento del problema. Por ello conviene combinar un residuo escalado con tolerancias absoluta y relativa.

5.3. Terminación auditable. Una implementación confiable debe devolver la aproximación, el número de iteraciones y el motivo de terminación. Además de comprobar el paso y el residuo, debe imponer un número máximo de iteraciones y distinguir entre convergencia, estancamiento y fracaso. Cerca de la precisión de la máquina, los cocientes de errores pueden dejar de ser informativos por efecto del redondeo.

Capítulo 3

Sistemas de ecuaciones lineales

1. Fundamentos

Antes de iniciar el estudio de los sistemas de ecuaciones lineales debemos complementar los fundamentos de la teoría, para esto veremos propiedades de las normas en $\mathbb{K}^n$ (considerando $\mathbb{K} = \mathbb{R}$ ó $\mathbb{C}$).

Definición. *Sea $\mathbb{K} = \mathbb{R}$ ó $\mathbb{C}$. A una función $\|\cdot\| : \mathbb{K}^n \to \mathbb{R}$ se le llama norma de vectores si se cumple:*

1) $\|x\| \geq 0$ *para todo* $x \in \mathbb{K}^n$, y $\|x\| = 0$ *si y sólo si* $x = 0$;
2) $\|\alpha x\| = |\alpha|\|x\|$, *para todos* $\alpha \in \mathbb{K}$ y $x \in \mathbb{K}^n$;
3) $\|x + y\| \leq \|x\| + \|y\|$, *para todo* $x, y \in \mathbb{K}^n$ *(desigualdad triangular).*

Teorema 3.1. *Sea $\|\cdot\|$ una norma en $\mathbb{R}^n$. Entonces se cumple:*

1) *Con respecto a la continuidad de una norma*
   a) $|\|x\| - \|y\|| \leq \|x - y\|$, *para todo* $x, y \in \mathbb{R}^n$;
   b) *existe* $C > 0$ *constante tal que* $|\|x\| - \|y\|| \leq C\|x - y\|_\infty$, *para todo* $x, y \in \mathbb{R}^n$.
2) *Para cada par de normas $\|\cdot\|_A$ y $\|\cdot\|_B$ en $\mathbb{K}^n$ existen constantes C y D tales que*

$$C\|x\|_A \leq \|x\|_B \leq D\|x\|_A, \text{ para todo } x \in \mathbb{K}^n. \tag{3}$$

Definición. *Si $\|\cdot\|_A$ y $\|\cdot\|_B$ satisfacen (3) son llamadas equivalentes.*

Demostración (del teorema).

1) En efecto
   a) Se sigue de la desigualdad triangular;
   b) de a), tenemos que:

$$|\|x\| - \|y\|| \leq \|x - y\| = \left\|\sum_{j=1}^{n}(x_j - y_i)e_j\right\| \leq \sum_{j=1}^{n}|x_j - y_i|\|e_j\|$$
$$\leq \sum_{j=1}^{n}\|x - y\|_\infty\|e_j\| \leq \|x - y\|_\infty \sum_{j=1}^{n}\|e_j\| = C\|x - y\|_\infty,$$

   con $C = \sum_{j=1}^{n}\|e_j\|$.
2) Sea $S := \{y \in \mathbb{K}^n : \|x\|_\infty = 1\}$. Como S es compacto y $\|\cdot\|_B$ es continua, entonces $\|\cdot\|_B$ toma sus extremos en S:

$$C := \min_{x \in S}\|x\|_B, \quad D := \max_{x \in S}\|x\|_B$$

Resulta que $C > 0$ ya que $0 \notin S$. Para cualquier $x \in \mathbb{K}^n \setminus \{0\}$ se cumple que $\dfrac{x}{\|x\|_\infty} \in S$ y se obtiene

$$C \leq \left\| \frac{x}{\|x\|_\infty} \right\|_B \leq D$$

de donde

$$C\|x\|_\infty \leq \|x\|_B \leq D\|x\|_\infty$$

□

Ejemplo 3.1. Tres normas vectoriales en $\mathbb{K}^n$ son

$$\|x\|_1 = \sum_{i=1}^{n} |x_i|.$$
$$\|x\|_2 = \left(\sum_{i=1}^{n} x_i^2 \right)^{1/2}.$$
$$\|x\|_\infty = \max_{i=1,\ldots,n} |x_i|$$

la segunda de éstas conocida como *norma euclidiana*; y la *norma de Hölder*:

$$\|x\|_p = \left(\sum_{i=1}^{n} |x_i|^p \right)^{1/p}, \quad p \in \mathbb{R}, \quad p \geq 1.$$

La bola unitaria de radio 1 con la norma $\|\cdot\|$ en $\mathbb{R}^n$ es el conjunto $B = \{x \in \mathbb{R}^n / \|x\| \leq 1\}$ y su frontera el conjunto $\{x \in \mathbb{R}^n / \|x\| = 1\}$.

Definición. *Sea $\|\cdot\|$ una norma en $\mathbb{K}^n$. La norma matricial subordinada o norma asociada a esta norma (o norma inducida) se define como*

$$\|A\| := \sup \left\{ \frac{\|Ax\|}{\|x\|} / x \in \mathbb{K}^n \setminus \{0\} \right\} = \sup_{x \neq 0} \frac{\|Ax\|}{\|x\|}.$$

Teorema 3.2. *Si $\|\cdot\|$ es una norma en $\mathbb{K}^n$, entonces se cumple:*

a) $\|A\| = \sup_{\|x\|=1} \|Ax\|$

b) $\|A\| = \sup_{x \neq 0} \dfrac{\|Ax\|}{\|x\|}$, *para toda $A \in \mathbb{K}^{n \times n}$, define una norma sobre el espacio vectorial de las matrices en $\mathbb{K}^{n \times n}$*

c) $\|Ax\| \leq \|A\|\|x\|$, *para todo $x \in \mathbb{K}^n$, $A \in \mathbb{K}^{n \times n}$*

d) $\|AB\| \leq \|A\|\|B\|$, *para todo $A, B \in \mathbb{K}^{n \times n}$.*

Demostración.

a) $\|A\| = \sup_{x \neq 0} \dfrac{\|Ax\|}{\|x\|} = \sup_{\frac{x}{\|x\|} \neq 0} \left\| A \left(\dfrac{x}{\|x\|} \right) \right\|$

b) Primero veamos que si $A = (a_1, a_2, \ldots, a_n) \neq 0$, entonces al menos una columna $a_i \neq 0$. Luego $Ae_i = a_i \neq 0$ y

$$0 < \frac{\|a_i\|}{\|e_i\|} = \frac{\|Ae_i\|}{\|e_i\|} \leq \sup_{x \neq 0} \frac{\|Ax\|}{\|x\|} = \|A\|$$

Así $\|A\| > 0$, para todo $A \neq 0$, de donde

$|A\| \geq 0,$ para todo $A \in \mathbb{K}^{n \times n},$ y $\|A\| = 0$ sí y solamente si $A = 0$

Las otras propiedades se cumplen trivialmente (Ejercicio).

c) Se tiene

$$\frac{\|Ax\|}{\|x\|} = \sup_{x\neq 0} \frac{\|Ax\|}{\|x\|} = \|A\|, \text{ para todo } x \neq 0.$$

Luego,

$$\|Ax\| \leq \|A\|\|x\|, \text{ para todo } x \neq 0.$$

Además para $x = 0$ se cumple trivialmente, de donde se tiene c).

d) Del item anterior se tiene que $\|ABx\| \leq \|A\|\|Bx\|$. Entonces

$$\|AB\| = \sup_{\|x\|=1} \|ABx\| \leq \sup_{\|x\|=1} \|A\|\|Bx\| = \|A\| \sup_{\|x\|=1} \|Bx\| = \|A\|\|B\|.$$

□

Ejemplo 3.2. Normas matriciales:

a) $\|A\|_\infty = \sup_{\|x\|_\infty=1} \|Ax\|_\infty$

b) $\|A\|_1 = \sup_{\|x\|_1=1} \|Ax\|_1$

Teorema 3.3. *Para toda matriz $A = (a_{ij}) \in \mathbb{K}^{n\times n}$, se cumple que:*

a) $\|A\|_\infty = \sup_{\|x\|_\infty=1} \|Ax\|_\infty = \max_{i=1,\ldots,n} \sum_{j=1}^{n} |a_{ij}|$

b) $\|A\|_1 = \sup_{\|x\|_1=1} \|Ax\|_1 = \max_{j=1,\ldots,n} \sum_{i=1}^{n} |a_{ij}|$

Demostración.

a) Primero notemos que

$$\begin{aligned}\|A\|_\infty &= \sup_{\|x\|_\infty=1} \|Ax\|_\infty = \sup_{\|x\|_\infty=1} \left(\max_{i=1,\ldots,n} |(Ax)_i|\right) \\ &= \sup_{\|x\|_\infty=1} \left(\max_{i=1,\ldots,n} \left|\sum_{k=1}^{n} a_{ik}x_k\right|\right)\end{aligned}$$

Sea $x \in \mathbb{K}^n$ con $\|x\|_\infty = \max_{k=1,\ldots,n} |x_k| = 1$. Entonces, para $i = 1, \ldots, n$ se tiene:

$$\begin{aligned}\left|\sum_{k=1}^{n} a_{ik}x_k\right| &\leq \sum_{k=1}^{n} |a_{ik}||x_k| \leq \sum_{k=1}^{n} |a_{ik}|\|x\|_\infty \\ &= \sum_{k=1}^{n} |a_{ik}| \leq \max_{i=1,\ldots,n} \sum_{k=1}^{n} |a_{ik}|,\end{aligned}$$

luego

$$\sup_{\|x\|_\infty=1} \left(\max_{i=1,\ldots,n} \left|\sum_{k=1}^{n} a_{ik}x_k\right|\right) \leq \max_{i=1,\ldots,n} \sum_{k=1}^{n} |a_{ik}| = \sum_{k=1}^{n} |a_{i_0k}|,$$

para algún i_0 tal que $1 \leq i_0 \leq n$, esto es,

$$\|A\|_\infty \leq \sum_{k=1}^{n} |a_{i_0k}|.$$

Ahora bien, sea $x' \in \mathbb{K}^n$ definido como

$$x'_k = \begin{cases} 1, & a_{i_0 k} = 0 \\ \dfrac{\overline{a_{i_0 k}}}{|a_{i_0 k}|}, & a_{i_0 k} \neq 0 \end{cases}$$

Entonces $\|x'\|_\infty = 1$ y además

$$\|A\|_\infty \geq \|Ax'\|_\infty = \max_{i=1,\ldots,n} |(Ax)_i| \geq |(Ax)_{i_0}| = \sum_{k=1}^{n} |a_{i_0 k}|.$$

Por lo tanto

$$|A\|_\infty = \sum_{k=1}^{n} |a_{i_0 k}| = \max_{i=1,\ldots,n} \sum_{k=1}^{n} |a_{ik}|.$$

b) ¡Ejercicio!

□

NOTA. Si $\|\cdot\|$ es una norma subordinada, entonces $\|I\| = 1$.

Otro ejemplo de norma matricial es la norma de Fröbenius:

$$\|A\|_F = \left(\sum_{i,j=1}^{n} |a_{ij}|^2 \right)^{1/2}$$

En este caso se cumplen:

a) $\|I\|_F = \sqrt{n}$
b) Para todo $x \in \mathbb{K}^n$

$$\begin{aligned} \|Ax\|_2^2 &= \sum_{i=1}^{n} \left| \sum_{j=1}^{n} a_{ij} x_j \right|^2 \leq \sum_{i=1}^{n} \left(\sum_{j=1}^{n} |a_{ij}|^2 \sum_{j=1}^{n} |x_j|^2 \right) \\ &= \left(\sum_{i=1}^{n} \sum_{j=1}^{n} |a_{ij}|^2 \right) \left(\sum_{j=1}^{n} |x_j|^2 \right) = \|A\|_F^2 \sum_{j=1}^{n} |x_j|^2 \end{aligned}$$

esto implica que $\|Ax\|_2 \leq \|A\|_F \|x\|_2$, de donde

$$\|A\|_2 \leq \|A\|_F$$

La norma de Fröbenius no es subordinada de alguna otra (¿porqué?).

LEMA 3.4. *Sean $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_n$ los valores propios de la matriz hermitiana $A \in \mathbb{K}^{n\times n}$. Entonces se cumple*

$$\lambda_n \|x\|_2^2 \leq x^* A x \leq \lambda_1 \|x\|_2^2, \text{ para todo } x \in \mathbb{K}^{n\times n}.$$

DEMOSTRACIÓN. Como A es hermitiana, existe una matriz $U \in \mathbb{K}^{n\times n}$ unitaria ($U^*U = I$) tal que

$$U^* A U = \operatorname{diag}(\lambda_1, \ldots, \lambda_n).$$

Para cualquier $x \in \mathbb{K}^n$ se cumple:

$$\begin{aligned} x^* A x &= x^* \operatorname{diag}(\lambda_1, \ldots, \lambda_n) U^* x \\ &= (U^* x)^* \operatorname{diag}(\lambda_1, \ldots, \lambda_n)(U^* x) \\ &= \sum_{j=1}^{n} \lambda_i |(U^* x)_j|^2 \leq \lambda_1 \sum_{j=1}^{n} |(U^* x)_j|^2 = \lambda_1 \|U^* x\|_2^2 \\ &= \lambda_1 (U^* x)^* (U^* x) = \lambda_1 x^* U U^* x = \lambda_1 x^* I x \\ &= \lambda_1 \|x\|_2^2 \end{aligned}$$

Esto implica que $x^* A x \leq \lambda_1 \|x\|_2^2$. De manera similar se obtiene $\lambda_n \|x\|_2^2 \leq x^* A x$. □

DEFINICIÓN. *Sea $A \in \mathbb{K}^{n\times n}$, al conjunto ξ de valores propios de A se le llama espectro de A y al número*

$$\rho(A) = \max_{\lambda_i \in \xi} |\lambda_i|$$

se le llama radio espectral de la matriz A.

LEMA 3.5. *Se cumple $\|A\|_2 = \rho(A^*A)^{1/2}$, para todo $A \in \mathbb{K}^{n\times n}$.*

DEMOSTRACIÓN. Se tiene que A^*A es hermitiana y semidefinida positiva (pues $x^*(A^*A)x = (Ax)^*(Ax) = \|Ax\|_2^2 \geq 0, \quad \forall x \in \mathbb{K}^n$). Entonces A^*A tiene valores propios no negativos:

$$\rho(A^*A) = \lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_n \geq 0.$$

Por el lema anterior:

$$\|Ax\|_2^2 = x^*A^*Ax \leq \lambda_1\|x\|_2^2 = \rho(A^*A)\|x\|_2^2,$$

de donde

$$\frac{\|Ax\|_2^2}{\|x\|_2^2} \leq \rho(A^*A)$$

para $x \neq 0$; luego

$$\|A\|_2 \leq \sqrt{\rho(A^*A)}.$$

Sea $\hat{x} \in \mathbb{K}^n$ un vector propio correspondiente a $\rho(A^*A)$ de A^*A con $\|\hat{x}\|_2 = 1$. Luego se tiene:

$$\begin{aligned} \|A\|_2^2 &= \sup_{\|x\|=1} \|Ax\|_2^2 \geq \|A\hat{x}\|_2^2 = \hat{x}^*A^*Ax \leq \rho(A^*A)\|\hat{x}\|_2^2 \\ \|A\|_2 &\geq \sqrt{\rho(A^*A)}. \end{aligned}$$

De lo anterior $\|A\|_2 = \sqrt{\rho(A^*A)}$. □

TEOREMA 3.6. *Se cumplen:*

1) *Sea $\|\cdot\|$ una norma en $\mathbb{K}^n$. Entonces $\rho(A) \leq \|A\|$, para toda matriz $A \in \mathbb{K}^{n\times n}$.*
2) *Si $A \in \mathbb{K}^{n\times n}$ es hermitiana se cumple $\rho(A) = \|A\|_2$.*
3) *Para toda matriz $A \in \mathbb{K}^{n\times n}$ y $\varepsilon > 0$, existe una norma en $\mathbb{K}^{n\times n}$ con $\|A\| < \rho(A) + \varepsilon$, esto es*

$$\rho(A) = \inf_{\|\cdot\|} \|A\|,$$

donde el ínfimo se toma sobre todas las normas subordinadas de $\mathbb{K}^{n\times n}$.

DEMOSTRACIÓN. 1) Sea λ un valor propio de A cualquiera. Tomemos un vector propio correspondiente x con $\|x\| = 1$. Entonces

$$|\lambda| = |\lambda|\|x\| = \|\lambda x\| = \|Ax\| \leq \|A\|\|x\| = \|A\|.$$

En particular, tomemos λ tal que $|\lambda| = \rho(A)$, de donde $\rho(A) \leq \|A\|$.

2) En efecto, si $A = A^*$ entonces

$$\|A\|_2 = \sqrt{\rho(A^*A)} = \sqrt{\rho(A\,A)} = \sqrt{\rho(A^2)} = \sqrt{\rho(A)^2} = \rho(A).$$

3) Tomemos $\varepsilon > 0$. Como A es cuadrada, entonces existe una matriz inversible U tal que $S := U^{-1}AU = (s_{ij})$ es triangular superior. Definamos $E = \operatorname{diag}(\varepsilon, \varepsilon^2, \ldots, \varepsilon^n)$. Consideremos la matriz $E^{-1}SE = (s_{ij}\varepsilon^{j-i})$. Esta matriz es triangular superior, al igual que S. Para los elementos posiblemente no nulos fuera de la diagonal ($i < j$), tenemos:

$$|s_{ij}\varepsilon^{j-i}| < |s_{ij}|\varepsilon$$

esto es, los elementos de la diagonal son arbitrariamente pequeños (basta escoger un ε adecuado). La matriz $P := (UE)^{-1}$ es tal que $PAP^{-1} =$

$(s_{ij}\varepsilon^{j-i})$.
Debido a esto, podemos escribir $PAP^{-1} = D+T$, con D diagonal y $\|T\|_\infty < \varepsilon$.
Ahora bien, es obvio que si $\|\cdot\|$ es una norma en $\mathbb{K}^n$ y P una matriz inversible , la aplicación definida por $\|x\|' := \|Px\|$, $\forall x \in \mathbb{K}^n$ también lo es. Su norma subordinada es (véase que $y := Px$):

$$\|A\|' = \sup_{x\neq 0} \frac{\|Ax\|'}{\|x\|'} = \sup_{x\neq 0} \frac{\|PAx\|}{\|Px\|} = \sup_{y\neq 0} \frac{\|PAP^{-1}y\|}{\|y\|} = \|PAP^{-1}\|$$

De lo anterior, tenemos:

$$\|PAP^{-1}\|_\infty \leq \|D\|_\infty + \|T\|_\infty < \rho(A) + \varepsilon$$

y sabiendo que $\|A\| := \|PAP^{-1}\|_\infty$ es una norma subordinada, tenemos

$$\|A\| < \rho(A) + \varepsilon$$

□

2. Eliminación de Gauss

Dado el sistema lineal

$$\begin{aligned} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n &= b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n &= b_2 \\ &\vdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n &= b_n \end{aligned}$$

En su forma matricial:

$$Ax = b$$

donde

$$A = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{bmatrix} \in \mathbb{K}^{n\times n}, \quad b = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix} \in \mathbb{K}^n, \quad x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \in \mathbb{K}^n.$$

Empezamos con el sistema lineal de forma triangular superior

$$\begin{aligned} a_{11}x_1 + \quad a_{12}x_2 + \cdots + \quad & a_{1,n-1}x_{n-1} + \quad a_{1n}x_n \quad = b_1 \\ a_{22}x_2 + \cdots + \quad & a_{2,n-1}x_{n-1} + \quad a_{2n}x_n \quad = b_2 \\ & \vdots \\ & a_{n-1,n-1}x_{n-1} + \quad a_{n-1,n}x_n \quad = b_{n-1} \\ & \qquad\qquad\qquad\quad a_{nn}x_n \quad = b_n \end{aligned}$$

Supongamos que los elementos de la diagonal de A son distintos de cero: $a_{ii} \neq 0$, $i = 1, 2, \dots, n$. Luego:

$$\begin{aligned} x_n &= b_n/a_{nn}, \\ x_{n-1} &= [b_{n-1} - a_{n-1,n}x_n]/a_{n-1,n-1}, \\ x_j &= [b_j - \sum_{k=j+1}^{n} a_{jk}x_k]/a_{jj} \end{aligned}$$

Teorema 3.7. *Dado un sistema de ecuaciones lineales $Ax = b$. Las siguientes operaciones:*

i) *la multiplicación de una ecuación por un factor diferente de cero;*
ii) *la adición de un múltiplo de una ecuación a otra;*
iii) *el cambio de ecuaciones;*

Algoritmo 1 Resolución de sistema triangular superior $Ax = b$

Entrada: $A = (a_{ij}) \in \mathbb{K}^{n\times n}$, $b = (b_1, \ldots, b_n)^t \in \mathbb{K}^n$
1: **Condiciones:**
2: $a_{ii} \neq 0$, para $i = 1, \ldots, n$
3: $a_{ij} = 0$ para $j = 1, \ldots, i-1$, $i = 2, \ldots, n$ (matriz triangular superior)
Salida: $x = (x_1, \ldots, x_n)^t$ tal que $Ax = b$
4: $x_n := \dfrac{b_n}{a_{nn}}$
5: **Para** $j = n-1, n-2, \ldots, 1$ **hacer**
6: $x_j := \dfrac{1}{a_{jj}} \left(b_j - \displaystyle\sum_{k=j+1}^{n} a_{jk} x_k \right)$
7: **Fin Para**
8: **Devolver** $(x_1, x_2, \ldots, x_n)^t$

no cambian la solución del sistema, es decir el sistema lineal obtenido por estas operaciones, $\tilde{A}x = \tilde{b}$ tiene la misma solución del sistema $Ax = b$.

Luego, la transformación a un sistema triangular funciona del siguiente modo:

1. Se busca el coeficiente de la primera columna de $(A|b)$ que posea el valor absoluto más grande.

$$|a_{r1}| = \text{máx}\{|a_{11}|, |a_{21}|, \ldots, |a_{n1}|\}$$

2. Cambiar la primera ecuación con la r-ésima, se obtiene $(\overline{A}|\overline{b})$ con $\overline{A} = (\overline{a}_{jk})$ y $\overline{b} = (\overline{b_1}, \ldots, \overline{b_n})$, donde

$$\begin{cases} \overline{a}_{1k} := a_{rk} \\ \overline{a}_{rk} := a_{1k}, \quad k = 1, \ldots, n \\ \overline{a}_{jk} := a_{jk}, \quad j = 2, \ldots, n, j \neq r \end{cases}$$

$$\begin{cases} \overline{b}_1 := b_r \\ \overline{b}_r := b_1 \\ \overline{b}_j := b_j, \quad j = 2, \ldots, n, j \neq r \end{cases}$$

3. "Eliminar"los elementos $\overline{a}_{21}, \overline{a}_{31}, \ldots, \overline{a}_{n1}$, obteniéndose :

$$(A|b) \sim \left[\begin{array}{cccc|c} \overline{a}_{11} & \overline{a}_{12} & \ldots & \overline{a}_{1n} & \overline{b}_1 \\ 0 & \overline{a}_{22}^{(1)} & \ldots & \overline{a}_{2n}^{(1)} & \overline{b}_2^{(1)} \\ \vdots & \vdots & \ddots & & \vdots \\ 0 & \overline{a}_{n2}^{(1)} & \ldots & \overline{a}_{nn}^{(1)} & \overline{b}_n^{(1)} \end{array}\right]$$

con

$$a_{jk}^{(1)} := \overline{a}_{jk} - \frac{\overline{a}_{j1}}{\overline{a}_{11}} \overline{a}_{1k}, \quad j, k = 2, \ldots, n$$
$$b_j^{(1)} := \overline{b}_j - \frac{\overline{a}_{j1}}{\overline{a}_{11}} b_1, \quad j = 2, \ldots, n$$

Aplicando nuevamente 1, 2 y 3 a la submatriz

$$\left[\begin{array}{ccc|c} a_{22}^{(1)} & \ldots & a_{2n} & b_2^{(1)} \\ \vdots & \ddots & & \vdots \\ a_{n2}^{(1)} & \ldots & a_{nn} & b_n^{(1)} \end{array}\right]$$

se obtiene:

$$(A|b) \sim \left[\begin{array}{ccccccc|c} \overline{a}_{11} & \overline{a}_{12} & \overline{a}_{13} & \overline{a}_{14} & \dots & \overline{a}_{1n} & \overline{b}_1 \\ 0 & \overline{a}_{22}^{(1)} & \overline{a}_{23}^{(1)} & \overline{a}_{24}^{(1)} & \dots & \overline{a}_{2n}^{(1)} & \overline{b}_2^{(1)} \\ 0 & 0 & \overline{a}_{33}^{(2)} & \overline{a}_{34}^{(2)} & \dots & \overline{a}_{3n}^{(2)} & \overline{b}_3^{(2)} \\ \vdots & \vdots & & & \ddots & & \vdots \\ 0 & 0 & 0 & 0 & \dots & \overline{a}_{nn}^{(n-1)} & \overline{b}_n^{(n-1)} \end{array}\right]$$

2.1. Algoritmo de Gauss Jordan. Dados los sistemas

$$Ax = b^{(1)}, Ax = b^{(2)}, \dots, Ax = b^{(m)}$$

sea

$$W := (A|b^{(1)}|b^{(2)}|\dots|b^{(m)})$$

queremos

$$W \sim (\tilde{A}|\tilde{b}^{(1)}|\tilde{b}^{(2)}|\dots|\tilde{b}^{(m)})$$

con $\tilde{A}$ triangular superior,

$$W = \left[\begin{array}{ccc|ccc} w_{11} & \dots & w_{1n} & w_{1,n+1} & \dots & w_{1,n+m} \\ \vdots & & & \vdots & & \\ w_{n1} & \dots & w_{nn} & w_{n,n+1} & \dots & w_{n,n+m} \end{array}\right]$$

Utilizamos el vector $p := (p_1, \dots, p_n)$ (llamado *vector de permutaciones*) para registrar los cambios de filas. Al inicio se empieza con $p := (1, 2, \dots, n)$. Luego, en vez de hacer los cambios de filas, hacemos los cambios en las componentes de p. Así, en el primer paso, al cambiar la r-ésima fila por la primera resulta $p := (r, 2, \dots, r-1, 1, r+1, \dots, n)$.
De este modo tenemos en Algoritmo de Gauss-Jordan:

Entrada: $W \in \mathbb{K}^{n\times(n+m)}$, $W := (w_{jk}) = (A\|b^{(1)}\|b^{(2)}\|\dots\|b^{(m)})$
Poner $p := (p_1, \dots, p_n)$ con $p_i = i, \quad i = 1, 2, \dots, n$
Para k:=1,…,n-1
Encontrar $j \geq k$ con $\|w_{p_j,k}\| = \text{máx}\{\|w_{p_k,k}\|, \dots, \|w_{p_n,k}\|\}$
Cambiar p_j y p_k en p
Para $i := k+1, \dots, n$
Poner $m := w_{p_i,k}/w_{p_k,k}$
Poner $w_{p_i,k} := w_{p_i,k}/w_{p_k,k}$
Para $j := k+1, \dots, n, n+1, \dots, n+m$
$w_{p_i,j} := w_{p_i,j} - m \cdot w_{p_k,j}$
Salida: $W = (\tilde{A}\|\tilde{b}^{(1)}\|\tilde{b}^{(2)}\|\dots\|\tilde{b}^{(m)})$ con $\tilde{A}$ triangular superior permutada.

NOTAS.

1. En general, si se tuvieran m sistemas lineales

$$Ax = b^{(q)}, \quad q = 1, 2, \dots, m,$$

luego de aplicar el algoritmo anterior se tendrá que resolver $\tilde{A}x = \tilde{b}^{(q)}$, donde

$$(\tilde{A}|\tilde{b}^{(q)}) = \left[\begin{array}{cccc|c} w_{p_1,1} & w_{p_1,2} & \dots & w_{p_1,n} & w_{p_1,n+q} \\ & w_{p_2,2} & \dots & w_{p_2,n} & w_{p_2,n+q} \\ & & \ddots & \vdots & \vdots \\ 0 & & & w_{p_n,n} & w_{p_n,n+q} \end{array}\right]$$

Se puede usar el algoritmo para resolver sistemas de la forma triangular superior.

2. Propuesta: Verificar
Si se quiere resolver $Ax = \mathfrak{b}$, donde $\mathfrak{b} = (b_1, b_2, \ldots, b_n)^t$ usando $\tilde{A}$ del algoritmo anterior, se puede usar el sgte algoritmo:

Para $j := 1, \ldots, n-1$		
	Para $k := j+1, \ldots, n$	
		$b_{p_k} := b_{p_k} - w_{p_k,j} \cdot b_{p_j}$.

Luego, se resuelve el sistema triangular superior $\tilde{A}x = \mathfrak{b}$, donde

$$(\tilde{A}|\mathfrak{b}) = \left[\begin{array}{cccc|c} w_{p_1,1} & w_{p_1,2} & \ldots & w_{p_1,n} & b_{p_1} \\ & w_{p_2,2} & \ldots & w_{p_2,n} & b_{p_2} \\ & & \ddots & \vdots & \vdots \\ 0 & & & w_{p_n,n} & b_{p_n} \end{array}\right]$$

3. La factorización LU

Dada una matriz $A \in \mathbb{K}^{n\times n}$, se buscan

$$L = \begin{bmatrix} l_{11} & 0 & \ldots & 0 \\ l_{21} & l_{22} & \ldots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ l_{n1} & l_{n2} & \ldots & l_{nn} \end{bmatrix} \quad \text{y} \quad U = \begin{bmatrix} u_{11} & u_{12} & \ldots & u_{1n} \\ 0 & u_{22} & \ldots & u_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & \ldots & 0 & u_{nn} \end{bmatrix}$$

tales que

$$A = LU.$$

Si se tiene $A = LU$, para resolver el sistema lineal $Ax = b$ se procede como sigue:

$$b = LUx = Ly$$

Resolver $Ly = b$ obteniendo y, luego resolver $Ux = y$ obteniendo x.
Si exigimos $\det(A) \neq 0 \Longrightarrow \det(L) \neq 0, \det(U) \neq 0$ lo cual implica

$$l_{ii} \neq 0, u_{ii} \neq 0, \quad i = 1, 2, \ldots, n$$

Damos el algoritmo para resolver un sistema $LU : LUx = b$

Teorema 3.8. *El método de Gauss implica la factorización LU, si no se aplica cambio de filas.*

Demostración. Después del primer paso se obtiene sin cambio de filas

$$A^{(1)} = \begin{bmatrix} a_{11} & a_{12} & \ldots & a_{1n} \\ 0 & a_{22}^{(1)} & \ldots & a_{2n}^{(1)} \\ \vdots & \vdots & \ddots & \\ 0 & a_{n2}^{(1)} & \ldots & a_{nn}^{(1)} \end{bmatrix}$$

$A^{(1)} = L^{(1)}A$ donde

$$L^{(1)} = \begin{bmatrix} 1 & 0 & 0 & \ldots & 0 \\ -a_{21}/a_{11} & 1 & 0 & \ldots & 0 \\ -a_{31}/a_{11} & 0 & 1 & \ldots & 0 \\ \vdots & \vdots & & \ddots & 0 \\ -a_{n1}/a_{11} & 0 & 0 & \ldots & 1 \end{bmatrix}$$

Algoritmo 2 Resolución de sistema $Ax = b$ usando factorización $A = LU$

Entrada: $L = (l_{ij})$ matriz triangular inferior, $U = (u_{ij})$ matriz triangular superior tal que $A = LU$, $b = (b_1, \ldots, b_n)^t$

Salida: $x = (x_1, \ldots, x_n)^t$ tal que $Ax = b$

1: Calcular $y_1 := \dfrac{b_1}{l_{11}}$
2: **Para** $j = 2, 3, \ldots, n$ **hacer**
3: $\quad y_j := \dfrac{1}{l_{jj}} \left(b_j - \displaystyle\sum_{i=1}^{j-1} l_{ji} y_i \right)$
4: **Fin Para**
5: Calcular $x_n := \dfrac{y_n}{u_{nn}}$
6: **Para** $j = n-1, n-2, \ldots, 1$ **hacer**
7: $\quad x_j := \dfrac{1}{u_{jj}} \left(y_j - \displaystyle\sum_{i=j+1}^{n} u_{ji} x_i \right)$
8: **Fin Para**
9: **Devolver** $x = (x_1, \ldots, x_n)^t$

después del segundo paso sin cambios de filas

$$A^{(2)} = \begin{bmatrix} a_{11} & a_{12} & a_{13} & a_{14} & \ldots & a_{1n} \\ 0 & a_{22}^{(1)} & a_{23}^{(1)} & a_{24}^{(1)} & \ldots & a_{2n}^{(1)} \\ 0 & 0 & a_{33}^{(2)} & a_{34}^{(2)} & \ldots & a_{3n}^{(2)} \\ \vdots & \vdots & & & & \vdots \\ 0 & 0 & a_{n3}^{(2)} & a_{n4}^{(2)} & \ldots & a_{nn}^{(2)} \end{bmatrix} = L^{(2)} A^{(1)} = L^{(2)} L^{(1)} A$$

Al final resulta:

$$A^{(n-1)} = L^{(n-1)} A^{(n-2)} = L^{(n-1)} \ldots L^{(1)} A$$

con

$$A^{(n-1)} = \begin{bmatrix} a_{11} & a_{12} & a_{13} & \ldots & a_{1n} \\ 0 & a_{22}^{(1)} & a_{23}^{(1)} & \ldots & a_{2n}^{(1)} \\ 0 & 0 & a_{33}^{(2)} & \ldots & a_{3n}^{(2)} \\ \vdots & \vdots & & \ddots & \vdots \\ 0 & 0 & 0 & \ldots & a_{nn}^{(n-1)} \end{bmatrix}$$

y

$$L^{(k)} = \begin{bmatrix} 1 & 0 & & 0 & & \ldots & & 0 \\ 0 & 1 & & \vdots & & & & \vdots \\ & \ddots & & & & & & \\ & & & 1 & & & & 0 \\ \vdots & & & -a_{k+1,k}^{(k-1)} / a_{kk}^{(k-1)} & & 1 & \ldots & 0 \\ & & & \vdots & & \vdots & \ddots & 0 \\ 0 & \ldots & & -a_{n,k}^{(k-1)} / a_{kk}^{(k-1)} & & 0 & \ldots & 1 \end{bmatrix}$$

definimos $U = A^{(n-1)}$, esta matriz es triangular superior.

$$L = \begin{bmatrix} 1 & 0 & \dots & 0 \\ a_{21}/a_{11} & 1 & & 0 \\ a_{31}/a_{11} & a_{32}^{(1)}/a_{22}^{(1)} & 1 & \vdots \\ \vdots & & \vdots & \ddots \quad 0 \\ a_{n1}/a_{11} & a_{n2}^{(1)}/a_{22}^{(1)} & & \dots \quad 1 \end{bmatrix}$$

que es una matriz triangular inferior. Luego:

$$A = LU$$

como se quería. □

Nota. La eliminación de Gauss sin cambios de fila no siempre es posible. Por ejemplo:

$$A = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}, \text{ se tiene } \det(A) \neq 0$$

supongamos

$$A = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} = \begin{bmatrix} l_{11} & 0 \\ l_{21} & l_{22} \end{bmatrix} \begin{bmatrix} u_{11} & u_{12} \\ 0 & u_{22} \end{bmatrix}$$

entonces

$$\begin{array}{ll} l_{11}u_{11} = 0 & (1) \\ l_{11}u_{12} = 1 & (2) \\ l_{21}u_{11} = 1 & (3) \\ l_{21}u_{12} + l_{22}u_{22} = 0 & (4) \end{array}$$

de (3) $u_{11} \neq 0$ y de (1) $l_{21} = 0$ lo cual no cumple (2). Por lo tanto $A = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$ no tiene una factorización LU .

Sin embargo:

Teorema 3.9. *Para una matriz regular A existe siempre, antes de la k-ésima eliminación en el algoritmo de Gauss, una permutación de filas, tal que el k-ésimo elemento diagonal es distinto de cero.*

Demostración. Si $a_{11} = 0$, entonces por lo menos existe un $a_{i1} \neq 0$ en la primera columna e i-ésima fila (de otro modo A no sería regular). Esto produce un elemento $\overline{a}_{11} \neq 0$ y se obtiene:

$$\det(A) = \begin{vmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{vmatrix} = (-1)^{v_1} \begin{vmatrix} \overline{a}_{11} & \overline{a}_{12} & \dots & \overline{a}_{1n} \\ 0 & \overline{a}_{22}^{(1)} & \dots & \overline{a}_{2n}^{(1)} \\ \vdots & \vdots & \ddots & \\ 0 & \overline{a}_{n2}^{(1)} & \dots & \overline{a}_{nn}^{(1)} \end{vmatrix}$$

donde

$$v_1 = \begin{cases} 1, & \text{si hubo cambio de fila} \\ 0, & \text{en otro caso} \end{cases}$$

de este modo:

$$\det(A) = (-1)^{v_1+v_2+\dots+v_{n-1}} \overline{a}_{11}\overline{a}_{22}^{(1)} \dots \overline{a}_{n-1,n-1}^{(n-2)} \overline{a}_{nn}^{(n-1)}.$$

□

Teorema 3.10. *Para cada matriz A regular, existe una matriz de permutación P, tal que el producto PA se puede factorizar como $PA = LU$.*

DEMOSTRACIÓN. Las matrices de permutación P contienen en cada fila y en cada columna un elemento igual a 1 y el resto igual a 0.
Todos los cambios de fila que sean necesarios para aplicar el método de Gauss se pueden almacenar en una matriz de permutación P (esto se hace cambiando las filas de la matriz identidad I según indica el vector de permutaciones p del método) de modo que al aplicar el método de Gauss a la matriz PA ya no sea necesario el cambio de filas. Luego, por el teorema 3.8, se obtiene que la matriz PA tiene una factorización LU. □

TEOREMA 3.11. *Si los menores principales de una matriz A son no singulares, entonces A admite la factorización LU sin cambios de filas.*

DEMOSTRACIÓN. Los menores principales de la matriz A son las submatrices

$$A_k = \begin{bmatrix} a_{11} & \dots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{k1} & \dots & a_{kk} \end{bmatrix}$$

Ahora bien, $\det(A_1) = det(a_{11}) = a_{11} \neq 0$.

$$\det(A_2) = \begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{vmatrix} = \begin{vmatrix} a_{11} & a_{12} \\ 0 & a_{22}^{(1)} \end{vmatrix} \neq 0 \Longrightarrow a_{11}a_{22}^{(1)} \neq 0 \Longrightarrow a_{22}^{(1)} \neq 0$$

y así

$$\det(A_k) = \begin{vmatrix} a_{11} & \dots & a_{1k} \\ \vdots & & \vdots \\ a_{k1} & \dots & a_{kk} \end{vmatrix} = a_{11}a_{22}^{(1)}a_{33}^{(2)} \dots a_{kk}^{(k-1)} \neq 0, \quad k = 1, 2, \dots, n$$

lo cual implica que $a_{kk}^{(k-1)} \neq 0, \quad k = 1, 2, \dots, n$.
Como no hay cambio de filas, por el teorema 3.8, A tiene una factorización LU. □

LEMA 3.12. *Sea $A = A^t \in \mathbb{K}^{n\times n}$ definida positiva. Entonces se puede aplicar la eliminación de Gauss sin cambio de filas y A tiene una factorización LU con L matriz triangular inferior con elementos en la diagonal iguales a 1 y U matriz triangular superior.*

DEMOSTRACIÓN. Los menores principales $A_k, \quad k = 1, 2, \dots n$ de A son matrices definidas positivas, pues como

$$x^t Ax > 0, \quad \text{para todo } x \neq 0, \quad x = (x_1, x_2, \dots, x_n) \in \mathbb{K}^n.$$

Dado un vector arbitrario $y = (y_1, y_2, \dots, y_k) \neq 0 \in \mathbb{K}^k$, tomando
$x = (y_1, \dots, y_k, 0, \dots, 0) \in \mathbb{K}^n$ tenemos:

$$y^t A_k y = x^t Ax > 0$$

De donde $\det(A_k) \neq 0, \quad k = 1, 2, \dots, n$. Por el teorema anterior, A tiene una factorización LU y por la prueba del teorema 3.8, L tiene elementos en la diagonal iguales a 1. □

4. Errores y condición de una matriz

4.1. Influencia de errores por redondeos.

EJEMPLO 3.3. Consideremos el sistema lineal:

$$\begin{array}{rcccc} 0{,}005 & x & + & y & = & 0{,}5 \\ & x & + & y & = & 1 \end{array}$$

entonces

$$x = \frac{5000}{9950} \approx 0{,}503$$
$$y = \frac{4950}{9950} \approx 0{,}497$$

En cálculos con punto flotante con 2 decimales (mantisa con $t = 2$):

a) Tomando a $a_{11} = 0{,}005$ como elemento pivote

$$\begin{aligned} 0{,}005\, x + \ y &= 0{,}5 \\ -199\, y &= -99 \end{aligned}$$

$$y = \frac{-99}{-199} \approx 0{,}50 \text{ de donde } x \approx 0$$

b) Tomando $a_{21} = 1$ como elemento pivote:

$$\begin{aligned} x \ + \ y &= 1 \\ 0{,}995\, y &= 0{,}495 \end{aligned}$$

$$y = \frac{0{,}495}{0{,}995} \approx 0{,}497 \approx 0{,}50 \text{ de donde } x \approx 0{,}50,$$

más exacto que antes.

c) Multiplicando por (400) la primera fila del sistema lineal inicial tenemos

$$\begin{aligned} 2\, x + 400\, y &= 200 \\ x \ + \ y &= 1 \end{aligned}$$

Eligiendo $a_{11} = 2$ como elemento de pivoteo se obtiene el mismo resultado inexacto como en (a).

Observación. La búsqueda del elemento de pivoteo muchas veces no tiene mucho sentido, si los coeficientes tienen un tamaño diferente.

4.2. Condición de una matriz.

Sea A una matriz invertible, y supongamos que en $Ax = b$, se cambia b por $\tilde{b}$. Veamos cómo influye esto en la solución del sistema x, que cambia a $\tilde{x}$. Tenemos $\|Ax\| = \|b\|$ y

$$Ax = b, \qquad A\tilde{x} = \tilde{b}.$$

Entonces:

$$\begin{aligned} \|x - \tilde{x}\| &= \|A^{-1}b - A^{-1}\tilde{b}\| \leq \|A^{-1}\|\|b - \tilde{b}\| = \|A^{-1}\|\frac{\|Ax\|}{\|b\|}\|b - \tilde{b}\| \\ &\leq \|A^{-1}\|\|A\|\|x\|\frac{\|b - \tilde{b}\|}{\|b\|} \end{aligned}$$

de donde

$$\frac{\|x - \tilde{x}\|}{\|x\|} \leq \|A^{-1}\|\|A\|\frac{\|b - \tilde{b}\|}{\|b\|}$$

o bien

$$\frac{\|\Delta x\|}{\|x\|} \leq (\|A^{-1}\|\|A\|)\frac{\|\Delta b\|}{\|b\|}$$

donde $\Delta x := x - \tilde{x}$, $\Delta b := b - \tilde{b}$, $b, x \neq 0$.

Definición. *El valor $\|A^{-1}\|\|A\|$ es denominado el número de condición de la matriz A y se denota por* $\mathrm{cond}(A)$*, esto es*

$$\mathrm{cond}(A) := \|A^{-1}\|\|A\|$$

o

$$\mathrm{cond}_{\|\cdot\|}(A) := \|A^{-1}\|\|A\|.$$

La condición de una matriz depende de la norma.

NOTA. Se cumple, para una norma subordinada, que

$$\mathrm{cond}_{\|\cdot\|}(A) = \|A^{-1}\|\|A\| \geq \|A^{-1}A\| = \|I\| = 1$$

EJEMPLO 3.4. Sean

$$A := \begin{bmatrix} 1 & 0{,}99 \\ 0{,}99 & 0{,}98 \end{bmatrix}, \quad b := \begin{bmatrix} 1{,}99 \\ 1{,}97 \end{bmatrix}, \quad \tilde{b} := \begin{bmatrix} 1{,}989903 \\ 1{,}970106 \end{bmatrix}$$

La solución exacta de $Ax = b$ es $x = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$

La solución de $A\tilde{x} = \tilde{b}$ es $\tilde{x} = \begin{bmatrix} 3 \\ -1{,}0203 \end{bmatrix}$

Aquí el cambio $b - \tilde{b} = \begin{bmatrix} -0{,}000097 \\ 0{,}000106 \end{bmatrix}$ que es pequeño influye en el cambio relativamente grande $x - \tilde{x} = \begin{bmatrix} 2{,}0000 \\ -2{,}0203 \end{bmatrix}$

$$\frac{\|x - \tilde{x}\|_\infty}{\|x\|_\infty} = \frac{2{,}0203}{1} = 2{,}0203$$
$$\frac{\|b - \tilde{b}\|_\infty}{\|b\|_\infty} = \frac{0{,}000106}{1{,}99} = 0{,}000053266$$

Como

$$\frac{\|\Delta x\|_\infty}{\|x\|_\infty} \leq \mathrm{cond}_\infty(A) \frac{\|\Delta b\|_\infty}{\|b\|_\infty}$$

Luego el error se propaga un factor

$$\frac{2{,}0203}{0{,}000053266} \approx 37928$$

Como

$$A^{-1} = \begin{bmatrix} -9800 & 9900 \\ 9900 & -10000 \end{bmatrix}$$

luego

$$\mathrm{cond}_\infty(A) = \|A^{-1}\|_\infty \|A\|_\infty = 19900 \cdot 1{,}99 = 39601$$

Entonces se dice que el problema es *mal condicionado*, cuando $\mathrm{cond}(A)$ es muy grande.

NOTA. En general el cálculo de $\|A^{-1}\|$ es un problema.

TEOREMA 3.13. *En el caso de la norma $\|\cdot\|_2$ se obtiene*

$$\mathrm{cond}_2(A) = \rho(A)\rho(A^{-1}) = \frac{|\lambda_{\text{máx}}|}{|\lambda_{\text{mín}}|},$$

donde $\lambda_{\text{máx}}$ es el valor propio de A con el valor absoluto más grande y $\lambda_{\text{mín}}$ es el valor propio con el valor absoluto más pequeño.

LEMA 3.14 (De perturbación). *Sea $A \in \mathbb{K}^{n\times n}$ regular. Si $S \in \mathbb{K}^{n\times n}$ es una perturbación de A con $\|A^{-1}\|\|S\| < 1$, entonces $A + S$ es regular y*

$$\left\|(A+S)^{-1}\right\| \leq \frac{\|A^{-1}\|}{1 - \|A^{-1}\|\|S\|}.$$

DEMOSTRACIÓN. Se cumple:

$$\left\|(I + A^{-1}S)y\right\| \geq \|y\| - \|A^{-1}Sy\| \geq \left(1 - \|A^{-1}S\|\right)\|y\|, \qquad \text{para todo } y \in \mathbb{K}^n. \tag{4}$$

Entonces, la ecuación $(I + A^{-1}S)y = 0$ implica $y = 0$ como solución única, esto es, $I + A^{-1}S$ es no singular. Luego $I + A^{-1}S$ y $A(I + A^{-1}S) = A + S$ son matrices regulares.

Para $y = (I + A^{-1}S)^{-1}x$, $x \in \mathbb{K}^n$, de (4) se obtiene:

$$\begin{aligned}\left\|(I + A^{-1}S)^{-1}x\right\| &\leq \frac{\left\|(I + A^{-1}S)(I + A^{-1}S)^{-1}x\right\|}{1 - \|A^{-1}\|\|S\|} \\ &= \frac{\|x\|}{1 - \|A^{-1}\|\|S\|},\end{aligned}$$

de donde

$$\left\|(I + A^{-1}S)^{-1}\right\| \leq \frac{1}{1 - \|A^{-1}\|\|S\|}$$

De esto se obtiene:

$$\begin{aligned}\left\|(A + S)^{-1}\right\| =& \left\|(I + A^{-1}S)^{-1}A^{-1}\right\| \\ &\leq \left\|(I + A^{-1}S)^{-1}\right\|\|A^{-1}\| \leq \frac{\|A\|^{-1}}{1 - \|A^{-1}\|\|S\|}.\end{aligned}$$

□

TEOREMA 3.15. *Sea $A \in \mathbb{K}^{n\times n}$ una matriz regular, $\Delta A \in \mathbb{K}^{n\times n}$ una matriz con $\|A^{-1}\|\|\Delta A\| < 1$, $b \in \mathbb{K}^n \setminus \{0\}$, $\Delta b \in \mathbb{K}^n$ y x, Δx definidos por $Ax = b$ y $(A + \Delta A)(x + \Delta x) = b + \Delta b$. Entonces se cumple*

$$\frac{\|\Delta x\|}{\|x\|} \leq \frac{\mathrm{cond}_{\|\cdot\|}(A)}{1 - \mathrm{cond}_{\|\cdot\|}(A)\dfrac{\|\Delta A\|}{\|A\|}}\left[\frac{\|\Delta A\|}{\|A\|} + \frac{\|\Delta b\|}{\|b\|}\right].$$

DEMOSTRACIÓN. Como $\|A^{-1}\|\|\Delta A\| < 1$ y siendo A regular, por el lema 3.14 para $S := \Delta A$ se obtiene que $A + \Delta A$ es regular y

$$\left\|(A + \Delta A)^{-1}\right\| \leq \frac{\|A^{-1}\|}{1 - \|A^{-1}\|\|\Delta A\|} \tag{5}$$

de $Ax = b$ y $(A + \Delta A)(x + \Delta x) = b + \Delta b$ se obtiene:

$$Ax + \Delta Ax + A\Delta x + \Delta A\Delta x = b + \Delta b$$

Luego,

$$\Delta x = (A + \Delta A)^{-1}(\Delta b - \Delta Ax). \tag{6}$$

De (5) y (6):

$$\begin{aligned}\|\Delta x\| &\leq \left\|(A + \Delta A)^{-1}\right\|\|\Delta b - \Delta Ax\| \\ &\leq \frac{\|A^{-1}\|}{1 - \|A^{-1}\|\|\Delta A\|}\left[\frac{\|\Delta b\|}{\|b\|}\|b\| + \frac{\|\Delta A\|\|x\|\|A\|}{\|A\|}\right] \\ &\leq \frac{\|A^{-1}\|}{1 - \|A^{-1}\|\|\Delta A\|}\left[\frac{\|\Delta b\|}{\|b\|}\|A\|\|x\| + \frac{\|\Delta A\|}{\|A\|}\|A\|\|x\|\right] \\ &= \frac{\|A^{-1}\|\|A\|}{1 - \left(\|A^{-1}\|\|A\|\right)\left(\dfrac{\|\Delta A\|}{\|A\|}\right)}\left[\frac{\|\Delta A\|}{\|A\|} + \frac{\|\Delta b\|}{\|b\|}\right]\|x\|,\end{aligned}$$

de donde

$$\frac{\|\Delta x\|}{\|x\|} \leq \frac{\mathrm{cond}_{\|\cdot\|}(A)}{1 - \mathrm{cond}_{\|\cdot\|}(A)\dfrac{\|\Delta A\|}{\|A\|}}\left[\frac{\|\Delta A\|}{\|A\|} + \frac{\|\Delta b\|}{\|b\|}\right].$$

□

5. Factorización LU para sistemas especiales

Sea $A = (a_{ij})_{n\times n} = LU$, donde

$$L = \begin{bmatrix} l_{11} & 0 & \dots & 0 \\ l_{21} & l_{22} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ l_{n1} & l_{n2} & \dots & l_{nn} \end{bmatrix} \qquad U = \begin{bmatrix} u_{11} & u_{12} & \dots & u_{1n} \\ 0 & u_{22} & \dots & u_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & \dots & 0 & u_{nn} \end{bmatrix}$$

se cumple que $a_{ij} = \sum_{k=1}^{n} l_{ik}u_{kj}, \quad i,j = 1,2,\dots,n.$

Para $k > i$, $l_{ik} = 0$; entonces basta calcular solamente para $1 \le i \le k$. Por otro lado, para $k > j$: $u_{kj} = 0$; basta entonces calcular solamente para $1 \le j \le k$. Luego:

$$a_{ij} = \sum_{k=1}^{\text{mín}\{i,j\}} l_{ik}u_{kj}, \quad i,j = 1,2,\dots,n$$

Específicamente, para

$$\begin{aligned} i = j: &\quad l_{jj}u_{jj} = a_{jj} - \sum_{k=1}^{j-1} l_{jk}u_{kj}, \quad j = 1,2,\dots,n \\ j > i: &\quad u_{ij} = \frac{1}{l_{ii}}(a_{ij} - \sum_{k=1}^{i-1} l_{ik}u_{kj}) \\ i > j: &\quad l_{ij} = \frac{1}{u_{jj}}(a_{ij} - \sum_{k=1}^{j-1} l_{ik}u_{kj}). \end{aligned}$$

5.1. Algoritmo de Cholesky.

TEOREMA 3.16. *Sea $A = A^t \in \mathbb{R}^{n\times n}$ definida positiva. Entonces existe una única matriz triangular inferior $L \in \mathbb{R}^{n\times n}$ con elementos diagonales positivos tal que $A = LL^t$.*

DEMOSTRACIÓN. Por el lema 3.12 existe una factorización LU para una matriz simétrica y definida positiva, esto es, existe $\hat{L} \in \mathbb{R}^{n\times n}$ triangular inferior con unos en la diagonal y $\hat{U} \in \mathbb{R}^{n\times n}$ matriz triangular superior regular tal que $A = \hat{L}\hat{U}$. Definamos $D := \hat{U}(\hat{L}^t)^{-1}$. De $A = \hat{L}\hat{U}$ y $A = A^t$ tenemos

$$\hat{L}\hat{U} = A = A^t = \hat{U}^t\hat{L}^t$$

de donde

$$D := \hat{U}(\hat{L}^t)^{-1} = \hat{L}^{-1}\hat{U}^t$$

Ahora bien, del álgebra lineal se sabe que el producto de matrices triangulares superiores [inferiores] es triangular superior [inferior], que la inversa de una matriz triangular superior [inferior] es triangular superior [inferior] y que la transpuesta de una matriz triangular superior [inferior] es triangular inferior [superior]. Sabiendo esto, la igualdad $D = \hat{U}(\hat{L}^t)^{-1}$ implica que la matriz D es triangular superior, y la igualdad $D = \hat{L}^{-1}\hat{U}^t$ implica que D es triangular inferior. Luego D es una matriz diagonal :

$$D = \text{diag}(d_{11}, d_{22}, \dots, d_{nn})$$

Además:

$$A = \hat{L}\hat{U} = \hat{L}D\hat{L}^t.$$

Siendo A definida positiva, D también lo es, pues dado $x \neq 0 \in \mathbb{R}^n$:

$$x^t D x = x^t \hat{L}^{-1} A (\hat{L}^t)^{-1} x = x^t \hat{L}^{-1} A (\hat{L}^{-1})^t x = \big((\hat{L}^{-1})^t x\big)^t A \big((\hat{L}^{-1})^t x\big) > 0$$

luego $d_{ii} = e_i^t D e_i > 0$, $i = 1, 2, \ldots, n$. Así, D tiene diagonal positiva. Definiendo $D^{1/2} = \operatorname{diag}\big(\sqrt{d_{11}}, \sqrt{d_{22}}, \ldots, \sqrt{d_{nn}}\big)$, tenemos:

$$A = \hat{L} D \hat{L}^t = \hat{L} D^{1/2} D^{1/2} \hat{L}^t = (\hat{L} D^{1/2})(\hat{L} D^{1/2})^t = L L^t$$

Con $L := \hat{L} D^{1/2}$, matriz triangular inferior con elementos diagonales positivos, como se buscaba.

La prueba de la unicidad se deja como ejercicio. □

DEFINICIÓN. *La factorización de una matriz $A = A^t \in \mathbb{R}^{n \times n}$ definida positiva, tal que $A = LL^t$ donde L es una matriz triangular inferior con elementos diagonales positivos, es denominada factorización de Cholesky de A.*

De las fórmulas vistas anteriormente con

$$\begin{aligned} u_{jj} &= l_{jj}, \quad j = 1, 2, \ldots, n \\ l_{ij} &= u_{ji}, \quad i, j = 1, 2, \ldots, n \end{aligned}$$

se obtiene

$$\begin{aligned} l_{jj}^2 &= a_{jj} - \sum_{k=1}^{j-1} l_{jk}^2, \quad j = 1, 2, \ldots, n \\ l_{ij} &= \frac{1}{l_{jj}} (a_{ij} - \sum_{k=1}^{j-1} l_{ik} l_{jk}), \quad j < i. \end{aligned}$$

Así tenemos el algoritmo de Cholesky:

Algoritmo 3 Descomposición de Cholesky de una matriz definida positiva A

Entrada: $A = A^t = (a_{ij}) \in \mathbb{R}^{n \times n}$, definida positiva
Salida: Parte triangular inferior de L tal que $A = LL^t$

1: Calcular $l_{11} := \sqrt{a_{11}}$
2: **Para** $i = 2, \ldots, n$ **hacer**
3: Calcular $l_{i1} := \dfrac{a_{i1}}{l_{11}}$
4: **Fin Para**
5: **Para** $j = 2, \ldots, n$ **hacer**
6: Calcular $l_{jj} := \left(a_{jj} - \sum_{k=1}^{j-1} l_{jk}^2 \right)^{1/2}$
7: **Para** $i = j + 1, \ldots, n$ **hacer**
8: Calcular $l_{ij} := \dfrac{1}{l_{jj}} \left(a_{ij} - \sum_{k=1}^{j-1} l_{ik} l_{jk} \right)$
9: **Fin Para**
10: **Fin Para**
11: **Devolver** Parte triangular inferior de L

Se cumple:

$$\begin{aligned} \operatorname{cond}_2(A) &= \|A\|_2 \|A^{-1}\|_2 = \rho(A)\rho(A^{-1}) = \rho(LL^t)\rho((L^{-1})^t L^{-1}) \\ \operatorname{cond}_2(L) &= \|L\|_2 \|L^{-1}\|_2 = \rho(L)\rho(L^{-1}) \end{aligned}$$

La cantidad de operaciones necesarias para este algoritmo, es solamente la mitad de las del algoritmo de Gauss para n bastante grande.

5.2. Algoritmo compuesto para sistemas tridiagonales. Consideremos el sistema:

$$\begin{array}{ccccccccccccc}
a_1x_1 & + & c_1x_2 & & & & & & & & & = & f_1 \\
b_2x_1 & + & a_2x_2 & + & c_2x_3 & & & & & & & = & f_2 \\
 & & b_3x_2 & + & a_3x_3 & + & c_3x_4 & & & & & = & f_3 \\
 & & & & b_4x_2 & & \dots & & & & & & \\
 & & & & \ddots & & & & & & & & \vdots \\
 & & & & & & b_{n-1}x_{n-2} & + & a_{n-1}x_{n-1} & + & c_{n-1}x_n & = & f_{n-1} \\
 & & & & & & & & b_nx_{n-1} & + & a_nx_n & = & f_n
\end{array}$$

Sea

$$A = \begin{bmatrix} a_1 & c_1 & 0 & \dots & 0 \\ b_2 & a_2 & c_2 & & 0 \\ 0 & b_3 & a_3 & & 0 \\ \vdots & & \ddots & & c_{n-1} \\ 0 & \dots & 0 & b_n & a_n \end{bmatrix}$$

El sistema anterior (con la matriz $A = (a_{ij})$ asociada) es *tridiagonal* cuando $a_{ij} = 0$, para $|i - j| > 1$.

Si $A = LU$ con

$$L = \begin{bmatrix} \alpha_1 & 0 & \dots & & 0 \\ b_2 & \alpha_2 & \dots & & 0 \\ 0 & b_3 & & & \\ \vdots & 0 & \ddots & & \vdots \\ 0 & \dots & 0 & b_n & \alpha_n \end{bmatrix} \qquad U = \begin{bmatrix} 1 & u_1 & 0 & \dots & 0 \\ 0 & 1 & & \dots & 0 \\ & & \ddots & & \vdots \\ \vdots & & & 1 & u_{n-1} \\ 0 & & \dots & 0 & 1 \end{bmatrix}$$

Entonces

$$\begin{array}{ll}
a_1 = \alpha_1 & c_1 = \alpha_1 u_1 \\
b_2 = \alpha_2 & a_2 = b_2u_1 + \alpha_2 \qquad c_1 = \alpha_1 u_1 \\
 & a_3 = b_3u_2 + \alpha_3 \qquad c_2 = \alpha_2 u_2 \\
 & \vdots \qquad\qquad \vdots \\
 & a_n = b_nu_{n-1} + \alpha_n \quad c_{n-1} = \alpha_{n-1}u_{n-1}
\end{array}$$

Se obtiene:

$$\begin{array}{l}
\alpha_1 = a_1, \quad u_1 := c_1/\alpha_1 \\
\alpha_j = a_j - b_ju_{j-1}, \quad j = 2, \dots, n \\
u_j = c_j/\alpha_j, \quad j = 2, \dots, n-1
\end{array}$$

Se requieren $\alpha_j \neq 0, \quad j = 1, 2, \dots, n.$

Así tenemos el algoritmo compuesto para sistemas tridiagonales:

6. La Factorización QR

DEFINICIÓN. *Sea $A \in \mathbb{R}^{m\times n}$, $m \geq n$. Si existe una matriz ortogonal $Q \in \mathbb{R}^{m\times m}$ ($Q^tQ = I$) y una matriz $R = \begin{bmatrix} R_1 \\ 0 \end{bmatrix} \in \mathbb{R}^{m\times n}$ con R_1 matriz matriz triangular superior tal que $A = QR$, entonces QR es denominada factorización QR de A.*

La razón de desear obtener una factorización tal es simple: dado el sistema $Ax = b$ con $A = QR$ y $Q^tQ = I$ entonces

$$QRx = b \text{ implica } Q^tQRx = Q^tb, \text{ y luego } Rx = Q^tb,$$

un sistema triangular superior.

Algoritmo 4 Resolución de sistemas tridiagonales $Ax = f$

Entrada: $A = (b_j, a_j, c_j)$ matriz tridiagonal, $f = (f_1, \ldots, f_n)^t$ vector lado derecho
Salida: Solución $(x_1, \ldots, x_n)^t$ tal que $Ax = f$

$\alpha_1 := a_1, \quad u_1 := \frac{c_1}{\alpha_1}$
Para $j = 2, \ldots, n-1$ **hacer**
    $\alpha_j := a_j - b_j u_{j-1}$
    $u_j := \frac{c_j}{\alpha_j}$
Fin Para
$\alpha_n := a_n - b_n u_{n-1}$
$y_1 := \frac{f_1}{\alpha_1}$
Para $j = 2, \ldots, n$ **hacer**
    $y_j := \frac{f_j - b_j y_{j-1}}{\alpha_j}$
Fin Para
$x_n := y_n$
Para $j = n-1, \ldots, 1$ **hacer**
    $x_j := y_j - u_j x_{j+1}$
Fin Para
Devolver Solución $(x_1, \ldots, x_n)^t$

TEOREMA 3.17. *Sea $A \in \mathbb{R}^{m\times n}$, con $rang(A) = n$, $m \geq n$. Entonces A tiene una factorización QR con $R = \begin{bmatrix} R_1 \\ 0 \end{bmatrix}$ y R_1 tiene elementos diagonales distintos de cero.*

DEMOSTRACIÓN. Aplicando el proceso de ortogonalización de Gram-Schmidt a las columnas $a_1, a_2, \ldots, a_n$ de A se obtiene un sistema ortonormal $\{q_1, q_2, \ldots, q_n\} \subset \mathbb{R}^n$ con $\text{lin}\{a_1, \ldots, a_k\} = \text{lin}\{q_1, \ldots, q_k\}$ para $1 \leq k \leq n$. En especial se cumple:

$$a_k = \sum_{j=1}^{k} r_{jk} q_j, \quad k = 1, \ldots, n$$

con $r_{kk} \neq 0$. Completando $\{q_1, \ldots, q_n\}$ a una base ortonormal de $\mathbb{R}^m$, digamos $\{q_1, \ldots, q_n, q_{n+1}, \ldots, q_m\}$, se tiene que $Q := [q_1, \ldots, q_m] \in \mathbb{R}^{m\times n}$ es ortogonal, y definiendo

$$(R_1)_{jk} := \begin{cases} r_{jk}, & \text{para } j \leq k \\ 0, & \text{para } j > k \end{cases}$$

se cumple

$$A = [a_1, \ldots, a_n] = QR, \quad R := \begin{bmatrix} R_1 \\ 0 \end{bmatrix}.$$

□

TEOREMA 3.18. *Para cualquier matriz $A \in \mathbb{R}^{m\times n}$, $m \geq n$ existe una factorización QR.*

6.1. Factorización QR de Householder.

Idea: En el primer paso se determina una matriz ortogonal $P_1 \in \mathbb{R}^{m\times m}$ tal que

$$P_1 A = \left[\begin{array}{c|ccc} * & & & \\ \hline 0 & * & \ldots & * \\ \vdots & \vdots & & \vdots \\ 0 & * & \ldots & * \end{array}\right]$$

Supongamos que ya han sido determinadas matrices ortogonales $P_1, P_2, \ldots, P_k$ tal que $P_k \ldots P_1 A$ tiene la siguiente forma:

$$P_k \ldots P_1 A = \left[\begin{array}{cccc|ccc} * & * & \ldots & * & * & \ldots & * \\ & * & \ldots & * & * & \ldots & * \\ & & \ddots & \vdots & \vdots & & \\ 0 & & \ldots & * & * & \ldots & * \\ \hline 0 & & \ldots & 0 & * & \ldots & * \\ \vdots & & & \vdots & \vdots & & \vdots \\ 0 & & \ldots & 0 & * & \ldots & * \end{array}\right] = \left[\begin{array}{c|c} R^k & A_{12}^k \\ \hline 0 & A_{22}^k \end{array}\right]$$

donde $R^k \in \mathbb{R}^{k\times k}$ es una matriz triangular superior. Sea $k \leq n+1$, de otro modo $P_k \ldots P_1 A$ tendría la forma deseada. Luego, se determina una matriz ortogonal $P_{k+1} \in \mathbb{R}^{(m-k)\times(m-k)}$ tal que la primera columna de $P_{k+1}A_{22}^k$ sea un múltiplo del primer vector canónico de $\mathbb{R}^{m-k}$ ($P_{k+1}A_{22}^k = \alpha(1, 0, \ldots, 0)^t$). Se define

$$P_{k+1} := \left[\begin{array}{c|c} I^k & 0 \\ \hline 0 & P_{k+1} \end{array}\right]$$

se cumple que $P_{k+1} \in \mathbb{R}^{m\times m}$ es ortogonal (¡verificar!). También se cumple:

$$P_{k+1}P_k \ldots P_1 A = \left[\begin{array}{c|c} R^k & A_{12}^k \\ \hline 0 & P_{k+1}A_{22}^k \end{array}\right] = \left[\begin{array}{c|c} R^{k+1} & A_{12}^{k+1} \\ \hline 0 & A_{22}^{k+1} \end{array}\right],$$

donde $\mathbb{R}^{k+1}$ es una matriz triangular superior.
Se debe notar que las primeras k filas no cambian por la multiplicación de $P_k \ldots P_1 A$ con P_{k+1} por su izquierda.

Definición. *Sea $u \in \mathbb{R}^n \setminus \{0\}$. Una matriz $P \in \mathbb{R}^{n\times n}$ de la forma*

$$P = I - \frac{2uu^t}{u^t u}$$

es denominada matriz de Householder.

Observación. Se cumple que la matriz de Householder es simétrica y ortogonal. En efecto, la simetría se sigue de

$$P^t = \left(I - \frac{2uu^t}{u^t u}\right)^t = I^t - \frac{2(u^t)^t u^t}{u^t u} = I - \frac{2uu^t}{u^t u} = P,$$

mientras que la ortogonalidad se sigue del hecho que

$$PP^t = \left(I - \frac{2uu^t}{u^t u}\right)\left(I - \frac{2uu^t}{u^t u}\right) = I - \frac{4uu^t}{u^t u} + \frac{4(uu^t)(uu^t)}{(u^t u)^2} = I - \frac{4uu^t}{u^t u} + \frac{4u(u^t u)u^t}{(u^t u)^2} = I.$$

Ahora bien, consideremos

$$\operatorname{sign}(x) = \begin{cases} 1, & x \geq 0 \\ -1, & x < 0 \end{cases}$$

Lema 3.19. *Sea $x \in \mathbb{R}^n \setminus \{0\}$. Definiendo $u := x + \operatorname{sign}(x_1)\|x\|_2 e_1$, se obtiene por*

$$P = I - \frac{2uu^t}{u^t u} = I - \beta uu^t \quad \text{con} \quad \beta = \frac{2}{u^t u} = \frac{1}{\|x\|_2\big(\|x\|_2 + |x_1|\big)},$$

una matriz de Householder con

$$Px = -\operatorname{sign}(x_1)\|x\|_2 e_1 = (*, 0, \ldots, 0)^t.$$

DEMOSTRACIÓN.

$$\begin{aligned} u^t u &= \big(x^t + \operatorname{sign}(x_1)\|x\|_2 e_1^t\big)\big(x + \operatorname{sign}(x_1)\|x\|_2 e_1\big) \\ &= \|x\|_2^2 + \operatorname{sign}(x_1)\|x\|_2 x_1 + x_1 \operatorname{sign}(x_1)\|x\|_2 + \operatorname{sign}(x_1)^2\|x\|_2^2 \\ &= 2\|x\|_2^2 + 2|x_1|\|x\|_2 = 2\|x\|_2\big(\|x\|_2 + |x_1|\big) \end{aligned}$$

lo cual implica que $\beta = \dfrac{2}{u^t u} = \dfrac{1}{\|x\|_2(\|x\|_2 + |x_1|)}$

$$\begin{aligned} Px &= P\big(u - \operatorname{sign}(x_1)\|x\|_2 e_1\big) = Pu - \operatorname{sign}(x_1)\|x\|_2 Pe_1 \\ &= \Big(I - \frac{2uu^t}{u^t u}\Big)u - \operatorname{sign}(x_1)\|x\|_2(I - \beta uu^t)e_1 \\ &= u - \frac{2uu^t u}{u^t u} - \operatorname{sign}(x_1)\|x\|_2 e_1 + \operatorname{sign}(x_1)\|x\|_2 \beta uu^t e_1 \\ &= -u - \operatorname{sign}(x_1)\|x\|_2 e_1 + \beta u_1 \operatorname{sign}(x_1)\|x\|_2 u \\ &= -u - \operatorname{sign}(x_1)\|x\|_2 e_1 + u\frac{(x_1 + \operatorname{sign}(x_1)\|x\|_2)}{\|x\|_2\big(\|x\|_2 + |x_1|\big)} \operatorname{sign}(x_1)\|x\|_2 \\ &= -\operatorname{sign}(x_1)\|x\|_2 e_1. \end{aligned}$$

□

Se obtiene el siguiente algoritmo:

Entrada: matriz $A = (a_{ij}) \in \mathbb{R}^{m\times n}$, $m \geq n$	
Para $k = 1, \ldots,$ mín$\{n, m-1\}$	
	Calcular una matriz $(m-k+1)\times(m-k+1)$ de Householder con $P_k(a_{kk}, \ldots, a_{mk})^t = (r_k, 0, \ldots, 0)^t$
	Hacer $P_k := diag(I_{k-1}, P_k)$
	Calcular $A := P_k A$
Salida: matriz transformada A a una matriz R triangular superior	

De esta manera, la matriz A se transforma en mín$\{n, m-1\}$ pasos en una matriz triangular.
Definiendo $Q := P_1, \ldots, P_n$ se ha encontrado la factorización QR.
Evitando un overflow y un underflow: Es conveniente primero calcular $y := x/\|x\|_\infty$ y después $u := y + \operatorname{sign}(y_1)\|y\|_2 e_1$. La matriz de Householder correspondiente será

$$P := I - \beta uu^t \quad \text{con} \quad \beta := \frac{1}{\|y\|_2\big(\|y\|_2 + |y_1|\big)}.$$

Al solucionar un sistema de ecuaciones lineales (mediante el siguiente algoritmo) no se requiere almacenar $Q := P_1 \ldots P_n$. Sin embargo se pueden almacenar los datos importantes para P_k, $u_k = (u_{kk}, \ldots, u_{mk})^t$ y β_k de la siguiente manera:

$$A := \begin{bmatrix} u_{11} & a_{12} & \ldots & a_{1n} \\ u_{21} & u_{22} & \ldots & a_{2n} \\ \vdots & & \ddots & \vdots \\ u_{n1} & u_{n2} & \ldots & u_{nn} \\ \vdots & & & \vdots \\ u_{m1} & u_{m2} & \ldots & u_{mn} \end{bmatrix}, \quad r = \begin{bmatrix} a_{11} \\ \vdots \\ a_{nn} \end{bmatrix}, \quad \beta = \begin{bmatrix} \beta_1 \\ \vdots \\ \beta_n \end{bmatrix}$$

La implementación del algoritmo para el k-ésimo paso para el cálculo de $\tilde{P}_k = I_{m-k+1} - \beta_k u_k u_k^t$, donde

$$u_k := (u_{kk}, \ldots, u_{mk})^t, \qquad \beta_k := \frac{2}{u_k^t u_k}$$

tal que

$$\tilde{P}_k a_k = (r_k, 0, \ldots, 0)^t \text{ con } a_k = (a_{kk}, \ldots, a_{mk})^t$$

es la siguiente:

Algoritmo 5 Algoritmo de transformación de Householder

Entrada: Matriz $A \in \mathbb{R}^{m\times n}$
Salida: Matriz R triangular superior y las matrices de reflexión de Householder

Calcular $\|a_k\|_\infty = \max_{i=k,\dots,n} |a_{ik}|$
$\alpha := 0$
Para $i = k, \dots, n$ **hacer**
    $u_{ik} := \frac{a_{ik}}{\|a_k\|_\infty}$
    $\alpha := \alpha + u_{ik}^2$
Fin Para
$\alpha := \sqrt{\alpha}$
$\beta := \frac{1}{\alpha(\alpha+|u_{kk}|)}$
$u_{kk} := u_{kk} + \operatorname{sign}(a_{kk})\alpha$
Actualizar $A := P_k A$ (se eliminan las entradas por debajo de la diagonal en la columna k)
$a_{kk} := -\operatorname{sign}(a_{kk})\|a_k\|_\infty \alpha$
Para $i = k+1, \dots, m$ **hacer**
    $a_{ik} := 0$
Fin Para
Para $j = k+1, \dots, n$ **hacer**
    $s := \beta \sum_{i=k}^{m} u_{ik} a_{ij}$
    Para $i = k, \dots, m$ **hacer**
        $a_{ij} := a_{ij} - s \cdot u_{ik}$
    Fin Para
Fin Para

6.2. Factorización QR de Givens. Sea $A = (a_{ij}) \in \mathbb{R}^{m\times n}$, $m \geq n$. Para obtener la factorización QR de A mediante el método de Givens, se multiplica por la izquierda a A sucesivamente por *rotaciones de Givens*, que son matrices $m \times m$ de la forma

$$
G_{ik} := \begin{bmatrix}
1 & & 0 & & & & & & \\
& \ddots & & \vdots & & 0 & \vdots & & 0 \\
0 & & 1 & & & & & & \\
& \cdots & & C & & \cdots & S & & \cdots \\
& & & & 1 & & & & \\
& 0 & & \vdots & & \ddots & \vdots & & 0 \\
& & & & & & 1 & & \\
& \cdots & & -S & & \cdots & C & & \cdots \\
& & & & & & & 1 & \\
& 0 & & \vdots & & 0 & \vdots & & \ddots \\
& & & & & & & & & 1
\end{bmatrix}
\begin{matrix} \\ \\ \\ \leftarrow i \\ \\ \\ \\ \leftarrow k \\ \\ \\ \\ \end{matrix}
$$

$$
\begin{matrix} \\ \\ \\ \uparrow \\ i \end{matrix}
\qquad
\begin{matrix} \\ \\ \\ \uparrow \\ k \end{matrix}
$$

con $C^2 + S^2 = 1$, $C \neq 0$, $1 \leq i \leq k \leq m$. Una rotación de Givens se distingue de la matriz identidad solamente por los elementos de las posiciones (i,i), (i,k), (k,i) y (k,k).

Las rotaciones de Givens gozan de las siguientes propiedades:

a) Los G_{ik} son ortogonales:

$$\begin{bmatrix} C & S \\ -S & C \end{bmatrix}^t \begin{bmatrix} C & S \\ -S & C \end{bmatrix} = \begin{bmatrix} C & -S \\ S & C \end{bmatrix} \begin{bmatrix} C & S \\ -S & C \end{bmatrix}$$
$$= \begin{bmatrix} C^2+S^2 & 0 \\ 0 & C^2+S^2 \end{bmatrix}$$
$$= \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

b) Multiplicación por un vector:
Sea $x \in \mathbb{R}^m$, $y := G_{ik}x$, entonces

$$y = \begin{bmatrix} x_1 \\ \vdots \\ x_{i-1} \\ Cx_i + Sx_k \\ x_{i+1} \\ \vdots \\ x_{k-1} \\ -Sx_i + Cx_k \\ \vdots \\ x_m \end{bmatrix} \begin{matrix} \\ \\ \\ \leftarrow i \\ \\ \\ \\ \leftarrow k \\ \\ \\ \end{matrix} = \begin{cases} Cx_i + Sx_k, & \text{para } j = i \\ -Sx_i + Cx_k, & \text{para } j = k \\ x_j, & \text{para } j \neq i, k \end{cases}$$

NOTA. $C = \cos(\theta)$, $S = \operatorname{sen}(\theta)$, θ: ángulo de rotación;

$$\begin{bmatrix} \cos(\theta) & \operatorname{sen}(\theta) \\ -\operatorname{sen}(\theta) & \cos(\theta) \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} x\cos(\theta) + y\operatorname{sen}(\theta) \\ -x\operatorname{sen}(\theta) + y\cos(\theta) \end{bmatrix}$$

Multiplicando una matriz $A \in \mathbb{R}^{m\times n}$ por la izquierda con una rotación de Givens G_{ik}, se obtiene solamente un cambio de la i-ésima y k-ésima filas. Las nuevas filas son una combinación lineal de las antiguas y están dadas por

$$\begin{aligned} (G_{ik}A)_{ij} &= \quad C\, a_{ij} + S\, a_{kj} \\ (G_{ik}A)_{kj} &= -S\, a_{ij} + C\, a_{kj}, \qquad j = 1, 2, \ldots, n \end{aligned}$$

En particular, si $a_{ij} = a_{kj} = 0$ entonces $(G_{ik}A)_{ij} = 0 = (G_{ik}A)_{kj}$.

Mediante la factorización QR de Givens, para cualquier $x \in \mathbb{R}^n$, $1 \leq i < k \leq m$ se puede encontrar una rotación de Givens tal que $(G_{ik}x)_k = 0$. Entonces se puede poner la k-ésima componente de $y := G_{ik}x$ a cero dejando todas las demás con la i-ésima componente sin cambio. Para esto, se define, para $(\alpha, \beta) \in \mathbb{R}^2$, $\gamma \in \mathbb{R}$ y $C^2 + S^2 = 1$ tales que

$$\begin{matrix} i \to \\ k \to \end{matrix} \begin{bmatrix} C & S \\ -S & C \end{bmatrix} \begin{bmatrix} \alpha \\ \beta \end{bmatrix} = \begin{bmatrix} \gamma \\ 0 \end{bmatrix}$$

Por consiguiente, mediante las rotaciones de Givens se pueden cambiar a cero los elementos que se encuentran debajo de la diagonal. Se debe tener en cuenta que los elementos que ya son iguales a cero se quedan así.

EJEMPLO 3.5. En el siguiente ejemplo tipo de una matriz 4×3, avanzando por columnas, escribiremos, en cada operación

$\circ$: elemento no cambiado por la transformación.
$*$: elemento cambiado por la transformación.

Algoritmo 6 Cálculo de rotación y escala

Entrada: $\alpha, \beta \in \mathbb{R}$
if $\beta = 0$ **then**
  $C \leftarrow 1$
  $S \leftarrow 0$
  $\gamma \leftarrow \alpha$
else
  if $|\beta| \geq |\alpha|$ **then**
    $t \leftarrow \alpha/\beta$
    $S \leftarrow 1/\sqrt{1+t^2}$
    $C \leftarrow St$
    $\gamma \leftarrow \beta\sqrt{1+t^2}$
  else
    $t \leftarrow \beta/\alpha$
    $C \leftarrow 1/\sqrt{1+t^2}$
    $S \leftarrow Ct$
    $\gamma \leftarrow \alpha\sqrt{1+t^2}$
  Fin if
Fin if
Salida: $\mathrm{rot}(\alpha, \beta) := (C, S, \gamma)$
Propiedad: $C^2 + S^2 = 1$ y

$$\begin{bmatrix} C & S \\ -S & C \end{bmatrix} \begin{bmatrix} \alpha \\ \beta \end{bmatrix} = \begin{bmatrix} \gamma \\ 0 \end{bmatrix}$$

$$A := \begin{bmatrix} \circ & \circ & \circ \\ \circ & \circ & \circ \\ \circ & \circ & \circ \\ \circ & \circ & \circ \end{bmatrix} \underset{(1,2)}{\overset{G_{12}}{\rightarrow}} \begin{bmatrix} * & * & * \\ 0 & * & * \\ \circ & \circ & \circ \\ \circ & \circ & \circ \end{bmatrix} \underset{(1,3)}{\overset{G_{13}}{\rightarrow}} \begin{bmatrix} * & * & * \\ 0 & \circ & \circ \\ 0 & * & * \\ \circ & \circ & \circ \end{bmatrix}$$

$$\underset{(1,4)}{\overset{G_{14}}{\rightarrow}} \begin{bmatrix} * & * & * \\ 0 & \circ & \circ \\ 0 & \circ & \circ \\ 0 & * & * \end{bmatrix} \underset{(2,3)}{\overset{G_{23}}{\rightarrow}} \begin{bmatrix} \circ & \circ & \circ \\ 0 & * & * \\ 0 & 0 & * \\ 0 & \circ & \circ \end{bmatrix} \underset{(2,4)}{\overset{G_{24}}{\rightarrow}} \begin{bmatrix} 0 & \circ & \circ \\ 0 & * & * \\ 0 & 0 & \circ \\ 0 & 0 & * \end{bmatrix} \underset{(3,4)}{\overset{G_{34}}{\rightarrow}} \begin{bmatrix} \circ & \circ & \circ \\ 0 & \circ & \circ \\ 0 & 0 & * \\ 0 & 0 & 0 \end{bmatrix}$$

Esto es, dada $A \in \mathbb{R}^{m \times n}$, aplicar sucesivamente $(1,2), (1,3), \ldots, (1,m), (2,3), \ldots, (2,m)$, $\ldots$, $\min(\{n, m-1\}, m)$.

Se obtiene el siguiente algoritmo:

Nota. Para el método de Givens se requieren más multiplicaciones/divisiones que para el método de Householder. Sin embargo, para matrices de una estructura especial, como por ejemplo matrices con muchos elementos nulos, el método de Givens es mejor. Además existe un método rápido de Givens.

7. Ejemplos

7.1. Cálculo de la factorización $A = QR$ por el algoritmo de Householder. Consideramos la matriz

$$A = \begin{bmatrix} 63{,}0000 & 41{,}0000 & -88{,}0000 \\ 42{,}0000 & 60{,}0000 & 51{,}0000 \\ 0{,}0000 & -28{,}0000 & 56{,}0000 \\ 126{,}0000 & 82{,}0000 & -71{,}0000 \end{bmatrix} \tag{7}$$

Algoritmo 7 Algoritmo de Givens para la descomposición QR

Entrada: Matriz $A \in \mathbb{R}^{m\times n}$, con $m \geq n$
Salida: Matriz R triangular superior y matriz ortogonal Q

Para $i = 1, 2, \ldots, \text{mín}(n, m-1)$ **hacer**
  Para $k = i+1, \ldots, m$ **hacer**
    $(C, S, a_{ii}) := \text{rot}(a_{ii}, a_{ki})$
    $a_{ki} := 0$
    Para $j = i+1, \ldots, n$ **hacer**

$$\begin{bmatrix} a_{ij} \\ a_{kj} \end{bmatrix} := \begin{bmatrix} C & S \\ -S & C \end{bmatrix} \begin{bmatrix} a_{ij} \\ a_{kj} \end{bmatrix}$$

    Fin Para
  Fin Para
Fin Para
Devolver $Q^tA = R$, donde Q es ortogonal y R tiene la forma:

$$R = \begin{bmatrix} R_1 \\ 0 \end{bmatrix} \begin{matrix} \leftarrow n \\ \leftarrow m-n \end{matrix}$$

donde R_1 es triangular superior.

Para la reducción de la matriz A a una forma triangular, realizamos 3 pasos sucesivos para reducir sus columnas.

En el primer paso, reducimos la columna $x_1 = (63{,}0000, 42{,}0000, 0{,}0000, 126{,}0000)^t$, definiendo

$$u_1 = x_1 + \text{sign}(x_{1(1)})\|x_1\|_2 e_1 = (210{,}0000, 42{,}0000, 0{,}0000, 126{,}0000)^t$$

y luego la matriz de Householder

$$\tilde{P}_1 = I - \frac{2u_1u_1^t}{u_1^tu_1} = \begin{bmatrix} -0{,}4286 & -0{,}2857 & 0{,}0000 & -0{,}8571 \\ -0{,}2857 & 0{,}9429 & 0{,}0000 & -0{,}1714 \\ 0{,}0000 & 0{,}0000 & 1{,}0000 & 0{,}0000 \\ -0{,}8571 & -0{,}1714 & 0{,}0000 & 0{,}4857 \end{bmatrix}$$

$$P_1 = \begin{bmatrix} -0{,}4286 & -0{,}2857 & 0{,}0000 & -0{,}8571 \\ -0{,}2857 & 0{,}9429 & 0{,}0000 & -0{,}1714 \\ 0{,}0000 & 0{,}0000 & 1{,}0000 & 0{,}0000 \\ -0{,}8571 & -0{,}1714 & 0{,}0000 & 0{,}4857 \end{bmatrix}$$

$$P_1A = \begin{bmatrix} -147{,}0000 & -105{,}0000 & 84{,}0000 \\ 0{,}0000 & 30{,}8000 & 85{,}4000 \\ 0{,}0000 & -28{,}0000 & 56{,}0000 \\ 0{,}0000 & -5{,}6000 & 32{,}2000 \end{bmatrix}$$

Para reducir la segunda columna, tomamos $x_2 = (30{,}8000, -28{,}0000, -5{,}6000)^t$ y luego

$$u_2 = x_2 + \text{sign}(x_{2(1)})\|x_2\|_2 e_1 = (72{,}8000, -28{,}0000, -5{,}6000)^t,$$

para luego calcular

$$\tilde{P}_2 = I - \frac{2u_2u_2^t}{u_2^tu_2} = \begin{bmatrix} -0{,}7333 & 0{,}6667 & 0{,}1333 \\ 0{,}6667 & 0{,}7436 & -0{,}0513 \\ 0{,}1333 & -0{,}0513 & 0{,}9897 \end{bmatrix}$$

$$P_2 = \begin{bmatrix} 1{,}0000 & 0{,}0000 & 0{,}0000 & 0{,}0000 \\ 0{,}0000 & -0{,}7333 & 0{,}6667 & 0{,}1333 \\ 0{,}0000 & 0{,}6667 & 0{,}7436 & -0{,}0513 \\ 0{,}0000 & 0{,}1333 & -0{,}0513 & 0{,}9897 \end{bmatrix}$$

Ahora

$$P_2P_1A = \begin{bmatrix} -147{,}0000 & -105{,}0000 & 84{,}0000 \\ 0{,}0000 & -42{,}0000 & -21{,}0000 \\ -0{,}0000 & 0{,}0000 & 96{,}9231 \\ 0{,}0000 & 0{,}0000 & 40{,}3846 \end{bmatrix}.$$

Finalmente, reducimos la tercera columna tomando $x_3 = (96{,}9231, 40{,}3846)^t$,

$$u_3 = x_3 + \text{sign}(x_{3(1)})\|x_3\|_2 e_1 = (201{,}9231, 40{,}3846)^t$$

y calculando

$$\tilde{P}_3 = I - \frac{2u_3u_3^t}{u_3^tu_3} = \begin{bmatrix} -0{,}9231 & -0{,}3846 \\ -0{,}3846 & 0{,}9231 \end{bmatrix}$$

$$P_3 = \begin{bmatrix} 1{,}0000 & 0{,}0000 & 0{,}0000 & 0{,}0000 \\ 0{,}0000 & 1{,}0000 & 0{,}0000 & 0{,}0000 \\ 0{,}0000 & 0{,}0000 & -0{,}9231 & -0{,}3846 \\ 0{,}0000 & 0{,}0000 & -0{,}3846 & 0{,}9231 \end{bmatrix}$$

Luego, las matrices triangular superior R y ortogonal Q tales que $A = QR$ son

$$R = P_3P_2P_1A = \begin{bmatrix} -147{,}0000 & -105{,}0000 & 84{,}0000 \\ 0{,}0000 & -42{,}0000 & -21{,}0000 \\ -0{,}0000 & -0{,}0000 & -105{,}0000 \\ 0{,}0000 & -0{,}0000 & -0{,}0000 \end{bmatrix}$$

$$Q = P_1P_2P_3 = \begin{bmatrix} -0{,}4286 & 0{,}0952 & 0{,}4762 & -0{,}7619 \\ -0{,}2857 & -0{,}7143 & -0{,}5714 & -0{,}2857 \\ 0{,}0000 & 0{,}6667 & -0{,}6667 & -0{,}3333 \\ -0{,}8571 & 0{,}1905 & -0{,}0476 & 0{,}4762 \end{bmatrix}$$

7.2. Cálculo de la factorización $A = QR$ por rotaciones de Givens. Consideramos la misma matriz A del ejemplo anterior, definida por (7). Siguiendo los pasos del ejemplo (3.5):

Definimos

$$(C, S, a_{11}) = \text{rot}(a_{11}, a_{21}) = \text{rot}(63{,}0000, 42{,}0000) = (0{,}8321, 0{,}5547, 75{,}717),$$

y

$$G_{12} = \begin{bmatrix} 0{,}8321 & 0{,}5547 & 0{,}0000 & 0{,}0000 \\ -0{,}5547 & 0{,}8321 & 0{,}0000 & 0{,}0000 \\ 0{,}0000 & 0{,}0000 & 1{,}0000 & 0{,}0000 \\ 0{,}0000 & 0{,}0000 & 0{,}0000 & 1{,}0000 \end{bmatrix}$$

$$G_{12}A = \begin{bmatrix} 75{,}7166 & 67{,}3961 & -44{,}9307 \\ 0{,}0000 & 27{,}1803 & 91{,}2482 \\ 0{,}0000 & -28{,}0000 & 56{,}0000 \\ 126{,}0000 & 82{,}0000 & -71{,}0000 \end{bmatrix}$$

Ahora

$$(C, S, a_{11}) = \text{rot}(a_{11}, a_{31}) = \text{rot}(75{,}7166, 0{,}0000) = (1{,}0000, 0{,}0000, 75{,}717)$$

y

$$G_{13} = \begin{bmatrix} 1{,}0000 & 0{,}0000 & 0{,}0000 & 0{,}0000 \\ 0{,}0000 & 1{,}0000 & 0{,}0000 & 0{,}0000 \\ 0{,}0000 & 0{,}0000 & 1{,}0000 & 0{,}0000 \\ 0{,}0000 & 0{,}0000 & 0{,}0000 & 1{,}0000 \end{bmatrix}$$

$$G_{13}G_{12}A = \begin{bmatrix} 75{,}7166 & 67{,}3961 & -44{,}9307 \\ 0{,}0000 & 27{,}1803 & 91{,}2482 \\ 0{,}0000 & -28{,}0000 & 56{,}0000 \\ 126{,}0000 & 82{,}0000 & -71{,}0000 \end{bmatrix}$$

Para

$$(C, S, a_{11}) = \text{rot}(a_{11}, a_{41}) = \text{rot}(75{,}7166, 126{,}0000) = (0{,}5151, 0{,}8571, 147{,}000),$$

$$G_{14} = \begin{bmatrix} 0{,}5151 & 0{,}0000 & 0{,}0000 & 0{,}8571 \\ 0{,}0000 & 1{,}0000 & 0{,}0000 & 0{,}0000 \\ 0{,}0000 & 0{,}0000 & 1{,}0000 & 0{,}0000 \\ -0{,}8571 & 0{,}0000 & 0{,}0000 & 0{,}5151 \end{bmatrix}$$

$$G_{14}G_{13}G_{12}A = \begin{bmatrix} 147{,}0000 & 105{,}0000 & -84{,}0000 \\ 0{,}0000 & 27{,}1803 & 91{,}2482 \\ 0{,}0000 & -28{,}0000 & 56{,}0000 \\ 0{,}0000 & -15{,}5316 & 1{,}9415 \end{bmatrix}$$

Para

$$(C, S, a_{11}) = \text{rot}(a_{22}, a_{32}) = \text{rot}(27{,}1803, -28{,}0000) = (-0{,}6965, 0{,}7175, -39{,}023),$$

$$G_{23} = \begin{bmatrix} 1{,}0000 & 0{,}0000 & 0{,}0000 & 0{,}0000 \\ 0{,}0000 & -0{,}6965 & 0{,}7175 & 0{,}0000 \\ 0{,}0000 & -0{,}7175 & -0{,}6965 & 0{,}0000 \\ 0{,}0000 & 0{,}0000 & 0{,}0000 & 1{,}0000 \end{bmatrix}$$

$$G_{23}G_{14}G_{13}G_{12}A = \begin{bmatrix} 147{,}0000 & 105{,}0000 & -84{,}0000 \\ 0{,}0000 & -39{,}0227 & -23{,}3750 \\ 0{,}0000 & 0{,}0000 & -104{,}4789 \\ 0{,}0000 & -15{,}5316 & 1{,}9415 \end{bmatrix}$$

Para

$$(C, S, a_{22}) = \text{rot}(a_{22}, a_{42}) = \text{rot}(-39{,}0227, -15{,}5316) = (0{,}9291, 0{,}3698, -42{,}000),$$

$$G_{24} = \begin{bmatrix} 1{,}0000 & 0{,}0000 & 0{,}0000 & 0{,}0000 \\ 0{,}0000 & 0{,}9291 & 0{,}0000 & 0{,}3698 \\ 0{,}0000 & 0{,}0000 & 1{,}0000 & 0{,}0000 \\ 0{,}0000 & -0{,}3698 & 0{,}0000 & 0{,}9291 \end{bmatrix}$$

$$G_{24}G_{23}G_{14}G_{13}G_{12}A = \begin{bmatrix} 147{,}0000 & 105{,}0000 & -84{,}0000 \\ 0{,}0000 & -42{,}0000 & -21{,}0000 \\ 0{,}0000 & 0{,}0000 & -104{,}4789 \\ 0{,}0000 & 0{,}0000 & 10{,}4479 \end{bmatrix}$$

Y para

$$(C, S, a_{11}) = \text{rot}(a_{33}, a_{43}) = \text{rot}(-104{,}4789, 10{,}4479) = (0{,}9950, -0{,}0995, -105{,}000),$$

$$G_{34} = \begin{bmatrix} 1{,}0000 & 0{,}0000 & 0{,}0000 & 0{,}0000 \\ 0{,}0000 & 1{,}0000 & 0{,}0000 & 0{,}0000 \\ 0{,}0000 & 0{,}0000 & 0{,}9950 & -0{,}0995 \\ 0{,}0000 & 0{,}0000 & 0{,}0995 & 0{,}9950 \end{bmatrix}$$

Finalmente

$$R = G_{34}G_{24}G_{23}G_{14}G_{13}G_{12}A = \begin{bmatrix} 147{,}0000 & 105{,}0000 & -84{,}0000 \\ 0{,}0000 & -42{,}0000 & -21{,}0000 \\ 0{,}0000 & 0{,}0000 & -105{,}0000 \\ 0{,}0000 & 0{,}0000 & 0{,}0000 \end{bmatrix}$$

y

$$Q = \begin{bmatrix} 0{,}4286 & 0{,}0952 & 0{,}4762 & -0{,}7619 \\ 0{,}2857 & -0{,}7143 & -0{,}5714 & -0{,}2857 \\ 0{,}0000 & 0{,}6667 & -0{,}6667 & -0{,}3333 \\ 0{,}8571 & 0{,}1905 & -0{,}0476 & 0{,}4762 \end{bmatrix}.$$

7.3. Cálculo de $A = LL^t$ por el algoritmo de Cholesky. Consideremos

$$A = \begin{bmatrix} 136{,}0000 & 90{,}8600 & 0{,}0000 & 0{,}0000 \\ 90{,}8600 & 98{,}8100 & -67{,}5900 & 0{,}0000 \\ 0{,}0000 & -67{,}5900 & 132{,}0100 & 42{,}2600 \\ 0{,}0000 & 0{,}0000 & 42{,}2600 & 177{,}1700 \end{bmatrix}$$

La factorización de Cholesky $A = LL^t$ con $L = (l_{ij}) \in \mathbb{R}^{4\times 4}$ se realiza de manera directa por las fórmulas obtenidas, teniendo en cuenta simplemente el orden de cálculo:

$$\begin{aligned} l_{11} &= (136{,}0000 - 0{,}0000)^{1/2} = 11{,}6619 \\ l_{21} &= (90{,}8600 - 0{,}0000)/11{,}6619 = 7{,}7912 \\ l_{31} &= (0{,}0000 - 0{,}0000)/11{,}6619 = 0{,}0000 \\ l_{41} &= (0{,}0000 - 0{,}0000)/11{,}6619 = 0{,}0000 \\ l_{22} &= (98{,}8100 - 60{,}7025)^{1/2} = 6{,}1731 \\ l_{32} &= (-67{,}5900 - 0{,}0000)/6{,}1731 = -10{,}9491 \\ l_{42} &= (0{,}0000 - 0{,}0000)/6{,}1731 = 0{,}0000 \\ l_{33} &= (132{,}0100 - 119{,}8821)^{1/2} = 3{,}4825 \\ l_{43} &= (42{,}2600 - 0{,}0000)/3{,}4825 = 12{,}1349 \\ l_{44} &= (177{,}1700 - 147{,}2563)^{1/2} = 5{,}4693 \end{aligned}$$

El resto de los elementos de L (por encima de la diagonal) es cero:

$$l_{12} = l_{13} = l_{14} = l_{23} = l_{24} = l_{34} = 0.$$

Luego

$$L = \begin{bmatrix} 11{,}6619 & 0{,}0000 & 0{,}0000 & 0{,}0000 \\ 7{,}7912 & 6{,}1731 & 0{,}0000 & 0{,}0000 \\ 0{,}0000 & -10{,}9491 & 3{,}4825 & 0{,}0000 \\ 0{,}0000 & 0{,}0000 & 12{,}1349 & 5{,}4693 \end{bmatrix}.$$

7.4. Factorización $PA = LU$ con pivoteo de filas escaladas. Sea

$$A = \begin{bmatrix} 30{,}0000 & 9{,}0000 & 77{,}0000 \\ 20{,}0000 & 6{,}0000 & 80{,}0000 \\ 27{,}0000 & 11{,}0000 & 98{,}0000 \end{bmatrix}$$

Realizaremos la factorización LU de A con pivoteo de filas escaladas: en lugar de elegir el pivote según el criterio (p. 29)

$$|a_{r1}| = \text{máx}\{|a_{11}|, |a_{21}|, \ldots, |a_{n1}|\},$$

elegimos el índice r tal que

$$\frac{|a_{r1}|}{s_r} = \text{máx}\Big\{\frac{|a_{11}|}{s_1}, \frac{|a_{21}|}{s_2}, \ldots, \frac{|a_{n1}|}{s_n}\Big\},$$

donde $s_i = |a_{i1}| + |a_{i2}| + \cdots + |a_{in}|$ para $i = 1, 2, \ldots, n$. Puesto que estos útimos números corresponden a las normas de las filas (mediante la norma $\|\cdot\|_1$), la elección del pivote se realiza, de manera equivalente, en una matriz cuyas filas han sido *escaladas* normalizándolas.

Los pasos del algoritmo sólo implican el intercambio de la segunda y tercera filas en una de las etapas, obteniendo el vector de permutaciones $p = (1, 3, 2)$, y las matrices

$$L = \begin{bmatrix} 1{,}0000 & 0{,}0000 & 0{,}0000 \\ 0{,}9000 & 1{,}0000 & 0{,}0000 \\ 0{,}6667 & -0{,}0000 & 1{,}0000 \end{bmatrix}$$

$$U = \begin{bmatrix} 30{,}0000 & 9{,}0000 & 77{,}0000 \\ 0{,}0000 & 2{,}9000 & 28{,}7000 \\ 0{,}0000 & 0{,}0000 & 28{,}6667 \end{bmatrix}$$

$$P = \begin{bmatrix} 1{,}0000 & 0{,}0000 & 0{,}0000 \\ 0{,}0000 & 0{,}0000 & 1{,}0000 \\ 0{,}0000 & 1{,}0000 & 0{,}0000 \end{bmatrix}$$

Finalmente

$$LU = PA = \begin{bmatrix} 30{,}0000 & 9{,}0000 & 77{,}0000 \\ 27{,}0000 & 11{,}0000 & 98{,}0000 \\ 20{,}0000 & 6{,}0000 & 80{,}0000 \end{bmatrix}.$$

8. Ejercicios

1. El siguiente ejercicio tiene como objetivo demostrar la desigualdad de Minkowsky

$$\|x + y\|_p \leq \|x\|_p + \|y\|_p,$$

donde $x = (x_1, \ldots, x_n), y = (y_1, \ldots, y_n) \in \mathbb{K}$, $p \geq 1$.

a) Sea $0 < \lambda < 1$. Definiendo

$$g(t) = \lambda t + (1 - \lambda) - t^\lambda,$$

demuestre que $g(t)$ posee un mínimo en $t = 1$. Concluya que $f(t) \geq 0$ para $t \geq 0$.

b) Usando el ítem anterior, demuestre que para $0 < \lambda < 1$ y $a, b > 0$, se tiene

$$a^\lambda b^{1-\lambda} \leq \lambda a + (1 - \lambda)b.$$

c) Sea $q \geq 1$ tal que

$$\frac{1}{p} + \frac{1}{q} = 1.$$

Para cada $1 \leq i \leq n$, defina

$$a = \frac{|x_i|^p}{\|x\|_p^p}, \quad b = \frac{|y_i|^q}{\|y\|_q^q}.$$

Usando la desigualdad anterior con $\lambda = 1/p$

$$\frac{|x_i|}{\|x\|_p} \cdot \frac{|y_i|}{\|y\|_q} \leq \frac{1}{p}\frac{|x_i|^p}{\|x\|_p^p} + \frac{1}{q}\frac{|y_i|^q}{\|x\|_q^q}.$$

y sumando, obtenga la desigualdad de Hölder:

$$\sum_{i=1}^{n} |x_i y_i| \leq \|x\|_p \|y\|_q.$$

d) A partir del hecho que

$$\|x+y\|_p^p \leq \sum_{i=1}^{n} |x_i||x_i+y_i|^{p-1} + \sum_{i=1}^{n} |y_i||x_i+y_i|^{p-1}$$

y con la desigualdad de Hölder, pruebe que

$$\|x+y\|_p^p \leq \|x\|_p \left(\sum_{i=1}^{n} |x_i+y_i|^{(p-1)q} \right)^{1/q} + \|y\|_p \left(\sum_{i=1}^{n} |x_i+y_i|^{(p-1)q} \right)^{1/q}.$$

e) Finalmente, pruebe la desigualdad de Minkowsky.

2. Demuestre que
$$\|A\|_2 \leq \|A\|_F \leq \sqrt{n}\|A\|$$
para toda matriz $A \in \mathbb{C}^{n\times n}$.
3. Caracterice las matrices $A \in \mathbb{R}^{n\times n}$ para las cuales $\|A^2\|_\infty = \|A\|_\infty^2$.
4. ¿Satisfacen las normas subordinadas matriciales la igualdad $\|AB\| = \|BA\|$? Justifique.
5. La norma ℓ_∞ ponderada es una norma en $\mathbb{R}^n$ dada por
$$\|x\| = \max_{1\leq i\leq n} w_i|x_i|,$$
donde $w_1, w_2, \ldots, w_n$ son números positivos prefijados, que reciben el nombre de *pesos*. Demuestre que esta función satisface la definición de norma. ¿Cuál es la norma matricial subordinada?
6. ¿Es necesariamente cierto, para cualquier norma matricial subordinada, que la norma de una matriz de permutación sea uno? Justifique su respuesta.
7. Demuestre que el número de condición $\text{cond}(A)$ se puede expresar mediante la fórmula
$$\text{cond}(A) = \sup_{\|x\|=\|y\|} \frac{\|Ax\|}{\|Ay\|}.$$
8. Dada la matriz
$$A = \begin{bmatrix} 3 & 4 & 5 \\ 5 & 2 & 6 \\ 1 & -54 & 3 \end{bmatrix},$$
calcular
   a) sus normas $\|A\|_1$, $\|A\|_2$,$\|A\|_\infty$, $\|A\|_F$;
   b) sus números de condición $\text{cond}_1(A)$, $\text{cond}_2(A)$, $\text{cond}_\infty(A)$, $\text{cond}_F(A)$;
   c) su factorización LU (con o sin cambios de filas).

   Sug.: `help norm`, `help cond`, `help lu`
9. Programe la resolución de un sistema triangular superior (inferior) no singular. *Sug.:* `help for`, `help sum`
10. Los elementos más grandes en magnitud en una matriz definida positiva aparecen sobre la diagonal y son positivos.
11. Una matriz $A = [a_{ij}]_{1\leq i,j\leq n} \in \mathbb{R}^{n\times n}$ es definida positiva, si y sólo si, los determinantes de las submatrices principales, llamados *menores principales*

$$\begin{vmatrix} a_{11} & a_{12} & \ldots & a_{1n} \\ a_{21} & a_{22} & & a_{2n} \\ \vdots & & \ddots & \vdots \\ a_{n1} & a_{n2} & & a_{nn} \end{vmatrix}$$

son números reales positivos.
Sug.: En la definición de definida positiva, considere $x = (x_1, \ldots, x_k, 0, \ldots, 0)^t$.

12. Si A es invertible y tiene una descomposición LU, entonces todos los menores principales de A son no singulares.
13. Sea $A \in \mathbb{R}^{n\times n}$ definida positiva. Supongamos que se puede realizar eliminación de Gauss sobre A sin cambios de filas. Luego de k pasos de eliminación, A será reducida a la forma

$$A^{(k)} = \begin{bmatrix} A_{11}^{(k)} & A_{12}^{(k)} \\ 0 & A_{22}^{(k)} \end{bmatrix},$$

donde $A_{22}^{(k)} \in \mathbb{R}^{(n-k)\times(n-k)}$. Pruebe por inducción que
   a) $A_{22}^{(k)}$ es definida positiva;
   b) $a_{ii}^{(k)} \leq a_{ii}^{(k-1)}$ para $k \leq i \leq n$, $k = 1, 2, \ldots, n-1$.
14. Una matriz $A = (a_{ij})$ en la que $a_{ij} = 0$ cuando $j > i$ o $j < i - 1$ se llama matriz de Stieltjes. Diseñe un algoritmo eficiente para invertir dicha matriz.
15. Si A es invertible y tiene una descomposición LU, entonces todos los menores principales de A son no principales.
16. Sabemos que si $Ax = b$ y $A\tilde{x} = \tilde{b}$ con $b \neq 0$, entonces

$$\frac{\|x - \tilde{x}\|}{\|x\|} \leq \text{cond}(A)\frac{\|b - \tilde{b}\|}{\|b\|}.$$

Demuestre que para toda matriz no singular A esta desigualdad se vuelve igualdad para algunos vectores b y $\tilde{b} \neq b$.
17. Demuestre que el número de condición $\text{cond}(A)$ puede expresarse mediante la fórmula

$$\text{cond}(A) = \sup_{\|x\|=\|y\|} \frac{\|Ax\|}{\|Ay\|}.$$

18. Demuestre que si existe un polinomio sin término constante $p(x)$, y que satisface

$$\big\|I - p(A)\big\| < 1$$

entonces A es invertible.
19. La eliminación gaussiana con pivoteo total trata tanto las filas como las columnas en un rden distinto del orden natural. Así, en el primer paso, el elemento pivote a_{ij} se elige de tal modo que $|a_{ij}|$ es el valor máximo de toda la matriz. Esto determina que la fila i sea la fila pivote y la columna j sea la columna pivote. Los ceros se producen en la columna j sustrayendo múltiplos de la fila i de las otras filas. Escriba el algoritmo que realiza este proceso. Serán necesarios dos vectores de permutación.
20. Resuelva el siguiente sistema por medio de la eliminación gaussiana con pivoteo total:

$$\begin{aligned} -9x_1 + x_2 + 17x_3 &= 5 \\ 3x_1 + 2x_2 - x_3 &= 9 \\ 6x_1 + 8x_2 + x_3 &= -3. \end{aligned}$$

21. Sabemos que si $Ax = b$ y $A\tilde{x} = \tilde{b}$ con $b \neq 0$, entonces

$$\frac{\|x - \tilde{x}\|}{\|x\|} \leq \text{cond}(A)\frac{\|b - \tilde{b}\|}{\|b\|}.$$

Demuestre que para toda matriz no singular A esta desigualdad se vuelve igualdad para algunos vectores b y $\tilde{b} \neq b$.

22. Si $A \in \mathbb{C}^{n\times n}$ es tal que
$$\rho(I - A^3 + 3A^2 + 5A) < 1,$$
entonces A es invertible.
23. Obtenga la factorización $A = QR$ de la matriz
$$A = \begin{bmatrix} -9 & 1 & 17 \\ 3 & 2 & -1 \\ 6 & 8 & 1 \end{bmatrix}$$
ya sea por el método de Householder o el de Givens. A continuación, resuelva $Ax = b$ donde $b = (44, 4, 25)^t$ con los resultados obtenidos.
24. Una matriz tiene *diagonal dominante* cuando
$$|a_{ii}| > \sum_{\substack{j=1 \\ j\neq i}}^{n} |a_{ij}|, \quad i = 1, \ldots, n.$$
Pruebe que todo sistema lineal con diagonal dominante puede ser resuelto con eliminación gaussiana sin pivoteo.

9. El teorema del punto fijo de Banach

DEFINICIÓN. *Sea $\|\cdot\|$ una norma en $\mathbb{R}^n$. La función $F : D \subset \mathbb{R}^n \to \mathbb{R}^n$ se dice que es continua en el sentido de Lipschitz en D, si existe una constante $L > 0$ tal que*
$$\|F(x) - F(y)\| \leq L\|x - y\|, \qquad \forall x, y \in D.$$
Si $L < 1$ se dice que F es una contracción en D con respecto a $\|\cdot\|$.

TEOREMA 3.20 (Teorema del punto fijo de Banach). *Sea $\|\cdot\|$ una norma en $\mathbb{R}^n$ y*
$F : D \subset \mathbb{R}^n \to \mathbb{R}^n$ con las siguientes propiedades:

1. *$\phi \neq D \subset \mathbb{R}^n$ es cerrado.*
2. *$F(D) \subset D$.*
3. *$\|F(x) - F(y)\| \leq L\|x - y\|, \qquad \forall x, y \in D, \qquad L \in (0, 1)$.*

Entonces:

(a) *La sucesión $\{x^{(k)}\}$ con $x^{(k+1)} := F(x^{(k)})$, $k = 0, 1, 2, \cdots$, converge para todo punto inicial $x^{(0)} \in D$ hacia $x^* \in D$ que es el único punto fijo de F en D.*

(b) $\|x^{(k)} - x^*\| \leq \dfrac{L^k}{1-L}\|x^{(1)} - x^{(0)}\|, \qquad k = 1, 2, \cdots$
(Estimación del error a priori).

(c) $\|x^{(k)} - x^*\| \leq \dfrac{L}{1-L}\|x^{(k)} - x^{(k-1)}\|, \qquad k = 1, 2, \cdots$
(Estimación del error a posteriori).

Demostración.

(a) Como $F(D) \subset D$ y $x^{(0)} \in D$ se cumple que $\{x^{(k)}\} \subset D$. Vamos a probar que $\{x^{(k)}\}$ es una sucesión de Cauchy, es decir, que para cada $\varepsilon > 0$, existe $N(\varepsilon) \in \mathbb{N}$ tal que
$$\|x^{(k)} - x^{(l)}\| < \varepsilon, \qquad \forall k, l \geq N(\varepsilon).$$
Como toda sucesión de Cauchy en $\mathbb{R}^n$ es convergente y siendo $D \subset \mathbb{R}^n$ cerrado, existe $x^* \in D$ como límite de $\{x^{(k)}\}$.

Para $p \in \mathbb{N}$, se cumple

$$\begin{aligned} \|x^{(p+1)} - x^{(p)}\| &= \|F(x^{(p)}) - F(x^{(p-1)})\| \\ &\leq L\|x^{(p)} - x^{(p-1)}\| \\ &\leq L^p\|x^{(1)} - x^{(0)}\| \end{aligned}$$

Para $l > k \geq 0$, se obtiene

$$\begin{aligned} \|x^{(l)} - x^{(k)}\| &\leq \sum_{i=1}^{l-k} \|x^{(k+i)} - x^{(k+i-1)}\| \\ &\leq \sum_{i=1}^{l-k} L^{k+i-1}\|x^{(1)} - x^{(0)}\| \\ &= L^k\left(\sum_{i=1}^{l-k} L^{i-1}\right)\|x^{(1)} - x^{(0)}\| \\ &\leq L^k\frac{1}{1-L}\|x^{(1)} - x^{(0)}\| = \frac{L^k}{1-L}\|x^{(1)} - x^{(0)}\|, \\ \|x^{(l)} - x^{(k)}\| &\leq \frac{L^k}{1-L}\|x^{(1)} - x^{(0)}\| \end{aligned}$$

pues $L < 1$. Por consiguiente, $\{x^{(k)}\}$ es una sucesión de Cauchy que converge hacia un $x^* \in D$. Siendo F continua en el sentido de Lipschitz se tiene que también es continua. Por consiguiente de $x^{(k)} \to x^*$ y $x^{(k+1)} = F(x^{(k)})$ se tiene que $x^* = F(x^*)$.

Unicidad: Supongamos que x^{**} es también un punto fijo de F, entonces:

$$\|x^* - x^{**}\| = \|F(x^*) - F(x^{**})\| \leq L\|x^* - x^{**}\|,$$

luego

$$(1-L)\|x^* - x^{**}\| \leq 0 \quad \Longrightarrow \quad x^* = x^{**} \qquad (\text{ pues } L < 1)$$

(b) A partir de la prueba de (a) se tiene

$$\|x^{(l)} - x^{(k)}\| \leq \frac{L^k}{1-L}\|x^{(1)} - x^{(0)}\|, \quad 0 \leq k \leq l$$

Para k fijo y $l \to +\infty$, se obtiene

$$\|x^{(k)} - x^*\| \leq \frac{L^k}{1-L}\|x^{(1)} - x^{(0)}\|, \quad k = 1, 2, \cdots$$

Nota: Esta inecuación permite "estimar."al inicio de una iteración el número de iteraciones necesarias para una cierta exactitud, conociendo $x^{(1)}$ y $x^{(0)}$ con $L < 1$.

(c) Sea $k \in \mathbb{N}$ fijo, $y^{(0)} := x^{(k-1)}$ y $y^{(1)} := F(y^{(0)})$. Se cumple que $y^{(1)} := F(x^{(k-1)}) = x^{(k)}$ y se obtiene

$$\begin{aligned} \|x^{(k)} - x^*\| &= \|y^{(1)} - x^*\| \leq \frac{L}{1-L}\|y^{(1)} - y^{(0)}\| \\ &= \frac{L}{1-L}\|x^{(k)} - x^{(k-1)}\|. \qquad \square \end{aligned}$$

10. Soluciones de sistemas de ecuaciones lineales por métodos iterativos

Supongamos que A es una matriz con los elementos diagonales distintos de cero, esto es, $a_{ii} \neq 0,\ i = 1, 2, \cdots, n$. El sistema lineal $Ax = b$ puede escribirse

como:

$$\begin{array}{ccccccccccc} a_{11}x_1 & + & a_{12}x_2 & + & a_{13}x_2 & + & \dots & + & a_{1n}x_n & = & b_1 \\ a_{21}x_1 & + & a_{22}x_2 & + & a_{23}x_2 & + & \dots & + & a_{2n}x_n & = & b_2 \\ & & & & & & \vdots & & & & \\ a_{n1}x_1 & + & a_{n2}x_2 & + & a_{n3}x_2 & + & \dots & + & a_{nn}x_n & = & b_n \end{array}$$

de donde:

$$\begin{array}{ccccccccccccccc} -a_{11}x_1 & = & & + & a_{12}x_2 & + & a_{13}x_3 & + & \cdots & & & + & a_{1n}x_n & - & b_1 & & \\ -a_{22}x_2 & = & a_{21}x_1 & + & & + & a_{23}x_3 & + & \cdots & & & + & a_{2n}x_n & - & b_2 & & \\ -a_{33}x_3 & = & a_{31}x_1 & + & a_{32}x_2 & + & & + & \cdots & & & + & a_{3n}x_n & - & b_3 & \dots & (*) \\ & & & + & & & & & & & \ddots & & & & & & \\ -a_{nn}x_n & = & a_{n1}x_1 & + & a_{n2}x_2 & + & \cdots & + & & + & \cdots & + & & - & b_n & & \end{array}$$

Dividiendo cada ecuación entre $-a_{ii}$, obtenemos

$$\begin{array}{c} x_1 = F_1(\overline{x}) \\ x_2 = F_2(\overline{x}) \\ \vdots \\ x_n = F_n(\overline{x}) \end{array}$$

o $\overline{x} = F(\overline{x})$, con $F : \mathbb{R}^n \to \mathbb{R}^n$, función a la cual se le puede aplicar el teorema 3.20 del punto fijo de Banach.
Definimos las matrices:

$$A_D = diag(a_{11}, a_{22}, \cdots, a_{nn}),$$

$$A_L = \begin{bmatrix} 0 & 0 & \dots & 0 \\ a_{21} & 0 & & \vdots \\ \vdots & & \ddots & \\ a_{n1} & \cdots & a_{n,n-1} & 0 \end{bmatrix} \quad \text{y} \quad A_D = \begin{bmatrix} 0 & a_{12} & \dots & a_{1n} \\ \vdots & & & \vdots \\ & 0 & \ddots & a_{n-1,n} \\ 0 & & \cdots & 0 \end{bmatrix}$$

y se cumple: $A = A_D + A_L + A_R$, de esto y de $(*)$ se obtiene:

$$-A_D x = (A_L + A_R)x - b$$

ó

$$\begin{array}{rl} x & = -A_D^{-1}(A_L + A_R)x + A_D^{-1}b \\ & = -A_D^{-1}(A - A_D)x + A_D^{-1}b \\ x & = (I - A_D^{-1}A)x + A_D^{-1}b =: F(x) \end{array}$$

De esto se obtiene el método de Jacobi (Método del paso entero):

$$\begin{array}{rl} x^{(j+1)} & = (I - A_D^{-1}A)x^{(j)} + A_D^{-1}b \\ & = A_D^{-1}b + A_D^{-1}(A_L + A_R)x^{(j)}, \qquad j = 1, 2, \cdots, n \end{array}$$

que escrito componente a componente:

$$x_i^{(j+1)} = \frac{1}{a_{ii}} \left[b_i - \sum_{\substack{k=1 \\ k \neq i}}^{n} a_{ik} x_k^{(j)} \right], \qquad i = 1, 2, \cdots, n, \quad a_{ii} \neq 0$$

Para la convergencia, según el teorema del punto fijo 3.20 de Banach se tiene que mostrar la existencia de $L \in \langle 0, 1 \rangle$ tal que

$$\|F(x) - F(y)\| \leq L\|x - y\|$$

con $F(x) = (I - A_D^{-1}A)x + A_D^{-1}b$ y como $F'(x) = I - A_D^{-1}A$, exigimos que

$$\|I - A_D^{-1}A\| < 1$$

Veamos el método de Gauss-Seidel:
Sabiendo que $(A_D + A_L + A_R)x = b$, tenemos que

$$(A_D + A_L)x = -A_R x + b$$

de donde

$$(A_D + A_L)x^{(j+1)} = -A_R x^{(j)} + b$$

lo cual puede escribirse como

$$A_D x^{(j+1)} = b - A_L x^{(j+1)} - A_R x^{(j)}$$

y en componentes:

$$a_{ii}x_i^{(j+1)} = b_i - \sum_{k=1}^{i-1} a_{ik}x_k^{(j+1)} - \sum_{k=i+1}^{n} a_{ik}x_k^{(j)}$$

despejando:

$$x_i^{(j+1)} = \frac{1}{a_{ii}}\left[b_i - \sum_{k=1}^{i-1} a_{ik}x_k^{(j+1)} - \sum_{k=i+1}^{n} a_{ik}x_k^{(j)}\right]$$

El método de Gauss-Seidel aprovecha para el cálculo de $x_i^{(j+1)}$ las componentes ya calculadas $x_1^{(j+1)}, \cdots, x_{i-1}^{(j+1)}$.

En general, la matriz A se descompone en la forma

$$A = B + (A - B), \quad B \in \mathbb{R}^{n\times n} \text{ regular}$$

Reemplazando en el sistema $Ax = b$ se obtiene

$$Bx = (B - A)x + B$$

ó

$$x = (I - B^{-1}A)x + B^{-1}b$$

Esto sugiere el método iterativo:

$$x^{(j+1)} = (I - B^{-1}A)x^{(j)} + B^{-1}b \qquad \ldots \qquad (1)$$

ó

$$Bx^{(j+1)} = (B - A)x^{(j)} + b \qquad \ldots \qquad (2)$$

Objetivo: Elegir B de manera que:

(a) Se pueda calcular fácilmente la sucesión $\{x^{(j)}\}$ y
(b) La sucesión $\{x^{(j)}\}$ converja rápidamente a la solución.
(c) La sucesión $\{x^{(j)}\}$ converja globalmente.

En la práctica no es necesario calcular B^{-1}, la ecuación (1) se usa para el análisis teórico.

TEOREMA 3.21. *Dado el sistema lineal $Ax = b$, $A \in \mathbb{C}^{n\times n}$ regular, $b \in \mathbb{C}^n$, aplicando el método iterativo*

$$Bx^{(j+1)} = (B - A)x^{(j)} + b,$$

donde $B \in \mathbb{C}^{n\times n}$ es regular, entonces se cumple:

(a) *La sucesión $\{x^{(j)}\}$ converge para cada valor inicial $x^{(0)} \in \mathbb{C}^n$ a la solución x^* de $Ax = b$, sí y sólo si $\rho(I - B^{-1}A) < 1$.*

(b) *Si* $L := \|I - B^{-1}A\| < 1$*, la sucesión* $\{x^{(j)}\}$ *converge para cada valor inicial* $x^{(0)} \in \mathbb{C}^n$ *a la solución* x^* *de* $Ax = b$.
Además se cumplen las siguientes estimaciones de error:

$$\|x^{(k)} - x^*\| \leq \frac{L^k}{1-L}\|x^{(1)} - x^{(0)}\|, \qquad k = 1, 2, \cdots$$

(Estimación del error a priori).

$$\|x^{(k)} - x^*\| \leq \frac{L}{1-L}\|x^{(k)} - x^{(k-1)}\|, \qquad k = 1, 2, \cdots$$

(Estimación del error a posteriori).

Demostración:

(a) Sea $\varepsilon^{(j)} := x^{(j)} - x^*$ el error de la i-ésima iteración. Entonces se obtiene:

$$\begin{aligned} \varepsilon^{(j+1)} &= x^{(j+1)} - x^* = B^{-1}(B - A)x^{(j)} + B^{-1}b - x^* \\ &= (I - B^{-1}A)x^{(j)} + B^{-1}Ax^* - x^* \\ &= (I - B^{-1}A)(x^{(j)} - x^*) \\ &= (I - B^{-1}A)\varepsilon^{(j)} \end{aligned}$$

($\Longrightarrow$) Sea λ el valor propio con el mayor módulo de $I - B^{-1}A$ y $\varepsilon^{(0)}$ un vector propio correspondiente. Entonces

$$(I - B^{-1}A)\varepsilon^{(0)} = \lambda\varepsilon^{(0)}$$

Elegimos el punto inicial $x^{(0)} := x^* + \varepsilon^{(0)}$ y se cumple

$$x^{(j+1)} - x^* = (I - B^{-1}A)^{j+1}\varepsilon^{(0)} = \lambda^{j+1}\varepsilon^{(0)}$$

Como $x^{(j+1)} \to x^*$, se obtiene $|\lambda| = \rho(I - B^{-1}A) < 1$, pues de otro modo se tendría que $x^{(j+1)} - x^* \not\to 0$.

($\Longleftarrow$) Eligiendo $\varepsilon > 0$ con $q := \rho(I - B^{-1}A) + \varepsilon < 1$, por el teorema 3.6 (pag. 27), existe una norma matricial $\|\cdot\|$ tal que

$$\|I - B^{-1}A\| < \rho(I - B^{-1}A) + \varepsilon = q < 1$$

Para cualquier $x^{(0)} \in \mathbb{C}^n$ se obtiene

$$\begin{aligned} \|x^{(j)} - x^*\| &= \|(I - B^{-1}A)^j(x^{(0)} - x^*)\| \\ &\leq \|I - B^{-1}A\|^j\|x^{(0)} - x^*\| \leq q^n\|x^{(0)} - x^*\| \end{aligned}$$

Como $q < 1$ se obtiene:

$$\lim_{j\to\infty} \|x^{(j)} - x^*\| = 0 \qquad \text{ó} \qquad \lim_{j\to\infty} x^{(j)} = x^*$$

(b) La función $F : \mathbb{C}^n \to \mathbb{C}^n$, $F(x) = (I - B^{-1}A)x + B^{-1}b$ cumple las condiciones del teorema del punto fijo de Banach 3.20. Las estimaciones corresponden a las estimaciones a priori y a posteriori del mismo teorema.

Nota: La velocidad de convergencia depende del radio espectral $\rho(I - B^{-1}A)$. Mientras más pequeño es el radio, más rápida es la velocidad de convergencia.

10.0.1. Relajación. Tiene como objetivo acelerar la convergencia de los métodos actuales. Introduciendo un *parámetro de relajación* del cual dependa la matriz iterativa se puede mejorar la rapidez de convergencia. Luego se tiene que determinar el parámetro de tal manera que el radio espectral resulte tan pequeño como sea posible.

Relajación del método de Jacobi.
Consideremos $w \neq 0, w \in \mathbb{R}$.

$$\begin{aligned} z_i^{(j+1)} &:= \frac{1}{a_{ii}}\left[b_i - \sum_{\substack{k=1 \\ k\neq i}}^{n} a_{ik}x_k^{(j)}\right] \\ x_i^{(j+1)} &:= (1 - w)x_i^{(j)} + wz_i^{(j+1)} \end{aligned}$$

Para $w = 1$, tenemos el método de Jacobi. La idea es minimizar

$$x^{(j+1)} - x^{(j)} = w(z^{(j+1)} - x^{(j)})$$

Matricialmente:

$$\begin{array}{rcl} z^{(j+1)} & := & -A_D^{-1}(A_L + A_R)x^{(j)} + A_D^{-1}b \\ x^{(j+1)} & := & (1-w)x^{(j)} + wz^{(j+1)} \\ & = & [(1-w)I - wA_D^{-1}(A_L + A_R)]x^{(j)} + wA_D^{-1}b \end{array}$$

Haciendo $B(w) := \dfrac{1}{w}A_D$ se obtiene

$$\begin{aligned} I - B(w)^{-1}A &= I - wA_D^{-1}(A_D + A_L + A_R) \\ &= (1-w)I - wA_D^{-1}(A_L + A_R) = J(w) \end{aligned}$$

En componentes:

$$x_i^{(j+1)} := (1-w)x_i^{(j)} + \frac{w}{a_{ii}}\left[b_i - \sum_{\substack{k=1 \\ k\neq i}}^{n} a_{ik}x_k^{(j)}\right]$$

Relajación del método de Gauss-Seidel (SOR-Successive OverRelaxation). Sea $w \neq 0$.

$$\begin{aligned} z_i^{(j+1)} &= \frac{1}{a_{ii}}\left[b_i - \sum_{k=1}^{i-1} a_{ik}x_k^{(j+1)} - \sum_{k=i+1}^{n} a_{ik}x_k^{(j)}\right] \\ x_i^{(j+1)} &:= (1-w)x_i^{(j)} + wz_i^{(j+1)} \qquad\qquad i = 1, 2, \cdots, n \end{aligned}$$

Para $w = 1$, se tiene el método de Gauss-Seidel. Matricialmente:

$$\begin{array}{rcl} A_D z^{(j+1)} & := & -A_L x^{(j+1)} - A_R x^{(j)} + b \\ x^{(j+1)} & := & (1-w)x^{(j)} + wz^{(j+1)} \end{array}$$

Luego:

$$\begin{aligned} &(A_D + wA_L)x^{(j+1)} = [(1-w)A_D - wA_R]x^{(j)} + wb \\ &x^{(j+1)} = (A_D + wA_L)^{-1}[(1-w)A_D - wA_R]x^{(j)} + w(A_D + wA_L)^{-1}b \end{aligned}$$

Definiendo

$$\begin{aligned} G(w) &:= (A_D + wA_L)^{-1}[(1-w)A_D - wA_R] \\ B(w) &:= \frac{1}{w}A_D + A_L \end{aligned}$$

se obtiene que $I - B(w)^{-1}A = G(w)$ (Ejercicio).
Por componentes:

$$x_i^{(j+1)} = \frac{w}{a_{ii}}\left[b_i - \sum_{k=1}^{i-1} a_{ik}x_k^{(j+1)} - \sum_{k=i+1}^{n} a_{ik}x_k^{(j)}\right], \qquad i = 1, 2, \cdots, n$$

Criterios para convergencia.

DEFINICIÓN. *Sea $A = (a_{ij}) \in \mathbb{C}^{n\times n}$.*

(a) *La matriz A satisface el criterio de la suma de filas, si*

$$\sum_{\substack{k=1 \\ k\neq i}}^{n} |a_{ik}| < |a_{ii}|, \qquad i = 1, 2, \cdots, n$$

(b) *La matriz A satisface el criterio débil de la suma de filas si*

$$\sum_{\substack{k=1 \\ k\neq i}}^{n} |a_{ik}| \begin{cases} \leq |a_{ii}|, & \text{para todo } i = 1, 2, \cdots, n \\ < |a_{ii}| & \text{para por lo menos un } i = i_0. \end{cases}$$

DEFINICIÓN. *Una matriz $A = (a_{ij}) \in \mathbb{C}^{n\times n}$ es denominada reducible si existen $N_1, N_2 \neq \phi$, $N_1, N_2 \subset N := \{1, 2, \cdots, n\}$ con $N_1 \cap N_2 = \phi$ y $N_1 \cup N_2 = N$ y $a_{ij} = 0$, $\forall (i, j) \in N_1 \times N_2$. Si A no es reducible se dice que es irreducible.*

Ejemplos:

(a)
$$A = \begin{bmatrix} 14 & 13 & 15 & 0 \\ 16 & 17 & 18 & 20 \\ 0 & 2 & 3 & 4 \\ 5 & 6 & 8 & 9 \end{bmatrix}$$
A es irreducible. Además, vemos que $|5|+|6|+|8| \not\leq 9$. Luego A no satisface el criterio débil ni el estricto de la suma de filas.

(b)
$$B = \begin{bmatrix} 4+3i & 1 & 1/2 \\ i & 5 & 3i \\ 4 & 5 & 100 \end{bmatrix} \qquad \begin{array}{l} |1| + |1/2| = 3/2 < |4+3i| = 5 \\ |i| + |3i| = 4 < |5| = 5 \\ |4| + |5| = 9 < |100| = 100 \end{array}$$
B satisface el criterio estricto de la suma de filas, luego también cumple el criterio débil de la suma de filas.

(c)
$$C = \begin{bmatrix} 3 & 4 & 5 & 56 \\ 0 & 9 & 10 & 0 \\ 0 & 8 & 11 & 0 \\ 6 & 7 & 12 & 13 \end{bmatrix}$$
Tenemos que $N_1 = \{2, 3\}$, $N_2 = \{1, 4\}$. Además $N_1 \cup N_2 = \{1, 2, 3, 4\}$,$N_1 \cap N_2 = \phi$ y $a_{21} = a_{31} = a_{24} = a_{34} = 0$. Por lo tanto C es reducible.

TEOREMA 3.22. *Sea $A = (a_{ij}) \in \mathbb{C}^{n\times n}$ y $J = -A_D^{-1}(A_L + A_R) = (I - A_D^{-1}A)$ la matriz iterativa de Jacobi con $A = A_D + A_L + A_R$.*

(a) *Si A cumple el criterio estricto, entonces $\|J\|_\infty < 1$ y las iteraciones de Jacobi convergen.*

(b) *Si A es irreducible y cumple el criterio débil, entonces $\rho(J) < 1$, y las iteraciones de Jacobi convergen.*

Demostración:

(a) Como A cumple el criterio estricto se tiene que $a_{ii} \neq 0$, $i = 1, 2, \cdots, n$. Entonces A_D^{-1} existe y $J = -A_D^{-1}(A_L + A_R)$ está bien definida. Luego:
$$\|J\|_\infty = \max\left(\sum_{\substack{k=1 \\ k\neq i}}^{n} \left|\frac{a_{ik}}{a_{ii}}\right|\right) = \max\left(\frac{1}{|a_{ii}|}\sum_{\substack{k=1 \\ k\neq i}}^{n} |a_{ik}|\right) < 1$$

(b) A es irreducible y cumple el criterio débil, entonces $a_{ii} \neq 0$ para $i = 1, 2, \cdots, n$. Supongamos que existe $i_0 \in N$ tal que $a_{i_0 i_0} = 0$. Sean
$$N_1 := \{i \in N \,/\, a_{ii} = 0\} \quad \text{y} \quad N_2 := \{i \in N \,/\, a_{ii} \neq 0\}$$
Luego se cumple que N_1 y N_2 son no vacíos, pues si $N_2 = \phi$ entonces el criterio débil no se cumpliría. Para $i \in N_1$ se cumple que $a_{ik} = 0, k = 1, 2, \cdots, n$ por el criterio débil. Entonces $a_{ik} = 0$ para $(i, k) \in N_1 \times N_2$, $N_1 \cap N_2 = \phi$ y $N_1 \cup N_2 = N$, lo cual contradice que A es irreducible, y por lo tanto $a_{ii} \neq 0$, $\forall i = 1, 2, \cdots, n$.
$$\rho(J) \leq \|J\|_\infty \leq \max_{1\leq i\leq n}\left(\frac{1}{|a_{ii}|}\sum_{\substack{k=1 \\ k\neq i}}^{n} |a_{ik}|\right) \geq 1$$

Supongamos que J tiene un valor propio λ con $|\lambda| = 1$. Sea x un valor propio correspondiente λ, con $\|x\|_\infty = 1$, de donde $J(x) = \lambda x$. Definimos

$$N_1 := \{i \in N : |x_i| = 1\}$$

entonces

$$|x_i| = |\lambda||x_i| = |\lambda x_i| = |(Jx)_i| = \frac{1}{|a_{ii}|}\left|\sum_{\substack{k=1\\k\neq i}}^{n} a_{ik}x_k\right| \leq \frac{1}{|a_{ii}|}\sum_{\substack{k=1\\k\neq i}}^{n}|a_{ik}| \leq 1$$

Luego, para todo $i \in N_1$, tenemos $|a_{ii}| = \sum_{k=1}^{n}|a_{ik}|$. $N_2 = N\setminus N_1 \neq \phi$, pues por el criterio débil existe al menos un $i_0 \in N$ tal que $|a_{i_0 i_0}| > \sum_{\substack{k=1\\k\neq i_0}}^{n}|a_{ik}|$.
Como A es irreducible, existe una pareja de índices $(i_0, j_0) \in N_1 \times N_2$ con $a_{i_0 j_0} \neq 0$. Entonces:

$$\begin{aligned}|\lambda| \quad &= 1 = |\lambda||x_0| = |(Jx)_{i_0}| \leq \frac{1}{|a_{i_0 i_0}|}\sum_{\substack{k=1\\k\neq i_0}}^{n}|a_{i_0 k}||x_k| \\ &< \frac{1}{|a_{i_0 i_0}|}\sum_{\substack{k=1\\k\neq i_0}}^{n}|a_{i_0 k}| \leq 1\end{aligned}$$

pues $|x_{j_0}| < 1,\ j_0 \in N_2$. Esto es una contradicción. Por tanto, no existe λ tal que $|\lambda| = 1$.

TEOREMA 3.23. *Si la matriz iterativa $J := A_D^{-1}(A_L + A_R)$ del método de Jacobi tiene solamente valores propios reales*

$$\lambda_1 \leq \lambda_2 \leq \cdots \leq \lambda_n \leq 1,$$

entonces el radio espectral de $J(w) = (1-w)I - wA_D^{-1}(A_L + A_R)$ es minimal para

$$w_{opt} := \frac{2}{2 - \lambda_1 - \lambda_n}$$

Demostración: Se cumple que la matriz $J(w)$ tiene valores propios $1-w+w\lambda_i$, con λ_i autovalor de J . Luego

$$\lambda_i' = 1 - w + w\lambda_i$$

Se tiene que probar que w_{opt} es solución del siguiente problema:

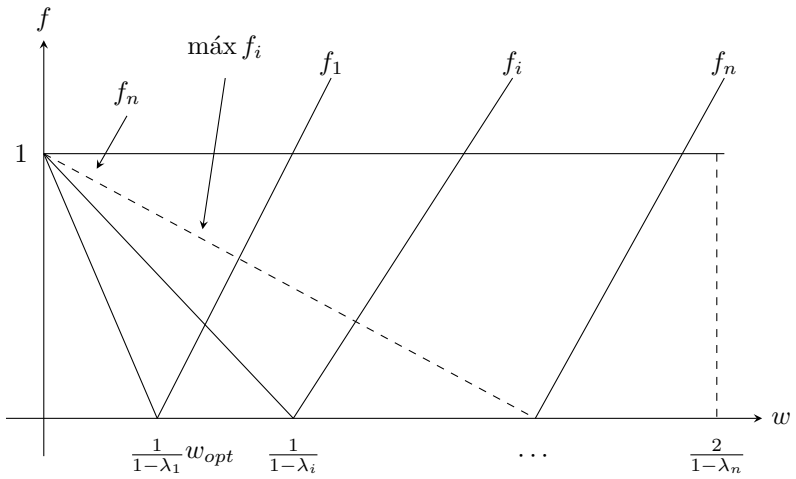
$$\text{mín}\left[\rho(J(w)) := \max_{i=1,\cdots,n}|1 - w + w\lambda_i|\right]$$

Definamos $f_i(w) := |1 - w + w\lambda_i|$, $i = 1, 2, \cdots, n$. Como $\lambda_1 \leq \lambda_2 \leq \cdots \leq \lambda_n \leq 1$, se cumple que

$$0 < \frac{1}{1-\lambda_1} \leq \frac{1}{1-\lambda_2} \leq \frac{1}{1-\lambda_3} \leq \cdots \leq \frac{1}{1-\lambda_n}$$

Tenemos que

$$\begin{aligned}&f_i(0) = 1, \quad i = 1, 2, \cdots, n \\ &f_i(\frac{1}{1-\lambda_i}) = \left|1 + (-1+\lambda_i)\frac{1}{1-\lambda_i}\right| = 0 \\ &f_i(\frac{2}{1-\lambda_i}) = \left|1 + (-1+\lambda_i)\frac{2}{1-\lambda_i}\right| = 1\end{aligned}$$



De este gráfico se aprecia que $\rho(J(w))$ toma su valor mínimo con $f_n(w_{opt}) = f_1(w_{opt})$, es decir

$$|1 - w_{opt} + w_{opt}\lambda_n| = |1 - w_{opt} + w_{opt}\lambda_1|$$

luego

$$1 - w_{opt} + w_{opt}\lambda_n = -1 + w_{opt} - w_{opt}\lambda_1$$

de donde

$$w_{opt} = \frac{2}{2 - \lambda_n - \lambda_1} \qquad \square$$

Ahora veamos la convergencia del método de Gauss-Seidel ($w = 1$) y el método SOR de manera conjunta.

TEOREMA 3.24. *Si los elementos diagonales de $A = (a_{ij}) \in \mathbb{C}^{n\times n}$ son distintos de cero, se cumple*

$$\rho(G(w)) \geq |w - 1|$$

donde:

$$G(w) := (A_D + wA_L)^{-1}[(1 - w)A_D - wA_R]$$

es la matriz iterativa del método SOR. Es decir, el método de SOR converge solamene si $w \in \langle 0, 2\rangle$.

Demostración:

$$\begin{aligned} G(w) &= (A_D + wA_L)^{-1}[(1 - w)A_D - wA_R] \\ &= (A_D + wA_L)^{-1}A_D[(1 - w)I - wA_D^{-1}A_R] \\ &= [A_D^{-1}(A_D + wA_L)]^{-1}[(1 - w)I - wA_D^{-1}A_L] \\ &= [I + wA_D^{-1}A_L]^{-1}[(1 - w)I - wA_D^{-1}A_R] \qquad \cdots \quad (*) \end{aligned}$$

Como la matriz $(I + wA_D^{-1}A_L)$ es triangular inferior con elementos en su diagonal iguales a 1, se tiene que $\det(I + wA_D^{-1}A_L) = 1$. Para el polinomio característico $P(\lambda)$ de $G(w)$ se cumple:

$$\begin{aligned} P(\lambda) &= \det(\lambda I - G(w)) \\ &= \det(I + wA_D^{-1}A_L)\det(\lambda I - G(w)) \\ &= \det(I + wA_D^{-1}A_L)(\lambda I - G(w)) \\ &= \det[(I + wA_D^{-1})\lambda I - ((1 - w)I + wA_D^{-1}A_R)] \quad [\text{por } (*)] \end{aligned}$$

Como $p(0)$ es igual al producto de los valores propios λ_i de $G(w)$, $i = 1, 2, \cdots, n$ se cumple

$$\prod_{i=1}^{n} \lambda_i = P(0) = \det[(w - 1)I + wA_D^{-1}A_R] = (w - 1)^n$$

pues A_R es diagonal superior con ceros en la diagonal, de donde $wA_D^{-1}A_R$ es diagonal superior con ceros en la diagonal. Luego:

$$|\lambda_{max}|^n \geq \prod_{i=1}^{n} |\lambda_i| = |w-1|^n$$

de donde finalmente:

$$\rho(G(w)) \geq |w-1|. \qquad \square$$

TEOREMA 3.25. *Si $A \in \mathbb{C}^{n\times n}$ cumple el criterio estricto, entonces $\|G(w)\|_\infty < 1$, $\forall w \in [0,1)$ y el método SOR converge para todos los valores iniciales.*

Demostración: Sea $x \in \mathbb{C}^n$ con $\|x\|_\infty = 1$ y $z := G(w)x$. Por $(*)$ se tiene:

$$(I + wA_D^{-1}A_L)z = [(1-w)I - wA_D^{-1}A_R]x.$$

Para las componentes se obtiene:

$$z_i = (1-w)x_i - \frac{w}{a_{ii}}\left[\sum_{k=1}^{i-1} a_{ik}z_k + \sum_{k=i+1}^{n} a_{ik}x_k\right]$$

$$|z_i| = (1-w) + \frac{w}{|a_{ii}|}\left[\sum_{k=1}^{i-1} |a_{ik}||z_k| + \sum_{k=i+1}^{n} |a_{ik}||x_k|\right], \quad i = 1,2,\cdots,n$$

En particular para $i = 1$:

$$\begin{aligned}
|z_1| &\leq (1-w) + \frac{w}{|a_{11}|}\left[\sum_{k=2}^{n} |a_{1k}|\right] \\
&\leq (1-w) + w\sum_{k=2}^{n} \frac{|a_{1k}|}{|a_{11}|} \\
&\leq (1-w) + w\left[\max_{j=1,2,\cdots,n} \sum_{\substack{k=1\\k\neq j}}^{n} \frac{|a_{jk}|}{|a_{jj}|}\right] \\
&= 1 - w + w\|J\|_\infty < 1 - w + w \\
&< 1
\end{aligned}$$

Esto es, $|z_1| < 1$. En general, $|z_i| < 1$, pues

$$\begin{aligned}
|z_2| &\leq (1-w) + \frac{w}{|a_{22}|}\left[|a_{21}||z_1| + \sum_{k=3}^{n} |a_{2k}|\right] \\
&\leq (1-w) + w\left[\max_{j=1,2,\cdots,n} \frac{1}{|a_{jj}|}\sum_{\substack{k=1\\k\neq j}}^{n} |a_{jk}|\right] \\
&< 1
\end{aligned}$$

Luego

$$\|G(w)\|_\infty = \sup_{\|x\|_\infty=1} \|G(w)x\|_\infty = \|z\|_\infty < 1 \qquad \square$$

TEOREMA 3.26. *Sea $A \in \mathbb{C}^{n\times n}$ hermitiana y definida positiva. Entonces el método SOR converge para todo $w \in \langle 0,2\rangle$, en especial el método de Gauss-Seidel en $w = 1$.*

Demostración: Vamos a probar que

$$\rho(G(w)) = \rho(I - B(w)^{-1}A) < 1, \qquad \forall w \in \langle 0,2\rangle.$$

Sea λ un valor propio de $G(w)$, $x \in \mathbb{C}^n$ un valor propio correspondiente.

$$[I - B(w)^{-1}A]x = \lambda x \qquad \Longleftrightarrow \qquad Ax = (1-\lambda)B(w)x \qquad \cdots \qquad (**)$$

Como A es definida positiva se cumple que $\det(A) \neq 0$ y por $(**)$ se concluye que $\lambda \neq 1$. De $(**)$,

$$\frac{Ax}{1-\lambda} = B(w)x \quad \Longrightarrow \quad \frac{x^*Ax}{1-\lambda} = x^*B(w)x$$
$$\frac{1}{1-\lambda} = \frac{x^*B(w)x}{x^*Ax}$$

Luego

$$2Re\left(\frac{1}{1-\lambda}\right) = 2Re\left(\frac{x^*B(w)x}{x^*Ax}\right) = \frac{x^*[B^*(w)+B(w)]x}{x^*Ax}$$

y como $B(w) = \dfrac{1}{w}A_D + A_L$, entonces

$$\begin{aligned} 2Re\left(\frac{1}{1-\lambda}\right) &= \frac{x^*[\frac{1}{w}A_D + A_L^* + \frac{1}{w}A_D + A_L]x}{x^*Ax} = \frac{x^*[\frac{1}{w}A_D + A_R + \frac{1}{w}A_D + A_L]x}{x^*Ax} \\ &= \left(\frac{2}{w}-1\right)\frac{x^*A_Dx}{x^*Ax} + \frac{x^*(A_R+A_D+A_L)x}{x^*Ax} \\ &= \left(\frac{2}{w}-1\right)\frac{x^*A_Dx}{x^*Ax} + 1 > 1 \end{aligned}$$

pues A_D también es definida positiva (y por tanto el primer término en la anterior expresión es positivo). Para $\lambda = \alpha + i\beta$ se obtiene

$$1 < 2Re\left(\frac{1}{1-\lambda}\right) = 2Re\left[\left(\frac{1}{1-\alpha-i\beta}\right)\cdot\left(\frac{1-\alpha+i\beta}{1-\alpha+i\beta}\right)\right] = \frac{2(2-\alpha)}{(1-\alpha)^2+\beta^2}$$

entonces

$$|\lambda^2| = |\alpha+i\beta|^2 = \alpha^2+\beta^2 < 1$$

pues $1-2\alpha+\alpha^2+\beta^2 < 2-2\alpha$. Por lo tanto

$$\rho(G(w)) < 1, \qquad \forall w \in \langle 0,1\rangle. \qquad \square$$

Capítulo 4

Sistemas de ecuaciones no lineales

1. Métodos unidimensionales

DEFINICIÓN (Raíz de una ecuación). *Sea $f : \mathbb{R} \to \mathbb{R}$. $\hat{x} \in \mathbb{R}$ es una raíz de f si $f(\hat{x}) = 0$.*

El problema que atacamos es el de resolver $f(x) = 0, \quad a \leq x \leq b$.
Para esto necesitamos algunos teoremas preliminares:

TEOREMA 4.1 (del valor intermedio). *Sea $f : \mathbb{R} \to \mathbb{R}$. Si $f \in C[a, b]$, $f(a) < f(b)$ y si $k \in \mathbb{R}$ es tal que $f(a) < k < f(b)$, entonces existe un punto $c \in (a, b)$ tal que $f(c) = k$.*

TEOREMA 4.2 (del cero). *Si $f \in C[a, b]$ y si $f(a)f(b) < 0$, entonces existe $c \in (a, b)$ tal que $f(c) = 0$.*

1.1. Algoritmo de la Bisección. Para revisar: otra alternativa al momento de calcular $x^{(j+1)}$ es:

$$x^{(j+1)} := a^{(j)} + \frac{(b^{(j)} - a^{(j)})}{2}$$

Queda como ejercicio comprobar que

$$|x^* - x^{(j+1)}| \leq |a^{(0)} - b^{(0)}|/2^{j+1}$$

1.2. Algoritmo Regula Falsi. Hipótesis: $f \in C^0[a, b]$, $f(a)f(b) < 0$. Es un algoritmo similar al anterior, la diferencia radica en que el cálculo de $x^{(j+1)}$ se hace con la ayuda de la recta secante a la gráfica:

La ecuación de la recta secante L_{sec}:

$$y - f(a^{(j)}) = \frac{f(b^{(j)}) - f(a^{(j)})}{b^{(j)} - a^{(j)}}(x - a^{(j)})$$

para $x = x^{(j+1)}$ se tiene que $y = 0$, luego

$$x^{(j+1)} = -f(a^{(j)})\frac{b^{(j)} - a^{(j)}}{f(b^{(j)}) - f(a^{(j)})} + a^{(j)}$$

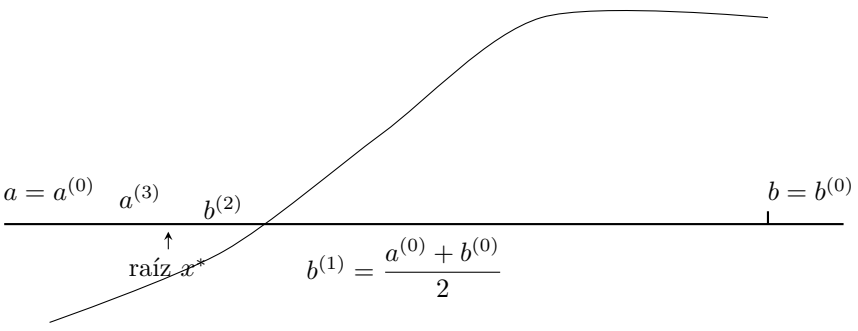


FIGURA 1. Método de la bisección

Algoritmo 8 Algoritmo de la bisección

Entrada: f continua sobre $[a^{(0)}, b^{(0)}]$, $f(a^{(0)})f(b^{(0)}) < 0$, $\varepsilon > 0$ (precisión)
1: Poner $j := 0$
2: Calcular $x^{(1)} := \frac{a^{(0)}+b^{(0)}}{2}$
3: **while** $|f(x^{(j+1)})| > \varepsilon$ **hacer**
4: **if** $f(a^{(j)})f(x^{(j+1)}) \leq 0$ **then**
5: $a^{(j+1)} := a^{(j)}$
6: $b^{(j+1)} := x^{(j)}$
7: **else**
8: $a^{(j+1)} := x^{(j)}$
9: $b^{(j+1)} := b^{(j)}$
10: **Fin if**
11: $j := j + 1$
12: Calcular $x^{(j+1)} := \frac{a^{(j)}+b^{(j)}}{2}$
13: **Fin while**
Salida: $x^{(j+1)}$ como aproximación para x^*, con $|x^* - x^{(j+1)}| \leq \frac{|a^{(0)}-b^{(0)}|}{2^{j+1}}$

de donde, simplificando:

$$x^{(j+1)} := \frac{a^{(j)}f(b^{(j)}) - b^{(j)}f(a^{(j)})}{f(b^{(j)}) - f(a^{(j)})}$$

Entonces tenemos el *Algoritmo Regula Falsi*:

Algoritmo 9 Algoritmo Regula Falsi

Entrada: f continua sobre $[a^{(0)}, b^{(0)}]$ y $f(a^{(0)})f(b^{(0)}) < 0$, $\varepsilon > 0$ (precisión)
1: Poner $j := 0$
2: Calcular $x^{(1)} := \frac{a^{(0)}f(b^{(0)})-b^{(0)}f(a^{(0)})}{f(b^{(0)})-f(a^{(0)})}$
3: **while** $|f(x^{(j+1)})| > \varepsilon$ **hacer**
4: **if** $f(a^{(j)})f(x^{(j+1)}) \leq 0$ **then**
5: $a^{(j+1)} := a^{(j)}$
6: $b^{(j+1)} := x^{(j+1)}$
7: **else**
8: $a^{(j+1)} := x^{(j+1)}$
9: $b^{(j+1)} := b^{(j)}$
10: **Fin if**
11: $j := j + 1$
12: Calcular $x^{(j+1)} := \frac{a^{(j)}f(b^{(j)})-b^{(j)}f(a^{(j)})}{f(b^{(j)})-f(a^{(j)})}$
13: **Fin while**
Salida: $x^{(j+1)}$ como aproximación de x^* con $f(x^*) = 0$

Nota: Aquí no es tan sencillo calcular la aproximación de $x^{(j+1)}$ a x^*. Si se desea una precisión adicional, se puede agregar una condición al algoritmo para la repetición del mismo (por ejemplo, poner $|f(x^{(j+1)})| > \varepsilon$ y $|x^* - x^{(j+1)}| \leq \frac{1}{2}10^{-n}$, donde n sería el número de cifras significativas deseadas).

1.3. Algoritmo Regula Falsi modificada. Este es un algoritmo de Regula Falsi Modificada, que es una mejora sobre el método de la falsa posición, para evitar el estancamiento en casos en los que una de las raíces no cambia de posición rápidamente.

Algoritmo 10 Algoritmo Regula Falsi Modificada

Entrada: f continua sobre $[a^{(0)}, b^{(0)}]$ y $f(a^{(0)})f(b^{(0)}) < 0$, $\varepsilon > 0$ (precisión)

Hacer $F := f(a^{(0)})$, $G := f(b^{(0)})$, $x^{(0)} := a^{(0)}$
Poner $j := 0$
Calcular $x^{(1)} := \frac{a^{(0)}G - b^{(0)}F}{G-F}$
while $|f(x^{(j+1)})| > \varepsilon$ **hacer**
    if $f(a^{(j)})f(x^{(j+1)}) \leq 0$ **then**
        $a^{(j+1)} := a^{(j)}$
        $b^{(j+1)} := x^{(j+1)}$
    else
        $a^{(j+1)} := x^{(j+1)}$
        $b^{(j+1)} := b^{(j)}$
    Fin if
    if $f(a^{(j)})f(x^{(j+1)}) \leq 0$ **then**
        $G := f(x^{(j+1)})$
    else
        $F := f(x^{(j+1)})$
    Fin if
    if $f(x^{(j)})f(x^{(j+1)}) > 0$ **then**
        if $f(a^{(j)})f(x^{(j+1)}) > 0$ **then**
            Hacer $F := F/2$
        else
            Hacer $G := G/2$
        Fin if
    Fin if
    $j := j + 1$
    Calcular $x^{(j+1)} := \frac{a^{(j)}G - b^{(j)}F}{G-F}$
Fin while

Salida: $x^{(j+1)}$ como aproximación de x^*

1.4. Método de las Secantes. De la figura, observamos que la pendiente de la recta secante es:

$$\frac{f(x^{(j)}) - 0}{x^{(j)} - x^{(j+1)}} = \frac{f(x^{(j)}) - f(x^{(j-1)})}{x^{(j)} - x^{(j-1)}}$$

de esto último tenemos:

$$x^{(j+1)} = x^{(j)} - f(x^{(j)}) \left(\frac{x^{(j)} - x^{(j-1)}}{f(x^{(j)}) - f(x^{(j-1)})} \right)$$

Algoritmo 11 Método de las Secantes

Entrada: $f \in C^0[x^{(0)}, x^{(1)}]$, $x^{(0)}$, $x^{(1)}$, $\varepsilon > 0$ (precisión)

Poner $j := 1$
repeat
    Calcular $x^{(j+1)} := x^{(j)} - f(x^{(j)}) \left(\frac{x^{(j)} - x^{(j-1)}}{f(x^{(j)}) - f(x^{(j-1)})} \right)$
    Incrementar $j := j + 1$
until $|f(x^{(j+1)})| \leq \varepsilon$

Salida: $x^{(j+1)}$ como aproximación para x^*

1.5. Método de Newton. La pendiente de la recta tangente L_t a la gráfica de f es:

$$m_t : f'(x^{(j)}) = \frac{0 - f(x^{(j)})}{x^{(j+1)} - x^{(j)}}$$

entonces

$$x^{(j+1)} := x^{(j)} - \frac{f(x^{(j)})}{f'(x^{(j)})}, \qquad j = 0, 1, 2, \ldots,$$

dado $x^{(0)}$: punto inicial, que debe ser bien escogido.

Algoritmo 12 Método de Newton

Entrada: f continua y derivable, $f'(x)$, $x^{(0)}$ (punto inicial bien escogido), $\varepsilon > 0$ (precisión)

1: Poner $j := 0$
2: **repeat**
3: Calcular $x^{(j+1)} := x^{(j)} - \frac{f(x^{(j)})}{f'(x^{(j)})}$
4: Incrementar $j := j + 1$
5: **until** $|f(x^{(j+1)})| \leq \varepsilon$

Salida: $x^{(j+1)}$ como aproximación para x^*

1.6. Métodos simplificado y modificado de Newton.

1.6.1. Método simplificado de Newton.

$$x^{(j+1)} := x^{(j)} - \frac{f(x^{(j)})}{f'(\hat{\mathrm{x}}^{(0)})}$$

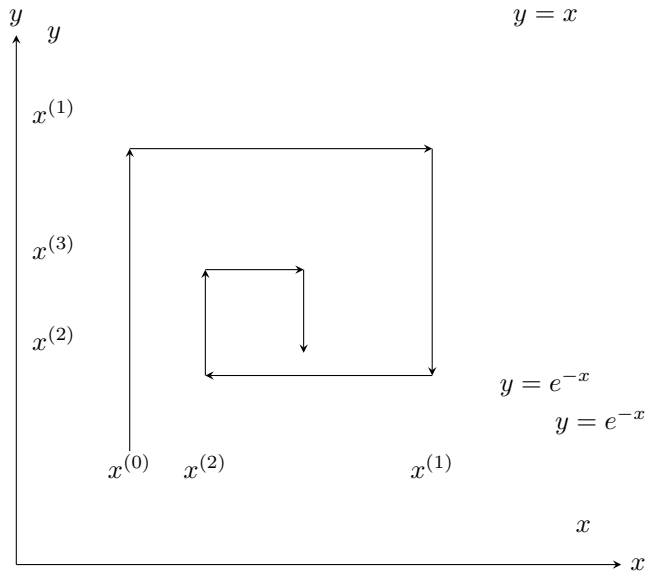
donde $f'(\hat{\mathrm{x}}^{(0)})$ se actualiza después de un número determinado de pasos. Este método es más lento.
La ventaja de este método es que no se requiere calcular la derivada de la función en todos los pasos, lo cual es numéricamente costoso.

1.6.2. Método modificado de Newton. Resulta de modificar la pendiente original. La iteración es:

$$x^{(j+1)} := x^{(j)} - m\frac{f(x^{(j)})}{f'(x^{(j)})}$$

donde m es un parámetro que puede, bien usado, evitar la divergencia del método sin él.

1.7. Método del Punto Fijo. Recordemos que nuestro problema inicial era el de resolver $f(x) = 0$.
A veces este problema se puede cambiar a un problema de punto fijo, $F(x) = x$ y se construye una sucesión $\{x^{(k)}\}$ que se inicia en $x^{(0)}$ y luego $x^{(k+1)} := F(x^{(k)})$.
Ejemplo: Resolver $f(x) = x + \ln x = 0$. Podemos resolver equivalentemente $F(x) = e^{-x} = x$.
Construímos la sucesión $x^{(k+1)} := e^{-x^{(k)}}$. Luego:



2. Teoremas de convergencia

Problema: Resolver el sistema de ecuaciones no lineales

$$\begin{array}{l} f_1(x_1, x_2, \cdots, x_n) = 0 \\ f_2(x_1, x_2, \cdots, x_n) = 0 \\ \qquad \vdots \\ f_n(x_1, x_2, \cdots, x_n) = 0 \end{array} \qquad \text{ó} \qquad f(\overline{x}) = \overline{0}.$$

Recordemos que muchas veces se cambia este problema a un problema de punto fijo de la forma $F(x) = x$ y se construye una sucesión $\{x^{(k)}\}$ que se inicia en $x^{(0)}$ y luego $x^{(k+1)} := F(x^{(k)})$.

Esto nos permitirá aplicar el teorema del punto fijo de Banach, teorema 3.20.

TEOREMA 4.3. *Sea $\|\cdot\|$ una norma en $\mathbb{R}^n$ y $F : \mathbb{R}^n \to \mathbb{R}^n$ una función tal que*

1. $\|F(x) - F(y)\| \leq L\|x - y\|, \quad \forall x, y \in B[x^{(0)}; r] = \{x \in \mathbb{R}^n / \|x - x^{(0)}\| \leq r\}$.
2. $\|F(x^{(0)}) - x^{(0)}\| \leq (1 - L)r$.

Entonces la sucesión $\{x^{(k)}\}$ dada por $x^{(k+1)} := F(x^{(k)})$, satisface:

(a) $\{x^{(k)}\} \subset B[x^{(0)}; r]$.

(b) *F tiene en $B[x^{(0)}; r]$ un punto fijo x^* único con $\lim_{k\to\infty} x^{(k)} = x^*$ y con las estimaciones a priori y a posteriori.*

Demostración: Es suficiente verificar las hipótesis del teorema del punto fijo de Banach con $D := B[x^{(0)}; r]$.
Como $D = B[x^{(0)}; r] \subset \mathbb{R}^n$ es cerrado y por la hipótesis (1); se cumplen la primera y tercera hipótesis del teorema del punto fijo de Banach. Solamente hay que probar que también se cumple la segunda hipótesis, es decir, que $F(D) \subset D$. Sea $x \in D = B[x^{(0)}; r]$, entonces se cumple

$$\begin{array}{rcl} \|F(x) - x^{(0)}\| & \leq & \|F(x) - F(x^{(0)})\| + \|F(x^{(0)}) - x^{(0)}\| \\ & \leq & L\|x - x^{(0)}\| + (1 - L)r \\ & \leq & L\, r + (1 - L)\, r = r \end{array}$$

esto es, $\|F(x) - x^{(0)}\| \leq r$, de donde $F(x) \in B[x^{(0)}; r]$. Por lo tanto $F(D) \subset D$. □

LEMA 4.4. *Sea $F \in C^1[a,b]$. Entonces F es continua sobre $[a,b]$ en el sentido de Lipschitz con $L := \max_{\xi\in[a,b]} |F'(\xi)|$.*

Demostración: Sean $x, y \in [a,b]$. Por el teorema del valor medio, existe ξ perteneciente al intervalo abierto con extremos x e y, tal que $F(x)-F(y) = F'(\xi)(x-y)$, entonces

$$|F(x) - F(y)| = |F'(\xi)||x-y| \leq \max_{\xi\in[a,b]} |F'(\xi)||x-y|, \qquad \forall x, y \in [a,b]. \square$$

LEMA 4.5. *Sea $g : [a,b] \to \mathbb{R}^n$ continua y $\|\cdot\|$ una norma en $\mathbb{R}^n$. Entonces*

$$\left\| \int_a^b g(t)dt \right\| \leq \int_a^b \|g(t)\| dt.$$

TEOREMA 4.6. *Sea $\phi \neq D \subset \mathbb{R}^n$ convexo, $U \subset \mathbb{R}^n$ abierto con $D \subset U$ y $F : U \to \mathbb{R}^n$ continuamente diferenciable. Para cualquier norma $\|\cdot\|$ de $\mathbb{R}^n$ se cumple*

$$\|F(x) - F(y)\| \leq \left(\sup_{\xi\in D} \|F'(\xi)\| \right) \|x-y\|, \qquad \forall x, y \in D.$$

Si D es compacto y las derivadas parciales son acotadas, entonces F es continua en el sentido de Lipschitz en D con constante

$$L := \sup_{\xi\in D} \|F'(\xi)\|.$$

Demostración: Se cumple que

$$\int_0^1 F'(x + t(y-x))(y-x)dt = F(y) - F(x).$$

De esto y usando el lema anterior se obtiene

$$\begin{aligned} \|F(y) - F(x)\| &= \left\| \int_0^1 F'(x + t(y-x))(y-x)dt \right\| \\ &\leq \int_0^1 \|F'(x + t(y-x))\| \, \|y-x\| dt \\ &\leq \sup_{\lambda\in[0,1]} \|F'(x + \lambda(y-x))\| \, \|y-x\|, \qquad \forall x, y \in D. \qquad \square \end{aligned}$$

Ejemplo: Consideremos el siguiente sistema no lineal:

$$\begin{aligned} x_1 &= 0{,}1x_1^2 + \sin x_2 \\ x_2 &= \cos x_1 + 0{,}1x_2^2 \end{aligned}$$

Entonces $F : \mathbb{R}^2 \to \mathbb{R}^2$ está definida por:

$$F(x) = F(x_1, x_2) = \begin{bmatrix} 0{,}1x_1^2 + \sin x_2 \\ \cos x_1 + 0{,}1x_2^2 \end{bmatrix} = \begin{bmatrix} f_1(x_1, x_2) \\ f_2(x_1, x_2) \end{bmatrix}.$$

Para $D := \{(x_1, x_2) \in \mathbb{R}^2 / \quad 0{,}75 \leq x_1 \leq 0{,}78, \quad 0{,}77 \leq x_2 \leq 0{,}80\}$ se cumple que $F(D) \subset D$. Además:

$$F'(x_1, x_2) = \begin{bmatrix} 0{,}2x_1 & \cos x_2 \\ -\sin x_1 & 0{,}2x_2 \end{bmatrix}$$

Eligiendo una norma:

$$\begin{aligned} &\sup_{\xi\in D} \|F'(\xi)\|_\infty \leq 0{,}74 \\ &\sup_{\xi\in D} \|F'(\xi)\|_1 < 0{,}878 \\ &\sup_{\xi\in D} \|F'(\xi)\|_F \leq 1{,}030, \end{aligned}$$

En este caso la velocidad de convergencia es lenta, porque la constante de Lipschitz es grande.
Analizando los valores propios de $F'(x^*)$, vemos que

$$\rho(F'(x^*)) \leq \|F'(x^*)\| \leq \sup_{\xi \in D} \|F'(\xi)\|$$

De esto se tiene que si $\rho(F'(x^*))$ no es pequeño, la velocidad de convergencia es lenta.

Convergencia local.

TEOREMA 4.7. *Sea x^* un punto fijo de $F : \mathbb{R}^n \to \mathbb{R}$ donde F es de clase C^1 en una vecindad de x^*. Si se cumple que $\rho(F'(x^*)) < 1$, entonces existe una vecindad $U(x^*)$ de x^* tal que la sucesión $\{x^{(k)}\}$ definida por $x^{(k+1)} := F(x^{(k)})$ converge a x^* para todo punto inicial $x^{(0)} \in U(x^*)$.*

Nota: Esto implica que las iteraciones del punto fijo tienen *convergencia local*.

DEFINICIÓN. *Sea $\{x^{(k)}\} \subset \mathbb{R}^n$ una sucesión que converge a $x^* \in \mathbb{R}$ con $x^{(k)} \neq x^*, \forall k \in \mathbb{N}$ y sea $\|\cdot\|$ una norma en $\mathbb{R}^n$:*

1. *Para $p \geq 1$ decimos que $\{x^{(k)}\}$ converge a x^* con por lo menos orden de convergencia p, si existe una constante $C > 0$ (para $p = 1, C \in \langle 0, 1\rangle$) y $n_0 \in \mathbb{N}$ tal que*

$$\|x^{(k+1)} - x^*\| \leq C\|x^{(k)} - x^*\|^p, \quad \forall k \geq n_0$$

2. *Si $\lim_{k\to\infty} \dfrac{\|x^{(k+1)} - x^*\|}{\|x^{(k)} - x^*\|} = 0$ se dice que $\{x^{(k)}\}$ converge a x^* de manera superlineal.*

Ejercicio: Probar que las iteraciones del método de las secantes tienen orden de convergencia igual a 1,6.

2.0.1. Método de Newton en $\mathbb{R}^n$. Para $f : \mathbb{R} \to \mathbb{R}$:

$$x^{(k+1)} := x^{(k)} - \frac{f(x^{(k)})}{f'(x^{(k)})}$$

Para $f : \mathbb{R}^n \to \mathbb{R}^n$:

$$x^{(k+1)} := x^{(k)} - \left[f'(x^{(k)})\right]^{-1} \cdot f(x^{(k)})$$

donde $f'(x^{(k)})$ es la matriz jacobiana.

Para obtener una iteración, resolvemos el sistema lineal

$$f'(x^{(k)})\,\overline{d} = f(x^{(k)}),$$

obteniendo $\overline{d}$ y luego hacemos $x^{(k+1)} := x^{(k)} - \overline{d}$.

TEOREMA 4.8. *Sea $f : \mathbb{R}^n \to \mathbb{R}^n$, y x^* un cero de f. Supongamos que se cumplen las condiciones:*

1. *f es de clase C^1 en una vecindad de x^*.*
2. *$f(x^*) \in \mathbb{R}^{n\times n}$ es regular.*

Entonces existe $\delta > 0$ tal que la sucesión $\{x^{(k)}\}$ del método de Newton está definida para todo $x^{(0)} \in B[x^*, \delta] := \{x \in \mathbb{R}^n / \|x - x^*\| \leq \delta\}$, y converge de manera superlineal a x^*.

3. *Supongamos además que se cumpla la condición de Lipschitz para f' en una vecindad bastante pequeña de x^*; es decir, si además existen $\eta > 0$ y $L > 0$ tales que*

$$\|f'(x) - f'(x^*)\| \leq L\|x - x^*\|, \quad \text{siempre que} \quad \|x - x^*\| \leq \eta$$

entonces $\{x^{(k)}\}$ converge a x^*, por lo menos cuadráticamente (orden 2).

Demostración: Se puede elegir un $\delta_1 > 0$ tan pequeño de modo que f' existe en $B[x^*, \delta_1]$ y

$$\|f'(x) - f'(x^*)\| \leq \frac{1}{2\|f'(x^*)^{-1}\|}, \qquad \forall x \in B[x^*, \delta_1] \qquad \ldots \qquad (*)$$

Para todo $x \in B[x^*, \delta_1]$, se cumple:

(a) $f'(x)$ es regular y $\|f'(x)^{-1}\| \leq 2\|f'(x^*)^{-1}\|$. De $(*)$, tenemos que

$$\|f'(x^*)^{-1}\|\|f'(x) - f'(x^*)\| \leq \frac{1}{2} < 1.$$

En el lema de perturbación 3.14 (pág. 36) con $A := f'(x^*)$ que es regular y $S := [f'(x) - f'(x^*)]$, se obtiene que $A + S = f'(x)$ es regular y

$$\|f'(x)^{-1}\| \leq \frac{\|f'(x^*)^{-1}\|}{1 - \|f'(x^*)^{-1}\|\|f'(x) - f'(x^*)\|}$$

Por tanto (Ejercicio)

$$\|f'(x)^{-1}\| \leq 2\|f'(x^*)^{-1}\|.$$

(b) Se cumple:

$$\|f'(x)^{-1} - f'(x^*)^{-1}\| \leq 2\|f'(x^*)^{-1}\|^2\|f'(x) - f'(x^*)\|$$

Esto se obtiene de lo sgte:

$$f'(x)^{-1} - f'(x^*)^{-1} = -f'(x)^{-1}[f'(x) - f'(x^*)]f'(x^*)^{-1}$$

Aplicando (a):

$$\begin{aligned} \|f'(x)^{-1} - f'(x^*)^{-1}\| &\leq \|f'(x)^{-1}\|\|f'(x) - f'(x^*)\|\|f'(x^*)^{-1}\| \\ &\leq 2\|f'(x^*)^{-1}\|^2\|f'(x) - f'(x^*)\|.\square \end{aligned}$$

Sea $F : B[x^*, \delta_1] \subset \mathbb{R}^n \to \mathbb{R}^n$ la función iterativa del método de Newton $x^{(k+1)} := F(x^{(k)})$ con $F(x) = x - f'(x)^{-1}f(x)$. Vamos a probar que la sucesión $x^{(k+1)} := F(x^{(k)})$ no sale de $B[x^*, \delta_1]$:

$$\begin{aligned} F(x) - x^* &= x - x^* - f'(x)^{-1}[f(x) - f(x^*)] \\ &= [f'(x^*)^{-1} - f'(x)^{-1}]f'(x^*)(x - x^*) - f'(x^*)^{-1}[f(x) - f(x^*) - f'(x^*)(x - x^*)] \\ &= [f'(x^*) - f'(x)^{-1}]f'(x^*)(x - x^*) - f'(x^*)^{-1}\int_0^1 [F'(x^* + t(x - x^*)) - F'(x^*)] \cdot (x - x^*)dt \end{aligned}$$

luego

$$\|F(x)-x^*\| \leq \{\|f'(x^*)-f'(x)^{-1}\|\|f'(x^*)\|+\|f'(x^*)^{-1}\|\int_0^1 \|F'(x^*+t(x-x^*))-F'(x^*)\|dt\}\|x-x^*\| \ldots (**)$$

Si hacemos $\varepsilon(x) := \|f'(x^*) - f'(x)^{-1}\|\|f'(x^*)\| + \|f'(x^*)^{-1}\|\int_0^1 \|F'(x^* + t(x - x^*)) - F'(x^*)\|dt$ en la última expresión, entonces

$$\|F(x) - x^*\| \leq \varepsilon(x)\|x - x^*\|$$

Aplicando (b):

$$\begin{aligned} \varepsilon(x) &\leq 2\|f'(x^*)^{-1}\|^2\|f'(x) - f'(x^*)\|\|f'(x^*)\| + \|f'(x)^{-1}\|\int_0^1 \|f'(x^* + t(x - x^*)) - f'(x^*)\|dt \\ &\leq 2\|f'(x^*)^{-1}\|\left\{\|f'(x^*)\|\|f'(x^*)^{-1}\|\|f'(x) - f'(x^*)\| + \int_0^1 \|f'(x^* + t(x - x^*)) - f'(x^*)\|dt\right\} \end{aligned}$$

por (a). Por la continuidad de f' en $B[x^*, \delta_1]$ y la existencia de $\delta \in [0, \delta_1]$ tal que:

$$\|F(x) - F(x^*)\| = \|F(x) - x^*\| \leq \frac{1}{2}\|x - x^*\|, \quad \forall x \in B[x^*, \delta]$$

se tiene convergencia superlineal,

$$\|x^{(k+1)} - x^*\| \leq \varepsilon(x^{(k)})\ \|x^{(k)} - x^*\| \quad \dots \quad (\alpha)$$

pues $\lim\limits_{k\to\infty} \dfrac{\|x^{(k+1)} - x^*\|}{\|x^{(k)} - x^*\|} = 0$, lo cual es cierto pues $\lim\limits_{k\to\infty} \varepsilon(x^{(k)}) = 0$.
De la condición de Lipschitz

$$\begin{aligned}\varepsilon(x^{(k)}) &\leq 2\|f'(x^*)^{-1}\| \left\{ \|f'(x)\|\|f'(x^*)^{-1}\|\|f'(x^{(k)}) - f'(x^*)\| + \textstyle\int_0^1 \|f'(x^* + t(x - x^*)) - f'(x^*)\| dt \right\} \\ &\leq 2\ L\|f'(x^*)^{-1}\| \left\{ \|f'(x^*)\|\|f'(x^*)^{-1}\| + \frac{1}{2} \right\} \|x^{(k)} - x^*\|\end{aligned}$$

por (3). Haciendo $G := 2\ L\|f'(x^*)^{-1}\| \left\{ \|f'(x^*)\|\|f'(x^*)^{-1}\| + \dfrac{1}{2} \right\}$ y reemplazando en (α), tenemos que

$$\|x^{(k+1)} - x^*\| \leq G\ \|x^{(k)} - x^*\|^2. \quad \square$$

La ventaja del método de Newton es que, en caso de convergencia, la convergencia es rápida (al menos de orden 2). Las desventajas principales son : la convergencia es lineal; además, en cada paso se tiene que solucionar un sistema lineal.
Problema: Encontrar un método para obtener convergencia global (esto es, que converja para todo $x^{(0)} \in \mathbb{R}^n$ inicial).

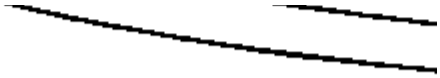


FIGURA 2. Movimiento en direcciones descendentes

3. Métodos de Minimización

Hemos visto que en el caso de que el método de Newton converja, la velocidad de convergencia es muy rápida. Sin embargo, según el teorema 4.8 no hay ninguna garantía para la convergencia. Luego se tiene que buscar otros métodos. Una idea es cambiar el problema de solucionar un sistema de ecuaciones no lineales es un problema de minimización

$$\begin{aligned} (P): &\qquad \text{Buscar } x^* \ / \ f(x^*) = 0, \quad f : \mathbb{R}^n \to \mathbb{R}^n \\ (M): &\qquad \text{Minimizar } h(x) := \|f(x)\|_2^2 = \sum_{i=1}^{n} [f_i(x)]^2 \end{aligned}$$

El siguiente lema muestra que los problemas (P) y (M) son equivalentes:

LEMA 4.9. *Si* $\det(f'(x^*)) \neq 0$, *entonces se cumple:*

$$f(x^*) = 0 \quad \Longleftrightarrow \quad 0 = h(x^*) \leq h(x), \quad \forall x \in \mathbb{R}^n \quad \Longleftrightarrow \quad \nabla h(x^*) = 0$$

Demostración:

($\Longrightarrow$) $f(x^*) = 0$ implica $f_i(x^*) = 0, \quad i = 1, 2, \ldots, n$. De esto $h(x^*) = 0 \leq h(x), \quad \forall x \in \mathbb{R}^n \quad \Longrightarrow \quad \nabla h(x^*) = 0$.

($\Longleftarrow$) Si $0 = \nabla h(x^*)$ entonces

$$0 = \nabla h(x^*) = \nabla \left(\sum_{i=1}^{n} [f_i]^2(x^*) \right) = 2 \sum_{i=1}^{n} \nabla f_i(x^*) \ f_i(x^*) = 2 \ f'(x^*)^t f(x^*)$$

lo cual implica $f'(x^*)^t f(x^*) = 0$. Como $\det(f'(x^*)^t) \neq 0$ se obtiene $f(x^*) = 0$.

También se cumple $h(x^*) = 0 \leq h(x), \quad \forall x \in \mathbb{R}^n$. □

DEFINICIÓN. *Sea* $h : \mathbb{R}^n \to \mathbb{R}$. *Se dice que* $p \in \mathbb{R}^n$ *es una dirección descendente para* h *en* $x \in \mathbb{R}^n$ *si existe* $t_0 > 0$ *tal que*

$$h(x + tp) < h(x), \quad \forall t \in \langle 0, t_0]$$

LEMA 4.10. *Sea* $h : \mathbb{R}^n \to \mathbb{R}$ *continuamente diferenciable. Entonces* $p \in \mathbb{R}^n$ *es una dirección descendente si* $\nabla h(x)^t p < 0$.

Demostración:

$$\lim_{t \to 0^+} \frac{h(x + tp) - h(x)}{t} = \nabla h(x)^t p$$

implica $h(x + tp) - h(x) < 0$ para $0 \leq t$ bastante pequeño ó $h(x + tp) < h(x)$. □

Estando en $x^{(k)}$, si encontramos una dirección descendente $p^{(k)} \in \mathbb{R}^n$ y definimos

$$x^{(k+1)} := x^{(k)} + t_k p^{(k)}$$

para t_k bastante pequeño, nos vamos acercando al mínimo de la función, lo cual implicaría que nos estamos acercando a la raíz de (P) .

Según esta idea se obtienen los siguientes métodos:

1. *Método modificado de Newton*:

$$x^{(k+1)} := x^{(k)} - t_k f'(x^{(k)})^{-1} f(x^{(k)}), \quad k = 0, 1, 2, \ldots$$

$t_k \in [0, 1]$, $t_k := 2^{-j}$ con j como el entero no negativo más pequeño tal que

$$h(x^{(k)}) - h(x^{(k)} + 2^{-j} p^{(k)}) > 0$$

y $p^{(k)} := -f'(x^{(k)})^{-1} f(x^{(k)})$ que es una dirección descendente. En efecto:

$$\begin{aligned} \nabla h(x^{(k)})^t p^{(k)} &= (2 f(x^{(k)})^t f'(x^{(k)}))(-f'(x^{(k)})^{-1} f(x^{(k)})) \\ &= -2 f(x^{(k)})^t \; I \; f(x^{(k)}) = -2\|f(x^{(k)})\|_2^2 < 0 \end{aligned}$$

Con este método se obtiene un radio de convergencia más grande que en el método de Newton. Si $x^{(k)}$ está bastante cercano a la solución, se puede mostrar que $(*)$ se cumple para $j = 0$, $t_k = 1$, lo que da una iteración del método de Newton. Luego el orden de convergencia es también 2.

2. *Método del descenso más rápido*:

$$x^{(k+1)} := x^{(k)} - t_k \nabla h(x^{(k)}).$$

Aquí $p^{(k)} = -\nabla h(x^{(k)})$ que es una dirección descendente, pues

$$\nabla h(x^{(k)})^t p(x^{(k)}) = \nabla h(x^{(k)})^t \nabla h(x^{(k)}) = -\|\nabla h(x^{(k)})\|_2^2 < 0$$

Hay varias maneras de elegir t_k:
(a)

$$x^{(k+1)} := x^{(k)} - \frac{h(x^{(k)})}{\|\nabla h(x^{(k)})\|_2^2} \nabla h(x^{(k)})$$

(b) *Búsqueda exacta*: Determinar t_k tal que

$$h(x^{(k)} - t_k p^{(k)}) = \min_{t \in [0,1]} h(x^{(k)} - t p^{(k)})$$

(c) *Prueba de Armijo*: Determinar $t_k := 2^{-j}$, donde j es el entero no negativo más pequeño, tal que para $\beta \in [0, 1/2]$ se cumpla

$$h(x^{(k)} + 2^{-j} p^{(k)}) - h(x^{(k)}) \leq \beta 2^{-j} \nabla h(x^{(k)})^t p^{(k)}$$

En los casos (b) y (c) se cumple $h(x^{(k+1)}) < h(x^{(k)})$ y se obtiene convergencia global. El orden de convergencia es solamente 1.

3.1. Métodos Quasi-Newton.

$$x^{(k+1)} := x^{(k)} - B_k^{-1} f(x^k), \quad j = 0, 1, 2, \ldots$$

donde $\{B_k\}$ es una sucesión de matrices adecuadas.
[Revise Luemberger, Programación lineal y no lineal]

3.2. Cálculo de ceros de polinomios.

TEOREMA 4.11. *Un polinomio de grado n tiene exactamente n ceros en el plano complejo, conviniendo que cada cero debe contarse un número de veces igual a su multiplicidad.*

TEOREMA 4.12. *Todos los ceros del polinomio*

$$P_n(z) = a_n z^n + a_{n-1} z^{n-1} + \cdots + a_2 z^2 + a_1 z + a_0$$

donde $a_k \in \mathbb{R}$ *o* $a_k \in \mathbb{C}, \quad k = 0, 1, \ldots, n$, *se encuentran en el disco cerrado cuyo centro está en el origen del plano complejo y cuyo radio es*

$$\rho = 1 + |a_n|^{-1} \max_{0 \le k < n} |a_k|$$

Demostración: Sea $C = \max_{0 \le k < n} |a_k|$ de modo que $\rho = 1 + |a_n|^{-1} C$ ó $C|a_n|^{-1} = \rho - 1$.
Si $|z| > \rho$, entonces

$$\begin{aligned}
|P_n(z)| &\ge |a_n z^n| - |a_{n-1} z^{n-1} + \cdots + a_2 z^2 + a_1 z + a_0| \\
&\ge |a_n z^n| - \sum_{k=0}^{n-1} |a_k| |z|^k \ge |a_n z^n| - \sum_{k=0}^{n-1} C|z|^k \\
&= |a_n z^n| - C|z|^n \sum_{k=0}^{n-1} \frac{1}{|z|^{n-k}} = |a_n z^n| - C|z|^n \sum_{k=1}^{n} \frac{1}{|z|^k} \\
&> |a_n z^n| - C|z|^n \frac{1}{|z|} \left(\frac{1}{1 - \dfrac{1}{|z|}} \right) \\
&= |a_n z^n| \left\{ 1 - C|a_n|^{-1} (|z| - 1|)^{-1} \right\} \\
|P_n(z)| &> |a_n z^n| \left\{ 1 - C|a_n|^{-1} (\rho - 1|)^{-1} \right\} = 0
\end{aligned}$$

de donde $P_n(z) \neq 0$. De esto, z no puede ser una raíz de P_n. □

Ejemplo: Hallar un disco cerrado en el origen que contenga todos los ceros del polinomio

$$P_4(z) = 7z^4 - 3z^3 - 4z^2 + 3^z + 1$$

Basta tomar

$$\begin{aligned}
\rho &= 1 + |a_4|^{-1} \max_{0 \le k < 4} |a_k| = 1 + 7^{-1} \max\{|1|, |3|, |-4|, |-3|\} \\
&= 1 + 7^{-1} 4 = \frac{11}{4}
\end{aligned}$$

Así tenemos el disco $D = \left\{ z \in \mathbb{C} \ / \ |z| < \dfrac{11}{4} \right\}$.

Sea $S_n(z) = z^n P_n(1/z)$. Entonces

$$\begin{aligned}
S_n(z) &= z^n \left[a_n \left(\frac{1}{z} \right)^n + a_{n-1} \left(\frac{1}{z} \right)^{n-1} + \cdots + \left(\frac{1}{z} \right) a_1 + a_0 \right] \\
&= a_n + a_{n-1} z + \cdots + a_1 z^{n-1} + a_0 z^n
\end{aligned}$$

Si $z_0 \neq 0$ se cumple:

$$P_n(z_0) = 0 \quad \Longleftrightarrow \quad S_n \left(\frac{1}{z_0} \right) = 0$$

Por lo tanto se obtiene el siguiente teorema:

TEOREMA 4.13. *Si todos los ceros de* S_n *están en el disco* $\{z : |z| \le \rho'\}$, *entonces todos los ceros no nulos de* P_n *se encuentran fuera del disco* $\{z : |z| < \rho'^{-1}\}$.

Ejemplo: Para el ejemplo anterior:

$$\begin{aligned} S_4(z) &= z^4 P_4(z) = z^4\left[7\left(\frac{1}{z}\right)^n - 3\left(\frac{1}{z}\right)^3 - 4\left(\frac{1}{z}\right)^2 + 3\left(\frac{1}{z}\right) + 1\right] \\ &= 7 - 3z - 4z^2 + 3z^3 + z^4 \end{aligned}$$

$$\begin{aligned} \rho' &= 1 + |A_4|^{-1} \max_{0\le k<4}\{|A_k|\} \\ &= 1 + 1^{-1}\,\text{máx}\{|7|, |-3|, |-4|, |3|\} = 1 + 7 = 8 \end{aligned}$$

Entonces los ceros de P_4 se encuentran fuera del disco de radio $\rho'^{-1} = 1/8$. Por lo tanto, los ceros de P_4 se encuentran en el anillo $\left\{z \in \mathbb{C} : \frac{1}{8} \le |z| \le \frac{11}{7}\right\}$ del plano complejo.

3.2.1. Algoritmo de Horner (Multiplicación anidada, división sintética). Dado un polinomio P_n y un número complejo z_0, el algoritmo de Horner proporciona $P_n(z_0)$ y el polinomio

$$Q_{n-1}(z) = \frac{P_n(z) - P_n(z_0)}{z - z_0} \quad \dots \quad (\alpha_1)$$

Se cumple:

$$P_n(z) = (z - z_0)Q_{n-1}(z) + P_n(z_0) \quad \dots \quad (\alpha_2)$$

Sea $Q_{n-1}(z) := b_{n-1}z^{n-1} + b_{n-2}z^{n-2} + \cdots + b_1 z + b_0$. Reemplazando en (α_2):

$$\begin{aligned} \sum_{k=0}^{n} a_k z^k &= (z - z_0)\sum_{k=0}^{n-1} b_k z^k + P_n(z_0) \\ &= \sum_{k=0}^{n-1} b_k z^{k+1} - z_0 \sum_{k=0}^{n-1} b_k z^k + P_n(z_0) \\ &= (-z_0 b_0 + P_n(z_0)) + \sum_{k=1}^{n} b_{k-1} z^k - z_0 \sum_{k=1}^{n-1} b_k z^k \\ &= (-z_0 b_0 + P_n(z_0)) + \sum_{k=1}^{n-1} (b_{k-1} - z_0 b_k) z^k + b_{n-1} z^n \end{aligned}$$

de esto obtenemos

$$\begin{aligned} &a_0 = -z_0 b_0 + P_n(z_0) \\ &a_k = b_{k-1} - z_0 b_k \qquad k = 1, 2, \dots, n-1 \\ &a_n = b_{n-1} \end{aligned}$$

de donde

$$\begin{aligned} &b_{n-1} = a_n \\ &b_{k-1} = a_k + z_0 b_k, \qquad k = n-1, n-2, \dots, 1 \\ &P_n(z_0) = a_0 + z_0 b_0 \end{aligned}$$

Entrada:	$n, a_0, a_1, \cdots, a_n, z_0$
$b_{n-1} := a_n$	
Para $k = n-1, n-2, \cdots, 0$	
	$b_{k-1} := a_k + z_0 b_k$
Salida:	$P_n(z_0) = b_{-1}, b_0, b_1, \cdots, b_{n-1}$

Ahora deseamos encontrar las raíces del polinomio. Para esto, podemos aplicar el método de Newton, pero necesitamos para ello la derivada del polinomio. Para esto tenemos el siguiente

TEOREMA 4.14. *Sea* $P(x) = a_n x^n + \cdots + a_1 x + a_0$. *Sean* (α_j, β_j) *para* $j = n, n-1, \cdots, 0$, *definidos por*

$$\begin{aligned}(\alpha_n, \beta_n) &= (a_n, 0)\\ (\alpha_j, \beta_j) &= (a_j + x\,\alpha_{j+1}, \alpha_{j+1} + x\,\beta_{j+1}), \quad j = n-1, n-2, \cdots, 0\end{aligned}$$

Entonces $\alpha_0 = P(x)$ *y* $\beta_0 = P'(x)$

TEOREMA 4.15 (Bodewig - 1946). *Sean* $x^{(k)}$ *y* $x^{(k+1)}$ *dos iteraciones sucesivas que resultan de la aplicación del método de Newton a un polinomio* P_n *de grado* n. *Entonces existe un cero de* P_n *en una vecindad de* $x^{(k)}$ *de radio* $\|x^{(k)} - x^{(k+1)}\|$ *en el plano complejo.*

3.3. Método de Bairstrow.

TEOREMA 4.16. *Si* $P_n(x) = a_n x^n + a_{n-1}x^{n-1} + \cdots + a_0$, $a_n \neq 0, a_i \in \mathbb{R}$ *y* z_0 *es un cero complejo de* P_n, *entonces* $\overline{z}_0$ *es también un cero de* P_n *y* $(x - z_0)(x - \overline{z}_0)$ *es un factor cuadrático real de* P_n.

Demostración: Como z_0 es un cero de P_n

$$P_n(z_0) = a_n z_0^n + a_{n-1} z_0^{n-1} + \cdots + a_1 z_0 + a_0 = 0$$

Tomando conjugadas a ambos miembros:

$$\overline{0} = 0 = a_n \overline{z_0}^n + a_{n-1}\overline{z_0}^{n-1} + \cdots + a_1 \overline{z_0} + a_0 = P_n(\overline{z_0})$$

entonces $\overline{z_0}$ es también un cero de P_n. Como z_0 no es un número real se tiene que z_0 y $\overline{z_0}$ son ceros distintos de P_n. Por consiguiente $P_n(x)$ contiene al factor cuadrático

$$\begin{aligned}(x - z_0)(x - \overline{z_0}) &= x^2 - (z_0 + \overline{z_0})x + z_0\,\overline{z_0}\\ &= x^2 - 2Re(z_0)x + |z_0|^2\end{aligned}$$

que es un factor cuadrático irreducible. □

TEOREMA 4.17. *Si el polinomio* $P_n(x) = a_n x^n + a_{n-1}x^{n-1} + \cdots + a_1 x + a_0$ *se divide entre el polinomio cuadrático* $x^2 - rx - q$, *entonces el cociente y el residuo están dados por*

$$\begin{aligned}Q_{n-2}(x) &= b_n x^{n-2} + b_{n-1}x^{n-3} + \cdots + b_3 x + b_2\\ R(x) &= b_1(x - r) + b_0\end{aligned}$$

con

$$P_n(x) = Q_{n-2}(x)(x^2 - rx - q) + R(x)$$

Los cuales pueden calcularse de manera recursiva utilizando

$$b_k = a_k + rb_{k+1} + qb_{k+2}, \quad k = n, n-1, \cdots, 0 \qquad \ldots \qquad (+)$$

donde $b_{n+1} = b_{n+2} = 0$.

Demostración: Tenemos (probar reemplazando Q_{n-2}):

$$P_n(x) = b_n x^n + (b_{n-1} - rb_n)x^{n-1} + \sum_{k=2}^{n-2}(b_k - rb_{k+1} - qb_{k+2})x^k + (b_1 - rb_2 - qb_3)x + (b_0 - rb_1 - qb_2) \quad \square$$

Para calcular las raíces de P_n buscamos un factor cuadrático real del tipo $x^2 - rx - q$ con $r, q \in \mathbb{R}$. En este proceso de división, se tiene

$$\begin{aligned}b_0 &= b_0(r, q)\\ b_1 &= b_1(r, q)\\ R(x) &= b_1(x - r) + b_0\end{aligned}$$

En el esquema de Bairstrow, este sistema no lineal se resuelve por el método de Newton:

$$\begin{pmatrix} r^{(k+1)} \\ q^{(k+1)} \end{pmatrix} = \begin{pmatrix} r^{(k)} \\ q^{(k)} \end{pmatrix} - \left[\begin{array}{cc} \dfrac{\partial b_0}{\partial r} & \dfrac{\partial b_0}{\partial q} \\ \dfrac{\partial b_1}{\partial r} & \dfrac{\partial b_1}{\partial q} \end{array} \right]^{-1} \Bigg|_{\substack{q=q^{(k)} \\ r=r^{(k)}}} \begin{pmatrix} b_0(r^{(k)}, q^{(k)}) \\ b_1(r^{(k)}, q^{(k)}) \end{pmatrix} \quad \cdots \quad (++)$$

Definiendo

$$c_k := \frac{\partial b_k}{\partial r}, \quad d_k := \frac{\partial b_{k-1}}{\partial q}$$

En el teorema anterior, derivando a ambos miembros de (+), se obtiene

$$\begin{aligned} &\frac{\partial b_k}{\partial r} = b_{k+1} + r\frac{\partial b_{k+1}}{\partial r} + q\frac{\partial b_{k+2}}{\partial r} \\ &c_k = b_{k+1} + r\, c_{k+1} + q\, c_{k+2} \\ &c_{n+1} = c_n = 0 \end{aligned}$$

Esto es, $P_(x) = Q_{n-2}(x)(x^2 - rx - q) + R(x)$. Del mismo modo, para q, obtenemos

$$\begin{aligned} &\frac{\partial b_k}{\partial q} = b_{k+1} + r\frac{\partial b_{k+1}}{\partial q} + q\frac{\partial b_{k+2}}{\partial q} \\ &d_k = b_{k+1} + r\, d_{k+1} + q\, d_{k+2} \\ &d_{n+1} = d_n = 0 \end{aligned}$$

Usando (++), llegamos al sistema

$$\begin{bmatrix} c_0 & c_1 \\ c_1 & c_2 \end{bmatrix} \begin{bmatrix} \Delta r^{(k)} \\ \Delta q^{(k)} \end{bmatrix} = \begin{bmatrix} b_0(r^{(k)}, q^{(k)}) \\ b_1(r^{(k)}, q^{(k)}) \end{bmatrix}$$

donde

$$\begin{bmatrix} \Delta r^{(k)} \\ \Delta q^{(k)} \end{bmatrix} = \begin{bmatrix} r^{(k+1)} - r^{(k)} \\ q^{(k+1)} - q^{(k)} \end{bmatrix}$$

Resolviendo el sistema: hacemos

$$\Delta = \begin{vmatrix} c_0 & c_1 \\ c_1 & c_2 \end{vmatrix}$$

De donde:

$$\begin{aligned} r^{(k+1)} &= r^{(k)} + \frac{1}{\Delta}(b_1 c_1 - b_0 c_2) \\ q^{(k+1)} &= q^{(k)} + \frac{1}{\Delta}(b_0 c_1 - b_1 c_0) \end{aligned}$$

Capítulo 5

Aproximación lineal

1. Introducción

En física, el siguiente problema es típico: dado un conjunto de puntos $\{(x_i, y_i)\}_{i=1}^n$, y una familia de rectas $\{y = ax + c / x \in \mathbb{R}\}$, hallar los coeficientes a, c que minimicen la sumas de los cuadrados de las distancias de los puntos a la recta (esto es lo que se llamará *recta mínimo cuadrática*) . Esto se puede expresar como:

$$\min_{(a,c)\in\mathbb{R}^2} \sum_{i=1}^{n} (y_i - ax_i - c)^2$$

el problema anterior es equivalente al siguiente problema:

$$\min_{x\in\mathbb{R}^n} \|Ax - b\|_2 = \left\| \begin{bmatrix} x_1 & 1 \\ x_2 & 1 \\ \vdots & \vdots \\ x_n & 1 \end{bmatrix} \begin{bmatrix} a \\ c \end{bmatrix} - \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} \right\|_2$$

donde

$$A := \begin{bmatrix} x_1 & 1 \\ x_2 & 1 \\ \vdots & \vdots \\ x_n & 1 \end{bmatrix}, \qquad x := \begin{bmatrix} a \\ c \end{bmatrix}, \qquad b := \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

Sea $A \in \mathbb{R}^{m\times n}$, $m \geq n$.

Formulamos entonces, de manera más general, el siguiente problema: buscar una solución $x \in \mathbb{R}^n$ tal que $Ax = b$ cuando se tienen más ecuaciones que variables. Una alternativa, es solucionar el problema equivalente

$$\min_{x\in\mathbb{R}^n} \|Ax - b\|.$$

Eligiendo la norma $\|\cdot\|_1$ o $\|\cdot\|_\infty$ se obtiene un problema de optimización lineal. En caso de que se trate de $\|\cdot\|_2$, se obtiene el problema del mínimo de los cuadrados más pequeños. Este último es conocido como el problema de aproximación lineal:

$$\min_{x\in\mathbb{R}^n} \|Ax - b\|_2. \tag{8}$$

2. Ecuaciones normales

TEOREMA 5.1. *Sea $A \in \mathbb{R}^{m\times n}$, $m \geq n$ y el problema de aproximación lineal:*

$$\min \|Ax - b\|_2, \quad x \in \mathbb{R}^n. \tag{9}$$

Entonces se cumplen:

1. *$x^* \in \mathbb{R}^n$ es solución de (9) sí, y sólo si $A^tAx^* = A^tb$, es decir, si se cumplen las ecuaciones normales.*

2. *El conjunto*
$$L = \{x \in \mathbb{R}^n : A^tAx = A^tb\}$$
de las soluciones de (9) es un subespacio no vacío, afín de $\mathbb{R}^n$*. Además se cumple* $Ax_1 = Ax_2$*, para todo* $x_1, x_2 \in L$*.*
3. *El problema (9) tiene una solución única sí y sólo si* $\operatorname{rang}(A) = n$*.*
4. *De todas las soluciones de (9) existe exactamente una solución con norma de Euclides minimal.*

Demostración.

1. Definimos $f : \mathbb{R}^n \to \mathbb{R}$ por
$$f(x) := \frac{1}{2}\|Ax - b\|_2^2 = \frac{1}{2}(Ax - b)^t(Ax - b)$$
Solucionar (9) es equivalente a solucionar mín $f(x)$. Sea $x^* \in \mathbb{R}^n$ una solución de (9). Entonces
$$\nabla f(x^*) = 0 \quad \text{implica} \quad A^tAx^* - A^tb = 0$$
esto es, $A^tAx^* = A^tb$. Luego x^* es una solución de las ecuaciones normales. Recíprocamente, sea x^* una solución de las ecuaciones normales, entonces (¡verifique!):
$$f(x) - f(x^*) = \frac{1}{2}\big[A(x - x^*)\big]^tA(x - x^*) + (A^tAx^* - A^tb)^t(x - x^*).$$
Luego
$$f(x) - f(x^*) = \frac{1}{2}\big\|A(x - x^*)\big\|_2^2 \geq 0, \tag{10}$$
lo cual implica que $f(x) \geq f(x^*)$, entonces x^* es solución de (9).
2. Primero se tiene que mostrar que $L \neq \emptyset$.
Se cumple: el sistema $Ax = b$ tiene solución sí y sólo si
$$y \in \operatorname{Nu}(A^t) \quad \text{implica} \quad b^ty = 0$$
En efecto, si $Ax = b$ tiene solución, entonces existe $x \in \mathbb{R}^n$ satisfaciendo
$$(A^ty)^tx = y^tAx = y^tb, \qquad y \in \mathbb{R}^m.$$
Por lo tanto
$$y \in \operatorname{Nu}(A^t) \text{ implica } A^ty = 0 \text{ y luego } y^tb = 0.$$
El recíproco se deja como ejercicio.
Ahora, sea $x \in \operatorname{Nu}(A^tA)^t = \operatorname{Nu}(A^tA)$, entonces
$$\|Ax\|_2^2 = x^t(A^tAx) = 0,$$
de donde $Ax = 0$ y
$$(A^tb)^tx = b^t(Ax) = 0.$$
Por la afirmación anterior, $L \neq \emptyset$.
Sean $x_1, x_2 \in L, \lambda \in \mathbb{R}$, entonces
$$\begin{aligned} A^tA(\lambda x_1 + (1 - \lambda)x_2) &= \lambda A^tAx_1 + (1 - \lambda)A^tAx_2 \\ &= \lambda A^tb + (1 - \lambda)A^tb = A^tb. \end{aligned}$$
Esto implica que $\lambda x_1 + (1 - \lambda)x_2 \in L$. Por lo tato L es afín.
Sean $x_1, x_2 \in L$, entonces $f(x_1) = f(x_2)$ y por (10)
$$0 = f(x_1) - f(x_2) = \frac{1}{2}\big\|A(x_1 - x_2)\big\|_2^2,$$
de donde $Ax_1 = Ax_2$.

3. $\mathrm{Nu}(A^tA) = \mathrm{Nu}(A)$ (¡verifíquelo!). Esto implica que $A^tA \in \mathbb{R}^{n\times n}$ es regular si $\mathrm{rang}(A) = n$. Luego (9) tendría solución única.
4. Sea $x^* \in L$, entonces $L \cap \{x \in \mathbb{R}^n / \|x\|_2 \leq \|x^*\|_2\} =: B$ es compacto (L es cerrado y el otro conjunto compacto). La función continua $\|\cdot\|_2$ posee un mínimo en $B \subset L$, luego también lo tiene en L.

   La unicidad de la solución se sigue del hecho que si $x_1, x_2 \in L$ son dos soluciones con norma minimal, entonces $\|x\|_1 = \|x\|_2$, y luego como L es afín $\frac{1}{2}(x_1 + x_2) \in L$ y

$$\left\|\frac{1}{2}(x_1 + x_2)\right\|_2 \leq \frac{1}{2}\big(\|x_1\|_2 + \|x_2\|_2\big) = \|x_1\|_2,$$

   de donde

$$\frac{1}{2}\|x_1 + x_2\| = \|x_1\|_2 = \|x_2\|_2.$$

   Luego

$$\|x_1 - x_2\|_2^2 = 2\big(\|x_1\|_2^2 + \|x_2\|_2^2\big) - \|x_1 + x_2\|_2^2 = 0,$$

   de donde $x_1 = x_2$.

□

3. Tratamiento numérico

Numéricamente, el problema de aproximación lineal (9) se trata de la manera siguiente: por el método de Householder o Givens se determina una matriz ortogonal $Q \in \mathbb{R}^{m\times n}$ tal que

$$Q^tA = R = \begin{bmatrix} R_1 \\ 0 \end{bmatrix} \begin{matrix} \leftarrow n \\ \leftarrow m-n \end{matrix} \qquad \text{y} \qquad Q^tb = \begin{bmatrix} c \\ d \end{bmatrix} \begin{matrix} \leftarrow n \\ \leftarrow m-n \end{matrix}$$

donde R_1 es una matriz triangular superior, $R_1 \in \mathbb{R}^{n\times n}$.
Si $\mathrm{rang}(A) = n$, R_1 es regular. Luego los elementos de la diagonal son distintos de cero.
Sea $x \in \mathbb{R}^n$, se cumple:

$$\begin{aligned} \|Ax - b\|_2^2 &= \|Q^t(Ax - b)\|_2^2 = \|Q^tAx - Q^tb\|_2^2 = \left\|\begin{bmatrix} R_1 \\ 0 \end{bmatrix} x - \begin{bmatrix} c \\ d \end{bmatrix}\right\|_2^2 \\ &= \|R_1x - c\|_2^2 + \|d\|_2^2 \end{aligned}$$

La solución se obtiene de $R_1x - c = 0$.

Para el caso en que la matriz A no tenga $\mathrm{rang}(A) = n$ o las columnas de A son "casi"linealmente dependientes, se deben utilizar otros métodos (problemas de buscar valores propios). El método numérico dado es más eficiente que aplicar el método de Cholesky a las ecuaciones normales ($A^tAx = A^tb$), porque A^tA tiene una pésima condición: para $A \in \mathbb{R}^{n\times n}$,

$$\begin{aligned} \mathrm{cond}_2(A) &= \|A^tA\|_2\|A^{-1}A^{-t}\|_2 = \rho(A^tA)\rho(A^{-1}A^{-t}) \\ &= \rho(A^2)\rho((A^2)^{-1}) = \mathrm{cond}_2(A^2). \end{aligned}$$

4. Ejercicios

1. Realice el ajuste de los datos de la tabla

x_i	1,1	1,9	2,7	4,3	5,1	7,8
y_i	11,2	16,8	18,7	8,1	2,7	14,3

   mediante una combinación lineal de las funciones 1, $\sin(x)$, $\cos(x)$.

2. Sea $A \in \mathbb{R}^{m\times n}$, $b \in \mathbb{R}^m$ y $\alpha > 0$. Defina $F : \mathbb{R}^n \to \mathbb{R}$ mediante
$$F(x) = \|Ax - b\|_2^2 + \alpha\|x\|_2^2.$$
Demuestre que F alcanza un mínimo cuando x es solución de la ecuación
$$(A^TA + \alpha I)x = A^Tb.$$
Demuestre que cuando x se define de esta manera,
$$F(x + h) = F(x) + (Ah)^TAh + \alpha h^Tx.$$

3. Encuentre la solución en mínimos cuadrados del sistema
$$\begin{bmatrix} x & y \end{bmatrix} \begin{bmatrix} 3 & 2 & 1 \\ 2 & 3 & 2 \end{bmatrix} = \begin{bmatrix} 3 & 0 & 1 \end{bmatrix}.$$

4. En un trabajo relacionado con el estudio de la eficiencia de la utilización de la energía por las larvas de la polilla modesta (*Pachysphinx modesta*), L. Schroeder utilizó los siguientes datos para determinar una relación entre W, el peso de las larvas vivas en gramos, y R, el consumo de oxígeno de las larvas en mililitros/hora. Por razones biológicas, se supone que entre W y R existe una relación de la forma
$$R = bW^a.$$
   a) Encuentre el polinomio lineal de mínimos cuadrados asociado a la fórmula anterior, y resuelva el problema de mínimos cuadrados hallando estimados de a y b. Calcule además el error asociado.
   b) Modifique la ecuación de la parte anterior para ajustarla al modelo
   $$R = b \cdot W^a \cdot W^{c \ln W}$$
   y calcule los nuevos parámetros.

   Los datos a utilizar se presentan en la siguiente tabla:

W	0,017	0,087	0,085	0,020	0,233	4,83	5,53
R	0,154	0,296	0,260	0,180	0,537	4,66	6,94

Capítulo 6

Interpolación

Las fórmulas de interpolación constituyen los puntos de partida de las derivaciones de muchos métodos del análisis numérico.

En general, para la solución del problema de interpolación se busca una función $g(x, \alpha_0, \ldots, \alpha_r)$ de la cual se eligen los parámetros $\alpha_0, \ldots, \alpha_r$, tal que la función asuma los valores de otra función o de una tabla, como

$$\{(x_i, y_i)\}_{i=1}^n, \qquad g(x_i, \alpha_0, \ldots, \alpha_r) = y_i, \quad i = 0, \ldots, n.$$

Como ejemplos:

1. En la interpolación polinomial:

$$g(x, \alpha_0, \ldots, \alpha_m) = \alpha_0 + \alpha_1 x + \alpha_2 x^2 + \cdots + \alpha_r x^r$$

2. Para funciones periódicas, se puede elegir:

$$g(x, \alpha_0, \ldots, \alpha_m) = \alpha_0 + \alpha_1 \operatorname{sen}(\alpha_2 x) + \alpha_3 \cos(\alpha_4 x) + \cdots + \alpha_{r-1} \cos(\alpha_r x)$$

3. Para oscilaciones amortiguadas:

$$g(x, \alpha_0, \ldots, \alpha_m) = \alpha_0 + \alpha_1 e^{\alpha_2 x} \operatorname{sen}(\alpha_3 x) + \alpha_4 e^{\alpha_5 x} \cos(\alpha_6 x) + \cdots + \alpha_{r-2} e^{\alpha_{r-1} x} \cos(\alpha_r x)$$

4. Para una función con polos:

$$g(x, \alpha_0, \ldots, \alpha_m) = \frac{\alpha_0 + \alpha_1 x + \alpha_2 x^2 + \cdots + \alpha_s x^s}{\alpha_{s+1} x^{s+1} + \cdots + \alpha_r x^r}$$

.

1. Interpolación polinomial

Supongamos que tenemos $x_0, x_1, \ldots, x_n$, $(n+1)$ puntos distintos del eje real y $f_0, f_1, \ldots, f_n$ los valores correspondientes de la ordenada. Buscamos un polinomio de grado menor o igual a n

$$P_n(x) = a_0 + a_1 x + a_2 x^2 + \cdots + a_n x^n$$

tal que $P_n(x_i) = f_i, \quad i = 0, 1, \ldots, n.$

TEOREMA 6.1. *Para $(n+1)$ puntos $(x_0, f_0), (x_1, f_1), \ldots, (x_n, f_n) \in \mathbb{R}^2$ con abscisas distintas (esto es, $x_i \neq x_j$ para $i \neq j$), existe un único polinomio P_n de grado menor o igual a n que cumple las condiciones interpolantes:*

$$P_n(x_i) = f_i, \quad i = 0, 1, \ldots, n$$

DEMOSTRACIÓN. Consideremos el sistema lineal:

$$f_i = a_0 + a_1 x_i + a_2 x_i^2 + \cdots + a_n x_i^n, \quad i = 0, 1, \ldots, n$$

en la forma $Ax = b$:

$$\begin{bmatrix} 1 & x_0 & x_0^2 & \ldots & x_0^n \\ 1 & x_1 & x_1^2 & \ldots & x_1^n \\ \vdots & & & & \vdots \\ 1 & x_n & x_n^2 & \ldots & x_n^n \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \end{bmatrix} = \begin{bmatrix} f_0 \\ f_1 \\ \vdots \\ f_n \end{bmatrix} \tag{11}$$

como $x_i \neq x_j$ para $i \neq j$ el determinante de Vandermonde

$$\det(A) = \prod_{i>j}(x_i - x_j)$$

$(i = 1, \ldots, n, j = 0, \ldots, n)$ es diferente de cero y el sistema lineal (11) tiene solución única $(a_0, a_1, \ldots, a_n)^t$ y por consiguiente $P_n(x) = a_0 + a_1 x + \cdots + a_n x^n$ es el único polinomio que cumple las condiciones interpolantes. □

1.1. Fórmula de Lagrange. Evitando el sistema lineal

$$\begin{bmatrix} 1 & x_0 & x_0^2 & \ldots & x_0^n \\ 1 & x_1 & x_1^2 & \ldots & x_1^n \\ \vdots & & & & \vdots \\ 1 & x_n & x_n^2 & \ldots & x_n^n \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \end{bmatrix} = \begin{bmatrix} f_0 \\ f_1 \\ \vdots \\ f_n, \end{bmatrix} \tag{12}$$

por ser usualmente este mal condicionado, escribimos

$$P_n(x) = f_0 L_0(x) + f_1 L_1(x) + \cdots + f_n L_n(x)$$

donde los polinomios $L_0, L_1, \ldots, L_n$ tienen grado n y

$$f_j = P_n(x_j) = f_0 L_0(x_j) + f_1 L_1(x_j) + \cdots + f_n L_n(x_j), \quad j = 0, 1, \ldots, n.$$

Esto se cumple, si se exige que

$$L_j(x_k) = \begin{cases} 0, & j \neq k \\ 1, & j = k \end{cases} = \delta_{jk}.$$

Los polinomios L_j con estas propiedades son denominados *polinomios básicos de Lagrange*. Como L_j es de grado n con $L_j(x_k) = 0, \quad k = 0, \ldots, n, \quad k \neq j$ entonces

$$L_j(x) = \alpha_j (x - x_0) \cdots (x - x_{j-1})(x - x_{j+1}) \ldots (x - x_n), \quad j = 0, \ldots, n,$$

y de $L_j(x_j) = 1$, se tiene

$$1 = \alpha_j (x_j - x_0) \cdots (x_j - x_{j-1})(x_j - x_{j+1}) \ldots (x_j - x_n).$$

Usando que $x_j \neq x_k$ para $j \neq k$ se obtiene:

$$L_j(x) = \frac{(x - x_0) \cdots (x - x_{j-1})(x - x_{j+1}) \cdots (x - x_n)}{(x_j - x_0) \cdots (x_j - x_{j-1})(x_j - x_{j+1}) \cdots (x_j - x_n)}$$

o en forma abreviada:

$$L_j(x) = \prod_{\substack{k=0 \\ k \neq j}}^{n} \frac{x - x_k}{x_j - x_k}$$

Reemplazando, obtenemos

$$P_n(x) = \sum_{j=0}^{n} f_j \prod_{\substack{k=0 \\ k \neq j}}^{n} \frac{x - x_k}{x_j - x_k}$$

de esta manera, hemos obtenido

TEOREMA 6.2. *Dados* $(x_i, f_i) \in \mathbb{R}^2, \quad i = 0, 1, \ldots, n$, $x_i \neq x_j$ *para* $i \neq j$, *entonces el único polinomio interpolante de la forma de Lagrange de grado no mayor que* n *puede expresarse como*

$$P_n(x) = \sum_{j=0}^{n} f_j L_j(x) \quad \textit{con} \quad L_j(x) = \prod_{\substack{k=0 \\ k \neq j}}^{n} \frac{x - x_k}{x_j - x_k}, \quad j = 0, 1, \ldots, n$$

Ejemplo 6.1. Para los datos:

x_j	0	0,5	1
f_j	1,1	0,9	0,6

tenemos:

$$\begin{aligned} L_0(x) &= \frac{(x-x_1)(x-x_2)}{(x_0-x_1)(x_0-x_2)} = \frac{(x-0{,}5)(x-1)}{(0-0{,}5)(0-1)} = 2x^2-3x+1 \\ L_1(x) &= \frac{(x-x_0)(x-x_2)}{(x_1-x_0)(x_1-x_2)} = \frac{(x-0)(x-1)}{(0{,}5-0)(0-1)} = 2x^2-2x \\ L_2(x) &= \frac{(x-x_0)(x-x_1)}{(x_2-x_0)(x_2-x_1)} = \frac{(x-0)(x-0{,}5)}{(1-0)(1-0{,}5)} = 2x^2-x \end{aligned}$$

Luego:

$$P_n(x) = 1{,}1(2x^2-3x+1) + 0{,}9(2x^2-2x) + 0{,}6(2x^2-x)$$

La desventaja de este método es que, si se añaden nuevos puntos interpolantes, se tiene que recalcular todos los polinomios nuevamente.

1.2. Forma de Newton. Se inicia con el polinomio de grado 0 que pasa por el punto (x_0, f_0)

$$P_0(x) = f_0, \quad x \in \mathbb{R}.$$

Añadiendo (x_1, f_1), se construye un polinomio $P_1(x)$ de grado no mayor que 1 tal que

$$\begin{cases} P_1(x_0) = f_0 \\ P_1(x_1) = f_1 \end{cases}$$

Sea $P_1(x) = P_0(x) + q_1(x)$, $\quad grado(q_1) \leq 1$. Como $P_1(x_0) = f_0$, entonces $q_1(x_0) = 0$. Luego $grado(q_1) = 1$ implica que $q_1(x) = b_1(x - x_0)$. Como $P_1(x_1) = f_1$, entonces $f_1 = P_1(x_1) = f_0 + b_1(x_1 - x_0) = f_1$. De esto último obtenemos la expresión para b_1:

$$b_1 = \frac{f_1 - f_0}{x_1 - x_0} = \frac{f_1 - P_0(x_1)}{x_1 - x_0}$$

En general, si se tiene un polinomio interpolante P_{n-1} de grado no mayor que $(n-1)$ que pasa por los puntos $(x_0, f_0), (x_1, f_1), \ldots, (x_{n-1}, f_{n-1})$, se calcula el polinomio $P_n(x)$ que pasa además por el punto (x_n, f_n) de la siguiente manera:

$$P_n(x) = P_{n-1}(x) + q_n(x), \text{ donde } grado(q_n) \leq n$$

Como $P_n(x_j) = P_{n-1}(x_j) = f_j$, $\quad j = 0, 1, \ldots, n-1$, entonces $q_n(x_j) = 0$, $\quad j = 0, 1, \ldots, n-1$. Luego

$$q_n(x) = b_n(x - x_0)(x - x_1)\cdots(x - x_{n-1})$$

El coeficiente b_n, se obtiene de $P_n(x_n) = P_{n-1}(x_n) + q_n(x_n) = f_n$, mediante

$$b_n = \frac{f_n - P_{n-1}(x_n)}{\prod_{j=0}^{n-1}(x_n - x_j)}$$

Veamos otra manera de obtener P_n a partir de P_{n-1}: de la expresión $P_n(x) = P_{n-1} + b_n \prod_{j=0}^{n-1}(x - x_j)$ notamos que el coeficiente correspondiente a x^n es b_n (pues $grado(P_{n-1}) \leq n-1$). Sea R_{n-1} el polinomio interpolante que pasa por los puntos $(x_1, f_1), (x_2, f_2), \ldots, (x_n, f_n)$. Definimos

$$P_n(x) = \frac{(x - x_n)P_{n-1}(x) - (x - x_0)R_{n-1}(x)}{x_0 - x_n}. \tag{13}$$

Este polinomio satisface las condiciones interpolantes

$$P_n(x_j) = f_j, \quad j = 0, 1, \ldots, n$$

En efecto: para $j = 0$

$$P_n(x_0) = \frac{(x_0 - x_n)f_0 - (x_0 - x_0)R_{n-1}(x_0)}{x_0 - x_n} = f_0;$$

para $j = 1, 2, \ldots, n-1$

$$P_n(x_j) = \frac{(x_j - x_n)f_j - (x_j - x_0)f_j}{x_0 - x_n} = f_j;$$

y para $j = n$

$$P_n(x_n) = \frac{(x_n - x_n)P_{n-1}(x_n) - (x_n - x_0)f_n}{x_0 - x_n} = f_n.$$

Sea b_{n-1}^R el coeficiente correspondiente a x^{n-1} en el polinomio $R_{n-1}(x)$. De (13) se obtiene:

$$b_n = \frac{b_{n-1} - b_{n-1}^R}{x_0 - x_n} \tag{14}$$

Denotemos con $f[x_j, x_{j+1}, \ldots, x_{j+k}]$ al coeficiente de x_k en el polinomio interpolante que pasa por los puntos $(x_j, f_j), (x_{j+1}, f_{j+1}), \ldots, (x_{j+k}, f_{j+k})$. Se cumple:

$$f[x_0] = f_0, \quad f[x_1] = f_1, \quad \ldots, \quad f[x_n] = f_n$$

y de (14) se obtiene:

$$b_n = f[x_0, \ldots, x_n] = \frac{f[x_1, \ldots, x_n] - f[x_0, \ldots, x_{n-1}]}{x_n - x_0}$$

En general:

$$f[x_j, \ldots, x_{j+k}] = \frac{f[x_{j+1}, \ldots, x_{j+k}] - f[x_j, \ldots, x_{j+k-1}]}{x_{j+k} - x_j}$$

El polinomio interpolante P_n puede ser escrito ahora como:

$$P_n(x) = f[x_0] + f[x_0, x_1](x - x_0) + \cdots + f[x_0, x_1, \ldots, x_n](x - x_0)\ldots(x - x_{n-1})$$

Damos ahora un esquema para calcular $f[x_0, \ldots, x_n]$, la *tabla de diferencias divididas*:

x	$f[x]$	$f[x,x]$	$f[x,x,x]$	$f[x,x,x,x]$	$\ldots$
x_0	$f_0 := f[x_0]$				
		$f[x_0,x_1] = \frac{f[x_1]-f[x_0]}{x_1-x_0}$			
x_1	$f_1 := f[x_1]$		$f[x_0,x_1,x_2] = \frac{f[x_1,x_2]-f[x_1,x_0]}{x_2-x_0}$		
		$f[x_1,x_2] = \frac{f[x_1]-f[x_0]}{x_1-x_0}$		$f[x_0,x_1,x_2,x_3]$	
x_2	$f_2 := f[x_2]$		$f[x_1,x_2,x_3] = \frac{f[x_2,x_3]-f[x_1,x_2]}{x_3-x_1}$		$\ldots$
		$f[x_2,x_3] = \frac{f[x_1]-f[x_0]}{x_1-x_0}$		$f[x_1,x_2,x_3,x_4]$	
x_3	$f_3 := f[x_3]$		$f[x_2,x_3,x_4] = \frac{f[x_3,x_4]-f[x_2,x_3]}{x_4-x_2}$	$\vdots$	
		$f[x_3,x_4] = \frac{f[x_1]-f[x_0]}{x_1-x_0}$	$\vdots$		
x_4	$f_4 := f[x_4]$	$\vdots$			
$\vdots$	$\vdots$				
x_4	$f_n := f[x_n]$				

NOTA. Ahora podemos ir agregando más y más puntos. Por ejemplo, al agregar el punto (x_{n+1}, f_{n+1}), tendremos

$$P_{n+1}(x) = P_n(x) + f[x_0, x_1, \ldots, x_{n+1}] \prod_{j=0}^{n} (x - x_j)$$

y así sucesivamente.

Tenemos ahora el *algoritmo de las diferencias divididas*:

Entrada: $x_0, x_1, \ldots, x_n, f_0, f_1, \ldots, f_n$
$f[x_0] := f_0, \quad f[x_1] := f_1, \quad \ldots, \quad f[x_n] := f_n$
Para $k = 1, 2, \ldots, n$
Para $j = 0, \ldots, (n-k)$
$f[x_j, \ldots, x_{j+k}] := \dfrac{f[x_{j+1}, \ldots, x_{j+k}] - f[x_j, \ldots, x_{j+k-1}]}{x_{j+k} - x_j}$

El cálculo se simplifica cuando se tienen puntos igualmente espaciados :

$$x_j := x_0 + jh, \quad j = 0, 1, \ldots, n, \quad h > 0$$

entonces $x_{k+l} - x_k = lh$. Definimos:

$$\Delta^0 f_k = f_k, \quad k = 0, 1, 2, \ldots$$
$$\Delta^l f_k = \Delta^{l-1} f_{k+1} - \Delta^{l-1} f_k$$

y se obtiene:

$$f[x_k, \ldots, x_{k+l}] = \frac{1}{l!} \frac{\Delta^l f_k}{h^l}$$

y el polinomio interpolante:

$$\begin{aligned} P_n(x) =& \Delta^0 f_0 + \frac{1}{1!} \frac{\Delta^1 f_0}{h^1}(x - x_0) + \frac{1}{2!} \frac{\Delta^2 f_0}{h^2}(x - x_0)(x - x_1) \\ &+ \cdots + \frac{1}{n!} \frac{\Delta^n f_0}{h^n}(x - x_0)(x - x_1) \cdots (x - x_{n-1}) \end{aligned}$$

que es parecido a la fórmula de Taylor.

NOTA. Para evaluar el polinomio en un punto, se puede utilizar el esquema de Horner:

$$P_n(x) = b_0 + (x - x_0)(b_1 + \cdots + (x - x_{n-3})(b_{n-2} + (x - x_{n-2})(b_{n-1} + (x - x_{n-1})b_n)) \cdots)$$

Por ejemplo, para $n = 3$:

$$\begin{aligned} P_3(x) &= b_0 + b_1(x - x_0) + b_2(x - x_0)(x - x_1) + b_3(x - x_0)(x - x_1)(x - x_2) \\ &= b_0 + (x - x_0)[b_1 + (x - x_1)[b_2 + (x - x_2)b_3]] \end{aligned}$$

1.3. Fórmula de Aitken-Neville. Para calcular el valor del polinomio interpolante en un punto x no es necesario el cálculo de todo el polinomio $P_n(x)$. Para este fin vamos a desarrollar el algoritmo de Aitken-Neville.
Sea $P_{j,k}$ el polinomio interpolante de grado no mayor que k que pasa por los puntos $(x_{j-k}, f_{j-k}), \ldots, (x_j, f_j) \in \{(x_j, f_j)\}_{j=0}^{n}$. Se tiene:

$$P_{j,k}(x_i) = f_i, \quad i = j - k, \ldots, j$$

Por ejemplo: $P_{5,2}$ es el polinomio interpolante de grado no mayor que 2, que pasa por los puntos $(x_3, f_3), (x_4, f_4), (x_5, f_5)$.
Con esta notación $P_{n,n}$ es el polinomio P_n que pasa por los puntos $(x_0, f_0), \ldots, (x_n, f_n)$.

TEOREMA 6.3. *Sea $P_{j,k}$ el polinomio interpolante que pasa por los puntos $(x_{j-k}, f_{j-k}), \ldots, (x_j, f_j) \in \{(x_j, f_j)\}_{j=0}^{n}$. Entonces este polinomio puede ser evaluado en un punto t recursivamente por:*

$$P_{j,0}(t) = f_j$$

para $j = 0, 1, \ldots, n$, y

$$P_{j,k}(t) = \frac{(t - x_{j-k})P_{j,k-1}(t) - (t - x_j)P_{j-1,k-1}(t)}{x_j - x_{j-k}},$$

para $k = 1, 2, \ldots, j$, $j = 1, 2, \ldots, n$.

DEMOSTRACIÓN. Por inducción sobre k:
Para $k = 1$:

$$\begin{aligned} P_{j,1}(t) &= \frac{(t - x_{j-1})f_j - (t - x_j)f_{j-1}}{x_j - x_{j-1}} \\ &= \frac{(t - x_{j-1})P_{j,0}(t) - (t - x_j)P_{j-1,0}(t)}{x_j - x_{j-1}} \end{aligned}$$

pasa por $(x_{j-1}, f_{j-1}), (x_j, f_j)$. Supongamos que la fórmula es correcta para $k = m$. Se tiene que probar que

$$P_{j,m+1}(t) = \frac{(t - x_{j-m-1})P_{j,m}(t) - (t - x_j)P_{j-1,m}(t)}{x_j - x_{j-m-1}}$$

cumple las condiciones interpolantes:

$$P_{j,m+1}(x_i) = f_i, \quad i = j - m - 1, \ldots, j$$

Se tiene:

$$\begin{aligned} &P_{j,m}(x_i) = f_i, \quad i = j - m, \ldots, j; \quad j - m \leq i \leq j - 1 \\ &P_{j-1,m}(x_i) = f_i, \quad i = j - m - 1, \ldots, j - 1 \end{aligned}$$

Luego para $i = j - m, \ldots, j - 1$:

$$P_{j,m+1}(x_i) = \frac{(x_i - x_{j-m-1})f_i - (x_i - x_j)f_i}{x_j - x_{j-m-1}} = f_i$$

También:

$$\begin{aligned} &P_{j+1,m}(x_{j-m-1}) = f_{j-m-1} \\ &P_{j-1,m}(x_j) = f_j \end{aligned}$$

□

Podemos calcular $P_{n,n}(t)$ con el esquema:

x_0	$f_0 := P_{0,0}(t)$				
		$P_{1,1}(t)$			
x_1	$f_1 := P_{1,0}(t)$		$P_{2,2}(t)$		
		$P_{2,1}(t)$			
x_2	$f_2 := P_{2,0}(t)$			$\ddots$	
$\vdots$	$\vdots$				$P_{n,n}(t)$
x_{n-1}	$f_{n-1} := P_{n-1,0}(t)$				
		$P_{n-1,1}(t)$			
x_n	$f_n := P_{n,0}(t)$				

Damos el algoritmo de Aitken-Neville:

Entrada: $x_0, \ldots, x_k, f_0, \ldots, f_k, t$		
Tomar $r_j := t - x_j, \quad j = 0, \ldots, n$		
Hacer $d_j := f_j, \quad j = 0, \ldots, n$		
Para $k = 1, \ldots, n$		
	Para $j = 0, \ldots, n-k$	
		$d_j := \dfrac{r_j d_{j+1} - r_{j+k} d_j}{x_{j+k} - x_k}$
Salida: $d_0 := P_{n,n}(t)$		

1.4. Error del polinomio interpolante. Suponemos que utilizamos un polinomio para aproximar los valores de otra función, lo suficientemente *suave*. ¿Cuál es el error de la aproximación realizada?

TEOREMA 6.4. *Sea $f \in C^{(n+1)}[a,b]$ con $\{x_i\}_{i=0}^n \subset [a,b]$ y $x_i \neq x_j$ para $i \neq j$. Sea P_n el polinomio interpolante con $P_n(x_i) = f(x_i)$, $i = 0, 1, \ldots, n$. Entonces para cada $x \in [a,b]$, existe un número $\xi \in]\min\{x, x_0, \ldots, x_n\}, \max\{x, x_0, \ldots, x_n\}[= I$ con*

$$f(x) - P_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \prod_{k=0}^{n} (x - x_k)$$

DEMOSTRACIÓN. Para $x = x_k, \quad k = 0, 1, \ldots, n$, resulta $f(x_k) = P_n(x_k)$. Definamos la función $w_n(x) := \prod_{k=0}^{n} (x - x_k)$, y tomemos además $x \in [a,b]$ tal que $x \neq x_k, \quad k = 0, 1, \ldots, n$.
Consideremos la función

$$\phi(t) := f(t) - P_n(t) - \frac{f(x) - P_n(x)}{w_n(x)} w_n(t),$$

se cumple que $\phi \in C^{(n+1)}[a,b], \quad \phi(x) = 0, \quad \phi(x_i) = 0, \quad i = 0, 1, \ldots, n$ (pues $w_n(x_i) = 0$). Entonces ϕ tiene por lo menos $(n+2)$ ceros distintos en el intervalo $[a,b]$, los cuales son $x, x_0, \ldots, x_n$. Por una extensión del teorema de Rolle se obtiene que existe $\xi \in I$ tal que $\phi^{(n+1)}(\xi) = 0$ o

$$f^{(n+1)}(\xi) - \frac{f(x) - P_n(x)}{w_n(x)} (n+1)! = 0$$

de donde

$$f(x) - P_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \prod_{k=0}^{n} (x - x_k)$$

□

1.5. Diferenciación numérica. Fórmulas de diferencias: Sean $(x_i, f_i), \quad i = 0, 1, \ldots, n$ puntos interpolantes. De la fórmula de Lagrange:

$$P_n(x) = \sum_{j=0}^{n} f_j \alpha_j \prod_{\substack{k=0 \\ k \neq j}}^{n} (x - x_k)$$

con $\alpha_j = \prod_{\substack{k=0 \\ k \neq j}}^{n} \frac{1}{x_j - x_k}$.
Se obtiene:

$$\frac{d^n P_n}{dx^n}(x) = \sum_{j=0}^{n} f_j \alpha_j n! \approx f^{(n)}(x)$$

que podría ser una posible aproximación de la n-ésima derivada $f^{(n)}$.

TEOREMA 6.5. *Sea $f \in C^{(n+1)}[a,b]$ con $a = \min\{x_0,\ldots,x_n\}$ y $b = \max\{x_0,\ldots,x_n\}$ con $x_{j+1} = x_j + h$ ($h > 0$, constante). Entonces existe $\xi \in]a,b[$ tal que*

$$f^{(n)}(\xi) = \sum_{j=0}^{n} f_j \frac{(-1)^{n-j}}{h^n} \binom{n}{j}$$

DEMOSTRACIÓN. Sea $g(x) = f(x) - P_n(x)$, P_n el polinomio interpolante para $f(x)$ en $(x_0,f_0),\ldots,(x_n,f_n)$. Entonces g tiene $n+1$ ceros $x_0, x_1, \ldots, n$. Luego, por una variante del teorema de Rolle, existe $\xi \in]a,b[$ tal que

$$g^{(n)}(\xi) = f^{(n)}(\xi) - P_n^{(n)}(\xi) = 0$$

Se cumple:

$$\begin{aligned}\alpha_j &= \prod_{\substack{k=0\\k\neq j}}^{n} \frac{1}{x_j - x_k} = \frac{1}{(-1)^{n-j}h^n[j\cdot(j-1)\cdots 1][1\cdot 2\cdots(n-j)]} \\ &= \frac{(-1)^{n-j}}{h^n\, n!}\binom{n}{j}\end{aligned}$$

entonces

$$\frac{d^n P_n}{dx^n}(x) = \frac{1}{h^n}\left[(-1)^n f_0 + (-1)^{n-1}\binom{n}{1} f_1 + (-1)^{n-2}\binom{n}{2} f_2 + \cdots - \binom{n}{n-1} f_{n-1} + f_n\right]$$

Para $n = 1, 2, 3$:

$$\begin{aligned} f'(x) &\approx \frac{f_1 - f_0}{h} \\ f''(x) &\approx \frac{f_2 - 2f_1 + f_0}{h^2} \\ f'''(x) &\approx \frac{f_3 - 3f_2 + 3f_1 - f_0}{h^3}. \end{aligned}$$

□

1.6. Método de Romberg. Este método para diferenciación numérica fue creado por el matemático alemán W. Romberg en el año 1955.
Sea $f : \mathbb{R} \to \mathbb{R}$, y definamos el cociente:

$$\varphi(h) := \delta_h f(x_0) = \frac{1}{2h}[f(x_0 + h) - f(x_0 - h)]$$

se cumple que

$$\lim_{h\to 0} \varphi(h) = \lim_{h\to 0} \delta_h f(x_0) = f'(x_0)$$

La idea principal del método de Romberg es la extrapolación de φ como función de h a través de interpolación polinomial y los puntos de partición $h_0, h_0/2, h_0/4, \ldots, h_0/2^n$, en el punto $h = 0$. Para este objetivo se utilizan las fórmulas de Aitken-Neville.

EJEMPLO 6.2. $f(x) = \tan(x), \quad x_0 = 0{,}5.$

$$\varphi(h) := \delta_h f(0{,}5) = \frac{1}{2h}[\tan(0{,}5 + h) - \tan(0{,}5 - h)]$$

Algoritmo de Romberg:

Entrada:	$n, h_0, x_0, \varphi(h) = \delta_h f(x_0)$
Para $j = 0,\ldots,n$	
	$r_j := -h_0/2^{n-j}$ $d_j := \varphi(h_0/2^{n-j})$
Para $k = 1,\ldots,n$	
	Para $j = 0,\ldots,(n-k)$
	$d_j := \dfrac{r_j d_{j+1} - r_{j+k} d_j}{r_j - r_{j+k}}$
Salida:	d_0, aproximación de $f'(x_0)$

1.7. Interpolación de Hermite. Ahora exigimos que el polinomio interpolante , además de pasar por algunos puntos, tenga que cumplir condiciones paa sus derivadas. En este caso se habla de *interpolación de Hermite*.

TEOREMA 6.6. *Dados los puntos interpolantes* $x_0, x_1, \ldots, x_n$, *consideremos* $m_0, m_1, \ldots, m_n \in \mathbb{N}$ *con* $\sum_{i=0}^{n} m_i = m+1$ *y* $f_i^{(k)} \in \mathbb{R}$ *para* $k = 0, \ldots, m_i - 1, \quad i = 0, \ldots, n$. *Entonces existe un único polinomio interpolante* P_m *de grado no mayor a* m *tal que*

$$P_m^{(k)}(x_i) = f_i^{(k)}$$

para $k = 0, 1, \ldots, m_i - 1, \quad i = 0, 1, \ldots, n$.

DEMOSTRACIÓN. Se tienen $\sum_{i=0}^{n} m_i = m+1$ condiciones interpolantes para los $(m+1)$ coeficientes del polinomio, esto es, se tienen $(m+1)$ ecuaciones lineales para las $(m+1)$ incógnitas.
Basta mostrar que el sistema homogéneo tiene solamente la solución trivial. Cuando P_m es un polinomio con $P^{(k)}(x_i) = 0$, para $k = 0, 1, \ldots, m_i - 1$, $i = 0, \ldots, n$ se tiene que P_m tiene el punto interpolante x_i como m_i-múltiple cero. Esto implica que P_m tiene por lo menos $\sum_{i=0}^{n} m_i = m+1$ ceros, de donde $P_m \equiv 0$. □

1.7.1. Interpolación de Hermite con polinomios de Lagrange. Trataremos ahora un caso especial de la interpolación de Hermite, en el caso en que las condiciones de interpolación se dan para el polinomio y sus derivadas en todos los nodos considerados.

TEOREMA 6.7. *Dados* $x_0, \ldots, x_n, f_0, \ldots, f_n, f_0', \ldots, f_n'$. *Entonces el único polinomio* P_{2n+1} *de grado no mayor que* $(2n+1)$ *con*

$$\begin{aligned} P_{2n+1}(x_i) &= f_i \\ P'_{2n+1}(x_i) &= f_i', \qquad i = 0, \ldots, n, \end{aligned}$$

tiene la forma

$$P_{2n+1}(x) = \sum_{j=0}^{n} f_j L_j^2(x)(c_j(x) + d_j) + f_j' L_j^2(x)(x - x_j),$$

con

$$c_j = -2 \sum_{\substack{k=0 \\ k \neq j}}^{n} \frac{1}{x_j - x_k}, \quad d_j = 1 - c_j x_j, \quad j = 0, \ldots, n.$$

DEMOSTRACIÓN. Sea $P_{2n+1}(x) = \sum_{j=0}^{n} f_j g_j(x) + f_j' h_j(x)$. Determinemos los polinomios g_j y h_j de grado no mayor que $(2n+1)$ de modo que

$$g_j(x_i) = \begin{cases} 1, & i = j \\ 0, & i \neq j \end{cases} \qquad h_j(x_i) = 0, \quad i, j = 0, \ldots, n$$

$$g_j'(x_i) = 0, \quad i, j = 0, \ldots, n \qquad h_j'(x_i) = \begin{cases} 1, & i = j \\ 0, & i \neq j \end{cases}$$

Definiendo

$$h_j(x) := L_j^2(x)(x - x_j), \text{ donde } L_j(x) = \prod_{\substack{k=0 \\ k \neq j}}^{n} \frac{x - x_k}{x_j - x_k},$$

se cumplen:

i) h_j tiene grado $2n+1$.
ii) $h_j(x_i) = 0, \quad i,j = 0,\ldots,n.$
iii) $h_j'(x) = 2L_j(x)L_j'(x)(x-x_j) + L_j^2(x)$, de donde
$$h_j'(x_i) = 2L_j(x_i)L_j'(x)(x_i - x_j) + L_j^2(x_i) = \begin{cases} 1, & i = j \\ 0, & i \neq j \end{cases}$$

Definiendo
$$g_j(x) := L_j^2(x)(c_j x + d_j), \quad j = 0,\ldots,n,$$
con c_j, d_j constantes, se cumple:

i) g_j tiene grado no mayor que $2n+1$.
ii) $g_j(x_i) = 0$ para $i \neq j$
iii) $g_j'(x) = 2L_j(x)L_j'(x)(c_j x + d_j) + c_j L_j^2(x)$, entonces
$g_j'(x_i) = 2L_j(x_i)L_j'(x_i)(c_j x_i + d_j) + c_j L_j^2(x_i) = 0, \quad i \neq j$

Las constantes c_j y d_j se determinan de las ecuaciones:
$$g_j(x_j) = 1 \quad \text{y} \quad g_j'(x_j) = 0.$$

Como $g_j'(x_j) = 2L_j'(x_j) + c_j = 0$ y del hecho que $L_j'(x_j) = \sum_{\substack{k=0 \\ k\neq j}}^{n} \frac{1}{x_j - x_k}$, se obtienen:

$$c_j = -2\sum_{\substack{k=0 \\ k\neq j}}^{n} \frac{1}{x_j - x_k} \quad \text{y} \quad d_j = 1 - c_j x_j, \quad j = 0,\ldots,n.$$

□

1.7.2. Interpolación de Hermite por diferencias divididas de Newton. Dos puntos interpolantes x_k y $x_{k+1} := x_k + h$ para $h \to 0$ son iguales. Por ello definimos para la primera diferencia dividida de Newton:
$$f[x_k, x_k] = \lim_{h\to 0} \frac{f[x_{k+1}] - f[x_k]}{x_{k+1} - x_k} = f'(x_k).$$

Para tres puntos equidistantes x_k, $x_{k+1} := x_k + h$, $x_{k+2} := x_k + 2h$ definimos para $h \to 0$ la segunda diferencia dividida:
$$\begin{aligned} f[x_k, x_k, x_k] &= \lim_{h\to 0} \frac{f[x_{k+1}, x_{k+2}] - f[x_k, x_{k+1}]}{x_{k+2} - x_k} \\ &= \lim_{h\to 0} \frac{\dfrac{f[x_{k+2}] - f[x_{k+1}]}{h} - \dfrac{f[x_{k+1}] - f[x_k]}{h}}{2h} = \frac{1}{2} f''(x_k). \end{aligned}$$

De manera análoga se define para $(n+1)$ puntos interpolantes:
$$f[x_k, x_k, \ldots, x_k] = \frac{1}{n!} f^{(n)}(x_k), \quad n = 1, 2, \ldots$$

Utilizando estas definiciones se puede calcular el polinomio de Hermite a través del esquema de las diferencias divididas.

Ejemplo 6.3. Dados los datos:

x_i	x_0	x_1
f_i	f_0	f_1
f_i'	f_0'	f_1'
f_i''	f_0''	f_1''

Tenemos 6 condiciones interpolantes. Se está buscando un polinomio de grado 5: $P_5(x)$.

x	$f[x]$	$f[x,x]$	$f[x,x,x]$	$f[x,x,x,x]$	$f[x,x,x,x,x]$	$f[x,x,x,x,x,x]$
x_0	$f[x_0]$					
		$f'(x_0)$				
x_0	$f[x_0]$		$\frac{1}{2}f''(x_0)$			
		$f'(x_0)$		$f[x_0,x_0,x_0,x_1]$		
x_0	$f[x_0]$		$f[x_0,x_0,x_1]$		$f[x_0,x_0,x_0,x_1,x_1]$	
		$f[x_0,x_1]$		$f[x_0,x_0,x_1,x_1]$		$f[x_0,x_0,x_0,x_1,x_1,x_1]$
x_1	$f[x_1]$		$f[x_0,x_1,x_1]$		$f[x_0,x_0,x_1,x_1,x_1]$	
		$f'(x_1)$		$f[x_0,x_1,x_1,x_1]$		
x_1	$f[x_1]$		$\frac{1}{2}f''(x_1)$			
		$f'(x_1)$				
x_1	$f[x_1]$					

Entonces

$P_5(x) = b_0+b_1(x-x_0)+b_2(x-x_0)^2+b_3(x-x_0)^3+b_4(x-x_0)^3(x-x_1)+b_5(x-x_0)^3(x-x_1)^2$

donde los b_i, $\quad i = 0,\ldots,5$ son los valores de la primera línea oblicua.

2. Splines cúbicos

Dados los puntos interpolantes $a = x_0 < x_1 < \ldots < x_m = b$ en el intervalo $[a,b]$ con los valores correspondientes $f_0, f_1, \ldots, f_m$ utilizando la interpolación por Splines cúbicos, se unen los puntos $(x_0,f_0),\ldots,(x_m,f_m)$ obteniendo una función spline cúbico S^3_Δ, tal que:

a) S^3_Δ es un polinomio de grado 3 en cada intervalo $[x_j,x_{j+1}]$, $(j = 0,1,\ldots,m-1)$.
b) $S^3_\Delta(x_j) = f_j$, $j = 0,1,\ldots,m$.
c) $S^3_\Delta \in C^2[a,b]$.

2.0.1. Construcción de S^3_Δ. La condición (a) implica que S^3_Δ se escribe como

$$S^3_\Delta(x) = P_j(x), \quad x_j \le x \le x_{j+1}, \quad j = 0,1,2,\ldots,m-1$$

donde

$$P_j(x) = a_j + b_j(x-x_j) + c_j(x-x_j)^2 + d_j(x-x_j)^3,$$

$x_j \le x \le x_{j+1}$, $j = 0,1,\ldots,m-1$; lo cual implica que requerimos $4m$ coeficientes. La condición (b) de interpolación nos da $m+1$ ecuaciones:

$$P_j(x_j) = f_j, \quad j = 0,1,\ldots,m.$$

Las condiciónes de continuidad sobre S^3_Δ, $(S^3_\Delta)'$ y $(S^3_\Delta)''$ (condición (c)) nos dan $3(m-1)$ ecuaciones:

$$\begin{aligned} P_{j-1}(x_j) &= P_j(x_j),\\ P'_{j-1}(x_j) &= P'_j(x_j),\\ P''_{j-1}(x_j) &= P''_j(x_j), \quad j = 1,\ldots,m-1. \end{aligned}$$

Tenemos entonces un total de $m+1+3(m-1) = 4m-2$ condiciones y $4m$ incógnitas. Agregamos entonces 2 condiciones más.
Se puede exigir

$$(S^3_\Delta)''(x_0) = 0 = (S^3_\Delta)''(x_m), \tag{15}$$

obteniendo en este caso el spline natural.
Para la interpolación de una función periódica se podría exigir

$$(S^3_\Delta)'(x_0) = (S^3_\Delta)'(x_m), \quad (S^3_\Delta)''(x_0) = (S^3_\Delta)''(x_m).$$

Otra posibilidad es

$$S^3_\Delta(x_0) = m_0 \ \text{ y } \ S^3_\Delta(x_m) = m_1,$$

donde los números m_0 y m_1 son dados.
De (15) se obtiene

$$P_0''(x_0) = 0, \quad P_{m-1}''(x_m) = 0. \tag{16}$$

Necesitamos las derivadas de P_k

$$\begin{aligned} P_k'(x) &= b_k + 2c_k(x - x_k) + 3d_k(x - x_k)^2 \\ P_k''(x) &= 2c_k + 6d_k(x - x_k), \qquad\qquad x_k \le x \le x_{k+1}, \quad k = 0, \ldots, m-1. \end{aligned}$$

De la continuidad de $(S_\Delta^3)''$, tenemos

$$2c_{j-1} + 6d_{j-1}(x_j - x_{j-1}) = P_{j-1}''(x_j) = P_j''(x_j) = 2c_j$$

y luego

$$2c_j = 2c_{j-1} + 6d_{j-1}(x_j - x_{j-1}).$$

Haciendo $h_j = x_{j+1} - x_j$ obtenemos

$$c_j = c_{j-1} + 3d_{j-1}h_j$$

esto es,

$$d_j = \frac{c_{j+1} - c_j}{3h_j}, \quad j = 0, 1, 2, \ldots, m-2, m-1. \tag{17}$$

De las condiciones de interpolación

$$a_j = P_j(x_j) = f_j, \quad j = 0, 1, \ldots, m. \tag{18}$$

y de la continuidad de S_Δ^3:

$$a_j = P_j(x_j) = P_{j-1}(x_j) = a_{j-1} + b_{j-1}(x_j - x_{j-1}) + c_{j-1}(x_j - x_{j-1})^2 + d_{j-1}(x_j - x_{j-1})^3,$$

esto es,

$$a_j = a_{j-1} + b_{j-1}h_{j-1} + c_{j-1}h_{j-1}^2 + d_jh_{j-1}^3, \quad j = 1, \ldots, m$$

de donde

$$b_j = \frac{a_{j+1} - a_j}{h_j} - h_j(c_j + h_jd_j), \quad j = 0, 1, \ldots, m-1.$$

Reemplazando (17) y (18) en la anterior expresión

$$b_j = \frac{f_{j+1} - f_j}{h_j} - \frac{h_j}{3}(c_{j+1} + 2c_j), \quad j = 0, \ldots, m-1. \tag{19}$$

Ahora de la continuidad de $(S_\Delta^3)'$ tenemos

$$b_j = P_j'(x_j) = P_{j-1}'(x_j) = b_{j-1} + 2c_{j-1}(x_j - x_{j-1}) + 3d_{j-1}(x_j - x_{j-1})^2, \quad j = 1, \ldots, m-1$$

o bien

$$b_j - b_{j-1} - 2c_{j-1}h_{j-1} = 3d_{j-1}h_{j-1}^2.$$

Reemplazando (17) y (19) se obtiene

$$\frac{f_{j+1} - f_j}{h_j} - \frac{h_j}{3}(c_{j+1} + 2c_j) - \frac{f_j - f_{j-1}}{h_{j-1}} + \frac{h_{j-1}}{3}(c_j + 2c_{j-1}) = h_{j-1}(c_j + c_{j-1}), \quad j = 1, \ldots, m-1.$$

De este modo

$$h_{j-1}c_{j-1} + 2(h_{j-1} + h_j)c_j + h_jc_{j+1} = g_j, \quad j = 1, \ldots, m-1$$

donde

$$g_j = 3\frac{f_{j+1} - f_j}{h_j} - 3\frac{f_j - f_{j-1}}{h_{j-1}}, \quad j = 1, \ldots, m-1. \tag{20}$$

Los g_j son conocidos. Entonces (20) es un sistema lineal de $(m-1)$ ecuaciones con $(m+1)$ incógnitas $c_0, c_1, \ldots, c_m$. Este sistema lineal sirve generalmente para splines cúbicos.

Veamos el caso de los splines naturales:

$$\begin{aligned} P_0''(x_0) &= 2c_0 = 0 \text{ de donde } c_0 = 0 \\ P_{m-1}''(x_m) &= 2c_{m-1} + 6d_{m-1}(x_m - x_{m-1}) = 0 \\ &= 2c_{m-1} + 6\frac{c_m - c_{m-1}}{3h_m}h_m \\ &= 2c_m = 0 \text{ de donde } c_m = 0 \end{aligned}$$

Dado que $c_0 = 0 = c_m$, el sistema anterior se reduce a un sistema de $(m-1)$ ecuaciones con $(m-1)$ incógnitas $c_1, \ldots, c_{m-1}$:

$$\begin{bmatrix} 2(h_0+h_1) & h_1 & & & 0 \\ h_1 & 2(h_1+h_2) & h_2 & & \\ & h_2 & & \ddots & \\ & & \ddots & & h_{m-2} \\ 0 & & & h_{m-2} & 2(h_{m-2}+h_{m-1}) \end{bmatrix} \begin{bmatrix} c_1 \\ c_2 \\ \\ \vdots \\ c_{m-1} \end{bmatrix} = \begin{bmatrix} g_1 \\ g_2 \\ \\ \vdots \\ g_{m-1} \end{bmatrix}$$

el cual tiene la forma $Ac = g$.

Ejemplo 6.4. Construímos la función interpolante spline cúbico para los datos:

j	0	1	2	3	4
x_j	-1	$-0{,}5$	0	0,5	1
f_j	0,5	0,8	1	0,8	0,5

Aquí $h_j = x_{j+1} - x_j = 0{,}5$; y el sistema de ecuaciones lineales es (asumiendo $c_0 = 0 = c_4$):

$$\begin{aligned} 2c_1 + 0{,}5c_2 &= -0{,}6 \\ 0{,}5c_1 + 2c_2 + 0{,}5c_3 &= -2{,}4 \\ 0{,}5c_2 + 2c_3 &= -0{,}6 \end{aligned}$$

el cual tiene como solución:

$$c_1 = 0, \quad c_2 = -1{,}2, \quad c_3 = 0.$$

De esta manera obtenemos los coeficientes:

$$\begin{array}{llll} b_0 = 0{,}6 & b_1 = 0{,}6 & b_2 = 0 & b_3 = -0{,}6 \\ d_0 = 0 & d_1 = -0{,}8 & d_2 = 0{,}8 & d_3 = 0 \end{array}$$

y formamos

$$S_\Delta^3(x) = \begin{cases} P_0(x), & x_0 \le x \le x_1 \\ P_1(x), & x_1 \le x \le x_2 \\ P_2(x), & x_2 \le x \le x_3 \\ P_3(x), & x_3 \le x \le x_4 \end{cases}$$

$$S_\Delta^3(x) = \begin{cases} 0{,}5 + 0{,}6(x+1), & -1 \le x \le -0{,}5 \\ 0{,}8 + 0{,}6(x+0{,}5) - 0{,}8(x+0{,}5)^3, & -0{,}5 \le x \le 0 \\ 1 - 1{,}2x^2 + 0{,}8x^3, & 0 \le x \le 0{,}5 \\ 0{,}8 - 0{,}6(x-0{,}5), & 0{,}5 \le x \le 1 \end{cases}$$

Para probar el resultado, veamos que

$$S_\Delta^3(0{,}8) = 0{,}62 \quad \text{y} \quad f(0{,}8) = 0{,}61.$$

Además se cumple

$$\max_{x\in[a,b]} \left|f(x) - S_\Delta^3(x)\right| \le Kh^4 \max_{x\in[a,b]} \left|f^{(4)}(x)\right|.$$

3. Interpolación trigonométrica

DEFINICIÓN. *Sea $n \in \mathbb{N}$, entonces el conjunto*

$$T_n := \Big\{ \sum_{j=0}^{n} c_j e^{ijx},\ c_j \in \mathbb{C},\ j = 0, 1, \ldots, n \Big\}$$

es denominado el conjunto de los polinomios trigonométricos complejos de grado menor o igual a n.

Para la interpolación: tenemos los puntos de partición $x_0, x_1, \ldots, x_{n-1} \in [0, 2\pi[$ con $x_k \neq x_j$ para $k \neq j$ y los valores correspondientes $f_0, f_1, \ldots, f_{n-1} \in \mathbb{C}$. Buscamos un polinomio $p \in T_{n-1}$ tal que $p(x_k) = f_k$, $k = 0, \ldots, n-1$.

TEOREMA 6.8. *Sean $(x_k, f_k) \in [0, 2\pi[\times \mathbb{C}$, $k = 0, \ldots, n-1$ con $x_k \neq x_j$ para $k \leq j$; entonces existe un único polinomio trigonométrico $P \in T_{n-1}$ tal que $P(x_k) = f_k$, $k = 0, \ldots, n-1$.*

DEMOSTRACIÓN. Sea

$$P(x) = \sum_{j=0}^{n-1} c_j e^{ijx}.$$

Exigiendo: $P(x_k) = f_k$, $k = 0, \ldots, n-1$ se obtiene el siguiente sistema lineal de ecuaciones:

$$\sum_{j=0}^{n-1} c_j e^{ijx_k} = f_k, \quad k = 0, \ldots, n-1.$$

Este sistema tendrá solución única si y solamente si el sistema homogéneo asociado tiene solamente la solución trivial.
Tenemos que probar que si

$$\sum_{j=0}^{n-1} c_j e^{ijx_k} = 0,\ k = 0, \ldots, n-1 \quad \text{entonces} \quad c_j = 0,\ j = 0, \ldots, n-1.$$

Definimos $z_k = e^{ix_k}$, $k = 0, 1, \ldots, n-1$. Se cumple que los z_k son puntos distintos de la circunferencia unitaria del plano complejo, y

$$\sum_{j=0}^{n-1} c_j e^{ijx_k} = \sum_{j=0}^{n-1} c_j z_k^j.$$

Definiendo $Q_{n-1}(z) := \sum_{j=0}^{n-1} c_j z^j$, tenemos que Q_{n-1} es un polinomio complejo de grado menor o igual a $(n-1)$ y

$$Q_{n-1}(z_k) = 0, \quad k = 0, 1, \ldots, n-1;$$

esto es, Q_{n-1} tiene n ceros. Esto implica que necesariamente $Q_{n-1}(z) = 0$, para todo $z \in \mathbb{C}$; de donde $c_j = 0$, $j = 0, 1, \ldots, n-1$. □

DEFINICIÓN. *Sea $n \in \mathbb{N}$. Entonces se define*

$$T_n^{\mathbb{R}} := \{ \frac{a_0}{2} + \sum_{j=1}^{n} (a_j \cos jx + b_j \operatorname{sen} jx) \,/\, a_o, a_j, b_j \in \mathbb{R},\ j = 1, \ldots, n \}$$

como el conjunto de polinomios trigonométricos reales de grado menor o igual a n.

TEOREMA 6.9. *Sean los puntos* $(x_k, g_k) \in [0, 2\pi[\times\mathbb{R}$, $k = 0, \ldots, 2n$ *con* $x_k \neq x_j$ *para* $k \leq j$. *Sea* $P(x) = \sum_{j=0}^{2n} c_j e^{ijx}$ *el polinomio trigonométrico complejo único de grado menor o igual a* $2n$ *con* $P(x_k) = e^{inx_k} g_k$, $k = 0, 1, \ldots, 2n$. *Entonces existe un polinomio trigonométrico real único* $q \in T_n^{\mathbb{R}}$ *tal que* $q(x_k) = g_k$, $k = 0, 1, \ldots, 2n$. *Este polinomio tiene la forma*

$$q(x) = \frac{1}{2}a_0 + \sum_{j=1}^{n}(a_j \cos jx + b_j \operatorname{sen} jx)$$

donde $a_0 = 2c_n$, $a_j = 2\,\Re(c_{n-j})$, $b_j = 2\Im(c_{n-j})$; $j = 1, \ldots, n$.

DEMOSTRACIÓN. Definimos $\tilde{P} \in T_{2n}$ por

$$\tilde{P}(x) = e^{2inx}\overline{P(x)} = e^{2inx}\sum_{j=0}^{2n}\overline{c_j}e^{-ijx} = \sum_{j=0}^{2n}\overline{c_j}e^{(2n-j)ix} = \sum_{j=0}^{2n}\overline{c_j}e^{jix} \tag{21}$$

Se cumple

$$\begin{aligned}\tilde{P}(x_k) &= e^{2inx_k}\overline{P(x_k)} = e^{2inx_k}\overline{P(x_k)} \\ &= e^{2inx_k}\overline{e^{inx_k}g_k} = e^{2inx_k}e^{-inx_k}g_k = e^{inx_k}g_k = P(x_k)\end{aligned}$$

$\tilde{P}$ cumple las mismas condiciones interpolantes que P. Entonces por la unicudad de P y (21) se obtiene que

$$c_j = \overline{c_{2n-j}},\ j = 0, \ldots, 2n \quad \text{implica} \quad c_{n+j} = \overline{c_{n-j}},\ j = 0, \ldots, n.$$

Luego $c_n = \overline{c_n}$, de donde c_n es real. Además

$$\begin{aligned}e^{-inx}P(x) &= e^{-inx}\sum_{j=0}^{2n}c_j e^{ijx} = \sum_{j=0}^{2n}c_j e^{(j-n)ix} = c_n + \sum_{j=1}^{n}[c_{n-j}e^{-jix} + c_{n+j}e^{ijx}] \\ &= c_n + \sum_{j=1}^{n}[c_{n-j}(\cos jx - i\operatorname{sen} jx) + c_{n+j}(\cos jx + i\operatorname{sen} jx)] \\ &= c_n + \sum_{j=1}^{n}[(c_{n-j} + \overline{c_{n-j}})\cos jx + i(-c_{n-j} + \overline{c_{n-j}})\operatorname{sen} jx] \\ &= \underbrace{c_n}_{a_0/2} + \sum_{j=1}^{n}[\underbrace{2\Re(c_{n-j})}_{a_j}\cos jx + \underbrace{2\Im(c_{n-j})}_{b_j}\operatorname{sen} jx]\end{aligned}$$

Sea $\hat{q}(x) = e^{-inx}P(x)$, entonces $\hat{q}(x_k) = e^{-inx_k}P(x_k) = e^{-inx_k}e^{inx_k}g_k = g_k$ y por tanto $q(x) = \hat{q}(x)$. □

3.1. Puntos de partición equidistantes.

LEMA 6.10. *Sea* $N \in \mathbb{N}$, $W_N = e^{2\pi i/N}$. *Entonces*

$$\frac{1}{N}\sum_{j=0}^{N-1}(W_N^{k-l})^j = \delta_{kl} = \begin{cases} 1, & k = l \\ 0, & k \neq l \end{cases}, \quad 0 \leq k, l \leq N-1.$$

DEMOSTRACIÓN. Para $l = k$, $0 \leq l, k \leq N$ se tiene $\frac{1}{N}\sum_{j=0}^{N-1}(W_N^0)^j = 1$.

Para $l \neq k$, $0 \leq l, k \leq N-1$, se tiene: $W_N^{k-l} = e^{\frac{2\pi}{N}(k-l)i} \neq 1$,

$$\begin{aligned}\frac{1}{N}\sum_{j=0}^{N-1}(W_N^{k-l})^j &= \frac{1}{N}\frac{1-W_N^{(k-l)N}}{1-W_N^{(k-l)}} = \frac{1}{N}\frac{1-e^{\frac{2\pi i}{N}(k-l)N}}{1-e^{\frac{2\pi i}{N}(k-l)}} \\ &= \frac{1}{N}\frac{1-e^{2(k-l)\pi i}}{1-W_N^{(k-l)}} = \frac{1}{N}\frac{(1-1)}{1-W_N^{(k-l)}} = 0.\end{aligned}$$

□

TEOREMA 6.11. *Para $N \in \mathbb{N}$, sea $W_N = e^{2\pi i/N}$, y sean dados los puntos de partición equidistantes $x_k = \frac{2\pi k}{N}$, $k = 0, 1, \ldots, N-1$ y sus valores correspondientes $f_k \in \mathbb{C}$, $k = 0, 1, \ldots, N-1$. Entonces el único polinomio complejo $P \in T_{n-1}$ con $P(x_k) = f_k$, $k = 0, 1, \ldots, N-1$ está dado por:*

$$P(x) = \sum_{j=0}^{N-1} c_j e^{ijx} \text{ con } c_j = \frac{1}{N}\sum_{k=0}^{N-1} W_N^{-jk} f_k, \quad j = 0, \ldots, N-1.$$

DEMOSTRACIÓN. La unicidad se tiene por el teorema 6.8. Falta mostrar que $P(x)$ satisface las condiciones interpolantes.

$$P(x_k) = \sum_{j=0}^{N-1}\left(\frac{1}{N}\sum_{l=0}^{N-1} W_N^{-jl} f_l\right) e^{ijx_k}$$

Se cumple: $e^{ijx_k} = e^{ij\frac{2\pi k}{N}} = (e^{2\pi i/N})^{jk} = W_N^{jk}$. Luego

$$P(x_k) = \sum_{l=0}^{N-1}\left(\frac{1}{N}\sum_{j=0}^{N-1} W_N^{j(k-l)}\right) f_l = \sum_{l=0}^{N-1}\delta_{kl} f_l = f_k, \quad k = 0, 1, \ldots, N-1.$$

□

TEOREMA 6.12. *Sea $N \in \mathbb{N}$,*

$$n := \begin{cases} \frac{1}{2}(N-1), & \text{si } N \text{ es impar} \\ \frac{1}{2}N, & \text{si } N \text{ es par.} \end{cases}$$

Dados los puntos de partición $x_k = \frac{2\pi k}{N}$, con sus valores correspondientes g_k, $k = 0, 1, \ldots, N-1$. Sean

$$\begin{aligned} a_j &= \frac{2}{N}\sum_{k=0}^{N-1} g_k \cos jx_k, \\ b_j &= \frac{2}{N}\sum_{k=0}^{N-1} g_k \operatorname{sen} jx_k, \quad j = 0, 1, \ldots, n. \end{aligned}$$

Definiendo el polinomio trigonométrico real q de grado menor o igual a n

$$q(x) := \begin{cases} \frac{a_0}{2} + \sum_{j=1}^{n}(a_j \cos jx + b_j \operatorname{sen} jx), & \text{para } N = 2n+1 \\ \frac{a_0}{2} + \sum_{j=1}^{n-1}(a_j \cos jx + b_j \operatorname{sen} jx) + \frac{a_n}{2}\cos nx, & \text{para } N = 2n \end{cases}$$

Se cumple $q(x_k) = g_k$, $k = 0, 1, \ldots, N-1$.

DEMOSTRACIÓN.

a) Para $N = 2n+1$. Sea $P(x) = \sum_{j=0}^{2n} c_j e^{ijx}$ el polinomio trigonométrico complejo de grado menor o igual a $2n$, que cumple las condiciones interpolantes

$$P(x_k) = e^{inx_k} g_k =: f_k, \quad k = 0, 1, \ldots, 2n.$$

Por el teorema 6.11 se tiene: $c_j = \frac{1}{N} \sum_{k=0}^{N-1} W_N^{-jk} e^{inx_k} g_k$. Se cumple

$$\begin{aligned} c_j &= \frac{1}{N} \sum_{k=0}^{N-1} W_N^{-jk} e^{in\frac{2\pi k}{N}} g_k = \frac{1}{N} \sum_{k=0}^{N-1} W_N^{(n-j)k} g_k \\ c_{n-j} &= \frac{1}{N} \sum_{k=0}^{N-1} W_N^{-(n-j)k} e^{inx_k} g_k = \frac{1}{N} \sum_{k=0}^{N-1} [e^{\frac{2\pi i}{n}}]^{-(n-j)k} e^{in\frac{2\pi k}{n}} g_k \\ &= \frac{1}{N} \sum_{k=0}^{N-1} e^{\frac{2\pi i}{n} jk} g_k = \frac{1}{N} \sum_{k=0}^{N-1} e^{ijx_k} g_k \\ &= \frac{1}{N} \sum_{k=0}^{N-1} g_k [\cos jx_k + i \operatorname{sen} jx_k] \end{aligned}$$

Se tiene que $c_{n-j} = \Re(c_{n-j}) + i\Im(c_{n-j})$. Por el teorema 6.9, $\frac{1}{2}(a_j + i\, b_j) = \frac{1}{N} \sum_{k=0}^{N-1} g_k(\cos jx_k + i \operatorname{sen} jx_k)$. Igualando las partes real e imaginaria se concluye.

b) Caso $N = 2n$. Sea $P(x) = \sum_{j=0}^{2n-1} c_j e^{ijx}$ el polinomio trigonométrico complejo de grado menor o igual a $2n-1$, tal que

$$P(x_k) = e^{inx_k} g_k =: f_k, \quad k = 0, 1, \ldots, 2n-1.$$

[Nota: No se puede aplicar el teorema 6.9 pues exige $k = 0, \ldots, 2N$]. Definimos el polinomio $\tilde{q}$ por $\tilde{q}(x) = \Re\big(e^{-inx} P(x)\big)$, este polinomio cumple $\tilde{q}(x_k) = g_k$, $k = 0, 1, \ldots, 2n-1$. Luego

$$\tilde{q}(x) = \Re\Big(\sum_{j=0}^{2n-1} c_j e^{(j-n)ix}\Big) = \Re(c_n + \sum_{j=1}^{n-1}(c_{n-j} e^{-ijx} + c_{n+j} e^{ijx}) + c_0 e^{-inx}\Big)$$

Entonces

$$\tilde{q}(x) = \frac{1}{2}\left[c_n + \overline{c_n} + \sum_{j=0}^{n-1}[(c_{n-j} + \overline{c_{n+j}})e^{-ijx} + (c_{n+j} + \overline{c_{n-j}})e^{ijx}] + c_0^{-inx} + \overline{c_0} e^{inx}\right]$$

□

3.2. Transformada Rápida de Fourier (FFT). El cálculo de los coeficientes de los polinomios trigonométricos exige $N(N-1)$ multiplicaciones complejas, lo cual indica que el algoritmo utilizado no es muy eficiente. Aplicando la transformada rápida de Fourier (FFT) (*Fast Fourier Transform*), inventada por Cooley/Tukey (1965) se puede reducir esta cantidad de multiplicaciones para el caso $N = 2^p$ (potencia de 2) a $\frac{1}{2}NP = \frac{N}{2}\log_2 N$, lo cual es una gran mejora.

La idea es la siguiente: Se puede reducir el cálculo de un vector de una transformada discreta de Fourier calculando dos DFT's (*Discrete Fourier Transform*) de longitud media. En el caso $N = 2^p$ se puede continua este proceso hasta que se manejan en

el p-ésimo paso n DFT's de longitud 1. La DFT $F_N : \mathbb{C}^N \to \mathbb{C}^N$ es representada por la matriz $\Omega_N = (\overline{W_N}^{jk})_{0\le j,k\le N-1} \in \mathbb{C}^{N\times N}$ con $\overline{W_N} = e^{-2\pi i/N}$. Entonces se cumple

$$F_n f = \Omega_N f, \quad \text{para todo } f = (f_0, f_1, \ldots, f_{N-1}) \in \mathbb{C}^N.$$

LEMA 6.13. *Para $N \in \mathbb{N}$, sea $\Omega_N \in \mathbb{C}^{N\times N}$ definido por $\Omega_N := (\overline{W_N}^{jk})$, $0 \le j,k \le N-1$ con $\overline{W_N} = e^{-2\pi i/N}$. Para N par sea $n = \frac{1}{2}N$ y $P_N \in \mathbb{R}^{N\times N}$ la matriz de permutación $P_N := (e_1, e_3, \ldots, e_{N-1}, e_2, e_4, \ldots, e_N)^t \in \mathbb{R}^{N\times N}$; donde e_j el el j-ésimo vector canónico de $\mathbb{R}^N$. Entonces se cumple*

$$P_N\Omega_N = \begin{bmatrix} \Omega_n & 0_n \\ 0_n & \Omega_n \end{bmatrix} \begin{bmatrix} I_n & I_n \\ D_n & -D_n \end{bmatrix} = \begin{bmatrix} \Omega_n & \Omega_n \\ \Omega_n D_n & -\Omega_n D_n \end{bmatrix}$$

donde $D_n := \operatorname{diag}(\overline{W_N}^0, \overline{W_N}^1, \ldots, \overline{W_N}^{N-1})$.

DEMOSTRACIÓN. Sea $f = (f_0, \ldots, f_{N-1})^t \in \mathbb{C}^N$ y $g := \Omega_N f$ la transformada discreta de Fourier. Entonces se cumple

$$P_N\Omega_N f = P_N g = (g_0, g_2, \ldots, g_{N-2}, g_1, g_3, \ldots, g_{N-1})^t.$$

Luego la aplicación de la matriz de permutación P_N respecto al vector $g = (g_0, g_1, \ldots, g_{N-1})^t$ produce la permutación de las componentes de g.
Se cumplen:

$$\begin{array}{rcl} \overline{W_N}^{2j(n+k)} & = & \overline{W_N}^{2jn+2jk} = (\overline{W_N}^N)^j \overline{W_N}^{2jk} = (\overline{W_N}^2)^{jk} = \overline{W_n}^{jk} \\ \overline{W_N}^{(2j+1)(n+k)} & = & \overline{W_N}^{2jn+n+(2j+1)k} = \overline{W_N}^{n+(2j+1)k} = -\overline{W_N}^{(2j+1)k} \\ & = & -(\overline{W_N}^2)^{jk}\overline{W_N}^k = -\overline{W_n}^{jk}\overline{W_N}^k \end{array}$$

Para $j = 0, \ldots, n-1$ se cumple

$$\begin{array}{rcl} g_{2j} & = & \displaystyle\sum_{k=0}^{N-1} \overline{W_N}^{2jk} f_k = \sum_{k=0}^{n-1} (\overline{W_N}^2)^{jk}(f_k + f_{n+k}) = \sum_{k=0}^{n-1} \overline{W_n}^{jk}(f_k + f_{n+k}) \\ g_{2j+1} & = & \displaystyle\sum_{k=0}^{N-1} \overline{W_N}^{(2j+1)k} f_k = \sum_{k=0}^{n-1} (\overline{W_N}^2)^{jk}(f_k - f_{n+k})\overline{W_N}^k \\ & = & \displaystyle\sum_{k=0}^{n-1} \overline{W_n}^{jk}(f_k - f_{n+k})\overline{W_N}^k. \end{array}$$

□

EJEMPLO 6.5. Sean $N = 2^2 = 4$, $f = (f_0, f_1, f_2, f_3)^t \in \mathbb{C}^4$, $\overline{W} = \overline{W_4} = e^{-2\pi i/4}$. Tenemos entonces

$$P_4 \begin{bmatrix} q_0 \\ q_1 \\ q_2 \\ q_3 \end{bmatrix} = \begin{bmatrix} q_0 \\ q_2 \\ q_1 \\ q_3 \end{bmatrix}.$$

Además

$$\begin{bmatrix} q_0 \\ q_2 \\ q_1 \\ q_3 \end{bmatrix} = P_4\Omega_4 \begin{bmatrix} f_0 \\ f_1 \\ f_2 \\ f_3 \end{bmatrix} = \left[\begin{array}{c|c} \Omega_2 & 0_2 \\ \hline 0_2 & \Omega_2 \end{array}\right] \left[\begin{array}{c|c} I_2 & I_2 \\ \hline D_2 & -D_2 \end{array}\right] \begin{bmatrix} f_0 \\ f_1 \\ f_2 \\ f_3 \end{bmatrix}$$

$$= \left[\begin{array}{c|c} \Omega_2 & 0_2 \\ \hline 0_2 & \Omega_2 \end{array}\right] \left[\begin{array}{cc|cc} 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \\ \hline \overline{W}^0 & 0 & -\overline{W}^0 & 0 \\ 0 & \overline{W}^1 & 0 & -\overline{W}^1 \end{array}\right] \begin{bmatrix} f_0 \\ f_1 \\ f_2 \\ f_3 \end{bmatrix}$$

$$= \left[\begin{array}{c|c} \Omega_2 & 0_2 \\ \hline 0_2 & \Omega_2 \end{array}\right] \begin{bmatrix} f_0 + f_2 \\ f_1 + f_3 \\ (f_0 - f_2)\overline{W}^0 \\ (f_1 - f_3)\overline{W}^1 \end{bmatrix}$$

Paso 1.

$$f^1 = \left[\begin{array}{cc|cc} 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \\ \hline \overline{W}^0 & 0 & -\overline{W}^0 & 0 \\ 0 & \overline{W}^1 & 0 & -\overline{W}^1 \end{array}\right] \begin{bmatrix} f_0 \\ f_1 \\ f_2 \\ f_3 \end{bmatrix} = \begin{bmatrix} f_0 + f_2 \\ f_1 + f_3 \\ (f_0 - f_2)\overline{W}^0 \\ (f_1 - f_3)\overline{W}^1 \end{bmatrix}$$

Ahora veamos que

$$P_2\Omega_2 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \Omega_2 = \Omega_2$$

de donde

$$\Omega_2 = P_2\Omega_2 = \left[\begin{array}{c|c} \Omega_1 & 0_1 \\ \hline 0_1 & \Omega_1 \end{array}\right] \left[\begin{array}{c|c} I_1 & I_1 \\ \hline D_1 & -D_1 \end{array}\right] = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ \overline{W}^0 & -\overline{W}^0 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ \overline{W}^0 & -\overline{W}^0 \end{bmatrix}$$

Paso 2.

$$\begin{bmatrix} g_0 \\ g_1 \\ g_2 \\ g_3 \end{bmatrix} = \begin{bmatrix} f_0^2 \\ f_1^2 \\ f_2^2 \\ f_3^2 \end{bmatrix} = \left[\begin{array}{cc|cc} 1 & 1 & 0 & 0 \\ \overline{W}^0 & -\overline{W}^0 & 0 & 0 \\ \hline 0 & 0 & 1 & 1 \\ 0 & 0 & \overline{W}^0 & -\overline{W}^0 \end{array}\right] \begin{bmatrix} f_0^1 \\ f_1^1 \\ f_2^1 \\ f_3^1 \end{bmatrix} = \begin{bmatrix} f_0^1 + f_1^1 \\ (f_0^1 - f_1^1)\overline{W}^0 \\ f_2^1 + f_3^1 \\ (f_2^1 - f_3^1)\overline{W}^0 \end{bmatrix}$$

Resumiendo tenemos:

Entrada		Paso 1		Paso 2	Salida
f_0	0	$f_0^1 = f_0 + f_2$	0	$f_0^2 = f_0^1 + f_1^1$	g_0
f_1	1	$f_1^1 = f_1 + f_3$	2	$f_1^2 = (f_0^1 + f_1^1)\overline{W}^0$	g_2
f_2	2	$f_2^1 = (f_0 - f_2)\overline{W}^0$	1	$f_2^2 = f_2^1 + f_3^1$	g_1
f_3	3	$f_3^1 = (f_1 - f_3)\overline{W}^0$	3	$f_3^2 = (f_2^1 + f_3^1)\overline{W}^0$	g_3

Los coeficientes de Fourier son, finalmente: $\frac{g_0}{N}, \frac{g_1}{N}, \frac{g_2}{N}, \frac{g_3}{N}$.

4. Ejercicios

1. Demuestre que si f es un polinomio de grado k, entonces para $n > k$

$$f[x_0, x_1, \ldots, x_n] = 0.$$

2. Demuestre que las diferencias divididas son mapeos lineales en relación con las funciones, esto es, para dos funciones f, g y escalares α, β

   $(\alpha f + \beta g)[x_0, x_1, \ldots, x_n] = \alpha f[x_0, x_1, \ldots, x_n] + \beta g[x_0, x_1, \ldots, x_n]$.

3. Demuestre la fórmula

$$f[x_0, x_1, \ldots, x_n] = \sum_{i=0}^{n} f(x_i) \prod_{\substack{j=0 \\ j \neq i}}^{n} (x_n - x_j)^{-1}.$$

4. Demuestre que

$$f[x_0, x_1, \ldots, x_n] = \frac{\begin{vmatrix} 1 & x_0 & x_0^2 & \ldots & x_0^{n-1} & f(x_0) \\ 1 & x_1 & x_1^2 & \ldots & x_1^{n-1} & f(x_1) \\ \vdots & \vdots & \vdots & & \vdots & \vdots \\ 1 & x_n & x_n^2 & \ldots & x_n^{n-1} & f(x_n) \end{vmatrix}}{2 \begin{vmatrix} 1 & x_0 & x_0^2 & \ldots & x_0^{n-1} & x_0^n \\ 1 & x_1 & x_1^2 & \ldots & x_1^{n-1} & x_0^n \\ \vdots & \vdots & \vdots & & \vdots & \vdots \\ 1 & x_n & x_n^2 & \ldots & x_n^{n-1} & x_0^n \end{vmatrix}}.$$

5. Demuestre la fórmula de Leibniz

$$(fg)[x_0, x_1, \ldots, x_n] = \sum_{k=0}^{n} f[x_0, x_1, \ldots, x_k] g[x_k, x_{k+1}, \ldots, x_n].$$

6. Encuentre el polinomio de interpolación de Newton para los siguientes datos:

x_i	1	3/2	0	2
y_i	3	13/4	3	5/3

7. Realice la interpolación de los datos de la tabla

x_i	1,1	1,9	2,7	4,3	5,1	7,8
y_i	11,2	16,8	18,7	8,1	2,7	14,3

   utilizando un spline cúbico natural.

8. Sea $f \in C^2[a, b]$ y tomemos $a = t_0 < t_1 < \ldots < t_n = b$. Si S es el spline cúbico natural que interpola f en los puntos t_i, $0 \leq i \leq n$, entonces

$$\int_a^b \big[S''(x)\big]^2 dx \leq \int_a^b \big[f''(x)\big]^2 dx.$$

9. Determine todos los valores de a, b, c, d y e para los cuales la siguiente función es un spline cúbico:

$$f(x) = \begin{cases} a(x-2)^2 + b(x-1)^3, & x \in]-\infty, 1] \\ c(x-2)^2, & x \in [1, 3] \\ d(x-2)^2 + e(x-3)^3, & x \in [3, +\infty[. \end{cases}$$

10. Determine todos los valores a, b, c de manera tal que la siguiente función sea un spline cúbico con nudos 0, 1, 2:

$$f(x) = \begin{cases} 3 + x - 9x^2, & x \in [0, 1] \\ a + b(x-1) + c(x-1)^2 + d(x-1)^3, & x \in [1, 2]. \end{cases}$$

    Calcule d de forma que $\displaystyle\int_0^2 \big[f''(x)\big]^2 dx$ sea mínimo. Finalmente, encuentre el valor de d que hace de f un spline cúbico natural y explique porqué este valor es distinto del que se calculó previamente.

11. Determine si la siguiente función es un spline cúbico:
$$f(x) = \begin{cases} x^3 + x, & x \leq 0 \\ x^3 - x, & x \geq 0. \end{cases}$$

12. Interpole y grafique una curva paramétrica en el plano, parametrizada por el intervalo $[0, 1]$, a partir de los siguientes datos:
$$x = \begin{bmatrix} -1 \\ 0{,}5 \\ 1 \\ 0 \\ 1 \end{bmatrix}, \quad y = \begin{bmatrix} 0 \\ 1 \\ 0 \\ -1 \\ 0 \end{bmatrix}.$$

13. Sean $L_i(x)$ los polinomios de Lagrange para abscisas de soporte distintas dos a dos $x_0, \ldots, x_n$, y sea $c_i = L_i(0)$. Muestre que

    a) $\displaystyle\sum_{i=0}^{n} c_i x_i^j = \begin{cases} 1 & \text{para } j = 0, \\ 0 & \text{para } j = 1, 2, \ldots, n, \\ (-1)^n x_0 x_1 \cdots x_n \text{ para } j = n+1, \end{cases}$

    b) $\displaystyle\sum_{i=0}^{n} L_i(x) = 1.$

14. Pruebe que el polinomio trigonométrico interpolante con abscisas de soporte x_k,
$$a \leq x_0 < x_1 \cdots < x_{2n} < a + 2\pi$$
y ordenadas de soporte $y_0, \ldots, y_{2n}$ es precisamente
$$T(x) = \sum_{j=0}^{2n} y_j t_j(x),$$
donde
$$t_j(x) = \frac{\displaystyle\prod_{\substack{k=0 \\ k \neq j}} \sin \frac{x - x_k}{2}}{\displaystyle\prod_{\substack{k=0 \\ k \neq j}} \sin \frac{x_j - x_k}{2}}.$$

15. Considere $f(x) = \ln(x+1)$ en el intervalo $I = [0, 1]$. Sea $p_n(x)$ el polinomio que interpola f en los puntos $x_0, \ldots, x_n \in I$.

    a) Calcule una cota superior para el error
    $$\|f - p_n\|_\infty = \sup_{x \in I} \big| f(x) - p_n(x) \big|$$
    que dependa solamente de n y no de la elección de los puntos de interpolación.

    b) Pruebe que $p_n \to f$ uniformemente.

    c) ¿Para qué valor de n se tiene que $\|f - p_n\|_\infty < 10^{-6}$?

Capítulo 7

Integración Numérica

Para el cálculo aproximado de integrales definidas de la forma

$$I(f) = \int_a^b f(x)dx, \quad f : \mathbb{R} \to \mathbb{R}$$

Se usan *fórmulas de cuadratura* de la forma

$$Q_n(f) = \sum_{j=0}^{n} \alpha_j f(x_j)$$

donde las constantes α_j son llamadas *pesos de integración*.

1. Fórmulas de Newton-Cotes

Consideremos una partición del intervalo $[a, b]$:

$$a = x_0 < x_1 < \cdots < x_n = b$$

Sea P_n el polinomio interpolante con $P_n(x_i) = f(x_i)$, $i = 0, \cdots, n$. Bajo estas condiciones, existe un único polinomio interpolante de grado menor o igual a n en la forma de Lagrange

$$P_n(x) = \sum_{j=0}^{n} f(x_j)L_j(x) \qquad \text{con} \qquad L_j(x) = \prod_{\substack{k=0 \\ k\neq j}}^{n} \frac{x - x_k}{x_j - x_k}$$

Utilizando este polinomio como aproximación para f resulta

$$Q_n(f) = \int_a^b P_n(x)dx = \sum_{j=0}^{n} \left[\int_a^b L_j(x)dx \right] f(x_j) = \sum_{j=0}^{n} \alpha_j f(x_j)$$

donde $\alpha_j = \displaystyle\int_a^b L_j(x)dx, \quad j = 0, \cdots, n.$

Definición. *La fórmula de cuadratura de Newton-Cotes está definida por*

$$Q_n(f) = \sum_{j=0}^{n} \alpha_j f(x_j) \qquad con \qquad \alpha_j = \int_a^b L_j(x)dx, \quad j = 0, \cdots, n$$

donde α_j son los pesos de integración y con el error de integración

$$E_n(f) = I(f) - Q_n(f) = \int_a^b f(x)dx - \sum_{j=0}^{n} \alpha_j f(x_j)$$

Para polinomios P_k de grado menor o igual a n se cumple $E_n(P_k) = 0$. Por el teorema 6.4, se cumple lo siguiente:

Teorema 7.1. *Para $a = x_0 < \cdots < x_n = b$, existe una única fórmula de cuadratura*

$$Q_n(f) = \sum_{j=0}^{n} \alpha_j f(x_j) \qquad con \qquad \alpha_j = \int_a^b L_j(x)dx, \quad j = 0, \cdots, n$$

la cual es exacta para todos los polinomios de grado menor o igual a n.

TEOREMA 7.2. *Para los puntos de partición equidistante*

$$x_j = a + jh, \quad j = 0, \cdots, n \qquad h = \frac{b-a}{n}$$

del intervalo $[a, b]$*, los pesos de integración están dados por*

$$\alpha_j^{(n)} = (-1)^{n-j} \frac{h}{j!(n-j)!} \int_0^n \prod_{\substack{k=0 \\ k \neq j}}^{n} (t-k) dt.$$

Demostración.

$$\alpha_j^{(n)} = \int_a^b L_j(x) dx = \int_a^b \prod_{\substack{k=0 \\ k \neq j}}^{n} \frac{x - x_k}{x_j - x_k} dx = \int_a^b \prod_{\substack{k=0 \\ k \neq j}}^{n} \frac{x - (a+kh)}{h(j-k)} dx$$

Con el cambio de variables $x = a + ht$, $dx = h\, dt$, se obtiene

$$\begin{aligned} \alpha_j^{(n)} &= \int_0^n \prod_{\substack{k=0 \\ k \neq j}}^{n} \frac{h(t-k)}{h(j-k)} h\, dt = \frac{h}{\prod_{\substack{k=0 \\ k \neq j}}^{n} (j-k)} \int_0^n \prod_{\substack{k=0 \\ k \neq j}}^{n} (t-k) dt \\ &= (-1)^{n-j} \frac{h}{j!(n-j)!} \int_0^n \prod_{\substack{k=0 \\ k \neq j}}^{n} (t-k) dt. \end{aligned}$$

De éstas fórmulas resultan las siguientes reglas:

Regla del Trapecio:$(n = 1)$

$$\begin{aligned} \alpha_0^{(1)} &= (b-a) \left(- \int_0^1 (t-1) dt \right) = \frac{b-a}{2} \\ \alpha_1^{(1)} &= (b-a) \int_0^1 t\, dt = \frac{b-a}{2} \\ Q_1(f) &= \frac{b-a}{2} (f(a) + f(b)) \end{aligned}$$

Regla de Simpson:$(n = 2)$

$$\begin{aligned} \alpha_0^{(2)} &= \frac{b-a}{2} \frac{1}{2} \int_0^2 (t-1)(t-2) dt = \frac{b-a}{6} \\ \alpha_1^{(2)} &= \frac{b-a}{2} \left(- \int_0^2 t(t-2) dt \right) = \frac{4(b-a)}{6} \\ \alpha_2^{(2)} &= \frac{b-a}{4} \int_0^2 t(t-1) dt = \frac{b-a}{6} \\ Q_2(f) &= \frac{b-a}{6} \left[f(a) + 4f\left(\frac{a+b}{2} \right) + f(b) \right] \end{aligned}$$

Fórmulas de Newton-Cotes $(1 \leq n \leq 6)$

n	$\alpha_j^{(n)}/(b-a)$							
1	$\frac{1}{2}$	$\frac{1}{2}$						Regla Trapezoidal
2	$\frac{1}{6}$	$\frac{4}{6}$	$\frac{1}{6}$					Regla de Simpson
3	$\frac{1}{8}$	$\frac{3}{8}$	$\frac{3}{8}$	$\frac{1}{8}$				Regla 3/8 de Newton
4	$\frac{7}{90}$	$\frac{32}{90}$	$\frac{12}{90}$	$\frac{32}{90}$	$\frac{7}{90}$			Regla de Milne
5	$\frac{19}{288}$	$\frac{75}{288}$	$\frac{50}{288}$	$\frac{50}{288}$	$\frac{75}{288}$	$\frac{19}{288}$		Anónimo
6	$\frac{41}{1400}$	$\frac{216}{1400}$	$\frac{27}{1400}$	$\frac{272}{1400}$	$\frac{27}{1400}$	$\frac{216}{1400}$	$\frac{41}{1400}$	Regla de Wedolle

Para $n = 1$**:** La regla trapezoidal es exacta para todos los polinomios de grado $n \leq 1$.
Para $n = 2$**:** La regla de Simpson es exacta para polinomios de grado $n \leq 3$, pues

$$\begin{aligned} E_2(x^3) &= I(x^3) - Q_2(x^3) \\ &= \int_a^b x^3 dx - \frac{b-a}{6}\left[a^3 + 4\left(\frac{b+a}{2}\right)^3 + b^3\right] = 0 \end{aligned}$$

pero $E_2(x^4) \neq 0$.
Para $n = 3$**:** Para la regla 3/8 de Newton resulta

$$E_3(x^3) = 0, \quad E_3(x^4) \neq 0$$

Para $n = 4$**:** Para la regla de Milne se obtiene

$$E_4(x^5) = 0, \quad E_4(x^6) \neq 0$$

En general se puede probar que $E_m(x^{m+1}) = 0$ si m es par, y que en caso de que m sea impar resulta solamente

$$E_m(x^m) = 0, \quad \text{y } E_m(x^{m+1}) \neq 0$$

Para $n = 8$ y $n \geq 10$ algunos de los pesos $\alpha_j^{(n)}$ se vuelven negativos, lo cual no tiene ningún sentido.
Utilizando la fórmula del error de un polinomio interpolante se obtiene:

$$\begin{aligned} E_n(f) &= I(f) - Q_n(P_n) = I(f) - I(P_n) = \int_a^b (f(x) - P_n(x))dx \\ &= \int_a^b \frac{f^{(n+1)}(\xi_x)}{(n+1)!} \prod_{k=0}^{n} (x - x_k)dx \end{aligned}$$

$$E_n(f) = \int_a^b \frac{f^{(n+1)}(\xi_x)}{(n+1)!}\rho_n(x)dx$$

donde

$$\rho_n(x) = \prod_{k=0}^{n}(x - x_k).$$

Usando integración por partes se obtiene:

TEOREMA 7.3. *Si $f \in C^{(n+2)}[a,b]$, con n par, entonces el error para la fórmula de cuadratura de Newton-Cotes está dado por*

$$E_n(f) = \frac{K_n}{(n+2)!} f^{(n+2)}(\xi), \qquad a < \xi < b$$

$$K_n = \int_a^b x\rho_n(x)dx, \qquad \rho_n(x) = \prod_{k=0}^{n}(x - x_k).$$

TEOREMA 7.4. *Si n impar y $f \in C^{(n+1)}[a,b]$, entonces el error de la fórmula de de Newton-Cotes está dado por*

$$E_n(f) = \frac{K_n}{(n+1)!} f^{(n+1)}(\xi), \qquad a < \xi < b$$

$$K_n = \int_a^b \rho_n(x)dx, \qquad \rho_n(x) = \prod_{k=0}^{n}(x - x_k).$$

De estos resultados, se obtienen para las siguientes reglas:
Regla Trapezoidal:$(n = 1)$

$$\alpha_0^{(1)} = \frac{b-a}{2}, \quad \alpha_1^{(1)} = \frac{b-a}{2}$$

$$Q_1(f) = \frac{b-a}{2}(f(a) + f(b))$$
$$E_1(f) = -\frac{1}{12}h^3 f''(\xi), \quad h = b - a$$

Regla de Simpson:$(n = 2)$

$$\alpha_0^{(2)} = \frac{b-a}{6} = \alpha_2^{(2)}; \quad \alpha_1^{(2)} = \frac{4(b-a)}{6}$$
$$Q_2(f) = \frac{b-a}{6}\left[f(a) + 4f\left(\frac{a+b}{2}\right) + f(b)\right]$$
$$E_2(f) = -\frac{h^5}{90}f^{(4)}(\xi) = -\frac{1}{2880}(b-a)^5 f^{(4)}(\xi), \quad a < \xi < b$$

Regla 3/8 de Newton:$(n = 3)$

$$Q_3(f) = \frac{b-a}{8}\left[f(a) + 3f\left(\frac{2a+b}{2}\right) + 3f\left(\frac{a+2b}{2}\right) + f(b)\right]$$
$$E_3(f) = -\frac{3h^5}{80}f^{(4)}(\xi) = -\frac{(b-a)^5}{6480}f^{(4)}(\xi), \quad a < \xi < b$$

Para $n \geq 4$ se obtienen fórmulas similares.

1.1. Fórmulas abiertas de Newton-Cotes. En las fórmulas abiertas de Newton-Cotes, los nodos $x_i = x_0 + ih$ se usan para cada $i = 0, \cdots, n$, donde

$$h = \frac{b-a}{b+2} \quad \text{y} \quad x_0 = a + h, \quad x_n = b - h.$$

Definiendo $x_{-1} := a$ y $x_{n+1} := b$ se obtiene la partición

$$a = x_{-1} < x_0 < \cdots < x_n < x_{n+1} = b$$

y todos los nodos empleados para la aproximación se encuentran en el intervalo abierto $\langle a, b\rangle$. Las fórmulas se convierten en

$$\int_a^b = \int_{x_{-1}}^{x_{n+1}} f(x)dx \approx \sum_{j=0}^{n} \alpha_j f(x_j)$$

donde

$$\alpha_j := \int_a^b L_j(x)dx$$

TEOREMA 7.5. *Si $\hat{K}_n(f) = \sum_{j=0}^{n} \alpha_j f(x_j)$ es la fórmula abierta de Newton-Cotes para $(n+1)$ puntos, tal que $x_{-1} = a$, $x_{n+1} = b$ y $h = (b-a)/(n+2)$, entonces:*

(i) *Si* $f \in C^{(n+2)}[a,b]$ *con* n *par, entonces existe* $\xi \in \langle a,b\rangle$ *tal que*

$$\int_a^b f(x)dx = \sum_{j=0}^{n} \alpha_j f(x_j) + \frac{h^{(n+3)} f^{(n+2)}(\xi)}{(n+2)!} \int_{-1}^{n+1} t^2(t-1)\cdots(t-n)dt$$

(ii) *Si* $f \in C^{(n+1)}[a,b]$ *con* n *impar, entonces existe* $\xi \in \langle a,b\rangle$ *tal que*

$$\int_a^b f(x)dx = \sum_{j=0}^{n} \alpha_j f(x_j) + \frac{h^{(n+2)} f^{(n+1)}(\xi)}{(n+1)!} \int_{-1}^{n+1} t(t-1)\cdots(t-n)dt$$

Las fórmulas abiertas de Newton-Cotes

Para $n = 0$**:** Regla del Punto Medio

$$\int_{x-1}^{x_1} f(x)dx = 2hf(x_0) + \frac{h^3}{3} f''(\xi), \quad \text{donde } \xi \in \langle x_{-1}, x_1\rangle$$

Para $n = 1$**:**

$$\int_{x-1}^{x_2} f(x)dx = \frac{3}{2}h[f(x_0) + f(x_1)]\frac{3}{4}h^3 f''(\xi),$$

$$\text{donde } \xi \in \langle x_{-1}, x_2\rangle$$

Para $n = 2$**:**

$$\int_{x-1}^{x_3} f(x)dx = \frac{4}{3}h[2f(x_0) - f(x_1) + 2f(x_2)]\frac{14}{45}h^5 f^{(4)}(\xi),$$

$$\text{donde } \xi \in \langle x_{-1}, x_3\rangle$$

Para $n = 3$**:**

$$\int_{x-1}^{x_4} f(x)dx = \frac{5}{24}h[11f(x_0) + f(x_1) + f(x_2) + 11f(x_3)] + \frac{95}{144}h^5 f^{(4)}(\xi),$$

$$\text{donde } \xi \in \langle x_{-1}, x_4\rangle$$

1.2. Regla Trapezoidal Compuesta. La composición de la fórmula trapezoidal se puede realizar de la siguiente manera:
Sea $x_j = a + jh$, $j = 0, 1, \cdots, n$ donde $n \in \mathbb{N}$, $h = (b-a)/n$ una partición regular de $[a,b]$ y $f \in C^2[a,b]$. Aplicando la regla trapezoidal en los subintervalos $[x_{j-1}, x_j]$, $j = 1, 2, \cdots, n$ se obtiene

$$\begin{aligned}\int_a^b f(x)dx &= \sum_{j=1}^{n} \int_{x_{j-1}}^{x_j} f(x)dx \\ &= \sum_{j=1}^{n} \left[\frac{h}{2}(f(x_{j-1}) + f(x_j)) - \frac{1}{12}h^3 f''(\xi_j)\right]\end{aligned}$$

donde $\xi_j \in \langle x_{j-1}, x_j\rangle$.

$$\int_a^b f(x)dx = h\left[\frac{f(x_0)}{2} + \sum_{j=1}^{n} f(x_j) + \frac{f(x_n)}{2}\right] - \sum_{j=1}^{n} \frac{1}{12}h^3 f''(\xi_j)$$

De esto se obtiene la fórmula trapezoidal compuesta:

$$T_n(f) := h\left[\frac{f(x_0)}{2} + \sum_{j=1}^{n} f(x_j) + \frac{f(x_n)}{2}\right]$$

$$\int_a^b f(x)dx = T_n(f) - \frac{h^2(b-a)}{12}\left(\frac{1}{n}\sum_{j=1}^{n} f''(\xi_j)\right)$$

Por el teorema del valor intermedio, el error puede ser expresado como:

$$\int_a^b f(x)dx - T_n(f) = -\frac{h^2(b-a)}{12} f''(\xi)$$

para algún $\xi \in \langle a, b\rangle$.

1.3. Regla Compuesta de Simpson. De manera similar se obtiene esta regla. Sean $n = 2m$ (par), $m \in \mathbb{N}$, $h = (b-a)/n$, $x_j = a+jh$, $j = 0, \cdots, n$, $f \in C^4[a, b]$. Aplicando la Regla compuesta de Simpson en los subintervalos $[x_{2(j-1)}, x_{2j}]$, $j = 1, \cdots, m$ se obtiene

$$\int_a^b f(x)dx = \sum_{j=1}^{m} \int_{x_{2j-2}}^{x_{2j}} f(x)dx = S_n[a, b] - \frac{h^4(b-a)}{180} \left[\frac{1}{m}\sum_{j=1}^{m} f^{(4)}(\xi_j)\right]$$

donde $\xi_j \in \langle x_{2(j-1)}, x_{2j}\rangle$ y

$$S_n[a, b] := \frac{h}{3}\left[f(x_0) + 4\sum_{j=1}^{m} f(x_{2j-1}) + 2\sum_{j=1}^{m-1} f(x_{2j}) + f(x_n)\right]$$

Por el teorema del valor intermedio el error puede ser expresado como:

$$\int_a^b f(x)dx - S_n[a, b] = -\frac{h^4(b-a)}{180} f^{(4)}(\xi),$$

para algún $\xi \in \langle a, b\rangle$.

Ejemplo. Se requiere calcular

$$\int_1^3 \frac{100}{x^2} sen\left(\frac{10}{x}\right) dx,$$

con $\varepsilon = 0{,}0000001$, utilizando para ello el algoritmo de Simpson compuesto. Para obtener el valor de n se debe realizar un análisis de error de este método, esto es, se debe encontrar un número n tal que se cumpla la siguiente desigualdad:

$$\left|\int_a^b f(x)dx - S_n[a, b]\right| = \left|-\frac{h^4(b-a)}{180} f^{(4)}(\xi)\right| \leq \max_{\xi\in[a,b]} h^4(b-a)|f^{(4)}|(\xi)| < \varepsilon$$

lo cual no es una tarea sencilla. Utilizando el algoritmo compuesto se obtiene

n	**Valor Aproximado**	**Error**
400	$-1{,}426024347713767$	$-0{,}000000408630$
1000	$-1{,}426024745884060$	$-0{,}000000010465$

2. Fórmula de Cuadratura de Gauss

Las fórmulas de cuadratura de Gauss aproximan integrales de la forma

$$I(f) = \int_a^b f(x)w(x)dx$$

donde $w : \langle a, b\rangle \to \mathbb{R}$ es una función no negativa, integrable y con un número finito de ceros en $\langle a, b\rangle$. La función w es denominada *función de peso* .

Notación. De ahora en adelante denotaremos con π_n al espacio de los polinomios con coeficientes reales de grado menor o igual a n y con π al espacio de todos los polinomios.

DEFINICIÓN. *Una fórmula de cuadratura* $G_n(f) := \sum_{j=0}^{n} A_j f(x_j)$ *con* $(n+1)$ *puntos de partición distintos para el cálculo de la integral* $I(f) = \int_a^b f(x)w(x)dx$ *es denominada del tipo Gauss, si*

$$G_n(p) = I(p), \quad \forall p \in \pi_{2n+1}.$$

TEOREMA 7.6. *La fórmula de cuadratura de Gauss*

$$G_n(f) := \sum_{j=0}^{n} A_j f(x_j)$$

con $(n+1)$ *puntos de partición distintos no es exacta para polinomios de grado mayor a* $(2n+1)$.

Demostración. Sea $q(x) = \prod_{k=0}^{n} (x - x_k)^2$, entonces

$$I(q) = \int_a^b w(x)q(x)dx > 0,$$

pues $q(x) > 0, \quad \forall x \in [a,b] \setminus \{x_k\}_{k=0}^n$. Pero $q(x_j) = 0,\ j = 0, \cdots, n$ implica que

$$G_n(q) = \sum_{j=0}^{n} \alpha_j q(x_j) = 0,$$

de donde

$$R_n(q) = I(q) - G_n(q) \neq 0$$

2.1. Construcción de la fórmula de cuadratura de Gauss. En $C[a,b]$ se define un producto escalar

$$\langle f, g\rangle = \int_a^b w(x)f(x)g(x)dx, \quad f, g \in C[a,b].$$

Se inicia con un proceso de ortonormalización de $\{1, x, x^2, \cdots, x^{n+1}\}$, obteniendo $\{P_i\}_{i=0}^{n+1}$ tales que

$$\langle P_i, P_i\rangle = 1; \qquad \langle P_i, P_j\rangle = 0,\ i \neq j$$

y donde $\{P_0, \cdots, P_k\}$ es una base de π_k.
Se cumple que los $(n+1)$ ceros de P_{n+1} son reales y distintos y están en $\langle a, b\rangle$.
Si $x_j,\ j = 0, \cdots, n$ $(x_0 < x_1 < \cdots < x_n)$ son los ceros de P_{n+1} se define G_n como fórmula de cuadratura con dichos puntos de partición:

$$G_n(f) = \sum_{j=0}^{n} \alpha_j f(x_j).$$

Se cumple entonces que $G_n(p) = I(p)$, $\forall p \in \pi_{2n+1}$.

TEOREMA 7.7. *Sea* $n \in \mathbb{N}$, $w \in C[a,b]$ *una función de peso y* $P_i \in \pi_i$, $i = 0, \cdots, n+1$ *dados por el proceso de ortonormalización de* $\{1, \cdots, x^{n+1}\}$ *con el producto escalar*

$$\langle f, g\rangle = \int_a^b w(x)f(x)g(x)dx, \quad f, g \in C[a,b].$$

Entonces se cumplen:

(a) *Los* $(n+1)$ *ceros de* P_{n+1} *son reales y distintos y se encuentran en* $\langle a, b\rangle$.

(b) *Sean* $x_0 < x_1 < \cdots < x_n$ *los ceros de* P_{n+1}. *Definiendo*

$$L_j(x) = \prod_{\substack{k=0 \\ k\neq j}}^{n} \frac{x - x_k}{x_j - x_k} \qquad y \qquad \alpha_j = \int_a^b w(x) L_j(x) dx, \quad j = 0, \cdots, n$$

Se obtiene la fórmula de cuadratura de Gauss

$$G_n(f) = \sum_{j=0}^{n} \alpha_j f(x_j).$$

Entonces G_n *es la fórmula de cuadratura de Gauss para el cálculo aproximado de*

$$I(f) = \int_a^b w(x) f(x) dx$$

Demostración.

(a) Sean $\xi_1, \xi_2, \cdots, \xi_m$ $(m \leq n+1)$ los ceros de P_{n+1} en $\langle a, b\rangle$ con multiplicidad impar. Como $\langle 1, P_{n+1}\rangle = 0$, se cumple que $m \geq 1$ y P_{n+1} cambia de signo. Sea $q_m(x) := \prod_{i=1}^{m}(x - \xi_i)$. Entonces $P_{n+1} q_m$ no cambia de signo en $\langle a, b\rangle$, lo que implica que $\langle P_{n+1}, q_m\rangle \neq 0$. Vamos a probar que $m = n + 1$: Supongamos que $m < n + 1$, entonces

$$q_m \in \pi_m \subset \pi_n = span\{P_0, \cdots, P_n\}$$

y como $\langle P_{n+1}, P_j\rangle = 0$, $j = 0, 1, \cdots, n$, se obtiene

$$\begin{aligned} \langle P_{m+1}, q_m\rangle &= \langle P_{m+1}, \sum_{l=0}^{n} \beta_l P_l\rangle \\ &= \sum_{l=0}^{n} \beta_l \langle P_{m+1}, P_l\rangle = 0 \end{aligned}$$

lo cual constituye una contradicción. Por lo tanto $m = n + 1$.

(b) Sea $p \in \pi_{2n+1}$. Dividiendo p por P_{n+1}, por el algoritmo de la división, existen $q, r \in \pi_n$ tales que

$$p = q P_{n+1} + r.$$

Como $P_{n+1}(x_j) = 0,\ j = 0, \cdots, n$, entonces

$$p(x_j) = q(x_j) P_{n+1}(x_j) + r(x_j) = r(x_j), \quad j = 0, \cdots, n$$

de donde

$$\begin{aligned} G_n(p) &= \sum_{j=0}^{n} \alpha_j p(x_j) = \sum_{j=0}^{n} \alpha_j r(x_j) \\ &= \sum_{j=0}^{n} \left(\int_a^b w(x) L_j(x) dx \right) r(x_j) \\ &= \int_a^b w(x) \sum_{j=0}^{n} L_j(x) r(x_j) dx = \int_a^b w(x) r(x) dx \\ &= \int_a^b w(x)(p(x) - q(x) P_{n+1}(x)) dx \\ &= \int_a^b w(x) p(x) - \langle q, P_{n+1}\rangle = \int_a^b w(x) p(x) \end{aligned}$$

esto es,

$$G_n(p) = I(p), \quad \forall p \in \pi_{2n+1}. \qquad \square$$

Capítulo 8

Ecuaciones Diferenciales Ordinarias

1. Problemas de valor inicial

1.0.1. El problema de Cauchy. Consideramos el problema

$$\begin{cases} \overline{y}'(t) = \overline{f}(t, \overline{y}(t)) \\ \overline{y}(t_0) = \overline{y}_0 \end{cases} \tag{22}$$

donde $\overline{f} : \Omega \to \mathbb{R}^d$ es continua, $\Omega \subset \mathbb{R} \times \mathbb{R}^d$ es abierto y convexo y $(t_0, \overline{y}_0) \in \Omega$. La dimensión del estado es d; reservaremos n para el número de pasos de la malla. La continuidad de $\overline{f}$ y la condición de Lipschitz local respecto de $\overline{y}$ aseguran existencia y unicidad local. En lo que sigue suponemos que la solución existe en todo el intervalo de integración considerado.

LEMA 8.1. *Sea $\overline{y}$ una función continua en un intervalo que contiene a t_0, con $(t, \overline{y}(t)) \in \Omega$. La función $\overline{y}$ es solución del problema de Cauchy* (22) *si y sólo si satisface*

$$\overline{y}(t) = \overline{y}_0 + \int_{t_0}^{t} \overline{f}(s, \overline{y}(s))\, ds.$$

DEMOSTRACIÓN. Si $\overline{y}$ resuelve el problema de Cauchy, basta integrar la ecuación y utilizar la condición inicial. Recíprocamente, el integrando es continuo; por el teorema fundamental del cálculo, la identidad integral implica $\overline{y}'(t) = \overline{f}(t, \overline{y}(t))$. Al evaluar en $t = t_0$ se recupera $\overline{y}(t_0) = \overline{y}_0$. □

Gracias a éste lema, podemos utilizar los resultados del capítulo anterior para resolver numéricamente ecuaciones diferenciales ordinarias.

1.1. Métodos de un paso. Consideremos el siguiente P.V.I. (Problema de Valor Inicial):

$$\begin{cases} \overline{y}'(t) = \overline{f}(t, \overline{y}(t)) \\ \overline{y}(a) = \overline{y}_0 \end{cases}, \quad a \le t \le b.$$

Aproximamos la solución en un número finito de nodos. Elegimos $n \in \mathbb{N}$, $n \ge 1$, y una partición regular de $[a, b]$, con $a < b$:

$$h = \frac{b-a}{n}, \qquad t_k = a + kh, \quad k = 0, \ldots, n.$$

Así, $t_0 = a$, $t_n = b$ y $t_{k+1} - t_k = h$.

Los métodos de un paso tienen la forma

$$\overline{y}_{k+1} := \overline{y}_k + h\overline{\phi}(t_k, \overline{y}_k; h),$$

en donde $\overline{y}_k$ es la aproximación a $\overline{y}(t_k)$ y $\overline{\phi}$ es la pendiente efectiva del paso. Se toma como valor inicial el dato $\overline{y}_0 = \overline{y}(a)$.

1.1.1. Método de Euler. Estudiamos el P.V.I.

$$\begin{cases} y'(t) = f(t, y(t)) \\ y(a) = y_0 \end{cases}, \quad a \le t \le b. \tag{23}$$

Consideramos una partición regular de $[a, b]$, de modo que

$$t_{k+1} = t_k + h, \quad k = 0, 1, \ldots, n-1$$

con $h > 0$ fijo.

Consideremos la aproximación de la integral

$$\int_{t_0}^{t_1} \varphi(s)ds \approx (t_1 - t_0)\varphi(t_0)$$

obtenida cuando aproximamos $\varphi(s)$ por la función constante $\varphi(t_0)$. De esta manera, obtenemos la aproximación

$$y_1 := y_0 + hf(t_0, y_0)$$

y, en general

$$y_{k+1} := y_k + hf(t_k, y_k); \qquad k = 0, 1, \ldots, n-1$$

el método de Euler.

El método también puede obtenerse como aproximación de la serie de Taylor, teniendo en cuenta que

$$y(t_0 + h) = y(t_0) + hy'(t_0) + \frac{h^2}{2}y''(\theta), \qquad \text{para algún } t_0 < \theta < t_1 = t_0 + h.$$

El método se presenta de forma operativa en el algoritmo 13.

Algoritmo 13 Método de Euler explícito

Entrada: Extremos $a < b$, valor inicial y_0, función f y entero $n \ge 1$
Salida: Vectores de nodos t y aproximaciones y

1: $h \leftarrow (b-a)/n$
2: $t_0 \leftarrow a$
3: **Para** $k = 0, \ldots, n-1$ **hacer**
4: $\quad y_{k+1} \leftarrow y_k + hf(t_k, y_k)$
5: $\quad t_{k+1} \leftarrow a + (k+1)h$
6: **Fin Para**
7: **Devolver** $(t_0, \ldots, t_n)$, $(y_0, \ldots, y_n)$

Consistencia y defecto local. Para estudiar si un método reproduce la ecuación diferencial al reducir el paso, se sustituye en su fórmula la solución exacta, no la trayectoria numérica. En el caso escalar, para $y_{k+1} = y_k + h\phi(t_k, y_k; h)$, definimos el *defecto local* y el *residuo local normalizado* por

$$d_{k+1}(h) = y(t_{k+1}) - y(t_k) - h\phi(t_k, y(t_k); h),$$
$$\tau_{k+1}(h) = \frac{d_{k+1}(h)}{h} = \frac{y(t_{k+1}) - y(t_k)}{h} - \phi(t_k, y(t_k); h).$$

Definición (Consistencia de un método de un paso). *El método es consistente en $[a, b]$ si, para cada solución exacta suficientemente regular en ese intervalo,*

$$\max_{0 \le k < n} |\tau_{k+1}(h)| \longrightarrow 0, \qquad h = \frac{b-a}{n}, \quad n \longrightarrow \infty.$$

Tiene orden de consistencia p si este máximo es $O(h^p)$, o, equivalentemente, $\max_k |d_{k+1}(h)| = O(h^{p+1})$.

PROPOSICIÓN 8.2 (Consistencia del método de Euler). *Si la solución exacta y pertenece a* $C^2[a,b]$ *y* $M = \max_{t\in[a,b]} |y''(t)|$*, Euler satisface*

$$\max_{0\le k<n} |\tau_{k+1}(h)| \le \frac{M}{2}h.$$

En consecuencia, es consistente de primer orden.

DEMOSTRACIÓN. Por Taylor, para algún $\xi_k \in (t_k, t_{k+1})$,

$$y(t_{k+1}) = y(t_k) + hy'(t_k) + \frac{h^2}{2}y''(\xi_k).$$

Como $y'(t_k) = f(t_k, y(t_k))$ y Euler usa $\phi(t, y; h) = f(t, y)$, al sustituir en el residuo se obtiene

$$\tau_{k+1}(h) = \frac{h}{2}y''(\xi_k), \qquad |\tau_{k+1}(h)| \le \frac{M}{2}h \longrightarrow 0.$$

La cota no depende de k, por lo que la convergencia es uniforme sobre la malla. □

Así, en Euler el residuo normalizado es $O(h)$ y el defecto sin normalizar es $O(h^2)$. La consistencia describe el error de un paso con inicio exacto; el error global $e_k = y(t_k) - y_k$ también depende de la propagación de los errores anteriores. Bajo una hipótesis de Lipschitz en y y suficiente regularidad, esa propagación permite obtener el error global $O(h)$.

1.1.2. Regla del trapecio y método de Heun. La identidad integral exacta de un paso es

$$y(t_{k+1}) = y(t_k) + \int_{t_k}^{t_{k+1}} f(s, y(s))\, ds.$$

La regla trapezoidal aproxima la integral mediante

$$\int_{t_k}^{t_{k+1}} \varphi(s)\, ds \approx \frac{h}{2}[\varphi(t_k) + \varphi(t_{k+1})].$$

Al sustituir los valores exactos por aproximaciones obtenemos el *trapecio implícito*:

$$y_{k+1} = y_k + \frac{h}{2}[f(t_k, y_k) + f(t_{k+1}, y_{k+1})]. \tag{24}$$

El valor y_{k+1} aparece en ambos lados. En general se debe resolver una ecuación en cada paso; si f es afín en y, basta despejar el valor nuevo.

Para obtener una fórmula explícita, primero calculamos un predictor de Euler y después lo sustituimos una sola vez en la pendiente del extremo derecho:

$$\begin{aligned} y_{k+1}^{\text{pred}} &= y_k + hf(t_k, y_k), \\ y_{k+1} &= y_k + \frac{h}{2}[f(t_k, y_k) + f(t_{k+1}, y_{k+1}^{\text{pred}})]. \end{aligned}$$

Es decir,

$$y_{k+1} = y_k + \frac{h}{2}[f(t_k, y_k) + f(t_k + h, y_k + hf(t_k, y_k))]. \tag{25}$$

Esta fórmula es el *método de Heun*, también llamado *trapecio explícito*. Una única corrección no equivale a resolver la ecuación (24). Bajo suficiente regularidad y Lipschitz, ambos métodos tienen orden global dos, aunque pueden producir valores distintos.

1.1.3. Métodos (Explícitos) de Runge-Kutta. Tienen la forma

$$\phi(t_k, y_k; h) = \sum_{i=1}^{m} c_i k_i(t_k, y_k; h)$$

con

$$k_1(t, y; h) = f(t, y)$$

y

$$k_i(t, y; h) = f\left(t + a_i h,\, y + h \sum_{\ell=1}^{i-1} b_{i\ell} k_\ell(t, y; h)\right), \quad i = 2, \ldots, m.$$

Los k_i representan pendientes; el factor h convierte cada combinación de pendientes en un incremento del estado.

En detalle:

$$\begin{aligned}
k_1 &:= f(t_k, y_k) \\
k_2 &:= f(t_k + a_2 h, y_k + h b_{2,1} k_1) \\
k_3 &:= f(t_k + a_3 h, y_k + h(b_{3,1} k_1 + b_{3,2} k_2)) \\
&\vdots \\
k_m &:= f(t_k + a_m h, y_k + h(b_{m,1} k_1 + b_{m,2} k_2 + \cdots + b_{m,m-1} k_{m-1})) \\
y_{k+1} &:= y_k + h(c_1 k_1 + c_2 k_2 + \cdots + c_m k_m).
\end{aligned}$$

Por lo general se exige $a_1 = 0$ y

$$a_i = \sum_{\ell=1}^{i-1} b_{i\ell}, \qquad i = 2, \ldots, m,$$

de modo que los desplazamientos temporales y de estado de las etapas sean compatibles. La exactitud para $y'(t) = 1$ requiere, además,

$$\sum_{i=1}^{m} c_i = 1,$$

pues en ese caso $k_i = 1$ y el incremento debe ser exactamente h. Con las condiciones anteriores, para orden dos se exige también $\sum_{i=1}^{m} c_i a_i = 1/2$. El número de etapas no determina por sí solo el orden del método.

m	i	c_i	a_i	b_{i1}	b_{i2}	b_{i3}	Método
1	1	1	0	0	0	0	Euler
2	1	0	0	0	0	0	Euler mejorado
	2	1	1/2	1/2	0	0	(punto medio explícito)
2	1	1/2	0	0	0	0	Heun
	2	1/2	1	1	0	0	(trapecio explícito)
4	1	1/6	0	0	0	0	Runge–Kutta
	2	1/3	1/2	1/2	0	0	clásico
	3	1/3	1/2	0	1/2	0	
	4	1/6	1	0	0	1	

De la tabla:

a) Método de Euler:

$$y_{k+1} := y_k + h f(t_k, y_k).$$

b) Método de Euler mejorado (punto medio explícito):

$$y_{k+1} := y_k + h f(t_k + \frac{1}{2}h, y_k + \frac{1}{2} h f(t_k, y_k)).$$

c) Método de Heun (trapecio explícito, (25)):

$$y_{k+1} := y_k + \frac{h}{2}[f(t_k, y_k) + f(t_k + h, y_k + hf(t_k, y_k))].$$

d) Método de Runge-Kutta clásico:

$$\begin{array}{rcl} k_1 & := & f(t_k, y_k) \\ k_2 & := & f(t_k + \frac{1}{2}h, y_k + \frac{1}{2}hk_1) \\ k_3 & := & f(t_k + \frac{1}{2}h, y_k + \frac{1}{2}hk_2) \\ k_4 & := & f(t_k + h, y_k + hk_3) \\ y_{k+1} & := & y_k + \frac{h}{6}(k_1 + 2k_2 + 2k_3 + k_4). \end{array}$$

Capítulo 9

Optimización numérica

1. Mínimo local. Dirección de descenso

Consideremos el problema

$$\text{(P)} \qquad \text{Minimizar } f(x), x \in \mathbb{R}^n, \text{ donde } f : \mathbb{R}^n \to \mathbb{R}$$

Distinguimos entre

- Solución global de (P), el elemento $x^* \in \mathbb{R}^n$ tal que

$$\forall x \in \mathbb{R}^n, f(x^*) \leq f(x).$$

- Solución local de (P), el elemento $x^* \in \mathbb{R}^n$ tal que

$$\forall x \in U^*, f(x^*) \leq f(x),$$

donde U^* es un entorno de x^*.

Búsqueda de una dirección factible:
Dado $x \in \mathbb{R}^n$ que no sea solución de (P). Existe una direción $p \in \mathbb{R}^n$ y $t_0 > 0$ con

$$f(x + tp) < f(x) \text{ para } t \in [0, t_0].$$

Para esto, calculamos la derivada direccional

$$f'(x; p) = \lim_{t \to 0^+} \frac{f(x + tp) - f(x)}{t}$$

en cada dirección p. Buscamos $p \in \mathbb{R}^n$ con $f'(x; p) < 0$ (dirección factible descendente).

Optimización suave para problemas sin restricciones. En lo que sigue, consideramos el problema general de optimización

$$\text{(26)} \qquad \min_{x \in \mathbb{R}^n} f(x), \quad f : \mathbb{R}^n \to \mathbb{R} \text{ suave}$$

donde "suave"significa que $f \in C^1$ o incluso C^2.

1.1. 6.1 Métodos de búsqueda en línea (descenso).

Definición (Dirección de descenso). *Sea f como en 6.1, x, $d \in \mathbb{R}^n$. d es una dirección de descenso de f en x si y solo si*

$$\exists \alpha_0 : f(x + \alpha d) < f(x), \quad \forall \alpha \in (0, \alpha_0).$$

Lema 9.1 (Descenso de gradiente). *Sea f como en 6.1, x, $d \in \mathbb{R}^n$. Si $\nabla f(x) \cdot d < 0$ (producto escalar), entonces d es una dirección de descenso de f en x. Esta condición no es necesaria.*

Demostración. Sea

$$g(t) := g(x + td), \quad g : \mathbb{R} \to \mathbb{R} \Rightarrow g'(t) = \nabla g(x + td) \cdot d.$$

Dado que ∇f es continua,

$$\nabla f(x) \cdot d < 0 \Rightarrow \exists \alpha_0 : \nabla f(x + td) \cdot d < 0 \quad \forall 0 < t < \alpha_0.$$

Entonces, para $0 < \alpha < \alpha_0$,

$$f(x + \alpha d) - f(x) = g(\alpha) - g(0) = \int_0^\alpha g'(t)\, dt = \int_0^\alpha \nabla f(t) \cdot d\, dt < 0.$$

Para la observación, sea $f(x) = -x^2$ y $x = 0$. □

Definición (Algoritmo de búsqueda en línea). *La estructura general de un algoritmo de búsqueda en línea es:*

- *Elegir un punto inicial $x^{(0)}$ y establecer $k = 0$.*
- *Elegir una dirección de descenso $d^{(k)}$ de f en $x^{(k)}$.*
- *Elegir una longitud de paso $\alpha^{(k)} > 0$ tal que $f(x^{(k)} + \alpha^{(k)} d^{(k)}) < f(x^{(k)})$.*
- *Establecer $x^{(k+1)} := x^{(k)} + \alpha^{(k)} d^{(k)}$.*
- *Incrementar $k := k + 1$ y repetir hasta que se satisfaga algún criterio de convergencia.*

Ejemplo 9.1 (Descenso de gradiente para ecuaciones lineales). Sea $A \in \mathbb{R}^{n \times n}$ definida positiva, $b \in \mathbb{R}^n$. Entonces la solución $\bar{x}$ de $Ax = b$ es la solución del problema sin restricciones

$$\min_{x \in \mathbb{R}^n} f(x), \quad f : \mathbb{R}^n \to \mathbb{R}, \quad f(x) := \frac{1}{2}(x, Ax) - (b, x).$$

Demostración: Tenemos que

$$\nabla f(x) = Ax - b, \quad \nabla^2 f(x) = A$$

lo que implica que $\bar{x}$ es el mínimo único de f usando 2.4 y 2.3.

Definimos el algoritmo de descenso de gradiente para ecuaciones lineales estableciendo

$$x^{(0)} := 0, \quad d^{(k)} := r^{(k)} := b - Ax^{(k)}$$

lo que implica que

$$d^{(k)} \nabla f(x^{(k)}) = -\|r^{(k)}\|_2^2 < 0$$

a menos que $x^{(k)}$ ya sea una solución.

Seleccionamos $\alpha^{(k)}$ tal que $x^{(k+1)}$ minimice

$$g : \mathbb{R} \to \mathbb{R}, \quad g(\alpha) := f(x^{(k)} + \alpha d^{(k)}) = \frac{1}{2}\left(A(x^{(k)} + \alpha d^{(k)}), x^{(k)} + \alpha d^{(k)}\right) - (b, x^{(k)} + \alpha d^{(k)}).$$

Entonces tenemos

$$0 = g'(\alpha^{(k)}) = (Ax^{(k)}, d^{(k)}) + \alpha^{(k)}(Ad^{(k)}, d^{(k)}) - (b, d^{(k)}).$$

o

$$\alpha^{(k)} = \frac{\langle r^{(k)}, d^{(k)} \rangle}{\langle d^{(k)}, Ad^{(k)} \rangle}.$$

Por supuesto, no todo método de descenso converge a una solución de la ecuación **??**. Simplemente toma

$$f(x) := x^2, \quad x^{(0)} = 3, \quad d^{(k)} = -1, \quad \alpha^{(k)} = \frac{1}{2^k}$$

que satisface todas las condiciones, pero $x^{(k)}$ converge a 1.

Deducimos teoremas generales de convergencia para métodos de descenso y comenzamos con algunas definiciones.

DEFINICIÓN (Punto estacionario, conjunto de subnivel). *Sea f como en la ecuación* **??**.

1. *$x \in \mathbb{R}^n$ es un punto estacionario de f si y solo si $\nabla f(x) = 0$.*
2. *Sea*
$$N(f, y) = \{x : f(x) \leq y\}.$$
N es llamado conjunto de (sub)nivel de f en el nivel y.

NOTA. Observa que para el algoritmo de la ecuación 28, $f^{(k)} \in N(f, f(x^{(0)}))$, por lo que siempre podemos restringir nuestras consideraciones a este subconjunto de $\mathbb{R}^n$.

COROLARIO 9.2 (Existencia de soluciones mínimas). *Sea f como en la ecuación* **??** *y $N(f, y)$ compacto para $y = x^{(0)} \in \mathbb{R}^n$. Entonces la ecuación* **??** *tiene una solución. Toda solución es un punto estacionario de f.*

Demostración: Como f es continua, f alcanza su mínimo en $N(f, y)$.
En lo que sigue, asumiremos siempre que este corolario se cumple, es decir, que existe una solución para la ecuación **??**.

LEMA 9.3 (Convergencia de los valores de los métodos de búsqueda en línea). *Sea f como en el corolario* **??** *y $x^{(k)}$ definido por el algoritmo 28. Entonces $f(x^{(k)})$ converge hacia su ínfimo. En particular, $f(x^{(k+1)}) - f(x^{(k)}) \to 0$.*

Demostración: $f(x^{(k)})$ es monótono y acotado.
Queremos derivar condiciones tales que $\nabla f(x^{(k)}) \to 0$.
Primero, observa que nuestra derivación del algoritmo de descenso se basó en
$$f(x^{(k)} + \alpha^{(k)} d^{(k)}) - f(x^{(k)}) \sim \alpha^{(k)} \langle \nabla f(x^{(k)}), d^{(k)} \rangle.$$
Queremos que esto se mantenga hasta una constante $c_1 > 0$, lo que significa
$$f(x^{(k)} + \alpha^{(k)} d^{(k)}) - f(x^{(k)}) \leq c_1 \alpha^{(k)} \langle \nabla f(x^{(k)}), d^{(k)} \rangle < 0. \tag{27}$$
Dado que el lado izquierdo converge a cero, tenemos
$$\alpha^{(k)} \langle \nabla f(x^{(k)}), d^{(k)} \rangle \to 0.$$
Si $\nabla f(x^{(k)}) \to 0$, entonces
$$\frac{(\langle \nabla f(x^{(k)}), d^{(k)} \rangle)^2}{\|d^{(k)}\|^2} \to 0. \tag{28}$$
Por lo tanto, requerimos que exista una constante $c_2 > 0$ tal que
$$\alpha^{(k)} \geq -c_2 \frac{\langle \nabla f(x^{(k)}), d^{(k)} \rangle}{\|d^{(k)}\|^2}. \tag{29}$$
En conjunto, con $c = c_1 c_2$ tenemos
$$f(x^{(k+1)}) \leq f(x^{(k)}) - c \frac{(\langle \nabla f(x^{(k)}), d^{(k)} \rangle)^2}{\|d^{(k)}\|^2}. \tag{30}$$
Si f satisface esta condición, la elección de la longitud de paso se denomina eficiente.

TEOREMA 9.4 (Existencia de longitudes de paso eficientes). *Sea f' Lipschitz–continua en $N(f, x^{(0)})$ (o dos veces diferenciable), $N(f, x^{(0)})$ compacto. Entonces existe una elección eficiente de la longitud de paso en el algoritmo 28.*

DEMOSTRACIÓN. Ejercicio. □

Ahora, para la selección de $d^{(k)}$. Para derivar la convergencia de 28, el gradiente y la dirección de descenso no deben volverse ortogonales, así que para alguna constante $c_3 > 0$

$$-\langle \nabla f(x^{(k)}), d^{(k)} \rangle \geq c_3 \|\nabla f(x^{(k)})\| \|d^{(k)}\|.$$

Esta elección se denomina basada en el gradiente.

TEOREMA 9.5 (Convergencia de algoritmos de búsqueda en línea eficientes basados en gradientes). *Sea f como en el corolario* **??** *y $x^{(k)}$ de un algoritmo de búsqueda en línea eficiente basado en gradientes. Entonces todo punto de acumulación de $x^{(k)}$ es un punto estacionario de f. Si $N(f, f(x^{(0)}))$ es compacto, la sucesión tiene al menos un punto de acumulación.*

DEMOSTRACIÓN. Sea $\bar{x}$ un punto de acumulación de $x^{(k)}$. Sin pérdida de generalidad, asumimos que $x^{(k)} \to \bar{x}$. De las preliminares, tenemos que

$$0 \geq -c_3 c \|\nabla f(x^{(k)})\|^2 \geq -c \frac{(\langle \nabla f(x^{(k)}), d^{(k)} \rangle)^2}{\|d^{(k)}\|^2} \geq f(x^{(k+1)}) - f(x^{(k)}) \to 0.$$

□

1.2. 6.2 Control de Tamaño de Paso para la Búsqueda en Línea. En el ejemplo 29, podríamos elegir $\alpha^{(k)}$ de tal manera que minimice el valor de la función en la dirección de descenso. Sin embargo, este es más o menos el único caso en el que esta elección explícita es posible. Para la mayoría de los casos, recurrimos a la idea en 27.

DEFINICIÓN (Regla de Armijo). *Sea $0 < c_1 \leq 1$ fijo. Una elección de parámetro $\alpha^{(k)}$ para 28 satisface la regla de Armijo si y solo si*

$$f(x^{(k+1)}) \leq f(x^{(k)}) + c_1 \alpha^{(k)} \langle \nabla f(x^{(k)}), d^{(k)} \rangle.$$

En vista del ejemplo 29, se desearía elegir $\alpha^{(k)}$ lo más grande posible. Una estrategia posible es intentar β^k para $k = 0, \ldots$ y elegir el primer valor que satisfaga la condición.

En general, se usa el siguiente procedimiento de actualización.

DEFINICIÓN (Algoritmo de Armijo-Goldstein). *Sean $0 < c_1 < 1$, $\gamma > 0$, $0 < \beta_1 \leq \beta_2 < 1$. Entonces elige $\alpha_0 = 1$ y establece $j = 0$.*

1. *Si*
$$f(x^{(k)} + \alpha_j d^{(k)}) \leq f(x^{(k)}) + c_1 \alpha_j \langle \nabla f(x^{(k)}), d^{(k)} \rangle,$$
entonces asigna $\alpha^{(k)} = \alpha_j$ y detente.
2. *Elige $\alpha_{j+1} \in [\beta_1 \alpha_j, \beta_2 \alpha_j]$.*
3. *Incrementa $j := j + 1$ y repite.*

Ahora examinamos el caso en el que la dirección de descenso está dada por una transformación lineal del gradiente.

LEMA 9.6 (Transformaciones lineales para Armijo). *Sea f como en el corolario* **??** *y ∇f Lipschitz–continua (o en C^2) con constante de Lipschitz L. En 28, sea $x = x^{(k)}$ y $d = d^{(k)} = -M \nabla f(x)$ para $M \in \mathbb{R}^{n \times n}$ simétrica definida positiva. Además, asumimos $\nabla f(x) \neq 0$.*

Sea $\lambda_{\text{máx}} = \|M\|_2$ el mayor autovalor de M y $\lambda_{\text{mín}} = \|M^{-1}\|_2$ el menor autovalor. Entonces, para el número de condición κ_2 tenemos

$$\kappa_2(M) = \kappa_2(M^{-1}) = \frac{\lambda_{\text{máx}}}{\lambda_{\text{mín}}}.$$

La condición de Armijo se satisface para $\alpha^{(k)} = \alpha$ si

$$0 < \alpha \leq \frac{2(1 - c_1)}{L \lambda_{\text{máx}} \kappa_2(M)}.$$

DEMOSTRACIÓN. Las relaciones de los autovalores se prueban fácilmente usando una base ortonormal de autovectores de M, la cual existe ya que M es s.p.d.

Tenemos

$$f(x+\alpha d) - f(x) = \int_0^1 \nabla f(x+\tau\alpha d)\cdot(\alpha d)\, d\tau.$$

Dado que ∇f es Lipschitz continua,

$$f(x+\alpha d) = f(x) + \alpha\nabla f(x)\cdot d + \alpha\int_0^1 \frac{(\nabla f(x+\tau\alpha d) - \nabla f(x))\cdot d}{\|\| \leq \tau\alpha\|d\|}\, d\tau,$$

y así, por Cauchy–Schwarz,

$$f(x+\alpha d) \leq f(x) + \alpha\nabla f(x)\cdot d + L\alpha^2\|d\|^2\frac{1}{2}.$$

Tenemos

$$\|Mz\|^2 \leq \|M\|^2\|z\|^2 = \lambda_{\text{máx}}^2\|z\|^2$$

y

$$\|z\|^2 = \|M^{-1/2}M^{1/2}z\|^2 \leq \|M^{-1/2}\|^2 z^t Mz = \frac{1}{\lambda_{\text{mín}}} z^t Mz.$$

Sustituyendo esto en la definición de d, tenemos

$$\|d\|^2 = \|M\nabla f(x)\|^2 \leq \lambda_{\text{máx}}^2\|\nabla f(x)\|^2 \leq \frac{\lambda_{\text{máx}}^2}{\lambda_{\text{mín}}}\nabla f(x)\cdot M\nabla f(x).$$

En resumen,

$$f(x+\alpha d) \leq f(x) + \alpha\left(1 - \frac{1}{2}L\alpha\kappa_2(M)\lambda_{\text{máx}}\right)\nabla f(x)\cdot d.$$

La condición de Armijo se satisface si

$$\left(1 - \frac{1}{2}L\alpha\kappa_2(M)\lambda_{\text{máx}}\right) \leq c_1$$

o

$$\alpha \leq \frac{2(1-c_1)}{L\kappa_2(M)\lambda_{\text{máx}}}.$$

□

COROLARIO 9.7. *Sea todo como en el lema* **??**, *excepto*

$$d^{(k)} = -M^{(k)}\nabla f(x^{(k)})$$

para $M^{(k)} \in \mathbb{R}^{n\times n}$ *definida positiva, y supongamos que las cotas comunes*

$$\lambda_{\text{máx}} \geq \lambda_{\text{máx}}^{(k)} \geq \lambda_{\text{mín}}^{(k)} \geq \lambda_{\text{mín}} > 0$$

(con las denominaciones como en **??***) se cumplen. Entonces, los tamaños de paso calculados en* **??** *satisfacen*

$$\alpha^{(k)} \geq \bar{\alpha} := \beta_1\frac{2(1-c_1)}{L\kappa\lambda_{\text{máx}}}$$

donde $\kappa = \frac{\lambda_{\text{máx}}}{\lambda_{\text{mín}}}$. *El número máximo de pasos tomados en* **??** *es*

$$\log_{\beta_2}\left(\frac{2(1-c_1)}{L\kappa\lambda_{\text{máx}}}\right).$$

DEMOSTRACIÓN. Inserta todo en el lema **??** y usa que, si $\alpha^{(k)} = \alpha_j$,

$$\alpha_j \leq \beta_2^j\bar{\alpha}, \quad \alpha_j \geq \beta_1\alpha_{j-1} > \bar{\alpha}.$$

La última desigualdad se cumple ya que el algoritmo toma el primer α_j que satisface **??**. □

TEOREMA 9.8 (Convergencia de Armijo–Goldstein). *Sea todo como en el corolario* **??**, *en particular sea f acotado inferiormente. Entonces cualquier punto de acumulación de $x^{(k)}$ es un punto estacionario de f.*

DEMOSTRACIÓN. Básicamente, esto es **??**. La elección de d es basada en gradiente, ya que

$$\langle d^{(k)}, \nabla f(x^{(k)})\rangle = \langle -M\nabla f(x^{(k)}), \nabla f(x^{(k)})\rangle \leq -\lambda_{\text{mín}}\|\nabla f(x^{(k)})\|^2 \leq -\frac{\lambda_{\text{mín}}}{\lambda_{\text{máx}}}\|\nabla f(x^{(k)})\|\|d\|.$$

Explícitamente, tenemos

$$\begin{aligned} f(x^{(k+1)}) - f(x^{(k)}) &\leq -c_1\alpha^{(k)}\langle \nabla f(x^{(k)}), M^{(k)}\nabla f(x^{(k)})\rangle \\ &\leq -c_1\alpha\lambda_{\text{mín}}\|\nabla f(x^{(k)})\|^2 \\ &\leq -c_1^2\beta_1\frac{(1-c_1)}{L\kappa^2}\|\nabla f(x^{(k)})\|^2 \leq 0. \end{aligned}$$

Ahora aplica el lema **??**. □

Por supuesto, la regla de Armijo por sí sola no es suficiente, ya que no excluye la elección de pasos muy pequeños (valores de α muy pequeños). De hecho, la regla de Armijo siempre se satisface para un paso en un intervalo $(0, \bar{\alpha}]$ sin un límite inferior. La razón por la cual **??** funciona es que detenemos el proceso tan pronto como se cumple **??**, y por lo tanto obtenemos un límite inferior.

Uno podría sentirse tentado a elegir β_1 y β_2 muy pequeños para minimizar el número de iteraciones en **??**. Sin embargo, eso daría como resultado que $\alpha^{(k)}$ subestime el valor óptimo que minimizaría f a lo largo de la dirección $d^{(k)}$. La idea obvia es: tomarlos pequeños, pero luego aumentar el valor hasta que se cumpla alguna condición. Esta es la idea de los algoritmos tipo Powell–Wolfe.

Comenzamos formulando la condición de Powell–Wolfe. El valor óptimo para α satisfaría $\nabla f(x+\alpha d)\cdot d = 0$, por lo que requerimos que este producto escalar sea pequeño.

DEFINICIÓN (Condición de Powell–Wolfe). *Sea todo como en el corolario* **??**. *Sean $0 < c_1 < c_2 < 1$ y $x, d \in \mathbb{R}^n$, $\nabla f(x)\cdot d < 0$. $\alpha > 0$ satisface la condición de Powell–Wolfe si y solo si*

$$f(x+\alpha d) \leq f(x) + c_1\alpha\nabla f(x)\cdot d \quad \textit{(regla de Armijo)}$$

y

$$\nabla f(x+\alpha d)\cdot d \geq c_2\nabla f(x)\cdot d.$$

Recuerda que en la segunda desigualdad el lado derecho es negativo. También observa que definiendo

$$g(t) := f(x+td)$$

esto equivale a requerir

$$g(\alpha) \leq g(0) + c_1\alpha g'(0), \quad g'(\alpha) \geq c_2 g'(0).$$

Típicamente, la condición de Powell–Wolfe se satisfará para α en un intervalo $[\beta, \bar{\alpha}]$.

LEMA 9.9 (Existencia de longitud de paso Powell–Wolfe). *En* **??**, *sea $c_1 < 1/2$. Entonces existe $\alpha > 0$ que satisface la condición de Powell–Wolfe.*

DEMOSTRACIÓN. Definimos

$$\Psi(\alpha) := f(x+\alpha d) - f(x) - c_1\alpha\nabla f(x)\cdot d \Rightarrow \Psi'(\alpha) = (\nabla f(x+\alpha d) - c_1\nabla f(x))\cdot d$$

de modo que Armijo se satisface si $\Psi(\alpha) < 0$. Dado que

$$\Psi'(0) = (1-c_1)\nabla f(x)\cdot d < 0, \quad \Psi(0) = 0$$

□

DEMOSTRACIÓN. Powell–Wolfe es una variante de **??**. □

TEOREMA 9.10. *Sea ∇f Lipschitz–continua con constante de Lipschitz L en $N(f, f(x^{(0)}))$. Entonces existe $\theta > 0$, independiente de d y x, tal que*

$$f(x + \alpha d) \geq f(x) - \theta \left(\frac{\langle \nabla f(x), d \rangle}{\|d\|} \right)^2$$

para todo α que satisfaga **??**.

DEMOSTRACIÓN. Dado que α satisface **??**, tenemos

$$(c_2 - 1)\langle \nabla f(x), d \rangle \leq \langle \nabla f(x + \alpha d) - \nabla f(x), d \rangle \leq L\alpha \|d\|^2.$$

Insertando esto en **??**,

$$f(x+\alpha d) \leq f(x)+c_1\alpha\langle \nabla f(x), d\rangle \leq f(x)+\frac{(c_2-1)\langle \nabla f(x), d\rangle}{L\|d\|^2} c_1\langle \nabla f(x), d\rangle = f(x)-\theta \left(\frac{\langle \nabla f(x), d\rangle}{\|d\|} \right)^2.$$

□

1.3. 6.3 Métodos tipo gradiente para ecuaciones lineales. Probamos la convergencia y estimaciones de error para 29 y el método de gradiente conjugado. Nota que, para simplificar, siempre establecemos $x^{(0)} := 0$.

TEOREMA 9.11 (Convergencia de 29). *Sea todo como en 29 y asumamos que $x^{(k)}$ se elige en consecuencia. En particular,*

$$x^{(0)} := 0, \quad d^{(k)} := r^{(k)} := b - Ax^{(k)}$$

y

$$\alpha^{(k)} := \frac{\langle r^{(k)}, d^{(k)} \rangle}{\langle d^{(k)}, Ad^{(k)} \rangle}.$$

Sea

$$(x, y)_A = \langle Ax, y \rangle, \quad \|x\|_A^2 = \langle x, Ax \rangle, \quad e^{(k)} = x - x^{(k)} \Rightarrow Ae^{(k)} = r^{(k)}.$$

Entonces tenemos:

1. *$x^{(k)}$ converge a la solución de $Ax = b$.*
2. *Sea $\kappa = k(A) = \|A\|_2 \cdot \|A^{-1}\|_2$. Entonces*

$$\|e_k\|_A \leq \left(\frac{\kappa - 1}{\kappa + 1} \right)^k \|e_0\|_A \Rightarrow \|e^{(k)}\| \leq \sqrt{\kappa} \left(\frac{\kappa - 1}{\kappa + 1} \right)^k \|e_0\|.$$

DEMOSTRACIÓN. Sea

$$G(\alpha) := \|x^{(k)}+\alpha r^{(k)}-x\|_A^2 = \|-e^{(k)}+\alpha r^{(k)}\|_A^2 = \|e^{(k)}\|_A^2-2\alpha\langle Ae^{(k)}, r^{(k)}\rangle+\alpha^2\|r^{(k)}\|_A^2.$$

Claramente, $\alpha^{(k)}$ es un minimizador de G. Para todo $\alpha > 0$, tenemos

$$G(\alpha) = \| - e^{(k)} + \alpha r^{(k)}\|_A^2 = \|(I - \alpha A)e^{(k)}\|_A^2 \leq \|(I - \alpha A)\|_A^2 \|e^{(k)}\|_A^2.$$

A es definida positiva, por lo que existe una matriz unitaria $U \in \mathbb{R}^{n \times n}$ y una matriz diagonal Σ con los autovalores en la diagonal tal que $A = U^T \Sigma U$. Sustituyendo esto obtenemos

$$\begin{aligned}
\|(I - \alpha A)\|_A^2 &= \sup_{\|x\|_A = 1} \frac{\langle (I - \alpha A)x, Ax \rangle}{\langle x, Ax \rangle} \\
&= \sup \frac{\langle \Sigma Ux - \alpha \Sigma^2 Ux, \Sigma Ux \rangle}{\langle \Sigma Ux, \Sigma Ux \rangle} \\
&= \sup \frac{\langle (I - \alpha \Sigma)y, y \rangle}{\langle y, y \rangle}, \quad y = \Sigma Ux \\
&= \|I - \alpha \Sigma\|_2^2 = \max_j |1 - \alpha \lambda_j|^2, \quad \lambda_j \text{ autovalor de } A.
\end{aligned}$$

Por lo tanto, $\forall \alpha > 0$

$$\|e^{(k+1)}\|_A^2 \leq G(\alpha) = \|(I-\alpha A)e^{(k)}\|_A^2 \leq \|(I-\alpha A)\|_A^2 \|e^{(k)}\|_A^2 \leq \max_j |1-\alpha\lambda_j|^2 \cdot \|e^{(k)}\|_A^2.$$

Sea $\lambda_{\text{máx}}, \lambda_{\text{mín}}$ el mayor y menor autovalor de A, respectivamente. Entonces

$$\kappa = \|A\|_2 \cdot \|A^{-1}\|_2 = \frac{\lambda_{\text{máx}}}{\lambda_{\text{mín}}}.$$

□

Sea

$$\alpha = \frac{2}{\lambda_{\text{máx}} + \lambda_{\text{mín}}}$$

a saber

$$1 - \alpha\lambda_{\text{máx}} = \frac{\lambda_{\text{máx}} + \lambda_{\text{mín}} - 2\lambda_{\text{máx}}}{\lambda_{\text{máx}} + \lambda_{\text{mín}}} = \frac{\lambda_{\text{mín}} - \lambda_{\text{máx}}}{\lambda_{\text{máx}} + \lambda_{\text{mín}}} = -\frac{\kappa - 1}{\kappa + 1}$$

y

$$1 - \alpha\lambda_{\text{mín}} = \frac{\lambda_{\text{máx}} + \lambda_{\text{mín}} - 2\lambda_{\text{mín}}}{\lambda_{\text{máx}} + \lambda_{\text{mín}}} = \frac{\lambda_{\text{máx}} - \lambda_{\text{mín}}}{\lambda_{\text{máx}} + \lambda_{\text{mín}}} = \frac{\kappa - 1}{\kappa + 1}.$$

En general, $|1 - \alpha\lambda_j|$ está siempre en el intervalo $\left[-\frac{\kappa-1}{\kappa+1}, \frac{\kappa-1}{\kappa+1}\right]$ y tenemos

$$\|e^{(k+1)}\|_A \leq \frac{\kappa - 1}{\kappa + 1}\|e^{(k)}\|_A.$$

Nos damos cuenta de que el número de condición es crucial para la velocidad de convergencia, sobre el cual no tenemos control directo. Sin embargo, podemos reescribir nuestra ecuación original y tratar de modificarla de tal manera que la nueva matriz tenga un número de condición menor.

Específicamente: Supongamos que H^{-1} es una matriz definida positiva simétrica con la propiedad de que

$$H^{-1}A \sim I.$$

Entonces H se llama un precondicionador para A. Existen muchas técnicas para construirlo, la más simple consiste en establecer $H^{-1} := D^{-1}$ donde D es la diagonal principal de A.

Luego, al establecer $y = H^{1/2}x$, tenemos

$$Ax = b \iff H^{-1/2}AH^{-1/2}y = H^{-1/2}b. \tag{6.6}$$

Dado que $H^{-1/2}AH^{-1/2}$ es definida positiva y

$$H^{-1/2}AH^{-1/2} = H^{1/2}H^{-1}AH^{-1/2} \sim I \Rightarrow \kappa_2(H^{-1/2}AH^{-1/2}) \sim 1$$

podemos usar 29 para resolver **??** y esperar una velocidad de convergencia favorable. Para una revisión extensa sobre algoritmos de precondicionamiento, ver Saad.

Puede que no sea completamente obvio por qué uno optaría por elegir una dirección de descenso $d^{(k)}$ diferente de $-\nabla f(x^{(k)})$, ya que esta elección garantiza la máxima disminución de la función de minimización en $x^{(k)}$. Sin embargo, esta visión se basa en una sola evaluación de ∇f. Supongamos que $k \geq 1$, entonces $f(x^{(l)})$ y $\nabla f(x^{(l)})$ están disponibles para $l \leq k$. Entonces surge la pregunta: ¿Podemos usar estas evaluaciones para idear una mejor elección de la dirección de descenso?

El más popular de estos algoritmos es el algoritmo de gradiente conjugado (CG). Damos un esquema del algoritmo.

Definición (Vectores conjugados). *Sea $A \in \mathbb{R}^{n\times n}$ definida positiva. Para $x, y \in \mathbb{R}^n$, definimos*

$$(x, y)_A := \langle x, Ay\rangle.$$

x y y son A-conjugados si son ortogonales en el producto escalar A,

$$0 = (x, y)_A = \langle x, Ay\rangle.$$

TEOREMA 9.12 (Descenso de gradiente para vectores conjugados). *Supongamos que en 29 las direcciones de descenso son A-conjugadas:*

$$(d^{(k)}, d^{(l)})_A = 0 \quad \forall k \neq l, \quad d^{(k)} \neq 0.$$

Todo lo demás se elige como en 29,

$$x^{(0)} := 0, \quad r^{(k)} := b - Ax^{(k)}, \quad \alpha^{(k)} := \frac{\langle r^{(k)}, d^{(k)} \rangle}{\langle d^{(k)}, Ad^{(k)} \rangle}.$$

Definimos

$$\mathcal{K}_k := \operatorname{span}\{d^{(0)}, \dots, d^{(k-1)}\}.$$

Sea x la solución de $Ax = b$. Entonces:

1. $x^{(k)}$ *es la solución de*
$$\min_{z \in \mathcal{K}_k} \|x - z\|_A.$$
2. $x^{(n)} = x$.
3. $x^{(k)}$ *es la solución de*
$$\min_{z \in \mathcal{K}_k} f(z).$$

DEMOSTRACIÓN. Observa que $u^{(k)} = d^{(k)}/\|d^{(k)}\|$ es una base ortonormal en el producto escalar $(,)_A$, y $x^{(j)} \in \mathcal{K}_j$.

1. La solución es la proyección ortogonal de x sobre $\mathcal{K}_k$, dada por
$$\sum_{j=0}^{k-1} (x, u^{(j)})_A u^{(j)} = \sum_{j=0}^{k-1} \langle Ax - Ax^{(j)}, u^{(j)} \rangle u^{(j)} = x^{(k)},$$
donde $x^{(j)} \perp_A u^{(j)}$.
2. De 1, como $d^{(0)}, \dots, d^{(n-1)}$ es una base de $\mathbb{R}^n$.
3. Como $x^{(k)}$ es la proyección ortogonal de x sobre $\mathcal{K}_k$, tenemos
$$x = x^{(k)} + u, \quad u \perp_A \mathcal{K}_k.$$
Sea $v \in \mathcal{K}_k$. Entonces
$$\begin{aligned} f(x^{(k)} + v) &= \frac{1}{2}\langle x^{(k)} + v, A(x^{(k)} + v) \rangle - \langle b, x^{(k)} + v \rangle \\ &= f(x^{(k)}) + \frac{1}{2}\langle v, Av \rangle + \langle v, Ax^{(k)} - b \rangle \\ &= f(x^{(k)}) + \frac{1}{2}\langle v, Av \rangle \geq f(x^{(k)}). \end{aligned}$$

□

Nótese que esto implica que cualquier método de descenso de gradiente para **??** con direcciones A-conjugadas está garantizado para terminar después de n iteraciones con la solución correcta, lo que implica que no es realmente un algoritmo iterativo, sino determinístico.

Sin embargo, para un sistema típico de ecuaciones grandes, es poco realista realizar n iteraciones; el número real es mucho menor.

En el algoritmo de gradiente conjugado, los $d^{(k)}$ se eligen como $r^{(k)}$ como en 29, pero se ortogonalizan usando Gram-Schmidt.

DEFINICIÓN (Algoritmo de Gradiente Conjugado, primera forma). *Sea todo como en 29. Aplica la ortogonalización de Gram–Schmidt en el producto escalar A a*

$$\{r^{(0)}, r^{(1)}, \dots\} \to \{d^{(0)}, d^{(1)}, \dots\}$$

y realiza 29.

Este procedimiento garantiza que las direcciones de descenso son conjugadas, siempre y cuando $r^{(k)} \neq 0$, pero entonces $Ax = b$ de todos modos. También nota que

$$d^{(k)} \in \operatorname{span}\{r^{(0)}, \dots, r^{(k)}\} = \mathcal{K}_{k+1}.$$

Sin embargo, aplicar Gram–Schmidt se vuelve computacionalmente costoso cuando k es grande. Simplificamos este procedimiento. Comenzamos con

LEMA 9.13. *Sea todo como en* **??**.

1. $\mathcal{K}_k$ *es el subespacio de Krylov*
$$\mathcal{K}_k = \{p(A)r^{(0)} : p \in \mathcal{P}_{k-1}\}.$$
2. $r^{(k)} \perp \mathcal{K}_k$.
3. $r^{(k)} \perp_A \mathcal{K}_{k-1}$.

DEMOSTRACIÓN. 1. Por inducción. Tenemos

$$r^{(k+1)} = b - Ax^{(k+1)} = b - A(x^{(k)} + \alpha^{(k)} d^{(k)}) = r^{(k)} - \alpha^{(k)} A d^{(k)} = p(A)r^{(0)} - q(A)r^{(0)}$$

donde $p \in \mathcal{P}_{k-1}$ y $q \in \mathcal{P}_k$.

2. Como $x^{(k)}$ minimiza $\|x - z\|_A$ para $z \in \mathcal{K}_k$, tenemos
$$\langle r^{(k)}, z\rangle_A = \langle Ax - Ax^{(k)}, z\rangle = \langle x - x^{(k)}, z\rangle_A = 0 \quad \forall z \in \mathcal{K}_k.$$
3. Sea $y \in \mathcal{K}_{k-1}$. Entonces
$$\langle r^{(k)}, y\rangle_A = \langle r^{(k)}, Ay\rangle = 0.$$

□

Para Gram–Schmidt, dado que $d^{(i)} \in \mathcal{K}_{i+1}$, esto da

$$\begin{aligned} d^{(k+1)} &= r^{(k+1)} - \sum_{i=0}^{k} \frac{\langle d^{(i)}, r^{(k+1)}\rangle_A}{\|d^{(i)}\|_A^2} d^{(i)} \\ &= r^{(k+1)} - \frac{\langle d^{(k)}, r^{(k+1)}\rangle_A}{\langle d^{(k)}, Ad^{(k)}\rangle} d^{(k)}. \end{aligned}$$

Concluimos con la segunda forma del algoritmo de gradiente conjugado. Nota que esta es la definición completa; en el contexto de la clase establecemos $x^{(0)} = 0$ para simplificar.

DEFINICIÓN (Algoritmo de Gradiente Conjugado, segunda forma). *Sea $A \in \mathbb{R}^{n\times n}$ definida positiva, $b, x^{(0)} \in \mathbb{R}^n$. Entonces el algoritmo de gradiente conjugado está definido por*

$$\begin{gathered} r^{(0)} = b - Ax^{(0)}, \quad d^{(0)} = r^{(0)} \\ \alpha^{(k)} = \frac{\langle d^{(k)}, r^{(k)}\rangle}{\langle d^{(k)}, Ad^{(k)}\rangle} \\ x^{(k+1)} = x^{(k)} + \alpha^{(k)} d^{(k)} \\ r^{(k+1)} = b - Ax^{(k+1)} = r^{(k)} - \alpha^{(k)} A d^{(k)} \\ \beta^{(k)} = \frac{\langle d^{(k)}, r^{(k+1)}\rangle_A}{\langle d^{(k)}, d^{(k)}\rangle_A} = \frac{\langle d^{(k)}, Ar^{(k+1)}\rangle}{\langle d^{(k)}, Ad^{(k)}\rangle} \\ d^{(k+1)} = r^{(k+1)} - \beta^{(k+1)} d^{(k)}. \end{gathered}$$

El algoritmo termina cuando $r^{(k)} = d^{(k)} = 0$ con $x = x^{(k)}$, la solución de $Ax = b$.

Si bien es útil que el algoritmo termine con la solución correcta (si no ocurren errores de redondeo), esta característica nunca se usa. En cambio, la iteración se detiene con $k \ll n$. En este caso, nuevamente necesitamos una estimación del error.

LEMA 9.14. *Sea todo como en* **??**. *Sean* $\lambda_1 \geq \cdots \geq \lambda_n > 0$ *los autovalores de* A *con la correspondiente base ortonormal de autovectores* $\{v_i\}$. *Además, sea* $p \in \mathcal{P}_k$ *tal que*

$$p(0) = 1 \quad y \quad |p(\lambda_j)| \leq r \quad \forall j.$$

Entonces, las iteraciones $x^{(k)}$ *del algoritmo de gradiente conjugado satisfacen*

$$\|e^{(k)}\|_A \leq r\|e^{(0)}\|_A.$$

DEMOSTRACIÓN. Tenemos

$$p(z) - 1 = zq(z), \quad q \in \mathcal{P}_{k-1}.$$

Sea $z = q(A)r^{(0)} \in \mathcal{K}_k$. Entonces

$$x - z = A^{-1}b - q(A)AA^{-1}r^{(0)} = (I + Aq(A))e^{(0)} = p(A)e^{(0)}.$$

Entonces

$$\begin{aligned}
\|x - x^{(k)}\|_A^2 \leq \|x - z\|_A^2 &= \|p(A)e^{(0)}\|_A^2 \\
&= \left\|\sum_{i=1}^n \alpha_i p(\lambda_i) v_i\right\|_A^2 \\
&= \left(\sum_{i=1}^n \alpha_i p(\lambda_i) v_i, \sum_{i=1}^n \alpha_i p(\lambda_i)\lambda_i v_i\right) \\
&= \sum_{i=1}^n \lambda_i (p(\lambda_i)\alpha_i)^2 \\
&\leq \sum_{i=1}^n \lambda_i r^2 \alpha_i^2 \\
= r^2 \left(\sum_{i=1}^n \alpha_i v_i, A\sum_{i=1}^n \alpha_i v_i\right) &= r^2\|x - x_0\|_A^2 = r^2\|e_0\|_A^2.
\end{aligned}$$

□

Este lema implica que las cotas para el error de aproximación de $x^{(k)}$ en $\mathcal{P}_{k-1}$ proporcionan límites de error para el algoritmo de gradiente conjugado.

TEOREMA 9.15 (Estimación de error para el algoritmo de gradiente conjugado). *Para el algoritmo de gradiente conjugado* **??** *tenemos*

$$\|e^{(k)}\|_A \leq 2\left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}\right)^k \|e^{(0)}\|_A, \quad \|e^{(k)}\|_2 \leq 2\sqrt{\kappa}\left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1}\right)^k \|e^{(0)}\|_2.$$

DEMOSTRACIÓN. En **??**, usa los polinomios de Chebyshev $T_k(x) = \cos(k \arc\cos x)$ (ejercicio). □

1.4. 6.4 Método de Newton. En este capítulo, utilizaremos el método de Newton, un algoritmo bien conocido para la solución de ecuaciones no lineales, para minimización. Comenzamos recordando la definición de velocidad de convergencia (orden de convergencia).

DEFINICIÓN (Orden de convergencia). *Sea* $x^{(k)}$ *una sucesión en* $\mathbb{R}^n$, $x^{(k)} \to \bar{x}$, *y sea la convergencia monótona en el sentido de que*

$$\|x^{(k+1)} - \bar{x}\| \leq \|x^{(k)} - \bar{x}\|, \quad x^{(k)} \neq \bar{x}.$$

1. *La velocidad de convergencia es lineal si existe* $\gamma \in (0, 1)$, $K > 0$ *tal que:*

$$\|x^{(k+1)} - \bar{x}\| \leq \gamma\|x^{(k)} - \bar{x}\| \quad \forall k > K.$$

2. *La velocidad de convergencia es superlineal si y solo si*
$$\frac{\|x^{(k+1)} - \bar{x}\|}{\|x^{(k)} - \bar{x}\|} \to 0.$$
3. *La velocidad de convergencia es de orden q (cuadrática para $q = 2$) si existe $C > 0$ tal que:*
$$\|x^{(k+1)} - \bar{x}\| \leq C\|x^{(k)} - \bar{x}\|^q.$$
4. *Sea $y^{(k)}$ una sucesión que también converge a $\bar{x}$, y*
$$\|y^{(k)} - \bar{x}\| \leq \|x^{(k)} - \bar{x}\|.$$
Si la convergencia de $x^{(k)}$ es lineal/superlineal/de orden q, entonces $y^{(k)}$ converge r-lineal/r-superlineal/de orden q.

Observación (Orden de convergencia).
1. La parte 4 parece extraña en la definición. Sin embargo, es necesaria. Considera la secuencia geométrica
$$x = (1, q, q^2, q^3, q^4, \dots).$$
La convergencia a 0 es obviamente lineal. Ahora toma la secuencia
$$y = (1, 0, q^2, 0, q^4, 0, \dots).$$
Según la definición, esta no es lineal, pero intuitivamente debería tener la misma velocidad de convergencia que x. En la literatura, muy a menudo, no existe una distinción exacta entre las definiciones de lineal y r-lineal, etc.
2. El método de descenso de gradiente y el método de gradiente conjugado convergen linealmente.

1.4.1. 6.4.1 Método de optimización de Newton. Para el método de optimización de Newton, buscamos la solución del problema no restringido
$$\min_{x \in \mathbb{R}^n} f(x), \quad f \in C^2.$$

Definición (Problema modelo de Newton). *En lo que sigue, asumimos que $\bar{x}$ es un minimizador que satisface las condiciones suficientes*
$$\nabla f(\bar{x}) = 0, \quad \nabla^2 f(\bar{x}) \text{ definida positiva}$$
y que $\nabla^2 f(x)$ es Lipschitz continua en un entorno U de $\bar{x}$, es decir,
$$\exists \gamma > 0 : \|\nabla^2 f(x) - \nabla^2 f(y)\| \leq \gamma \|x - y\| \quad \forall x, y \in U.$$

El método clásico de Newton para la solución de ecuaciones no lineales se define de la siguiente manera.

Teorema 9.16 (Método de Newton para encontrar el cero de ecuaciones no lineales). *Sea $F : \mathbb{R}^n \to \mathbb{R}^n$ diferenciable. Supongamos que $F(\bar{x}) = 0$ y $F'(\bar{x})$ es invertible. Sea $x^{(k)}$ una sucesión tal que $L^{(k)}(x^{(k+1)}) = 0$, donde $L^{(k)}$ es la linealización de F en $x^{(k)}$, es decir,*
$$L^{(k)}(x) = F(x^{(k)}) + F'(x^{(k)})(x - x^{(k)}).$$
Si F' es Lipschitz continua en un entorno de $\bar{x}$, entonces existe $\epsilon > 0$ tal que el método de Newton para ecuaciones no lineales está bien definido (y es único) y converge a $\bar{x}$ con orden 2 si
$$\|x^{(0)} - \bar{x}\| \leq \epsilon.$$

En particular, tenemos
$$x^{(k+1)} = x^{(k)} - F'(x^{(k)})^{-1} F(x^{(k)}).$$

DEMOSTRACIÓN. Análisis Numérico. □

Esto puede interpretarse de la siguiente manera: En el método de Newton para ecuaciones no lineales, la función F se reemplaza por un modelo lineal L, y tomamos cada siguiente iteración como el cero de ese modelo lineal.

Nótese que el método de Newton converge rápidamente, pero requiere que $x^{(0)}$ esté (muy) cerca de $\bar{x}$, la cual es desconocida. También observa que, formalmente, estamos escribiendo la inversa aquí, pero, por supuesto, la actualización se determina resolviendo un sistema lineal apropiado.

A partir de aquí, podemos derivar fácilmente el método de Newton para minimización no restringida.

TEOREMA 9.17 (Método de Newton para minimización no restringida). *Sea todo como en* **??**. *Sea* $F(x) = \nabla f(x)$. *Entonces*

$$F : \mathbb{R}^n \to \mathbb{R}^n, \quad F(\bar{x}) = 0, \quad F'(\bar{x}) \text{ definida positiva, en particular invertible.}$$

De **??** *tenemos: existe* $\epsilon > 0$ *tal que el método de Newton para encontrar un cero de* F *está bien definido y converge cuadráticamente al minimizador* $\bar{x}$ *de* f *siempre que* $\|x^{(0)} - \bar{x}\| \leq \epsilon$.

En particular, tenemos

$$x^{(k+1)} = x^{(k)} - \nabla^2 f(x^{(k)})^{-1} \nabla f(x^{(k)}).$$

Hay otra forma de motivar esta ecuación. Sea $m^{(k)}(x)$ la serie de Taylor truncada (cuadrática) de f en $x^{(k)}$, entonces

$$m^{(k)}(x) = f(x^{(k)}) + \nabla f(x^{(k)}) \cdot (x - x^{(k)}) + \frac{1}{2}(x - x^{(k)})^T \nabla^2 f(x^{(k)})(x - x^{(k)}).$$

En cada paso, en lugar de minimizar f, minimizamos el modelo cuadrático y usamos el minimizador como el siguiente paso. Usando 29, el mínimo está dado por

$$x^{(k+1)} = x^{(k)} - \nabla^2 f(x^{(k)})^{-1} \nabla f(x^{(k)})$$

y obtenemos nuevamente el método de Newton.

Nótese que al establecer $M^{(k)} = \nabla^2 f(x^{(k)})^{-1}$, este es un método de descenso en el sentido de **??** con longitud de paso 1; lo único que aún necesitamos probar son límites comunes en el Hessiano.

Sin embargo, nuevamente, esto solo es cierto en una pequeña vecindad de $\bar{x}$ donde se garantiza que el Hessiano no se desvía demasiado del Hessiano en $\bar{x}$, el cual es definido positivo. Por lo tanto, esta afirmación solo es localmente verdadera.

No obstante, tenemos **??**. Si aseguramos que en cada paso para la dirección de actualización $d^{(k)}$ se cumple

$$(*) \qquad -\nabla f(x^{(k)}) \cdot d^{(k)} \geq \lambda \|\nabla f(x^{(k)})\| \|d^{(k)}\|$$

y la longitud de paso se elige mediante la regla de Armijo, entonces el algoritmo convergerá.

TEOREMA 9.18 (Algoritmo de Newton globalmente convergente). *En* **??** *sea*

$$y^{(k)} = -\nabla^2 f(x^{(k)})^{-1} \nabla f(x^{(k)}).$$

Si $y^{(k)}$ *satisface (*), entonces use* $d^{(k)} = y^{(k)}$ *como la dirección de descenso; de lo contrario, use* $d^{(k)} = -\nabla f(x^{(k)})$. *Determine la longitud de paso* $t^{(k)}$ *utilizando el algoritmo de Armijo, y defina*

$$x^{(k+1)} = x^{(k)} + t^{(k)} d^{(k)}.$$

Entonces, todo punto de acumulación de $x^{(k)}$ *es un minimizador (independientemente de* $x^{(0)}$*).*

DEMOSTRACIÓN. **??**. □

Nótese que en esta forma, la demostración es bastante inútil. Después de todo, no mejora realmente la **??**, ya que podría darse el caso de que el algoritmo nunca elija direcciones de Newton y solo converja linealmente. Sin embargo, se puede demostrar que si $x^{(k)}$ está lo suficientemente cerca de $\bar{x}$ para algún k, el algoritmo convergerá cuadráticamente.

1.4.2. 6.4.2 Métodos Quasi–Newton. La principal desventaja del método de Newton es que es computacionalmente muy costoso. Para calcular simplemente el Hessiano $H^{(k)} \sim \nabla^2 f(x^{(k)})$ a partir de diferencias finitas, f debe evaluarse n^2 veces en comparación con n veces para el gradiente. Además, incluso si el Hessiano está disponible, se debe resolver un sistema lineal de $n \times n$. Por lo tanto, existe mucho interés en simplificar el paso de Newton.

Para superar el primer problema, solo se utiliza una aproximación muy tosca del Hessiano. Resulta que el método de Newton es convergente siempre que $\|H^{(k)}\| \leq C$ para algún $C > 0$. ¡Incluso elegir $H^{(k)}$ fijo funcionará! (Ejercicios) Sin embargo, típicamente se pierde la velocidad de convergencia cuadrática con estas ideas simples.

Para el segundo problema, podríamos considerar que la dirección de actualización $d^{(k)}$ no apunta exactamente hacia $\bar{x}$ de todos modos. Por lo tanto, podríamos tener la idea de que la ecuación lineal no tiene que resolverse exactamente, sino que un algoritmo iterativo con pocos pasos (número fijo de pasos) será suficiente.

Nótese que el segundo caso se puede reformular como un caso especial del primer caso.

Para formalizar la idea, supongamos que utilizando alguna variante del método de Newton ya hemos calculado $x^{(k+1)}$. Para continuar, definimos la aproximación $H^{(k+1)}$ del Hessiano en $x^{(k+1)}$ usando lo que tenemos que calcular de todos modos, es decir, la aproximación $H^{(k)}$ del Hessiano en $x^{(k)}$, $\nabla f(x^{(k+1)})$ y $f(x^{(k)})$. Formalmente, para alguna función φ, tenemos

$$H^{(k+1)} = \varphi\left(H^{(k)}, x^{(k+1)}, x^{(k)}, \nabla f(x^{(k+1)}), \nabla f(x^{(k)})\right).$$

1. $H^{(k)}$ debe ser simétrica, posiblemente definida positiva.
2. φ debe ser computacionalmente barata.
3. Nuevamente, del teorema fundamental del cálculo, tenemos

$$\nabla f(x^{(k+1)}) - \nabla f(x^{(k)}) = \underbrace{\int_0^1 \nabla^2 f\left(x^{(k)} + t(x^{(k+1)} - x^{(k)})\right) dt}_{\sim H^{(k+1)} \text{ si } x^{(k)} \sim x^{(k+1)}} (x^{(k+1)} - x^{(k)}).$$

   Esto motiva la condición quasi-Newton

$$H^{(k+1)}(x^{(k+1)} - x^{(k)}) = \nabla f(x^{(k+1)}) - \nabla f(x^{(k)}).$$

   Obviamente, esta es una ecuación en $\mathbb{R}^n$, pero el Hessiano está en $\mathbb{R}^{n \times n}$, por lo que φ está lejos de estar definida de manera única.
4. Elegir $\|H^{(k+1)} - H^{(k)}\| \to 0$. Esto se motiva de la siguiente manera:

$$\|(H^{(k)} - \nabla^2 f(x^{(k)}))d^{(k)}\| \leq \|(H^{(k)} - H^{(k+1)})d^{(k)}\| + \|H^{(k+1)}d^{(k)} - \nabla^2 f(x^{(k)})d^{(k)}\|.$$

   Usando la condición quasi-Newton, el segundo término se convierte en

$$\left\|\nabla f(x^{(k+1)}) - \nabla f(x^{(k)}) - \nabla^2 f(x^{(k)})(x^{(k+1)} - x^{(k)})\right\| = o(\|x^{(k+1)} - x^{(k)}\|)$$

   con expansión de Taylor en ∇f. Por lo tanto, si $\|H^{(k)} - H^{(k+1)}\| \to 0$, ambos términos tienden a $o(\|H^{(k)}\|)$.

Dado que φ no está definida de manera única, hay una multitud de opciones para la actualización. La más simple es una actualización de rango 1. Aquí, elegimos φ tal que $H^{(k+1)} - H^{(k)}$ tiene rango 1 o

$$H^{(k+1)} = H^{(k)} + v^{(k)}(v^{(k)})^t.$$

Para la condición quasi-Newton, obtenemos

$$H^{(k+1)}d^{(k)} = \underbrace{\nabla f(x^{(k+1)}) - \nabla f(x^{(k)})}_{=y^{(k)}}.$$

Sustituyendo en la definición de $H^{(k+1)}$, obtenemos

$$(*) \qquad y^{(k)} = H^{(k)}d^{(k)} + v^{(k)}(v^{(k)})^t d^{(k)} = H^{(k)}d^{(k)} + (v^{(k)})^t d^{(k)} v^{(k)}$$

o

$$v^{(k)} = \frac{1}{(v^{(k)})^t d^{(k)}} \underbrace{\left(y^{(k)} - H^{(k)}d^{(k)}\right)}_{=\lambda},$$

donde λ es un escalar desconocido. Al insertar en $(*)$ se determina λ hasta su signo, y esto define φ.

Reglas más sofisticadas consideran una actualización de rango 2 de la forma

$$H^{(k+1)} = H^{(k)} + u^{(k)}(u^{(k)})^t + v^{(k)}(v^{(k)})^t.$$

Como ahora tenemos dos grados de libertad, la actualización no está definida de manera única, y existen muchas opciones posibles. Una de las más populares es BFGS (Broyden–Fletcher–Goldfarb–Shanno), que elige

$$H^{(k+1)} = H^{(k)} + \frac{y^{(k)}(y^{(k)})^t}{(y^{(k)})^t d^{(k)}} - \frac{H^{(k)}d^{(k)}(H^{(k)}d^{(k)})^t}{(y^{(k)})^t d^{(k)}(d^{(k)})^t}.$$

Se puede demostrar que BFGS es cuadráticamente convergente en una pequeña vecindad de $\bar{x}$.

1.4.3. 6.4.3 Métodos de Región de Confianza. Otro problema del método de Newton es su convergencia local. Para superar esto, se han desarrollado métodos de región de confianza, que se tratan en los ejercicios. Damos un breve esquema de la idea.

1. En nuestros métodos, reemplazamos $f(x)$ por una función modelo (aproximación). Para Newton, elegimos

   $$f(x^{(k)} + s) = m^{(k)}(s) = f(x^{(k)}) + g^{(k)} \cdot s + \frac{1}{2}s^t H^{(k)} s$$

   donde $g^{(k)}$ es el gradiente y $H^{(k)}$ es el Hessiano en $x^{(k)}$.
2. Típicamente, el modelo/la aproximación solo será confiable en una vecindad de $x^{(k)}$, por lo que si

   $$\|s\| \leq \delta^{(k)}.$$

3. Cuando elegimos la actualización de Newton normal $d^{(k)}$, y $\|d^{(k)}\| > \delta^{(k)}$, esto no tiene sentido (ya que estamos usando el modelo en una región donde no es confiable).
4. En lugar de tomar el mínimo global de $m^{(k)}$, calculamos

   $$d^{(k)} = \min_{\|s\| \leq \delta^{(k)}} m^{(k)}(s).$$

   Para el modelo cuadrático, esto puede calcularse explícitamente (ejercicios).

5. En cada paso, $\delta^{(k)}$ se actualiza. Para ello, comparamos la reducción predicha en el modelo

$$pred(s) := m^{(k)}(0) - m^{(k)}(s)$$

y la reducción real

$$ared(s) := f(x^{(k)}) - f(x^{(k+1)}).$$

Si

$$\rho := \frac{ared(s)}{pred(s)} \approx 1$$

entonces el modelo es confiable y se acepta el paso actual. Además, ajustamos que el radio de confiabilidad podría ampliarse y elegimos $\delta^{(k+1)} = 2\delta^{(k)}$.

Si este no es el caso, rechazamos el paso actual, estableciendo $x^{(k+1)} = x^{(k)}$ y reduciendo el radio de confiabilidad configurando $\delta^{(k+1)} = \delta^{(k)}/2$.

2. Optimización numérica con restricciones

Deseamos derivar métodos numéricos para el problema general (o,1) que incluye restricciones, es decir,

$$\text{mín}\, f(x) : c_I(x) \leq 0,\ c_E(x) = 0$$

con definiciones como en (o,1).

3. Métodos de penalización

La idea aquí es reutilizar los métodos para optimización sin restricciones, pero añadir un término de penalización $\Psi(x)$ a la función de minimización f que sea cero para x factible y grande en caso contrario, es decir,

$$F(x,\gamma) = f(x) + \gamma\Psi(x), \quad \Psi(x) = \begin{cases} 0 & x \text{ factible}, \\ > 0 & x \text{ infactible}, \quad \gamma > 0. \end{cases}$$

El método de penalización entonces resuelve para un γ fijo el problema de minimización sin restricciones:

$$\text{mín}\, F(x,\gamma)$$

y acepta la solución como una aproximación para un punto mínimo $\bar{x}$.

Una elección típica es la función de penalización cuadrática:

$$\Psi_2(x) = \frac{1}{2}\left(\|c_E(x)\|^2 + \|c_I(x)^+\|^2\right),$$

donde $z^+ = \text{máx}(z, 0)$.

Nótese que si c_I y c_E son diferenciables, entonces también Ψ_2 lo es, y

$$\nabla\Psi_2 = c_E'(x)^t c_E(x) + c_I'(x)^t c_I(x)^+.$$

donde $'$ denota el Jacobiano (recuerda la definición del Jacobiano en 2.1). Obviamente, para x factible, tenemos

$$F(x,\gamma) = f(x), \quad \nabla F(x,\gamma) = \nabla f(x).$$

Formalmente, para $\gamma \to \infty$, recuperamos nuestro problema original. Sin embargo, cuando γ es grande, también la derivada de F es grande, lo que conduce a inestabilidades numéricas. Ignoramos esto por el momento y demostramos que los métodos de penalización tienen algunas propiedades esperadas.

TEOREMA 9.19 (Propiedades del método de penalización). *Sean f, c_I, c_E continuas. Sea $\{\gamma^{(k)}\}$ una secuencia estrictamente creciente con límite ∞ y $\gamma^{(0)} > 0$. Supongamos que el problema de minimización sin restricciones para F tiene una solución $x^{(k)}$ para todo $\gamma^{(k)}$, y que el problema con restricciones tiene una solución global. Entonces:*

1. *$F(x^{(k)}, \gamma^{(k)})$ es creciente.*
2. *$\Psi(x^{(k)})$ es decreciente.*
3. *$f(x^{(k)})$ es creciente.*
4. *$\Psi(x^{(k)}) \to 0$.*
5. *Todo punto de acumulación de $\{x^{(k)}\}$ es una solución global del problema sin restricciones.*

Nótese que necesitamos el requisito adicional de que exista la solución global para los problemas sin restricciones, incluso si el problema con restricciones tiene una solución global. Simplemente asumamos que el conjunto factible es compacto y que $f(x)$ decrece exponencialmente; entonces una solución para el problema con restricciones existe, pero ninguno de los problemas de penalización es resoluble (usando términos de penalización cuadráticos). Para asegurar la resolubilidad, uno podría cortar la función $f(x)$ para $\|x\| > x_0$ o aplicar una función estrictamente creciente de amortiguamiento a f, por ejemplo, $\min \log f(x)$ en lugar de $\min f(x)$.

Para las demostraciones, simplemente insertamos la propiedad de minimización definitoria de $x^{(k)}$.

DEMOSTRACIÓN. 1.

$$F(x^{(k)}, \gamma^{(k)}) \leq F(x^{(k+1)}, \gamma^{(k)}) \leq F(x^{(k+1)}, \gamma^{(k+1)}).$$

2. De la condición de optimalidad para $x^{(k)}$, tenemos

$$F(x^{(k)}, \gamma^{(k)}) \leq F(x^{(k+1)}, \gamma^{(k)})$$
$$F(x^{(k+1)}, \gamma^{(k+1)}) \leq F(x^{(k)}, \gamma^{(k+1)}).$$

□

Sumando estas expresiones, obtenemos

$$(\gamma^{(k)} - \gamma^{(k+1)}) \underbrace{\Psi(x^{(k)})}_{>0} \leq (\gamma^{(k)} - \gamma^{(k+1)})\Psi(x^{(k+1)})$$

lo que implica

$$\Psi(x^{(k+1)}) \leq \Psi(x^{(k)}).$$

3. Tenemos

$$0 \leq F(x^{(k+1)}, \gamma^{(k)}) - F(x^{(k)}, \gamma^{(k)}) = f(x^{(k+1)}) - f(x^{(k)}) + \gamma^{(k)} \underbrace{(\Psi(x^{(k+1)}) - \Psi(x^{(k)}))}_{\leq 0 \text{ (de 2)}}.$$

Por lo tanto,

$$f(x^{(k+1)}) - f(x^{(k)}) \geq 0.$$

4. Sea $\hat{x}$ una solución (factible) del problema con restricciones. Entonces

$$F(x^{(k)}, \gamma^{(k)}) \leq F(\hat{x}, \gamma^{(k)}) = f(\hat{x}),$$

lo que implica

$$f(\hat{x}) \geq f(x^{(k)}) + \gamma^{(k)}\Psi(x^{(k)}) \geq f(x^{(0)}) + \gamma^{(k)}\Psi(x^{(k)}).$$

Esto significa que $\gamma^{(k)}\Psi(x^{(k)})$ está acotado, por lo que $\Psi(x^{(k)}) \to 0$.

5. Sin pérdida de generalidad (WLOG), supongamos que $x^{(k)} \to \bar{x}$. De (4) y la continuidad de c_I, c_E, tenemos que $\bar{x}$ es factible. Sea $x \in \mathbb{R}^n$ factible. Entonces
$$f(x^{(k)}) \leq F(x^{(k)}, \gamma^{(k)}) \leq F(x, \gamma^{(k)}) = f(x).$$
Tomando el límite en esta desigualdad y usando que f es continua, obtenemos
$$f(\bar{x}) \leq f(x).$$

Ya observamos que para Ψ_2, la función de minimización F es diferenciable, siempre que f, c_I, c_E sean diferenciables. Para la siguiente observación, recordamos las definiciones de la función de Lagrange. Para el problema completo (o,1), la función de Lagrange se define como
$$L(x, \mu, \lambda) := f(x) + \mu^t c_I(x) + \lambda^t c_E(x), \quad \mu \in \mathbb{R}^p,\ \lambda \in \mathbb{R}^m,\ \mu \geq 0.$$

Para Ψ_2, tenemos
$$\begin{aligned} 0 = \nabla F(x^{(k)}, \gamma^{(k)}) &= \nabla f(x^{(k)}) + \gamma^{(k)} c_E'(x^{(k)})^t c_E(x^{(k)}) + \gamma^{(k)} c_I'(x^{(k)})^t c_I(x^{(k)})^+, \\ &= \nabla f(x^{(k)}) + c_E'(x^{(k)})^t (\underbrace{\gamma^{(k)} c_E(x^{(k)})}_{=\lambda^{(k)}}) + c_I'(x^{(k)})^t (\underbrace{\gamma^{(k)} c_I(x^{(k)})^+}_{=\mu^{(k)}}), \\ &= \nabla L(x^{(k)}, \mu^{(k)}, \lambda^{(k)}), \end{aligned}$$
que es una parte de la definición del punto silla (y que recuerda a los multiplicadores de Lagrange).

De hecho, tenemos:

Teorema 9.20 (Métodos de penalización y las condiciones KKT). *Sean las condiciones como en 7.1 y $\Psi = \Psi_2$.*

1. *Si $(\bar{x}, \bar{\lambda}, \bar{\mu})$ es un punto de acumulación de $(x^{(k)}, \lambda^{(k)}, \mu^{(k)})$, entonces $(\bar{x}, \bar{\mu}, \bar{\lambda})$ satisface las condiciones de Kuhn–Tucker (2.16):*
$$\nabla_x L(\bar{x}, \bar{\mu}, \bar{\lambda}) = 0, \quad \bar{x} \text{ factible}, \quad \bar{\mu} c_I(\bar{x}) = 0.$$
2. *Si $\bar{x}$ es un punto de acumulación de $x^{(k)}$ y $\bar{x}$ es regular (es decir, los gradientes de las restricciones activas son linealmente independientes), entonces existen $\bar{\mu}, \bar{\lambda}$ tales que $(\bar{x}, \bar{\mu}, \bar{\lambda})$ es un punto de acumulación de $(x^{(k)}, \mu^{(k)}, \lambda^{(k)})$.*

Demostración. 1. Supongamos WLOG que $x^{(k)} \to \bar{x}$, $\mu^{(k)} \to \bar{\mu}$, $\lambda^{(k)} \to \bar{\lambda}$. De 7.1 sabemos que $\bar{x}$ es una solución, y por la observación anterior tenemos
$$0 = \nabla_x L(x^{(k)}, \mu^{(k)}, \lambda^{(k)}) \to \nabla_x L(\bar{x}, \bar{\mu}, \bar{\lambda}).$$
Además,
$$0 \leq \gamma^{(k)} c_I(x^{(k)})^+ = \mu^{(k)} \to \bar{\mu}.$$
Dado que $\bar{x}$ es factible, $c_I(\bar{x}) \leq 0$. Supongamos que $c_I(\bar{x})_j < 0$. Entonces, para k suficientemente grande, $c_I(x^{(k)})_j < 0$, lo que implica que $c_I(x^{(k)})_j^+ = 0$ para k grande, por lo que $\bar{\mu}_j = 0$. Por lo tanto, $c_I(\bar{x})_j = 0$ o $\bar{\mu}_j = 0$.

2. La única diferencia con la parte 1 es que aquí no tenemos la convergencia de la subsecuencia correspondiente. Supongamos WLOG que todas las restricciones de desigualdad son inactivas (de lo contrario, pasamos a restricciones de igualdad). Entonces, para $k > K$ como antes, $c_I(x^{(k)}) < 0$ y $\mu^{(k)} \to 0 := \mu$. Sea
$$A = c_E'(x)^t = (\nabla c_E(x))^t, \quad A^{(k)} = c_E'(x^{(k)})^t.$$

□

Dado que $\bar{x}$ es regular, A tiene rango completo, por lo que A^tA es invertible. Además, a partir de algún índice, el determinante de $A^{(k)t}A^{(k)}$ no se anula ($A^{(k)} \to A$ y el determinante es una función continua), por lo que para $k > K$, $A^{(k)t}A^{(k)}$ es invertible. Por lo tanto,

$$0 = A^{(k)t}\nabla_x \tilde{L}(x^{(k)}, \lambda^{(k)}) = A^{(k)t}\nabla f(x^{(k)}) + A^{(k)t}A^{(k)}\lambda^{(k)},$$

donde $\tilde{L}(x, \lambda) = L(x, 0, \lambda)$. Dado que $A^{(k)t}A^{(k)}$ es invertible, esto se puede resolver para $\lambda^{(k)}$, y

$$\lambda^{(k)} \to -(A^tA)^{-1}A^t\nabla f(\bar{x}).$$

De alguna manera, estos últimos dos teoremas son un gran resultado. Aunque la idea de los métodos de penalización es tan simple, tienen más o menos todas las propiedades que uno podría desear: convergencia al mínimo e incluso convergencia de los parámetros duales. Sin embargo, la afirmación inicial se mantiene: para $\gamma^{(k)} \to \infty$, los problemas están mal escalados y son numéricamente inestables para $\gamma^{(k)}$ grandes.

Queremos evitar esto. Es una gran sorpresa que un $\gamma^{(k)}$ grande no siempre sea necesario. De hecho, algunas funciones de penalización Ψ son exactas, lo que significa que producen el resultado correcto $\bar{x}$ para un $\gamma^{(k)}$ finito.

Definición (Métodos de penalización exactos). *Una función de penalización Ψ se denomina exacta para un problema de minimización si un minimizador (local) del problema restringido es un minimizador (local) de la función penalizada F para algún $\gamma > 0$.*

Un ejemplo de una función de penalización exacta para problemas con dualidad fuerte es el término de penalización L_1:

$$\Psi_1(x) = \|c_I(x)^+\|_1 + \|c_E(x)\|_1.$$

Demostramos la exactitud solo para problemas convexos.

Teorema 9.21 (Ψ_1 es exacta). *Sean f, c_I convexas, c_E lineales, y $(\bar{x}, \bar{\mu}, \bar{\lambda})$ satisface las condiciones KKT del problema restringido (o,1), y es un mínimo global. Entonces $\bar{x}$ es una solución del problema global dado por*

$$F(x, \gamma) := f(x) + \gamma\Psi_1(x)$$

para $\gamma \geq$ máx$(|\lambda_i|, \mu_i)$.

Demostración. $\bar{x}$ es una solución (factible) del problema global. □

Además, para cualquier $x \in \mathbb{R}^n$, tenemos:

$$\begin{aligned} F(\bar{x}, \gamma) = f(\bar{x}) &= f(\bar{x}) + \bar{\mu}^t c_I(\bar{x}) + \bar{\lambda}^t c_E(\bar{x}) \quad \text{(complementariedad)} \\ &= L(\bar{x}, \bar{\mu}, \bar{\lambda}) \leq L(x, \bar{\mu}, \bar{\lambda}) \quad \text{(propiedad de punto silla)} \\ &\leq f(x) + \bar{\mu}^t c_I(x)^+ + |\bar{\lambda}^t||c_E(x)| \quad \text{(componente a componente)} \\ &\leq f(x) + \gamma\Psi_1(x) = F(x, \gamma). \end{aligned}$$

Observación (Observación 7.5). Sea Ψ exacta para γ_0. Entonces Ψ es exacta para $\gamma \geq \gamma_0$.

Demostración. Sea $\bar{x}$ un minimizador del problema restringido, por lo que $\bar{x}$ es factible. A partir de esto y de la exactitud para γ_0, tenemos que para todo $x \in \mathbb{R}^n$,

$$f(\bar{x}) = F(\bar{x}, \gamma_0) \leq F(x, \gamma_0),$$

y por lo tanto,

$$F(\bar{x}, \gamma) = f(\bar{x}) \leq F(x, \gamma_0) \leq F(x, \gamma).$$

□

COROLARIO 9.22 (Funciones de penalización exactas no son diferenciables). *Sea Ψ diferenciable y exacta para γ_0 y un mínimo (local) $\bar{x}$. Entonces $\nabla f(\bar{x}) = 0$.*

DEMOSTRACIÓN. De la observación, sabemos que Ψ es exacta para $\gamma > \gamma_0$. Así,

$$\nabla_x F(\bar{x}, \gamma) = 0 = \nabla_x F(\bar{x}, \gamma_0) \implies (\gamma - \gamma_0)\nabla\Psi(\bar{x}) = 0 \implies \nabla\Psi(\bar{x}) = 0.$$

Y nuevamente, dado que

$$0 = \nabla_x F(\bar{x}, \gamma),$$

tenemos que $\nabla f(\bar{x}) = 0$. □

Sin embargo, la diferenciabilidad es definitivamente una propiedad deseable. A continuación, cambiaremos ligeramente la definición de las funciones de penalización. Consideramos primero solo restricciones de igualdad, es decir, $m = 0$ en *o*,1.

OBSERVACIÓN (No exactitud de Ψ_2). Sea $\Psi = \Psi_2$, $\bar{x}$ una solución de *o*,1 con solo restricciones de igualdad, $\bar{\lambda}$ el multiplicador de Lagrange correspondiente, y $\bar{\lambda} \neq 0$. Entonces, la factibilidad de $\bar{x}$ solo puede lograrse haciendo que $\gamma^{(k)} \to \infty$.

DEMOSTRACIÓN. De la prueba del Teorema 7.2, tenemos que en este caso:

$$\lambda^{(k)} = \gamma^{(k)} c_E(x^{(k)}) \to \bar{\lambda}.$$

□

Por lo tanto, necesitamos una nueva idea. Comenzamos definiendo una función de Lagrange ligeramente modificada. Recordemos que para restricciones únicamente de igualdad, tenemos:

$$L(x, \lambda) = f(x) + \lambda^t c_E(x).$$

Definimos L_A, el Lagrangiano aumentado, como la función de Lagrange para la función objetivo penalizada $F(x, \gamma)$. Recordemos que, dado que $\Psi(x) = 0$ para x factible, el problema penalizado con restricciones es equivalente al problema original con restricciones.

DEFINICIÓN (Lagrangiano aumentado). *Consideremos o,1 con restricciones únicamente de igualdad. Entonces, el Lagrangiano aumentado se define como:*

$$L_A(x, \lambda, \gamma) = f(x) + \frac{\gamma}{2}\|c_E(x)\|^2 + \lambda^t c_E(x) = L(x, \lambda) + \gamma\Psi_2(x).$$

Recordemos que $c_E(x) = (h_1(x), \ldots, h_p(x))^t$, y definimos $\Psi = \Psi_2$.

LEMA 9.23 (Gradiente del Lagrangiano aumentado). *Tenemos que*

$$\nabla_x L_A(x, \lambda, \gamma) = \nabla f(x) + DC_E(x)^t(\lambda + \gamma c_E(x)) = \nabla f(x) + \sum_{i=1}^{m}(\lambda_i + \gamma h_i(x))\nabla h_i(x).$$

Idea del método: En el algoritmo, determinamos la solución primal x^* y su multiplicador de Lagrange λ^*. Por lo tanto:

1. **Entrada:** Aproximación $x^{(0)}$ para el punto mínimo, aproximación $\lambda^{(0)}$ para el multiplicador de Lagrange, $\gamma^{(0)}$ como punto inicial para el término de penalización, parámetro de tolerancia τ_0.
2. Calcular una aproximación $x^{(k+1)}$ al problema de minimización sin restricciones para $L_A(\cdot, \lambda^{(k)}, \gamma^{(k)})$ tal que
$$\|\nabla_x L_A(x^{(k+1)}, \lambda^{(k)}, \gamma^{(k)})\| \leq \tau_k.$$
Ver 2.12.
3. Actualizar $\lambda^{(k+1)}$ basado en $\lambda^{(k)}$.
4. Elegir $\gamma^{(k+1)} \geq \gamma^{(k)}, \tau^{(k+1)} \leq \tau^{(k)}$.

5. Repetir desde el paso 2.

Idea para la actualización de $\lambda^{(k)}$:

A partir de la propiedad de minimización, tenemos:

$$\nabla_x L_A(x^{(k+1)}, \lambda^{(k)}, \gamma^{(k)}) = \nabla f(x^{(k+1)}) + \sum_{i=1}^{m} (\lambda_i^{(k)} + \gamma^{(k)} h_i(x^{(k+1)})) \nabla h_i(x^{(k+1)}).$$

Para el verdadero minimizador y su multiplicador de Lagrange, tenemos:

$$0 = \nabla_x L(x^*, \mu^*) = \nabla f(x^*) + \sum_j \mu_j^* \nabla h_j(x^*).$$

Asumamos que $x^{(k+1)} \to x^*$, $\mu^{(k+1)} \to \mu^*$, entonces

$$\lambda^{(k+1)} = \lambda^{(k)} + \gamma^{(k)} c_E(x^{(k+1)})$$

es una elección razonable.

TEOREMA 9.24 (Propiedad casi exacta del Lagrangiano aumentado). *Sea x^* una solución (local) de o,1 con restricciones de igualdad y regular. Asumamos que las condiciones suficientes de segundo orden de 2.14 están satisfechas, y que λ^* es el multiplicador de Lagrange correspondiente. Entonces existe $\gamma^* > 0$ tal que para $\gamma \geq \gamma^*$, x^* es un mínimo estricto (local) de $L_A(x, \lambda^*, \gamma)$.*

Nota: Esto es cercano a la exactitud, pero no completamente, ya que se requiere conocimiento del verdadero multiplicador de Lagrange.

Recordatorio: Las condiciones suficientes de segundo orden requieren que:

$$c_E(x^*) = 0, \quad \nabla f(x^*) + \lambda^t \nabla c_E(x^*) = 0,$$

y que

$$\text{Hess}_x L(x^*, \lambda) = \text{Hess} f(x^*) + \sum_k \lambda_k \,\text{Hess}\, h_k(x^*)$$

sea definida positiva en el núcleo de $DC_E(x^*)^t$.

DEMOSTRACIÓN. Demostramos que las condiciones suficientes de segundo orden de 2.14 se cumplen. Tenemos:

$$\nabla_x L_A(x^*, \lambda^*, \gamma) = \nabla f(x^*) + \sum_j (\lambda_j^* + \gamma h_j(x^*)) \nabla h_j(x^*),$$

$$= \nabla f(x^*) + \lambda^t c_E(x^*) = 0,$$

ya que x^* es factible según 2.11.

Ahora probamos la definición positiva del hessiano. A partir de la fórmula para el gradiente, derivando una vez más, tenemos:

$$\text{Hess} L_A(x^*, \lambda^*, \gamma) = \text{Hess} L(x^*, \lambda) + \gamma \sum_j \left(h_j(x^*)\,\text{Hess}\, h_j(x^*) + \nabla h_j(x^*) \nabla h_j(x^*)^t \right).$$

Sea $A := DC_E(x^*) = (\nabla h_1(x^*), \ldots, \nabla h_p(x^*))^t$. Entonces, A tiene rango completo $p \leq n$, ya que x^* es regular y factible. Por lo tanto:

$$\text{Hess}_x L_A(x^*, \lambda^*, \gamma) = \text{Hess} L(x^*, \lambda) + \gamma A^t A.$$

Supongamos que $\text{Hess}_x L_A(x^*, \lambda^*, \gamma)$ no es definida positiva para algún $\gamma > \gamma_0$. Entonces, existe un $w^{(k)} \in \mathbb{R}^n$, con $\|w^{(k)}\| = 1$, tal que:

$$0 \geq w^{(k)t} \text{Hess}_x L_A(x^*, \lambda^*, \gamma) w^{(k)} = w^{(k)t} \text{Hess} L(x^*, \lambda) w^{(k)} + \gamma \|A w^{(k)}\|^2.$$

La bola unitaria es compacta, por lo que $w^{(k)}$ tiene una subsucesión convergente. Sin pérdida de generalidad, sea $w^{(k)} \to w$, con $\|w\| = 1$. Además, tenemos:

$$\|A w^{(k)}\|^2 \leq -\frac{1}{k} w^{(k)t} \text{Hess} L(x^*, \lambda) w^{(k)} \to 0,$$

por lo que $\|Aw\| = 0$, o w está en el núcleo de $DC_E(x^*)^t$.

Finalmente:

$$0 \geq -k\|Aw^{(k)}\|^2 + w^{(k)t}\mathrm{Hess}_x L(x^*, \lambda)w^{(k)} \to w^t \mathrm{Hess}_x L(x^*, \lambda)w,$$

lo que contradice la positividad definida de $\mathrm{Hess}_x L(x^*, \lambda)$ en el núcleo de $DC_E(x^*)^t$. □

Idea para restricciones de desigualdad: Convertimos el problema completo *o*,1 en uno con solo restricciones de igualdad, introduciendo las variables de holgura s_i, escribiendo $g_i(x) \leq 0$ como $g_i(x) + s_i^2 = 0$. Esta es una reformulación del problema original en las nuevas variables (x, s) con solo restricciones de igualdad.

La correspondiente Lagrangiana aumentada es:

$$L_A(x, s, \mu, \lambda, \gamma) = f(x) + \lambda^t h(x) + \frac{1}{2}\gamma\|h(x)\|^2 + \sum_i \mu_i\big(g_i(x) + s_i^2\big) + \frac{1}{2}\gamma\big(g_i(x) + s_i^2\big)^2.$$

Nuestro algoritmo es exactamente el mismo, excepto que ahora debemos actualizar no solo x y λ, sino también s y μ. Respecto a la actualización de s: L_A es una función cuadrática en s_i^2, y el mínimo se puede calcular explícitamente. Resulta que el minimizador está dado por:

$$s_i^* = \left(\text{máx}(0, -\frac{\mu_i}{\gamma} + g_i(x))\right)^{\frac{1}{2}}.$$

4. Programación cuadrática

En esta sección, sea f cuadrático y c_E lineal, es decir, *o*,1 se escribe como:

$$\min_x f(x) := \frac{1}{2}x^t Q x + c^t x \quad \text{con } c_E(x) := Bx = \beta,\ c_I(x) := Ax \leq \alpha,$$

donde $Q \in \mathbb{R}^{n\times n}, c \in \mathbb{R}^n, B \in \mathbb{R}^{p\times n}, \beta \in \mathbb{R}^p, A \in \mathbb{R}^{m\times n}, \alpha \in \mathbb{R}^m$.

Sea x^* una solución factible. Las condiciones de Karush–Kuhn–Tucker 2.16 garantizan la existencia de $\lambda^* \in \mathbb{R}^p, \mu^* \in \mathbb{R}^m$ tales que:

$$Qx^* + c + B^t\lambda^* + A^t\mu^* = 0, \quad \mu^* \geq 0, \quad \mu^*\big(Ax^* - \alpha\big) = 0, \quad Ax^* \leq \alpha, \quad Bx^* = \beta.$$

4.1. Restricciones de igualdad. Comenzamos considerando solo restricciones de igualdad ($m = 0$). Entonces, las condiciones KKT se reducen a:

$$\begin{pmatrix} Q & B^t \\ B & 0 \end{pmatrix}\begin{pmatrix} x^* \\ \lambda^* \end{pmatrix} = \begin{pmatrix} -c \\ \beta \end{pmatrix}.$$

Suponiendo que Q es definido positivo y que x es regular (lo cual implica que las filas de B son linealmente independientes), este sistema de ecuaciones tiene una solución única (el punto mínimo x y su multiplicador de Lagrange correspondiente).

4.1.1. Estrategia de restricciones activas para restricciones de desigualdad. Ahora permitimos tanto restricciones de igualdad como desigualdad. Para motivar el algoritmo, asumimos que x^* es conocido. Sea I el conjunto de índices:

$$I := \{i : (Ax^*)_i = \alpha_i\}.$$

Definimos:

$$A_I := (A_{i,k} : i \in I), \quad \alpha_I := (\alpha_i : i \in I), \quad \mu_I^* := (\mu_i^* : i \in I).$$

Entonces:

$$Bx^* = \beta, \quad A_I x^* = \alpha_I.$$

Dado que $\mu_k^* = 0$ para $k \notin I$, tenemos:

$$\begin{pmatrix} Q & A_I^t & B^t \\ A_I & 0 & 0 \\ B & 0 & 0 \end{pmatrix}\begin{pmatrix} x^* \\ \mu_I^* \\ \lambda^* \end{pmatrix} = \begin{pmatrix} -c \\ \alpha_I \\ \beta \end{pmatrix}. \tag{7.1}$$

De nuevo, suponiendo que Q es definido positivo y que x^* es regular, tenemos que este sistema de ecuaciones tiene una solución única.

Dado que cualquier solución de (**??**) y definiendo $\mu_k^* = 0$ para $k \notin I$, se satisface 2,16 si y solo si $\mu_i^* \geq 0$ para todo $i \in I$.

Esto motiva la siguiente estrategia:

1. Recorrer todos los subconjuntos de índices I de $(1, \ldots, m)$.
2. Calcular la solución correspondiente de (**??**).
3. Verificar si $\mu_i^* \geq 0$. Si es así, x^* es un potencial mínimo (local).

Esto es ineficiente, por lo que seguimos una estrategia inspirada en el algoritmo del simplex:

1. **Entrada:** Un $x^{(0)}$ factible, un conjunto de índices inicial $I = I^{(0)}$ tal que $A_I x^* = \alpha_I$.
2. Calcular x^*, μ^* vía (**??**) para el conjunto de índices $I^{(k)}$.
3. Verificar si x^* es factible. Dado que $A_I x^* = \alpha_I, Bx^* = \beta$, esto solo es posible si $(Ax^*)_k > \alpha_k$ para algún $l \notin I^{(k)}$.
4. Si x^* es factible, continuar en el paso 6.
5. Agregar uno de los índices que bloquean x de la factibilidad al conjunto $I^{(k)}$, es decir, definir

$$t^* := \text{máx}\{t : x^{(k)} + t(x^* - x^{(k)}) \text{ es factible}\} = \text{mín}\left\{ \frac{\alpha_l - (Ax^{(k)})_l}{(A(x^* - x^{(k)}))_l} : l \notin I^{(k)} \right\}.$$

   Entonces, existe $l \notin I^{(k)}$ tal que $x_l^{(k+1)} = 0$. Definir:

$$x^{(k+1)} := x^{(k)} + t^*(x^* - x^{(k)}), \quad I^{(k+1)} := I^{(k)} \cup \{l\}.$$

   Luego, continuar en el paso 2.
6. Verificar si $\mu \geq 0$. Si es así, se ha encontrado un punto KKT.
7. Si no, eliminar uno de los índices bloqueantes de $I^{(k)}$, es decir:

$$l = \arg\min_l \mu_l^*, \quad I^{(k+1)} := I^{(k)} \setminus \{l\}, \quad x^{(k+1)} := x^{(k)}.$$

Este algoritmo no garantiza la terminación ni la convergencia. Sin embargo, al menos se garantiza que $x^* - x^{(k)}$ es una dirección de descenso si Q es s.p.d.

Bibliografía

[1] R. L. Burden and D. J. Faires. *Numerical Analysis*. Brooks Cole, December 2004.

[2] K. L. Judd. *Numerical Methods in Economics*, volume 1 of *MIT Press Books*. The MIT Press, 1 edition, December 1998.

[3] D. R. Kincaid and E. W. Cheney. *Numerical Analysis*. Brooks/Cole Publishing Company, 1991.

[4] J. Stoer and R. Bulirsch. *Introduction to numerical analysis*, volume 12 of *Texts in Applied Mathematics*. Springer-Verlag, New York, third edition, 2002. Translated from the German by R. Bartels, W. Gautschi and C. Witzgall.