

Sistemas de ecuaciones lineales



UNIVERSIDAD
DEL PACÍFICO

Métodos iterativos matriciales

Oswaldo José Velásquez Castañón
Métodos Numéricos – 2026-2

Iterar reemplaza una factorización costosa

Los métodos directos producen una solución después de factorizar A . Los métodos iterativos construyen aproximaciones

$$x^{(0)}, x^{(1)}, x^{(2)}, \dots$$

usando operaciones simples con A .

Cuándo resultan atractivos

Sistemas grandes, matrices dispersas, almacenamiento limitado o una precisión moderada que no exige completar una factorización.

El reto es doble: cada paso debe ser barato y la sucesión debe converger.

Una matriz sencilla define la iteración

Escriba

$$A = B + (A - B),$$

donde resolver sistemas con B sea fácil. Entonces

$$Ax = b \iff Bx = (B - A)x + b.$$

Esto sugiere

$$Bx^{(k+1)} = (B - A)x^{(k)} + b.$$

Implementación

No se calcula B^{-1} : en cada paso se resuelve un sistema diagonal o triangular con matriz B .

La forma de punto fijo facilita el análisis

Como B es no singular,

$$x^{(k+1)} = Tx^{(k)} + c, \quad T = I - B^{-1}A, \quad c = B^{-1}b.$$

Un punto fijo x^* satisface

$$x^* = Tx^* + c \iff Ax^* = b.$$

- ▶ La elección de B determina el costo de cada paso.
- ▶ La matriz T determina la convergencia.

El error evoluciona con la matriz iterativa

Sea x^* la solución y defina $e^{(k)} = x^{(k)} - x^*$. Restando las dos ecuaciones de punto fijo,

$$e^{(k+1)} = T e^{(k)}.$$

Por inducción,

$$\boxed{e^{(k)} = T^k e^{(0)}}.$$

Por tanto, el método converge para todo valor inicial exactamente cuando $T^k \rightarrow 0$.

Convergencia: radio espectral

El radio espectral de T es

$$\rho(T) = \max_{\lambda \in \sigma(T)} |\lambda|.$$

Criterio necesario y suficiente

La iteración estacionaria converge hacia x^* para todo $x^{(0)}$ si y solo si

$$\boxed{\rho(T) < 1}.$$

Si $\|T\| < 1$ para alguna norma matricial subordinada, entonces

$$\rho(T) \leq \|T\| < 1,$$

una condición suficiente que suele ser más fácil de comprobar.

El radio mide la rapidez

Para errores dominados por el modo propio más lento,

$$\|e^{(k)}\| \approx C \rho(T)^k.$$

- ▶ $\rho(T)$ cercano a 0: pocas iteraciones.
- ▶ $\rho(T)$ cercano a 1: convergencia lenta.
- ▶ $\rho(T) > 1$: existe un error inicial que crece.

Conexión con la Unidad 2

Los métodos estacionarios convergentes presentan típicamente convergencia lineal; el factor asintótico está relacionado con $\rho(T)$.

Una contracción ofrece cotas computables

Si $L = \|T\| < 1$, entonces para $k \geq 1$:

$$\|x^{(k)} - x^*\| \leq \frac{L^k}{1-L} \|x^{(1)} - x^{(0)}\|,$$

$$\|x^{(k)} - x^*\| \leq \frac{L}{1-L} \|x^{(k)} - x^{(k-1)}\|.$$

- ▶ La primera es una cota **a priori**.
- ▶ La segunda es una cota **a posteriori**.

Separar D , L y U genera los métodos

Separe

$$D = \text{diag}(a_{11}, \dots, a_{nn}),$$
$$L = \begin{bmatrix} 0 & \cdots & 0 \\ a_{21} & \ddots & \vdots \\ \vdots & \ddots & 0 \\ a_{n1} & \cdots & a_{n,n-1} \end{bmatrix}, \quad U = \begin{bmatrix} 0 & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ 0 & \cdots & 0 \end{bmatrix}.$$

Supondremos $a_{ii} \neq 0$. Jacobi usa $B = D$; Gauss–Seidel usa $B = D + L$.

Jacobi actualiza en paralelo

Con $B = D$,

$$Dx^{(k+1)} = -(L + U)x^{(k)} + b,$$

$$x^{(k+1)} = T_J x^{(k)} + c_J, \quad T_J = -D^{-1}(L + U), \quad c_J = D^{-1}b.$$

Componente a componente,

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j \neq i} a_{ij} x_j^{(k)} \right).$$

Todas las componentes nuevas usan exclusivamente la iteración anterior.

Algoritmo de Jacobi

Una iteración completa

Entrada: $A, b, x^{(0)}$, tolerancia y máximo de iteraciones.

1. Para $k = 0, 1, \dots$:
2. Para $i = 1, \dots, n$:
3. $x_i^{\text{nuevo}} \leftarrow (b_i - \sum_{j \neq i} a_{ij} x_j^{(k)}) / a_{ii}$.
4. evaluar residuo y cambio entre iteraciones.
5. si se satisface el criterio, terminar.
6. $x^{(k+1)} \leftarrow x^{\text{nuevo}}$.

Salida: aproximación, residuo, iteraciones y diagnóstico.

Sistema de comparación

Considere

$$A = \begin{bmatrix} 4 & -1 & 0 \\ -1 & 4 & -1 \\ 0 & -1 & 3 \end{bmatrix}, \quad b = \begin{bmatrix} 15 \\ 10 \\ 10 \end{bmatrix}, \quad x^{(0)} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}.$$

La solución exacta es

$$x^* = \begin{bmatrix} 5 \\ 5 \\ 5 \end{bmatrix}.$$

La matriz es simétrica, definida positiva y estrictamente dominante por filas. Estas propiedades anticipan convergencia de Jacobi, Gauss–Seidel y SOR.

Jacobi se aproxima usando valores atrasados

k	$x_1^{(k)}$	$x_2^{(k)}$	$x_3^{(k)}$
0	0.0000	0.0000	0.0000
1	3.7500	2.5000	3.3333
2	4.3750	4.2708	4.1667
3	4.8177	4.6354	4.7569

$$x_1^{(k+1)} = \frac{15 + x_2^{(k)}}{4}, \quad x_2^{(k+1)} = \frac{10 + x_1^{(k)} + x_3^{(k)}}{4}, \quad x_3^{(k+1)} = \frac{10 + x_2^{(k)}}{3}.$$

Los tres valores de la fila $k + 1$ se calculan desde la fila k .

Gauss–Seidel reutiliza valores nuevos

Con $B = D + L$,

$$(D + L)x^{(k+1)} = -Ux^{(k)} + b,$$

$$T_{GS} = -(D + L)^{-1}U.$$

Por componentes,

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j < i} a_{ij} x_j^{(k+1)} - \sum_{j > i} a_{ij} x_j^{(k)} \right).$$

La actualización sigue el orden de las ecuaciones.

Algoritmo de Gauss–Seidel

Actualización en el mismo vector

Entrada: A , b , $x^{(0)}$, tolerancia y máximo de iteraciones.

1. Para $k = 0, 1, \dots$:
2. guardar $x^{\text{anterior}} \leftarrow x$.
3. Para $i = 1, \dots, n$:
4. $x_i \leftarrow (b_i - \sum_{j < i} a_{ij}x_j - \sum_{j > i} a_{ij}x_j^{\text{anterior}}) / a_{ii}$.
5. evaluar residuo y cambio entre iteraciones.
6. si se satisface el criterio, terminar.

Salida: aproximación, residuo, iteraciones y diagnóstico.

Gauss–Seidel avanza dentro de cada barrido

Para el mismo sistema:

k	$x_1^{(k)}$	$x_2^{(k)}$	$x_3^{(k)}$
0	0.0000	0.0000	0.0000
1	3.7500	3.4375	4.4792
2	4.6094	4.7721	4.9240
3	4.9430	4.9668	4.9889

Al calcular $x_2^{(1)}$ ya se usa $x_1^{(1)} = 3.75$; al calcular $x_3^{(1)}$ ya se usa $x_2^{(1)} = 3.4375$.

El radio explica la diferencia observada

Para el ejemplo,

$$\rho(T_J) = \sqrt{\frac{7}{48}} \approx 0.3819, \quad \rho(T_{GS}) = \frac{7}{48} \approx 0.1458.$$

Después de suficientes iteraciones, el error de Gauss–Seidel se contrae mucho más por barrido.

Advertencia

Gauss–Seidel no siempre supera a Jacobi. La comparación depende de la matriz, del orden de las variables y de las posibilidades de paralelización.

La dominancia diagonal es fácil de verificar

$A = (a_{ij})$ es estrictamente dominante por filas si

$$\sum_{j \neq i} |a_{ij}| < |a_{ii}|, \quad i = 1, \dots, n.$$

En ese caso,

$$\|T_J\|_{\infty} = \max_i \frac{\sum_{j \neq i} |a_{ij}|}{|a_{ii}|} < 1.$$

Consecuencia

Jacobi y Gauss–Seidel convergen para cualquier valor inicial. SOR también converge en el intervalo subrelajado $0 < \omega \leq 1$. Estas condiciones son suficientes, pero no necesarias.

La dominancia débil necesita conexión

La dominancia débil exige

$$\sum_{j \neq i} |a_{ij}| \leq |a_{ii}|$$

en todas las filas y desigualdad estricta en al menos una.

Irreducibilidad

La matriz es irreducible si no puede reordenarse en bloques triangulares con un bloque completamente desconectado del otro.

Si A es irreducible y débilmente dominante por filas, entonces $\rho(T_J) < 1$ y Jacobi converge.

Positividad definida y Gauss–Seidel

Si A es real, simétrica y definida positiva, entonces Gauss–Seidel converge para cualquier $x^{(0)}$.

- ▶ No se necesita comprobar dominancia diagonal.
- ▶ La propiedad depende de la estructura global de A .
- ▶ Esta es la misma clase de matrices para la que existe Cholesky.

Dos alternativas

Cholesky es directo; Gauss–Seidel permite detenerse cuando la aproximación ya es suficiente.

Relajar Jacobi modifica la longitud del paso

Primero calcule la propuesta de Jacobi $z^{(k+1)}$ y luego combine

$$x^{(k+1)} = (1 - \omega)x^{(k)} + \omega z^{(k+1)}.$$

En forma matricial,

$$x^{(k+1)} = J(\omega)x^{(k)} + \omega D^{-1}b,$$

$$J(\omega) = (1 - \omega)I - \omega D^{-1}(L + U) = I - \omega D^{-1}A.$$

Para $\omega = 1$ se recupera Jacobi.

Los autovalores orientan el peso de Jacobi

Si los autovalores reales de T_J satisfacen

$$\lambda_1 \leq \dots \leq \lambda_n < 1,$$

los autovalores de $J(\omega)$ son

$$1 - \omega + \omega \lambda_i.$$

El peso que equilibra los dos extremos es

$$\omega_{\text{opt}} = \frac{2}{2 - \lambda_1 - \lambda_n}.$$

Esta fórmula minimiza $\max_i |1 - \omega + \omega \lambda_i|$ bajo las hipótesis indicadas.

SOR relaja cada actualización de Gauss–Seidel

Sea $z_i^{(k+1)}$ la propuesta de Gauss–Seidel:

$$z_i^{(k+1)} = \frac{1}{a_{ii}} \left(b_i - \sum_{j < i} a_{ij} x_j^{(k+1)} - \sum_{j > i} a_{ij} x_j^{(k)} \right).$$

SOR usa

$$x_i^{(k+1)} = (1 - \omega) x_i^{(k)} + \omega z_i^{(k+1)}.$$

ω significa *successive over-relaxation*; también permite subrelajación.

SOR mantiene un sistema triangular

Reordenando las actualizaciones,

$$(D + \omega L)x^{(k+1)} = [(1 - \omega)D - \omega U]x^{(k)} + \omega b.$$

La matriz iterativa es

$$T_{\omega} = (D + \omega L)^{-1}[(1 - \omega)D - \omega U].$$

En cada paso se resuelve un sistema triangular inferior; no se forma $(D + \omega L)^{-1}$.

Algoritmo SOR

Barrido relajado

Entrada: $A, b, x^{(0)}, \omega \neq 0$, tolerancia y máximo.

1. Para $k = 0, 1, \dots$:
2. guardar $x^{\text{anterior}} \leftarrow x$.
3. Para $i = 1, \dots, n$:
4. calcular la propuesta z_i de Gauss–Seidel.
5. $x_i \leftarrow (1 - \omega)x_i^{\text{anterior}} + \omega z_i$.
6. evaluar residuo y cambio entre iteraciones.
7. si se satisface el criterio, terminar.

Salida: aproximación, residuo, iteraciones y diagnóstico.

El parámetro cambia dirección y amplitud

Valor de ω	Interpretación
$0 < \omega < 1$	subrelajación: paso más conservador
$\omega = 1$	Gauss–Seidel
$1 < \omega < 2$	sobrerrelajación: paso más largo

No existe un valor universal

El mejor ω depende de A . Un valor demasiado agresivo puede volver lenta o divergente una iteración que convergía con $\omega = 1$.

SOR solo puede converger dentro de $(0, 2)$

Para la matriz iterativa de SOR se cumple

$$\rho(T_\omega) \geq |\omega - 1|.$$

Por tanto, una condición necesaria de convergencia es

$$0 < \omega < 2.$$

Esta condición no es suficiente para una matriz general.

- ▶ $\omega \leq 0$ no produce una relajación convergente.
- ▶ $\omega \geq 2$ fuerza $\rho(T_\omega) \geq 1$.

En matrices positivas, todo $(0, 2)$ es seguro

Si A es hermitiana definida positiva, entonces SOR converge para

$$0 < \omega < 2.$$

En particular, $\omega = 1$ garantiza la convergencia de Gauss–Seidel.

Lo que aún debe elegirse

La garantía de convergencia no identifica el valor más rápido. Se busca ω que haga pequeño $\rho(T_\omega)$.

Una relajación adecuada acelera el ejemplo

Para el sistema de comparación,

$$\rho(T_J) \approx 0.3819, \quad \rho(T_{GS}) \approx 0.1458.$$

La estructura tridiagonal simétrica permite estimar

$$\omega_{\text{opt}} \approx 1.04, \quad \rho(T_{\omega_{\text{opt}}}) \approx 0.04.$$

Lectura

La mejora es asintótica. El costo por barrido de SOR es casi el mismo que el de Gauss–Seidel, pero la selección de ω requiere información adicional.

El residuo debe controlar la detención

Para una aproximación $x^{(k)}$, calcule

$$r^{(k)} = b - Ax^{(k)}.$$

Un criterio escalado es

$$\frac{\|r^{(k)}\|}{\|A\| \|x^{(k)}\| + \|b\|} \leq \text{tol.}$$

También puede exigirse

$$\frac{\|x^{(k)} - x^{(k-1)}\|}{1 + \|x^{(k)}\|} \leq \text{tol.}$$

Conviene verificar ambos y fijar siempre un máximo de iteraciones.

Un paso pequeño no basta por sí solo

Una actualización pequeña puede aparecer por:

- ▶ convergencia verdadera;
- ▶ un parámetro ω demasiado pequeño;
- ▶ estancamiento por redondeo;
- ▶ mala escala de las variables.

Diagnóstico mínimo

Reporte método, valor inicial, tolerancia, iteraciones, norma del residuo y razón de salida. Si se usa SOR, reporte también ω .

La dispersidad reduce el costo de cada barrido

Si A tiene s elementos no nulos:

- ▶ un barrido de Jacobi, Gauss–Seidel o SOR cuesta $O(s)$;
- ▶ el almacenamiento puede ser $O(s + n)$;
- ▶ no se genera necesariamente el llenado de una factorización directa.

Diferencia computacional

Jacobi separa lectura y escritura y se paraleliza con facilidad. Gauss–Seidel y SOR tienen dependencias dentro de cada barrido.

Comparación de los tres métodos

	Jacobi	Gauss–Seidel	SOR
B	D	$D + L$	$\omega^{-1}D + L$
Nuevos valores	No	Sí	Sí
Parámetro	ninguno	ninguno	ω
Paralelización	sencilla	limitada	limitada
Punto fuerte	simplicidad	mayor contracción	aceleración

La elección depende del problema

Importan la estructura de A , la memoria, la arquitectura de cómputo y la precisión requerida.

La matriz iterativa resume todo el método

1. Elija B fácil de resolver y forme conceptualmente $T = I - B^{-1}A$.
2. Compruebe convergencia mediante $\rho(T) < 1$ o una condición suficiente.
3. Use Jacobi, Gauss–Seidel o SOR según estructura y paralelización.
4. Controle residuo, cambio entre iteraciones y máximo de pasos.
5. Compare costo por barrido y rapidez de contracción.

Cierre del capítulo 3

Los métodos directos transforman o factorizan A ; los iterativos explotan una descomposición sencilla y aceptan una aproximación controlada.