

Mínimos cuadrados

QR, condicionamiento y
aplicaciones

Oswaldo José Velásquez Castañón
Métodos Numéricos – 2026-2



UNIVERSIDAD
DEL PACÍFICO

Objetivos de la clase

- ▶ Resolver mínimos cuadrados mediante factorización QR.
- ▶ Explicar la pérdida de precisión al formar $A^T A$.
- ▶ Reconocer columnas casi dependientes y problemas de escala.
- ▶ Formular ajustes ponderados y regularizados.
- ▶ Distinguir un ajuste en niveles de uno en logaritmos.

Usaremos la misma recta y los mismos datos de la clase anterior.

Ecuaciones normales y cómputo

La caracterización matemática es

$$A^T A \theta = A^T b.$$

Si A tiene rango columna completo, podemos formar $A^T A$, aplicar Cholesky y resolver dos sistemas triangulares.

Dificultad numérica

El producto $A^T A$ puede perder información cuando las columnas de A son casi dependientes. QR trabaja directamente con A .

La equivalencia algebraica entre dos métodos no garantiza la misma precisión.

Condicionamiento

Para una matriz rectangular de rango columna completo,

$$\kappa_2(A) = \frac{\sigma_{\text{máx}}(A)}{\sigma_{\text{mín}}(A)}.$$

Los valores propios de $A^T A$ son los cuadrados de los valores singulares de A . Así,

$$\boxed{\kappa_2(A^T A) = \kappa_2(A)^2.}$$

Si $\kappa_2(A) = 10^6$, el sistema normal tiene condición 10^{12} . Este ejemplo describe el condicionamiento, no una cifra exacta de error final.

Columnas casi dependientes

Considere

$$A_\varepsilon = \begin{bmatrix} 1 & 1 \\ 0 & \varepsilon \end{bmatrix}, \quad A_\varepsilon^T A_\varepsilon = \begin{bmatrix} 1 & 1 \\ 1 & 1 + \varepsilon^2 \end{bmatrix}.$$

La independencia de las columnas depende de ε . Cuando ε^2 queda por debajo de la precisión relativa de la máquina, el cálculo de $1 + \varepsilon^2$ puede redondearse a 1.

Consecuencia

Una matriz de rango completo puede producir un sistema normal singular en aritmética de máquina.

Factorización QR completa

Sea $A \in \mathbb{R}^{m \times n}$, $m \geq n$, de rango n . Escribimos

$$A = Q \begin{bmatrix} R \\ 0 \end{bmatrix}, \quad Q^T Q = I_m, \quad R \in \mathbb{R}^{n \times n}.$$

La matriz R es triangular superior y no singular. Separamos

$$Q^T b = \begin{bmatrix} c \\ d \end{bmatrix}, \quad c \in \mathbb{R}^n, \quad d \in \mathbb{R}^{m-n}.$$

Householder y Givens permiten construir esta factorización con transformaciones ortogonales.

Reducción a un sistema triangular

Como las matrices ortogonales preservan la norma,

$$\begin{aligned}\|A\theta - b\|_2^2 &= \|Q^T(A\theta - b)\|_2^2 \\ &= \|R\theta - c\|_2^2 + \|d\|_2^2.\end{aligned}$$

El segundo término no depende de θ . Por tanto,

$$\boxed{R\theta^* = c}, \quad \boxed{\min_{\theta} \|A\theta - b\|_2 = \|d\|_2}.$$

Una sustitución hacia atrás recupera los coeficientes.

QR reducida

Si $A = Q_1 R$ con $Q_1 \in \mathbb{R}^{m \times n}$ y $Q_1^T Q_1 = I_n$,

$$R\theta^* = Q_1^T b.$$

La proyección y el residuo son

$$\hat{b} = Q_1 Q_1^T b, \quad r = b - \hat{b}.$$

Para el ajuste basta almacenar las primeras n columnas de Q o aplicar sus reflectores directamente a b .

Conexión con el capítulo de QR

La factorización es la misma. Ahora la usamos para resolver un problema de aproximación.

Ejemplo: QR de la matriz de diseño

Para $A = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix}$, una QR reducida es

$$Q_1 = \begin{bmatrix} \frac{1}{2} & -\frac{3}{2\sqrt{5}} \\ \frac{1}{2} & -\frac{1}{2\sqrt{5}} \\ \frac{1}{2} & \frac{1}{2\sqrt{5}} \\ \frac{1}{2} & \frac{3}{2\sqrt{5}} \end{bmatrix}, \quad R = \begin{bmatrix} 2 & 3 \\ 0 & \sqrt{5} \end{bmatrix}.$$

Se verifica $Q_1^T Q_1 = I_2$ y $Q_1 R = A$. La segunda columna ortogonaliza el predictor respecto de la constante.

Ejemplo: sustitución hacia atrás

Con $b = (1, 2, 2, 4)^T$,

$$Q_1^T b = \begin{bmatrix} 4.5 \\ 4.5/\sqrt{5} \end{bmatrix}.$$

Resolvemos

$$\begin{bmatrix} 2 & 3 \\ 0 & \sqrt{5} \end{bmatrix} \begin{bmatrix} c \\ a \end{bmatrix} = \begin{bmatrix} 4.5 \\ 4.5/\sqrt{5} \end{bmatrix}.$$

Primero $a = 4.5/5 = 0.9$. Después,

$$c = \frac{4.5 - 3(0.9)}{2} = 0.9.$$

Obtenemos la misma recta $\hat{y} = 0.9 + 0.9x$.

Algoritmo de mínimos cuadrados

Entrada: matriz A de rango columna completo y vector b .

1. Factorizar A mediante Householder o Givens.
2. Aplicar las transformaciones ortogonales a b .
3. Resolver $R\theta = c$ por sustitución hacia atrás.
4. Calcular $r = b - A\theta$ en las variables originales.
5. Revisar la norma del residuo y $A^T r$.

No se necesita formar una inversa explícita.

Centrado del predictor

Tomamos $t_i = x_i - \bar{x}$ y escribimos

$$\hat{y} = \beta_0 + \beta_1 t.$$

Como $\sum_i t_i = 0$, las columnas 1 y t son ortogonales:

$$A_t^T A_t = \begin{bmatrix} m & 0 \\ 0 & \sum_i t_i^2 \end{bmatrix}.$$

En nuestro ejemplo, $\bar{x} = 1.5$, $\beta_0 = 2.25$ y $\beta_1 = 0.9$. Se recupera el intercepto original mediante

$$c = \beta_0 - \beta_1 \bar{x} = 0.9.$$

Escala de las columnas

Si los predictores tienen unidades o magnitudes muy diferentes, podemos usar

$$t_i = \frac{x_i - \bar{x}}{s_x}, \quad s_x > 0.$$

- ▶ El escalado mejora el equilibrio entre las magnitudes de las columnas.
- ▶ Debemos transformar los coeficientes al interpretar el modelo original.
- ▶ El escalado no elimina una dependencia lineal verdadera.

En bases polinómicas, centrar y escalar resulta especialmente útil.

Rango deficiente y SVD

Si $A = U\Sigma V^T$, una solución de mínima norma es

$$\theta^* = A^+ b = \sum_{j:\sigma_j>0} \frac{u_j^T b}{\sigma_j} v_j.$$

A^+ es la pseudoinversa. Los valores singulares pequeños amplifican las perturbaciones de b .

Rango numérico

En cómputo se usa una tolerancia para decidir qué valores singulares son significativos. QR con pivoteo también ayuda a detectar dependencia.

Mínimos cuadrados ponderados

Con pesos $w_i > 0$, minimizamos

$$\sum_i w_i (y_i - \hat{y}_i)^2 = \|W^{1/2}(A\theta - b)\|_2^2, \quad W = \text{diag}(w_1, \dots, w_m).$$

La formulación equivalente es

$$\tilde{A} = W^{1/2}A, \quad \tilde{b} = W^{1/2}b.$$

Aplicamos QR a $\tilde{A}$. Si las observaciones tienen varianzas conocidas y errores independientes, una elección habitual es $w_i = 1/\sigma_i^2$.

Regularización de Tikhonov

Para limitar coeficientes grandes, consideramos

$$J_{\lambda}(\theta) = \|A\theta - b\|_2^2 + \lambda \|\theta\|_2^2, \quad \lambda > 0.$$

Las condiciones de optimalidad son

$$(A^T A + \lambda I)\theta^* = A^T b.$$

Como $A^T A + \lambda I$ es definida positiva, el minimizador es único, incluso si A tiene rango deficiente. El parámetro λ equilibra ajuste y tamaño de los coeficientes.

Regularización mediante QR

La misma función objetivo puede escribirse como

$$J_{\lambda}(\theta) = \left\| \begin{bmatrix} A \\ \sqrt{\lambda} I \end{bmatrix} \theta - \begin{bmatrix} b \\ 0 \end{bmatrix} \right\|_2^2.$$

Así resolvemos un problema aumentado de mínimos cuadrados.

Penalización selectiva

Si queremos penalizar solo algunos coeficientes, reemplazamos I por una matriz L y usamos $\lambda \|L\theta\|_2^2$. La unicidad exige $\mathcal{N}(A) \cap \mathcal{N}(L) = \{0\}$.

Demostración del mínimo regularizado

Si $(A^T A + \lambda I)\theta^* = A^T b$, entonces

$$J_\lambda(\theta^* + h) - J_\lambda(\theta^*) = \|Ah\|_2^2 + \lambda \|h\|_2^2.$$

El miembro derecho es positivo para $h \neq 0$.

Conclusión

θ^* es el único mínimo global. La penalización añade curvatura positiva en todas las direcciones.

Esta identidad permite verificar la solución sin invocar únicamente el gradiente.

Modelo de potencia

Un modelo $y = bx^a$, con $x, y > 0$ y $b > 0$, se transforma en

$$\ln y = \ln b + a \ln x.$$

Con $z_i = \ln x_i$ y $v_i = \ln y_i$, ajustamos

$$v_i \approx \theta_0 + \theta_1 z_i, \quad b = e^{\theta_0}, \quad a = \theta_1.$$

Objetivo que cambia

El ajuste minimiza errores cuadrados en logaritmos. Minimizar errores cuadrados en niveles define un problema distinto.

Bases trigonométricas

Para aproximar datos periódicos, podemos elegir

$$\hat{y}(x) = \theta_0 + \theta_1 \sin x + \theta_2 \cos x.$$

Entonces

$$A = \begin{bmatrix} 1 & \sin x_1 & \cos x_1 \\ \vdots & \vdots & \vdots \\ 1 & \sin x_m & \cos x_m \end{bmatrix}.$$

La selección de la base incorpora estructura al modelo. Los coeficientes se obtienen con el mismo procedimiento QR.

Validación del ajuste

- ▶ Residuo: calcular $\|b - A\theta\|_2$ en las unidades originales.
- ▶ Optimalidad: comprobar que $A^T(b - A\theta)$ es pequeño respecto de las escalas.
- ▶ Rango: examinar valores singulares o la factorización con pivoteo.
- ▶ Modelo: buscar patrones sistemáticos en los residuos.
- ▶ Predicción: evaluar con datos que no participaron en el ajuste.

La estabilidad del algoritmo y la adecuación del modelo son propiedades distintas.

Actividad de clase

Use $t_i = x_i - 1.5$ para los datos de la clase y ajuste $\beta_0 + \beta_1 t_i$.

1. Compruebe que las columnas 1 y t son ortogonales.
2. Recupere $\beta_0 = 2.25$ y $\beta_1 = 0.9$ mediante QR.
3. Penalice solo la pendiente con $\lambda = 1$.
4. Verifique que la nueva pendiente es 0.75.
5. Calcule el nuevo error de ajuste y explique el compromiso introducido.

Ejercicio original: ajuste trigonométrico

Ajuste los datos mediante una combinación lineal de 1, $\sin x$ y $\cos x$:

x_i	1.1	1.9	2.7	4.3	5.1	7.8
y_i	11.2	16.8	18.7	8.1	2.7	14.3

1. Escriba la matriz de diseño y las ecuaciones normales.
2. Resuelva el problema usando QR.
3. Calcule los valores ajustados y la norma del residuo.

Notas del curso, capítulo Aproximación lineal, ejercicio 1

Ejercicio original: regularización

Sea $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$ y $\alpha > 0$. Defina

$$F(\theta) = \|A\theta - b\|_2^2 + \alpha \|\theta\|_2^2.$$

Demuestre que F alcanza su único mínimo en la solución de

$$(A^T A + \alpha I)\theta = A^T b.$$

Para esa solución, pruebe la identidad

$$F(\theta + h) = F(\theta) + \|Ah\|_2^2 + \alpha \|h\|_2^2.$$

Notas del curso, ejercicio 2, identidad algebraica corregida

Ejercicio original: sistema transpuesto

Encuentre la solución en mínimos cuadrados de

$$\begin{bmatrix} u & v \end{bmatrix} \begin{bmatrix} 3 & 2 & 1 \\ 2 & 3 & 2 \end{bmatrix} = \begin{bmatrix} 3 & 0 & 1 \end{bmatrix}.$$

1. Transponga la expresión y formule $A\theta \approx b$.
2. Obtenga y resuelva las ecuaciones normales.
3. Verifique que el residuo es ortogonal a las columnas de A .

Notas del curso, capítulo Aproximación lineal, ejercicio 3

Ejercicio original: modelo de potencia

Las notas recogen datos de peso W (gramos) y consumo de oxígeno R (mililitros por hora) para larvas de *Pachysphinx modesta*.

W	.017	.087	.085	.020	.233	4.83	5.53
R	.154	.296	.260	.180	.537	4.66	6.94

Ajuste el modelo $R = bW^a$ mediante logaritmos.

1. Obtenga a y b por mínimos cuadrados.
2. Calcule el error en logaritmos y el error en la escala original.

Datos reproducidos de las notas del curso, ejercicio 4, atribuidos allí a L. Schroeder

Ejercicio original: modelo ampliado

Con los mismos datos, ajuste

$$R = bW^a W^{c \ln W}.$$

Tomar logaritmos da

$$\ln R = \ln b + a \ln W + c(\ln W)^2.$$

1. Construya la matriz de diseño de tres columnas.
2. Calcule los nuevos parámetros mediante QR.
3. Compare el error en logaritmos con el modelo anterior.
4. Explique qué garantiza agregar una columna al espacio de ajuste.

Cierre de la clase

- ▶ QR reduce mínimos cuadrados a un sistema triangular.
- ▶ Formar $A^T A$ eleva al cuadrado el número de condición.
- ▶ Centrado, escala y rango influyen en la calidad numérica.
- ▶ Los pesos y la regularización modifican el objetivo de aproximación.

El siguiente capítulo estudia interpolación y la construcción de funciones que cumplen condiciones exactas en los nodos.