Optimización sin restricciones

Descenso del gradiente y búsqueda lineal

Oswaldo José Velásquez Castañón

Métodos Numéricos – 2026-2

Dirección y longitud de paso

Buscamos minimizar una función diferenciable $f : \mathbb{R}^n \to \mathbb{R}$.

$$g_k = \nabla f(x_k), \qquad x_{k+1} = x_k + \alpha_k p_k, \qquad \alpha_k > 0.$$

Si $g_k^{\mathsf{T}} p_k < 0$, un desplazamiento suficientemente corto en dirección p_k reduce f.

Descenso del gradiente

Con $p_k = -g_k$, la derivada direccional es $-\|g_k\|^2$. La dirección normalizada es la de descenso más rápido en norma euclidiana.

Estudiaremos primero un paso constante α y luego cómo elegir α_k en cada iteración.

Convexidad y optimalidad

La convexidad exige que para $0 \leq t \leq 1$,

$$f((1-t)x + ty) \leq (1-t)f(x) + tf(y).$$

Si f es diferenciable, equivale a que todo plano tangente sea soporte inferior.

$$f(y) \geq f(x) + \nabla f(x)^{\mathsf{T}}(y - x).$$

Consecuencia

En una función convexa diferenciable, $\nabla f(x^*) = 0$ caracteriza un mínimo global. En general, un mínimo local diferenciable solo exige estacionariedad como condición necesaria.

El tamaño de paso en una cuadrática

Para $f(x) = x^2$, el descenso satisface $x_{k+1} = (1 - 2\alpha)x_k$. Con $x_0 \neq 0$ y paso constante,

Paso	Comportamiento
$0 < \alpha < 1$	Converge a 0
$\alpha = 1$	Alterna entre x_0 y $-x_0$
$\alpha > 1$	Diverge en magnitud

También puede fallar un paso variable que disminuye muy rápido. Con $\alpha_k = 1/[2(k+2)^2]$, el producto de los factores $1 - 2\alpha_k$ tiende a $1/2$.

Wegner, *Mathematische Einführung in Data Science*, cap. 17

Suavidad y modelo cuadrático superior

El gradiente es L-Lipschitz si $\|\nabla f(y) - \nabla f(x)\| \le L\,\|y - x\|$. Con $s = y - x$, integramos la derivada sobre el segmento.

$$f(x+s) - f(x) - \nabla f(x)^{\mathsf{T}} s = \int_0^1 [\nabla f(x + ts) - \nabla f(x)]^{\mathsf{T}} s \, dt \le \tfrac{L}{2}\,\|s\|^2 .$$

Descenso con paso fijo

Al usar $s = -\alpha \nabla f(x)$,

$$f(x+s) \le f(x) - \alpha(1 - L\alpha/2)\,\|\nabla f(x)\|^2 .$$

Para $0 < \alpha < 2/L$ hay descenso cuando $\nabla f(x) \neq 0$.

Convexidad y suavidad combinadas

Si f es convexa y L-suave,

$$f(u) - f(v) - \nabla f(v)^{\mathsf{T}}(u - v) \geq \frac{1}{2L} \|\nabla f(u) - \nabla f(v)\|^2 .$$

Demostración

Sea $h(z) = f(z) - \nabla f(v)^{\mathsf{T}} z$. Es convexa y v la minimiza. El modelo superior con paso $1/L$ da

$$h(v) \leq h\Big(u - \nabla h(u)/L\Big) \leq h(u) - \frac{1}{2L} \|\nabla h(u)\|^2 .$$

Al sustituir h se obtiene la desigualdad.

Wegner, *Mathematische Einführung in Data Science*, cap. 17

Convergencia sublineal con paso $1/L$

Supongamos que f es convexa y L-suave y que existe x^*. Sea $\delta_k = f(x_k) - f(x^*)$ y $R = \|x_0 - x^*\|$.

1. Al expandir $\|x_k - x^* - g_k/L\|^2$ y aplicar la desigualdad anterior con $u = x^*$, la distancia a x^* decrece en sentido no estricto.
2. Por convexidad, $\delta_k \leq R\,\|g_k\|$. Por suavidad, $\delta_k - \delta_{k+1} \geq \|g_k\|^2/(2L)$.
3. Mientras $\delta_{k+1} > 0$, esto da $1/\delta_{k+1} - 1/\delta_k \geq 1/(2LR^2)$.

$$\delta_k \leq \frac{2LR^2}{k}, \qquad k \geq 1.$$

Una subsucesión acotada converge a un minimizador. La distancia a ese minimizador decrece, de modo que converge toda la sucesión.

Wegner, *Mathematische Einführung in Data Science*, cap. 17

Convexidad fuerte y suavidad

f es μ-fuertemente convexa si $f(x) - \mu \|x\|^2/2$ es convexa para $\mu > 0$. Junto con la suavidad se obtiene

$$\tfrac{\mu}{2}\|y-x\|^2 \le f(y) - f(x) - \nabla f(x)^{\mathsf{T}}(y-x) \le \tfrac{L}{2}\|y-x\|^2 .$$

- La cota inferior implica coercividad y, por continuidad, existe un mínimo. La convexidad estricta garantiza que sea único.
- Ambas cotas implican $\mu \le L$. Si f es C^2, equivalen a $\mu I \preceq \nabla^2 f(x) \preceq LI$.

El cociente $\kappa = L/\mu$ compara la curvatura máxima con la mínima.

Wegner, *Mathematische Einführung in Data Science*, cap. 17

Desigualdad de interpolación de Wegner

Con $s = y - x$ y $d = \nabla f(y) - \nabla f(x)$,

$$d^{\mathsf{T}} s \geq \frac{\mu L}{\mu + L} \|s\|^2 + \frac{1}{\mu + L} \|d\|^2 .$$

Para $L > \mu$, $h(x) = f(x) - \mu \|x\|^2 / 2$ es convexa y su modelo superior tiene constante $L - \mu$. Aplicamos la desigualdad anterior a h en ambos órdenes y sumamos.

$$(d - \mu s)^{\mathsf{T}} s \geq \frac{\|d - \mu s\|^2}{L - \mu}.$$

Al desarrollar el cuadrado se obtiene el resultado. Si $L = \mu$, las cotas coinciden y $d = \mu s$.

Wegner, *Mathematische Einführung in Data Science*, cap. 17, lema 17.22.

El paso que cancela el término del gradiente

Sea $e_k = x_k - x^*$ y $g_k = \nabla f(x_k)$. Como $\nabla f(x^*) = 0$, la desigualdad anterior aplicada a x^* y x_k da

$$\begin{aligned}\|e_{k+1}\|^2 &= \|e_k\|^2 - 2\alpha g_k^{\mathsf{T}} e_k + \alpha^2 \|g_k\|^2 \\ &\leq \left(1 - \frac{2\alpha\mu L}{\mu + L}\right)\|e_k\|^2 + \left(\alpha^2 - \frac{2\alpha}{\mu + L}\right)\|g_k\|^2 .\end{aligned}$$

Elección de Wegner

Con $\alpha = 2/(\mu + L)$ desaparece el último término y queda

$$\|e_{k+1}\| \leq q\,\|e_k\|, \qquad q = \frac{L - \mu}{L + \mu}.$$

Wegner, *Mathematische Einführung in Data Science*, cap. 17

Tasa lineal y condicionamiento

$$\|x_k - x^*\| \le q^k \|x_0 - x^*\|, \qquad f(x_k) - f(x^*) \le \tfrac{L}{2} q^{2k} \|x_0 - x^*\|^2 .$$

La segunda cota usa el modelo superior en x^*.

$\kappa = L/\mu$	q en distancia	q^2 en la cota del objetivo
2	$1/3$	$1/9$
8	$7/9$	$49/81$
100	$99/101$	$(99/101)^2$

Con κ grande, la garantía de reducción por iteración es pequeña. £Cómo elegir el paso cuando μ y L son difíciles de estimar?

La función sobre la dirección de descenso

En la iteración actual fijamos x y p, con $\nabla f(x)^{\mathsf{T}} p < 0$.

$$\phi(\alpha) = f(x + \alpha p), \qquad \phi'(\alpha) = \nabla f(x + \alpha p)^{\mathsf{T}} p.$$

Una búsqueda lineal inexacta evalúa candidatos hasta encontrar un paso que cumpla las condiciones de aceptación.

Ejemplo para las dos condiciones

Tomamos $\phi(\alpha) = (\alpha - 1)^2$, con $\phi(0) = 1$, $\phi'(0) = -2$ y mínimo en $\alpha = 1$.

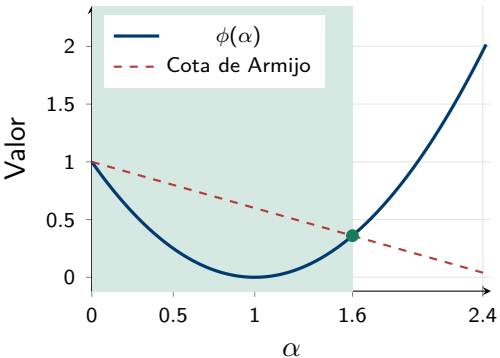
Armijo y disminución suficiente

Para $0 < c_1 < 1$ se exige

$$\phi(\alpha) \leq \phi(0) + c_1 \alpha \phi'(0).$$

Con $c_1 = 0.2$, la recta de aceptación es $1 - 0.4\alpha$.

El gráfico sombrea los pasos positivos que cumplen Armijo. Aquí, $0 < \alpha \leq 1.6$.



Retroceso de Armijo

Se fija un paso de prueba $\bar{\alpha} > 0$ y un factor $0 < \rho < 1$. Se prueban $\bar{\alpha}, \rho\bar{\alpha}, \rho^2\bar{\alpha}, \ldots$ hasta que se cumpla Armijo.

$$\phi(\alpha) - \phi(0) - c_1\alpha\phi'(0) = (1 - c_1)\alpha\phi'(0) + o(\alpha).$$

Como $\phi'(0) < 0$, los pasos positivos suficientemente pequeños se aceptan.

En el gráfico anterior

Con $\bar{\alpha} = 2.4$ y $\rho = 1/2$, se rechaza 2.4 y se acepta 1.2. También se aceptaría 0.25 si fuera el primer candidato.

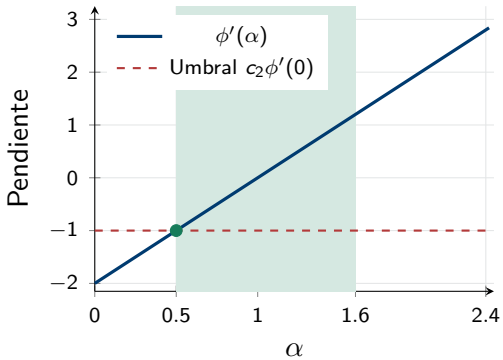
Powell–Wolfe y condición de curvatura

Con $0 < c_1 < c_2 < 1$, se pide Armijo y además

$$\phi'(\alpha) \geq c_2 \phi'(0).$$

Para $c_2 = 0.5$, se requiere $2(\alpha - 1) \geq -1$. La pendiente en 0.25 es -1.5 y falla la segunda condición.

Ambas se cumplen en $[0.5, 1.6]$**.**



Expansión y bisección para Powell–Wolfe

1. Si el candidato cumple las dos condiciones, se acepta.
2. Si cumple Armijo pero la pendiente sigue por debajo del umbral, se guarda como extremo inferior. Mientras falte un extremo superior, se duplica el paso.
3. Si falla Armijo, se guarda como extremo superior. Con ambos extremos, el próximo candidato es el punto medio. El extremo inferior puede empezar en 0.

Con $\bar{\alpha} = 2.4$ en el ejemplo

2.4 falla Armijo. La bisección de $[0, 2.4]$ prueba 1.2, que cumple ambas.

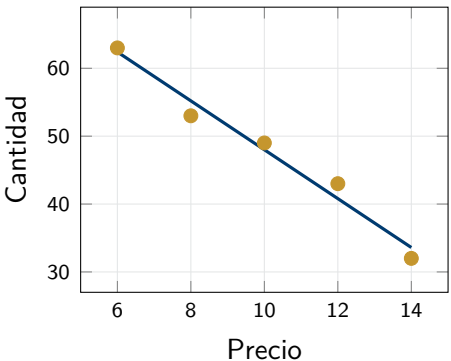
La prueba de curvatura requiere evaluar el gradiente. El laboratorio registra ese costo y limita el número de intentos.

Ajuste de una curva de demanda

Con precios P_i y cantidades Q_i simulados, estimamos $\widehat{Q}(P) = a + b(P - 10)$.

$$\min_{a,b\in\mathbb{R}} \frac{1}{10} \sum_{i=1}^{5} \Big[a + b(P_i - 10) - Q_i\Big]^2.$$

En $P = 10$ la demanda ajustada es $a^* = 48$. Una unidad adicional de precio se asocia con 3.6 unidades menos de demanda.



El paso fijo en el ajuste de demanda

Los precios centrados tienen media 0 y segundo momento 8. Por ello,

$$H = \begin{pmatrix} 1 & 0 \\ 0 & 8 \end{pmatrix}, \qquad \mu = 1, \quad L = 8, \quad \alpha = 2/9.$$

Con el paso fijo, el error en a se multiplica por $7/9$ y el error en b por $-7/9$. La pendiente estimada alterna alrededor de $b^* = -3.6$.

Comparación en el cuaderno

Desde $(a_0, b_0) = (44, -1)$, se compara la distancia al ajuste de referencia y el costo de las tres reglas de paso.

Rosenbrock y protocolo de comparación

$$f(x, y) = (1 - x)^2 + 100(y - x^2)^2.$$

El mínimo global está en $(1, 1)$. El valle curvo permite observar un comportamiento distinto al de la cuadrática de demanda.

- En cada problema se mantiene el mismo punto inicial y criterio de parada para los tres métodos.
- El cuaderno registra $f(x_k) - f(x^*)$, $\|\nabla f(x_k)\|$ y las evaluaciones de función y gradiente.
- Los contornos muestran cuánto avanza cada trayectoria dentro del mismo presupuesto de iteraciones.

Material de laboratorio y referencias

- Cuaderno `Optimizacion_Descenso_Gradiente_2026-2.ipynb`. Incluye las dos gráficas de búsqueda lineal, el ajuste de demanda y la comparación en Rosenbrock.
- Wegner, *Mathematische Einführung in Data Science*, cap. 17. Descenso con paso fijo para funciones convexas.
- Armijo (1966), *Minimization of functions having Lipschitz continuous first partial derivatives*.
- Wolfe (1969), *Convergence Conditions for Ascent Methods*.